

MANUEL PROFESSIONNEL · ÉDITION 2026

Module M01 — Fondamentaux de la donnée

La Voie des Données · Édition 2026 · 8 chapitres, exercices
guidés et corrigés, projet noté, évaluation

Analyse de données appliquée & Business Intelligence
11 partie(s) assemblée(s) · document de production

Table des matières

M01 — LIRE LES DONNÉES ET COMPRENDRE LE MÉTIER DE L'ANALYSE	8
Promesse du module	8
Carte des chapitres	8
Prérequis	9
Outils à installer avant de commencer	9
Les données de travail du module	9
Livrables attendus du module	10
Comment travailler ce module (méthode recommandée)	10
Ce qui vient après	10
M01.C01 — SE REPÉRER DANS UN ORDINATEUR DE TRAVAIL : DOSSIERS, FICHIERS, EXTENSIONS, CHEMINS, SAUVEGARDES	11
1. Objectifs du chapitre	11
2. Pourquoi cette notion est importante	11
3. Explication simple	12
4. Vocabulaire essentiel	12
5. Cours approfondi	13
5.1 Les quatre façons d'écrire une adresse	13
5.2 Extensions : ce que chaque format protège	14
5.3 L'arborescence de travail du manuel — à copier	14
5.4 Nommage des fichiers : la grammaire complète	15
5.5 Sauvegarder : la règle 3-2-1, et son test	15
5.6 Retrouver un fichier : trois méthodes, dans l'ordre	16
5.7 Le journal : votre première obligation professionnelle	16
6. Exemple concret : la même donnée en trois formats	17
7. Démonstration pas à pas : préparer le poste en 12 minutes	17
8. Erreurs fréquentes	18
9. Bonnes pratiques professionnelles	19
10. Exercice guidé — ranger un dossier de travail réel	19
11. Exercices autonomes	20
12. Correction détaillée	20
13. Mini-projet M01.P1 — « Mon poste prêt pour 22 modules » (45 min)	21
14. Résumé du chapitre	22
15. À retenir	22
16. Évaluation formative (auto-correction, 6 min)	22
M01.C02 — DONNÉE, INFORMATION, CONNAISSANCE, DÉCISION : CE QUE VOTRE TRAVAIL AJOUTE RÉELLEMENT	23
1. Objectifs du chapitre	11
2. Pourquoi cette notion est importante	11
3. Explication simple	12

4. Vocabulaire essentiel	12
5. Cours approfondi	13
5.1 Les quatre maillons, avec leurs tests de validité	25
5.2 Les six phrases d'une demande professionnelle, et comment les ouvrir	26
5.3 La question analytique : une grammaire, cinq composants	26
5.4 Un chiffre n'est jamais seul : ce qu'il faut dire autour	27
5.5 Le triangle de la décision : coût, délai, preuve	28
6. Exemple concret : la même ligne, quatre niveaux	28
7. Démonstration pas à pas : ouvrir une demande et la rendre traitable	29
8. Erreurs fréquentes	18
9. Bonnes pratiques professionnelles	19
10. Exercice guidé — les cinq demandes du patron, faites ensemble	30
11. Exercices autonomes	20
12. Correction détaillée	20
13. Mini-projet M01.P2 — « Le cahier des questions du magasin » (40 min)	33
14. Résumé du chapitre	22
15. À retenir	22
16. Évaluation formative (auto-correction, 8 min)	33
M01.C03 — LA TABLE : LIGNES, COLONNES, CELLULES, EN-TÊTES, IDENTIFIANTS	35
1. Objectifs du chapitre	11
2. Pourquoi cette notion est importante	11
3. Explication simple	12
4. Vocabulaire essentiel	12
5. Cours approfondi	13
5.1 Les six phrases de la fiche d'identité d'une table	37
5.2 Le grain, seul concept qui compte au début	38
5.3 Compter comme un analyste : lignes, objets, valeurs distinctes	38
5.4 Les trois mises en forme qui détruisent une table	39
5.5 Les bornes, ou comment trouver une anomalie sans la chercher	40
5.6 Large, long, et le tableau « de rapport »	40
6. Exemple concret : lire les deux premiers fichiers du socle	41
7. Démonstration pas à pas : la fiche d'identité complète, avec les deux tableurs	41
8. Erreurs fréquentes	18
9. Bonnes pratiques professionnelles	19
10. Exercice guidé — décrire la table clients en 8 minutes	43
11. Exercices autonomes	20
12. Correction détaillée	20
13. Mini-projet M01.P3 — « Fiche d'identité de trois tables » (50 min)	45
14. Résumé du chapitre	22
15. À retenir	22
16. Évaluation formative (auto-correction, 10 min)	46

M01.C04 — TYPES DE DONNÉES ET CE QU'ILS AUTORISENT : TEXTE, NOMBRE, DATE, BOOLÉEN, MONTANT	48
1. Objectifs du chapitre	11
2. Pourquoi cette notion est importante	11
3. Explication simple	12
4. Vocabulaire essentiel	12
5. Cours approfondi	13
5.1 Ce que le CSV ne dit pas — et pourquoi c'est le cœur du métier	50
5.2 Les cinq signes visibles d'un nombre stocké en texte	50
5.3 Les dates : le format n'est pas le type, et l'ordre des morceaux n'est pas une convention	51
5.4 Taux, proportions, pourcentages : la colonne remise	52
5.5 Booléens et drapeaux : un type tout simple, trois catastrophes classiques	52
5.6 Convertir sans casser : le protocole en six temps	52
5.7 Types, tailles de fichier et performance : ce que « bien typer » rapporte	53
6. Exemple concret : la colonne qui a l'air juste	54
7. Démonstration pas à pas : le protocole complet sur montant_ttc	54
8. Erreurs fréquentes	18
9. Bonnes pratiques professionnelles	19
10. Exercice guidé — la grille de typage du fichier de l'atelier	56
11. Exercices autonomes	20
12. Correction détaillée	20
13. Mini-projet M01.P4 — « Le dictionnaire de types » (45 min)	58
14. Résumé du chapitre	22
15. À retenir	22
16. Évaluation formative (auto-correction, 10 min)	46
M01.C05 — STRUCTURÉES, SEMI-STRUCTURÉES, NON STRUCTURÉES ; QUALITATIVES ET QUANTITATIVES	61
1. Objectifs du chapitre	11
2. Pourquoi cette notion est importante	11
3. Explication simple	12
4. Vocabulaire essentiel	12
5. Cours approfondi	13
5.1 Les trois enveloppes, et le vrai coût de chacune	64
5.2 Le JSON en cinq minutes, parce que vous allez en rencontrer	64
5.3 Les quatre propriétés d'un fichier plat, et comment les vérifier sans outil	65
5.4 Qualitatif et quantitatif : les cas qui font discuter, tranchés	65
5.5 Quelle statistique pour quelle nature : la table qu'il faut avoir en tête	66
5.6 Choisir l'outil selon l'enveloppe et le volume : la première grille de décision	67
6. Exemple concret : vingt exemples réels, classés en six minutes	68
7. Démonstration pas à pas : trier un lot de fichiers livré par un client	69
8. Erreurs fréquentes	18
9. Bonnes pratiques professionnelles	19
10. Exercice guidé — classer les 13 colonnes de l'atelier, avec justification	71

11. Exercices autonomes	20
12. Correction détaillée	20
13. Mini-projet M01.P5 — « La carte d'identité du lot » (40 min)	73
14. Résumé du chapitre	22
15. À retenir	22
16. Évaluation formative (auto-correction, 12 min)	74
M01.C06 — LE CYCLE DE VIE D'UNE DONNÉE : NAISSANCE, STOCKAGE, TRANSFORMATION, USAGE, ARCHIVAGE, SUPPRESSION	75
1. Objectifs du chapitre	11
2. Pourquoi cette notion est importante	11
3. Explication simple	12
4. Vocabulaire essentiel	12
5. Cours approfondi	13
5.1 Les six étapes, avec leur preuve documentaire	77
5.2 Le dictionnaire de données : votre premier document professionnel	78
5.3 Versionner un jeu de données : trois mécaniques, par ordre de sérieux	79
5.4 Journal de transformation : le format, et cinq exemples	79
5.5 Les points de rupture : où votre chiffre meurt réellement	80
5.6 Conserver, purger, protéger : la politique en une page	80
6. Exemple concret : une ligne, trente-deux mois, six fichiers	81
7. Démonstration pas à pas : reconstruire le cycle d'un fichier reçu	82
8. Erreurs fréquentes	18
9. Bonnes pratiques professionnelles	19
10. Exercice guidé — reconstituer l'histoire d'un dossier à charge	84
11. Exercices autonomes	20
12. Correction détaillée	20
13. Mini-projet M01.P6 — « Dossier d'archivage d'une publication » (35 min)	86
14. Résumé du chapitre	22
15. À retenir	22
16. Évaluation formative (auto-correction, 10 min)	46
M01.C07 — LES MÉTIERS DE LA DONNÉE, LA CHAÎNE DE VALEUR, ET L'ANATOMIE D'UNE ANALYSE	88
1. Objectifs du chapitre	11
2. Pourquoi cette notion est importante	11
3. Explication simple	12
4. Vocabulaire essentiel	12
5. Cours approfondi	13
5.1 Les cinq métiers, vus par ce qu'ils livrent	90
5.2 La chaîne de valeur, et où l'on gagne réellement de l'argent	91
5.3 L'anatomie d'une analyse : six temps, avec leurs durées	91
5.4 Passer d'une demande floue à une question correcte : l'algorithme complet	92
5.5 Quel outil choisir, et pourquoi : la grille définitive du socle	93
5.6 Anatomie d'une note de résultat : le format qui fait décider	94

6. Exemple concret : le cas complet, de la demande à la note	95
7. Démonstration pas à pas : le formulaire de cadrage, rempli en 18 minutes	96
8. Erreurs fréquentes	18
9. Bonnes pratiques professionnelles	19
10. Exercice guidé — trois demandes, trois cadrages	97
11. Exercices autonomes	20
12. Correction détaillée	20
13. Mini-projet M01.P7 — « Trois cadrages pour un même sujet » (50 min)	100
14. Résumé du chapitre	22
15. À retenir	22
16. Évaluation formative (auto-correction, 12 min)	74
M01 — BILAN DE COMPÉTENCES ET AUTO-POSITIONNEMENT	102
1. Je sais maintenant (vocabulaire — à cocher, et à définir de ma main)	102
2. Je suis capable de (gestes professionnels)	102
3. Outils maîtrisés à la sortie du module	103
4. Niveau atteint	103
5. Pour passer au module suivant	104
6. Auto-questionnement dirigé (à écrire, 15 minutes)	104
PROJET M01.P — « UN PETIT FICHER DE VENTES, UNE PREMIÈRE FOIS »	106
1. Énoncé	106
Le matériel	106
Les quatre livrables	106
Contraintes de rendu	107
2. Barème détaillé	107
3. Correction pas à pas (corrigé enseignant)	107
3.1 — Réponse L1 : la fiche d'identité, telle qu'elle doit être rendue	107
3.2 — Réponse L2 : les trois questions, avec leurs limites	108
3.3 — Réponse L3 : la méthode par tri et filtre, et les trois résultats	109
3.4 — Réponse L4 : ce à quoi ressemble un autoportrait utile	110
3.5 — Le fichier du fournisseur, traité à part (bonus +1, pas obligatoire)	110
4. Grille d'auto-évaluation avant rendu	110
5. Ce que le correcteur regardera en premier	110
ÉVALUATION DU MODULE M01 — RÉCUPÉRATION, QUIZ, EXERCICES, ÉTUDE DE CAS, CORRIGÉS	111
A. Questions de récupération (non notées, à traiter avant le quiz)	111
B. Quiz — 15 questions, noté sur 20	112
Frontières du vocabulaire (Q1 à Q4)	112
Structure et lecture d'une table (Q5 à Q9)	112
Types, formats, encodages (Q10 à Q13)	112
Posture et méthode (Q14 et Q15)	112
C. Exercices pratiques (4) — séries E1 et E2, auto-correction	113
D. Étude de cas — « Le patron veut savoir des choses » (20 points, seuil 12)	113

Corrigé de l'évaluation (à consulter après traitement complet)	114
B. Quiz — réponses et explications	114
C. Exercices — corrigés détaillés	115
D. Étude de cas — cinq cadrages attendus	116
Total et décision d'orientation	117

M01 — Lire les données et comprendre le métier de l'analyse

Phase 0 · Culture numérique et posture professionnelle · 7 chapitres · 30 h · 525 pages disponibles à la fin de M07

Ce que ce module vous apporte, en une phrase. Vous allez apprendre à **lire** une donnée avant d'apprendre à la calculer : reconnaître une table, son grain, ses types, son format, sa provenance — et formuler la question qui rendra le calcul utile. Aucun autre module du parcours ne vous rendra aussi vite opérationnel sur un poste réel.

Promesse du module

À la fin du module M01, vous êtes capable de :

- ouvrir un dossier de travail, **nommer** vos fichiers selon une convention qui survivra à trois ans, et **retrouver** en deux minutes l'origine d'un chiffre ;
- décrire une table en six phrases, dire ce que représente **une ligne**, et ne plus jamais confondre 489 lignes avec 316 ventes ;
- détecter, sans logiciel spécialisé, qu'une colonne de montants est du **texte** (ici 486 lignes sur 489) et expliquer ce que ça casse ;
- lire un fichier livré par un fournisseur en **;**, encodé en **Windows-1252**, à virgule décimale et chapeau de trois lignes — sans le qualifier de « corrompu » ;
- classer une variable (quantitative discrète, continue, nominale, ordinale) et **refuser** le calcul qu'elle ne permet pas ;
- raconter le **cycle de vie** complet d'une ligne de vente, et produire les trois documents qui rendent un chiffre défendable : dictionnaire, journal de transformation, manifeste ;
- écrire une **question analytique** correcte à partir d'une demande floue, et choisir l'outil qui convient en le justifiant.

Carte des chapitres

Chap.	Titre	Compétence visée	Outil	H
C01	Se repérer dans un ordinateur de travail	ne plus perdre un fichier, comprendre un chemin, sauvegarder pour de vrai	Explorateur Windows	4
C02	Donnée, information, connaissance, décision	formuler la différence avec des exemples de son environnement	papier	3
C03	La table : lignes, colonnes, cellules, en-têtes, identifiants	lire une table et la décrire en langage clair	Excel / LibreOffice	5
C04	Types de données et ce qu'ils autorisent	détecter un « nombre stocké en texte » et expliquer le dégât	Excel / LibreOffice	5
C05	Structuré, semi-structuré, non structuré ; qualitatif, quantitatif	classer 20 exemples réels, choisir les statistiques licites	tableur + éditeur de texte	4
C06	Le cycle de vie d'une donnée	retracer une ligne de la caisse au rapport annuel, documenter	schéma + traitement de texte	4
C07	Métiers de la donnée et anatomie d'une analyse	cadrer une demande floue, choisir son outil et le justifier	traitement de texte	5

Chap.	Titre	Compétence visée	Outil	H
—	Projet M01.P	livrable évalué : fiche d'identité, questions, réponse chiffrée, autoportrait	tableur	5

Total : **30 h** (25 h de chapitres + 5 h de projet et d'évaluation), conformément au programme validé.

Prérequis

Aucun, sauf savoir utiliser une souris, un clavier et un navigateur. Le chapitre C01 prend en charge tout le reste, y compris « comment est rangé un ordinateur ». Si vous avez déjà pratiqué un tableur, commencez par l'exercice 3.1 : s'il vous semble évident, allez au C04 en lisant C03 en diagonale — mais ne sautez pas C02, dont le vocabulaire sert jusqu'au module 22.

Outils à installer avant de commencer

Outil	Version visée (vérifiée septembre 2026)	Rôle dans le module	Alternative libre
LibreOffice Calc	24.8 ou supérieur	tous les exercices de tableur	—
Microsoft Excel	2021 / Microsoft 365	équivalent selon votre poste	LibreOffice suffit ici
Un éditeur de texte	Bloc-notes, gedit, VS Code	lire les fichiers bruts	n'importe lequel
Un terminal	PowerShell, Terminal, Git Bash	compter, vérifier encodage et empreintes	facultatif mais très utile

Deux précisions utiles, parce qu'elles reviennent dans tous les forums : **LibreOffice 24.8 et supérieur** gère nativement les fonctions récentes (RECHERCHEX, FILTRE, UNIQUE, LET, SEQUENCE), là où les versions antérieures ne les avaient pas ; **Excel** propose RECHERCHEX depuis 2021, mais FILTRE, UNIQUE, LET, SÉQUENCE et TRIBY supposent Microsoft 365 ou Excel 2024. Le module 3 reprend ce point en détail ; ici, aucune fonction récente n'est nécessaire.

Les données de travail du module

Tout le module, puis tout le parcours, travaille sur un jeu de données **réellement livré dans ce dossier**, pas sur un exemple fictif :

Fichier	Rôle	Volumétrie réelle
01_socle_donnees/data/projection/ventes_magasin5_2025.csv	votre fichier de travail : extrait du magasin 5, année 2025	489 lignes × 13 colonnes (dont 9 en double)
01_socle_donnees/data/brut/ventes_brutes.csv	le fichier complet, pour mesurer l'échelle	243 360 lignes × 20 colonnes , 28,5 Mo
01_socle_donnees/data/reference/ventes_propres.csv	la référence propre, pour vérifier vos calculs	240 000 lignes
01_socle_donnees/data/reference/ventes_magasin5_2025_ATTENDU.csv	le corrigé de l'extrait nettoyé	480 lignes
01_socle_donnees/data/brut/tarif_fournisseur_peinture.csv	le fichier hostile (encodage, chapeau, virgule)	42 lignes dont 38 utiles
01_socle_donnees/data/reference/verites_terrain.csv	les totaux de contrôle du jeu complet	CA TTC 4 ans : 15 419 985 157 FCFA
01_socle_donnees/data/reference/chiffres_cites.md	la source unique des chiffres cités dans ce manuel	tous les nombres de ce module en viennent

Règle de travail : si un nombre de l'énoncé ne correspond plus à votre fichier, **c'est votre fichier qui a changé**, pas l'énoncé. Régénérez (`python3 01_socle_donnees/scripts/generation_socle.py`) puis relisez `chiffres_cites.md`. Le jeu est déterministe : une graine fixe (20260917) produit toujours les mêmes fichiers, donc les mêmes chiffres, pour vous comme pour le correcteur.

Livrables attendus du module

1. le dossier `Sahel/` rangé selon la convention (C01, mini-projet P1) ;
2. la fiche d'identité des trois tables (C03, mini-projet P3) ;
3. le dictionnaire de types (C04, mini-projet P4) ;
4. la carte d'identité du lot de données (C05, mini-projet P5) ;
5. le dossier d'archivage d'une publication (C06, mini-projet P6) ;
6. les trois formulaires de cadrage (C07, mini-projet P7) ;
7. **le projet M01.P complet** (fiche, questions, réponse chiffrée, page d'autoportrait) ;
8. l'évaluation : quiz 15 questions, 4 exercices, étude de cas, notés sur 20.

Comment travailler ce module (méthode recommandée)

Séance	Durée	Contenu	Contrôle de fin de séance
1	4 h	C01 + mise en place du poste	arborescence + 12 lignes de journal
2	3 h	C02, cahier en main	cinq demandes réelles converties en questions
3-4	5 h	C03 sur le fichier réel	six phrases + cinq comptages justes
5-6	5 h	C04 : typage du fichier de l'atelier	NB = NBVAL après conversion, total à 36 073 185 FCFA
7	4 h	C05	classement des 13 colonnes + réponse en 5 lignes
8	4 h	C06	dictionnaire + journal + politique
9	5 h	C07	trois formulaires de cadrage
10-11	5 h	projet M01.P et évaluation	rendu noté, quiz $\geq 14/20$ pour passer en M02

Seuil de passage en M02 : quiz $\geq 14/20$ **et** projet M01.P complet (les quatre livrables). Vous pouvez commencer M02 avec un 13/20 si vous reprenez les deux exercices manqués pendant le module suivant — le parcours est conçu pour que rien ne soit éliminatoire, sauf l'abandon.

Ce qui vient après

Le module 2 (statistiques du résumé) utilise le **même fichier**, nettoyé par vos soins. Le module 3 (tableur avancé) remplace vos formules de comptage par des tableaux croisés. Le module 4 (qualité de la donnée) reprend vos 9 doublons, vos 65 dates et vos 7 quantités aberrantes, et en fait un chantier documenté. Vous n'apprendrez donc rien « en l'air » : chaque module consomme le livrable du précédent.

M01.C01 — Se repérer dans un ordinateur de travail : dossiers, fichiers, extensions, chemins, sauvegardes

Outil de ce chapitre : Explorateur Windows (équivalents montrés : Finder sur macOS, Files sur Linux). **Durée indicative :** 4 h. **Niveau :** N1.

Pourquoi ce chapitre existe. On ne commence pas un métier de la donnée par un logiciel : on le commence par une **méthode de travail**. Un analyste qui égare ses fichiers, qui écrase une donnée brute ou qui nomme ses classeurs `final_final_v3.xlsx` perd un temps considérable et rend un résultat invérifiable. Les trois heures que vous allez y consacrer vous en rendront des centaines sur les vingt et un modules suivants — et, en entreprise, elles vous éviteront de recompter un chiffre devant un directeur.

1. Objectifs du chapitre

À la fin de ce chapitre, vous saurez :

1. **Nommer** les quatre parties d'un chemin (lecteur · dossiers · nom · extension) et **écrire** un chemin sans faute sous Windows, macOS et Linux ;
2. **Organiser** un dossier de travail conforme à la convention du manuel (`01_brut`, `02_propre`, `03_analyse`, `04_livrables`, `90_journal`) ;
3. **Reconnaître** une extension et dire quel logiciel l'ouvre, quel format la remplace, et ce que le format garantit ou ne garantit pas ;
4. **Sauvegarder** avec la règle 3-2-1 et **vérifier** qu'une sauvegarde est utilisable (une sauvegarde non testée n'est pas une sauvegarde) ;
5. **Retrouver** un fichier perdu en moins de deux minutes avec la recherche par nom, par date et par contenu.

2. Pourquoi cette notion est importante

Situation 1 — le fichier disparu. Un auditeur demande, trois ans plus tard, le détail d'un chiffre figurant dans un rapport que vous avez produit. Vous retrouvez le rapport (PDF). Le classeur qui l'a calculé est sur un poste retiré du réseau, dans un dossier `Bureau/Nouveau dossier (2)`. Le chiffre devient indéfendable. En entreprise, un chiffre indéfendable se transforme vite en décision annulée — ou en perte de crédibilité pour la personne, pas pour l'outil.

Situation 2 — l'écrasement. Vous recevez `ventes_2025.csv`. Vous « rangez » les colonnes directement dans ce fichier, vous enregistrez. Le fichier source n'existe plus. Toute correction ultérieure — le montant que le directeur conteste — devient une reconstitution, pas un calcul. La règle que vous allez apprendre (toujours partir du brut, ne jamais l'abîmer) est la plus rentable de tout le module.

Situation 3 — le nom qui ment. `rapport_mensuel.xlsx` reçu le 4 du mois, `rapport_mensuel (2).xlsx`, `Rapport Mensuel FINAL.xlsx` : trois fichiers, un seul bon, personne pour trancher. La

moitié des erreurs de reporting dans les petites structures viennent d'un fichier mal nommé, mal daté ou mal placé — pas d'un mauvais calcul.

Dans les faits. Dans les audits de systèmes d'information, le constat revient sous un nom : provenance (savoir d'où vient un chiffre). Une étude publiée sur la qualité des données en PME africaines de distribution situe entre 20 et 35 % du temps d'analyse la seule reconstitution du contexte d'un fichier. Ce temps, une arborescence et un journal le suppriment.

3. Explication simple

Votre ordinateur est une **ville de fichiers**. Chaque fichier est une maison ; il n'a pas de sens tout seul, il a une **adresse**. L'adresse d'un fichier se lit de la gauche vers la droite, du plus grand au plus petit :

- le **lecteur** (ou la racine) : le quartier — `C:\` sous Windows, `/` sous Linux et macOS ;
- les **dossiers** : la rue, puis le numéro de rue — `Users\A.minani\Documents\Sahel\01_brut\` ;
- le **nom du fichier** : la maison — `ventes_magasin5_2025` ;
- l'**extension** : la forme de la porte, qui indique comment entrer — `.csv`, `.xlsx`, `.pdf`.

Un **dossier** est un conteneur, rien de plus. Il n'y a pas de « vraie » hiérarchie dans le disque : un fichier déplacé change d'adresse, point. C'est pour cela que les liens (« raccourcis », « alias ») se cassent quand on déplace le fichier cible.

Deux réflexes résument le chapitre :

1. **Un fichier = une adresse + un nom qui dit la vérité.** Si le nom dit `final`, il ment : un fichier de données se nomme par sa date et son contenu.
2. **Un dossier = un rôle, pas une personne.** On range par étape du travail (brut → propre → analyse → livrables), pas par logiciel ni par collègue.

4. Vocabulaire essentiel

Français — English	Définition simple	Piège à éviter
Dossier — folder / directory	Conteneur de fichiers et d'autres dossiers.	Un dossier ne protège rien : il n'empêche ni l'écrasement ni la suppression.
Chemin — path	Adresse complète d'un fichier ou d'un dossier.	Chemin absolu (complet, depuis la racine) ≠ chemin relatif (depuis le dossier courant). Les scripts, eux, parlent surtout en relatif.
Séparateur separator	— Caractère qui sépare les dossiers : <code>\</code> sous Windows, <code>/</code> sous Linux/macOS.	Dans un script, <code>C:\new\data.csv</code> est un piège classique : <code>\n</code> est un retour à la ligne. On écrit <code>C:/new/data.csv</code> ou <code>r"C:\new\data.csv"</code> .
Extension extension	— suffixe après le dernier point, qui indique le format.	Windows masque les extensions par défaut : <code>rapport.pdf.exe</code> s'affiche <code>rapport.pdf</code> (classique des rançongiciels). À désactiver le masquage, tout de suite.
Format	Règle d'écriture des octets d'un fichier (CSV, XLSX, PDF...).	Le format décide de ce qui est conservé : un CSV ne conserve ni formats, ni formules, ni couleurs.
Arborescence tree	— Organisation des dossiers en arbre.	Une arborescence trop profonde (plus de 4 niveaux) n'est plus parcourue ; trop plate, elle devient un dépôt.
Sauvegarde backup	— Copie du travail sur un autre support, restaurable.	Un dossier OneDrive/Dropbox synchronisé n'est pas une sauvegarde : une suppression se propage.

Français — English	Définition simple	Piège à éviter
Versionnage versioning	— Conservations numérotées et datées des états d'un fichier.	v1, v2, final ne sont pas des versions : il faut une date et un auteur .
Journal — log	Fichier texte qui note ce que vous avez fait, dans l'ordre.	Sans journal, personne (vous, dans trois mois) ne peut rejouer le travail.
Métadonnées metadata	— Informations sur le fichier : auteur, date de création, taille, logiciel.	Un PDF sans métadonnées de source est un document non vérifiable.

5. Cours approfondi

5.1 Les quatre façons d'écrire une adresse

Sous **Windows**, le séparateur usuel est l'antislash :

```
C:\Users\aminani\Documents\Sahel\01_brut\ventes_2025.csv
|   |               |               |               |
|   | utilisateur   | racine pro| dossier de travail | étape | fichier
|   | lecteur       |           | (étape 1)          |
|   |               |               |               |
```

Sous **Linux** et **macOS**, le séparateur est la barre oblique, et il n'y a pas de lecteur :

```
/home/amina/Documents/Sahel/01_brut/ventes_2025.csv
/Users/amina/Documents/Sahel/01_brut/ventes_2025.csv
```

Le **point** (.) désigne le dossier courant, **deux points** (..) le dossier parent. Ces deux notations sont le vocabulaire de base des logiciels de données : quand on vous demande « le fichier 01_socle_donnees/data/brut/ventes_brutes.csv, depuis le dossier du projet », on vous demande un chemin relatif.

À connaître aussi :

- **chemin réseau** : `\\serveur-compta\exports\ventes.csv` (Windows) ou `smb://serveur/exports` (macOS) — un lecteur réseau est une porte vers une autre machine, pas un disque local ;
- **URL fichier** : `file:///C:/Users/.../ventes.csv`, que les navigateurs et certains logiciels affichent ;
- **caractères interdits** sous Windows : `< > : " / \ | ? *`. Les accents et les espaces sont autorisés mais déconseillés dans les fichiers de travail : ils cassent scripts, liens et imports, et s'affichent mal chez le destinataire.

Définition. Chemin — path — l'adresse complète d'un fichier ou d'un dossier. Deux écritures coexistent : le chemin **absolu** (absolute path) part de la racine du disque et fonctionne de n'importe où ; le chemin **relatif** (relative path) part du dossier où l'on se trouve et fonctionne tant que l'on ne bouge pas. Un script choisit l'un des deux et s'y tient : les mélanger donne une adresse qui marche sur un poste et nulle part ailleurs.

Attention. Les antislashes ne sont pas neutres. `C:\nouveau\data.csv` est une adresse Windows valide, mais dans un langage de programmation la séquence `\n` devient un saut de ligne et le chemin part en vrille. Réflexe : barres obliques, ou fonction de jointure de chemin fournie par l'outil, jamais accumulation de antislashes à la main.

5.2 Extensions : ce que chaque format protège

Extension	Ce que c'est	Ce qu'il faut savoir
.csv	texte brut, une ligne = une ligne du tableau, colonnes séparées par un caractère (; ou ,).	Léger, universel, sans mise en forme ni formule ; le séparateur et l'encodage doivent être connus ou devinés (M01.C04).
.xlsx	classeur Excel : plusieurs feuilles, formats, formules.	Riche mais « boîte noire » : binaire, difficile à diffuser et à tracer. C'est un fichier d' usage , pas un fichier de référence .
.ods	classeur LibreOffice Calc.	Équivalent libre de .xlsx ; attention aux fonctions non traduites lors des allers-retours.
.txt	texte brut.	Un fichier de données en .txt est un .csv qui ne dit pas son nom : il faut connaître son séparateur.
.json	texte structuré, par paires clé/valeur imbriquées.	Format roi des échanges entre logiciels ; se lit à l'œil, se charge en une ligne dans les outils d'analyse.
.parquet	binaire colonnaire compressé (vu en M08 et M24).	Beaucoup plus petit et plus rapide que le CSV sur les gros volumes ; pas éditable à la main.
.pdf	document figé pour l'impression et la signature.	Excellent pour livrer, mauvais pour transmettre de la donnée : copier un tableau d'un PDF produit des lignes cassées.
.zip, .7z, .rar	conteneurs compressés.	À l'extraction, le chemin d'origine peut être conservé... ou tout se retrouver dans un seul dossier. À vérifier.

Définition. Extension — file extension — les lettres placées après le dernier point du nom, qui indiquent le **format** du fichier, donc le logiciel capable de l'ouvrir et ce que ce logiciel va y trouver. Le contenu réel est indépendant de l'extension : renommer un .csv en .xlsx ne convertit rien, cela rend seulement le fichier difficile à ouvrir.

Attention. Windows masque les extensions connues. Conséquence directe : un fichier `tarif_fournisseur_peinture.csv` reçu d'un logiciel métier peut être en réalité un .xls (l'ancien format binaire) qui **s'ouvre** dans Excel mais que vos scripts ne liront pas. Réflexe professionnel : afficher les extensions (Explorateur → Affichage → « Extensions de noms de fichiers ») **le premier jour**, et vérifier le contenu d'un fichier avec un éditeur de texte quand un doute surgit.

Définition. Arborescence — **tree** — l'organisation des dossiers en arbre, depuis un point d'entrée unique. Ce qui la rend vivable n'est pas son élégance mais sa **profondeur** : au-delà de quatre niveaux, plus personne ne descend, et les fichiers se déposent n'importe où. Règle d'usage : un niveau = une nature de chose (brut, propre, livré), jamais un niveau = un mois.

5.3 L'arborescence de travail du manuel — à copier

Tous les modules de ce manuel travaillent dans la même structure, créée au chapitre 1 et jamais modifiée ensuite :

```

Sahel/
├─ 00_doc/                ← dictionnaire des données, NOTICE, captures d'écran
├─ 01_brut/               ← fichiers reçus, tels quels, en lecture seule
├─ 02_propre/             ← fichiers après nettoyage, jamais une retouche du brut
├─ 03_analyse/            ← scripts, requêtes, tableaux de travail
├─ 04_livrables/          ← ce qui sort vers les autres : PDF, classeurs, exports
├─ 90_journal/            ← journal_datation.txt, journal_transformations.txt
└─ 99_archive/            ← ce qui ne sert plus mais qui ne se supprime pas

```

Quatre règles rendent cette structure efficace :

1. **Le numéro devant le nom** impose l'ordre d'affichage et donc l'ordre de travail (l'Explorateur trie par nom, pas par importance).

2. **Le brut est en lecture seule** : clic droit → Propriétés → « Lecture seule ». Toute tentative d'enregistrement dessus échoue, ce qui est exactement le but. Un fichier brut modifié est une preuve perdue.
3. **Rien ne sort de 04_livrables/ sans date dans le nom** : 2026-09-17_note_CA_M5_minani.pdf.
4. **On archive, on ne supprime pas**. 99_archive/ coûte de la place ; une erreur regrettée coûte un poste.

5.4 Nommage des fichiers : la grammaire complète

AAAA-MM-JJ_quoi_qui_etat.ext — quatre champs, un seul séparateur, aucun accent :

- **AAAA-MM-JJ** = date des **données**, pas date du travail. 2025 pour l'année des ventes. Si c'est un extrait mensuel : 2025-12.
- **quoi** = contenu, en mots-clés courts : ventes, tarifs, objectifs.
- **qui** = auteur ou périmètre : M5 (magasin 5), minani (vous).
- **etat** = brut, propre, v1, corrigé. Le mot **final** n'existe pas dans cette grammaire.

Exemples justes : 2025_ventes_M5_brut.csv, 2025_ventes_M5_propre.csv, 2026-09-17_note_CA_M5_minani_v2.pdf. Exemples fautifs, et pourquoi : ventes.xlsx (aucune date, aucune période, état inconnu), Nouveau Microsoft Excel Worksheet.xlsx (le nom par défaut du logiciel : illisible dans six mois), rapport final (1).pdf (fabriqué par le navigateur, deux sens possibles), ventes_magasin5_2025 - Copie.csv (une copie non datée est un doublement involontaire — le défaut que vous rencontrerez en M01.C03).

Conseil professionnel. Les analystes expérimentés ajoutent un **préfixe de statut** aux fichiers en attente : WIP_ (work in progress) ou HOLD_. En liste, le statut saute aux yeux ; dans un dossier partagé, cela évite qu'un collègue prenne votre brouillon pour un livrable. Le préfixe est retiré à la sortie du fichier, jamais avant.

Définition. Nommage — naming convention — grammaire écrite des noms de fichiers. Un nom correct répond dans l'ordre fixé par l'équipe à quatre questions : qui produit, de quoi il s'agit, pour quelle période, à quel état. Ce n'est pas une question de goût : le tri alphabétique devient un tri chronologique, et un programme retrouve le fichier sans avoir à demander une liste.

5.5 Sauvegarder : la règle 3-2-1, et son test

3 copies de vos données, sur 2 supports différents, dont 1 hors site. Concrètement, pour un poste de travail :

1. le disque de l'ordinateur (copie de travail) ;
2. un disque dur externe ou un partage réseau de l'entreprise, débranché après copie (copie locale froide) ;
3. un espace distant — cloud d'entreprise, serveur mutualisé (copie hors site).

Trois précisions qui font la différence entre une politique et un résultat :

- **Une synchronisation n'est pas une sauvegarde.** OneDrive, Dropbox, Google Drive, Nextcloud : ils propagent la suppression et l'écrasement en quelques secondes. Ils sauvegardent si l'historique de versions est activé et conservé assez longtemps — vérifiez la durée (souvent 30 jours, quelquefois 1).
- **Une sauvegarde non testée n'existe pas.** Le rituel professionnel : une fois par mois, restaurer **un** fichier dans un dossier test_restoration/, l'ouvrir, vérifier le nombre de lignes, supprimer. Douze minutes. C'est ce qui sépare une équipe qui récupère d'une équipe qui pleure.

- **Chiffrer les copies mobiles.** Un disque externe dans un sac, contenant des données clients, est un incident de conformité en puissance. BitLocker (Windows), le chiffrement de disque (macOS), VeraCrypt (les deux) se règlent en une fois.

Définition. Rétenion — retention period — durée pendant laquelle on conserve un fichier et ses versions. En comptabilité et en fiscalité, les pièces justificatives se conservent **10 ans** dans la zone OHADA (dont le Burkina Faso) ; un jeu de données d'analyse servant à justifier un chiffre publié relève de la même prudence.

Attention. Un dossier **synchronisé** n'est pas une sauvegarde. La synchronisation reproduit fidèlement l'écrasement, la suppression accidentelle et le chiffrement par rançongiciel sur toutes les copies. Une sauvegarde se juge à trois choses : un autre support, une durée de conservation, un test de restauration daté.

5.6 Retrouver un fichier : trois méthodes, dans l'ordre

1. **Par nom** : dans la barre d'adresse de l'Explorateur ou avec Alt + F, taper un fragment, en acceptant les jokers : 2025*ventes*, *.csv. Sous Linux/macOS : `find . -iname "*ventes*2025*"`.
2. **Par date et taille** : recherche avancée sur `datemodifiée:2026-09-17 taille:>1mo` (Explorateur) ou `ls -lhS` (terminal). Un fichier de données récent et volumineux se débusque en dix secondes.
3. **Par contenu** : dans Excel/LibreOffice on ne cherche pas, on cherche **le fichier qui contient ce mot** — Windows Indexation (Options de recherche → « Propriétés et informations de fichier ») ou, méthode radicale, `grep -l "Sahel Distribution" *.txt`.

Dernier recours, celui qui marche toujours : le **journal**. Si chaque action est notée dans `90_journal/journal_datation.txt`, le fichier ne peut pas être perdu — il est décrit. C'est le prix du réflexe du §5.7.

5.7 Le journal : votre première obligation professionnelle

Un fichier texte, une ligne par action, jamais réécrit :

```
2026-09-17 09:12 a.minani réception mail « export ventes » → 01_brut/2025_ventes_M5_brut.csv
(489 lignes, 32 Ko, md5 9clf...)
2026-09-17 09:14 a.minani chmod lecture seule 01_brut/ ; copie de travail créée 02_propre/
2025_ventes_M5_propre.csv
2026-09-17 10:02 a.minani suppression de 9 lignes strictement identiques (doublons) → 480
lignes ; total TTC avant 36 339 317, après 36 073 185 FCFA
```

Trois colonnes suffisent : **quand** · **qui** · **quoi**. Ajoutez-y la **taille** ou le **nombre de lignes** à chaque entrée : c'est ce qui permettra, plus tard, de prouver qu'aucune ligne n'a été perdue sans le vouloir. Le hash `md5` est facultatif au début, indispensable en M05 : c'est l'empreinte numérique du fichier, deux fichiers de même empreinte sont identiques au bit près.

Boîte à outils. Windows — Afficher les extensions : Explorateur → Affichage → Afficher → « Extensions de noms de fichiers ». Recherche avec jokers : `*` et `?`. Propriétés → « Lectures/seulement ». Historique de versions : clic droit → « Restaurer les versions précédentes ». **macOS** — Finder → « Préférences → Avancé → afficher les extensions ». Historique : Time Machine. **Linux / terminal** — `ls -l`, `cp -p` (préserve les dates), `md5sum fichier.csv`, `grep -l "motif" *.csv`, `diff -u a.csv b.csv`. **Raccourcis à mémoriser** — Ctrl+Shift+N nouveau dossier (Windows), F2 renommer, Ctrl+F rechercher, Alt+Entrée propriétés.

Définition. Journal — log — fichier texte horodaté qui enregistre, dans l'ordre, ce qui a été fait sur les données. Un journal utile se lit à rebours : on part du chiffre publié et l'on remonte jusqu'à l'action qui l'a produit. S'il ne permet pas de refaire le travail à partir de rien, ce n'est pas un journal, c'est un brouillon.

À retenir. Le poste de travail fait partie de la qualité : un fichier introuvable est une donnée perdue, un fichier écrasé est une preuve perdue. Les quatre réflexes du chapitre — adresse absolue ou relative mais jamais les deux, extension visible, arborescence peu profonde à un niveau par nature de chose, nom qui se trie tout seul — coûtent douze minutes une fois et en font gagner des centaines chaque année.

6. Exemple concret : la même donnée en trois formats

Le fichier de l'atelier de ce module pèse **489 lignes** et **13 colonnes** au format CSV. Regardons ce que chaque format en conserve, sur la première ligne :

Format	Ce que la ligne contient	Taille approximative	Ouvrable par
2025_ventes_M5_brut.csv	T05-250101-075845;2025-01-01;11:01;Magasin 5 – Kaya Marché;Moussa Ilboudo;10857;... — tout en texte, séparé par des points-virgules	32 Ko	n'importe quoi, y compris un éditeur de texte
..._propre.xlsx	les mêmes valeurs, plus : dates réellement typées, colonne figée, filtre actif, un onglet « dictionnaire »	46 Ko	Excel, LibreOffice, Power BI
..._note.pdf	le résultat (un total, un graphique), plus aucune ligne de détail	18 Ko	tout le monde, mais on ne peut plus recalculer

Le CSV est le seul des trois que vous pouvez **relire ligne par ligne** avec un outil qui n'existe pas encore dans vingt ans. C'est la raison pour laquelle tous les socles de données sérieux, y compris celui de ce manuel, gardent le brut en texte : `ventes_brutes.csv` fait 28,5 Mo pour 243 360 lignes, et chacun peut l'ouvrir avec un bloc-notes. Le `.xlsx` est fait pour le travail quotidien, le `.pdf` pour la décision.

7. Démonstration pas à pas : préparer le poste en 12 minutes

Faites-le réellement. Ce que vous construisez ici sert jusqu'au module 22.

Étape 1 — Rendre les extensions visibles (30 s). Windows : onglet **Affichage** → **Afficher** → cochez **Extensions de noms de fichiers**. macOS : Finder → **Réglages...** → **Avancé** → cochez **Afficher toutes les extensions**.

Étape 2 — Créer l'arborescence (3 min). Dans `Documents`, créez le dossier `Sahel`, puis les six sous-dossiers numérotés (`00_doc`, `01_brut`, `02_propre`, `03_analyse`, `04_livrables`, `90_journal`, `99_archive`). Sous Windows, Ctrl+Maj+N, puis `Entrée` et `Entrée` enchaîne les créations.

Étape 3 — Déposer le fichier brut (1 min). Copiez `ventes_magasin5_2025.csv` depuis `formation-data-bi/01_socle_donnees/data/projection/` vers `01_brut/`, puis **renommez-le** selon la grammaire : `2025_ventes_M5_brut.csv`. Clic droit → **Propriétés** → cochez **Lecture seule**.

Étape 4 — Vérifier la nature réelle du fichier (2 min). Ouvrez-le avec le **Bloc-notes** (pas avec Excel). Vous devez voir la ligne d'en-tête puis des lignes séparées par des `;` :

```
n_ticket;date;heure;magasin;vendeur;client;produit;categorie;quantite;prix_unitaire_ht;remise;montant_ht;montant_t
T05-250101-075845;2025-01-01;11:01;Magasin 5 – Kaya Marché;Moussa Ilboudo;I0857;Plâtre de
construction 25 kg – réf 1;Matériaux;11;4500;0.03;48015;56 658
```

Notez deux choses, visibles sans logiciel d'analyse : la **date** de la première ligne est au format international `2025-01-01`, mais ailleurs dans le fichier des dates sont écrites `12/01/2025` — et le **montant** de dernière colonne est `56 658`, avec un espace : ce n'est pas un nombre, c'est du texte. Vous venez de faire, à l'œil, le travail du chapitre 3.

Étape 5 — Le premier comptage, sans tableur (2 min). Dans le Bloc-notes : `Ctrl+G` va à la fin, notez le numéro de ligne : **490** (489 lignes de données + 1 en-tête). Sous Linux/macOS, ou dans le terminal Git de Windows :

```
wc -l 2025_ventes_M5_brut.csv          # 490
awk -F';' 'NR>1 {s+=$13} END{print s}' 2025_ventes_M5_brut.csv  # ne marche pas : le champ 13
contient un espace
```

Ce second résultat — faux, ou carrément une erreur — est volontairement laissé là : il vous montre qu'un fichier de données doit être **typé** avant d'être **somme**. Vous le réglerez en `M01.C04`.

Étape 6 — Créer le journal (1 min). Dans `90_journal/`, fichier `journal_datation.txt`, avec les trois colonnes, consignez les cinq étapes ci-dessus. Format imposé par le manuel : `AAAA-MM-JJ HH:MM auteur action (constat chiffré)`.

Étape 7 — Sauvegarder et tester la restauration (3 min). Copiez `Sahel/` sur un second support (disque externe ou répertoire sauvegarde/ d'un cloud d'entreprise). Depuis ce support, restaurez **un** fichier dans `Sahel/test_restoration/`, comptez ses lignes (`wc -l` ou fin du Bloc-notes) : vous devez retrouver 490. Supprimez le dossier de test. Vous venez de faire la seule chose qui compte : prouver que votre sauvegarde s'utilise.

8. Erreurs fréquentes

Symptôme	Cause	Correction
« Fichier introuvable » après avoir renommé un dossier parent	Un lien, un script ou un onglet Excel pointe sur l'ancien chemin.	Ne renommez jamais les six dossiers numérotés ; renommez les fichiers. Si un chemin est codé dans un script, documentez-le dans le journal.
Deux fichiers identiques, des totaux différents	Copie créée puis retouchée séparément (« - Copie », « (2) »).	Un seul fichier de travail par sujet ; les autres sont archivés avec un préfixe <code>ARCHIVE_</code> et une date.
Le script lit 0 ligne dans un <code>.xlsx</code> renommé <code>.csv</code>	L'extension ne convertit pas le contenu.	Exporter depuis le logiciel vers le format voulu (Enregistrer sous → CSV), jamais renommer.
Un fichier de 489 lignes devient 490 après enregistrement	Excel a réécrit l'en-tête ou ajouté une ligne vide.	Comparer le nombre de lignes avant et après chaque enregistrement : c'est la première ligne du journal de transformation.
Le PDF d'un livrable change de pagination chez le destinataire	Polices non intégrées.	Dans l'export, cocher « incorporer les polices » ; vérifier en ouvrant le PDF dans un autre lecteur.
La sauvegarde du jour est vide	Le disque externe était débranché, et la tâche de copie a échoué en silence.	Tâche de sauvegarde qui écrit un journal + une vérification hebdomadaire de ce journal.

9. Bonnes pratiques professionnelles

- [] Extensions visibles sur le poste de travail, dès le premier jour.
- [] Arborescence à six dossiers numérotés, identique pour tous les sujets.
- [] Réception = copie dans 01_brut/ + lecture seule + entrée dans le journal.
- [] Noms de fichiers datés, sans accent, sans espace, sans le mot final.
- [] Un seul fichier de travail par sujet ; les états antérieurs dans 99_archive/.
- [] 3-2-1 pour la sauvegarde, avec une restauration testée chaque mois.
- [] Chiffrement des supports amovibles contenant des données clients.
- [] Journal de transformation obligatoire pour tout chiffre destiné à autrui.

10. Exercice guidé — ranger un dossier de travail réel

Point de départ. Un collègue vous envoie un dossier compressé contenant, dans le désordre :

```
Nouveau Microsoft Excel Worksheet.xlsx
export caisse (1).csv
export caisse.csv
ventes_2025.xlsx
rapport_final_final.pdf
```

Faites-le avec moi, une décision à la fois.

1. **Ne rien ouvrir.** On commence par ce que l'on peut savoir sans risque : la liste, les tailles, les dates. Sous Windows : Affichage → Détails, trier par Date. Notez ces trois informations : c'est votre matière de travail.
2. **Dégager les doublons évidents.** export caisse.csv et export caisse (1).csv : le (1) est la marque du navigateur, qui renomme à la deuxième réception de la même URL. Comparez les tailles : si elles sont identiques, l'empreinte aussi l'est presque certainement ; vérifiez avec md5sum (ou Propriétés → détails). **Décision** : on garde une copie, on archive l'autre avec une date — on ne supprime pas avant d'avoir vérifié le contenu.
3. **Identifier le fichier utile.** Nouveau Microsoft Excel Worksheet.xlsx est suspect : un nom par défaut veut dire un travail non enregistré ailleurs. Ouvrez-le : s'il contient des données réelles, il est **brut** (il aurait dû être enregistré dans 01_brut/) ; s'il est vide, il va dans 99_archive/ et non à la corbeille.
4. **Traduire en convention.** Chaque fichier gardé reçoit un nom correct : 2025_ventes_M5_brut.csv, 2025_ventes_M5_brut.xlsx (si le classeur contient autre chose que le CSV), 2026-09-12_note_CA_M5_brut.pdf. Le **format** reste inchangé : on ne convertit pas un brut.
5. **Placer.** Les .csv et .xlsx sources → 01_brut/ (lecture seule). Le PDF, qui est une **sortie**, → 04_livrables/ s'il vient de vous, sinon 99_archive/ avec une note : un livrable reçu n'est pas une source.
6. **Écrire le journal.** Six lignes, une par décision prise, avec le motif : « export caisse (1).csv : empreinte identique à export caisse.csv → archivé 2026-09-17_export_caisse_dupli_99archive.csv ».

Résultat attendu : plus aucun nom ne contient final, Nouveau, Copie ou (1). Le nombre de fichiers dans 01_brut/ est 2, et chacun est en lecture seule. Si votre 01_brut/ contient trois fichiers ou plus, vous avez gardé un doublon ou placé une sortie parmi les sources.

11. Exercices autonomes

Exercice 1.1 (★) — Les adresses. Écrivez, pour un même fichier de votre poste, le chemin absolu sous Windows, le chemin absolu sous Linux, le chemin relatif depuis Documents, et le nom complet du fichier. Que change le passage de l'un à l'autre ? (résultat attendu : 4 lignes, seule la partie « dossier » varie ; l'extension reste identique)

Exercice 1.2 (★) — Chasse aux extensions. Listez tous les fichiers de votre Téléchargements modifiés cette semaine et regroupez-les par extension. Pour chaque groupe, dites en une phrase ce que ce format **ne conserve pas**. (attendu : au moins 4 groupes ; PDF → pas de calcul ; PNG → pas de texte ; XLSX → pas d'historique de la source ; CSV → pas de types)

Exercice 1.3 (★★) — Reconstruction d'histoire. Un dossier contient CA 2025.xlsx (taille 1,2 Mo, modifié le 08/01/2026) et CA 2025 (2).xlsx (940 Ko, modifié le 03/01/2026). Rédigez trois hypothèses expliquant l'écart et, pour chacune, la **vérification** qui l'infirme ou la confirme. (attendu : 3 hypothèses + 3 tests — nombre de feuilles, nombre de lignes par feuille, présence d'une table pivot, empreintes)

Exercice 1.4 (★★) — La sauvegarde qui ment. Vous activez la corbeille, supprimez 01_brut/2025_ventes_M5_brut.csv, le restaurez. Puis vous synchronisez avec le cloud **après** la suppression et attendez 24 h. Le fichier est-il récupérable, et grâce à quoi précisément ? (attendu : oui si l'historique de versions couvre 24 h ; non si la rétention est inférieure ; la réponse doit citer la rétention en jours, pas « il y a un cloud »)

Exercice 1.5 (★★) — Journal. Reprenez l'exercice 1.3 et consignez-le en 6 lignes de journal. Un pair doit pouvoir rejouer votre travail sans vous parler. (attendu : chaque ligne commence par date+heure, puis auteur, puis action, puis constat chiffré)

12. Correction détaillée

Exercice 1.1. Supposons le fichier C : \Users\A.minani\Documents\Sahel\01_brut\2025_ventes_M5_brut.csv. - absolu Windows : C : \Users\A.minani\Documents\Sahel\01_brut\2025_ventes_M5_brut.csv - absolu Linux (même arborescence sur un poste libre) : /home/A.minani/Documents/Sahel/01_brut/2025_ventes_M5_brut.csv - relatif depuis Documents : Sahel/01_brut/2025_ventes_M5_brut.csv - nom complet : 2025_ventes_M5_brut.csv (nom + extension) Ce qui change : la **racine** et le **séparateur**. Ce qui ne change pas : la structure des dossiers et le nom — c'est ce qui permet d'écrire un script portable en utilisant des chemins relatifs et le caractère /.

Exercice 1.2. Réponses attendues (non exhaustives) : .pdf ne conserve ni le calcul ni la donnée d'origine, seulement l'apparence ; .png/.jpg conservent une image d'un tableau, pas le tableau ; .xlsx conserve formules et mise en forme mais son contenu binaire n'est pas lisible sans le logiciel, et l'origine du fichier n'y est pas tracée ; .csv conserve des caractères, donc rien des types : une date y est une suite de signes, un montant peut y être du texte. Un apprenant qui répond « le CSV ne conserve que du texte » a juste ; s'il ajoute « donc les nombres peuvent être faux », il a compris l'enjeu du chapitre 4.

Exercice 1.3. Trois hypothèses et leurs tests : 1. Le plus gros fichier contient des feuilles supplémentaires (graphiques, historique). → ouvrir les deux, comparer le nombre d'onglets et, dans chaque onglet, Ctrl+Fin pour voir la dernière cellule utilisée. 2. Le second est un enregistrement antérieur, plus petit car moins de lignes. → comparer le nombre de lignes de la feuille de données (sélectionner la colonne A, lire le compteur de la barre d'état). 3. Le second est un sous-ensemble filtré (lignes masquées au lieu de supprimées). → vérifier si des filtres sont actifs et si des numéros de ligne se suivent pas à pas ; une ligne masquée saute dans la numérotation. Ce

qui **n'est pas** une vérification recevable : « l'œil » sur la mise en forme, ou le nom. Toute réponse doit contenir une manipulation qui produit un nombre.

Exercice 1.4. La corbeille locale a restauré le fichier, donc à cet instant tout va bien. Après synchronisation post-suppression, l'état supprimé est propagé au serveur. Récupération possible **uniquement** si la **rétenion d'historique** du service couvre 24 h (elle est de 30 jours sur les offres classiques d'entreprise, souvent moins sur les offres gratuites) — sinon le fichier n'existe plus que sur le disque externe, c'est-à-dire la copie froide. Réponse attendue : citer la rétenion en jours et le nom du service, et conclure par la règle : une synchronisation n'est pas une sauvegarde, la copie froide l'est.

Exercice 1.5. Modèle de journal, avec les quatre constantes imposées (date-heure, auteur, action, constat) :

```
2026-09-17 11:04 a.minani ouverture 2 fichiers CA 2025.xlsx → onglets : 4 vs 2 ; dernière cellule
utilisée : A1:F4800 vs A1:F4790
2026-09-17 11:07 a.minani test filters → fichier (2) : filtre « magasin = 5 » actif, 10 lignes
masquées
2026-09-17 11:09 a.minani décision → CA 2025.xlsx = source complète ; CA 2025 (2).xlsx = extrait,
archivé avec date
```

Correction : est jugé conforme un journal qui (1) ne contient aucun jugement non chiffré, (2) permet de retrouver la décision prise, (3) horodate chaque ligne. Un journal du type « j'ai rangé les fichiers » est refusé au projet du module.

13. Mini-projet M01.P1 — « Mon poste prêt pour 22 modules » (45 min)

Livrable unique : un dossier `Sahel/` conforme, une capture d'écran de l'arborescence développée (les six sous-dossiers, fichiers visibles, extensions affichées), et un `journal_datation.txt` d'au moins 12 lignes.

Critères de réussite, auto-valuables :

#	Critère	Vérification
1	Six dossiers numérotés présents, aucun autre à la racine	liste
2	Fichier brut présent dans <code>01_brut/</code> , nommé selon la grammaire, en lecture seule	Propriétés
3	Zéro occurrence de <code>final</code> , <code>Nouveau</code> , <code>(1)</code> , <code>Copie</code> , espace ou accent dans les noms	recherche
4	Journal : 12 lignes minimum, chaque ligne datée, signée, avec un constat chiffré	lecture
5	Test de restauration écrit dans le journal, avec le nombre de lignes vérifié (490)	lecture

Ce mini-projet est noté sur 10 et entre dans le bilan de compétences du module. Le même livrable est réutilisé en M04 (journal de nettoyage) et en M21 (dossier de soutenance) : ne le jetez pas.

14. Résumé du chapitre

Un chemin = un lecteur + des dossiers + un nom + une extension

C:/	Users/a.minani/Documents/Sahel/	01_Extract/	ventes_magasin5_2025	.csv
	lecteur	dossiers	sous-dossier	nom
				extension

Séparateur : « / » sous Linux, macOS et dans Python ; « \ » sous Windows.
Excel et Python acceptent les deux ; l'Explorateur Windows n'en accepte qu'un.

ventes_magasin5_2025.csv	le fichier des ventes du magasin 5, année 2025 nom écrit par vous, date explicite
ventes_magasin5_2025_v2.xlsx	la version 2, retravaillée dans Excel piège : « v2 » ne dit ni qui ni quand
rapport_final(1).pdf	le même rapport téléchargé deux fois piège : nom fabriqué par le navigateur

Convention du manuel : AAAA-MM-JJ_quoi_qui.ext, sans espace ni accent.

exemple : 2026-09-17_ventes_M5_minani.csv

Figure 1 — Décortiquer un chemin, et les trois noms de fichiers qui posent problème dès la première semaine.

Un fichier n'a d'existence que par son **adresse** et par le **format** qu'il prétend avoir. L'adresse se lit en quatre morceaux ; le format décide de ce qui est conservé — et le CSV, qui ne conserve que des caractères, est le plus fragile et le plus durable à la fois. La méthode tient en trois réflexes : ne jamais abîmer le brut, nommer par date et contenu, consigner chaque décision dans un journal chiffré. La sauvegarde n'existe que si sa restauration a été testée, à froid, hors site. Le chapitre suivant quitte le fichier pour son sens : ce qu'une ligne de données veut dire, et ce qu'elle ne dit pas.

15. À retenir

À retenir. 1. **Extension ≠ conversion** : renommer ne change pas le contenu d'un fichier. 2. **Le brut ne se touche pas** : lecture seule, et l'on travaille toujours sur une copie nommée `..._propre`. 3. **Nommage** : AAAA-MM-JJ_quoi_qui_etat.ext, sans accent, sans espace, sans final. 4. **Une synchronisation n'est pas une sauvegarde** : 3-2-1, et l'on teste une restauration chaque mois. 5. **Sans journal chiffré, un chiffre n'a pas de preuve** — et donc pas de valeur en entreprise.

16. Évaluation formative (auto-correction, 6 min)

1. Quel caractère sépare les dossiers dans un chemin Windows, et lequel est recommandé dans les scripts ? (\ pour l'Explorateur ; / dans les scripts, qui l'acceptent partout)
2. Un fichier `budget.pdf` reçu par un collègue : doit-il aller dans `01_brut/` ? Justifiez. (non : c'est un livrable d'autrui, donc `99_archive/` ou `00_doc/` avec note ; le brut est ce qui sert à calculer, pas ce qui résulte d'un calcul)
3. Vrai ou faux : « un fichier copié sur OneDrive est sauvegardé ». (faux : sans rétention d'historique suffisante, une suppression se propage)
4. Un `.xlsx` de 940 Ko contient 4 790 lignes ; l'autre, 1,2 Mo, en contient 4 800. Quelle explication est la plus probable, et quel test la confirme ? (extrait filtré contre fichier complet ; test : compter les lignes après suppression des filtres, comparer les empreintes des colonnes-clés)
5. **Question ouverte** : en trois phrases, expliquez à un directeur pourquoi vous refusez de « corriger directement dans le fichier de la caisse ». (le fichier de caisse est la preuve ; une correction dedans détruit la traçabilité et rend le chiffre contestable à bas coût ; je produis un fichier propre à côté, et le journal permet à quiconque de refaire le calcul)

M01.C02 — Donnée, information, connaissance, décision : ce que votre travail ajoute réellement

Outil de ce chapitre : papier, crayon, un tableau blanc. Aucun logiciel. **Durée indicative :** 3 h. **Niveau :** N1.

L'idée du chapitre. Personne ne paie pour des données. On paie pour une **décision prise plus juste, plus tôt**. Entre la ligne sortie d'une caisse et la décision du directeur, il y a trois transformations, et chacune a un nom, un test de validité et des erreurs typiques. Les apprendre avant de toucher Excel change durablement la qualité de votre travail : vous ne chercherez plus « un chiffre », vous chercherez le maillon manquant.

1. Objectifs du chapitre

À la fin de ce chapitre, vous saurez :

1. **Distinguer** une donnée, une information, une connaissance et une décision, et classer 10 énoncés courants dans ces quatre cases ;
2. **Formuler** une **question analytique** correcte : unité, période, périmètre, comparaison, critère de réussite ;
3. **Traduire** une demande professionnelle floue (« est-ce que ça marche bien ? ») en deux ou trois questions traitables, et **explicit**er la décision attendue ;
4. **Dire** ce qu'un chiffre ne dit pas : ce qui manque, ce qui est supposé, ce qui est caché par le choix de la moyenne ;
5. **Écrire** une note d'une page qui remonte du chiffre à la décision, sans jargon.

2. Pourquoi cette notion est importante

Situation 1 — le tableau de bord inutile. Un analyste passe trois semaines sur un tableau de bord de 14 indicateurs. Le directeur l'ouvre deux fois, puis plus personne. Cause unique : aucun des 14 indicateurs ne répondait à une décision précise. On ne mesure pas ce qui est mesurable, on mesure ce qui **change quelque chose**.

Situation 2 — le chiffre juste, la conclusion fausse. « Le magasin 5 a réalisé 36 073 185 FCFA de chiffre d'affaires en 2025. » Exact. Et totalement inerte : est-ce bien ? Est-ce mieux que 2024 ? Ce total est-il dû à trois gros clients ? Un chiffre sans comparaison autorise toutes les lectures — y compris la mauvaise, faite par le plus fort en réunion.

Situation 3 — la bonne réponse à une mauvaise question. On demande : « pourquoi les ventes baissent ? » L'analyste démontre que les ventes **n'ont pas baissé** en volume mais que le prix moyen a baissé. Il avait raison, il a perdu du temps, et la direction a perdu confiance, parce que la demande portait en réalité sur la **marge**. Cadrer, c'est ouvrir le mot « pourquoi » pour voir la décision cachée dessous.

Dans les faits. Dans une étude restée classique sur la culture « pilotée par la donnée » (McAfee & Brynjolfsson, Harvard Business Review, 2012), les entreprises qui décident sur mesurabilité plutôt que sur l'intuition enregistraient environ **5 à 6 % de productivité** et **6 % de profit** de plus que les autres pour la même année. Ce n'est pas un chiffre du cours : c'est l'argument de vente de votre futur métier, et il tient en une phrase — la donnée fait gagner de l'argent quand elle **déplace une décision**.

3. Explication simple


Prenons un fait tout bête : sur un ticket du 1^{er} janvier 2025 au magasin 5, onze sacs de plâtre à 4 500 FCFA.

- C'est une **donnée** : une valeur brute, enregistrée, sans commentaire. Elle ne dit rien.
- Additionnez, filtrez, datez : « magasin 5, année 2025, total des lignes facturées : **36 073 185 FCFA** » devient une **information**. Elle dit quelque chose, elle est vérifiable, mais elle ne juge pas.
- Comparez : « **décembre 2025 = 5 292 517 FCFA, mai 2025 = 1 258 801 FCFA : le meilleur mois fait 4,2 fois le pire** ». Voilà une **connaissance** : elle explique un écart et peut être contestée par des faits.
- Décidez : « **dès le 20 novembre, on double le stock de plomberie et de sacs de plâtre au magasin 5, responsable M. Bationo, budget +1,4 M FCFA** ». C'est une **décision** : elle a un acteur, une date, un coût, et elle est réversible.

Retenez la phrase qui sert de boussole dans tous les modules :

Une donnée sans contexte est une information manquée ; une information sans comparaison n'est pas une connaissance ; une connaissance sans décision est du travail perdu.

La chaîne qui transforme une ligne de caisse en décision



Tout le métier est dans les deux flèches du milieu : sans comparaison, rien ne se décide.

Demande reçue : « le magasin 5 marche bien ? » — ni prouvable, ni réfutable.
Question analytique : « **quel mois de 2025 s'écarte le plus de la médiane mensuelle ?** »

Figure 2 — Les quatre maillons, chiffrés sur le fichier réel de l'atelier (ventes_magasin5_2025.csv).

4. Vocabulaire essentiel

Français — English	Définition simple	Piège à éviter
Donnée — data	Fait brut enregistré : une valeur, une case, une ligne.	Croire qu'elle est « la réalité » : elle est ce que le système a bien voulu noter.
Information	Donnée replacée : quoi, qui, quand, combien, dans quelle unité.	Confondre avec un résultat : sans unité ni période, ce n'est pas une information.

Français — English		Définition simple	Piège à éviter
Connaissance insight	—	Information comparée, qui explique ou surprend, et dont on peut discuter.	Publier une connaissance sans sa méthode : elle devient une opinion.
Décision		Engagement : une action, un responsable, une date, des conséquences.	« Il faut regarder de plus près » n'est pas une décision.
Question analytique		Question fermée, chiffrable, qui précède toute extraction.	Écrire une question dont la réponse est un adjectif (« bon », « mauvais »).
Critère réussite	de	Ce qui prouvera, à la fin, que la question a été traitée (valeur attendue, tolérance, validateur).	Ne pas le fixer avant de calculer : on se justifie après coup.
Périmètre scope	—	Parties retenues : magasins, clients, périodes, types d'opérations.	Le périmètre implicite est la première cause de deux totaux différents pour « la même » question.
Métrique		Définition de calcul d'un indicateur, écrite noir sur blanc.	Deux personnes qui calculent le CA TTC avec des règles différentes sans le savoir.
Indicateur — KPI		Chiffre suivi dans le temps, rattaché à un objectif.	Un KPI sans objectif ni seuil est un nombre que l'on regarde passer.
Biais de cadrage		La question initiale oriente déjà la réponse.	Accepter la formulation du demandeur sans chercher la décision sous-jacente.

5. Cours approfondi

5.1 Les quatre maillons, avec leurs tests de validité

Chaque maillon a une question de contrôle. C'est ce qui rend le travail **vérifiable** au lieu de personnel.

Maillon	Ce qu'on ajoute	Test de validité	Défaut typique
Donnée	rien — on la recueille	la ligne existe-t-elle dans la source ? sa date est-elle la date du fait ou de la saisie ?	date de saisie prise pour date de vente
Information	agrégation contexte	+ le total est-il reproductible avec la même définition et le même périmètre ?	« total 2025 » sans dire si les retours sont inclus
Connaissance	comparaison hypothèse	+ l'écart survit-il à un autre calcul raisonnable ?	conclusion tirée d'une moyenne, sans regarder la médiane
Décision	engagement échéance	+ qui, quand, avec quoi, et à quel signe saura-t-on que ça a marché ?	recommandation sans acteur ni indicateur de suivi

La règle métier qui découle du tableau : **on ne présente jamais un maillon tout seul**. Une information s'accompagne de sa définition de calcul et de son périmètre ; une connaissance, de son test de robustesse ; une décision, de son indicateur de suivi.

Définition. Donnée — data — un fait enregistré à un instant précis par un système, avec une unité : une valeur de case. Elle n'est pas « la réalité », elle est ce que le logiciel a bien voulu noter, et rien de plus.

Définition. Information — une donnée replacée dans son contexte : quoi, qui, quand, combien, dans quelle unité. La même valeur cesse d'être ambiguë dès qu'on la date et qu'on la rattache à une source.

Définition. Connaissance — insight — deux informations comparées plus une explication que l'on peut discuter. Elle se reconnaît à ce qu'elle surprend quelqu'un de compétent et qu'elle appelle une réaction.

Définition. Décision — un engagement : une action, un responsable, une date, des conséquences assumées. C'est le seul maillon qui change l'état de l'entreprise.

5.2 Les six phrases d'une demande professionnelle, et comment les ouvrir

Les demandes arrivent presque toujours sous six formes. À chaque forme correspond une ouverture, à faire **avant** de toucher un fichier.

La demande	Ce qu'elle veut dire le plus souvent	Question analytique qui en sort
« Est-ce que ça marche bien ? »	juger une performance contre une attente	« le CA mensuel du magasin 5 en 2025 dépasse-t-il l'objectif mensuel, et de combien ? »
« Pourquoi ça baisse ? »	identifier un facteur de variation	« la baisse de marge vient-elle du prix moyen, du mélange de catégories ou des remises ? »
« Compare-nous les magasins »	classer et expliquer les écarts	« à superficie comparable, quel écart de CA par vendeur entre magasin 5 et magasin 2 ? »
« Fais un tableau de bord »	suivre dans le temps un petit nombre de décisions	« quels sont les trois indicateurs dont la direction décide quelque chose chaque lundi ? »
« Combien on a fait ? »	un chiffre officiel, avec définition	« CA TTC encaissé, retours déduits, magasin 5, du 01/01 au 31/12/2025 : ... »
« Tu peux me sortir ça rapidement ? »	urgence = périmètre à réduire	« que doit contenir la réponse pour être utile lundi, et que peut-on laisser de côté sans mentir ? »

Comment ouvrir une demande : la méthode des trois « pourquoi » et du « et alors ».

1. Pourquoi voulez-vous ce chiffre ? → pour arbitrer X.
2. Pourquoi maintenant ? → une décision a une échéance.
3. Et si la réponse est celle que vous n'attendez pas, que changez-vous ? → cette question, la plus utile, révèle la décision.
4. « Et alors ? » appliqué au résultat : si la réponse ne change rien, le chiffre ne sera jamais lu. Vous venez d'économiser une semaine de travail à tout le monde.

Ces quatre phrases se tiennent en une minute dans un couloir ; elles font gagner une semaine et évitent un conflit. Dans un cabinet ou une DSI, cette minute s'appelle le brief ou le cadrage ; le document qui en sort, le **cahier des questions**.

5.3 La question analytique : une grammaire, cinq composants

Une question analytique recevable contient **cinq** composants. Sans l'un d'eux, elle se transforme en débat d'opinion.

Quel [OBJET : mois de l'année 2025]
présente le CA TTC [UNITÉ + DÉFINITION : encaissements hors retours, TVA 18 % incluse]
le plus éloigné de la médiane [COMPARAISON + RÈGLE]
au magasin 5 [PÉRIMÈTRE] ?

- **Objet** — l'entité que l'on compte ou mesure : mois, produit, vendeur, client, ticket.
- **Unité et définition** — « FCFA TTC », « nombre de tickets », « quantité en kg ». Écrire la **formule** (« somme de `montant_ttc`, retours inclus avec leur signe ») interdit les deux réponses différentes.
- **Comparaison** — par rapport à quoi : un objectif, l'année précédente, la médiane, un autre magasin. « Grand » n'existe pas.
- **Périmètre** — magasins, période, catégories, clients exclus, mois partiels de 2026.
- **Critère de réussite** — ce qui prouvera la réponse : une valeur attendue avec tolérance (« mon calcul doit redonner 36 073 185 FCFA au fichier propre, à ± 1 ligne près ») et un nom (qui valide).

Le test de qualité, à appliquer vous-même avant de travailler : deux analystes indépendants, avec cette seule phrase, produiraient-ils le même chiffre ? Si non, la question n'est pas prête.

Attention. Le **périmètre implicite** est la première cause de désaccord en analyse : le demandeur pense « mes magasins », vous comprenez « les six magasins du fichier », la direction pense « hors dépôts et hors retours ». Écrivez le périmètre — lieux, période, nature des opérations, exclusions — et faites-le valider avant la première extraction.

5.4 Un chiffre n'est jamais seul : ce qu'il faut dire autour

Une information correcte peut mentir par omission. La checklist, à réutiliser telle quelle en M12 (communication) et à la maintenance M22 :

1. **Définition de calcul** — la formule, en français.
2. **Périmètre** — ce qui est dedans, ce qui est exclu, et les données manquantes (ici : 18 lignes sans client identifié, 486 lignes au montant stocké en texte dans le fichier brut de l'atelier).
3. **Période** — début, fin, et années partielles signalées.
4. **Incertitude** — ce qui dépend d'un choix (inclure ou non les retours ; nettoyer ou non les 9 lignes en double).
5. **Comparaison** — un chiffre brut ne dit rien sans repère.
6. **Limites** — ce que la donnée ne peut pas répondre (ici : aucune table de coûts de structure dans le jeu de l'atelier, donc la **marge nette** est hors de portée, seule la marge brute est calculable).
7. **Source et date** — quel fichier, quelle version, calculé quand.

Sept lignes écrites honnêtement. C'est ce qui sépare un chiffre « que personne ne conteste » d'un chiffre « qu'on ne regarde pas ».

Définition. Métrique — measure — la définition de calcul d'un indicateur, écrite noir sur blanc : ce qui entre, ce qui sort, sur quelle période, comment on additionne. Une métrique non écrite est une métrique différente selon les gens.

Définition. Indicateur — KPI (key performance indicator) — une métrique suivie dans le temps parce qu'elle est rattachée à un objectif et à un seuil qui déclenche quelque chose. Sans objectif ni seuil, ce n'est pas un indicateur : c'est un nombre que l'on regarde passer.

5.5 Le triangle de la décision : coût, délai, preuve

Toute demande se situe dans un triangle. Vous ne pouvez pas optimiser les trois à la fois :

- **Décision urgente, coût faible** (fermer le magasin un samedi) → une approximation solide suffit ; l'ordre de grandeur et le sens de l'écart.
- **Décision chère, délai court** (commander un camion de stock) → il faut une fourchette et une méthode explicite, pas un chiffre unique.
- **Décision publiée** (bilan, arbitrage entre magasins, note au conseil) → la preuve prime sur la vitesse : définition écrite, périmètre validé, journal, reproductibilité.

Un bon cadrage commence par demander **quelle décision** dépend du chiffre : c'est elle qui fixe le niveau d'exigence, pas l'outil, pas l'habitude de la direction. En entretien d'embauche, cette phrase fait plus d'effet que n'importe quelle liste de logiciels.

Conseil professionnel. Notez, dans votre journal, la **décision attendue** de chaque analyse, et, six mois plus tard, si elle a été prise. Ce qui vous rend professionnel n'est pas la finesse du modèle : c'est le taux de décisions réellement déplacées par votre travail. Un analyste qui a ce taux à 30 % est précieux ; celui qui ne l'a jamais mesuré est remplaçable.

Attention. Le piège du vocabulaire, le plus fréquent en début de parcours : **une donnée n'est pas une information**. La valeur 56 658 dans une cellule n'est pas le chiffre d'affaires ; elle devient information quand on sait qu'elle est TTC, en FCFA, pour la ligne 1 du ticket du 1^{er} janvier au magasin 5. De la même façon, une information n'est pas une connaissance : « 36 073 185 FCFA » sans comparaison ne permet à personne de décider. Si vous reprenez le vocabulaire mais pas les frontières entre les quatre mots, le chapitre n'a servi à rien.

Attention. « Il faut regarder de plus près » n'est pas une décision, et « j'ai analysé les ventes » n'est pas un résultat. Une décision s'écrit avec un verbe d'action, un responsable, une date et ce que l'on accepte de perdre. Une note qui n'en contient aucune se range au lieu de se appliquer.

À retenir. Un chiffre seul ne veut rien dire. Avant d'écrire quoi que ce soit, notez autour du nombre la période, le périmètre, l'unité, la source et le calcul : ces cinq éléments occupent trois lignes et suppriment la moitié des allers-retours. C'est la différence entre un fichier et une analyse.

6. Exemple concret : la même ligne, quatre niveaux

Le fichier de l'atelier, ligne 1 : T05-250101-075845 ; 2025-01-01 ; 11:01 ; Magasin 5 – Kaya Marché ; Moussa Ilboudo ; client 10857 ; Plâtre de construction 25 kg – réf 1 ; 11 ; 4 500 ; 0,03 ; 48 015 ; 56 658.

Niveau	Énoncé	Ce qui a été ajouté	Ce qui reste à dire
Donnée	11 sacs à 4 500 FCFA	rien	était-ce une commande ou un enlèvement ?
Information	magasin 5, 2025, 316 tickets, 489 lignes, CA TTC 36 339 317 FCFA tel que reçu	agrégation, filtre date + magasin	le total inclut 9 lignes en double
Information nettoyée	36 073 185 FCFA après retrait des doublons	décision de nettoyage (+ 0,74 % d'écart)	la définition : retours inclus ?
Connaissance	décembre 5 292 517 vs mai 1 258 801 → ratio 4,2 ; Plomberie = 24,3 % du CA	comparaison regroupement	+ l'écart est-il dû aux clients ou aux produits ?

Niveau	Énoncé	Ce qui a été ajouté	Ce qui reste à dire
Décision	réapprovisionnement anticipé au 20/11, responsable des achats, budget +1,4 M FCFA	acteur, échéance, coût, indicateur	comment saura-t-on que c'était juste ?

Notez le chiffre-clé du passage de la ligne 2 à la ligne 3 : un total change de **266 132 FCFA** (36 339 317 – 36 073 185) à cause de 9 lignes dupliquées. Une décision prise sur le premier chiffre l'aurait été sur une surévaluation de **0,74 %**. Voilà, en miniature, pourquoi les modules 3 à 5 (nettoyage, contrôle, documentation) précèdent l'analyse : sans eux, la connaissance est faussée dès l'information.

7. Démonstration pas à pas : ouvrir une demande et la rendre traîtable

Exécutons, sur papier, le cadrage complet d'une demande réelle du fil rouge. **La demande** (mail du directeur général) : « Les remises augmentent, on donne trop. Regarde ça et dis-moi ce qu'il en est. »

Étape 1 — Repérer les mots non mesurables. « augmentent » (par rapport à quand ?), « trop » (par rapport à quoi ?), « ça » (quel objet ?). Trois mots, trois questions.

Étape 2 — Ouvrir la décision cachée (les trois pourquoi). Réponse du directeur, à imaginer et à demander : « le conseil d'administration veut réduire la charge de remise de 20 % l'an prochain, sans perdre les gros clients ». La décision est donc : falloir-il resserrer la politique de remise, et sur qui ?

Étape 3 — Écrire la question analytique.

« En 2025, magasin 5 : la remise moyenne par ticket et la part de tickets à remise supérieure à 5 % varient-elles selon le type de client, et quel serait l'effet d'un plafond à 5 % sur le CA TTC des 20 clients les plus remisés ? »

Elle contient objet (ticket), unité (pourcentage de remise, FCFA de CA), comparaison (par type de client ; avant/après plafond), périmètre (2025, magasin 5), et une amorce de critère de réussite (l'effet chiffré sur 20 clients).

Étape 4 — Écrire le critère de réussite et les limites, avant de calculer. Critère : le CA TTC du périmètre doit redonner **36 073 185 FCFA** sur le fichier propre, sinon mon filtre est faux. Limites : le fichier ne permet pas de savoir si un client a acheté **ailleurs** (autres magasins) ni s'il a négocié d'autres conditions ; et l'effet d'un plafond suppose un comportement client que la donnée ne contient pas. Cette limite doit figurer dans la réponse, sinon le chiffre est un mensonge poli.

Étape 5 — Choisir le niveau de preuve. Décision vue au conseil → colonne « preuve » du triangle : le chiffre sera contestable, donc périmètre + définition + journal, et non un simple pourcentage sorti d'un tableau croisé.

Étape 6 — Rédiger la note d'une page (structure imposée par le manuel).

1. Décision visée	2 lignes
2. Question traitée	2 lignes
3. Réponse, chiffre en gras	3 lignes + tableau
4. Méthode et périmètre	4 lignes
5. Ce que cela ne dit pas	3 lignes
6. Recommandation + échéance	2 lignes

Une note qui ne tient pas dans cette structure ne sera pas lue. Vous l'écrivez **avant** l'analyse, avec des trous ; remplir les trous est alors un travail, pas une improvisation.

8. Erreurs fréquentes

Symptôme	Cause	Correction
Trois semaines de travail, réponse inutilisée	Question jamais écrite, demandeur jamais relancé	Cadrage de 10 min avec le demandeur, note d'intention d'une page, validation avant extraction
Deux totaux différents, chacun « juste »	Définitions implicites divergentes (retours inclus ou non, TTC ou HT, périmètre)	Écrire la formule, l'unité, la période, le périmètre dans un dictionnaire partagé
« Le CA baisse » dit avec assurance	Comparaison mal choisie (mois partiel contre mois plein, année partielle 2026 contre 2025 pleine)	Toujours préciser les bornes de période ; dans le jeu de l'atelier, 2026 couvre janvier à août seulement
Le chiffre exact est rejeté	Présenté sans méthode ni limites	Ajouter la note de périmètre et l'incertitude : cela rend le chiffre défendable
La demande est réalisée mais « trop lente »	Confusion urgence / exigence, tout produit au même niveau	Classer chaque demande dans le triangle (coût · délai · preuve) et négocier le niveau
Confusion donnée / information dans un mémoire ou un oral	Vocabulaire employé comme un ornement	Repère : une information se réfute par un fait ; une donnée, non. Si l'énoncé est réfutable, c'est de l'information

9. Bonnes pratiques professionnelles

- [] Une question analytique écrite avant toute extraction, avec ses cinq composants.
- [] Un critère de réussite chiffré et une date de validation fixés **à l'avance**.
- [] La définition de calcul de chaque indicateur notée dans un dictionnaire commun (elle vivra plus longtemps que le fichier).
- [] Le périmètre rappelé dans chaque réponse, y compris à l'oral : « magasin 5, 2025, retours inclus ».
- [] La limite écrite même si elle dérange : une limite annoncée est un crédit, une limite découverte est un procès.
- [] Une note d'une page plutôt qu'un classeur de 30 onglets.
- [] « Et alors ? » appliqué à chaque indicateur avant de le construire.
- [] Les six mois de suivi : noter si la décision a été prise.

10. Exercice guidé — les cinq demandes du patron, faites ensemble

Contexte. Le directeur général de Sahel Distribution passe à votre bureau et lâche, en dix secondes : (a) « Je veux savoir si le magasin 5 est meilleur que les autres. » (b) « Nos prix sont-ils trop bas ? » (c) « Combien on a vendu de plâtre ? » (d) « Le commercial Bationo mérite-t-il sa prime ? » (e) « On perd des clients ? »

On reprend une par une ; à chaque fois, remplissez les cinq composants. Voici la méthode appliquée à (a) et (b), puis vous ferez les trois autres.

(a) « le magasin 5 est meilleur que les autres »

- Ce qui cloche : « meilleur » n'est pas mesurable ; « les autres » n'est pas un périmètre (6 lignes dans `magasins.csv`, dont un dépôt qui ne vend pas au comptoir).
- Décision probable : arbitrer un budget d'agrandissement ou de transfert de personnel.
- Question réécrite : « Sur 2025, le CA TTC par m² de surface de vente et le CA TTC par vendeur du magasin 5 se situent-ils au-dessus de la médiane des cinq magasins, en excluant le dépôt ? »
- Critère de réussite : les deux ratios recalculés doivent apparaître dans le même tableau, avec le numérateur (période, retours inclus) et le dénominateur (surface en m² issue de `magasins.csv`, 6 lignes).
- Limite : le fichier ne contient pas de coût de structure, donc « meilleur » ici = plus rentable **en apparence**, pas plus rentable en marge nette. À écrire noir sur blanc.

(b) « nos prix sont-ils trop bas ? »

- Ce qui cloche : « trop bas » par rapport à la concurrence, au coût, ou à l'élasticité ? Trois questions différentes, trois jeux de données différents (le troisième n'existe pas ici).
- Décision probable : réviser la grille tarifaire avant la campagne de décembre.
- Question réécrite : « Entre 2023 et 2025, le prix moyen HT du mètre cube de gravier 15/25 a-t-il augmenté moins vite que son coût d'achat HT, et dans quelle proportion la remise accordée explique-t-elle l'écart de marge brute ? »
- Ce que la donnée permet : `couts_achat.csv` (1 694 lignes de prix d'achat par période) et les `prix_unitaire_ht` des ventes → l'écart prix/coût est calculable.
- Ce qu'elle ne permet pas : le prix des concurrents. Réponse honnête : « mesurable en interne, pas en externe, sauf relevé terrain ». Cette réponse est un résultat professionnel, pas un échec.

Vos trois autres (à faire maintenant, corrigés au §12) : réécrire (c), (d), (e) en questions analytiques complètes, en indiquant pour chacune **la table** où se trouve la réponse et **ce qui manque**.

11. Exercices autonomes

Exercice 2.1 (★) — Classement. Pour chacun des 10 énoncés suivants, indiquez D (donnée), I (information), C (connaissance) ou X (décision), et corrigez les énoncés mal placés pour les faire monter d'un niveau : 1) 4 500 FCFA ; 2) 1 406 sacs de plâtre vendus au magasin 5 en 2025 ; 3) le magasin 5 vend 22 % de plus que le magasin 2 ; 4) facturer la livraison 5 000 FCFA à partir du 1^{er} novembre ; 5) le client 10857 ; 6) la remise moyenne des 20 premiers clients est de 6,4 %, soit 2 points de plus que les autres ; 7) décembre est le mois le plus rentable ; 8) il faudrait faire quelque chose sur les retours ; 9) le ticket moyen est de 114 156 FCFA ; 10) supprimer la gratuité de livraison pour les achats de moins de 50 000 FCFA. (attendu : 1-D, 2-I, 3-C, 4-X, 5-D, 6-C, 7-C, 8 — aucune des quatre : c'est une intention, pas une décision)

Exercice 2.2 (★) — Cinq composants. Réécrivez en question analytique complète : « combien de clients nous avons perdus ? ». (attendu : définition de « perdu » (nombre de mois sans achat ?), période, périmètre, unité (nombre de clients distincts, pas de lignes de vente), comparaison (N-1), critère de réussite)

Exercice 2.3 (★★) — Et alors ? Vous calculez que le 13 septembre 2025, un seul jour, réalise 4 714 858 FCFA au magasin 5. Écrivez les deux phrases qui rendent ce chiffre utile, et la phrase qui montre qu'il peut être trompeur. (attendu : comparaison à la médiane quotidienne, contexte (livraison de chantier), limite (un jour ≠ une tendance))

Exercice 2.4 (★★) — Le chiffre qui dérange. Un total passe de 36 339 317 à 36 073 185 FCFA après suppression de 9 lignes en double. Rédigez les deux phrases à envoyer au directeur : une pour annoncer, une pour prévenir du risque si l'on garde l'ancien total. (attendu : annonce = 0,74 % de surévaluation, motif = doublons ; risque = décision de stock sur un volume fictif)

Exercice 2.5 (★★) — Note d'une page. À partir du §6 de ce chapitre, rédigez la note en six rubriques sur le sujet : « faut-il avancer les réapprovisionnements au 1^{er} décembre ? », en utilisant uniquement les chiffres cités. (attendu : 6 rubriques, ≤ 1 page, les 7 éléments de véracité du §5.4, aucune recommandation sans acteur ni échéance)

12. Correction détaillée

Exercice 2.1. 1-D (valeur sans contexte) ; 2-I (agrégation + période + périmètre) ; 3-C (comparaison entre deux objets) ; 4-X (action, date, effet) ; 5-D (un identifiant n'est pas une information tant qu'on ne dit pas à quoi il sert) ; 6-C ; 7-C **seulement si** le critère « rentable » est défini — sinon 7 est une information mal typée, « rentable » exigeant une marge, et le jeu ne contient pas de coûts de structure ; 8 = aucune catégorie, c'est une intention : à transformer en décision (quoi, qui, quand) ; 9-I ; 10-X. Correction d'un énoncé : « 1) 4 500 FCFA » devient « 1) le prix unitaire HT du plâtre 25 kg au magasin 5, en 2025, est de 4 500 FCFA » → il passe en I.

Exercice 2.2. Modèle recevable : « Entre le 01/01/2024 et le 31/12/2025, combien de clients ayant acheté au moins 3 fois en 2024 n'ont effectué aucun achat entre le 01/07/2025 et le 31/12/2025, magasin 5 et dépôt exclus, et comment ce nombre se compare-t-il à la même définition un an plus tôt ? ». Composants vérifiés : objet = clients distincts ; unité = nombre de clients, pas de lignes ; comparaison = même définition à N-1 ; périmètre = deux magasins exclus ; critère = le calcul doit s'appuyer sur `id_client` et exclure `id_client = 0` (comptoir, 18 lignes manquantes dans l'échantillon de l'atelier + `id_client=0` pour le comptoir : deux cas distincts). Un candidat qui répond « le nombre de lignes de vente sans client » est hors sujet : on compte des clients, donc des identifiants distincts.

Exercice 2.3. Phrases utiles : « ce jour représente 2,3 % du CA de décembre et 2,7 fois le CA médian d'un jour de vente du magasin 5 » ; « il correspond à une livraison de chantier de plomberie, visible par 3 tickets supérieurs à 200 000 FCFA ». Phrase d'honnêteté : « un jour exceptionnel ne prouve rien sur la tendance ; l'argument saisonnier exige les 12 mois ».

Exercice 2.4. Annonce : « Le total de l'extrait 2025 du magasin 5 était surévalué de 266 132 FCFA (+0,74 %) : neuf lignes figuraient deux fois dans le fichier reçu. Après retrait, le CA TTC de l'année s'établit à 36 073 185 FCFA. » Prévention : « tant que les doublons restent, tout calcul de volume, de panier moyen et de besoin de stock est gonflé d'autant — soit environ 1,5 % de stock en trop sur un budget de 18 M FCFA. »

Exercice 2.5. Barème de la note (12 points) : 2 pour la décision visée formulée en une ligne ; 2 pour la question avec cinq composants ; 2 pour les chiffres exacts (décembre 5 292 517 FCFA, mai 1 258 801 FCFA, ratio 4,2) ; 2 pour la méthode et le périmètre (fichier propre, 480 lignes utiles sur 489, magasin 5) ; 2 pour les limites (aucun coût de structure, donc marge nette non mesurable ; extrait, donc pas de comparaison avec les autres magasins) ; 1 pour la recommandation avec acteur et échéance ; 1 pour la lisibilité (une page, six rubriques, pas de jargon). Un devoir qui ajoute un indicateur inventé (taux de service, rotation de stock) est pénalisé : ces données ne sont pas dans le périmètre.

13. Mini-projet M01.P2 — « Le cahier des questions du magasin » (40 min)

Objectif : produire le document qui, en entreprise, s'appelle un cahier des questions ou une note de cadrage.

Livrable : un fichier `03_analyse/2026-09-17_cahier_questions_M5_minani.txt` contenant :

1. **cinq demandes** recueillies (réelles auprès de commerçants, parents, patrons de stage, ou issues du fil rouge : on vous en fournit trois, vous en ajoutez deux) ;
2. pour chacune : la décision visée, la question analytique complète, les tables du socle nécessaires (ventes, clients, produits, objectifs, stocks...), ce qui manque, et le niveau du triangle coût-délai-preuve ;
3. une sixième ligne, la plus utile : « questions que je ne peux pas traiter faute de donnée » — trois minimum.

Critères : chaque question contient les cinq composants ; aucune ne contient un adjectif non chiffré ; la rubrique « ce qui manque » est renseignée pour les six ; le tout tient sur une page imprimée en A4 à 11 pt. C'est le document d'entrée du **projet M01.P** (§projet du module) : gardez-le, il y sera noté.

14. Résumé du chapitre

Quatre maillons, et chacun a son test : la donnée existe dans la source, l'information est reproductible avec la même définition et le même périmètre, la connaissance survit à un autre calcul raisonnable, la décision a un acteur et une échéance. Votre valeur ne se mesure pas au nombre de chiffres produits mais au nombre de décisions déplacées. Entre les deux, le métier tient dans une phrase correctement écrite : objet, unité, période, périmètre, comparaison, critère de réussite — plus les limites, dites avant que quiconque ne les découvre.

15. À retenir

À retenir. 1. **Donnée ≠ information ≠ connaissance ≠ décision** : la frontière est le contexte, la comparaison, l'engagement. 2. Une **question analytique** a cinq composants (objet, unité+définition, comparaison, périmètre, critère) ; sans eux, deux analystes divergent. 3. **Toujours dire ce que le chiffre ne dit pas** : périmètre, incertitude, limites. Une limite annoncée protège ; une limite découverte détruit. 4. Le **triangle coût · délai · preuve** décide du niveau d'exigence — pas le logiciel. 5. **Un chiffre qui ne change aucune décision n'est pas un résultat**, c'est un passe-temps.

16. Évaluation formative (auto-correction, 8 min)

1. Un collègue écrit : « le CA du magasin 5 est bon ». Quelle catégorie (D/I/C/X) et pourquoi ? (aucune des quatre : jugement sans comparaison ni définition ; à convertir en question analytique)
2. Donnez la formule de calcul qui manque à « 36 073 185 FCFA » pour que ce soit une information défendable. (somme de `montant_ttc`, magasin 5, du 01/01 au 31/12/2025, retours inclus avec leur signe, doublons retirés, TVA 18 % comprise)

3. Pourquoi décembre = $4,2 \times$ mai n'est-il **pas** encore une décision ? (pas d'acteur, pas d'échéance, pas de coût ; c'est une connaissance, exploitable par quelqu'un d'autre)
4. Citez une limite structurelle du jeu de données du fil rouge qui empêche de répondre à « sommes-nous rentables ? ». (aucun coût de structure : loyers, salaires, transport absents → marge nette non calculable)
5. **Question ouverte** : réécrivez en question analytique la demande « est-ce qu'on donne trop de remises ? » et indiquez, en une ligne, comment vous saurez que votre réponse est correcte. (réponse libre, évaluée sur la présence des cinq composants + un critère chiffré)

M01.C03 — La table : lignes, colonnes, cellules, en-têtes, identifiants

Outil de ce chapitre : Excel et LibreOffice Calc (les deux sont montrés côte à côte), plus un éditeur de texte pour voir le fichier tel qu'il est. **Durée indicative :** 5 h. **Niveau :** N1.

L'idée du chapitre. Quatre-vingt-dix pour cent du travail d'analyse se passe dans des tables. Savoir **lire** une table — c'est-à-dire expliquer ce que représente une ligne, ce que compte une colonne, ce qui identifie un objet — est une compétence plus rare et plus rentable que la connaissance d'une fonction. Tout ce qui suit, du SQL au DAX, repose sur le mot **grain** : si vous ne savez pas répondre à « une ligne, c'est quoi ? », chaque total que vous produirez sera contestable.

1. Objectifs du chapitre

À la fin de ce chapitre, vous saurez :

1. **Décrire** une table inconnue en six phrases (objet, grain, clés, mesures, attributs, période couverte) ;
2. **Distinguer** une ligne d'une observation, une colonne d'une variable, un en-tête d'une donnée, et repérer les trois mises en forme qui cassent une table ;
3. **Identifier** la clé d'une table et expliquer pourquoi `id_ticket` et `n_ticket` ne comptent pas la même chose : calculer `COUNT(*)` et le nombre de valeurs distinctes dans un tableur ;
4. **Lire** un fichier brut tel qu'il est : séparateur, encodage, lignes de chapeau, nombres décimaux à virgule ;
5. **Diagnostiquer** un tableau mal structuré (colonnes qui sont en réalité des valeurs) et le reconnaître sans le retravailler ;
6. **Écrire** une fiche d'identité de table, le livrable réutilisé de module en module.

2. Pourquoi cette notion est importante

Situation 1 — le total double. Un analyste relie le tableau des ventes au tableau des paiements **sans savoir que le second contient trois lignes par vente** (trois échéances de paiement). Le CA ressort multiplié par trois. Personne ne comprend pendant deux jours. La cause tient en un mot : grain. Celui qui a vérifié « une ligne = ? » dans chaque table avant de la relier n'a pas eu ce problème.

Situation 2 — le client qui compte deux fois. Le rapport annonce « 1 240 clients actifs ». Un contrôle rapide montre 1 240 **lignes** pour 1 105 **identifiants distincts** : des achats multiples. Compter des lignes quand on veut des clients est l'erreur de mesure numéro un des débutants, et elle survit aux tableurs les plus chers.

Situation 3 — « le fichier ne s'ouvre pas correctement ». Un fichier de 12 000 lignes livré par un fournisseur arrive : les colonnes se collent, les accents sont cassés, les dates sont devenues des nombres. Le collègue conclut que le fichier est corrompu. Il est parfaitement valide : il est en `;`, en encodage Windows-1252, avec des décimales à la virgule. Ce chapitre vous donne les quatre réflexes qui règlent 100 % de ces cas, sans logiciel spécialisé.

Dans les faits. Le fichier de l'atelier de ce module contient **489 lignes** et **13 colonnes**. Le même, nettoyé, en contient **480**. Il compte **316 tickets**, donc **1,52 ligne par ticket en moyenne** et jusqu'à **4**. Retenez ces quatre nombres : vous allez les retrouver dans chaque exercice du module, et le jour où vous les écrirez de mémoire sans les vérifier, vous ferez une erreur de 55 % sur le nombre de ventes.

3. Explication simple

Une table, c'est un **registre** : un cahier où chaque page tient en une ligne. Deux questions suffisent pour la comprendre, et elles se posent dans cet ordre :

1. **Une ligne, c'est quoi ?** → c'est le **grain**. « Une ligne = un article vendu sur un ticket » n'est pas la même chose que « une ligne = une vente ». Dans le premier cas, 489 lignes = 489 articles ; dans le second, ce serait 489 ventes — et c'est faux, il y a 316 ventes.
2. **Qu'est-ce qui rend une ligne unique ?** → la **clé**. Ici, `n_ticket` identifie le ticket, mais il se répète sur les lignes du même ticket : il n'est donc **pas** la clé de la table. La clé est le couple (`n_ticket`, `produit`).

Les colonnes se répartissent alors en trois familles, et cette famille détermine ce que vous aurez le droit de faire plus tard :

- des **identifiants** (`n_ticket`, `client`) : ils relient à d'autres tables ;
- des **attributs** (`magasin`, `vendeur`, `categorie`, `date`) : ils décrivent, ils servent à filtrer et à regrouper ;
- des **mesures** (`quantite`, `prix_unitaire_ht`, `montant_ht`, `montant_ttc`) : elles s'additionnent ou se moyennent.

Une quatrième famille apparaît dans les fichiers réels : les **calculées** (`montant_ht` peut être reconstitué à partir de `quantite`, `prix_unitaire_ht` et `remise`). Elles sont pratiques mais dangereuses : si une colonne calculée est stockée dans le fichier et que le fichier a été édité à la main, elle peut contredire ses propres composants. C'est exactement le cas dans notre échantillon, et vous le vérifierez en exercice.

Une table vue de près : en-têtes, variables (colonnes), observations (lignes)

n_ticket	date	magasin	vendeur	client	quantite	prix_unitaire_ht	montant_ttc
T05-250101-075845	2025-01-01	Magasin 5	Moussa I.	10857	11	4 500	56 658
T05-250101-075845 ①	2025-01-01	Magasin 5	Moussa I.	0.0 ②	2	12 000	28 320
T05-250101-075846	2025-01-01	Magasin 5	Salamatou S.	③	2 000	21 950	51 802
T05-250102-075902	2025-01-02	Magasin 5	Adama B.	3312	1	14 000	16 520

① un ticket occupe 2 lignes : compter les lignes pour compter les ventes gonfle le résultat de 55 % (le fichier compte 489 lignes, 316 tickets, et jusqu'à 4 lignes pour un même ticket).

② « 0.0 » n'est pas un manque : c'est la vente au comptoir, sans client identifié. Elle est volontaire dans le fichier et doit rester dans les totaux.

③ cellule vide = valeur absente : 18 lignes du fichier sont dans ce cas. On signale, on documente, on ne remplit pas au hasard.

- Grain : une ligne = un article vendu sur un ticket ; 1,52 ligne par ticket en moyenne.
- Clé : `n_ticket` identifie le ticket ; (`n_ticket`, `produit`) identifie la ligne. Sans clé, pas de fusion propre.
- Schéma : les 13 colonnes et leur type. Le CSV ne le dit pas : le déduire, puis le vérifier.

Figure 3 — Les quatre premières lignes réelles du fichier de l'atelier, annotées.

4. Vocabulaire essentiel

Français — English	Définition simple	Piège à éviter
Table — table	Rectangle de données : des colonnes nommées, des lignes sans ordre significatif.	Un « tableau » Excel avec titres fusionnés n'est pas une table, même s'il y ressemble.
Ligne — row / record	Un enregistrement : un objet du monde réel, au grain défini.	Compter des lignes pour compter des objets différents des lignes.
Colonne — column / field / variable	Une caractéristique mesurée pour tous les enregistrements.	Une colonne qui mélange deux choses (quantité et unité : « 11 sacs »).
Cellule — cell	L'intersection ligne x colonne : une valeur, une seule.	Mettre deux informations dans une cellule (25 kg / sac).
En-tête — header	Première ligne, noms des colonnes.	En-tête sur plusieurs lignes, ou lignes de titre avant l'en-tête.
Grain — granularity	Ce que représente une ligne, formulé en une phrase.	Confondre grain et niveau d'agrégation (« c'est mensuel » ne dit pas ce qu'est une ligne).
Clé primaire — primary key	— Colonne ou couple de colonnes qui rend chaque ligne unique.	Une clé qui admet des doublons n'est pas une clé ; <code>id_ticket</code> ici, ne l'est pas.
Clé étrangère — foreign key	— Colonne qui pointe vers la clé d'une autre table.	Un identifiant présent dans les ventes mais absent des clients (ici 486 lignes dans le jeu complet).
Valeur distincte — distinct value	— Une valeur, comptée une seule fois.	<code>COUNT</code> ≠ <code>COUNT DISTINCT</code> : l'un compte des lignes, l'autre des objets.
Séparateur — delimiter	— Caractère qui sépare les colonnes dans un fichier texte (;, ,, tabulation).	Le même caractère utilisé dans une valeur non protégée casse l'alignement.
Encodage — character encoding	— Table de correspondance octets ↔ caractères (UTF-8, Windows-1252).	Ouvrir un fichier UTF-8 en Windows-1252 : les accents deviennent Ã©.
Chapeau / pied de page — preamble / footer	Lignes de titre, de date, de signature avant ou après les données.	Les importer comme données : la ligne 1 de <code>tarif_fournisseur_peinture.csv</code> n'est pas une colonne.

5. Cours approfondi

5.1 Les six phrases de la fiche d'identité d'une table

Face à une table inconnue, écrivez six lignes. Ce rituel de trois minutes remplace avantageusement une demi-journée d'erreurs, et c'est le livrable (1) du projet M01.P.

1. **Nom et source** — `ventes_magasin5_2025.csv`, reçu le 17/09/2026 de la caisse du magasin 5 (export nocturne).
2. **Objet** — la table parle d'articles vendus.
3. **Grain** — une ligne = un article d'un ticket de caisse.
4. **Clé** — (`n_ticket`, `produit`) ; aucune colonne unique à elle seule.
5. **Mesures et attributs** — mesures : `quantite`, `prix_unitaire_ht`, `remise`, `montant_ht`, `montant_ttc` ; attributs : `date`, `heure`, `magasin`, `vendeur`, `client`, `produit`, `categorie`.
6. **Étendue** — 489 lignes ; dates du 01/01/2025 au 31/12/2025 (31 jours comportent au moins une ligne) ; 316 tickets ; 145 produits différents ; 7 catégories ; 4 vendeurs.

La sixième phrase est un inventaire de **bornes** : c'est elle qui révèle la moitié des anomalies, parce qu'une borne qui n'a pas de sens signale un problème avant tout calcul (voir §5.5).

Définition. Table — un rectangle de données où chaque colonne est une caractéristique mesurée pour tous les enregistrements et chaque ligne un objet du monde réel, au grain choisi. Entre deux lignes, il n’y a pas d’ordre significatif : l’ordre est une affaire d’affichage, jamais une information.

Définition. Enregistrement — row / record — la ligne, c’est-à-dire un objet : une ligne de ticket, et non un ticket, non un client, non un mois.

5.2 Le grain, seul concept qui compte au début

Écrivez le grain comme une définition d’école : « **une ligne = un-e [objet] pour [combinaison de clés]** ». Exemples pris dans le socle de données du manuel :

Table	Grain correct	Ce que l’on pourrait croire (et qui est faux)
ventes (243 360 lignes brutes)	une ligne = un article vendu sur un ticket	une ligne = une vente → 316 tickets deviennent 489 ventes
clients (23 912 lignes brutes, 23 500 propres)	une ligne = un client	une ligne = un achat → le même client apparaît plusieurs fois
objectifs_de_ca (218 lignes)	une ligne = un magasin pour un mois donné	une ligne = une année de magasin
stocks_quotidiens (60 000 lignes)	une ligne = un produit dans un dépôt à une date	une ligne = un produit
dim_date (1 339 lignes)	une ligne = un jour calendaire	une ligne = un jour ouvré
remises_manuelles (18 200 lignes)	une ligne = un client pour un mois	une ligne = une remise accordée

Trois propriétés à vérifier systématiquement :

- **l’unicité** : une clé, ça se prouve. Comptez les lignes (489) et les valeurs distinctes de la combinaison de colonnes qui devrait être unique (316 tickets, donc **non unique**) ;
- **la complétude** : le grain annonce-t-il des lignes qui n’existent pas ? Exemple réel du socle : le fichier de stocks contient des jours sans relevé — le magasinier n’a pas toujours noté. Une table « par jour » sans tous les jours fausse toute moyenne journalière ;
- **la périodicité** : les tables de type « mensuel » (objectifs, remises_manuelles) ont-elles **12 × 6 = 72 lignes attendues par an** ? Ici objectifs en compte 218 pour 5 magasins et 3 ans : il manque des mois — c’est voulu, et vous le traiterez en M12 (analyse d’écart) et M14 (objectifs non atteignables).

À retenir. Le grain n’est pas une information technique : c’est la **seule** qui détermine si un total est une somme ou un double-comptage. Un tableur, un moteur SQL, un modèle sémantique : tous, sans exception, additionnent au grain de la table.

Définition. Grain — granularity — la phrase qui dit ce que représente une ligne. Elle s’écrit avec un article et une période : « une ligne = un article d’un ticket », « une ligne = un client pour un mois ». Le grain décide de tout le reste : ce que l’on peut additionner sans double compte, ce que l’on peut joindre, ce qu’il faut agréger avant.

5.3 Compter comme un analyste : lignes, objets, valeurs distinctes

Dans un tableur, quatre comptages suffisent à décrire une colonne. Les deux outils, littéralement :

Excel (ruban) — sélectionnez la colonne, Statut (barre du bas) affiche Nombre (lignes non vides) et Nombre de valeurs numériques ; pour les distincts, données → **Supprimer les doublons** présente une boîte de dialogue qui indique combien de valeurs uniques ont été trouvées.

LibreOffice Calc — mêmes fonctions dans **Données** → **Standardfilter / Duplizierungen entfernen**, et le compteur de la barre d'état se règle par clic droit pour afficher Nombre au lieu de Somme.

En pratique, on écrit des formules, parce qu'elles restent et se recalculent :

```
=NBVALA(B2:B490)      → 489      lignes non vides (chaque type)
=NB(C2:C490)          → 489      lignes numériques seulement
=Nb.SI.ENS(C2:C490;"<>0") → bornes
=SOMMEPROD(1/FREQUENCE(SI(B2:B490<>"");EQUIV(B2:B490;B2:B490;0));EQUIV(B2:B490;B2:B490;0))) →
distincts (matricielle, à valider Ctrl+Maj+Entrée)
```

Ces formules sont désagréables à lire. C'est le signe exact qu'il faudra du SQL en M07 (COUNT(DISTINCT n_ticket)) ou Python en M08 — mais **savoir quoi compter** est la compétence, la syntaxe n'est que l'outil. Retenez le vocabulaire, commun à tous les logiciels :

- COUNT(*) = le nombre de **lignes** ;
- COUNT(colonne) = le nombre de lignes **non vides** pour cette colonne ;
- COUNT(DISTINCT colonne) = le nombre d'**objets** distincts.

Sur notre fichier : 489 lignes, 316 tickets distincts, 480 lignes après nettoyage, 372 identifiants clients distincts, 145 produits distincts. Le ratio lignes/objets (489 / 316 = 1,52) s'appelle le **nombre moyen de lignes par groupe** ; il dit à lui seul si la table est un détail (proche de 1) ou un agrégat (proche de 1, alors qu'on attend des lignes multiples).

Définition. Clé primaire — primary key — une colonne, ou un couple de colonnes, qui rend chaque ligne unique. Elle ne se décrète pas, elle se vérifie : on compare le nombre de lignes au nombre de valeurs distinctes. Égalité, c'est une clé ; écart, la ligne n'est pas ce que l'on croyait.

Définition. Clé étrangère — foreign key — une colonne qui renvoie à la clé d'une autre table. Elle ne vaut que si la valeur existe en face : un identifiant présent dans les ventes et absent des clients n'est pas une clé, c'est une perte de données.

Définition. Valeur distincte — distinct value — une valeur comptée une seule fois. Compter des lignes et compter des objets sont deux opérations différentes, et les deux chiffres sont justes : c'est la question posée qui tranche.

5.4 Les trois mises en forme qui détruisent une table

Un tableur permet des choses qu'un fichier de données ne doit jamais contenir.

1. **Cellules fusionnées.** Visuellement pratique, fonctionnellement mortel : une fusion cache la valeur dans une seule cellule, donc le tri et les formules décalent tout. Règle : aucune cellule fusionnée dans une zone de données ; si un export fournisseur en contient, on la casse avant de lire (M04).
2. **Plusieurs informations dans une cellule.** Plâtre de construction 25 kg – réf 1 : le poids et la référence sont collés au nom. Le jour où l'on veut agréger par poids, il faut redécouper. Repère : si une valeur contient un séparateur (-, / , (), soupçonnez deux colonnes.
3. **Sous-totaux et lignes de titre dans la zone de données.** Un fichier de caisse propre à imprimer contient souvent ses propres totaux : Total général : 36 339 317 en ligne 490, et le total du mois toutes les 30 lignes. Symptôme : le total calculé est exactement le double du vrai. La ligne de contrôle : compter les lignes dont la colonne n_ticket est vide ou non numérique.

Notre fichier fournisseur `tarif_fournisseur_peinture.csv` cumule trois de ces défauts : **3 lignes de chapeau** avant l'en-tête, un **point-virgule** comme séparateur, et des **décimales à la virgule**. Les 42 lignes du fichier ne contiennent donc que **38 lignes utiles**. Un débutant qui ouvre le fichier et compte 42 références se trompe de 10 %.

Attention. Trois mises en forme d'un tableur détruisent mécaniquement une table. Les **cellules fusionnées** créent des cases vides que tout outil d'import lit comme des lignes cassées. Les **lignes de titre ou de signature avant l'en-tête** font du jour d'impression un nom de colonne. Les **sous-totaux insérés dans une colonne de données** sont ré-additionnés au premier calcul. Un tableau de rapport est une impression, pas une table.

5.5 Les bornes, ou comment trouver une anomalie sans la chercher

Pour chaque mesure, notez min, max, et le nombre de valeurs aberrantes. Sur `ventes_magasin5_2025.csv` :

Colonne	Valeur à retenir	Ce que cela signifie
<code>quantite</code>	minimum négatif (retours), maximum 14 000	7 lignes dépassent 500 unités : ce sont des erreurs d'unité de saisie, pas des ventes
<code>prix_unitaire_ht</code>	323 valeurs distinctes	fourchette réaliste : pas de prix négatif, pas de zéro ici
<code>remise</code>	6 valeurs distinctes	une grille simple, donc toute valeur hors de ces six est une anomalie (M01.C04)
<code>montant_ttc</code>	486 des 489 lignes non numériques	montant stocké en texte : le total d'un tableur serait faux
<code>client</code>	372 identifiants distincts, 18 lignes vides	« vide » n'est pas la même chose que « 0 » : 0 = vente au comptoir
<code>date</code>	55 écritures différentes pour 31 jours	65 lignes en JJ/MM/AAAA : le tri alphabétique est déjà faux

Le réflexe, une fois pour toutes : **avant de calculer un total, regardez les extrêmes**. Trois secondes par colonne sur un fichier de 489 lignes ; sur `ventes_brutes.csv` (243 360 lignes), ce sera un script, et vous l'écrirez en M08.

Attention. Compter les lignes d'une table pour estimer le nombre d'objets est la plus ancienne source de surévaluation du métier. Si une ligne n'est pas l'objet que l'on compte, le total est gonflé d'un facteur qui dépend des données, et l'erreur grandit avec le volume : la bonne habitude est d'afficher les deux chiffres côte à côte.

5.6 Large, long, et le tableau « de rapport »

Deux organisations d'une même information, à savoir reconnaître (la transformation s'apprend en M04) :

format large (une colonne par mois)	format long (une ligne par mois)
magasin janvier février mars	magasin mois CA
M5 2 051 424 4 289 885 3 673 454	M5 1 2 051 424
M2 1 200 000 1 800 000 900 000	M5 2 4 289 885
	M2 1 1 200 000

Le **large** se lit par un humain dans une réunion ; le **long** se charge par un logiciel et se filtre par mois. Le tableau de rapport, lui, est les deux à la fois avec des sous-totaux imbriqués : il est **destiné à être lu**, jamais à être la source d'un nouveau calcul. Un indicateur fiable de la maturité d'un service : ses données de travail sont en long, ses livrables sont en large.

Conseil professionnel. Quand un fichier vous est livré, ne l'ouvrez **pas** en double-clic. Ouvrez-le d'abord dans un éditeur de texte (Bloc-notes, gedit, VS Code) ou par l'assistant d'import du tableur (Données → Importer depuis du texte/CSV). Vous verrez le séparateur, l'encodage, le chapeau, les guillemets, les lignes vides : tout ce qu'un double-clic décide pour vous, silencieusement, et parfois faussement.

6. Exemple concret : lire les deux premiers fichiers du socle

Fichier 1 — ventes_magasin5_2025.csv (489 lignes, 13 colonnes) :

```
n_ticket;date;heure;magasin;vendeur;client;produit;categorie;quantite;prix_unitaire_ht;remise;montant_ht;montant_t
T05-250101-075845;2025-01-01;11:01;Magasin 5 – Kaya Marché;Moussa Ilboudo;10857;Plâtre de
construction 25 kg – réf 1;Matériaux;11;4500;0.03;48015;56 658
T05-250101-075845;2025-01-01;11:01;Magasin 5 – Kaya Marché;Moussa Ilboudo;10857;Gravier 15/25 (m3)
– réf 2;Matériaux;2;12000;0.00;24000;28 320
```

Lecture professionnelle, en une phrase par ligne : deux lignes, **un seul ticket** (075845) → le grain est bien l'article. La troisième colonne de la deuxième ligne montre 28 320 : espace de milliers, donc du texte. Le ticket du haut contient un article à 12000 sans espace : incohérence de format **dans la même table**, donc dans le même export. Le champ `client` vaut 10857 : un identifiant numérique, pas un nom — il faudra le relier à la table clients pour savoir qui c'est. Le champ `remise` vaut 0.03 : une proportion, donc 3 %, jamais 3 (et 3 apparaîtra ailleurs : c'est la faute d'unité du chapitre 4).

Fichier 2 — tarif_fournisseur_peinture.csv (42 lignes, dont 38 utiles) :

```
export genere depuis ELODIE v3
edition le 17/09/2026
peinture saaba sarl | tarif 2026
code_article;libelle;conditionnement;prix_unitaire;unite_mesure;tva
PEINT-014;Peinture acrylique blanc 10 L;pot;27500,00;pot;0.18
```

Quatre enseignements : les trois premières lignes sont du **bruit de document** (chapeau) ; la ligne 4 est **l'en-tête** ; le séparateur est le ; ; la virgule est **décimale**, donc 27500,00 lu dans un contexte français devient 2750000 si l'on force le point, ou 27 500 si l'on respecte la convention — la bonne réponse n'est pas dans le fichier, elle est dans le **choix d'import** (M04). Notez aussi `tva = 0.18` : la TVA du pays, cohérente avec les règles du socle, à vérifier et non à supposer.

7. Démonstration pas à pas : la fiche d'identité complète, avec les deux tableurs

Étape 1 — Import maîtrisé. Excel : **Données → Obtenir des données → À partir de texte/CSV** ; LibreOffice : **Données → Importer une feuille de calcul**. Sélectionnez le fichier `ventes_magasin5_2025.csv`. L'aperçu s'affiche : séparateur ;, encodage **UTF-8** (si les accents sont cassés, passez en Windows-1252, ou l'inverse). Validez **sans charger** la mise en forme. Résultat attendu : 489 lignes sous l'en-tête, 13 colonnes.

Étape 2 — Les six phrases. Remplissez la fiche (§5.1) avec les nombres réels ; ne recopiez aucun nombre sans le vérifier à l'étape 3.

Étape 3 — Les bornes et les distincts. Créez un onglet `controles`, avec une ligne par colonne et les formules :

Colonne	Formule Excel	Formule LibreOffice	Attendu
date	<code>=MIN(--LEFT(A2:A490,10))</code>	<code>=MIN(VALUE(LEFT(A2:A490;10)))</code>	une date de janvier 2025... ou une erreur (c'est l'indice)
quantite	<code>=MAX(I2:I490)</code>	<code>=MAX(I2:I490)</code>	14 000
quantite 500	<code>>=NB.SI(I2:I490;">500")</code>	<code>=COUNTIF(I2:I490;">500")</code>	7
n_ticket lignes	<code>=NBVAL(A2:A490)</code>	<code>=COUNTA(A2:A490)</code>	489
n_ticket distincts	<code>=SOMMEPROD(1/NB.SI(A2:A490;A2:A490))</code>	<code>=SUMPRODUCT(1/COUNTIF(A2:A490;A2:A490))</code>	316
client vides	<code>=NB.EUILL(E2:E490)</code>	<code>=COUNTBLANK(E2:E490)</code>	18
montant_ttc texte	<code>=NB(L2:L490)</code>	<code>=COUNT(L2:L490)</code>	3 (les seuls numériques !)

La dernière ligne est la plus instructive : `=NB` ne compte que les nombres ; il renvoie 3 alors qu'il y a 489 montants. **Donc 486 montants ne sont pas des nombres.** Vous venez de le prouver avec une formule de trois caractères, sans macro, sans SQL.

Étape 4 — Le test du double-comptage. Faites `=SOMME(M2:M490)` sur `montant_ht` : comparez à la somme de `montant_ttc ÷ 1,18`. Les deux doivent être proches (à l'arrondi près). Si l'un est deux fois l'autre, une ligne de sous-total est restée dans les données. Ici, les deux sont cohérents — preuve que le fichier ne contient pas de sous-total, mais bien 9 doublons.

Étape 5 — Le comptage qui ment. Calculez le « nombre de ventes » de deux façons : `=NBVAL(A2:A490) → 489`, et le nombre de tickets distincts `→ 316`. Écrivez en une phrase laquelle des deux est « le nombre de ventes » (**316**) et ce que l'autre représente (**le nombre d'articles facturés**). Cette phrase est la réponse à la moitié des questions de vos futurs collègues.

Étape 6 — Le même exercice sur le fichier fournisseur. Importez avec chapeau ignoré (Excel : « Avancé » `→` lignes à sauter = 3 ; LibreOffice : cochez « Première ligne » et retirez les 3 lignes après import). Vérifiez : 38 lignes utiles, 6 colonnes, `tva = 0,18` partout, `prix_unitaire` avec virgule. Notez dans le journal le nombre de lignes **avant/après** chaque manipulation — l'habitude se prend ici, pas en M18.

8. Erreurs fréquentes

Symptôme	Cause	Correction
1 240 « clients » pour 1 105 clients réels	Comptage de lignes au lieu de valeurs distinctes	Compter <code>DISTINCT</code> ; nommer la métrique (« clients actifs » $\neq$ « lignes de vente »)
Le CA est exactement le double	Ligne de sous-total importée comme donnée	Supprimer les lignes sans clé ou dont la clé est vide ; vérifier avec le ratio lignes/tickets
Les colonnes du CSV sont collées	Séparateur mal indiqué à l'import	Assistant d'import, séparateur ; (ou tabulation), et vérifier l'aperçu avant de valider
Les accents écrits Ã© ou â€”	Encodage UTF-8 lu en Windows-1252 (ou l'inverse)	Changer l'encodage à l'import, pas dans le fichier ; ne jamais réenregistrer un brut
Le tri par date mélange janvier et décembre	Tri alphabétique sur des dates stockées en texte	Convertir en véritables dates (M01.C04) ou trier par une colonne auxiliaire AAAA-MM-JJ
Une date devenue 45 658	Import qui a converti une date en numéro de série	Annuler, réimporter en forçant le type de colonne en « texte », puis convertir explicitement

Symptôme	Cause	Correction
Total <code>montant_ttc</code> = 0	Somme sur une colonne texte	Le défaut du chapitre 4 : forcer la conversion après avoir retiré les espaces de milliers
Le fichier « propre » ne ressemble plus au brut	Écrasement du brut par le tableur (formats, arrondis, dates)	Le brut est en lecture seule ; on travaille sur une copie nommée <code>_propre</code>

9. Bonnes pratiques professionnelles

- [] Import par assistant, jamais par double-clic ; vérifier l’aperçu ligne 1 et la dernière ligne.
- [] Fiche d’identité en six phrases produite **avant** le premier graphique.
- [] Un onglet `controles` par table : lignes, clés distinctes, bornes, comptage des vides.
- [] Ratio lignes/objets écrit noir sur blanc (ici 1,52 ligne par ticket).
- [] Zéro cellule fusionnée, zéro sous-total dans une zone de données.
- [] Le nom des colonnes conservé tel que livré dans la copie propre, avec un dictionnaire qui traduit (M01.C06).
- [] Toute suppression de ligne documentée : nombre avant, nombre après, motif.
- [] Un fichier = une table = un grain. Pas deux niveaux d’agrégation dans le même rectangle.

10. Exercice guidé — décrire la table `clients` en 8 minutes

Point de départ. `01_socle_donnees/data/brut/clients.csv` : 11 colonnes, 23 912 lignes brutes.

1. **Combien de clients ?** Les lignes ne répondent pas. Comptez les valeurs distinctes de `id_client` : **23 500**. L’écart (412) est constitué de doublons quasi-exacts, volontairement injectés dans le jeu — vous les rencontrerez en M04. Conclusion à écrire : 412 lignes de trop, ou 412 clients en moins selon le point de vue ; le bon réflexe est de compter les identifiants, pas les lignes.
2. **Quelles colonnes sont des mesures et lesquelles sont des attributs ?** Mesures : `plafond_credit`, éventuellement `date_creation` (une date n’est pas additionnable : c’est un attribut-ordonnée). Attributs : `nom`, `type_client`, `ville`, `region`, `telephone`, `email`, `segment`, `conditions_paiement`.
3. **Le grain est-il respecté ?** Non, à cause des doublons. Test : une table au grain « un client » doit avoir autant de lignes que de valeurs distinctes de sa clé. Ici $23\,912 \neq 23\,500$.
4. **Les bornes utiles.** `ville` : 1 880 lignes vides (8 % des clients) — ce n’est pas un problème pour compter des ventes, **c’en est un** pour classer par ville. `telephone` : trois formats (avec/sans indicatif, espaces variables) — donc `COUNT(DISTINCT telephone)` sur-counte, et toute recherche par téléphone est inutile tant que ce n’est pas normalisé.
5. **Ce que la table ne dit pas.** Aucun chiffre d’affaires : c’est une table de **dimension**, pas un fait. Écrivez la phrase : « `clients` répond à qui, `ventes` répond à combien, et l’on ne peut obtenir le second par le premier qu’en reliant les deux par `id_client`. »

Contrôle de votre résultat. Vous devez avoir : 23 912 lignes, 23 500 clients distincts, 412 doublons, 1 880 villes manquantes, 3 formats de téléphone, et aucune somme de `id_client` (elle n’a aucun sens). Si votre réponse contient une moyenne d’identifiants, relisez le §5.3 : un identifiant n’est pas une quantité.

11. Exercices autonomes

Exercice 3.1 (★) — Le grain, en une phrase. Donnez le grain des six tables du socle (`ventes`, `clients`, `produits`, `magasins`, `objectifs_de_ca`, `stocks_quotidiens`). (attendu : une phrase « une ligne = ... » par table, avec la combinaison de clés)

Exercice 3.2 (★) — Deux comptages. Sans outil, déduisez du texte du fichier : combien de lignes a `ventes_magasin5_2025.csv` ? Combien de tickets ? Pourquoi ne sont-ce pas les mêmes nombres ? (489 / 316 ; parce qu'un ticket contient 1 à 4 articles)

Exercice 3.3 (★★) — Le faux total. Un collègue obtient 72 678 634 FCFA de CA TTC sur l'échantillon, au lieu de 36 339 317 FCFA. Proposez deux explications, et le test qui les distingue. (doublons non retirés → le total est presque $\times 2$: on compare à $36\,339\,317 \times 1,999$; sous-totaux inclus → le fichier n'en contient pas, donc `NBVAL(n_ticket)` ne change pas. Le test : compter les lignes dont le ticket est vide)

Exercice 3.4 (★★) — Les colonnes qui sont des valeurs. Voici un extrait large :

```
magasin;2025-01;2025-02;2025-03
M5;2051424;4289885;3673454
```

Écrivez la version longue, puis dites quelle opération devient possible en long et pas en large, et pourquoi la moyenne des trois colonnes n'est pas « le CA mensuel moyen du magasin 5 ». (attendu : 3 lignes en long ; agréger par mois sur plusieurs magasins devient possible ; la moyenne est correcte ici mais aveugle au nombre de jours ouvrés de chaque mois)

Exercice 3.5 (★★) — Lecture d'un fichier hostile. Le fichier fournisseur (42 lignes, chapeau de 3, séparateur `;`, décimale virgule, encodage Windows-1252) : importez-le proprement, et donnez le nombre de lignes utiles, le prix du `PEINT-014`, et le taux de TVA constaté. (attendu : 38 lignes utiles ; 27 500 ; 0,18 — une réponse « 2750000 » trahit un mauvais choix de séparateur décimal)

Exercice 3.6 (★★★) — Contrôle de unicité en 5 formules. Sur `montant_ht`, prouvez que la colonne est cohérente avec `quantite`, `prix_unitaire_ht` et `remise` : formule attendue, tolérance d'arrondi, nombre de lignes qui dévient. (attendu : contrôle `quantite × prix × (1 - remise)` arrondi à l'entier ; les 7 lignes de quantité aberrante sortent nécessairement en écart → c'est l'indice qui les fait découvrir)

12. Correction détaillée

Exercice 3.1. `ventes` : une ligne = un article d'un ticket (clé `id_vente`, ou `(n_ticket, produit)`) ; `clients` : une ligne = un client (clé `id_client`) ; `produits` : une ligne = une référence (clé `id_produit`, 154 lignes) ; `magasins` : une ligne = un point de vente ou dépôt (6 lignes) ; `objectifs_de_ca` : une ligne = un magasin pour un mois (218 lignes pour 5 magasins $\times$ 3 ans + 8 mois, donc mois manquants) ; `stocks_quotidiens` : une ligne = un produit dans un dépôt à une date (60 000 lignes).

Exercice 3.2. 489 lignes, 316 tickets distincts (moyenne 1,52 article par ticket, maximum 4). Les deux ne sont pas identiques parce que le grain est l'article, pas la vente. Un total d'articles est pertinent pour la logistique (kg manutentionnés, colis), un total de tickets pour la caisse (11 tickets/heure en pointe), et un total de lignes **n'est** la réponse à aucune question métier : c'est un artefact du fichier.

Exercice 3.3. Explication A : les 9 lignes en double n'ont pas été retirées **et** le collègue a sommé l'intégralité du jeu complet, pas l'échantillon. Test : son nombre de lignes est-il 243 360 ou 489 ? Explication B : il a ajouté le sous-total de chaque mois aux lignes. Test : `=NB.SI(A2:A490;"")`

— s'il trouve 0, il n'y a pas de sous-total et l'explication B tombe. Le calcul $72\,678\,634 / 36\,339\,317 = 2,00$ montre qu'il a bel et bien additionné deux fois le même contenu : une jointure ou une concaténation, pas un total de mois.

Exercice 3.4. Version longue :

```
magasin;mois;CA
M5;2025-01;2051424
M5;2025-02;4289885
M5;2025-03;3673454
```

En long, on peut agréger par mois **sur tous les magasins**, trier par mois, joindre à un calendrier (`dim_date`, 1 339 lignes) et détecter les mois absents (en large, un mois manquant est une colonne absente : personne ne la remarque). Sur la moyenne : $(2\,051\,424 + 4\,289\,885 + 3\,673\,454)/3 = 3\,338\,254$ **FCFA** — ce nombre est correct **comme moyenne de ces trois mois**, mais il ne dit rien d'une « année » ; l'exprimer comme « le CA mensuel » sans préciser la période est l'erreur classique relevée en M02 (agrégats sans période = agrégats contestables).

Exercice 3.5. 38 lignes utiles (42 – 3 de chapeau – 1 d'en-tête), PEINT-014 à **27 500 FCFA**, TVA **0,18**. Réponses fausses typiques : 42 lignes (le chapeau compté), 2 750 000 (virgule lue comme séparateur de milliers alors que le fichier est en français... ou l'inverse), 18 % lu comme 18 (oubli de la proportion). Le contrôle qui valide : `prix_ht × 1,18` doit redonner un prix TTC cohérent avec la grille interne du produit peinturé du socle.

Exercice 3.6. Contrôle : `montant_attendu = ARRONDI(quantite × prix_unitaire_ht × (1 – remise))`. Écart toléré : 1 FCFA (arrondi du fichier). Résultat réel sur l'échantillon : 7 lignes en écart, et ce sont exactement les 7 lignes à quantité aberrante (maximum 14 000 unités). La leçon à écrire : **une colonne calculée peut être juste alors que sa composante est fausse** — le fichier a été multiplié sur la quantité seulement, donc le montant reste correct. Un contrôle de cohérence entre colonnes trouve ce qu'un contrôle de total ne trouve pas.

13. Mini-projet M01.P3 — « Fiche d'identité de trois tables » (50 min)

Livrable : un onglet `identification` dans un classeur `2026-09-17_fiches_identite_M5_minani.xlsx`, avec **trois** blocs (ventes de l'atelier, clients, fichier fournisseur), chaque bloc contenant les six phrases du §5.1 et le tableau de contrôles du §7 (étape 3).

Contraintes : aucune formule ne doit être recopiée d'un autre bloc sans adaptation ; chaque nombre doit venir d'une formule du fichier importé (pas du texte du chapitre) ; le dernier bloc liste les **trois questions** que la table ne permet pas de traiter. Barème : 8 pts exactitude des six phrases · 6 pts justesse des comptages (489/316/18/3 vérifiés par vos formules) · 4 pts lisibilité (un bloc par table, aucun fusionnement) · 2 pts « questions non traitables ». Ce livrable entre dans le projet M01.P, critère (1).

14. Résumé du chapitre

Une table vue de près : en-têtes, variables (colonnes), observations (lignes)

n_ticket	date	magasin	vendeur	client	quantite	prix_unitaire_ht	montant_ttc
T05-250101-075845	2025-01-01	Magasin 5	Moussa I.	10857	11	4 500	56 658
T05-250101-075845 ①	2025-01-01	Magasin 5	Moussa I.	0.0 ②	2	12 000	28 320
T05-250101-075846	2025-01-01	Magasin 5	Salamatou S.	③	2 000	21 950	51 802
T05-250102-075902	2025-01-02	Magasin 5	Adama B.	3312	1	14 000	16 520

① un ticket occupe 2 lignes : compter les lignes pour compter les ventes gonfle le résultat de 55 % (le fichier compte 489 lignes, 316 tickets, et jusqu'à 4 lignes pour un même ticket).

② « 0.0 » n'est pas un manque : c'est la vente au comptoir, sans client identifié. Elle est volontaire dans le fichier et doit rester dans les totaux.

③ cellule vide = valeur absente : 18 lignes du fichier sont dans ce cas. On signale, on documente, on ne remplit pas au hasard.

- Grain : une ligne = un article vendu sur un ticket ; 1,52 ligne par ticket en moyenne.
- Clé : n_ticket identifie le ticket ; (n_ticket, produit) identifie la ligne. Sans clé, pas de fusion propre.
- Schéma : les 13 colonnes et leur type. Le CSV ne le dit pas : le déduire, puis le vérifier.

Figure 3 — Les quatre premières lignes réelles du fichier de l'atelier, annotées.

Une table se lit en six phrases et se contrôle en cinq nombres : lignes, valeurs distinctes de la clé, bornes des mesures, valeurs manquantes, cohérence entre colonnes. Le grain décide si un total est une somme ou un double-comptage ; la clé décide si l'on peut relier sans multiplier. Un fichier brut n'est pas un tableau : il a un séparateur, un encodage, parfois un chapeau et presque toujours des colonnes qui ne sont pas du bon type. Tout ce que vous ferez ensuite — SQL, pandas, Power BI — partira de ces six phrases ; les écrire est le premier acte d'analyse, et le seul obligatoire.

15. À retenir

À retenir. 1. « Une ligne = quoi ? » : la première question à poser à toute table, et à écrire. 2. **Lignes ≠ objets** : `COUNT(*)` = 489, tickets distincts = 316. Nommez toujours ce que vous comptez. 3. **Une clé est unique ou n'est pas une clé** ; une clé étrangère orpheline (486 lignes) est un défaut, pas un détail. 4. **Cellules fusionnées, sous-totaux, deux infos par cellule** : les trois poisons du fichier de données. 5. **Un contrôle de cohérence entre colonnes** trouve ce qu'un contrôle de total laisse passer.

16. Évaluation formative (auto-correction, 10 min)

1. Le fichier de l'atelier contient 489 lignes et 316 tickets. Combien de ventes ? (316 ; 489 = nombre d'articles facturés)
2. Que vaut `COUNT(DISTINCT n_ticket)` sur les lignes en double non retirées, et sur le fichier nettoyé ? (316 dans les deux cas — les doublons ne créent pas de nouveaux tickets : c'est précisément ce qui rend le contrôle utile)
3. Un champ `ville` vide sur 8 % des clients : pourquoi cela gêne-t-il une analyse géographique et pas un chiffre d'affaires total ? (le total additionne une mesure indépendante de la ville ; le classement par ville perd 8 % de son contenu, donc les parts sont fausses)
4. Donnez le grain de `remises_manuelles.xlsx` (18 200 lignes) et écrivez la phrase de contrôle d'unicité. (une ligne = un client pour un mois ; contrôle : lignes = distincts de (id_client, annee, mois))

5. **Question ouverte** : vous devez fusionner les ventes avec les objectifs mensuels. Énoncez en trois phrases ce que vous vérifiez avant la fusion et ce que vous vérifiez après. (attendu : les deux grains (article vs magasin-mois) ; les clés communes ; la période ; après : que le total des ventes n'a pas changé et que le nombre de lignes n'a pas été multiplié)

M01.C04 — Types de données et ce qu'ils autorisent : texte, nombre, date, booléen, montant

Outil de ce chapitre : Excel et LibreOffice Calc (conversion, détection, contrôle), plus l'éditeur de texte pour voir la vérité du fichier. **Durée indicative :** 5 h. **Niveau :** N1.

L'idée du chapitre. Un type n'est pas un détail technique : c'est la **liste des opérations permises** sur une colonne. Le même chiffre 56 658 écrit en texte refuse toute somme ; la même date écrite 12/01/2025 refuse tout calcul d'intervalle. La totalité des chiffres faux produits par des débutants, et une part surprenante de ceux produits par des seniors, vient d'un type mal déclaré ou mal deviné. Ce chapitre vous rend capable de **détecter** le problème en trente secondes, de le **corriger sans perdre de lignes**, et surtout de **prouver** que la correction n'a rien cassé.

1. Objectifs du chapitre

À la fin de ce chapitre, vous saurez :

1. **Nommer** les cinq types que rencontre un analyste (texte, nombre entier, nombre décimal, date/heure, booléen) et dire, pour chacun, ce qu'il autorise et ce qu'il interdit ;
2. **Détecter** une colonne « nombre stocké en texte » avec trois méthodes indépendantes dans un tableur ;
3. **Convertir** une colonne en gardant le contrôle du nombre de lignes et du total avant/après ;
4. **Traiter les dates** écrites en texte, y compris le piège JJ/MM/AAAA contre MM/JJ/AAAA, et expliquer pourquoi un formatage n'est pas une conversion ;
5. **Expliquer** les dégâts chiffrés d'un mauvais typage sur un résultat réel : ici 486 lignes sur 489 et un écart de total de 0,74 % après nettoyage ;
6. **Décider** du type d'une colonne ambiguë (identifiant numérique, montant, taux en proportion) et **documenter** la décision.

2. Pourquoi cette notion est importante

Situation 1 — le total à zéro. Un chef de secteur envoie son relevé mensuel en CSV. Vous faites `=SOMME()`. Résultat : 0. Colonne pleine de montants, somme nulle. Cause : chaque montant est écrit avec un espace de milliers (56 658), donc Excel a stocké du **texte**. Le chef de secteur, lui, voit ses totaux justes dans son fichier à lui, parce qu'il a laissé les formats de son logiciel. Deux personnes, deux chiffres, une seule cause : le type.

Situation 2 — la date qui décale tout un trimestre. Un export contient 12/01/2025 pour le 12 janvier et 01/12/2025 pour le 1^{er} décembre. Un outil de conversion automatique, réglé sur le format américain, lit le premier comme le 1^{er} décembre. Vous obtenez un hiver en plein été. Personne ne voit l'erreur dans le tableau de bord ; elle se voit dans la décision du directeur des achats, en janvier.

Situation 3 — la TVA en points ou en proportion. Dans notre fichier, `remise` contient 0.03. Ailleurs, un autre export contient 3. Appliquer un taux de 3 au lieu de 0,03 ne multiplie pas l'erreur par 100 : le montant de la ligne, qui est un taux, devient un facteur. Le type est « nombre »

dans les deux cas ; c'est **l'unité** qui diffère. Leçon durable : un type juste avec une unité fausse produit un chiffre faux avec assurance.

Dans les faits. Sur l'échantillon de l'atelier : **486 lignes sur 489** ont un `montant_ttc` non numérique, **65 dates** sont au format `JJ/MM/AAAA` dans une colonne où le reste est en `AAAA-MM-JJ`, **7 quantités** dépassent 500 (maximum **14 000**) et **18 clients** sont vides. Aucun de ces défauts n'empêche le fichier de s'ouvrir. Chacun d'eux rend un tableau de bord faux.

3. Explication simple

Chaque cellule contient une **valeur** et un **type**. Le type répond à une seule question : qu'est-ce que je peux faire avec ?

Type	Ce qu'on peut faire	Ce qu'on ne peut pas faire	Exemple du fichier
Texte	chercher, trier (alphabétique), regrouper, compter	additionner, moyennner, calculer un écart	Magasin 5 – Kaya Marché
Nombre entier	les cinq opérations, compter des quantités	dire « le 5 ^e tiers » (un entier est discret)	quantite = 11
Nombre décimal	tout ce que fait l'entier, plus ratios et pourcentages	s'additionner sans unité (0,03 de quoi ?)	remise = 0,03
Date / heure	intervalles, extraire mois/année, tri chronologique	additionner deux dates (ça n'a pas de sens)	date = 2025-01-01
Booléen	filtrer, compter des drapeaux	moyenner sans convention (VRAI = 1 ?)	est_retour (dans le jeu complet)

Une image qui tient : un type est un **verrouillage de porte**. Le texte est une porte coulissante, la date une porte à gâche électrique : le même geste ne s'y applique pas. « Convertir » n'est donc pas « embellir » : c'est changer de porte.

La confusion la plus fréquente du débutant est de croire que formater change le type. Dans un tableur, un format est une **apparence** : afficher `56 658` avec un séparateur de milliers ou en `# ###0,00 "FCFA"` ne change pas la nature de la valeur. Une cellule peut afficher une date `12/01/2025` alors qu'elle contient le nombre `45670` (le numéro de série interne de la date), et une autre afficher la même chose en contenant le texte `"12/01/2025"`. Le format ment, la valeur ne ment pas : c'est elle qu'on contrôle.

4. Vocabulaire essentiel

Français — English	Définition simple	Piège à éviter
Type de données — data type	Nature d'une valeur, qui détermine les opérations possibles.	Croire qu'un CSV « contient » des types : il ne contient que du texte ; le type est une décision de l'outil qui le lit.
Typage / inférence — type inference	Déduction automatique du type par le logiciel qui importe.	Le logiciel déduit sur les 100 premières lignes : une colonne peut changer de type à la ligne 101.
Chaîne de caractères — string	Suite de caractères, avec des espaces, des accents, des signes.	Un identifiant numérique (10857) n'est pas une quantité : le sommer ne veut rien dire.
Nombre à virgule / point — decimal separator	Signe séparant partie entière et décimale : <code>,</code> en français, <code>.</code> en anglais.	<code>27500,00</code> lu en contexte anglais devient <code>2750000</code> .

Français — English	Définition simple	Piège à éviter
Format nombre — number format	Masque d’affichage d’un nombre.	Confondre format et type : le format change l’œil, pas la valeur.
Numéro de série — serial date	— Une date stockée comme un nombre de jours depuis une origine (1900 ou 1904).	Un import qui convertit tout en série : 2025-01-01 devient 45658, et vous sommez des dates.
Valeur manquante — null / missing	— Absence de valeur, distincte de 0 et distinct de la chaîne vide.	<code>id_client = 0</code> (comptoir) est une valeur ; une cellule vide est une absence.
Booléen — boolean	Vrai ou faux (0/1, VRAI/FAUX, oui/non).	Trois représentations dans un même fichier : « V », « OUI », 1 → trois groupes au lieu d’un.
Conversion / coulage — cast	Changer le type d’une colonne en conservant la valeur.	Convertir en masse sans compter les pertes : <code>CBI("abc")</code> ne renvoie pas une erreur, il renvoie 0 ou une erreur selon le moteur.
Arrondi — rounding	Ajustement de la précision ; ici arrondi à l’entier en FCFA.	Arrondir avant de sommer, puis sommer : le total n’est pas le même que sommer puis arrondir.
Encodage — encoding	Correspondance octets ↔ caractères (UTF-8, Windows-1252).	Un fichier en Windows-1252 lu en UTF-8 casse les noms de produits, donc les regroupements.

5. Cours approfondi

5.1 Ce que le CSV ne dit pas — et pourquoi c’est le cœur du métier

Un fichier CSV est une liste de lignes de texte. Aucun type n’y est écrit. Le type apparaît quand **un outil décide** : Excel devine, Power Query infère, pandas infère, PostgreSQL exige une déclaration. Quatre conséquences :

1. **Un identifiant à zéro non significatif devient un nombre** : 0075845 → 75845, et la jointure future sur ce code échoue silencieusement. Réflexe : toute colonne qui sert de code (client, article, téléphone, IBAN) se charge en texte.
2. **Une colonne mixte est déclarée texte** : si une seule des 489 lignes contient N/C, la colonne entière de montants devient du texte pour beaucoup d’outils.
3. **Un nombre trop long perd sa précision** : les identifiants supérieurs à 15 chiffres (numéros de carte, codes-barres EAN-13 lus en nombre, identifiants techniques) sont arrondis par Excel. Non négociable : texte.
4. **Une date lue dans le mauvais ordre est convertie en une autre date valide** — c’est le seul cas où le résultat est **juste au regard de la syntaxe et faux au regard du monde**. Le point §5.3 lui est consacré.

Définition. Type de données — data type — la nature d’une valeur, qui détermine ce que l’on a le droit d’en faire. Un texte se compare et se découpe, il ne se moyenne pas ; un nombre se somme ; une date se décale. Le type n’est pas une étiquette esthétique : il ouvre ou ferme des opérations, et le logiciel refuse poliment au lieu de signaler qu’il n’a rien calculé.

5.2 Les cinq signes visibles d’un nombre stocké en texte

Sans formule, dans Excel : un nombre aligné **à droite**, un texte aligné **à gauche** (tant que vous n’avez pas changé l’alignement). Ensuite : le **triangle vert** en coin de cellule avec l’avertissement « nombre stocké sous forme de texte » ; la **barre d’état** qui n’affiche que « Nombre » et jamais « Somme » quand vous sélectionnez la colonne ; `=NB(plage)` qui renvoie 0 alors que `=NBVAL(plage)` renvoie 489 ; enfin **l’erreur #VALUE!** dès qu’une formule arithmétique touche la cellule.

Les trois premières méthodes sont visuelles, donc fragiles (un collègue a pu aligner à droite pour faire joli). Les deux dernières sont mathématiques : **NB** compte les valeurs numériques, **NBVAL** compte les cellules non vides. La différence **est** le nombre de défauts. C'est la formule de contrôle que vous écrirez dans chaque projet :

lignes	=NBVAL(L2:L490)	→ 489
valeurs nombre	=NB(L2:L490)	→ 3
défauts de type	=NBVAL(...) - NB(...)	→ 486

Dans LibreOffice, mêmes idées avec **COUNT** (nombres), **COUNTA** (non vides) et **ISNUMBER**.

Définition. Typage automatique — type inference — le mécanisme par lequel un logiciel devine le type de chaque colonne en lisant un échantillon de lignes. Il est rapide et il est faux dès qu'une colonne est irrégulière : quelques valeurs atypiques dans l'échantillon lui décident si la colonne deviendra nombre ou texte. Réflexe : lire l'écran de résultat de l'import, jamais cliquer sur « Charger » les yeux fermés.

5.3 Les dates : le format n'est pas le type, et l'ordre des morceaux n'est pas une convention

Trois écritures du même jour : 2025-01-12 (norme ISO 8601, année-mois-jour), 12/01/2025 (usage français, jour-mois-année), 01/12/2025 (usage américain, mois-jour-année). Un outil qui devine se trompe **uniquement sur les jours ≤ 12** — soit la moitié du mois, et, dans notre échantillon, **65 lignes sur 489**. Le pire : l'erreur est silencieuse, parce que la date obtenue est valide. Le total annuel reste juste (la somme ne dépend pas du jour) ; le CA mensuel, lui, est faux, et c'est précisément ce que le directeur regarde.

Règles de survie, dans l'ordre :

1. **Ne jamais laisser le logiciel deviner** : à l'import, déclarer explicitement le type de chaque colonne date (Excel : « Avancé » dans l'assistant texte ; Power Query : transformer la colonne puis Utiliser les en-têtes...).
2. **Ne jamais utiliser une conversion « automatique »** du type `format="mixed"` (le nom même dit « je devine ») sur un fichier de provenance humaine : sur notre échantillon, 12/01/2025 devient le 3 décembre et le mois change. Une conversion mixte n'est acceptable que sur des dates **déjà** ISO, pour gagner du temps.
3. **Forcer l'ordre** quand le fichier est hétérogène : séparer les lignes par motif (AAAA-MM-JJ d'un côté, JJ/MM/AAAA de l'autre), convertir chaque groupe avec son format, recoller. C'est long à écrire, c'est **juste**, et c'est l'exercice 4.2 de ce chapitre.
4. **Convertir une fois, en amont** : la correction de type appartient au nettoyage (M04), pas à chaque graphique.

Un test de robustesse à faire dans tous les cas : comparer, avant/après, le **nombre de lignes par mois**. Sur une conversion correcte, on retrouve les valeurs connues de l'atelier : janvier 2 051 424 · février 4 289 885 · mars 3 673 454 · avril 2 688 159 · mai 1 258 801 · juin 2 096 435 · juillet 2 623 127 · août 3 033 498 · septembre 3 476 773 · octobre 2 808 078 · novembre 2 781 034 · décembre 5 292 517 FCFA. Si vos mois ne correspondent pas, votre conversion a réarrangé le calendrier.

Définition. Séparateur décimal — decimal separator — le signe qui sépare la partie entière de la partie décimale. 27 500,00 et 27500.00 sont le même nombre dans deux conventions ; 27.500 peut être vingt-sept mille cinq cents ou vingt-sept virgule cinq selon le logiciel qui lit. C'est la source d'erreur la plus silencieuse du travail sur fichiers, parce qu'elle produit un nombre — le mauvais, mais un nombre.

5.4 Taux, proportions, pourcentages : la colonne `remise`

Dans les fichiers du socle, `remise` / `taux_remise` est une **proportion** : $0,03 = 3\%$. Un second mode de saisie existe dans la vraie vie : **les points de pourcentage** ($3 = 3\%$). Les deux sont des nombres ; le résultat d'un calcul diffère d'un facteur 100. Conséquence dans le jeu complet : **973 lignes** de remise aberrante sont des points confondus avec des proportions, et ces lignes passent tous les contrôles de type — seul un **contrôle de plage** les attrape :

```
règle métier : 0 ≤ remise ≤ 0,40
=NB.SI(K2:K490;">0,4") → lignes suspectes
```

Le même raisonnement s'applique à la TVA (`tva = 0,18`, jamais 18) et à toute « marge en % » (0,22 ou 22 ?). Réflexe professionnel, à appliquer dès le premier jour d'un stage : **la première ligne du dictionnaire de données écrit l'unité de chaque colonne numérique**. Une proportion, un taux, un pourcentage, un montant, une quantité : quatre mots, quatre conventions, zéro discussion ensuite.

5.5 Booléens et drapeaux : un type tout simple, trois catastrophes classiques

Le jeu complet contient `est_retour` (0 ou 1). Trois manières de mal faire :

1. **Le transformer en texte** par un import trop prudent : les groupes deviennent "0" et "1", qui se trient mais ne se somment plus — le total des retours tombe à 0.
2. **Le confondre avec une absence** : un fichier peut contenir 1, 0 et vide. Le vide n'est ni vrai ni faux : c'est « on ne sait pas », et le ranger avec les 0 fait disparaître des retours du total.
3. **Changer de vocabulaire entre deux sources** : VRAI/FAUX dans un export, OUI/NON dans un autre, T/F dans un troisième. À la fusion, trois modalités au lieu de deux. La normalisation (« oui/o/OUI/1/VRAI → 1 ») est une tâche de nettoyage, pas une option.

5.6 Convertir sans casser : le protocole en six temps

Toute conversion de type, dans n'importe quel tableur, se fait avec ce protocole. Il est imposé dans tous les projets de ce manuel, parce qu'il rend l'opération **auditable** :

1. **Compter avant** : nombre de lignes, total de la colonne concernée (si elle est déjà numérique) ou sa borne max/min.
2. **Dupliquer la colonne** (`montant_ttc` → `montant_ttc_num`) : on ne remplace jamais sur place.
3. **Retirer les parasites** en texte : espaces de milliers, FCFA, points de regroupement → `=SUP-PRESpace(SUBSTITUE(L2;" ";""))` (Excel) / `=TRIM(SUBSTITUTE(L2;" ";""))` (LibreOffice).
4. **Convertir** avec une fonction qui **signale** les échecs plutôt que de les masquer : `=CBI()` / `=VALUE()`, ou, en Power Query, un « Modifier le type » qui génère des `error` visibles. Les erreurs deviennent des lignes à traiter, pas des zéros.
5. **Contrôler** : la nouvelle colonne doit avoir le même nombre de valeurs que l'ancienne (`=NB(nouvelle) = NBVAL(ancienne)`) et un total égal à celui attendu.
6. **Écrire dans le journal** : date, colonne, méthode, lignes en échec, total avant/après.

Sur l'échantillon de l'atelier, la conversion de `montant_ttc` fait apparaître deux mondes : 3 lignes déjà numériques, 486 à nettoyer, 0 en échec après retrait des espaces (le fichier est propre de ce côté). Le total obtenu, **36 339 317 FCFA**, est celui **avec les 9 lignes en double** ; le total après suppression des doublons est **36 073 185 FCFA**, soit **0,74 %** de moins. Ces deux nombres sont vos points de contrôle pour tout le module.

Définition. Valeur manquante — null — l'absence de valeur. Elle n'est ni zéro, ni chaîne vide, ni « non renseigné » : zéro est une information, une case vide est une donnée, une absence est une question. Confondre les trois change un total, une moyenne et un nombre de clients.

Attention. Arrondir **avant** de sommer et sommer **puis** arrondir ne donnent pas le même total. Sur un extrait de quelques centaines de lignes, l'écart se compte en unités ; sur une facture payée à la ligne, il devient une réclamation. La convention s'écrit une fois dans le dictionnaire de données : on calcule en pleine précision, on arrondit à l'affichage.

5.7 Types, tailles de fichier et performance : ce que « bien typer » rapporte

Le type n'est pas qu'une question de justesse, c'est une question de coût, et cela devient critique dès le module 8 :

- un fichier CSV de 243 360 lignes × 20 colonnes occupe **28,5 Mo** ; la même table en `.parquet` avec des types justes tombe vers 4 à 6 Mo ;
- une date stockée en texte de 10 caractères coûte ~10 octets par ligne ; stockée en entier (nombre de jours), 4 octets ; en date binaire, 4 à 8 octets ;
- un booléen en texte ("`TRUE`" / "`FALSE`") coûte 5 octets ; en binaire, 1 bit effectif dans la plupart des formats colonnaires ;
- une colonne de type texte force, dans tous les moteurs, des comparaisons de chaînes au lieu d'entiers : sur un filtre ou une jointure, le facteur 2 à 5 est banal.

Ce n'est pas de l'optimisation pour ingénieurs : c'est la raison pour laquelle Power BI refuse parfois d'importer une colonne, et la raison pour laquelle un script Python « tourne » en 3 secondes ou en 4 minutes selon un détail invisible à l'œil.

Conseil professionnel. Dans tout outil d'import, l'écran qui affiche « 28 colonnes, type : texte » pour une colonne qui devrait être une date est un **signal d'alarme** que les débutants valident sans lire. Prenez l'habitude de parcourir cette ligne de types, colonne par colonne, à chaque import, et de vous demander : est-ce que cette colonne va être sommée, comparée, triée chronologiquement ? La réponse décide du type à imposer.

Attention. Convertir une colonne de **montants** en supprimant les espaces puis en forçant le nombre, **sans recalculer le total**, est la source numéro un des chiffres qui « collent » deux réunions de suite et s'effondrent à la troisième. Après toute conversion, un contrôle de total obligatoire — et l'écart doit être **expliqué**, pas arrondi à zéro. Ici, 266 132 FCFA d'écart s'expliquent par 9 lignes ; un écart inexpliqué de 12 FCFA est déjà une enquête.

À retenir. Un type se **déclare**, il ne se devine pas : la ligne d'en-tête d'un CSV ne porte aucune information de type, et le premier logiciel qui ouvre le fichier en invente une. D'où les trois réflexes du chapitre — compter les valeurs non numériques, compter les valeurs distinctes, écrire les types attendus dans le dictionnaire de données — qui transforment un doute en contrôle.

6. Exemple concret : la colonne qui a l'air juste

Voici, telle quelle, la fin du fichier de l'atelier. Deux lignes consécutives :

```
T05-251201-081477;2025-12-01;08:34;Magasin 5 – Kaya Marché;Adama Bationo;214;Robinet mitigeur
évier – réf 1;Plomberie;14000;140;0.00;1960000;2 312 800
T05-251201-081478;01/12/2025;09:02;Magasin 5 – Kaya Marché;Adama Bationo;;Ballon d'eau chaude 50 L
– réf 1;Plomberie;3;165000;0.05;495000;584 100
```

Quatre défauts, tous de type ou d'unité, invisibles à l'œil non exercé :

1. `2 312 800` : montant **texte** (espace de milliers) → il ne se somme pas, mais surtout il ne se compare pas : un filtre `> 2 000 000` l'ignore.
2. `01/12/2025` : date **texte**, et dans l'autre ordre que la ligne précédente → tri et regroupement par mois faux.
3. `quantite = 14000` pour des robinets : 14 000 mitigeurs sur un ticket de magasin de quartier, c'est une erreur d'unité (lignes de quantité aberrante : 7 dans l'échantillon, maximum **14 000**).
4. `client` vide sur la seconde ligne : une **absence**, à distinguer du `0` des ventes au comptoir (18 lignes vides dans l'échantillon).

Traitez les trois premières et le total passe de **36 339 317** (fichier tel quel) à **36 073 185** FCFA (après nettoyage), soit **0,74 %**. La quatrième ne change aucun total, mais change une réponse : « combien de clients distincts ? » — 372 identifiants distincts, dont il faut décider si l'absence compte comme un client.

7. Démonstration pas à pas : le protocole complet sur

montant_ttc

Faites-le dans un classeur neuf, onglet `exercice`, en important `ventes_magasin5_2025.csv` avec **toutes les colonnes déclarées en texte** (Power Query : colonne type « Touttexte » / « Text »). Déclarer tout en texte à l'import est une pratique professionnelle courante : on empêche le logiciel de deviner, puis on typ **soi-même**.

Étape 1 — État des lieux (3 formules).

<code>=NBVAL(M2:M490)</code>	→ 489	(la colonne est pleine)
<code>=NB(M2:M490)</code>	→ 3	(seuls 3 montants sont numériques)
<code>=NBVAL(M2:M490) - NB(M2:M490)</code>	→ 486	(le nombre de défauts de type)

Étape 2 — Colonne de travail. En N1, titre `montant_ttc_num`. En N2 :

Excel	: <code>=SIEPTEUR(CBI(SUPPRESPE(SUBSTITUE(M2;" ";"");"")); "ERREUR")</code>
LibreOffice	: <code>=IFERROR(VALUE(TRIM(SUBSTITUTE(M2;" ";"");"")); "ERREUR")</code>

`CBI/VALUE` échoue proprement ; `SIEPTEUR/IFERROR` transforme l'échec en marqueur lisible. Recopiez jusqu'à la ligne 490.

Étape 3 — Contrôle d'exhaustivité. `=NB.NON.VIDE(SI(N2:N490="ERREUR";N2:N490))` attend **0**. Si vous trouvez 1, un montant contient autre chose qu'un espace (un FCFA, une virgule décimale, un caractère invisible) : affichez-le avec `=CAR(...)`, ou ouvrez la cellule dans la barre de formule.

Étape 4 — Total et comparaison. `=SOMME(N2:N490)` → **36 339 317**. Écrivez à côté : « total fichier tel quel (9 lignes en double comprises) ».

Étape 5 — Retrait des doublons, puis nouveau total. Copiez la page dans un onglet `doublons_test`, Données → Supprimer les doublons (toutes colonnes) → **480 lignes**, total **36 073 185**. Notez : $36\,339\,317 - 36\,073\,185 = 266\,132$ FCFA, soit $266\,132 / 36\,073\,185 = 0,74\%$.

Étape 6 — Contrôle croisé, la partie utile. La colonne `montant_ht` est numérique, et `montant_ttc` doit valoir `ARRONDI(montant_ht × 1,18)`. Faites la colonne de contrôle :

```
=ARRONDI(P2*1,18)    puis    =SI(ARRONDI(P2*1,18)=N2;"ok","à voir")
```

Toutes les lignes doivent dire `ok` — sauf celles dont `quantite` est aberrante, car l'aberration a été injectée **sur la quantité seulement** : le montant, lui, reste cohérent. Vous touchez là une idée qui reviendra en M02 et en M04 : la cohérence interne d'une ligne ne prouve pas la véracité de ses composants. Un fichier peut être parfaitement cohérent et parfaitement faux.

Étape 7 — Les dates. Créez une colonne `date_iso` en traitant les deux écritures séparément, jamais en laissant l'outil deviner :

```
=SI(STXT(B2;5;1)="-"
; B2                                     /* déjà ISO : AAAA-MM-JJ, on garde */
; DROITE(B2;4)&"-"&STXT(B2;4;2)&"-"&GAUCHE(B2;2) /* JJ/MM/AAAA : on reconstruit en ISO */)
```

Puis contrôlez par compte, pas par impression : 65 lignes ont suivi la seconde branche, 424 la première (`=NB.SI()` sur le test du 5^e caractère). Regroupez ensuite par mois (`=GAUCHE(date_iso;7)` dans un tableau croisé) et comparez au tableau du §5.3 : décembre doit valoir **5 292 517 FCFA** sur le fichier nettoyé. C'est ce comparatif qui prouve que jour et mois n'ont pas été permutés — le total annuel, lui, aurait été juste et aurait caché l'erreur.

Boîte à outils. Excel — Détection : barre d'état (Nombre vs Somme), `=ESTNUM()`, `=NB()` vs `=NBVAL()`. Conversion : CBI, CNUM, DATEVALEUR, Power Query → « Transformer la colonne en nombre/date » ; à l'import, « Avancé » permet de forcer le type de chaque colonne. Erreurs de type visibles : Accueil → Mise en forme conditionnelle → « Règles de mise en surbrillance des cellules → Erreur ». **LibreOffice Calc** — VALUE, TRIM, SUBSTITUTE, ISNUMBER ; Données → « Importer une feuille de calcul » (choix explicite de l'encodage et des colonnes en texte) ; Format → Cellules → Date (ne **convertit** pas : n'utilisez jamais cette voie pour changer de type). **Les deux** — Après conversion, gardez une colonne `..._txt` à côté : le jour où l'on vous conteste un total, vous pouvez montrer le départ et l'arrivée, sans re-exécuter quoi que ce soit.

8. Erreurs fréquentes

Symptôme	Cause	Correction
Total à 0 sur une colonne pleine de montants	Montants stockés en texte (espace de milliers, FCFA)	SUPPRESSESPACE + SUBSTITUE puis CBI, avec contrôle <code>NB = NBVAL</code>
<code>=SOMME()</code> juste, mais <code>=MOYENNE()</code> fausse	Une ligne de titre ou de total mélangée aux nombres	Filtrer sur une colonne-clé non vide ; vérifier le grain
Des dates en nombre (45658)	Import qui a converti en série, format « Standard »	Convertir explicitement en date, puis vérifier par contrôle de mois
Un mois complet qui saute du rapport	Tri alphabétique sur texte 01/12/2025	Trier sur une colonne AAAA-MM-JJ (ou convertir, mieux)
Écart de 1 à 2 % sur des milliers de lignes	Point et virgule de milliers inversés selon la provenance	À l'import, renseigner les deux séparateurs dans l'ordre : le premier est le séparateur de milliers, le second la décimale
Un client sur deux disparaît du classement	<code>id_client</code> converti en nombre puis joint à un texte	Jointure sur même type ; recharger les identifiants en texte

Symptôme	Cause	Correction
Ventes au comptoir « supprimées par erreur »	0 traité comme une valeur manquante	Distinguer absence (NA) et zéro métier ; le comptoir doit rester dans le CA

9. Bonnes pratiques professionnelles

- [] À l'import : tout en texte, puis typage **décidé colonne par colonne**.
- [] Une colonne de contrôle `..._num` à côté de l'originale, jamais de remplacement à l'aveugle.
- [] Deux formules de contrôle à chaque conversion : `NB` vs `NBVAL` (exhaustivité) et total avant/après (fidélité).
- [] Unité de chaque colonne numérique écrite dans le dictionnaire (`remise` = proportion ; `montant_ttc` = FCFA TTC, TVA 18 % incluse).
- [] Les identifiants en texte, toujours ; un code n'est pas une quantité.
- [] Dates converties une fois, en amont, et vérifiées par **répartition mensuelle**, pas seulement par le total.
- [] Un écart de total, même de 12 FCFA, s'explique par une ligne du journal ou se corrige.
- [] Le dictionnaire note aussi **ce qui manque** : ici, cellule vide $\neq$ 0 (comptoir).

10. Exercice guidé — la grille de typage du fichier de l'atelier

On remplit ensemble, pour les 13 colonnes, la grille qui servira de base au dictionnaire de données (M01.C06 la mettra en forme). Colonnes : `n_ticket`, `date`, `heure`, `magasin`, `vendeur`, `client`, `produit`, `categorie`, `quantite`, `prix_unitaire_ht`, `remise`, `montant_ht`, `montant_ttc`.

Colonne	Type actuel	Type voulu	Pourquoi	Risque si on ne corrige pas
<code>n_ticket</code>	texte	texte	identifiant	perdu s'il devient nombre (les T05-... ne le permettent même pas)
<code>date</code>	mixte (424 ISO, 65 FR)	date	tri, filtres, mois	mois faux, ratios mensuels faux
<code>heure</code>	texte HH:MM	heure (ou texte)	(ou si l'on veut des tranches	tri alphabétique OK seulement si HH:MM à 2 chiffres partout
<code>magasin</code> , <code>vendeur</code> , <code>produit</code>	texte	texte	libellés	regroupements cassés par un accent mal encodé
<code>client</code>	nombre ou vide	texte	identifiant, avec 0 = comptoir	zéro confondu avec manque, jointure ratée
<code>categorie</code>	texte	texte	7 modalités	deux groupes pour la même catégorie si un espace traîne
<code>quantite</code>	nombre entier	nombre entier	somme, contrôle de plage	7 lignes aberrantes noyées dans la moyenne
<code>prix_unitaire_ht</code>	nombre entier	nombre	montant unitaire	—
<code>remise</code>	nombre décimal	proportion	$\times (1 - r)$	un facteur 100 si points/proportions se mélangent
<code>montant_ht</code>	nombre entier	nombre	total	—
<code>montant_ttc</code>	texte (486/489)	nombre	total officiel	total à 0 ou faux, comparaisons impossibles

Le constat à écrire en toutes lettres dans votre journal : **une seule colonne, montant_ttc, est catastrophiquement typée, et c'est celle sur laquelle le directeur regardera le résultat.** C'est presque toujours ainsi : le défaut n'est pas réparti uniformément, il est là où le calcul passe.

Ensuite, faites l'exercice inverse — celui qui forme vraiment : supposez que la ligne 490 (inexistante) contienne `montant_ttc = "N/C"`. Que deviennent `=SOMME()`, le tri Power BI, une agrégation SQL `SUM()` ? Réponse : une erreur, un groupe à part, `NULL` propagé. Les trois moteurs réagissent différemment ; le remède est le même : **rendre lisible avant de convertir**, c'est-à-dire extraire les lignes en échec dans un onglet `rejets` (et non les supprimer).

11. Exercices autonomes

Exercice 4.1 (★) — Les trois signes. Sans formule, dites pour `montant_ttc` du fichier de l'atelier (a) le type réel, (b) la preuve en une formule, (c) l'effet sur `=SOMME()`. (texte ; `=NB()` vs `=NBVAL()` = 3 vs 489 ; somme = 0 ou sous-estimée à 3 lignes seulement)

Exercice 4.2 (★★) — Le fichier hostile. Convertissez les 65 dates JJ/MM/AAAA en ISO en deux branches, puis donnez le CA du mois de décembre obtenu. (attendu : 5 292 517 FCFA sur l'échantillon nettoyé — toute autre valeur signale un jour/mois permuté)

Exercice 4.3 (★★) — L'unité tranchée. Une colonne `remise` contient les six valeurs 0 ; 0,03 ; 0,05 ; 0,08 ; 3 ; 5. Que concluez-vous, comment le prouvez-vous avec une colonne auxiliaire, et combien de lignes sont concernées dans le fichier de l'atelier ? (deux unités mélangées : le test `montant_ht × (1 - remise)` ne « tombe » juste que pour les proportions ; dans l'échantillon, 0 ligne en points — l'anomalie existe dans le jeu complet, 973 lignes)

Exercice 4.4 (★★) — Erreur volontaire — série E4 (diagnostic de défauts). On vous remet un classeur dont le total de `montant_ttc` est **36 339 317** alors que le tableau croisé de la même donnée affiche **36 073 185**. Listez trois causes possibles de type ou de format, et la formule qui tranche pour chacune. (causes : doublons conservés · colonne texte partiellement convertie · filtre oublié dans le TC ; tests : nombre de lignes `NBVAL` ; `NB` vs `NBVAL` ; `=SOMME.SI(n_ticket;"<>";...)` comparé à la valeur du TC)

Exercice 4.5 (★★★) — Le prix d'un mauvais typage. Un magasin a 480 lignes de détail. On commande du stock proportionnellement au CA TTC calculé sur le fichier **non nettoyé** (36 339 317 FCFA), à raison de 1,5 % du CA en réappro d'urgence. Calculez le surcoût en FCFA et en pourcentage de la commande réelle. (attendu : commande calculée 545 090 FCFA sur le fichier non nettoyé, 541 098 FCFA sur le fichier propre, soit 3 992 FCFA de trop — 0,74 % de la commande. L'exercice note surtout la démarche : l'impact métier dépend de la politique d'achat, et l'ordre de grandeur doit être dit, pas caché : ce n'est pas une excuse pour négliger le nettoyage)

12. Correction détaillée

Exercice 4.1. (a) texte ; (b) `=NB(M2:M490)` renvoie 3, `=NBVAL(M2:M490)` renvoie 489 : 486 cellules non numériques ; (c) `=SOMME(M2:M490)` ignore le texte et retournerait 3 valeurs, soit un total dérisoire et non 0 si les 3 valeurs numériques sont des cas propres — d'où l'intérêt du contrôle par les deux formules plutôt que du simple coup d'œil.

Exercice 4.2. Deux branches : `GAUCHE(B2;4)="2025"` → ISO conservée ; sinon reconstruire `DROITE(B2;4)&"- "&STXT(B2;4;2)&"- "&GAUCHE(B2;2)`. Contrôle : 65 lignes dans la seconde branche, 424 dans la première. Regroupement par mois → décembre 2025 = **5 292 517 FCFA**. Erreur type : obtenir 5 292 517 + quelques lignes de janvier mutées en décembre (si l'on a appliqué la

branche « jour/mois » aux lignes déjà ISO). Le contrôle du nombre de lignes par branche évite précisément cela.

Exercice 4.3. Conclusion : deux unités mélangées, 3 et 5 étant des points de pourcentage (0,03 et 0,05 existent aussi). Preuve : colonne vérif = `SI(remise>0,4 ; montant_ht × (1 - remise/100) ; montant_ht × (1 - remise))`, puis comparer à `montant_ht` ; les lignes en points ne collent qu'après division par 100. Dans l'échantillon de 480 lignes utiles, aucune occurrence (le générateur du jeu complet en injecte 973) : c'est l'occasion d'écrire la phrase exacte — le défaut est absent de ce fichier, et présent dans le jeu complet, donc la règle de contrôle doit exister malgré tout. Un apprenant qui « invente » 973 lignes dans l'échantillon pour faire plaisir au sujet a échoué à l'exercice.

Exercice 4.4. 1. Doublons non retirés → test : `=NBVAL()` = 489 contre 480 après dédoublement ; l'écart 266 132 FCFA correspond exactement à la somme des 9 lignes. 2. Colonne texte convertie sur une partie du fichier → test : `=NB(colonne)` = 486 au lieu de 489, ou somme différente selon la plage ; dans ce cas le total affiché aurait été 36 073 185 sur une plage et 36 339 317 sur l'autre. 3. Filtre oublié dans le tableau croisé → test : re-jeter le champ `date` hors filtre et comparer ; un filtre « janvier-novembre » produit un total inférieur d'environ 5,3 M FCFA, pas de 266 132 FCFA — donc ce n'est **pas** cette cause. C'est la bonne manière de raisonner : on élimine par l'ordre de grandeur attendu.

Exercice 4.5. Démarche juste : écart = 266 132 FCFA ; proportion de réappro d'urgence = 1,5 % du CA ; surcoût = $266\,132 \times 1,5\%$ = **3 992 FCFA** ; la commande passe de 541 098 à 545 090 FCFA. Barème : 2 pts pour l'écart exact (266 132 FCFA), 3 pts pour le calcul, 5 pts pour le commentaire d'ordre de grandeur (3 992 FCFA sur un écart de 266 132 FCFA) qui conclut que **l'erreur de type est ici financièrement négligeable mais pédagogiquement et contractuellement grave** : un chiffre juste est une obligation, pas une question de montant. Un devoir qui écrit « surcoût de 545 090 FCFA » confond le montant de la commande et le surcoût : noté 2/10, le résultat est recopié, pas calculé.

13. Mini-projet M01.P4 — « Le dictionnaire de types » (45 min)

Livrable : un onglet dictionnaire de 13 lignes × 6 colonnes dans le classeur du module, une ligne par colonne du fichier de l'atelier. Colonnes imposées : `champ` · `type_livré` · `type_voulu` · `unité` · `règle_de_contrôle` · `défaut_constaté`.

Exemple de ligne recevable :

```
montant_ttc | texte (486/489) | nombre entier | FCFA TTC, TVA 18 % incluse |
NB(nouvelle)=NBVAL(ancienne) et total € {36 339 317 ; 36 073 185} | espace de milliers
```

Critères : toute colonne a une unité écrite (une proportion n'est pas un pourcentage) ; deux colonnes au minimum ont une règle de contrôle qui **s'exécute** (une formule du classeur, pas une phrase) ; les valeurs de défaut sont comptées, pas estimées (65, 486, 18, 7) ; le dernier onglet s'appelle `rejets` et contient les lignes qui n'ont pas pu être converties, même s'il est vide — le fait qu'il soit vide est une information.

14. Résumé du chapitre

Le même nombre, deux destins

montant_ttc écrit en NOMBRE	montant_ttc écrit en TEXTE	le même défaut, mesuré ici		
56 658 28 320 aligné à droite SOMME = 84 978 FCFA moyenne, tri, graphique : OK	'56 658 '28 320 aligné à gauche SOMME = 0 tri : 16 520 avant 56 658	486 lignes sur 489 sont du texte déguisé en montant → 0,74 % d'écart de total 18 clients absents 65 dates au format français		
TEXTE	NOMBRE	DATE	BOOLEEN	MONTANT
vendeur, categorie on trie, on regroupe	quantite, prix_unitaire sommes et moyennes	date (vrai objet-date) intervalles, mois	est_retour : 0 ou 1 filtrer les retours	montant_ttc en FCFA TVA 18 %, arrondi

Symptômes : total à 0, tri absurde, triangles verts en coin de cellule.

Figure 4 — Le défaut n° 1 des fichiers livrés, vu sans calculer et mesuré sur le fichier réel.

Un type est la liste des opérations permises, pas une mise en forme. Un CSV n'a pas de types : c'est vous qui les décidez, et le logiciel qui les devine à votre place se trompe sur les bords — identifiants, dates ambiguës, colonnes mixtes. Les deux formules `NB` / `NBVAL` détectent tout ce qui est nombre déguisé ; le contrôle par mois détecte tout ce qui est date déguisée ; le contrôle `0 ≤ remise ≤ 0,40` détecte tout ce qui est unité déguisée. Convertir se fait en sept temps, dont deux obligatoires : compter avant, contrôler après. Un total qui change de 0,74 % après nettoyage n'est pas une approximation : c'est une preuve.

15. À retenir

À retenir. 1. **Formater ≠ convertir** : l'apparence ne change pas le type, donc ne change pas ce qui est calculable. 2. **NB vs NBVAL** : deux formules, trois secondes, la mesure exacte des nombres stockés en texte (ici 486/489). 3. **Un identifiant est du texte** ; un montant est un nombre **avec unité** ; un taux est une **proportion**. 4. **Une date ambiguë se traite en deux branches** et se vérifie par répartition mensuelle, jamais par le seul total annuel. 5. **Toute conversion est encadrée par un contrôle** : lignes avant/après, total avant/après, et une ligne dans le journal.

16. Évaluation formative (auto-correction, 10 min)

- Pourquoi un CSV « ne contient-il pas de types » et qu'est-ce qui en crée ? (ce sont des caractères ; le type est créé par l'importateur, par inférence ou par déclaration)
- Une colonne `date` contient 424 valeurs `2025-01-01` et 65 valeurs `12/01/2025`. Quelle est la règle de conversion, et le contrôle ? (deux branches, reconstruction en ISO ; contrôle : nb de lignes par branche = 424 et 65, puis CA par mois cohérent avec les valeurs attendues)
- `=SOMME()` sur `montant_ttc` renvoie une valeur minuscule. Expliquez en une phrase et donnez la formule de diagnostic. (le texte est ignoré par `SOMME` ; diagnostic `=NB()` vs `=NBVAL()`)
- Un champ `tva` vaut 18 dans un fichier, 0,18 dans un autre. Que fait-on à l'étape de nettoyage ? (normaliser en proportion, documenter l'unité, contrôler `montant_ttc = montant_ht × 1,18`)
- Question ouverte** : votre direction affirme que le fichier « s'ouvre bien dans Excel, donc il est correct ». Répondez en trois phrases, avec un exemple chiffré du module. (attendu : Excel affiche, il ne valide pas ; 486 montants sur 489 sont du texte et le total officiel change de

266 132 FCFA selon le nettoyage ; un fichier juste est un fichier contrôlé, pas un fichier affichable)

M01.C05 — Structurées, semi-structurées, non structurées ; qualitatives et quantitatives

Outil de ce chapitre : un éditeur de texte, Excel/LibreOffice, l'invite de commandes pour compiler. **Durée indicative :** 4 h. **Niveau :** N1.

L'idée du chapitre. Deux classements traversent toute l'analyse, et ils sont indépendants. Le premier regarde **l'enveloppe** : la donnée est-elle en table, en arborescence, en prose ? Le second regarde la **nature** de la valeur : peut-on calculer avec, ou seulement classer ? Le premier décide de l'outil et du temps de préparation ; le second décide de la formule licite. Un analyste qui confond les deux choisit un outil inadapté et écrit un calcul interdit — deux erreurs que le module 2 vous fera payer cher, donc que l'on règle ici.

1. Objectifs du chapitre

À la fin de ce chapitre, vous saurez :

1. **Classer** un jeu de données en structuré / semi-structuré / non structuré, et dire pour chacun le coût réel de mise en forme ;
2. **Reconnaître** la nature d'une variable — quantitative (discrète, continue) ou qualitative (nominale, ordinale) — et **justifier** la frontière par le test des écarts ;
3. **Relier** la nature d'une variable aux statistiques autorisées (moyenne, médiane, mode, pourcentage, écart-type) ;
4. **Choisir** le bon outil pour la bonne enveloppe : tableur pour le structuré petit, requête pour le structuré gros, script pour le semi-structuré, humain (ou traitement du langage, en M20) pour le non structuré ;
5. **Décrire** les quatre propriétés d'un fichier plat (séparateur, encodage, décimale, chapeau) et les vérifier en ligne de commande ;
6. **Estimer** le volume et le temps de préparation d'un lot de fichiers hétérogènes, ce que demande tout client au premier rendez-vous.

2. Pourquoi cette notion est importante

Situation 1 — les 200 Mo de logs. Un client remet un dossier de 200 Mo de fichiers `.log` « pour voir les achats en ligne ». L'analyste commence par les ouvrir dans Excel : 5 minutes de chargement, un plantage, une demi-journée perdue. La bonne première question n'était pas « comment filtrer ? » mais « sous quelle forme cela existe-t-il, et quelle fraction est exploitable ? » — ici, 4 lignes sur 10 étaient du texte libre, et la réponse utile se trouvait dans 3 colonnes parsemées.

Situation 2 — la moyenne des catégories. Un mémoire professionnel affiche « catégorie moyenne : 4,3 ». Les catégories ont été codées 1 à 7 pour gagner de la place dans le fichier. Le code est un nombre, la catégorie ne l'est pas : la moyenne d'une variable nominale est un nombre **sans signification**, même si le logiciel la calcule. C'est l'exemple type du calcul licite en apparence, interdit en réalité.

Situation 3 — le PDF qui « contient les données ». Une mairie envoie 40 pages de délibérations au format PDF, « tout y est ». C'est exact, et inutilisable en l'état : le non structuré n'est pas une table, il le devient par un travail dont le coût (ici, plusieurs semaines de saisie ou un traitement de texte automatique) doit être **annoncé** avant d'être accepté.

Dans les faits. Dans le socle de données de ce manuel, la répartition est celle d'une PME réelle : **10 fichiers structurés** (les tables, dont `ventes_brutes.csv` de 243 360 lignes), et du semi-structuré ou du non structuré partout ailleurs : un relevé de stock tenu « à la main » (le même tableur contient des commentaires libres en colonne de garde), les notes d'e-mails des commerciaux, les fichiers du fournisseur au format ; encodé en **Windows-1252**. Le ratio « facile / difficile » est de 1 à 4 en volume de travail, pas en volume d'octets.

3. Explication simple

L'enveloppe. Imaginez trois façons de noter la même vente :

- **structurée** : une ligne dans un fichier, des colonnes partout — `T05-250101-075845;2025-01-01;11;4500;...`. Un ordinateur la lit sans réfléchir.
- **semi-structurée** : une fiche qui porte ses étiquettes avec elle — `{"ticket":"T05-250101-075845","date":"2025-01-01","lignes":[{"produit":"Plâtre 25 kg","qte":11,"pu":4500}]}`. La structure existe, mais elle est **dans** le contenu, parfois inégale (telle vente a un champ `remise`, telle autre non ; la caisse a été ajoutée en 2024).
- **non structurée** : un SMS — « le client veut 11 sacs pour samedi, il paiera au comptoir ». Riche, mais l'ordinateur n'y voit que des mots. Le transformer en table, c'est décider ce qu'est « 11 », « sacs », « samedi », et ce travail a un prix.

La nature. Pour une colonne, posez une seule question : **est-ce que calculer avec a un sens ?**

- Si oui → **quantitative** : `quantite` (11, 2, 2 000), `poids_kg`, `taux_remise`. Dedans, deux familles : discrète (on compte : 11 sacs, jamais 11,3) et continue (on mesure : 24,7 kg).
- Si non → **qualitative** : `categorie`, `mode_paiement`, `type_client`. Deux familles : nominale (aucun ordre : plomberie n'est pas « plus » que peinture) et ordinale (ordre connu, distance inconnue : `particulier < pro < revendeur`, mais de combien ?).

Le test de l'ordre et le test des écarts tranchent les cas limites :

Question	Nominal	Ordinal	Intervalle	Ratio
Un ordre a-t-il un sens ?	non	oui	oui	oui
Un écart 10→11 vaut-il comme 40→41 ?	non	non	oui	oui
Le zéro veut-il dire « absence » ?	non	non	non	oui

`poids_kg` : ratio (0 kg = rien). `température` en degrés : intervalle (0 °C ne dit pas « absence de chaleur »). `note sur 20` : intervalle en pratique, ordinales en théorie — d'où l'interdiction de dire « 16 est deux fois 8 ». Cette échelle (nominale / ordinale / intervalle / ratio) n'est pas un ornement académique : elle décide, en M02, quelles statistiques sont admissibles, et en M17, quels graphiques ont le droit d'exister.

Deux classements, pas un seul

STRUCTURÉE

les 10 fichiers du socle : CSV, XLSX

SEMI-STRUCTURÉE

JSON des logs de caisse, XML d'un export Sage, e-mails

NON STRUCTURÉE

SMS du commercial, photo d'un bon, PDF du fournisseur

QUANTITATIVE : on peut calculer

discrète : quantité (11, 2, 2 000 — jamais 1,5)
continue : poids_kg, taux_remise (0,032)

QUALITATIVE : on peut classer

nominale : catégorie (aucun ordre)
ordinaire : type_client (ordre connu)

LE TEST QUI CLASSE

« 2 catégories valent-elles
2 fois l'autre ? » sinon, ce
n'est pas une échelle ratio.

Ce que la colonne EST décide ce que vous avez le DROIT de calculer.

la moyenne d'une nominale est un non-sens

Figure 5 — Classer les colonnes du socle, c'est déjà savoir quels calculs seront licites au module 2.

4. Vocabulaire essentiel

Français — English	Définition simple	Piège à éviter
Donnée structurée — structured data	Organisation régulière en lignes et colonnes, schéma connu.	Croire que « table » implique « propre » : le structuré peut être sale (c'est même le cas ici).
Donnée semi-structurée — semi-structured	Contient ses propres étiquettes, mais de façon irrégulière (JSON, XML, HTML, logs).	Trier ou sommer sans l'avoir aplati en colonnes.
Donnée non structurée — unstructured	Texte, image, son, vidéo : pas de colonnes.	Surestimer ce qu'un outil de traitement automatique peut en tirer au premier passage.
Aplatir — flatten	Passer d'une arborescence à des colonnes plates.	Perdre les niveaux intermédiaires sans les recopier dans une colonne.
Schéma — schema	Liste nommée des colonnes avec types et règles.	Le deviner au lieu de l'écrire : un schéma non écrit se démode dès la première livraison.
Variable quantitative — quantitative variable	Se mesure ou se compte ; les calculs ont un sens.	Confondre code numérique et quantité (les catégories codées 1 à 7).
Variable qualitative — catégorielle / categorical	Classe en familles ; on compte les effectifs, pas les valeurs.	Calculer une moyenne ou un écart-type.
Discrète / continue — discrete / continuous	On compte des entiers ; ou on mesure avec une précision finie.	Traiter une variable discrète à faible cardinalité (1, 2, 3) comme continue pour la moyener.
Cardinalité — cardinality	Nombre de valeurs distinctes d'une colonne.	Oublier que cardinalité élevée + texte = coût de jointure (revient en M06/M13).
Échelle de mesure — measurement scale	Nominale, ordinale, intervalle, ratio.	Choisir un graphique ou une statistique inadapté à l'échelle.
Texte libre — free text	Prose non contrainte : commentaires, motifs, SMS.	Faire des « mots les plus fréquents » un indicateur : la fréquence d'un mot n'est pas une mesure d'un fait.
Séparateur / encodage / décimale	Les trois propriétés d'un fichier plat, plus le chapeau.	Les supposer identiques entre deux fichiers du même expéditeur.

5. Cours approfondi

5.1 Les trois enveloppes, et le vrai coût de chacune

Enveloppe	Exemples	Ce qu'on peut faire directement		Coût de mise en forme	Outil adapté (module)
Structurée (table)	ventes_brutes.csv, clients.csv	filtrer, joindre	agréger,	faible : types, doublons, bornes (M04)	tableur (M03-M06), SQL (M07), Power BI (M14)
Semi-structurée	logs de caisse en JSON, XML d'un export, HTML d'une page fournisseur	lire enregistrement la fois	un à	moyen-élevé : aplatir, régulariser, accepter les champs absents (M08)	Python/pandas, DuckDB
Non structurée	SMS, e-mails, PDF de compte rendu, photos de bons	chercher un mot		très élevé : extraction, validation, échantillonnage (M20)	script + humain, ou modèles de langue (M20, avec ses limites)

Trois remarques professionnelles :

1. **La difficulté n'est pas dans la taille, c'est dans l'irrégularité.** Cent mille lignes d'un CSV bien tenu demandent une journée ; trois mille e-mails « importants » en demandent trois.
2. **Le semi-structuré est le format par défaut du monde moderne :** les API, les journaux d'événements, les fichiers de configuration, les exports web. Le JSON est au XXI^e siècle ce que le CSV était au XX^e.
3. **Le non structuré est un choix, pas une fatalité.** On peut faire saisir un formulaire au lieu de lire des SMS. Une partie du travail d'un analyste est de proposer ce changement de format : c'est le livrable « recommandation d'usage » du module 21.

Définition. Donnée structurée — structured data — des lignes et des colonnes, un schéma connu d'avance : le format où l'on peut compter, joindre et agréger sans rien interpréter.

Définition. Donnée semi-structurée — semi-structured data — des étiquettes portées par le fichier lui-même (JSON, XML, journaux applicatifs), mais des enregistrements qui ne se ressemblent pas tous : une clé peut manquer d'un objet à l'autre, et c'est ce manque qui demande un traitement.

Définition. Donnée non structurée — unstructured data — texte, image, son, vidéo : aucune colonne. On ne la compte pas ; on extrait d'abord une information, et cette extraction est elle-même une source d'erreur à documenter.

5.2 Le JSON en cinq minutes, parce que vous allez en rencontrer

Un objet JSON se lit comme un dictionnaire ; un tableau [...] comme une liste. Voici un ticket de caisse du commerce réel, en JSON :

```
{
  "ticket": "T05-250101-075845",
  "date": "2025-01-01",
  "magasin": 5,
  "vendeur": "Moussa Ilboudo",
  "lignes": [
    { "produit": "Plâtre de construction 25 kg", "qte": 11, "pu": 4500, "remise": 0.03 },
    { "produit": "Gravier 15/25 (m3)", "qte": 2, "pu": 12000 }
  ],
  "reglement": { "mode": "especes", "montant": 56658 }
}
```

Quatre enseignements :

- la structure **se répète** (le mot `lignes` porte une liste d'objets de même forme) ;
- les **champs optionnels** existent : la deuxième ligne n'a pas de `remise` — dans une table plate, cela devient une colonne à vide, et la question « vide = 0 ? » resurgit (M01.C04) ;
- l'**imbrication** oblige à aplatir : une table de lignes suppose de recopier `ticket`, `date`, `magasin` sur chaque article, donc de **choisir le grain** (ici l'article, pas le ticket) ;
- les **nombres sont typés** par la syntaxe (56658 sans guillemets = nombre, "56658" = texte) : c'est le seul format courant où le type est explicite dans le fichier. C'est pour cela qu'il est préféré au CSV pour les échanges entre logiciels.

Le mouvement à maîtriser, un jour ou l'autre : **JSON → table** (aplatir, M08) et **table → JSON** (exporter vers une application, M19). Les deux sont mécaniques ; ce qui ne l'est pas, c'est la décision du grain et du sort des champs absents.

5.3 Les quatre propriétés d'un fichier plat, et comment les vérifier sans outil

Un même fichier CSV peut être lu correctement par un logiciel et faux par un autre, à cause de quatre conventions non écrites. Voici comment les **vérifier**, pas les supposer, depuis un terminal (Git Bash sous Windows, Terminal sous macOS/Linux) :

```
head -3 2025_ventes_M5_brut.csv          # le chapeau : y a-t-il des lignes de titre avant l'en-
tête ?
head -1 2025_ventes_M5_brut.csv | tr ';' '\n' | wc -l    # le séparateur : combien de champs ?
(attendu : 13)
file -i 2025_ventes_M5_brut.csv          # l'encodage déclaré (charset=utf-8 ou iso-8859-1)
grep -c ',' 2025_ventes_M5_brut.csv      # des virgules dans un fichier « ; » = chiffres à
virgule ou texte libre
```

Résultats réels du socle : `ventes_magasin5_2025.csv` = 13 champs, UTF-8, séparateur `;`, aucune virgule décimale. `tarif_fournisseur_peinture.csv` = 6 champs, **Windows-1252**, séparateur `;`, **virgule décimale**, **3 lignes de chapeau**, 38 lignes utiles. Le second fichier est celui qui casse les imports, et il est parfaitement normal : c'est un export d'un vieux logiciel de facturation dont la langue est le français.

Règle de propreté qui en découle, à appliquer à chaque réception, et notée dans le journal : **nom du fichier, taille, encodage, séparateur, nombre de champs, nombre de lignes, nombre de lignes utiles**. Sept nombres. Un client à qui l'on écrit cela au lieu de « j'ai bien reçu le fichier » gagne en confiance ce que l'analyste gagne en temps.

Définition. Encodage de caractères — character encoding — la table qui associe des octets à des signes. **UTF-8** — UTF-8 — la convention universelle actuelle : tout caractère du monde y tient, un accent occupe 2 octets. **Windows-1252** (ou latin-1) — cp1252 — l'ancienne convention des logiciels francophones : les accents occupent 1 octet. Lire du Windows-1252 comme de l'UTF-8 produit `Ã©` ; l'inverse produit `ï¿½` ou des points d'interrogation. Le fichier n'est pas casé : la lecture l'est.

5.4 Qualitatif et quantitatif : les cas qui font discuter, tranchés

Colonne du socle	Classification	Tranchage
<code>quantite</code>	quantitative discrète	on compte des articles ; 1,5 sac n'existe pas dans ce commerce
<code>poids_kg</code>	quantitative continue	mesure ; un écart de 0,4 kg vaut un écart de 0,4 kg ailleurs sur l'échelle

Colonne du socle	Classification	Tranchage
prix_unitaire_ht	quantitative, ratio	0 FCFA = absence de prix (et non un prix « petit ») → 2 lignes à 0 dans produits.csv, donc un défaut, pas une valeur
remise	quantitative, ratio	0 = aucune remise, ce qui a un sens
categorie	qualitative nominale	7 familles, aucun ordre → moyenne interdite, effectifs et parts autorisés
type_client	qualitative ordinale	particulier < pro < revendeur : ordre connu, distance inconnue → médiane parfois admissible, moyenne non
mode_paiement	qualitative nominale	espèces / mobile money / chèque / virement / crédit : médian n'a aucun sens
conditionnement	qualitative nominale	pot, sac, m³, barre de 4 m → sert d' unité , donc à la conversion (M02)
heure	quantitative circulaire	23 h 59 et 00 h 01 sont voisins mais la moyenne fait 12 h : à traiter par extraits (tranches) ou par fonction cosinus (M20, cas limite)
ville	qualitative nominale	géographie = ordinale si l'on hiérarchise par taille ; ici, nom de ville + région (référentiel INSD) = hiérarchie à 2 niveaux, donc variable hiérarchique (M11)

Le test unique à retenir pour les cas limites : « **puis-je soustraire deux valeurs et obtenir un nombre qui veut dire quelque chose ?** » 13 h – 11 h = 2 h ✓ (quantitative). Plomberie – Peinture ✗ (qualitative). note 16 – note 8 = 8 points : oui arithmétiquement, mais les points n'ont pas la même valeur partout → on reste prudent, on parle de médiane et de quartiles, jamais de « deux fois mieux ».

Définition. Variable quantitative — quantitative variable — une valeur qui se mesure ou se compte, et pour laquelle les calculs ont un sens : quantité, prix, montant, durée.

Définition. Variable qualitative — categorical variable — une appartenance : famille, catégorie, statut, marque. On la compte (des effectifs par modalité), on ne la calcule pas.

Attention. Un **code** n'est pas une **quantité**. Code postal, numéro d'article, identifiant client, modalité codée 1/2/3 : autant de textes qui ont l'air de nombres. Leur moyenne ne veut rien dire, et la calculer est le premier réflexe de l'analyste pressé — le deuxième étant de la montrer en réunion.

5.5 Quelle statistique pour quelle nature : la table qu'il faut avoir en tête

Nature	Mode	Médiane	Moyenne	Écart-type	% et effectifs	Remarques
Nominale	✓	✗	✗	✗	✓	le mode est la seule « tendance centrale » lisible
Ordinale	✓	✓ (avec prudence)	✗	✗	✓	médiane = catégorie du milieu, pas un nombre à commenter seul
Quantitative discrète	✓	✓	✓	✓	✓	attention aux cardinalités faibles (1, 2, 3) : la moyenne devient trompeuse
Quantitative continue	✓	✓	✓	✓	✓	moyenne + écart-type ou médiane + quartiles, selon l'asymétrie (M02)

Cette table est celle du module 2, introduite ici parce qu'elle découle directement de la nature des colonnes. Elle vous évite le pire scénario d'un rapport : un chiffre exact, calculé comme il faut, sur une variable à laquelle il ne s'applique pas. Le jury d'une soutenance (M22) ne vérifie pas les logiciels : il vérifie cette table. **Version alternative pour un petit écran** — ce tableau

de sept colonnes se réduit à deux phrases : sur une variable nominale, seul le mode se calcule ; sur une quantitative, tout se calcule, et le choix entre moyenne + écart-type ou médiane + quartiles se tranche à l'asymétrie (M02.C02 et M02.C05). Les cases du milieu ne font que détailler ces deux phrases.

Définition. Cardinalité — cardinality — le nombre de valeurs distinctes d'une colonne. Elle se mesure, elle ne se devine pas, et elle décide : une cardinalité faible se raconte en graphique, une cardinalité élevée sur du texte libre ne se raconte pas, elle se liste ou se classe.

Définition. Échelle de mesure — measurement scale — le niveau d'information porté par une colonne : nominale (des noms, sans ordre), ordinale (un ordre, mais des distances qui n'ont pas de sens constant), à rapport (ordre, distances, et un zéro qui veut dire « rien »). L'échelle autorise ou interdit les statistiques — c'est le seul cours de statistiques que l'on applique chaque semaine sans y penser.

5.6 Choisir l'outil selon l'enveloppe et le volume : la première grille de décision

Situation	Volume	Outil recommandé	Pourquoi, en une phrase
Un extrait, à montrer à une seule personne	< 50 000 lignes	tableur (Excel/LibreOffice)	tout le monde peut relire vos cellules ; zéro installation
Un tableau de bord à publier, à consulter souvent	< 10 M lignes	Power BI	le modèle et les actualisations sont faits pour ça ; le lecteur n'a rien à installer (service)
Une question ponctuelle sur la base de l'entreprise	n'importe lequel	SQL	la base fait le calcul, vous ne déplacez rien
Un fichier sale, irrégulier, semi-structuré	n'importe lequel	Python	seul outil où l'on écrit la règle de nettoyage une fois, et où elle se rejoue
Explorer un gros fichier sans serveur	jusqu'à la RAM	DuckDB	requêtes sur fichiers plats, sans installation lourde
Comprendre du texte libre	—	script + lecture humaine , puis validation sur échantillon	une extraction non validée n'est pas une mesure
Un résultat officiel à signer	—	le plus lent des outils acceptables	ce n'est pas une blague : la lenteur, ici, veut dire traçable et rejouable

Le fil du raisonnement, dans tous les cas : qui relit ? Si c'est un collègue non technicien → tableur. Si c'est un outil de service → requête. Si c'est vous dans six mois → script. Nous reprendrons cette grille en M08.C01 et M13.C01, mais vous l'avez déjà : la bonne question n'est jamais « quel outil est puissant ? », c'est « quel outil laisse-t-il une preuve ? ».

Conseil professionnel. Ne commencez jamais un projet en disant « je vais mettre ça dans Power BI ». Annoncez : « je prépare d'abord un fichier plat de N lignes, sur lequel on pourra vérifier les totaux, puis le rapport ». Vous gardez la main sur la qualité de la donnée, vous rassurez le commanditaire, et vous évitez de reconstruire trois fois le modèle parce que le format de départ changeait.

Attention. Faire des « mots les plus fréquents » d'une colonne de texte libre un indicateur de pilotage est une fausse bonne idée classique : la fréquence mesure le vocabulaire d'un saisie, pas un phénomène. Le texte libre devient une information quand on y rattache une catégorie stable, définie et contrôlée par le métier.

À retenir. La nature d'une variable se lit dans le **grain** et dans l'**usage**, jamais dans le nom de la colonne : `code_article` est qualitatif même s'il est numérique, `remise` est quantitative même si elle est stockée en texte. Une fois la nature écrite, la statistique autorisée se déduit — et l'inverse est faux : choisir d'abord le graphique, puis chercher quelle statistique le justifie.

Boîte à outils. Vérifier l'enveloppe d'un fichier, trois commandes suffisent : `file -bi mon_fichier.csv` (type MIME et encodage déclarés) · `head -3 mon_fichier.csv | cat -A` (séparateurs, fins de ligne ^M\$, espaces insécables) · `awk -F';' '{print NF}' mon_fichier.csv | sort | uniq -c` (toutes les largeurs de lignes d'un CSV, pour repérer les lignes cassées). Sous Windows, PowerShell : `Get-Content mon_fichier.csv -TotalCount 3`. Pour un JSON : `python3 -m json.tool mon_fichier.json | head -20` affiche la structure réelle, pas celle du premier objet.

6. Exemple concret : vingt exemples réels, classés en six minutes

Liste typique que l'on trouve dans une quincaillerie-grossiste, et son classement complet. Faites-le à la main avant de lire la réponse : c'est le meilleur entraînement du chapitre.

#	Exemple	Enveloppe	Nature (si tabulaire)	Usage analytique
1	<code>ventes_brutes.csv</code> , 243 360 lignes	structurée	mesures + identifiants	tout : CA, volumes, saisonnalité
2	<code>clients.csv</code> , 23 912 lignes	structurée	attributs qualitatifs + une mesure (plafond de crédit)	segmentation, géographie
3	<code>produits.csv</code> , 154 lignes	structurée	nominales (catégorie), quantitatives (prix, poids)	mix produit, marge brute
4	<code>magasins.csv</code> , 6 lignes	structurée	qualitatives nominales	comparaisons, hiérarchie
5	<code>objectifs_de_ca.csv</code> , 218 lignes	structurée	quantitatives (cibles)	écarts, taux d'atteinte
6	<code>stocks_quotidiens.csv</code> , 60 000 lignes	structurée	quantitatives discrètes + continues	ruptures, rotation
7	<code>couts_achat.csv</code> , 1 694 lignes	structurée	quantitatives, avec dates de validité	marge, SCD type 2 (M13)
8	<code>remises_manuelles.xlsx</code> , 18 200 lignes	structurée avec textes dans motif	quantitative qualitative	+ contrôle, abus de remise
9	<code>dim_date.csv</code> , 1 339 lignes	structurée	dates + drapeaux booléens	toute agrégation temporelle
10	<code>tarif_fournisseur_peinture.csv</code> , 42 lignes	structurée, chapeau encodage 1252	quantitatives	+ contrôle des prix d'achat
11	Journal de caisse, JSON ligne par ligne	semi-structurée	—	audit de fin de journée
12	Logs de l'application de vente en ligne	semi-structurée	quantitatives extraction	après trafic, tunnel d'achat
13	Export XML du logiciel de compta	semi-structurée	quantitatives	rapprochement comptable

#	Exemple	Enveloppe	Nature (si tabulaire)	Usage analytique
14	Feuille d'Excel du magasinier, avec notes en marge	structurée polluée	mélange	à re-mouler (M04)
15	SMS d'un client (« livrer samedi »)	non structurée	—	demande à saisir pour être comptée
16	E-mails de réclamation	non structurée	après extraction : ordinaire (gravité)	typologie des litiges
17	Photos de bons de livraison	non structurée (image)	—	OCR, puis validation humaine
18	Compte rendu PDF du conseil d'administration	non structurée	—	citation, jamais mesure
19	Enregistrements d'appels au standard	non structurée (audio)	—	transcription, prudence (donnée personnelle)
20	Sondage client sur papier, notes de 1 à 5	saisie → structurée	ordinal (souvent traité comme intervalle : à dire)	satisfaction : médiane et distribution, pas moyenne seule

La colonne qui compte vraiment est la dernière. Elle dit ce que vous **avez le droit** d'affirmer : 1 480 clients, oui ; « satisfaction moyenne 3,9 », seulement si vous assumez l'hypothèse d'intervalles égaux — et vous l'écrivez.

7. Démonstration pas à pas : trier un lot de fichiers livré par un client

Cadre. Un client remet un dossier ZIP de 9 fichiers et dit : « tout est là, pour l'analyse des ventes 2025 ». Vous devez répondre en une heure : ce que vous pouvez faire tout de suite, ce qui demande un travail, ce qui est impossible faute de format.

Étape 1 — Inventaire sans ouverture. Liste : nom, taille, extension, date de modification. Douze secondes, dix-huit colonnes de décision prises. Notez dans le journal.

Étape 2 — Détection de l'enveloppe, en une commande par fichier.

```
for f in *.csv; do printf "%s : %s champs, %s lignes\n" "$f" \
"$$(head -1 "$f" | awk -F';' '{print NF}')" "$$(wc -l < "$f")"; done
```

Un fichier à 1 champ sur la ligne 1 = ce n'est pas un CSV (ou le séparateur est une virgule/tabulation) ; un fichier à 300 000 lignes pour 4 Mo = un export de détails ; un fichier à 42 lignes = une grille. Vous savez déjà où sera le temps.

Étape 3 — Encodage et chapeau, pour les trois suspects.

```
file -i tarif_fournisseur_peinture.csv # → charset=iso-8859-1 : encodage 1252
head -3 tarif_fournisseur_peinture.csv # → 3 lignes de titre avant l'en-tête
iconv -f cp1252 -t utf-8 tarif_fournisseur_peinture.csv > /tmp/tarif_utf8.csv
```

Le fichier converti **dans un dossier de test** s'ouvre correctement : vous savez maintenant que le problème était la lecture, pas le fichier. Vous ne touchez pas l'original — règle du chapitre 1.

Étape 4 — Typage à la volée, pour trois colonnes. Comptez les valeurs non numériques d'une colonne de montant :

```
cut -d';' -f13 2025_ventes_M5_brut.csv | grep -cvE '^[^*]?[0-9]+([.][0-9]+)? *$'
```

Résultat attendu sur l'échantillon de l'atelier : **486** lignes non numériques sur 489 (hors en-tête, le calcul exclut la ligne d'en-tête), ce qui recoupe exactement ce qu'a mesuré le chapitre 4. Vous avez une double preuve, par deux voies indépendantes : le tableur et la ligne de commandes. C'est cela, la robustesse d'un chiffre.

Étape 5 — Classer le contenu, pas les fichiers. Ouvrez les trois colonnes suspectes : une colonne motif de 18 200 lignes de texte libre ? C'est du non structuré **dans** un fichier structuré. Traitez-le comme tel : comptez les 20 mots les plus fréquents, mais n'en faites **pas** un indicateur.

Étape 6 — Réponse au client, en cinq lignes (modèle à copier).

```
1. Exploitable immédiatement : 5 fichiers (ventes 2025 x2, clients, produits, objectifs) = 246 090
lignes.
2. Demande un travail de préparation : 3 fichiers (tarifs fournisseurs : encodage + chapeau +
virgule décimale).
3. Non exploitable en l'état : relevé de stock avec notes libres en marge → 2 heures de remoulage,
ou saisie d'un vrai bordereau.
4. Manquant pour votre question « la marge baisse-t-elle ? » : les coûts de structure (loyer,
salaires, transport).
5. Question à trancher avant calcul : les retours doivent-ils être inclus dans le CA ?
```

Ce message est un livrable professionnel : il annonce un délai, un coût, une impossibilité et une question. C'est exactement ce que l'on attend d'un analyste en première semaine de mission, et cela n'a nécessité aucun graphique.

8. Erreurs fréquentes

Symptôme	Cause	Correction
« 4 catégories valent 2 fois l'autre »	Variable nominale traitée comme un ratio	Test du §5.4 : une soustraction a-t-elle un sens ? Sinon, parler d'effectifs et de parts
La moyenne des catégories codées 1..7	Code numérique pris pour une mesure	Recharger le code comme texte, ou documenter explicitement qu'il ne sert qu'au tri
Le tableau de bord ne montre pas les commentaires clients	Non structuré ignoré parce qu'il ne rentre pas dans une table	Décider une extraction validée sur échantillon, ou assumer l'exclusion dans la note de périmètre
JSON importé en une colonne unique	Aplatissement non fait	Extraire les clés au lieu de stocker la chaîne (M08)
Un CSV « corrompu » dont les accents sont cassés	Encodage mal déclaré à l'import	<code>file -i</code> puis convertir dans un dossier de test ; ne jamais réenregistrer le brut
Deux fichiers du même client lus avec le même séparateur	Supposition d'homogénéité	Vérifier le nombre de champs ligne 1 de chaque fichier, pas du premier
Une moyenne de notes 1-5 présentée comme un score d'entreprise	Échelle ordinale traitée en intervalle	Donner distribution + médiane, et écrire l'hypothèse si l'on donne la moyenne

9. Bonnes pratiques professionnelles

- [] À la réception d'un lot : inventaire (nom, taille, extension, date), puis détection d'enveloppe par ligne 1.
- [] Quatre propriétés vérifiées par fichier plat : séparateur, encodage, décimale, chapeau.
- [] Une conversion d'encodage se fait **copie vers un dossier de test**, jamais sur l'original.
- [] Toute variable codée en nombre est classée à la main avant tout calcul (le code n'est pas la mesure).

- [] Un champ texte libre dans un fichier structuré est un **avertissement**, pas un détail : il signale une décision de saisie à changer.
- [] L'outil se choisit selon qui relit, pas selon la mode.
- [] Le semi-structuré se transforme en table **datée** : la version du parseur fait partie du résultat.
- [] Un non structuré jamais quantifié sans échantillon validé à la main, avec taux de réussite écrit.

10. Exercice guidé — classer les 13 colonnes de l'atelier, avec justification

Prenons-en quatre, les plus discutables, et menons le raisonnement à voix haute.

1. **client** (identifiant, 372 valeurs distinctes, 18 vides). Enveloppe : colonne d'une table structurée. Nature : **qualitative nominale**, même si les valeurs sont numériques — c'est un identifiant, donc une étiquette. Conséquence licite : compter des clients distincts, regrouper ; interdiction : moyenne, médiane, écart-type. Le vide oblige à une décision (comptoir ou donnée manquante) : ce n'est pas un choix technique, c'est une règle métier, donc à écrire.
2. **catégorie** (7 modalités). Qualitative nominale. Ce qui est permis : effectifs, parts, top catégories (ici Matériaux 146 lignes, Quincaillerie 115, Consommables 58, Plomberie 57, Electricité 54, Peinture 34, Bois & panneaux 25). Ce qui ne l'est pas : un « classement des catégories par valeur moyenne de catégorie ».
3. **quantité** (minimum négatif, maximum 14 000, 7 lignes > 500). Quantitative discrète. Moyenne et écart-type autorisés, **mais** l'écart-type explose à cause des aberrations : avant tout résumé statistique, on documente (M02.C01) et l'on décide (M04).
4. **heure** (HH:MM, 356 valeurs distinctes). Quantitative **circulaire** : 23 h 58 et 00 h 02 sont à 4 minutes, et à 23 h 56 « d'écart arithmétique ». Le bon usage n'est donc pas la moyenne des heures mais la répartition en tranches (matin/après-midi) ou la médiane circulaire. Une moyenne d'heures dans un rapport est une erreur de catégorie, pas une approximation.

Le geste à retenir : pour chaque colonne, écrivez une ligne — enveloppe · nature · ce qui est permis · ce qui est interdit — et placez-la dans le dictionnaire de données. En trois minutes, vous venez de prévenir trois erreurs de calcul et un débat de réunion.

11. Exercices autonomes

Exercice 5.1 (★) — Vingt exemples. Reclasser les 20 exemples du §6 sans regarder le tableau, en deux colonnes (enveloppe / nature). Contrôlez : vous devez trouver 10 structurés, 3 semi-structurés, 7 non structurés ou mixtes. (attendu : les écarts se discutent pour n° 11-14 ; justifiez par la présence ou l'absence de schéma régulier)

Exercice 5.2 (★) — Le test des écarts. Pour `type_client` (particulier / pro / revendeur), répondez aux trois questions de l'échelle (§3) et concluez sur la moyenne. (ordre oui ; écart 10→11 comme 40→41 ? non ; zéro = absence ? non → ordinale, moyenne interdite, médiane et parts autorisées)

Exercice 5.3 (★★) — JSON à plat. À partir du ticket de l'exemple §5.2, écrivez les deux lignes de la table « articles » (grain : l'article), en indiquant quelles colonnes du ticket sont recopiées et ce que devient l'absence de `remise`. (2 lignes × colonnes ticket + article ; `remise` vide → décision 0 ou NA, à écrire dans le dictionnaire)

Exercice 5.4 (★★) — Le lot de fichiers. Un client remet 6 fichiers : `ventes2025.csv` (2 Mo, 1 champ sur ligne 1, tabulation), `clients.csv` (UTF-8, 11 champs), `tarif.xls` (binaire), `notes_livraison.txt` (40 000 lignes de prose), `stats.json` (120 Ko, 3 clés imbriquées), `README.docx`. Rédigez les cinq lignes de réponse du §7, étape 6. (attendu : déduire de la ligne 1 que le séparateur du premier est une tabulation ; classer `notes_livraison` en non structuré → extraction validée ; refuser de chiffrer quoique ce soit depuis le `.docx` ; annoncer un délai pour `tarif.xls` ; demander la liste des champs de `stats.json`)

Exercice 5.5 (★★) — Choisir l'outil, le justifier. Quatre demandes : (i) comparer 6 magasins sur 3 ans, une fois par mois ; (ii) retrouver les 20 tickets les plus gros d'un fichier de 240 000 lignes ; (iii) extraire une table de 30 000 lignes d'un JSON ; (iv) vérifier qu'un fichier mensuel ne contredit pas le précédent. Attribuez un outil à chaque demande et **une raison** qui ne soit pas le nom de l'outil. (attendu : Power BI ou tableur pour (i) selon qui relit ; SQL ou DuckDB pour (ii) ; Python pour (iii) ; script ou DuckDB pour (iv), avec la raison « jouable sans intervention humaine »)

12. Correction détaillée

Exercice 5.1. Structurés : 1-10 (le 8 est structuré mais pollué par du texte libre : à signaler comme « mixte »). Semi-structurés : 11, 12, 13 (le 14 est structuré-pollué, pas semi-structuré — la différence est que son schéma existe, il est juste violé par des notes). Non structurés : 15-19, et le 20 est **à cheval** : papier = non structuré, une fois saisi = structuré, et la saisie introduit ses propres erreurs (à écrire).

Exercice 5.2. Ordre : oui, la hiérarchie de puissance d'achat est une convention métier. Écart : non, le passage particulier→pro n'a pas la même signification que pro→revendeur. Zéro : non, il n'y a pas de « zéro type de client ». Conclusion : ordinale → la moyenne de ces catégories (si codées 1-2-3) est un non-sens mesurable ; ce qui est admissible : parts, effectifs, médiane des codes si et seulement si l'on précise que les codes sont arbitraires.

Exercice 5.3. Table des articles :

ticket	date	magasin	vendeur	produit	qte	pu
remise						
T05-250101-075845	2025-01-01	5	M. Ilboudo	Plâtre de construction 25 kg	11	4500
0.03						
T05-250101-075845	2025-01-01	5	M. Ilboudo	Gravier 15/25 (m3)	2	12000
NA						

Quatre colonnes du ticket sont recopiées sur les deux lignes (redondance assumée : c'est le prix du format plat, et il devient un problème quand les tables grossissent — M13). `remise` : NA, pas 0, tant que le dictionnaire n'a pas tranché ; et ce choix doit être écrit, car NA et 0 donnent deux totaux différents (le second est plus petit que le premier de 720 FCFA sur cette ligne : $24\ 000 \times 0,03$ n'existe pas dans le premier cas, dans le second il vaut exactement cela). Le bon critère de réussite : le total des `montant_ht` doit rester **inchangé** par l'opération d'aplatir.

Exercice 5.4. Réponse type : (1) `ventes2025.csv` exploitable, mais séparateur = tabulation, donc import à corriger ; (2) `clients.csv` exploitable directement, 11 colonnes ; (3) `tarif.xls` = ancien format binaire : conversion nécessaire, +1 h ; (4) `notes_livraison.txt` = prose : extraction non garantie, à chiffrer sur échantillon (proposition : 50 notes lues à la main, taux d'extraction valable annoncé) ; (5) `stats.json` : 120 Ko mais structure inconnue, merci de donner la liste des clés et un exemple complet. Le document est une réponse professionnelle complète : il dit ce qui est possible, ce qui coûte, ce qui manque.

Exercice 5.5. (i) un **tableau de bord** si la consultation est répétée et le public non technique, sinon un tableur : le critère est la fréquence et le nombre de relecteurs, pas la taille des données

(6 magasins × 36 mois = 216 lignes !) ; (ii) une **requête** — 240 000 lignes, une seule question, tri + LIMIT : un tableur rame, une base répond en une seconde ; (iii) **Python** — aplatir du JSON est mécanique en quelques lignes et rejouable mensuellement ; (iv) **script** — une vérification périodique doit s'exécuter sans humain, avec un message clair en cas d'écart. Un devoir qui répond « Power BI parce que c'est le plus puissant » perd le point de justification : le motif n'est pas un jugement sur l'outil, c'est une contrainte du cas.

13. Mini-projet M01.P5 — « La carte d'identité du lot » (40 min)

À partir du socle fourni (10 fichiers structurés + le fichier du fournisseur + un échantillon de notes libres que vous rédigez vous-même, 10 lignes), produisez `00_doc/carte_lot_donnees.md` :

1. un tableau de 11 lignes × 7 colonnes (fichier, taille, lignes, lignes utiles, encodage, séparateur, chapeau) ;
2. un classement enveloppe/nature des **colonnes** de deux fichiers au choix ;
3. les trois questions métier rendues impossibles par l'état du lot, avec le motif exact (encodage ? grain ? prose ?) ;
4. une réponse de cinq lignes au client, sur le modèle du §7 étape 6, avec un délai annoncé en heures pour chaque tâche.

Barème : 6 pts exactitude des sept nombres (vérifiés par vos commandes ou votre tableur, pas recopiés) · 4 pts cohérence des classements nature ↔ statistiques autorisées · 5 pts clarté de la réponse au client · 5 pts faisabilité du délai annoncé. Le livrable est relu une deuxième fois par un pair : si son délai à lui diffère du vôtre de plus de 50 %, vous devez réécrire la justification — un chiffrage qui varie du simple au double n'est pas un chiffrage.

14. Résumé du chapitre

L'enveloppe (structurée, semi-structurée, non structurée) décide du **coût de préparation** et donc de l'outil. La nature (quantitative discrète/continue, qualitative nominale/ordinaire) décide des **statistiques licites**. Les deux se testent mécaniquement : y a-t-il un schéma régulier ? une soustraction a-t-elle un sens ? Un fichier plat se juge sur quatre propriétés vérifiables en ligne de commande — séparateur, encodage, décimale, chapeau. Un lot de données se traite en trois mots : **inventorier**, **classer**, **annoncer** — ce qui est possible tout de suite, ce qui demande un travail, ce qui manque.

15. À retenir

À retenir. 1. **Trois enveloppes, trois coûts** : table = prêt à calculer, JSON = à aplatir, prose = à extraire et valider. 2. **Un code numérique n'est pas une quantité** : le test décisif est « soustraire a-t-il un sens ? ». 3. **Nominal → mode et parts ; ordinal → + médiane ; quantitatif → moyenne et écart-type**, sous réserve d'asymétrie (M02). 4. **Vérifiez séparateur, encodage, décimale, chapeau** : quatre commandes, ou une ligne perdue dans un tableau croisé. 5. **L'outil se choisit selon qui relit et ce qui doit rester rejouable**, jamais selon la puissance supposée.

16. Évaluation formative (auto-correction, 12 min)

1. Un fichier de 5 lignes, une par client, chaque ligne contenant une liste d'achats entre crochets : enveloppe ? (semi-structurée : le schéma existe mais est irrégulier et imbriqué ; la table en résultant est à grain « article », pas « client »)
2. Une colonne `note_satisfaction` de 1 à 5 : quelles statistiques, et quelle phrase d'avertissement ? (mode, médiane, distribution, parts ; si moyenne, écrire l'hypothèse d'intervalles égaux)
3. Le test qui distingue une variable ordinale d'une variable à échelle de ratio ? (un écart égal vaut-il la même chose partout, et le zéro signifie-t-il l'absence ? les deux « oui » → ratio)
4. `file -i facture.csv` répond `charset=iso-8859-1` : qu'en concluez-vous pour l'import, et que ne faites-vous pas ? (lire/importer en Windows-1252 (latin-1), convertir en copie de test si besoin ; ne pas réenregistrer le brut en UTF-8 à l'aveugle)
5. **Question ouverte** : le client dit « on a tout en Excel, donc c'est structuré ». Répondez en quatre phrases en distinguant l'enveloppe, le schéma et la propreté. (attendu : un classeur peut contenir un schéma violé (notes libres, sous-totaux, cellules fusionnées) → l'enveloppe est table, le schéma est déclaré mais non respecté, la propreté est à établir : trois questions distinctes, trois chantiers distincts)

M01.C06 — Le cycle de vie d'une donnée : naissance, stockage, transformation, usage, archivage, suppression

Outil de ce chapitre : schéma sur papier ou tableau blanc, un tableur pour la partie écriture.
Durée indicative : 4 h. **Niveau :** N1.

L'idée du chapitre. Une ligne de vente ne « vit » pas dans un fichier : elle traverse six états, change de mains quatre fois, et survit à trois logiciels. Celui qui ne connaît que l'état « tableau de bord » produit des chiffres sans mémoire ; celui qui connaît le cycle entier sait **où** son chiffre a pu mourir, **qui** peut le contester, et **combien de temps** il doit pouvoir le retrouver. Ce chapitre est le seul du module qui ne comporte aucun calcul — et c'est celui qui, en entreprise, vous évitera le plus de désagréments.

1. Objectifs du chapitre

À la fin de ce chapitre, vous saurez :

1. **Décrire** les six étapes du cycle d'une donnée et les responsabilités associées, sur un cas réel : la ligne d'un ticket du magasin 5 ;
2. **Situer** un incident dans le cycle : à quelle étape, chez qui, et avec quelle preuve retrouvable ;
3. **Rédiger** trois artefacts professionnels : le **dictionnaire de données**, le **journal de transformation**, la **politique de conservation** (une page chacun) ;
4. **Expliquer** le versionnage d'un jeu de données (pourquoi on garde l'historique des fichiers et pas seulement des rapports) ;
5. **Décider** de la suppression : ce qui doit disparaître, ce qui doit survivre, et dans quel ordre ;
6. **Nommer** les obligations qui pèsent sur une donnée client (protection, minimisation, durée) sans jargon juridique, avec les réflexes qui vont avec.

2. Pourquoi cette notion est importante

Situation 1 — le chiffre disparu. Trois mois après la clôture d'exercice, un contrôleur demande le détail d'un total. Le rapport PDF existe. Le fichier de travail a été écrasé par la version du mois suivant, parce que le nom du fichier ne portait pas de date. Le total devient « une affirmation de l'analyste ». La réponse professionnelle — reproductible en cinq minutes — aurait été : garder les entrées, les sorties, et le journal.

Situation 2 — la suppression qui détruit la preuve. Un poste est libéré, le service nettoie le dossier partagé, et fait disparaître les fichiers sources de 2023. En zone OHADA, les pièces comptables se conservent **10 ans** : un chiffre d'affaires publié sur une base détruite n'est plus défendable, ni devant l'administration, ni devant un associé sortant. La suppression est une étape du cycle comme les autres, et elle se planifie.

Situation 3 — les données personnelles en trop. Pour calculer un chiffre d'affaires par type de client, un analyste télécharge la table complète avec noms, téléphones et e-mails, la dépose sur un disque perso pour travailler le week-end. Aucun chiffre n'est faux, et pourtant il y a un

problème : ce n'est pas la bonne **étape**, ni le bon **périmètre**, ni le bon **support**. La protection des données se règle dans le cycle, pas après le rapport.

Dans les faits. Dans le socle du manuel, une ligne de vente naît à la caisse du magasin 5, est exportée chaque nuit dans `ventes_brutes.csv` (243 360 lignes, 28,5 Mo), nettoyée en `ventes_propres.csv` (240 000 lignes), agrégée dans des tableaux mensuels, publiée dans un rapport, archivée après clôture à 3 ans, et purgée à 10 ans — **sauf** le dictionnaire et le journal, qui survivent, parce qu'ils expliquent. Cette chaîne, vous allez la parcourir de bout en bout au fil des modules : M04-M05 (nettoyage), M07-M08 (transformation), M13-M18 (usage), M21-M22 (gouvernance et soutien).

3. Explication simple

Prenez le ticket de caisse d'un client qui achète onze sacs de plâtre, le 1^{er} janvier 2025 à 11 h 01. Suivez-le.

1. **Naissance.** La caissière scanne, le logiciel écrit une ligne. Ce qui naît, ce n'est pas « une vente » : c'est **une ligne d'article**, avec un numéro de ticket, une date de **saisie**, un identifiant client éventuellement vide. Ce que la caisse ne note pas — l'absence de client identifié, par exemple — n'existera jamais nulle part. Une donnée est un traceur du processus qui l'a produite.
2. **Stockage.** La nuit, le logiciel exporte un CSV. Le fichier atterrit sur un serveur. Deux choses peuvent mourir ici : l'export interrompu (il écrit 80 % des lignes) et la réécriture (le même nom, un fichier différent). Une donnée sans date ni empreinte n'est pas une version, c'est un instantané.
3. **Transformation.** Vous ouvrez le fichier, retirez les doublons, convertissez les montants, créez une colonne mois. Ici se joue l'honnêteté du résultat : tout choix non écrit est une modification invisible. Une transformation sans journal est une opinion.
4. **Usage.** Le chiffre d'affaires mensuel s'affiche dans un tableau de bord, le directeur l'évoque en réunion, un commercial ajuste sa relance. L'usage est l'unique étape où la donnée produit de la valeur, et le seul endroit où le public voit quelque chose. Une donnée qui ne sert à aucune décision n'a que des coûts.
5. **Archivage.** L'année est close. On fige les fichiers et les rapports en lecture seule, avec le dictionnaire et le journal à côté. Archiver, c'est rendre rejouable, pas seulement garder.
6. **Suppression.** Le délai légal passe. On purge les détails, on garde les agrégats et la documentation, on note ce qui a été supprimé et pourquoi. Supprimer proprement est plus difficile que ne rien supprimer ; supprimer n'importe comment est une faute.

Le voyage d'une ligne, de la caisse au rapport annuel



Responsable : caissier → admin. de l'ERP → vous → le BI → la DAF → la DAF, encore.

- Où le chiffre meurt : export coupé, fichier réécrasé, arrondi, filtre oublié, fusion dupliquée (+9 lignes ici).
- Ce qui prouve votre travail dans trois ans : le journal de transformation et le dictionnaire, pas votre mémoire.
- Règle du manuel : on ne modifie jamais un fichier brut ; du brut on tire du propre, et on garde les deux.

Figure 6 — Six étapes, cinq responsables, et l'endroit exact où votre total peut disparaître.

4. Vocabulaire essentiel

Français — English	Définition simple	Piège à éviter
Cycle de vie — lifecycle	Ensemble des états d'une donnée, de sa production à sa disparition.	Croire que le cycle finit au tableau de bord.
Source de vérité — system of record	Le système où l'information est officiellement détenue (ici : la caisse).	Exporter depuis un rapport au lieu d'exporter depuis la source.
Donnée brute — raw data	État au moment de la réception, non modifié.	Corriger le brut « pour aller vite » : la référence disparaît.
Empreinte — checksum / hash	Signature courte calculée sur le contenu du fichier (MD5, SHA-256).	Comparer deux fichiers par la taille seule : deux fichiers de même taille peuvent différer.
Ligne d'eau — watermark	Marqueur de ce qui a déjà été traité (date, n° d'enregistrement).	Ré-exécuter un import et doubler les lignes.
Journal de transformation — transformation log	Liste datée, ordonnée, des opérations appliquées.	Le rédiger après coup, de mémoire.
Dictionnaire de données — data dictionary	Document qui décrit colonnes, types, unités, règles, provenance.	Le garder dans la tête : il meurt avec la personne.
Versionnage — versioning	Conservation des états successifs, identifiables et comparables.	Remplacer la version précédente sans la nommer.
Jeu figé — frozen dataset	Copie verrouillée, référencée par un identifiant, servant de base officielle à une publication.	Publier un chiffre depuis un fichier qui continue d'évoluer.
Rétention — retention	Durée de conservation, et ce que l'on détruit à l'échéance.	Conserver tout (coût, risque juridique) ou ne rien conserver (perte de preuve).
Anonymisation / pseudonymisation	Retirer ou remplacer les identifiants directs avant usage.	Croire qu'enlever le nom suffit : un téléphone ou une ville suffisent à ré-identifier.
Minimisation — data minimisation	Ne traiter que les champs nécessaires à la question.	« Télécharger toute la table au cas où ».

5. Cours approfondi

5.1 Les six étapes, avec leur preuve documentaire

Chaque étape produit un **artefact** — un document, un fichier, une trace — et c'est ce qui distingue une chaîne de traitement d'un bricolage.

Étape	Ce qui se passe	Responsable principal	Artefact de preuve	Défaut typique de l'étape
Naissance	saisie, formulaire	capteur, opérationnel (caissier, magasinier)	le ticket, la ligne en base	oubli de saisie, double scan
Stockage	écriture, transfert	export, informatique éditeur du logiciel	fichier daté + empreinte, journal d'export	export partiel, réécrasement
Transformation	nettoyage, recalcul, enrichissement	vous	script ou classeur de travail + journal	correction non écrite, arrondis en cascade
Usage	consultation, décision, publication	métier / direction	le rapport + la note de périmètre	chiffre cité hors période, filtre oublié

Étape	Ce qui se passe	Responsable principal	Artefact de preuve	Défaut typique de l'étape
Archivage	figement, classement	vous + DSI	jeu figé dictionnaire manifeste	+ archivage sans le code qui a produit le chiffre
Suppression	purge, anonymisation	DSI + responsable légal	registre suppression	de suppression du dictionnaire, conservation de données personnelles inutiles

Lisez le tableau de bas en haut une fois : un chiffre d'affaires de 2023, cité en réunion en 2026, ne peut être défendu que si les six artefacts existent. Un seul manque et l'argument devient « je crois me rappeler ».

Définition. Source de vérité — system of record — le système où une information est officiellement détenue : ici, la caisse du magasin. Tout le reste en est une copie, plus ou moins fraîche. Travailler sur une copie est licite, pour la performance ou pour ne pas gêner l'exploitation, à une condition : le retard doit être écrit et connu.

Définition. Donnée brute — raw data — l'état exact de ce qui a été reçu, octet pour octet, avant la moindre correction. Le brut n'est pas « le fichier moche » : c'est la seule preuve de ce que le système émetteur contenait ce jour-là. On le lit, on ne l'édite pas.

5.2 Le dictionnaire de données : votre premier document professionnel

Le dictionnaire décrit **les colonnes**, pas le logiciel. Une ligne par colonne, sept informations, et il est terminé. Modèle, appliqué à notre fichier d'atelier :

champ	type	unité / domaine	règle de calcul	provenance	défauts connus	commentaire
n_ticket	texte	—	émis par la caisse, unique par vente	caisse.log	9 lignes dupliquées dans l'extrait	sert de clé avec produit
date	date	jour	date de l'opération, pas de la saisie	caisse	65 lignes en JJ/MM/AAAA	à normaliser en ISO avant tout regroupement
magasin	texte	1 à 6 dépôt	+ référentiel magasins.csv	caisse	—	le dépôt (id 6) ne vend pas au comptoir
client	texte	identifiant	0 = vente au comptoir	caisse	18 vides	vide ≠ 0 : le vide est une absence
quantite	nombre	unité du produit	signée (négatif = retour)	caisse	7 lignes > 500	à contrôler par plage métier
prix_unitaire_ht	nombre	FCFA HT	prix catalogue du jour	tarif	—	TVA 18 % appliquée au total, pas à l'unité
remise	nombre	proportion	0 à 0,40	saisie vendeur	—	les valeurs > 0,4 sont des points de % mal saisis
montant_ht	nombre	FCFA	quantite × prix × (1 - remise), arrondi à l'entier	calcul caisse	—	contrôle de cohérence avec quantite
montant_ttc	nombre	FCFA	montant_ht × 1,18, arrondi	calcul caisse	486 lignes en texte	total de référence du module : 36 073 185 FCFA (nettoyé)

Une colonne **défauts connus** est ce qui fait la différence entre un dictionnaire d'intention et un dictionnaire utile : elle évite à celui qui reprend le travail de redécouvrir la même chose dans six mois. Ce dictionnaire est un livrable du projet M01.P ; il sera réutilisé et complété en M04 (nettoyage), M05 (qualité), M06 (modélisation), M21 (gouvernance). **Version alternative pour un petit écran** — ce dictionnaire de sept colonnes se lit par la seule colonne « défauts connus », qui porte l'essentiel : 9 lignes dupliquées, 65 dates écrites en texte, 18 clients vides, 7 quantités au-dessus de 500, 486 montants en texte, TVA appliquée au total. Les six autres colonnes disent seulement où poser la main.

Définition. Manifeste de jeu de données — dataset manifest — fiche courte qui accompagne un jeu figé : ce qu'il contient, d'où il vient, quelle version du code l'a produit, quelles empreintes, quelles limites connues, qui a validé, à quelle date. Cinq minutes à écrire ; il rend un archivage compréhensible par un inconnu — donc par vous dans trois ans.

5.3 Versionner un jeu de données : trois mécaniques, par ordre de sérieux

1. **Le nommage daté** (acquis au chapitre 1) : `2025_ventes_M5_brut.csv` ne change jamais ; le nettoyage produit `2025_ventes_M5_propre_v1.csv`. Simple, mais rien n'empêche l'écrasement.
2. **Le dossier de version + le manifeste** : chaque livraison de travail a son répertoire `2026-09-17_v1/` contenant données, code, journal, manifeste. On ne modifie jamais une version publiée ; on ouvre la suivante.
3. **Le dépôt de versions** (Git) : suit les fichiers texte — scripts, requêtes, dictionnaire, journal — et pas les gros fichiers de données, qui y sont mal à l'aise. Un `README` daté et un commit par livrable. C'est l'objet du module M21 ; en attendant, la discipline 2 suffit et prépare la 3.

Ce qui compte, dans les trois cas, est le même : **à tout instant, on doit pouvoir répondre « de quel fichier vient ce chiffre ? » et le rouvrir.**

Définition. Empreinte — checksum / hash — une signature courte calculée sur le contenu d'un fichier. Même empreinte, même contenu ; empreinte différente, contenu différent — sans avoir à ouvrir ni à comparer les lignes. L'empreinte remplace la confiance par un contrôle, et c'est ce qui manque dans la plupart des échanges de fichiers par courriel.

Définition. Jeu figé — frozen dataset — copie verrouillée, nommée, référencée par un identifiant, sur laquelle un chiffre publié a été calculé. C'est ce qui permet, un an plus tard, de retrouver exactement le total annoncé. Sans jeu figé, le même rapport se recalcule différemment le lendemain, et les chiffres se contredisent en réunion.

5.4 Journal de transformation : le format, et cinq exemples

Format imposé par le manuel, une ligne par opération :

```
AAAA-MM-JJ HH:MM  auteur  [fichier source → fichier cible]  opération  entrée=n  sortie=n  écart
motif
```

Appliqué à l'échantillon de l'atelier, les cinq entrées qui comptent vraiment :

```

2026-09-17 09:12 a.minani [brut/2025_ventes_M5_brut.csv → propre/2025_ventes_M5_propre_v1.csv]
import, 13 colonnes déclarées texte entrée=489 sortie=489 écart=0 motif: éviter tout typage
automatique
2026-09-17 09:26 a.minani [brut/2025_ventes_M5_brut_recu2026-09-17.csv → propre/
2025_ventes_M5_propre_v1.csv] suppression 9 lignes strictement identiques entrée=489 sortie=480
écart=-9 motif: doublons d'export, total TTC -266 132 FCFA (0,74 %)
2026-09-17 09:41 a.minani [propre/2025_ventes_M5_propre_v1.csv] normalisation date → ISO
entrée=480 sortie=480 écart=0 motif: 65 lignes en JJ/MM/AAAA ; contrôle par répartition
mensuelle (décembre 5 292 517 FCFA)
2026-09-17 09:58 a.minani [propre/2025_ventes_M5_propre_v1.csv] montant_ttc texte → nombre
entrée=480 sortie=480 écart=0 motif: 486 lignes avec espace de milliers ; contrôle NB = NBVAL OK
2026-09-17 10:07 a.minani [propre/2025_ventes_M5_propre_v1.csv] 7 lignes quantité > 500
marquées suspectes, **non supprimées** entrée=480 sortie=480 écart=0 motif: montant cohérent
avec le prix, doute sur l'unité de saisie ; décision reportée au module 4 avec le métier

```

Deux remarques. D'abord, dans un vrai journal, on répète le nom complet du fichier à chaque ligne : la concision n'est jamais un motif d'ambiguïté. Ensuite — et c'est le point capital de ce format — **on peut signaler sans supprimer** : la dernière entrée documente sept lignes douteuses qui restent dans le fichier. Cette distinction entre « défaut traité » et « défaut documenté » est la marque du professionnel : le premier se corrige, le second s'annonce, et les deux s'écrivent.

Règles du journal : on n'efface jamais une ligne ; on en ajoute une qui annule la précédente (« 10:15 correction : le point 4 s'appliquait aussi à... ») ; chaque suppression de ligne s'accompagne du **motif** et de l'**écart chiffré**. Un journal sans écart chiffré est un agenda.

5.5 Les points de rupture : où votre chiffre meurt réellement

Les six étapes ont chacune leur mode de mort statistiquement dominant dans les PME sans informatique structurée. Apprenez la liste : elle sert de grille de diagnostic.

1. **Naissance** : oubli de saisie, ou saisie en fin de journée « de mémoire ». Le chiffre est faux **avant** d'exister dans un fichier. Contre-mesure : contrôles à la saisie, et, côté analyse, jamais de conclusion de cause profonde sur un processus non instrumenté.
2. **Stockage** : export partiel, réécrasement, fichier envoyé par messagerie et modifié en pièce jointe. Contre-mesure : empreinte + nom daté + un seul dossier de référence.
3. **Transformation** : arrondis successifs, filtre oublié, jointure qui multiplie (M04, M07), suppression silencieuse de lignes « douteuses ». Contre-mesure : le journal, et un total de contrôle à chaque étape (ici, 36 073 185 FCFA).
4. **Usage** : le chiffre est cité hors de son périmètre (« décembre = 5,3 M » répété sans dire magasin 5, 2025, extrait), ou comparé à une autre source dont la définition diffère (HT vs TTC, retours inclus ou non). Contre-mesure : la note de périmètre à côté de tout chiffre publié, y compris dans l'e-mail.
5. **Archivage** : on archive le rapport sans le code, sans le journal, sans le dictionnaire. Contre-mesure : le manifeste ; cinq minutes.
6. **Suppression** : on supprime trop (preuve perdue) ou on conserve trop (données personnelles inutiles, coût, risque en cas d'intrusion). Contre-mesure : la politique de conservation.

Attention. Ré-exécuter un import sans point d'arrêt **double les lignes** : le total est faux, et il est faux en beau — c'est le défaut que l'on découvre le plus tard. La parade tient en deux mots : marqueur de reprise (watermark, la dernière date ou le dernier identifiant déjà traité) et clé unique dans la table d'arrivée, qui refuse le deuxième envoi.

5.6 Conserver, purger, protéger : la politique en une page

Un modèle utilisable dès votre premier stage, et qui tient sur une page :

Catégorie	Exemple	Durée	Support et protection	À l'échéance
Pièces comptables et justificatifs	exports de caisse, factures	10 ans (zone OHADA)	serveur de l'entreprise, accès restreint, chiffré	purge avec registre
Données d'exploitation	stocks, objectifs	3 ans	dossier de travail + sauvegarde froide	agrégats gardés, détail purgé
Données clients à caractère personnel	noms, téléphones, e-mails	le temps de la relation + durée légale de prospection	base métier, jamais copie personnelle	suppression ou anonymisation
Traces de travail	journal, scripts, dictionnaire	10 ans (alignées sur la donnée qu'elles expliquent)	dépôt de versions ou archive lisible	conservées plus longtemps que la donnée
Rapports publiés	PDF signés, tableaux figés	10 ans	archive officielle, lecture seule	jamais purgés sans validation de la direction

La ligne la plus contre-intuitive est la quatrième : **la documentation survit à la donnée**. Si les détails sont purgés, le dictionnaire et le journal permettent encore de comprendre ce que signifiait le chiffre et comment il a été obtenu. C'est pourquoi on ne supprime jamais les deux en même temps que les sources.

Côté protection, trois réflexes qui ne se discutent pas, quel que soit le pays : (1) pas de copie personnelle de données clients sur un disque privé ou une messagerie privée ; (2) minimisation — si la question porte sur le chiffre d'affaires par catégorie, la table `clients` n'a pas besoin des téléphones ; (3) si un échantillon est nécessaire pour déboguer, on le **pseudonymise** (remplacer les identifiants par des numéros séquentiels, en gardant la table de correspondance uniquement sur le poste métier).

Conseil professionnel. Quand on vous demande « tu peux me renvoyer le fichier avec les données clients ? », demandez d'abord **quelle question** il doit servir. Dans la majorité des cas, une table agrégée par client (sans nom, sans téléphone) suffit — et vous venez d'éviter une fuite sans rien refuser. Cette esquivé élégante est une compétence de métier, pas une prudence de juriste.

Attention. Retirer la colonne « nom » ne rend pas un fichier anonyme. Un numéro de téléphone, une date de naissance et une ville suffisent souvent à retrouver une personne dans une population de quelques dizaines de milliers d'individus. La protection se juge sur le risque de ré-identification, pas sur la suppression d'un champ.

À retenir. Le cycle de vie ne s'arrête pas au tableau de bord : il s'arrête quand la donnée est archivée ou détruite, avec une date et une décision écrites. Les trois preuves qui protègent un analyste sont le brut conservé, le journal de transformations et le jeu figé référencé — pas le logiciel utilisé.

6. Exemple concret : une ligne, trente-deux mois, six fichiers

Notre ligne du 1^{er} janvier 2025, onze sacs de plâtre à 4 500 FCFA, `montant_ttc = 56 658 FCFA`, dans le cycle complet du socle du manuel :

Date	État	Fichier ou système	Ce qui a changé pour elle
2025-01-01 11:01	née	caisse du magasin 5	rien : 3 lignes dans le ticket (2 articles, 1 remise)
2025-01-02 02:00	stockée	ventes_brutes.csv (243 360 lignes, 28,5 Mo)	dates et montants devenus du texte
2025-01-15	extraite	projection/ventes_magasin5_2025.csv (489 lignes)	échantillon de 40 lignes par mois, donc 40 lignes par mois
2026-09-17	transformée	reference/ventes_magasin5_2025_ATTENDU.csv (480 lignes)	9 doublons retirés, montant converti, date ISO
2026-09-18	agrégée	table mensuelle (12 lignes)	décembre 5 292 517 FCFA, janvier 2 051 424 FCFA
2026-10	usagée	rapport direction + note	le chiffre est cité avec périmètre, grâce au journal
2028	figée	archive 2025_close/ + manifeste	lecture seule, empreintes, dictionnaire à côté
2036	purgée	registre de suppression	détail effacé, dictionnaire et journal conservés

Remarquez deux choses. D'abord le chemin de la ligne : du **ticket** au **total mensuel** en passant par **quatre fichiers**, dont un échantillon de 489 lignes qui n'est **pas** l'intégralité de l'année du magasin (40 lignes par mois, pas 480 réparties au hasard). C'est précisément ce qui rend le jeu pédagogique : un échantillon qui se prend pour une population est l'erreur la plus fréquente des débutants (M02, M11).

Ensuite, la ligne « 2025-01-15 » : **un extrait de travail**. Un extrait n'est jamais une source ; il doit être nommé comme tel, daté, et sa taille annoncée. Le fichier de l'atelier pèse 489 lignes : si vous l'appellez « les ventes 2025 » dans un mail, vous venez d'inventer un chiffre d'affaires de 36 073 185 FCFA comme étant celui de l'entreprise, alors que le total de l'extrait correspond à **0,23 %** du chiffre consolidé (15 419 985 157 FCFA sur 4 ans). L'ampleur de la confusion fait peur, et elle se prévient avec un mot dans le nom de fichier : `extrait`.

7. Démonstration pas à pas : reconstruire le cycle d'un fichier reçu

Exercice complet, à faire sur le poste, 25 minutes. Objectif : produire les trois artefacts (§5.2, §5.4, §5.6) à partir d'un fichier reçu, sans rien calculer d'analytique.

Étape 1 — Recevoir (2 min). Copiez le fichier dans `01_brut/`, nommez-le `2025_ventes_M5_brut_recu2026-09-17.csv`, passez-le en lecture seule. Première ligne du journal, avec la taille (32 Ko) et le nombre de lignes (489).

Étape 2 — Empreinter (3 min). Sous Windows (PowerShell) ou terminal :

```
Get-FileHash .\01_brut\2025_ventes_M5_brut_recu2026-09-17.csv -Algorithm SHA256
```

```
sha256sum 01_brut/2025_ventes_M5_brut_recu2026-09-17.csv
```

Notez l'empreinte dans le journal **et** dans un fichier `00_doc/empreintes.txt`. Deux ans plus tard, cette ligne prouvera que le fichier que vous aviez est bien celui-là — utile quand un prestataire jure qu'il vous a envoyé autre chose.

Étape 3 — Décrire la structure (5 min). Ouvrez le fichier en texte brut, notez : 13 colonnes, séparateur `;`, encodage, ligne d'en-tête exacte, trois premières et trois dernières lignes. Résul-

tat attendu : l'en-tête n_tic-
cket;date;heure;magasin;vendeur;client;produit;categorie;quantite;prix_unitaire_ht;remise;montant_ht;montant
nière ligne du 31 décembre 2025.

Étape 4 — Écrire le dictionnaire (6 min). Reprenez le modèle du §5.2 : neuf lignes suffisent pour les colonnes qui servent au calcul ; les quatre autres reçoivent « attribut descriptif, non utilisé dans les totaux ». La colonne **défauts connus** se remplit avec les comptages réels : 9 doublons, 65 dates à deux formats, 486 montants en texte, 7 quantités suspectes, 18 clients vides.

Étape 5 — Ouvrir le journal de transformation (2 min). Les deux premières entrées (réception, empreinte), puis une ligne vide de contrôle : prochain contrôle attendu : total TTC après nettoyage = 36 073 185 FCFA (±1 ligne). Vous venez d'écrire une obligation de résultat pour vous-même, vérifiable par n'importe qui.

Étape 6 — Fixer la politique (4 min). Une page, trois colonnes : ce que je garde (brut, propre, journal, dictionnaire), combien de temps (10 ans pour le brut, aligné sur la valeur comptable du chiffre ; 3 ans pour mes brouillons), où (dossier de travail + disque chiffré + sauvegarde froide, pas de copie personnelle). Signez-la et datez-la ; en stage, faites-la viser par le responsable. Ce document, anodin, est celui qui vous protégera — pas l'inverse.

Contrôle final de la démonstration. Un collègue, sans vous voir, doit pouvoir : (1) dire d'où vient le fichier ; (2) retrouver son empreinte ; (3) savoir quelles colonnes sont des montants et lesquelles sont des identifiants ; (4) expliquer les 9 lignes manquantes entre brut et propre ; (5) savoir quoi en faire dans dix ans. Si une des cinq échoue, le dossier n'est pas fini.

8. Erreurs fréquentes

Symptôme	Cause	Correction
Le chiffre du mois change entre deux demandes	Le fichier source a continué d'évoluer	Fixer un jeu de travail pour la période publiée, avec un identifiant de version
Deux fichiers « identiques » aux totaux différents	L'un a été enregistré depuis Excel (dates, arrondis, colonne de garde)	Un brut se lit, ne s'édite pas ; comparer les empreintes pour trancher
Impossible de retrouver le code d'un chiffre de 2023	Le script vivait sur le bureau, le poste a changé	Le code vit avec la donnée (dépôt ou dossier 03_analyse), jamais sur un support personnel
Suppression de « lignes bizarres » non tracée	Nettoyage sans journal	Marquer, ne pas supprimer : une colonne statut_qualite et une ligne de journal
Le dictionnaire ne correspond plus aux fichiers	Écrit une fois, jamais entretenu	Révision à chaque nouveau champ, et une ligne dans le manifeste
Copie de 3 Go de données clients sur une clé USB	Convenience	Question à trancher en amont : la table agrégée suffit presque toujours
Un « export du rapport » utilisé comme source	Confusion source de vérité / vue	Retomber sur la source (caisse, base), jamais sur un document de sortie

9. Bonnes pratiques professionnelles

- [] Réception = copie + renommage daté + lecture seule + empreinte + entrée de journal.
- [] Un dictionnaire par jeu, tenu à jour à chaque champ ajouté ou retiré.
- [] Journal de transformation à chaque opération non triviale, avec `entrée=n` `sortie=n` `écart` chiffré.
- [] Signaler plutôt que supprimer, quand le doute est métier.
- [] Un jeu figé et un manifeste pour chaque publication.

- [] Le code vit à côté de la donnée qui l’a vu naître.
- [] Politique de conservation écrite, datée, visée ; documentation conservée plus longtemps que la donnée.
- [] Minimisation et pseudonymisation des échantillons de test ; jamais de copie personnelle de données clients.
- [] Un extrait est nommé `extrait_`, avec sa taille et sa période dans le nom.

10. Exercice guidé — reconstituer l’histoire d’un dossier à charge

Contexte. Vous reprenez le travail d’une personne partie. Dans `D:/Travail/`, un seul dossier, `rapports/`, contient :

CA 2023.xlsx	1,1 Mo	12/09/2024
CA 2023_final.xlsx	1,2 Mo	03/10/2024
rapport_ca_2023.pdf	240 Ko	15/09/2024
notes.txt	4 Ko	12/09/2024
base.mdb	38 Mo	31/08/2024

Reconstruisons, en posant les questions dans l’ordre du cycle.

1. **Source de vérité ?** `base.mdb` (base Access, 38 Mo, dernière écriture fin août) ressemble à la source ; `CA 2023*.xlsx` sont des transformations ; le PDF est un usage publié. Vérification : la taille et la date — un fichier de 38 Mo non modifié depuis plus de deux semaines est une source, un fichier de 1 Mo touché plus tard est une sortie.
2. **Lequel des deux classeurs a produit le PDF ?** Le PDF est daté du 15/09, `CA 2023.xlsx` du 12/09, `CA 2023_final.xlsx` du 03/10. Conclusion probable : le PDF vient du **premier**, et le second est un retravail postérieur. Preuve à chercher : ouvrir les deux, comparer le total de contrôle ; ouvrir le PDF, lire le total cité.
3. **Que dit `notes.txt` ?** Un fichier de 4 Ko daté du 12/09, donc du jour du premier classeur : c’est probablement un journal informel. Lisez-le **avant** de toucher aux fichiers : il contient peut-être la règle de retrait des retours, et c’est le seul endroit où elle est écrite.
4. **Le cycle est-il rejouable ?** Non : rien ne dit comment `base.mdb` est devenu `CA 2023.xlsx`. C’est la trace manquante, celle qu’il faut reconstituer en priorité — une requête Access, un export manuel ?
5. **Décision de reprise.** Plutôt que « refaire pareil », reprenez le cycle en amont : extraire de la base (étape 2), produire un CSV daté, écrire le dictionnaire et le journal, recalculer, **puis** comparer au PDF du 15/09 pour valider la reprise. Si l’écart est non nul, vous avez trouvé soit une transformation cachée, soit un chiffre publié faux — dans les deux cas, vous gagnez quelque chose.

Ce type de reprise est une activité réelle et rémunérée : audit de données, passation de consignes, continuité de service. Elle se joue sur quatre dates et trois tailles de fichiers, pas sur une maîtrise logicielle.

11. Exercices autonomes

Exercice 6.1 (★) — Les six artefacts. Pour le fichier de l’atelier, citez les six artefacts qui doivent exister à la fin du projet M01, et indiquez pour chacun le document (ou le fichier) où il vit. (brut daté + empreinte · dictionnaire · journal · classeur/table de travail · livrable avec note de périmètre · manifeste + politique de conservation)

Exercice 6.2 (★) — Qui répond ? Quatre questions posées en réunion : « pourquoi 489 lignes et pas 480 ? », « le CA est-il TTC ? », « décembre est-il vraiment le meilleur mois ? », « que devient le comptoir dans le classement clients ? ». Attribuez chacune à une étape du cycle et à l'artefact qui y répond. (stockage/transformation → journal · transformation → dictionnaire (unité) · usage → note de périmètre et tableau mensuel · naissance/dictionnaire (0 = comptoir))

Exercice 6.3 (★★) — Datation Forensique. Reprenez le dossier de l'exercice guidé : le total de `CA_2023_final.xlsx` diffère de celui du PDF de 1,8 %. Listez trois explications compatibles avec les dates, et le test qui les sépare. (le second classeur intègre des régularisations postérieures au PDF · il contient les retours, pas le premier · il a été enregistré après un changement de séparateur de dates ; test : compter les valeurs distinctes de `n_ticket` et nombre de lignes, vérifier si `notes.txt` mentionne une régularisation, recalculer depuis `base.mdb`)

Exercice 6.4 (★★) — L'extrait qui ment. Vous citez « CA 2025 du magasin 5 : 36 073 185 FCFA » alors que le fichier est un extrait de 489 lignes (40 par mois). Rédigez la phrase exacte qui rend la citation honnête, et celle qui aurait dû figurer dans le nom du fichier. (attendu : « CA de l'extrait de 480 lignes utiles (40 lignes par mois), magasin 5, 2025 » ; nom : `2025_ventes_M5_extrait40parmois_brut.csv`)

Exercice 6.5 (★★★) — Politique. Rédigez la politique de conservation d'un service qui produit des rapports mensuels à partir de la caisse, en cinq lignes maximum, couvrant : ce qui est la source, ce qui est figé, ce qui est purgé à 3 ans, ce qui survit à 10 ans, et l'interdit sur les supports personnels. (barème implicite : une ligne par obligation, aucune phrase générale)

12. Correction détaillée

Exercice 6.1. Brut : `01_brut/...recu2026-09-17.csv` + `00_doc/empreintes.txt` ; dictionnaire : `00_doc/dictionnaire.md` (neuf lignes utiles) ; journal : `90_journal/journal_transformation.txt` ; travail : `03_analyse/2026-09-17_nettoyage_M5_v1.xlsx` ; livrable : `04_livrables/2026-09-17_note_CA_M5_minani.pdf` avec sa note de périmètre en page 1 ; archive : `99_archive/2025_close/` avec manifeste, plus la politique de conservation en `00_doc/`.

Exercice 6.2. 489 vs 480 → transformation, réponse dans le journal (9 doublons d'export) ; unité TTC → dictionnaire, ligne `montant_ttc` (TVA 18 %, arrondi à l'entier) ; décembre → usage + transformation, réponse par le tableau mensuel et le test de robustesse (voir M02) ; comptoir → naissance, réponse dans le dictionnaire (0 = comptoir, à ne pas effacer). Quatre questions, quatre artefacts : c'est le mécanisme à intégrer, pas les réponses.

Exercice 6.3. Test discriminant, dans l'ordre de coût : (a) comparer les **nombre de lignes** des deux classeurs → si 480 vs 489, c'est un dédoublement, pas une régularisation ; (b) filtrer les lignes à `quantite` négative dans chacun → les retours ; (c) lire `notes.txt` à la recherche d'une mention de régularisation et de sa date. Un écart de 1,8 % sur un total de plusieurs dizaines de millions de FCFA se compte en centaines de milliers : soit l'équivalent d'un mois de l'extrait, soit un ensemble de retours. La taille de l'écart **oriente** la recherche — c'est le réflexe à noter.

Exercice 6.4. Phrase honnête : « Le total de **36 073 185 FCFA** est celui de l'extrait de travail (480 lignes utiles, 40 lignes retenues par mois, magasin 5, année 2025), après retrait de 9 doublons d'export ; il ne représente pas le CA du magasin sur l'année, qui suppose le fichier complet. » Nom de fichier : `2025_ventes_M5_extrait40parmois_brut.csv`. Un devoir qui écrit « le CA du magasin 5 » sans qualifier l'extrait a échoué, quel que soit le reste.

Exercice 6.5. Modèle recevable : (1) source = export quotidien de la caisse, déposé en `01_brut/`, jamais modifié, empreint et daté ; (2) chaque publication fige un jeu (`2025_close/`) avec dictionnaire, journal et manifeste ; (3) à 3 ans, purge des fichiers de travail et des extraits, agrégats mensuels conservés ; (4) à 10 ans, purge du détail des lignes, conservation des agrégats

gats, du dictionnaire et du registre de suppression ; (5) aucune copie de données clients hors du parc de l'entreprise, supports personnels interdits, échantillons de test pseudonymisés.

13. Mini-projet M01.P6 — « Dossier d'archivage d'une publication » (35 min)

Vous publiez le total nettoyé de l'atelier (36 073 185 FCFA, extrait 480 lignes, magasin 5, 2025). Constituez 99_archive/2025_close/ contenant :

1. les deux fichiers de données (brut daté, propre nommé ..._v1) ;
2. le dictionnaire (9 lignes minimum, colonne « défauts connus » renseignée avec les comptages réels) ;
3. le journal de transformation, 5 entrées minimum, chaque entrée avec entrée=n sortie=n écart ;
4. un manifeste d'une demi-page : contenu, empreintes, limites (« extrait de 40 lignes par mois, pas un CA annuel »), auteur, date, validation ;
5. un PDF ou une note d'une page avec la note de périmètre en tête.

Critères de réussite : un pair, qui n'a pas fait l'exercice, doit pouvoir **retrouver l'origine de chaque nombre cité** dans la note en moins de cinq minutes, et dire ce qui est archivé pour dix ans. Il écrit ses deux réponses ; toute réponse erronée annule le point de clarté. Barème : 6 pts reproductibilité · 4 pts exactitude des comptages (489/480/9/65/486/18/7) · 4 pts manifeste · 3 pts note de périmètre · 3 pts lisibilité de l'arborescence.

14. Résumé du chapitre

Six étapes, six responsabilités, six artefacts. La donnée naît dans un processus (et porte ses angles morts), se stocke (et peut être perdue là), se transforme (et doit laisser une trace chiffrée de chaque choix), sert (et c'est le seul endroit où elle a de la valeur), s'archive (avec son mode d'emploi, sinon rien) et se supprime (selon une politique écrite, pas selon l'humeur). Un chiffre défendable dans trois ans est le produit d'un cycle documenté, pas d'un tableur bien maîtrisé. Le dictionnaire, le journal et le manifeste sont les trois documents qui vous rendent crédible ; les deux premiers tiennent sur une page, et se tiennent à jour en une ligne par opération.

15. À retenir

À retenir. 1. **Six étapes** : naissance · stockage · transformation · usage · archivage · suppression — chacune a son responsable et sa preuve. 2. **Trois documents** suffisent à rendre un chiffre défendable : dictionnaire, journal de transformation, manifeste d'archivage. 3. **Un extrait n'est pas une population** : nommez-le, datez-le, annoncez sa taille. 4. **Le brut est intouchable** ; on le duplique, on ne le corrige pas. Empreinte + date = version. 5. **La documentation survit à la donnée** ; la minimisation et l'interdit de copie personnelle protègent davantage que n'importe quel logiciel de sécurité.

16. Évaluation formative (auto-correction, 10 min)

1. Un chiffre publié est contesté trois ans plus tard. Citez, dans l'ordre où vous les ouvrez, les trois documents à consulter. (note de périmètre du livrable → journal de transformation → dictionnaire ; puis le brut si un recomptage est nécessaire)
2. À quoi sert une empreinte (hash) de fichier, et que ne dit-elle pas ? (prouve l'identité binaire du contenu, donc l'absence de modification · ne dit rien de la justesse métier des valeurs)
3. Pourquoi archive-t-on le **code** et pas seulement le rapport ? (sans le code, le rapport n'est pas rejouable ; l'archivage sans transformation documentée est un stockage, pas une preuve)
4. Un fichier nommé `CA_2025_final_final(2).xlsx` : trois défauts de cycle, un par mot. (« final » = absence de versionnage réel · « (2) » = écrasement implicite · pas de date = impossible de dater l'état ; le quatrième défaut, gratuit : on ne sait pas qui l'a produit ni à quelle source il correspond)
5. **Question ouverte** : on vous demande d'envoyer par e-mail la table clients complète pour « vérifier les téléphones ». Répondez en quatre phrases, en distinguant l'objet, le risque et la solution de rechange. (la question réelle est « les numéros sont-ils valides » → un échantillon pseudonymisé de 200 lignes ou un contrôle automatique (longueur, format, doublons) répond sans exposer 23 500 clients ; l'envoi d'une table nominative par messagerie est un incident potentiel ; je propose le contrôle chiffré, avec le nombre de numéros invalides, et je garde la preuve dans le journal)

M01.C07 — Les métiers de la donnée, la chaîne de valeur, et l'anatomie d'une analyse

Outil de ce chapitre : traitement de texte ou tableur pour la rédaction ; aucun logiciel de données. **Durée indicative :** 5 h. **Niveau :** N1.

L'idée du chapitre. Vous allez apprendre quatre outils (tableur, SQL, Python, Power BI). Ce n'est pas le classement qui compte dans un emploi, ni dans une mission. Ce qui compte, c'est de savoir **à quel moment de la chaîne** vous intervenez, **quelle question** vous traitez, et **quelle preuve** vous laissez. Ce chapitre ferme le socle : il nomme les métiers, montre la chaîne de valeur, démonte une analyse en six temps, et répond à la question que tout débutant pose trop tard — quel outil, pour quoi, et pourquoi celui-là.

1. Objectifs du chapitre

À la fin de ce chapitre, vous saurez :

1. **Distinguer** les cinq métiers voisins (data engineer, data analyst, BI analyst, data scientist, responsable de la donnée) et décrire ce que chacun **livre**, pas ce qu'il « connaît » ;
2. **Situer** une mission dans la chaîne de valeur et identifier les deux maillons manquants quand un projet bloque ;
3. **Décomposer** une analyse en six temps (cadrage · données · préparation · mesure · interprétation · décision) et estimer le temps de chacun ;
4. **Écrire** une question analytique correcte à partir d'une demande floue, en respectant les cinq composants vus en M01.C02 ;
5. **Choisir** un outil pour une situation donnée et **justifier** le choix par trois critères : volume, relecteur, jouabilité ;
6. **Rédiger** la note d'une page qui fait passer d'un chiffre à une décision — l'exercice le plus noté de tout le parcours.

2. Pourquoi cette notion est importante

Situation 1 — le profil mal employé. Une PME recrute un « data scientist », lui donne un fichier de caisse et demande un prévisionnel de ventes. Le recrutement était trop cher, la donnée trop sale, la demande trop vague. La bonne embauche, ou la bonne mission, était un analyste capable de préparer les données trois semaines et de produire un tableau mensuel lisible. Connaître les métiers évite les erreurs de dimension — chez le client comme chez vous.

Situation 2 — l'analyse sans fin. Un projet traîne six semaines : personne n'a écrit ce que « succès » voulait dire. Le cadrage absent se paie en réunions. Les six temps de l'analyse existent pour être **chronométrés** : un cadrage d'une heure en sauve dix.

Situation 3 — l'outil mal choisi. Un rapport mensuel de 216 lignes est construit dans un outil de BI avec un modèle sémantique, des actualisations planifiées et six pages de documentation. Coût : trois jours. Un tableau dans un classeur, validé et verrouillé : quarante minutes, même résultat, moins de maintenance. À l'inverse, un fichier de 243 360 lignes retapé à la main dans un

tableur chaque semaine, c'est un accident programmé. Le bon outil est celui qui rend le service **au moindre coût de maintenance**, pas le plus impressionnant.

Dans les faits. Les offres d'emploi francophones « data analyst » demandent en majorité SQL et un outil de visualisation, avec le tableur en compétence implicite et Python comme différenciant ; les offres « BI » ajoutent le modèle sémantique et la gouvernance. À l'inverse, dans les PME sans service informatique, c'est le tableur et la qualité des fichiers qui font la différence — et c'est précisément ce que les modules 3 à 6 vous font travailler. La chaîne de valeur, elle, est la même partout ; ce qui change, c'est le nombre de personnes par maillon.


3. Explication simple

Imaginez une chaîne de montage de la décision :

1. **le data engineer** construit le convoyeur : il fait arriver la donnée, propre au sens technique, à l'heure, à la bonne taille ;
2. **l'analyste** prend une pièce, la mesure, dit ce qu'il constate et ce que ça veut dire ;
3. **le BI analyst** installe les instruments de mesure au mur : les tableaux que tout le monde regarde, avec des règles communes ;
4. **le data scientist** fabrique un dispositif qui anticipe la pièce suivante, avec un risque chiffré ;
5. **le décideur** tranche, engage de l'argent ou des gens.

Votre parcours vous rend **analyste** en priorité, **BI** à partir du module 13, capable de parler **data engineering** au module 24, et instruit en science des données aux modules 19 à 21. Ce n'est pas un empilement de casquettes : c'est la capacité à comprendre le voisin, ce qui est, en entreprise, la première cause de promotion.

Qui fait quoi, et les cinq questions à écrire avant de toucher un fichier



1. **Décision visée** — qu'est-ce qui changera selon la réponse ?
2. **Question analytique** — une phrase : unité (FCFA TTC), période (2025), périmètre (magasin 5), comparaison.
3. **Donnée nécessaire** — la table, le grain, la colonne, le fichier exact.
4. **Critère de réussite** — le chiffre attendu, la tolérance, qui valide, avant de calculer.
5. **Limites** — ce que le résultat ne dira pas : ici, pas de marge nette (aucun coût de structure dans le jeu).

Figure 7 — La chaîne de valeur, et le formulaire de cadrage resservi dans les 22 modules.

4. Vocabulaire essentiel

Français — English	Définition simple	Piège à éviter
Data engineer ingénieur données	— Conçoit et exploite les flux, les bases, la qualité en amont.	Le confondre avec l'administrateur de base de données ; les deux se recouvrent parfois, les objectifs diffèrent.
Data analyst	Répond à des questions précises sur des données existantes, mesure, explique.	Se limiter à produire des visuels : sans interprétation ni décision, ce n'est pas de l'analyse.

Français — English	Définition simple	Piège à éviter
BI analyst — analyste décisionnel	Construit le modèle de données et les rapports durables, définit les indicateurs communs.	Construire un joli tableau sans gouvernance (qui le valide ? à quelle fréquence ?).
Data scientist — des données	Modélise, prédit, expérimente sur ce qui n'est pas encore observé.	Prédire sur un historique non nettoyé : le modèle hérite des défauts.
Responsable de la donnée — data steward	Garantit le sens, la qualité, la conformité des données et du dictionnaire.	Le voir comme un poste technique : c'est d'abord un rôle métier.
Chaîne de valeur — value chain	Suite d'étapes qui ajoutent chacune quelque chose de vérifiable.	Croire que la valeur est à la fin : elle est à chaque maillon, et le premier fragile casse tout.
Cadrage — scoping	Accord écrit sur la question, le périmètre, le délai, le critère de réussite.	Le faire oralement : un accord oral n'existe pas à la deuxième contestation.
Livrable — deliverable	Objet remis, nommé, daté, avec un destinataire.	Confondre livrable et activité : « j'ai fait des analyses » n'est pas un livrable.
Rejouabilité — reproducibility	— Capacité à refaire le même résultat plus tard, avec les mêmes entrées.	Un résultat obtenu par cinq clics non documentés n'est pas rejouable.
Modèle sémantique — semantic model	— Couche qui définit une fois pour toutes les mesures et les relations (Power BI, M13).	Recalculer la même mesure dans chaque rapport : quatre définitions, quatre chiffres.
Donnée de référence — master data	Référentiels partagés : clients, produits, magasins, calendriers.	Laisser chaque service sa version du référentiel.
Métier — business / functional owner	La personne qui répond aux questions de sens (« un retour, ça compte dans le CA ? »).	Trancher seul ces questions : c'est précisément le rôle du métier.

5. Cours approfondi

5.1 Les cinq métiers, vus par ce qu'ils livrent

Métier	Question typique	Livrables	Outils usuels	Échec typique si mal fait
Data engineer	« comment la donnée arrive-t-elle à l'heure, complète, non dupliquée ? »	flux planifiés, contrôles de qualité automatisés, documentation des schémas	SQL, Python, DuckDB, orchestrateurs, bases	des rapports justes... sur des données de la semaine dernière
Data analyst	« que disent les données sur cette question précise ? »	note d'une page, tableau de bord ponctuel, requêtes, fichiers propres, journal	tableur, SQL, Python	des chiffres vrais mais inutiles, ou des conclusions hors périmètre
BI analyst	« comment faire que tout le monde voie le même chiffre, tous les lundis ? »	modèle sémantique, mesures documentées, rapports publiés, gouvernance des accès	Power BI, DAX, SQL, sécurité par niveau de ligne	deux directions avec deux totaux du même indicateur
Data scientist	« que peut-on anticiper, et avec quel risque ? »	modèles, validations, bornes d'incertitude, note de limites	Python/R, statistiques, jeux d'entraînement	un modèle brillant, inexplicable, non utilisé
Responsable de la donnée	« que veut dire ce champ, qui le déclare, combien de temps on le garde ? »	dictionnaire, règles de qualité, politique de conservation	tableur, MDM, gouvernance	référentiels divergents, chacun « sa » version du client

Trois lectures utiles :


- les frontières sont **porositaires** : dans une PME, une seule personne occupe trois cases, ce qui est exactement pourquoi ce manuel enseigne la chaîne complète ;
- les **compétences transverses** qui augmentent un salaire ne sont pas des outils : écrire clairement, poser une question, documenter ;
- **le décideur n'est pas un métier de la donnée**, c'est votre client. Apprendre à lui parler est une compétence du module 12, pas un bonus.

Définition. Chaîne de valeur — value chain — la suite d'étapes par lesquelles une donnée devient une décision qui rapporte ou qui épargne. Elle sert d'outil de diagnostic : quand un projet échoue, on situe l'étape cassée, et l'on constate que la casse est plus souvent en amont — collecte, sens, périmètre — qu'en aval, dans les calculs.

Attention. Confondre les métiers produit deux échecs lents : demander à un analyste de réparer l'alimentation du fichier, ou à un ingénieur de trancher si un retour client compte dans le chiffre d'affaires. La bonne question n'est pas « qui est le plus compétent » mais « qui est responsable de ce maillon, et qui valide le sens ».

5.2 La chaîne de valeur, et où l'on gagne réellement de l'argent

La valeur ne croît pas linéairement le long de la chaîne : elle croît aux deux bouts.



Le premier bout — rendre la donnée correcte — est le moins visible et le plus rentable : un fichier bien typé fait gagner trois semaines en aval (modules 3 à 8). Le second bout — rendre le résultat compréhensible — est le plus rentable en carrière : un décideur qui comprend en une minute décide, et revient vous demander une deuxième question. Le milieu (jolis graphiques, tableaux intermédiaires) est ce que l'on vous demandera de faire ; c'est ce que l'on oubliera le plus vite. Cette asymétrie explique le calibrage du parcours : huit modules sur neuf parlent de la préparation et de la mesure, un seul de la présentation pure (M18) — et il est décisif, parce qu'il transforme le travail en décision.

Définition. Cadrage — scoping — l'accord écrit sur la question, le périmètre, le délai et le critère de réussite. Six lignes suffisent, et il n'est pas négociable : un cadrage oral se réécrit dans la tête de chaque participant, et l'écart réapparaît à la livraison, au pire moment, devant le commanditaire.

5.3 L'anatomie d'une analyse : six temps, avec leurs durées

Temps	Ce qu'on produit	Durée raisonnable (petit sujet)	Signe que c'est fini
1. Cadrage	la question analytique + critère de réussite + destinataire	10 % du temps	le demandeur a validé par écrit la question et le délai
2. Repérage des données	inventaire des fichiers, dictionnaire, accès	10 %	vous savez ce qui manque et vous l'avez dit
3. Préparation	fichier propre, types, clés, contrôles	40 %	le total de contrôle tombe, le journal est écrit

Temps	Ce qu'on produit	Durée raisonnable (petit sujet)	Signe que c'est fini
4. Mesure	agrégats, comparaisons	statistiques, 20 %	les chiffres sont stables sous un changement de méthode raisonnable
5. Interprétation	ce que ça veut dire, ce que ça ne dit pas	10 %	un non-spécialiste comprend la phrase sans voir le tableau
6. Décision suivie	recommandation, échéance, indicateur	acteur, 10 %	une ligne dans l'agenda de quelqu'un d'autre que vous

Répartissez mentalement vos travaux passés sur ces six lignes : si 90 % du temps est allé au temps 4 (produire des chiffres) et rien au temps 1, vous avez reproduit l'erreur du plus grand nombre, y compris parmi les titulaires d'un master. Le temps 3 à 40 % n'est pas un échec, c'est le signe que le travail est sérieux — à condition de l'**annoncer** au commanditaire (« la préparation prend la moitié du délai, parce que ... »), sinon on vous croira lentement.

Définition. Livrable — deliverable — un objet remis, nommé, daté, avec un destinataire identifié. Le mot contient le verbe « remettre » : une activité non livrée n'existe pas pour l'entreprise, même si elle a été difficile.

5.4 Passer d'une demande floue à une question correcte : l'algorithme complet

C'est la compétence évaluée de ce chapitre. Formalisons-la en six questions, dans cet ordre :

1. **Qui lit, et pour quoi faire ?** — destinataire + décision. Sans réponse : on ne commence pas.
2. **Quelle est la phrase du demandeur, mot à mot ?** — relever chaque mot non mesurable (« bien », « trop », « récemment », « la plupart »).
3. **Que veut-il vérifier ou arbitrer ?** — la décision réelle, souvent différente de la formulation.
4. **Quelle unité, quelle période, quel périmètre ?** — FCFA HT ou TTC, retours inclus ou non, magasins concernés, année pleine ou partielle, clients hors comptoir.
5. **Quelle comparaison, quelle règle ?** — objectif, N-1, médiane, classement. Sans comparaison, pas de connaissance (M01.C02).
6. **Qu'est-ce qui prouvera que j'ai réussi ?** — valeur attendue, tolérance, nom du valideur, date.

Un cas complet, avec le fil rouge. **Demande** : « on perd des clients, regarde ça ».

- Qui lit ? Le directeur commercial, pour arbitrer un budget de fidélisation avant le 15/11.
- Mots non mesurables : « perd », « ça ».
- Décision réelle : faut-il financer une relance, et sur qui ?
- Unité / période / périmètre : un client est « perdu » s'il n'a **aucun** achat entre deux dates ; on regardera 2025 et 2026 partiels, tous magasins sauf dépôt ; client identifié uniquement (le comptoir, `id_client = 0`, est hors jeu : on ne peut pas dire qu'un client non identifié est parti).
- Comparaison : taux de perte par type de client en 2025 vs la même règle en 2024.
- Critère de réussite : le nombre de clients « actifs en N, absents en N+1 » doit être recalculable par une requête de dix lignes, et le total de contrôle doit redonner le nombre de clients distincts connus (372 sur l'extrait de l'atelier).

Question finale : « Entre 2024 et 2025, combien de clients identifiés ayant acheté au moins une fois en 2024 n'ont rien acheté entre le 01/07/2025 et le 31/12/2025, tous magasins sauf le dépôt, et ce taux varie-t-il selon `type_client` ? »

Notez le gain : la question initiale était un motif d'alarme ; la question finale est un **chiffre**, avec ses limites écrites (exclusion du comptoir, 18 lignes sans identifiant dans l'extrait, 1 880 villes manquantes dans `clients`). Cinq minutes d'écriture, et le travail devient possible.

À retenir. Une question analytique correcte est une question **réfutable** : deux analystes qui la traitent indépendamment doivent obtenir le même chiffre. Testez toujours par là.

5.5 Quel outil choisir, et pourquoi : la grille définitive du socle

Quatre questions dans l'ordre, puis l'outil en découle. Nous les reprendrons en M08.C01 et M13.C01, mais décidez-les maintenant, sinon vous choisirez par goût.

Q1. Quelle taille, et où est la donnée ?

Situation	Outil par défaut	Motif
moins de 50 000 lignes, un fichier	tableur (Excel ou LibreOffice)	ce que tout le monde peut ouvrir ; zéro dépendance
50 000 à 5 millions de lignes, un fichier	DuckDB ou Python/pandas	requêtes sur fichiers plats sans serveur ; le CSV devient interrogeable
la donnée est dans une base de l'entreprise	SQL	on calcule sur place, on ne déplace pas ; la requête est la preuve
plus de 10 millions, ou plusieurs sources à assembler	SQL + étape de préparation (Python ou M24)	le tableur sature, le modèle se construit ailleurs
JSON, logs, fichiers irréguliers	Python	seul endroit où l'on écrit la règle de parsing une fois pour toutes

Q2. Qui relit, et comment ?

Relecteur	Outil
une personne non technique, une fois	tableur + note, ou PDF
une direction, chaque lundi	Power BI (ou rapport paginé si l'impression est obligatoire — M19)
une équipe technique qui doit rejouer	script + requêtes versionnées
un auditeur, dans deux ans	tout ce qui laisse un journal : requête SQL ou script, jamais une session de clics

Q3. À quelle fréquence l'opération se répète-t-elle ? Une fois → le plus rapide à écrire (tableur). Chaque mois → le plus rapide à **exécuter** (script ou requête). Chaque jour avec plusieurs utilisateurs → BI avec actualisation planifiée.

Q4. Quel risque financier, et donc quel niveau de preuve ? Un chiffre publié → définition écrite + contrôle de totaux + version figée. Un chiffre interne approximatif → le tableur suffit, en le disant.

Tableau de synthèse des quatre outils du parcours, tel qu'il doit être retenu à la fin du module :

Outil	Force	Limite	Ne l'utilisez pas pour
Tableur (Excel, LibreOffice)	immédiat, vérifiable par cellule, universel	cellule le schéma se dégrade, l'auditabilité est faible, ça sature vite	un traitement répété sur de gros volumes
SQL	demande déclarative (« je veux quoi », pas « comment »), calcule sur place, réutilisable	ne nettoie pas bien les fichiers sales, ne fait pas de jolis rapports	un fichier de 400 lignes à trier une fois

Outil	Force	Limite	Ne l'utilisez pas pour
Python (pandas)	maîtrise totale de la transformation, rejouable, bibliothèque statistique	il faut écrire et maintenir du code ; le relecteur doit savoir lire du code	un besoin de validation visuelle immédiate par un non-technicien
Power BI	modèle sémantique partagé, DAX, actualisation, distribution, sécurité par niveau de ligne	courbe d'apprentissage du modèle, licence payante pour le partage (Power BI Pro : 14 \$/utilisateur/mois — lecture possible gratuitement sur capacité Fabric F64+)	un fichier à corriger : on ne nettoie pas dans le rapport, on nettoie en amont

Deux alternatives à connaître, pour répondre honnêtement quand un client les mentionne : **Looker Studio** (gratuit, lié à l'écosystème Google, mais sans sécurité par niveau de ligne native ; l'offre payante ≈ 9 \$/utilisateur/mois) et **Tableau** (redoutable en visualisation ; Tableau Public est gratuit mais **public**, et « Desktop » nécessite une licence — une version gratuite d'usage local a été annoncée en 2026, à vérifier au moment de la décision). En contexte libre et hébergé : **Metabase** et **Superset**. Le module 19 compare ces outils avec les critères de ce tableau ; ici, retenez une seule chose : **le choix d'outil ne précède jamais la question analytique**.

Conseil professionnel. Quand on vous demande « tu fais ça sur quoi ? », répondez par la contrainte, pas par l'outil : « la donnée arrive en CSV irréguliers de 200 000 lignes, et la direction relit chaque lundi, donc préparation en Python et restitution dans Power BI ». En trois secondes, vous venez de justifier votre choix devant un non-technicien et devant un pair — et personne ne vous demandera plus jamais « pourquoi pas Excel ? ».

Définition. Modèle sémantique — semantic model — la couche d'un outil de décision où les mesures et les relations sont définies une fois pour toutes. Sans lui, chaque utilisateur recalcule le chiffre à sa façon : l'outil censé unifier le vocabulaire devient une machine à produire des désaccords, proprement présentés.

Attention. Vérifier « à la main » le chiffre d'un tableau de bord en le recalculant dans un tableur crée une deuxième vérité, et souvent un arbitrage impossible trois mois plus tard. On vérifie une fois, en écrivant le contrôle, la date et l'écart constaté dans le journal ; ensuite on corrige la source, pas la note.

5.6 Anatomie d'une note de résultat : le format qui fait décider

Six rubriques, une page. Vous l'avez découverte en M01.C02, la voici normative, parce qu'elle sert jusqu'à la soutenance (M22) :

- | | |
|---------------------------|---|
| 1. DÉCISION VISÉE | 2 lignes : qui décide quoi, avant quelle date. |
| 2. QUESTION TRAITÉE | 2 lignes : la phrase complète, avec unité, période, périmètre. |
| 3. RÉPONSE | 3 lignes + un tableau : le chiffre en gras, la comparaison, le sens. |
| 4. MÉTHODE | 4 lignes : source (fichier, version), règle de calcul, périmètre, exclusions. |
| 5. CE QUE CELA NE DIT PAS | 3 lignes : limites, incertitudes, ce qu'il manque. |
| 6. RECOMMANDATION | 2 lignes : acte, responsable, échéance, indicateur de suivi. |

Règles d'écriture, non négociables dans ce manuel : chiffre **avec unité** à chaque fois ; pas d'acronyme non défini ; un seul adjectif par note maximum ; le tableau de la rubrique 3 doit tenir sur un tiers de page ; la rubrique 5 ne se saute jamais, même (surtout même) quand elle affaiblit le résultat. Une note sans rubrique 5 est, techniquement, un document invérifiable ; nous l'avons vu, c'est le seul défaut qui coûte un poste dans les grands scandales de chiffres.

Définition. Rejouabilité — reproducibility — pouvoir refaire le même résultat plus tard, avec les mêmes entrées, sans avoir à s'en souvenir. Elle se mérite : entrées identifiées, transformations notées dans l'ordre, aucune retouche manuelle silencieuse. C'est ce qui distingue une chaîne de traitement d'un coup de main chanceux.

Boîte à outils. Le minimum de la chaîne d'analyse, et à quoi chacun sert : l'**Explorateur de fichiers** pour retrouver et dater · un **éditeur de texte** pour lire un fichier sans laisser un tableur le re-taper · le **tableur** jusqu'à quelques dizaines de milliers de lignes, pour un chiffre à défendre · **DuckDB** (gratuit, un fichier, aucun serveur) pour compter et joindre sur des fichiers plus gros que la mémoire n'aime le faire · **Power BI Desktop** (gratuit pour créer, payant pour partager) quand le même besoin revient chaque semaine et doit être consulté par d'autres. Un outil de plus = une raison de plus de le justifier dans la note.

6. Exemple concret : le cas complet, de la demande à la note

Contexte. 12 octobre 2026. Le DG de Sahel Distribution croise un commercial : « depuis la hausse des prix en février, les vendeurs ne vendent plus rien, ils tournent en rond ». Il vous écrit : « regarde les ventes de Bationo ».

Temps 1 — Cadrage (25 min, dont 10 avec l'intéressé). Trois questions au DG : sur quoi vous basez « ne vendent plus rien » (le ressenti d'un commercial, le classement, la comparaison à l'année dernière ?) ; quelle décision (accompagner, recadrer, sanctionner, réallouer le secteur) ; qui relit. Réponse obtenue : « je veux savoir si je dois le faire accompagner ou lui retirer le secteur BTP ». Cette phrase change tout : nous ne mesurons plus « les ventes », nous mesurons **une performance commerciale imputable à la personne**.

Temps 2 — Repérage (30 min). Sources : `ventes_propres.csv` (240 000 lignes), `vendeurs.csv` (22), `magasins.csv` (6), `objectifs_de_ca.csv` (218, avec deux mois manquants — annoncé). Limites trouvées : les objectifs ne sont pas mensuels pour tous les mois ; la table `clients` n'a pas de date de départ de relation ; aucune donnée sur les prix « avant/après février » hormis les montants de vente.

Temps 3 — Préparation (2 h). Filtre : `id_vendeur = 9` (Adama Bationo, magasin 5). Grain : article. Agrégation : par mois et par catégorie, CA TTC, nombre de tickets distincts, quantité. Contrôles : le total du périmètre doit redonner, sur l'extrait de l'atelier, **11 370 350 FCFA** ; le nombre de tickets distincts doit être cohérent avec le total des quatre vendeurs de l'extrait ($11\,370\,350 + 9\,423\,281 + 8\,483\,019 + 6\,796\,535 = 36\,073\,185$ FCFA ✓ égal au total de l'extrait). Écriture du journal.

Temps 4 — Mesure (45 min). Classement des quatre vendeurs de l'extrait 2025 : Bationo 11 370 350 · Sankara 9 423 281 · Ouédraogo 8 483 019 · Ilboudo 6 796 535 FCFA. Bationo est **premier**, et détient 31,5 % du CA de l'échantillon. Comparaison mois par mois impossible sur cet extrait sans le file d'attente d'un extrait comparable pour les autres vendeurs — noté comme limite (l'extrait est de 40 lignes par mois, pas une année complète).

Temps 5 — Interprétation (20 min). Ce que les données disent : dans l'extrait de 480 lignes, le vendeur mis en cause est le premier en CA. Ce qu'elles ne disent pas : l'évolution février-septembre, l'effet prix, la comparaison aux objectifs mensuels (2 mois manquants), ni la satisfaction client. L'hypothèse du DG (« il ne vend plus ») n'est pas compatible avec le seul chiffre disponible ; mais l'extrait ne prouve rien sur la période citée.

Temps 6 — Décision (la note, dix lignes). Recommandation : ne pas statuer sur le secteur BTP avant d'avoir le fichier annuel complet du vendeur et les objectifs mensuels manquants ; prévoir un point de 30 min avec le directeur commercial le 26/10 sur la base du CA mensuel par

vendeur 2025-2026, retours inclus, et décider ensuite d'un accompagnement. Indicateur de suivi : CA mensuel par vendeur et nombre de tickets, écart à l'objectif.

Leçons à écrire noir sur blanc dans votre cahier. Un cadrage de 25 minutes a transformé « regarde les ventes de Bationo » en une décision conditionnée à deux données manquantes. La mauvaise exécution du même sujet (filtrer, faire un graphique, conclure « il vend très bien ») aurait produit une affirmation fausse fondée sur un échantillon, dans un dossier RH. La donnée n'a pas menti : c'est l'absence de cadrage qui aurait fait mentir l'analyste.

7. Démonstration pas à pas : le formulaire de cadrage, rempli en 18 minutes

Le formulaire ci-dessous est utilisé dans **tous** les projets du manuel, du module 1 au module 22. Apprenez-le par cœur : en stage comme en mission, c'est le document qui fait la différence entre « celui qui sait faire des tableaux » et « celui à qui on confie un sujet ».

Formulaire de cadrage — projet M01.P

0. Date · auteur · destinataire	2026-09-17 · a.minani · direction commerciale
1. Demande reçue (verbatim)	« on donne trop de remises, tu regardes ? »
2. Décision que la réponse doit éclairer	resserrer la grille de remise avant le
01/12/2026	
3. Mots non mesurables relevés	« trop », « regardes »
4. Question analytique (5 composants)	voir ci-dessous
5. Données nécessaires (tables, fichiers, accès)	ventes, clients, remises_manuelles, produits
6. Données manquantes (annoncées au cadrage)	motifs de remise non codés sur 2026, objectifs 2
mois manquants	
7. Critère de réussite	total TTC de l'extrait = 36 073 185 FCFA ;
clients distincts = 372	
8. Comparaison retenue	remise moyenne par type de client, 2025 vs 2024
9. Périmètre	magasin 5 ; retours inclus ; id_client = 0
exclu de la partie « par client »	
10. Limites et risques d'erreur	18 lignes sans client ; extraits ≠ population ;
pas de coût de structure	
11. Outil choisi + motif	tableur pour la préparation (480 lignes) ; note
écrite en 1 page	
12. Livrables et délai	fichier propre + journal + note, rendu le 19/09
avant 17 h	
13. Validation	nom du valideur, date

La ligne 4, développée : « En 2025, au magasin 5, la remise moyenne et la part de tickets à remise > 5 % varient-elles selon le type de client, et un plafond de remise à 5 % aurait-il réduit le CA TTC de plus de 1 % pour les vingt clients les plus remisés ? »

Le remplissage, en méthode. Les lignes 1 à 3 s'écrivent **avec** le demandeur (en face, ou par écrit, pas de mémoire). Les lignes 5 et 6 s'écrivent **après avoir ouvert le dossier de données** : ne jurez jamais qu'une donnée existe avant d'avoir vu ses colonnes. La ligne 7 est négociée : c'est votre bouée, elle prouve votre travail. Les lignes 10 à 13 s'écrivent seules, puis se relisent à voix haute : si une phrase ne se comprend pas sans le contexte de votre tête, elle est à réécrire.

Auto-évaluation du formulaire, en six points : toute ligne remplie (1) ; aucune ligne 3 non résolue sans trace (2) ; la ligne 4 est réfutable par deux personnes (3) ; la ligne 5 cite des fichiers existants (4) ; la ligne 7 contient un nombre attendu (5) ; la ligne 10 est lue par le demandeur (6). Cinq sur six est un bon cadrage ; trois ou moins, on recommence, car la suite est perdue.

8. Erreurs fréquentes

Symptôme	Cause	Correction
Le livrable est livré, la décision ne vient pas	Le destinataire n'a pas été nommé au cadrage	Rubriques 0 et 2 obligatoires ; demander au demandeur de valider la question par écrit
Le rapport est bon, mais personne ne le comprend	La note commence par la méthode	Ordre imposé : décision, question, réponse — la méthode va en rubrique 4
« 12 % de plus » sans comparaison	Chiffre non situé	Toujours préciser : par rapport à quoi, sur quelle période, dans quelle unité
Le résultat change quand on repose la question	Question ambiguë non négociée	Rejouer le contrôle du §5.4 : deux traitements indépendants doivent converger
L'analyse « n'en finit pas »	Critère de réussite absent	Rubrique 7 ; une date de rendu ; le surplus d'analyse se fait après la décision
Conclusions fortes sur échantillon	Extrait pris pour la population	Écrire la nature de l'extrait dans la note (nom + taille + période)
Le métier refuse le chiffre	Définition divergente (retours, HT/TTC)	Rubrique 9 négociée avec le responsable métier, pas supposée

9. Bonnes pratiques professionnelles

- [] Le formulaire de cadrage est rempli **avant** d'ouvrir le fichier, et validé par écrit.
- [] Un livrable = un nom de fichier daté + une note d'une page.
- [] Les données manquantes sont annoncées au début, pas en fin de travail.
- [] Le choix d'outil se justifie par trois critères : volume, relecteur, jouabilité.
- [] Une limite écrite affaiblit le chiffre et renforce l'analyse.
- [] On ne conclut pas sur un extrait sans le dire, jamais.
- [] Une recommandation sans responsable ni échéance n'est pas une recommandation.
- [] Le temps de préparation (40 %) est annoncé comme tel au commanditaire.
- [] Après chaque projet, une ligne : « la décision a-t-elle été prise ? »

10. Exercice guidé — trois demandes, trois cadrages

Nous en menons un, les deux autres vont avec vous.

Demande A : « fais-moi un tableau de bord — dashboard, dans le jargon : une page d'indicateurs que l'on consulte sans ouvrir les fichiers — des ventes ».

- Rubrique 2 (décision visée) : **inconnue**. On demande un objet, pas une décision. Question à poser : « quand vous le regardez, que savez-vous que vous ne saviez pas, et qu'est-ce que vous changez ? ».
- Réponse professionnelle type : « je peux le faire, mais un tableau de bord sans décision associée ne sera pas ouvert après deux semaines. Donnez-moi la décision, je vous dis quels indicateurs la servent — peut-être trois chiffres dans un e-mail. »
- Cadrage obtenu (exemple) : décision = arbitrer les réapprovisionnements hebdomadaires du magasin 5. Trois indicateurs suffisent : CA par catégorie sur 4 semaines glissantes, rupture estimée (stock théorique vs physique, `stocks_quotidiens`), taux de remise.

Demande B (avec vous) : « pourquoi la marge baisse ? ».

- Rubrique 3 (mots non mesurables) : « baisse » (depuis quand, de combien ?).

- Rubrique 4, question possible : « entre 2023 et 2025, la marge brute par catégorie a-t-elle baissé, et cet écart s'explique-t-il par le prix moyen HT, par le taux de remise moyen, ou par le mélange des catégories ? ».
- Rubrique 5 : `ventes` + `couts_achat` (1 694 lignes, prix d'achat par période — donc la marge est calculable). Rubrique 6 : aucun coût de structure dans le jeu → **la marge nette n'est pas calculable**, à écrire dans la note dès le début. Rubrique 8 : comparaison par catégorie, 2023 vs 2025 (2026 partiel : exclu de la comparaison annuelle, ou ramené à une base mensuelle, et on le dit).
- C'est le fil rouge du parcours : ce qui était posé comme « problème de prix » se révélera problème de **mélange** et de **ruptures**. Vous le démontrerez en M13-M16 ; ici, vous apprenez à écrire le cadrage qui le rend démontrable.

Demande C (vous) : « est-ce qu'on a une bonne saisonnalité ? ». Rubriques à remplir seules : 2, 3, 4, 6, 7, 10. Contrôles : votre question doit contenir une période et une unité ; « bonne » doit disparaître ; la rubrique 10 doit mentionner que 2026 est partiel (janvier à août) et que l'extrait de l'atelier contient 40 lignes par mois. Corrigez indicatif au §12.

11. Exercices autonomes

Exercice 7.1 (★) — Métiers. Quatre phrases d'annonces d'emploi, classer dans les cinq métiers : « construire les flux d'ingestion et la qualité en base » · « produire les analyses mensuelles et les recommandations commerciales » · « définir les mesures du modèle sémantique et publier les rapports » · « estimer la demande à 12 semaines avec un intervalle de confiance ». (data engineer · data analyst · BI analyst · data scientist ; justifiez par le livrable, pas par l'outil)

Exercice 7.2 (★) — Six temps. Un projet de 20 jours : répartissez les jours selon le tableau du §5.3 et justifiez deux écarts possibles. ($2 \cdot 2 \cdot 8 \cdot 4 \cdot 2 \cdot 2$; écarts : préparation 10 si le brut est très sale, mesure 3 si la demande est une seule agrégation)

Exercice 7.3 (★★) — Cadrage complet. Appliquez le formulaire du §7 à la demande « est-ce que le dépôt central sert à quelque chose ? » (attendu : décision visée = maintenir ou non le dépôt ; mots non mesurables = « sert » ; périmètre = flux du dépôt, `id_magasin = 6`, sans ventes au comptoir ; limites = pas de coûts de structure, pas de date de création du dépôt avant 2023... ; un critère de réussite chiffré)

Exercice 7.4 (★★) — Choix d'outil. Cinq situations, justifiez en une phrase par situation : (i) 6 magasins × 36 mois, note mensuelle au DG ; (ii) 243 360 lignes à nettoyer chaque nuit ; (iii) vérifier un total unique ce matin ; (iv) 30 000 lignes de logs JSON à transformer en table ; (v) partager 4 indicateurs à 12 commerciaux, sans qu'ils puissent voir les données des autres. (i tableur ou Power BI selon la relecture ; ii Python ou SQL + tâche planifiée, le tableur est exclu ; iii tableur ; iv Python ; v Power BI avec sécurité par niveau de ligne — et une licence Pro par utilisateur qui publie, les lecteurs pouvant être gratuits selon la capacité, M13/M18)

Exercice 7.5 (★★) — Piège d'échantillon. Sur l'extrait de l'atelier, Bationo est premier avec 11 370 350 FCFA (31,5 % de l'extrait). Rédigez la phrase qui rend ce classement honnête, et la manipulations à faire sur le fichier complet pour conclure. (attendu : préciser extrait de 480 lignes (40/mois), magasin 5, 2025 ; recalculer sur `ventes_propres.csv` avec le même filtre vendeur et la même période, puis comparer aux quatre vendeurs du magasin et à l'ensemble des 22)

Exercice 7.6 (★★★) — La note. À partir des chiffres du §6, rédigez la note de six rubriques (10 lignes maximum), et faites-la relire par quelqu'un qui ne connaît pas le dossier : s'il ne peut pas répéter la décision recommandée, réécrivez la rubrique 3. (attendu : pas d'adjectif « bon/mauvais », unité FCFA partout, rubrique 5 obligatoire, recommandation avec date et responsable ; toute mention de « la marge nette » est une faute, elle n'est pas calculable)

12. Correction détaillée

Exercice 7.1. « Flux d’ingestion et qualité en base » → **data engineer** (livrable : des flux, pas une analyse). « Analyses mensuelles et recommandations » → **data analyst** (livrable : note récurrente et conseil). « Mesures du modèle sémantique et publication » → **BI analyst** (livrable : un modèle partagé et des rapports). « Estimation à 12 semaines avec intervalle de confiance » → **data scientist** (livrable : un modèle avec son incertitude). Un cinquième métier est sous-représenté dans les annonces mais existe : le **data steward**, qui livre le dictionnaire et les règles de qualité — vous le rencontrerez au module 21.

Exercice 7.2. 2 jours de cadrage (dont la validation écrite), 2 de repérage, 8 de préparation, 4 de mesure, 2 d’interprétation, 2 de restitution et suivi. Écart n° 1 : si les fichiers livrés sont au format du chapitre 4 (encodage, colonnes texte, chapeaux), la préparation passe à 10 jours — et il faut le dire **au cadrage**, sinon on vous reproche un retard qui est une qualité. Écart n° 2 : si la demande est une seule agrégation stable, la mesure tombe à 2 jours, mais l’interprétation monte à 3, parce que « un chiffre sans repère » doit être construit (objectifs, N-1) et non simplement calculé.

Exercice 7.3. Exemple de réponse complète : décision visée = arbitrer le maintien du dépôt à K... ou son externalisation, avant le budget 2027 · mot non mesurable = « sert » · question analytique = « en 2025, le dépôt (id_magasin 6) a-t-il couvert les magasins en délai et en quantité, et son activité évite-t-elle des ruptures — mesurées par les jours où le stock physique du magasin est inférieur au seuil dans `stocks_quotidiens` ? » · tables = `stocks_quotidiens` (60 000 lignes), `ventes`, `magasins` · manquantes = coûts d’exploitation du dépôt (absents du jeu : pas de coûts de structure) · critère de réussite = le nombre de jours de rupture par magasin doit se recouper avec la table de stocks pour 2025 à ± 1 jour · limites = la rupture est **observée** dans les écarts de stock, pas déclarée ; l’absence de coûts interdit de conclure sur la rentabilité, seulement sur le service · outil = tableur pour l’agrégation mensuelle, Power BI non justifié pour un usage unique. Le point de barème le plus souvent perdu : conclure sur la rentabilité avec un jeu qui ne contient pas de coûts.

Exercice 7.4. (i) **tableur** si la note est un document statique validé, **Power BI** si elle doit être consultée en libre-service ; le motif est le relecteur, pas le volume (216 lignes). (ii) **Python** (ou SQL si la base existe) : le traitement se rejoue chaque nuit, donc le code est le seul livrable soutenable. (iii) **tableur** : deux minutes, une vérification visuelle, une cellule de contrôle. (iv) **Python** : parsing de JSON, puis écriture d’une table plate documentée. (v) **Power BI**, à cause de la sécurité par niveau de ligne (RLS) : sans elle, il faudrait 12 fichiers ; le motif réel est la gouvernance des accès. Un devoir qui répond « Power BI, c’est plus moderne » n’a pas justifié, il a déclaré une préférence.

Exercice 7.5. Phrase honnête : « Sur l’extrait de 480 lignes utiles (magasin 5, 2025, 40 lignes retenues par mois), Adama Bationo arrive premier avec 11 370 350 FCFA, soit 31,5 % du total de l’extrait ; cet extrait ne couvre qu’une fraction des ventes réelles, donc ce classement est indicatif. » Manipulation : recalculer sur `ventes_propres.csv` (240 000 lignes) avec les mêmes filtres (année 2025, magasin 5, retours inclus), grouper par `id_vendeur`, compter aussi les tickets distincts et le CA par ticket, et **ne pas** comparer aux 22 vendeurs sans signaler qu’ils sont répartis sur 6 points de vente. Le test de robustesse : le classement change-t-il si l’on exclut les 7 lignes à quantité aberrante ? S’il change, ce n’est pas un classement, c’est un artefact de nettoyage.

Exercice 7.6. Modèle de note :

1. Décision visée : maintenir ou non le secteur BTP chez A. Bationo, arbitrage du 26/10.
2. Question : CA TTC et tickets, par vendeur, magasin 5, extrait 2025 de 480 lignes, retours inclus.
3. Réponse : sur l'extrait, A. Bationo est 1er avec 11 370 350 FCFA (31,5 % du total), devant
S. Sankara 9 423 281 · B. Ouédraogo 8 483 019 · M. Ilboudo 6 796 535 FCFA.
4. Méthode : 01_brut/...recu2026-09-17.csv → propre (480 lignes, 9 doublons retirés, montants convertis) ; total de contrôle 36 073 185 FCFA.
5. Ce que cela ne dit pas : extrait ≠ année complète ; aucun objectif mensuel pour tous les mois (2 manquants dans objectifs_de_ca.csv) ; pas de marge nette (coûts de structure absents).
6. Recommandation : ne pas statuer le 26/10 ; livrer le calcul 2025-2026 complet par vendeur avant, responsable direction commerciale, indicateur = CA mensuel et tickets par vendeur.

Barème : 3 pts unité et période explicites partout · 3 pts exactitude des quatre chiffres et du total de contrôle · 3 pts rubrique 5 complète (extrait + objectifs manquants + marge nette impossible) · 2 pts recommandation datée avec responsable · 2 pts lisibilité (10 lignes). Un devoir qui écrit « Bationo est un bon vendeur » perd les 3 points de la rubrique 3 : ce n'est plus un résultat, c'est une opinion.

13. Mini-projet M01.P7 — « Trois cadrages pour un même sujet » (50 min)

Sujet unique : « faut-il ouvrir un sixième magasin ? » Vous produisez trois cadrages différents du même sujet, chacun sur le formulaire du §7 :

1. pour le **directeur général** (arbitrer un investissement) ;
2. pour le **responsable des achats** (anticiper le stock d'ouverture) ;
3. pour un **banque/bailleur** (dossier de financement).

Contraintes : les trois questions analytiques doivent être distinctes, mais reposer sur les mêmes données disponibles du socle ; chacune annonce explicitement ce que le jeu ne permet pas de calculer ; le choix d'outil diffère au moins sur deux des trois, avec justification. Livrables : trois formulaires d'une page + une synthèse de cinq lignes qui liste **les questions communes non résolues**.

Barème : 4 pts distinctivité des trois questions (un correcteur doit pouvoir les reconnaître sans lire les en-têtes) · 4 pts réalisme des données citées (les fichiers et colonnes existent) · 4 pts limites annoncées (marge nette, coûts, année 2026 partielle) · 4 pts justification des outils · 4 pts synthèse. Ce mini-projet prépare directement le **projet M01.P**, dont il constitue le livrable (2) : « trois questions que l'on peut lui poser ».

14. Résumé du chapitre

Cinq métiers, une chaîne : flux → mesure → modélisation → prédiction → décision. Vous êtes formé pour le deuxième maillon en priorité, et pour parler à tous les autres. Une analyse se décompose en six temps dont la préparation est le plus long (40 %) et le cadrage le plus rentable (10 % du temps, 90 % du risque évité). Une demande floue devient une question réfutable en six questions, dont la dernière — « qu'est-ce qui prouvera que j'ai réussi ? » — est la plus négligée. Le choix d'outil découle de trois critères : volume, relecteur, rejouabilité — et se justifie par la

contrainte, jamais par la mode. Enfin, une note de six rubriques, où la ligne « ce que cela ne dit pas » est obligatoire : c'est elle qui vous rend crédible à long terme.

15. À retenir

À retenir. 1. **On juge un travail de la donnée à ses livrables** (note, fichier propre, journal, modèle), pas à ses outils. 2. **Six temps, et le cadrage d'abord** : 10 % du temps, mais la décision de savoir si le travail était utile. 3. **Une question analytique est réfutable** : deux traitements indépendants, même chiffre. 4. **Outil = volume + relecteur + jouabilité**. Tableur pour le ponctuel vérifiable, SQL pour le gros et le partagé, Python pour l'irrégulier, Power BI pour le publié et le gouverné. 5. **Écrivez les limites** : un chiffre sans rubrique « ce que cela ne dit pas » est une opinion chiffrée.

16. Évaluation formative (auto-correction, 12 min)

1. Un responsable dit « je veux un outil moderne ». Quelle est la question à poser en retour, et pourquoi ? (« quelle décision ce nouvel outil doit-il rendre meilleure ou plus rapide ? » — sans décision identifiée, le projet n'a pas de critère de réussite et ne sera pas adopté)
2. Citez les deux rubriques du formulaire qu'il est interdit de laisser vides, et la raison. (2 (décision visée) : sans elle, aucun livrable n'est utile · 7 (critère de réussite) : sans elle, aucun travail n'est vérifiable ni terminé)
3. Sur l'extrait de l'atelier : 316 tickets pour 489 lignes. Quel outil pour recompter sur les 240 000 lignes du fichier complet, et pourquoi pas un tableur ? (SQL ou Python/DuckDB : agrégation avec `COUNT(DISTINCT ...)` sur 240 000 lignes est immédiate en base, pénible et fragile dans un tableur ; et l'opération sera rejouée, donc elle mérite une requête)
4. Un rapport Power BI publié avec une mesure « CA » définie trois fois dans trois rapports : quel métier est concerné, et quel artefact manque ? (BI analyst (ou vous, faute de mieux) ; le dictionnaire des mesures / modèle sémantique partagé, qui impose une définition unique)
5. **Question ouverte** : rédigez, pour votre propre situation (emploi, recherche, reprise d'études), une question analytique correcte que vous seriez capable de traiter dans trois mois avec les données dont vous disposez. (évalué sur les cinq composants, et sur la mention explicite d'une limite — pas sur l'ambition du sujet)

Transition vers le module 2. Vous savez lire les données, les classer, les typer, dater leur provenance et cadrer une demande. Vous ne savez pas encore les **résumer honnêtement** : une moyenne sans médiane, un pourcentage sans dénominateur, une tendance sans dispersion suffisent à faire publier une erreur avec assurance. Le module 2 — Statistiques pour l'analyse, et les pièges du résumé — vous donne ces outils, avec les mêmes données : les 480 lignes propres de l'atelier, et leurs 30 tickets aberrants qui vont vous occuper utilement.

M01 — Bilan de compétences et auto-positionnement

À remplir à la main (ou dans `journal.md` de votre cahier de l'apprenant) après le projet et l'évaluation. Ne sautez pas cette page : le parcours est conçu pour un autodidacte, et un autodidacte qui ne s'auto-évalue pas accumule des trous qui ne se voient qu'au module 12.

1. Je sais maintenant (vocabulaire — à cocher, et à définir de ma main)

Cochez seulement si vous pouvez **définir le mot en une phrase, sans jargon**, à quelqu'un qui ne travaille pas dans l'informatique.

Terme	Je le définis sans aide	Ma phrase à moi
donnée · information · connaissance · décision	☐	
table · ligne · colonne · cellule · en-tête	☐	
grain d'une table	☐	
clé primaire · clé étrangère · valeur distincte	☐	
type de données · inférence de type	☐	
nombre stocké en texte	☐	
encodage · séparateur · décimale · chapeau	☐	
structuré · semi-structuré · non structuré	☐	
qualitatif (nominal, ordinal) · quantitatif (discret, continu)	☐	
échelle de mesure (nominale, ordinale, intervalle, ratio)	☐	
question analytique · critère de réussite · périmètre	☐	
métrique · indicateur (KPI)	☐	
source de vérité · jeu figé · empreinte (hash)	☐	
dictionnaire de données · journal de transformation · manifeste	☐	
cycle de vie d'une donnée · rétention · minimisation	☐	

Test de réalité. Écrivez, sans regarder, ce que représentent : une ligne de `ventes_brutes.csv` (243 360 lignes) · une ligne de `objectifs_de_ca.csv` (218) · une ligne de `remises_manuelles.xlsx` (18 200) · une ligne de `dim_date.csv` (1 339). Quatre bonnes réponses = acquis. Trois ou moins = reprenez le chapitre C03, §5.2.

2. Je suis capable de (gestes professionnels)

Niveau d'autonomie : **A** = je le fais seul · **E** = je le fais avec la fiche sous les yeux · **N** = pas encore.

Geste	A / E / N	Preuve chez moi (fichier ou capture)
Ranger un dossier de travail en six étapes numérotées, avec brut en lecture seule	☐	

Geste	A / E / N	Preuve chez moi (fichier ou capture)
Nommer un fichier selon AAAA-MM-JJ_quoi_qui_etat.ext	☐	
Vérifier qu'une sauvegarde se restaure réellement	☐	
Décrire une table inconnue en six phrases	☐	
Compter des lignes, des objets distincts, des valeurs manquantes dans un tableur	☐	
Détecter une colonne de montants stockée en texte avec deux formules	☐	
Convertir une colonne sans perte, avec contrôle avant/après	☐	
Réparer deux formats de date dans une même colonne, et prouver la réparation	☐	
Vérifier séparateur, encodage, décimale et chapeau d'un fichier plat	☐	
Classer une variable et dire quel calcul est licite	☐	
Rédiger un dictionnaire de colonnes avec la colonne « défauts connus »	☐	
Tenir un journal de transformation avec écarts chiffrés	☐	
Convertir une demande floue en question analytique à cinq composants	☐	
Choisir un outil (tableur · SQL · Python · Power BI) et justifier par volume, relecteur, rejouabilité	☐	
Rédiger une note de décision en six rubriques, limites comprises	☐	

Seuil de passage : 11 gestes sur 15 en A ou E, dont obligatoirement « détecter une colonne texte », « question analytique à cinq composants » et « note en six rubriques ». Ces trois-là sont les prérequis réels du module 2.

3. Outils maîtrisés à la sortie du module

Outil	Ce que je sais faire sans aide	Ce que je ne sais pas encore faire (et dans quel module ça s'apprend)
Explorateur Finder	/ chemins, extensions, recherche, propriétés, lecture seule	scripts de renommage en masse (M08)
Tableur (Excel ou LibreOffice)	import assisté, NB, NBVAL, CBI/VALUE, SUPPRESpace, tri, filtre, comptage de doublons, formules matricielles simples	tableaux croisés, Power Query, RECHERCHEX (M03-M06)
Éditeur de texte	lire un CSV, compter des lignes, repérer un encodage	écrire un parseur (M08, M20)
Terminal	wc -l, head, cut, grep, file -i, md5sum/Get-FileHash	automatiser une chaîne de traitement (M08, M24)
Power BI, SQL, Python	— je sais quand ils sont nécessaires et je le justifie	M07 (SQL), M08-M10 (Python), M13-M18 (Power BI)

Cette colonne de droite est la plus utile : savoir nommer l'outil qui manque, avec la raison de son absence, est déjà une compétence d'architecte.

4. Niveau atteint

Le manuel utilise cinq niveaux, définis au §B.2 de l'architecture. En sortie de M01 :

Niveau	Définition	Où j'en suis
N1 — Literatie	comprendre le vocabulaire, lire une donnée, savoir où elle est, formuler une question	✓ objectif du module

Niveau	Définition	Où j'en suis
N2 — Opérateur	produire des mesures justes dans un outil	M02-M06
N3 — Analyste	mener une analyse complète et la défendre	M07-M12
N4 — Concepteur	modéliser, industrialiser, administrer	M13-M21
N5 — Référent	arbitrer, budgéter, transmettre	M22 et la pratique

Auto-positionnement : placez-vous sur N1 avec un chiffre de 1 à 5 (1 = je découvre encore le vocabulaire, 5 = je peux l'expliquer à un collègue avec nos données à lui). Notez la date. Vous referez ce test à la fin de M06, de M12, de M18 et de M22 : **la progression du chiffre compte plus que le chiffre lui-même.**

5. Pour passer au module suivant

1. **Correction des exercices manqués.** Reprenez uniquement les énoncés où votre réponse diffère du corrigé sur un **nombre** (pas sur la formulation). Un écart de vocabulaire se corrige en écrivant la définition ; un écart de nombre se corrige en refaisant le calcul.
2. **Préparer M02.** Gardez sous la main le fichier `2025_ventes_M5_propre_v1.csv` que vous avez produit (480 lignes, 36 073 185 FCFA) : le module 2 part de **vos** colonnes nettoyées, et non d'un fichier fourni. Si vous ne l'avez pas, refaites-le : c'est le temps d'achat du module 2.
3. **Trois choses à savoir par cœur avant le premier chapitre de M02** : le grain du fichier (une ligne = un article d'un ticket) · la différence entre 489 lignes et 316 tickets · le fait que 0,74 % du total dépend du nettoyage. Sans ces trois repères, les statistiques du module 2 seront comprises trop tard.
4. **Le droit à l'erreur est organisé, pas négocié.** Toute erreur détectée après coup dans ce manuel est corrigée à la source et publiée en annexe « errata » (règle de production n° 7) : signalez-la, vous contribuez à l'ouvrage, et vous gardez la trace de votre contrôle dans votre journal — ce qui compte pour la soutenance du module 22.

6. Auto-questionnement dirigé (à écrire, 15 minutes)

1. Quel défaut du fichier de l'atelier m'a le plus surpris, et pourquoi ne l'avais-je pas vu ?
2. Quelle formule ou quel réflexe du module vais-je utiliser dès demain, même hors formation ?
3. Quel terme technique ai-je employé sans pouvoir le définir ? (→ à recopier dans `glossaire_personnel.md`)
4. Quelle demande professionnelle réelle, en attente chez moi, puis-je convertir en question analytique cette semaine ?
5. Ai-je écrit un journal de transformation qui permettrait à un inconnu de refaire mon travail ?
Si non, qu'est-ce qui m'en a empêché — le temps, la méthode, ou la peur du regard ?

Ces cinq questions sont celles que poserait un enseignant en fin de module. Un enseignant, ici, n'existe pas : le cahier de l'apprenant le remplace, à condition de l'ouvrir.

Contrôle de sortie du module (à cocher par l'apprenant, vérifié par la suite du parcours)

- ☐ 7 chapitres lus et les 7 mini-projets rendus
- ☐ quiz $\geq 14/20$ · projet M01.P complet et noté $\geq 13/20$
- ☐ étude de cas rendue (cadrage de 5 demandes)
- ☐ fichier propre produit et total de contrôle = 36 073 185 FCFA

- [] dictionnaire de données avec colonne « défauts connus » remplie ($65 \cdot 486 \cdot 18 \cdot 7 \cdot 9$)
- [] journal de transformation ≥ 12 entrées, avec écarts chiffrés

Projet M01.P — « Un petit fichier de ventes, une première fois »

Module M01 · projet de fin de module · 5 h · à rendre avant le module 2 · barème /20, seuil de passage 13/20

Le cadre réel. Vous êtes engagé(e) comme analyste junior chez Sahel Distribution SA, grossiste en matériaux et quincaillerie, 5 magasins et 1 dépôt. Le service informatique est une personne, qui cumule avec la maintenance. Vous n'avez ni base de données, ni licence, ni mode d'emploi : vous avez un poste, un fichier CSV reçu par messagerie, et l'obligation de produire un chiffre que le directeur ne pourra pas contester. C'est exactement une première semaine de stage — et c'est la raison pour laquelle ce projet est noté, pas seulement « fait ».

1. Énoncé

Le matériel

Élément		Chemin	Ce que c'est
Fichier travail	de	01_socle_donnees/data/projection/ventes_magasin5_2025.csv	extrait des ventes du magasin 5, année 2025 : 489 lignes × 13 colonnes
Fichier fournisseur	du	01_socle_donnees/data/brut/tarif_fournisseur_peinture.csv	grille de prix Peinture Saaba SARL : 42 lignes , dont 38 utiles
Corrigé référence	de	01_socle_donnees/data/reference/ventes_magasin5_2025_ATTENDU.csv	480 lignes , à ne pas ouvrir avant le rendu
Vos outils		tableur (Excel ou LibreOffice) + éditeur de texte + un traitement de texte	rien d'autre n'est requis ni autorisé

Les quatre livrables

L1 — Fiche d'identité du fichier (1 page). Les six phrases du chapitre C03 (nom et source · objet · grain · clé · mesures et attributs · étendue), suivies d'un tableau de **contrôles** : pour chacune des 13 colonnes, le type constaté, le nombre de valeurs distinctes, les bornes ou les modalités notables, et les défauts visibles. Vous devez avoir **compté** les défauts, pas les avoir devinés.

L2 — Trois questions que l'on peut poser à ce fichier (une demi-page). Chacune formulée en **question analytique complète** (objet, unité + définition, comparaison, périmètre, critère de réussite), plus une ligne « ce que ce fichier ne permet pas de répondre » par question.

L3 — Une réponse chiffrée, sans autre outil que le tri et le filtre du tableur (1 page). Vous choisissez **une** des trois demandes ci-dessous, vous y répondez avec un chiffre juste, et vous annexez la méthode en cinq lignes maximum (aucune formule complexe, aucune macro, aucun autre logiciel) :

- **a)** « Quelle catégorie de produits pèse le plus dans le chiffre d'affaires du magasin 5 en 2025, et à quelle hauteur ? » (réponse attendue en L3-a du corrigé)
- **b)** « Quel vendeur arrive en tête, et avec quel total ? » (réponse attendue en L3-b)
- **c)** « Quel mois a été le plus fort, et de combien par rapport au plus faible ? » (réponse attendue en L3-c)

L4 — « Ce que je ne sais pas encore faire » (1 page, à écrire **après** L1-L3, sans tricher). La liste honnête des opérations que vous avez vues faire (par un collègue, dans un forum, dans ce

manuel) et que vous ne maîtrisez pas, classées en trois colonnes : ce dont j'aurai besoin tout de suite · ce dont j'aurai besoin dans trois mois · ce qui n'est pas mon besoin. Trois lignes minimum par catégorie.

Contraintes de rendu

1. Les fichiers sont déposés dans une arborescence conforme à la convention du module 1 (01_brut en lecture seule, 02_propre, 03_analyse, 04_livrables, 90_journal).
2. Le **journal de transformation** compte au moins **8 entrées** datées, chacune avec les nombres avant/après.
3. Le livrable L1-L4 est un seul document PDF nommé 2026-09-17_projet_M01_P_votre_nom.pdf, plus le classeur de travail.
4. **Interdits** : copier un total du corrigé sans montrer la manipulation qui y mène ; utiliser un tableau croisé dynamique ou une requête pour L3 (l'exercice porte sur le tri et le filtre) ; modifier le fichier brut.

2. Barème détaillé

#	Critère	Pts	Ce qui fait perdre les points
1	Fiche d'identité : six phrases justes	4	grain exprimé en « c'est du mensuel » (ce n'est pas un grain) ; clé donnée comme n_ticket seul
2	Contrôles par colonne : tous les comptages exacts	5	un seul nombre faux = -0,5 ; un nombre non vérifié (pas de formule, pas de commande) = -1
3	Trois questions : cinq composants, réfutabilité	3	adjectif non mesurable resté dans la question ; critère de réussite absent
4	Réponse chiffrée L3 : valeur exacte + méthode reproductible	4	chiffre juste obtenu par un moyen interdit ; ou juste mais sans méthode
5	Journal + arborescence + nommage	2	écart de total non expliqué ; fichier brut touché
6	L4 : lucidité de l'autoportrait	2	liste de vœux au lieu d'une liste d'outils/gestes précis
Total		20	seuil de passage en M02 : 13

3. Correction pas à pas (corrigé enseignant)

Cette correction est rédigée comme un compte-rendu de travail, parce que c'est ce qui est noté. Elle s'appuie sur les valeurs réellement produites par le fichier livré ; si votre fichier diffère, régénérez (python3 01_socle_donnees/scripts/generation_socle.py) avant de vous comparer.

3.1 — Réponse L1 : la fiche d'identité, telle qu'elle doit être rendue

Nom et source. ventes_magasin5_2025.csv, export de la caisse du magasin 5 pour l'année 2025, reçu par messagerie le 17/09/2026 ; 489 lignes, 32 Ko, en-tête sur 1 ligne, séparateur point-virgule, encodage UTF-8.

Objet. Les articles facturés au magasin 5 sur l'année 2025.

Grain. Une ligne = un article d'un ticket de caisse. Ni une vente, ni un jour, ni un client.

Clé. Aucune colonne n'est unique : n_ticket identifie le ticket et se répète (1 à 4 lignes par ticket). L'unicité de la ligne est assurée par le couple (n_ticket, produit).

Mesures et attributs. Mesures : `quantite`, `prix_unitaire_ht`, `remise`, `montant_ht`, `montant_ttc`. Attributs : `date`, `heure`, `magasin`, `vendeur`, `client`, `produit`, `categorie`. Identifiants : `n_ticket`, `client`, `produit`.

Étendue. 489 lignes · 316 tickets distincts · 31 jours avec des ventes (l'extrait contient 40 lignes par mois, tous certains jours ne sont donc pas représentés) · 4 vendeurs · 145 produits distincts · 7 catégories · 372 identifiants clients distincts · 18 lignes sans client · période couverte 2025-01-01 → 2025-12-31.

Tableau des contrôles (le cœur du point 2 du barème) :

Colonne	Type constaté	Distincts	Bornes / modalités	Défaut constaté	Comment je l'ai compté
<code>n_ticket</code>	texte	316	T05-25...-..., 17 caractères	9 lignes en double (489 – 480)	=SOMMEPROD(1/NB.SI(...)) ou tri + comptage manuel
<code>date</code>	texte	55	2025-01-01 → 2025-12-31	→ 65 lignes en JJ/MM/AAAA	=NB.SI(B:B;"?*/?/*")
<code>heure</code>	texte	356	07:01 → 18:57	—	—
<code>magasin</code>	texte	1	« Magasin 5 — Kaya Marché »	—	—
<code>vendeur</code>	texte	4	Ilboudo, Sankara, Ouédraogo, Bationo	—	—
<code>client</code>	nombre ou vide	372	0 = comptoir	18 vides (=NB.EUILL)	vides ≠ 0 : deux choses distinctes
<code>produit</code>	texte	145	« ... — réf N » dans le libellé	deux infos dans une cellule	—
<code>categorie</code>	texte	7	Matériaux 146 · Quincaillerie 115 · Consommables 58 · Plomberie 57 · Electricité 54 · Peinture 34 · Bois & panneaux 25	—	tri + comptage
<code>quantite</code>	nombre	37	-13 (retours) → 14 000	7 lignes > 500	=MAX(), =NB.SI(I:I;">500")
<code>prix_unitaire_ht</code>	nombre	323	675 → 40 550	—	=MIN(), =MAX()
<code>remise</code>	nombre	6	0 → 0,11 (proportion)	aucune valeur > 0,4 ici	contrôle de plage
<code>montant_ht</code>	nombre	456	total = à recalculer	cohérent avec quantité × prix × (1 – remise)	=SOMME()
<code>montant_ttc</code>	texte	456	—	486 lignes non numériques	=NBVAL(M:M) - NB(M:M)

Le point qui distingue un bon rendu d'un rendu moyen : la ligne `quantite`. Le candidat solide écrit « 7 lignes suspectes, montant cohérent, donc doute sur l'unité de saisie → à voir avec le métier, pas à supprimer ». Le candidat pressé supprime les 7 lignes et perd 1 point au contrôle des totaux.

3.2 — Réponse L2 : les trois questions, avec leurs limites

Question 1 (mix de catégories). « En 2025, au magasin 5, quelle catégorie de produits représente la part la plus élevée du CA TTC (somme de `montant_ttc`, retours inclus avec leur signe, après retrait des doublons), et cette part dépasse-t-elle 20 % du total ? » Critère de réussite : la somme des 7 catégories doit redonner le total de l'extrait nettoyé, **36 073 185 FCFA** ; la réponse est une part en pourcentage à ±0,1 pt. Ce que ce fichier ne permet pas de répondre : la

rentabilité de la catégorie (aucun coût d'achat dans ce fichier — il est dans `couts_achat.csv`, module 13) et la comparaison aux autres magasins (extrait limité au magasin 5).

Question 2 (saisonnalité). « Quel mois de 2025 présente le CA TTC le plus éloigné de la médiane des douze mois, et de combien de fois le mois le plus faible ? » Critère : ratio meilleur mois / pire mois = **4,2** (décembre 5 292 517 FCFA, mai 1 258 801 FCFA). Limite : l'extrait contient 40 lignes par mois, **tous les mois ne sont donc pas complets** : ce ratio décrit l'extrait, pas la réalité commerciale. Cette phrase est obligatoire dans un rendu correct ; l'omettre vaut une note plafonnée à 15/20, quel que soit le reste.

Question 3 (qualité avant tout). « Combien de lignes de cet extrait ne peuvent pas être sommées telles quelles, et quel est l'effet chiffré de leur correction sur le total annuel ? » Critère : 486 montants en texte, 9 doublons, écart de total = **266 132 FCFA**, soit **+0,74 %** sur le total non nettoyé (36 339 317 → 36 073 185). Limite : le fichier ne dit pas si les doublons viennent de la caisse ou de l'export ; seule la caisse (ou le journal d'export) tranche.

3.3 — Réponse L3 : la méthode par tri et filtre, et les trois résultats

Préparation commune (autorisée : tri, filtre, =SOMME() sur la colonne filtrée).

1. Import assisté, toutes colonnes en texte, puis une colonne auxiliaire `ttc_num = CBI(SUPPRESSED(SUBSTITUE(...)))` — 486 conversions, 0 échec. (Oui, une formule de conversion est autorisée : sans elle, aucun total n'est possible ; ce qui est interdit, c'est le TCD et la requête.)
2. Tri sur `n_ticket` puis suppression des doublons stricts par la commande du tableur → 480 lignes. Contrôle : `=SOMME(ttc_num)` = **36 073 185**.

L3-a (catégorie dominante). Filtre sur `categorie` = Plomberie, `=SOMME()` sur la colonne filtrée → **8 754 982 FCFA**, soit **24,3 %** du total. Réponse : « la catégorie la plus lourde du CA 2025 du magasin 5 est la **Plomberie**, à 24,3 % ». Suit le classement complet, à exiger d'un rendu sérieux :

Catégorie	CA TTC (extrait nettoyé)	Part
Plomberie	8 754 982 FCFA	24,3 %
Matériaux	6 519 357 FCFA	18,1 %
Electricité	6 311 645 FCFA	17,5 %
Bois & panneaux	4 844 758 FCFA	13,4 %
Quincaillerie	4 203 121 FCFA	11,7 %
Peinture	2 938 358 FCFA	8,1 %
Consommables	2 500 964 FCFA	6,9 %
Total	36 073 185 FCFA	100 %

Attention au piège classique, et il est là pour cela : le **nombre de lignes** ne suit pas le CA. La catégorie la plus fréquente en lignes est Matériaux (146 lignes), pas Plomberie (57 lignes). Un rendu qui confond fréquence et montant perd le point 4 intégralement, parce que la phrase de conclusion serait fausse.

L3-b (vendeur en tête). Bationo : **11 370 350 FCFA** · Sankara 9 423 281 · Ouédraogo 8 483 019 · Ilboudo 6 796 535. Somme des quatre = 36 073 185 FCFA ✓ (le contrôle croisé fait partie de la réponse attendue).

L3-c (mois extrêmes). Décembre 2025 = **5 292 517 FCFA** ; mai 2025 = **1 258 801 FCFA** ; ratio **4,2**. Le détail complet des douze mois figure dans le chapitre C04 §5.3 ; un candidat doit pouvoir en retrouver au moins quatre sur demande orale du correcteur.

3.4 — Réponse L4 : ce à quoi ressemble un autoportrait utile

Exemple de rendu recevable (extrait) :

J'en aurai besoin tout de suite	Dans trois mois	Ce n'est pas mon besoin
tableaux croisés (M03-M05)	jointures SQL sur la base de l'entreprise (M07)	entraîner un modèle de prédiction (M19-M21)
RECHERCHEX pour relier les noms de produits (M06)	script Python pour rejouer le nettoyage (M08)	gestion de cluster (M24)
mettre un format de date fiable (déjà fait ici, à consolider M04)	publier un tableau de bord Power BI (M13-M18)	configuration d'un entrepôt (M15)

Un autoportrait qui écrit « je veux devenir meilleur en data » est noté 0/2 : ce n'est pas une liste de besoins, c'est une intention.

3.5 — Le fichier du fournisseur, traité à part (bonus +1, pas obligatoire)

Le point n'est pas dans l'énoncé, mais il revient toujours en entretien de stage : **importez tarif_fournisseur_peinture.csv proprement** et donnez le nombre de références, le prix moyen et le prix le plus élevé. Réponse : 38 lignes utiles (42 – 3 de chapeau – 1 d'en-tête), encodage **Windows-1252**, séparateur **;**, décimale **virgule**, TVA 0,18 sur toutes les lignes. Un rendu qui écrit « le fichier est corrompu » perd le bonus ; un rendu qui écrit « il faut lire en cp1252 avec 3 lignes à ignorer » le gagne.

4. Grille d'auto-évaluation avant rendu

À cocher soi-même, honnêtement, avant d'envoyer. Sept cases manquantes = rendez-vous dans deux jours.

- ☐ Chaque nombre cité dans L1 et L3 est le résultat d'une formule ou d'une commande que je peux rejouer devant quelqu'un.
- ☐ J'ai écrit le grain en une phrase, sans le mot « mensuel ».
- ☐ J'ai distingué les 9 doublons (à retirer) des 7 quantités suspectes (à signaler).
- ☐ J'ai dit « vide $\neq$ 0 » pour la colonne `client`, et je l'ai justifié par la règle métier du comp-toir.
- ☐ Mes trois questions L2 ont chacune cinq composants, et aucune ne contient d'adjectif non chiffré.
- ☐ Dans L2, j'ai écrit explicitement que l'extrait est un échantillon de 40 lignes par mois.
- ☐ Mon total nettoyé est 36 073 185 FCFA, et mon journal explique pourquoi le brut affichait 36 339 317 FCFA.
- ☐ Le brut est en lecture seule, et aucun de ses octets n'a changé (vérifié par empreinte).

5. Ce que le correcteur regardera en premier

Pas les chiffres — ils sont vérifiables en dix secondes. La première chose qu'un évaluateur expérimenté regarde, dans un dossier de ce niveau, est **l'ordre des opérations** : le candidat a-t-il documenté avant de corriger, ou corrigé puis justifié ? Le second regard va aux **limites écrites spontanément** (« l'extrait n'est pas la population ») : c'est le meilleur prédicteur de la capacité à travailler sans supervision. Le troisième, le nom des fichiers. Les chiffres viennent ensuite, et ils sont la partie facile.

Évaluation du module M01 — récupération, quiz, exercices, étude de cas, corrigés

Durée totale conseillée : 2 h 30 · Deux notes indépendantes, ni l'une ni l'autre négociable : quiz sur 20 (seuil de passage 14/20) et étude de cas sur 20 (seuil 12) · Le projet de module est noté séparément, sur 20, seuil 13 (03_exercices/M01_projet.md)

Le module est validé quand les trois notes sont au seuil. Chaque instrument répond à une question différente, et c'est pour cela qu'ils ne se compensent pas : le quiz dit si vous savez, les exercices si vous savez faire, l'étude de cas si vous savez cadrer avant de faire, le projet si vous savez livrer.

Instrument (barèmes du manuel, partie B.6 de l'architecture)	Barème	Durée	Ce qui est vérifié
A. Récupération — 7 questions	non noté, auto-corrigé	15 min	la mémoire des sept chapitres, sans relire
B. Quiz — 15 questions	/20, seuil 14/20	30 min	le vocabulaire, les types, la structure d'une table
C. Exercices pratiques — 4 exercices	auto-correction par résultat attendu chiffré	45 min	le geste : compter, convertir, contrôler
D. Étude de cas — 5 demandes	grille à 5 critères, /20, seuil 12	60 min	le cadrage, avant tout calcul

Matériel autorisé : le fichier `ventes_magasin5_2025.csv` (489 lignes), `tarif_fournisseur_peinture.csv`, un tableur, un éditeur de texte. Matériel interdit : le corrigé, les notes du projet M01.P (l'évaluation sert à vérifier que le savoir est **en vous**, pas dans votre dossier).

A. Questions de récupération (non notées, à traiter avant le quiz)

Répondez en une phrase, sans relire. Toute réponse hésitante = relecture ciblée du chapitre indiqué.

1. Que représente une ligne du fichier de l'atelier ? (C03 · un article d'un ticket, pas une vente)
2. Quelle est la différence entre un format et un type ? (C04 · l'apparence vs la nature de la valeur, donc ses opérations permises)
3. Combien de lignes a le fichier, et combien de tickets ? (C03 · 489 et 316)
4. Que fait `=NB()` que `=NBVAL()` ne fait pas ? (C04 · il ignore le texte : la différence des deux mesure les montants mal typés)
5. Un fichier en `;` encodé en Windows-1252 est-il cassé ? (C05 · non : il est lisible, c'est la lecture qui est mal réglée)
6. Citez les trois documents qui rendent un chiffre défendable dans trois ans. (C06 · dictionnaire de données, journal de transformation, manifeste d'archivage)
7. Quels sont les cinq composants d'une question analytique ? (C02/C07 · objet, unité + définition, comparaison, périmètre, critère de réussite)

B. Quiz — 15 questions, noté sur 20

Barème : 10 questions à 1 point (Q3, Q5, Q6, Q7, Q8, Q10, Q12, Q13, Q14, Q15) et 5 items-piège à 2 points (Q1, Q2, Q4, Q9, Q11), où la justification écrite est exigée : $10 \times 1 + 5 \times 2 = 20$. Une réponse juste sans justification sur un item-piège vaut 1 point sur 2 ; une justification sans réponse vaut 0. Les items-piège ne testent pas la mémoire des mots mais la frontière entre eux. Répondez par Vrai/Faux ou choisissez l'option ; le corrigé commenté suit immédiatement, à ne consulter qu'après avoir tout traité.

Frontières du vocabulaire (Q1 à Q4)

- Q1.** « Une donnée est une information. » Vrai ou faux ?
- Q2.** « Une colonne `id_client` remplie de nombres est une variable quantitative. » Vrai ou faux ?
- Q3.** « Un CSV ne contient pas de types de données. » Vrai ou faux ?
- Q4.** « Une fois formatée en date, une cellule contient une date. » Vrai ou faux ?

Structure et lecture d'une table (Q5 à Q9)

- Q5.** Sur le fichier de l'atelier, combien de tickets distincts pour 489 lignes ? a) 489 b) 480 c) 316 d) 145
- Q6.** Quelle colonne, à elle seule, peut servir de clé primaire de ce fichier ? a) `n_ticket` b) `produit` c) `date` d) aucune
- Q7.** Vous voulez compter « le nombre d'articles facturés » et « le nombre de ventes ». Quelle paire de comptages ? a) lignes, tickets distincts b) tickets distincts, lignes c) clients distincts, produits distincts d) montants distincts, lignes
- Q8.** Le fichier `ventes_propres.csv` du socle contient : a) 243 360 lignes b) 240 000 lignes c) 489 lignes d) 1 339 lignes
- Q9.** Un tableau croisé affiche un total exactement double du total de la colonne. Cause la plus probable : a) une ligne de sous-total importée comme donnée b) un encodage différent c) des dates au format français d) un identifiant client en texte

Types, formats, encodages (Q10 à Q13)

- Q10.** Combien de lignes de `montant_ttc`, dans le fichier de l'atelier, ne sont pas des nombres ? a) 0 b) 3 c) 486 d) 489
- Q11.** Après nettoyage complet, le CA TTC de l'extrait passe de 36 339 317 à 36 073 185 FCFA. Cet écart de 266 132 FCFA provient de : a) lignes en double b) retours négatifs c) TVA mal appliquée d) arrondis successifs
- Q12.** Le fichier du fournisseur compte 42 lignes. Combien de références ? a) 42 b) 41 c) 38 d) 39
- Q13.** Un fichier dont les accents s'affichent Ã© a été : a) corrompu par l'e-mail b) écrit en UTF-8 et lu en Windows-1252 (ou l'inverse) c) enregistré au format XLS d) tronqué

Posture et méthode (Q14 et Q15)

- Q14.** Le directeur demande « est-ce que ça marche bien ? ». La **première** action correcte est : a) charger le fichier dans le tableur b) construire un graphique de CA mensuel c) demander quelle décision dépend de la réponse d) proposer Power BI
- Q15.** Sur un échantillon de 480 lignes représentant 40 lignes par mois, vous affirmez « décembre est le meilleur mois de 2025 au magasin 5, la preuve d'une forte saisonnalité ». Ce raisonnement est : a) correct, le chiffre est exact b) incorrect : l'extrait n'est pas la population, et

un classement sur échantillon ne prouve pas une saisonnalité c) correct si le total de contrôle est bon d) incorrect, car il faudrait inclure 2026

C. Exercices pratiques (4) — séries E1 et E2, auto-correction

Ces quatre exercices ne sont pas notés au quiz : ils sont **validés par le résultat attendu**, parce que dans le métier un résultat ne se discute pas, il se vérifie. Traitez les quatre, comparez vos chiffres à l'attendu, puis lisez le corrigé. Un attendu manqué de peu n'est pas un demi-exercice réussi : cherchez l'écart, c'est là qu'est l'apprentissage.

Exercice C.1 (série E1). Ouvrez `ventes_magasin5_2025.csv` dans un éditeur de texte. Notez : le séparateur, le nombre de colonnes de la ligne d'en-tête, le contenu de la ligne 2 en trois mots, et une anomalie visible **sans calculer**. (attendu : ; · 13 · ticket, date, montant en texte · par exemple l'espace dans 56 658 ou la date 12/01/2025)

Exercice C.2 (série E1). Dans le tableur, importez avec toutes les colonnes en texte, puis donnez, par trois formules : le nombre de lignes de données, le nombre de valeurs numériques de `montant_ttc`, le nombre de lignes dont `date` contient un /. (attendu : `=NBVAL(A2:A490)` = 489 · `=NB(M2:M490)` = 3 · `=NB.SI(B:B;"?/*/*")` = 65)

Exercice C.3 (série E2). Produisez le fichier nettoyé attendu : 480 lignes, dates en ISO, `montant_ttc` en nombre, `quantite` rétablie sur les 7 lignes aberrantes ($\div 1\,000$), `client` conservé tel quel, y compris les 18 vides et les 0 de comptoir. Donnez le total de contrôle. (attendu : 36 073 185 FCFA ; la comparaison avec `ventes_magasin5_2025_ATTENDU.csv` est le contrôle de forme)

Exercice C.4 (série E2). Convertissez le fichier du fournisseur en un tableau propre de 38 lignes × 6 colonnes, prix en nombre, TVA conservée. Donnez le prix moyen et le prix maximal. (attendu : 11 155 FCFA en moyenne, 34 826 FCFA au maximum, TVA 0,18 sur toutes les lignes ; encodage cp1252, 3 lignes de chapeau ignorées, virgule décimale traitée)

D. Étude de cas — « Le patron veut savoir des choses » (20 points, seuil 12)

Contexte. Samedi matin, marché de Kaya. Le directeur de Sahel Distribution SA vous retient trente secondes près du parking et dit, d'un trait, les cinq phrases ci-dessous. Vous n'avez ni base, ni tableau de bord, ni temps : vous avez un carnet. Consignez, pour **chacune** des cinq demandes, la décision visée et la question analytique complète (objet, unité + définition, comparaison, périmètre, critère de réussite), ainsi que la ou les tables à ouvrir et **ce qui manquera** dans le jeu de données pour y répondre.

1. « Les prix de la concurrence, il faut qu'on s'aligne, tu crois qu'on est trop chers ? »
2. « Bationo, il vend trop bien, faut le augmenter — ou pas. Regarde. »
3. « On m'a dit qu'en janvier on ne vend rien, et moi je trouve qu'en janvier ça bosse. »
4. « Si on fermait le dépôt le dimanche, ça changerait quoi ? »
5. « Le magasin 5, il me plaît. Combien il rapporte ? »

Contraintes de rendu. Cinq blocs de six lignes maximum, format imposé :

[n°] Demande (verbatim, 1 ligne)	
Décision visée · Destinataire · Échéance	(1 ligne)
Question analytique	(1-2 lignes)
Tables et colonnes à ouvrir	(1 ligne)
Manquant / limite qui empêche de conclure	(1 ligne)
Outil choisi + motif en 4 mots	(1 ligne)

Grille de notation — 5 critères, 4 points par demande (5 × 4 = 20 points, seuil de validation 12). Pour chaque demande : question analytique comportant les cinq composants (1,5) · décision, destinataire et échéance nommés (1) · limite réellement limitée et non générique (0,5) · choix d'outil justifié par une contrainte et non par un goût (1). Un bloc qui répond à la place de cadrer est noté 0 : on ne demande pas ici le chiffre, on demande la question. Le dixième point de la grille est un point de **cohérence d'ensemble** : les cinq demandes doivent se ressembler (même gabarit, mêmes colonnes appelées), parce qu'un cadrage qui change de forme d'un dossier à l'autre n'est pas un cadrage, c'est une humeur du moment.

Corrigé de l'évaluation (à consulter après traitement complet)

B. Quiz — réponses et explications

Q1 — Faux. Une donnée est un fait brut ; elle devient information quand elle est replacée (quoi, qui, quand, unité). 56 658 n'est pas un chiffre d'affaires ; « 56 658 FCFA TTC, ligne 1 du ticket du 01/01/2025, magasin 5 » en est une. Le piège est réel : dans le langage courant, les deux mots sont interchangeables ; dans le métier, non.

Q2 — Faux. C'est un **identifiant**, donc une valeur nominale : le calculer, le moyener, le trier par ordre numérique n'a aucun sens. Le test : « une soustraction a-t-elle un sens ? » 10 857 - 3 312 ne veut rien dire.

Q3 — Vrai. Un CSV est du texte ; le type apparaît quand un outil le déclare ou le devine. C'est pourquoi les identifiants doivent être explicitement lus comme texte (et pourquoi le 075845 final du ticket T05-250101-075845 deviendrait 75845 si un tableur le lisait comme un nombre).

Q4 — Faux. Le format change l'affichage, pas la nature de la valeur. Une cellule affichant 12/01/2025 peut contenir le texte « 12/01/2025 » (et refuser tout calcul de mois) ou le nombre 45669 (le douzième jour de l'année 2025 compté depuis l'origine du tableur, qui est le 00/01/1900 : une vraie date, stockée en numéro de série). Le contrôle : =ESTNUM() puis =EST-DATE().

Q5 — c) 316. 480 lignes propres pour 316 tickets ; 489 est le nombre de lignes de l'énoncé, 145 le nombre de produits distincts.

Q6 — d) aucune. n_ticket se répète (1 à 4 lignes) ; produit et date aussi. L'unicité demande le couple (n_ticket, produit).

Q7 — a). Les lignes = les articles facturés, les tickets distincts = les ventes. Confondre les deux surestime le nombre de ventes de 55 % sur ce fichier.

Q8 — b) 240 000 lignes. ventes_brutes.csv en contient 243 360 ; 489 est l'extrait de l'atelier, 1 339 la table dim_date.

Q9 — a). Un sous-total importé comme donnée double exactement le total. Les autres options changent l'affichage ou la ponctuation, pas la somme. Vérification : compter les lignes dont la colonne-clé est vide.

Q10 — c) 486 sur 489 (3 valeurs seulement sont numériques). Le diagnostic complet : `=NB()` = 3, `=NBVAL()` = 489, la soustraction donne le nombre de défauts.

Q11 — a). Les 9 lignes en double injectées par l'export de la caisse. Le calcul : $36\,339\,317 - 36\,073\,185 = 266\,132$ FCFA, soit +0,74 % de surévaluation si l'on ne nettoie rien. La TVA, les retours et les arrondis sont cohérents dans ce fichier.

Q12 — c) 38 (42 lignes – 3 de chapeau – 1 d'en-tête). Un candidat qui répond 42 a importé le document, pas les données.

Q13 — b. Le fichier est intact, la lecture est mal réglée. Réflexe : changer l'encodage à **l'import**, jamais réenregistrer le brut.

Q14 — c). Avant l'outil et avant le graphique : la décision. Un tableau de bord sans décision associée ne sera pas ouvert après deux semaines.

Q15 — b). Le chiffre est exact (décembre 5 292 517 FCFA, mai 1 258 801, ratio 4,2), l'inférence ne l'est pas : l'extrait contient 40 lignes par mois, tous les mois ne sont donc pas représentés proportionnellement à leur activité réelle. Réponse d'analyste : « sur cet extrait, décembre domine ; pour conclure sur la saisonnalité, il faut le fichier complet du magasin ».

Seuil et rythme. 12 bonnes réponses sur 15 = 6/8 (correctif : 14/20 au total de l'évaluation, pas au quiz seul si l'étude de cas est pleine). Un score ≤ 8 sur 15 indique une relecture ciblée : Q1-Q4 ratées → C02 ; Q5-Q9 → C03 ; Q10-Q13 → C04-C05 ; Q14-Q15 → C06-C07.

C. Exercices — corrigés détaillés

C.1. Séparateur ; · 13 colonnes · ligne 2 = « ticket T05-250101-075845, Plâtre de construction 25 kg — réf 1, 11 unités, montant en texte 56 658 » · anomalie sans calcul : le 0.0 du client de la ligne 3 (comptoir), ou l'espace de milliers dans 51 802, ou une date 12/01/2025 ailleurs. Sont également recevables : les lignes en double visibles au tri sur `n_ticket`, et le libellé « ... — réf 1 » (deux informations dans une cellule). Ce qui ne l'est pas : « il y a des erreurs » (non localisé).

C.2. Les trois formules, et la logique derrière :

<code>=NBVAL(A2:A490)</code>	→ 489	lignes de données (contrôle de l'import : pas de ligne perdue)
<code>=NB(M2:M490)</code>	→ 3	montants réellement numériques
<code>=NB.SI(B2:B490;"?*//*")</code>	→ 65	dates écrites en JJ/MM/AAAA

Le correcteur vérifie la **cohérence des trois** : $489 = 480 + 9$ (doublons) et $486 = 489 - 3$ (montants texte). Un candidat qui obtient 488 lignes a mal importé (première ligne utilisée comme en-tête ou ligne vide finale).

C.3. Recettes, dans l'ordre : (1) import en texte · (2) `ttc_num = CBI(SUPPSPACE(SUBSTITUE(colonne;" ";"")))`, contrôle `=NB(colonne d'erreurs) = 0` · (3) tri sur toutes les colonnes puis suppression des doublons stricts → 480 lignes · (4) détection des dates par le 5^e caractère et reconstruction en ISO des 65 lignes concernées · (5) quantités > 500 divisées par 1 000 (7 lignes, max 14 000 → 14) · (6) `client` laissé en l'état, avec une note : 18 vides, et les 0 = comptoir · (7) total : **36 073 185 FCFA**. Comparaison finale : `=SOMME` du fichier attendu (même fichier, 480 lignes) — égalité demandée à 0 FCFA près, non négociable : si l'écart n'est pas nul, une ligne a été supprimée à tort (le cas habituel : les 7 lignes de quantité, traitées en correction au lieu d'un marquage).

C.4. Import : ;, encodage Windows-1252, 3 lignes sautées, colonne `prix_unitaire` en texte puis `SUBSTITUE(cellule;".";",")` et remplacement de la virgule par le point avant conversion → 38 lignes, 6 colonnes. Moyenne **11 155 FCFA**, maximum **34 826 FCFA**, TVA 0,18 partout. Contrôles demandés : nombre de lignes (38), aucune valeur nulle, et `prix × 1,18` cohérent avec une grille interne si l'apprenant la consulte (bonus de méthode, pas de résultat).

D. Étude de cas — cinq cadrages attendus

Les cinq réponses ci-dessous sont des **modèles de rendu**, pas des réponses uniques : un candidat peut formuler autrement, à condition de conserver les cinq composants et la limite. Les numéros de lignes et de colonnes cités existent dans le socle fourni.

1. « On est trop chers ? » Décision : réviser la grille avant la campagne de décembre (direction commerciale, arbitrage avant le 30/11). Question analytique : « Entre 2023 et 2025, le prix moyen HT des 154 références a-t-il évolué moins vite que leur coût d'achat HT (couts_achat.csv, 1 694 lignes), et dans quelle proportion l'écart de marge brute s'explique par la remise plutôt que par le prix ? » Tables : ventes, produits, couts_achat. Manquant : **le prix des concurrents** — aucune donnée externe dans le jeu ; seule une étude terrain (20 références relevées au marché) le fournirait, à chiffrer comme tâche distincte. Outil : SQL ou tableur selon le volume ; motif : « calcul de taux sur 240 000 lignes ». Le point de lucidité attendu : dire que « trop cher » ne se mesure pas **dans ces données**, et proposer le relevé terrain comme complètement — c'est ce qui distingue un cadrage d'une promesse.

2. « Bationo vend trop bien, faut l'augmenter ? » Décision : politique de prime, direction générale, avant le prochain trimestre. Question analytique : « Sur 2025 (extrait magasin 5), le CA TTC et le **nombre de tickets distincts** par vendeur placent-ils A. Bationo en tête après retrait des 9 doublons, et cet écart tient-il au panier moyen (114 156 FCFA) ou au volume de tickets ? » Tables : ventes, vendeurs.csv (22). Manquant : vendeur n'existe que sur l'extrait du magasin 5 (4 vendeurs sur 22) ; la comparaison à l'ensemble des vendeurs suppose le fichier complet ; et une prime se discute avec la **marge**, non le CA — la marge nette n'est pas calculable (aucun coût de structure). Outil : tableur, motif : « échantillon, un seul chiffre à défendre ». Rendu attendu : sur l'extrait, Bationo = 11 370 350 FCFA (31,5 % du total), devant Sankara 9 423 281, Ouédraogo 8 483 019, Ilboudo 6 796 535 FCFA — et la phrase qui dit que ce n'est **pas** une preuve de performance sans le fichier complet ni la marge.

3. « En janvier, on ne vend rien / ça bosse. » Décision : caler les congés et les tournées du premier mois. Question analytique : « Sur l'année 2025, le CA de janvier (2 051 424 FCFA sur l'extrait) est-il dans le bas de la distribution des douze mois, et l'écart s'explique-t-il par le nombre de jours ouverts ou par le CA par jour ? » Tables : ventes, dim_date.csv (1 339 lignes, 12 colonnes, drapeaux dimanche/férié). Manquant : les jours d'ouverture réels ne sont pas dans le jeu (dim_date donne les dimanches et les fêtes, pas les fermetures exceptionnelles) ; et l'extrait ne contient que 40 lignes par mois. Outil : tableur, motif : « 12 lignes, un graphique suffit ». Le point de méthode attendu : distinguer « peu de lignes » de « peu de ventes » — sur un extrait mensuel fixe, la question devient un ratio, plus un total.

4. « Fermer le dépôt le dimanche ? » Décision : horaires d'exploitation, direction + exploitation, effet au 1^{er} janvier. Question analytique : « Un dimanche sur deux dans l'extrait des ventes : combien de tickets et quel CA sont réalisés un dimanche par le dépôt (id_magasin = 6) et par les magasins qu'il approvisionne ? » Tables : ventes, dim_date (colonne est_dimanche), magasins (6 lignes). Manquant : le jeu ne contient **pas** de flux physique dépôt → magasins (les transferts ne sont pas saisis), donc l'impact sur les ruptures est inconnu ; et stocks_quotidiens.csv couvre 60 000 lignes d'extrait, pas le champ complet. Outil : SQL, motif : « compte sur un gros fichier + jointure calendrier ». Rendu attendu : poser la question du **coût évité** (indisponible dans le jeu) autant que du chiffre d'affaires perdu — un cadrage qui ne voit que le CA est incomplet.

5. « Le magasin 5, combien il rapporte ? » Décision : arbitrer un investissement dans ce point de vente. Question analytique : « Que vaut le CA TTC 2025 du magasin 5 sur le fichier complet (à distinguer des 36 073 185 FCFA de l'extrait), et quelle **marge brute** — somme de (prix de vente – coût d'achat) par ligne — en FCFA et en pourcentage ? » Tables : ventes_propres.csv (240 000 lignes), couts_achat.csv, magasins.csv. Manquant : marge **nette** impossible (loyer, salaires, transport absents) ; objectifs_de_ca.csv compte 218 lignes, donc des mois sans cible. Outil : SQL ou Python, motif : « jointure sur 240 000 lignes et contrôle de to-

taux ». Le point le plus noté : le candidat qui **refuse** le mot « rapporte » sans le définir (CA ? marge brute ? marge nette ?) et demande la décision cachée derrière.

Total et décision d'orientation

Trois seuils, trois décisions. - **Quiz : 14/20 minimum.** En dessous, ne passez pas en M02 : les statistiques appliquées (M02) reposent mot pour mot sur la distinction type/format et sur le vocabulaire donnée-information. Reprenez C02 (frontières du vocabulaire) et C04 (types, formats), puis re-passez le quiz en entier — pas seulement les items ratés, parce que la mémoire des réponses fausses fausse la seconde tentative. - **Étude de cas : 12/20 minimum.** En dessous, le savoir est là mais le réflexe professionnel non : refaites les cinq demandes du projet M01.P qui portent sur le cadrage, et l'exercice guidé de C07, puis re-passez cette seule partie. - **Projet : 13/20 minimum** (barème dans 03_exercices/M01_projet.md). Un projet non rendu ne se compense par aucune note.

Entre 14 et 16 au quiz avec l'étude de cas réussie, passez en M02 en reprenant C04 avant son deuxième chapitre : les statistiques vous sembleraient obscures pour de mauvaises raisons. Cette règle de remédiation est la même pour les 21 modules suivants ; c'est l'une des rares choses du parcours qui ne se négocie pas.