

MANUEL PROFESSIONNEL · ÉDITION 2026

Module M02 — Statistiques descriptives et inférence

La Voie des Données · Édition 2026 · 8 chapitres, 5 exercices guidés et leur corrigé par chapitre, 4 mini-projets, projet de module noté

Analyse de données appliquée & Business Intelligence
10 partie(s) assemblée(s) · document de production

Table des matières

MODULE M02.C01 — POPULATION, ÉCHANTILLON, INDIVIDU, VARIABLE, MODALITÉ, FRÉQUENCE	8
1. Objectifs du chapitre	8
2. Pourquoi cette notion est importante	8
3. Explication simple	9
4. Vocabulaire essentiel	9
5. Cours approfondi	10
5.1 Les cinq questions qui précèdent tout calcul	10
5.2 Population et échantillon : deux noms, un écart à déclarer	10
5.3 L'individu n'est pas la ligne	11
5.4 Variable, modalité, cardinalité : trois mots, trois usages	11
5.5 Effectif et fréquence : le calcul, et son total qui doit tomber juste	12
5.6 Deux fréquences qui se discutent, et pourquoi elles se discutent	13
5.7 Comment un échantillon se construit — et ce que chaque méthode coûte	13
6. Exemple concret : le même fichier, trois descriptions	14
7. Démonstration pas à pas : produire la fiche d'identité statistique	14
8. Erreurs fréquentes	15
9. Bonnes pratiques professionnelles	16
10. Exercice guidé — la fiche d'identité, ensemble, en 25 minutes	16
11. Exercices autonomes	17
12. Correction détaillée	17
13. Mini-projet M02.P1 — « La fiche d'identité statistique du fichier complet » (50 min)	18
14. Résumé du chapitre	18
15. À retenir	19
16. Évaluation formative (auto-correction, 8 min)	19
MODULE M02.C02 — LES CENTRES : MOYENNE, MÉDIANE, MODE ; MINIMUM, MAXIMUM, ÉTENDUE	21
1. Objectifs du chapitre	8
2. Pourquoi cette notion est importante	8
3. Explication simple	9
4. Vocabulaire essentiel	9
5. Cours approfondi	10
5.1 Les formules, sans mystère	23
5.2 Les trois centres sur le fichier du module : lire les écarts	23
5.3 La médiane a un effet de seuil, la moyenne un effet de niveau	24
5.4 Moyenne simple, moyenne pondérée : la colonne remise le démontre	24
5.5 Le cas d'école : tickets simples contre paniers composés	24
5.6 Minimum et maximum ne sont pas des bornes métier	25
5.7 Calculer les six nombres dans les trois outils	25
6. Exemple concret : le même indicateur, quatre énoncés	26
7. Démonstration pas à pas : les six nombres, trois outils, un contrôle	26

8. Erreurs fréquentes	15
9. Bonnes pratiques professionnelles	16
10. Exercice guidé — le trio moyenne / médiane / mode, ensemble	28
11. Exercices autonomes	17
12. Correction détaillée	17
13. Mini-projet M02.P2 — « Deux pages, six nombres, une décision » (45 min)	30
14. Résumé du chapitre	18
15. À retenir	19
16. Évaluation formative (auto-correction, 10 min)	31
M02.C03 — MESURER LA DISPERSION : ÉTENDUE, INTERVALLE INTERQUARTILES, ÉCART-TYPE	33
1. Objectifs du chapitre	8
2. Pourquoi cette notion est importante	8
3. Explication simple	9
4. Vocabulaire essentiel	9
5. Cours approfondi	10
5.1 Trois dispersions, trois usages	35
5.2 D'où vient l'écart-type, et pourquoi il a des décimales	35
5.3 L'IQR et la règle des 1,5 : une borne qui résiste à ce qu'elle détecte	36
5.4 Comparer deux colonnes : le coefficient de variation	36
5.5 Par catégorie : où la moyenne est-elle descriptive ?	37
5.6 L'erreur type : de combien votre moyenne est-elle fautive ?	38
5.7 Deux dispersions robustes, et ce que leur écart apprend	38
5.8 Quel outil pour quelle dispersion	39
6. Exemple concret : négocier le bois de chauffage, ou non	39
7. Démonstration pas à pas : les trois dispersions, trois outils, un contrôle	40
8. Erreurs fréquentes	15
9. Bonnes pratiques professionnelles	16
10. Exercice guidé — trois dispersions sur la colonne des prix	41
11. Exercices autonomes	17
12. Correction détaillée	17
13. Mini-projet M02.P2 — suite : la colonne « précision » (30 min)	43
14. Résumé du chapitre	18
15. À retenir	19
16. Évaluation formative (auto-correction, 10 min)	31
M02.C04 — SE SITUER : QUARTILES, DÉCILES, PERCENTILES, LECTURE DU BOX-PLOT	45
1. Objectifs du chapitre	8
2. Pourquoi cette notion est importante	8
3. Explication simple	9
4. Vocabulaire essentiel	9
5. Cours approfondi	10

5.1 Un percentile est un rang, pas une valeur	47
5.2 Le calcul, puis la divergence des logiciels	47
5.3 Retourner le calcul : du montant au percentile	48
5.4 Lire une boîte à moustaches	49
5.5 Déciles et concentration : ce que porte la pyramide	49
5.6 Décider avec les percentiles : trois usages types	50
5.7 Quels percentiles publier, lesquels garder	50
5.8 Calculer les positions dans les trois outils	51
6. Exemple concret : la livraison gratuite, décidée au percentile	52
7. Démonstration pas à pas : tracer la boîte vous-même	52
8. Erreurs fréquentes	15
9. Bonnes pratiques professionnelles	16
10. Exercice guidé — les cinq nombres, puis le dessin	54
11. Exercices autonomes	17
12. Correction détaillée	17
13. Mini-projet M02.P2 — suite : la page des positions (30 min)	55
14. Résumé du chapitre	18
15. À retenir	19
16. Évaluation formative (auto-correction, 10 min)	31
M02.C05 — LA FORME D'UNE DISTRIBUTION : HISTOGRAMME, ASYMÉTRIE, VA- LEURS EXTRÊMES	57
1. Objectifs du chapitre	8
2. Pourquoi cette notion est importante	8
3. Explication simple	9
4. Vocabulaire essentiel	9
5. Cours approfondi	10
5.1 Une distribution, trois miroirs	59
5.2 Construire l'histogramme : les trois décisions	59
5.3 L'asymétrie : combien de queue à droite	61
5.4 Le kurtosis : ce que les queues racontent	61
5.5 Trois sortes de valeurs extrêmes, trois traitements	62
5.6 Commenter une forme en cinq phrases — grille de rédaction	62
5.7 Ce que cette forme interdit de faire	62
5.8 Représenter la forme : quelle figure pour quelle question	63
6. Exemple concret : « nos clients ne sont pas comme ça »	63
7. Démonstration pas à pas : des comptes de classes à la bosse	64
8. Erreurs fréquentes	15
9. Bonnes pratiques professionnelles	16
10. Exercice guidé — refaire les classes, et voir ce qui change	65
11. Exercices autonomes	17
12. Correction détaillée	17
13. Mini-projet M02.P2 — suite : la page de forme (30 min)	67
14. Résumé du chapitre	18
15. À retenir	19

16. Évaluation formative (auto-correction, 12 min)	68
M02.C06 — RELIER DEUX VARIABLES : COVARIANCE, CORRÉLATION, CAUSALITÉ, PARADOXES	69
1. Objectifs du chapitre	8
2. Pourquoi cette notion est importante	8
3. Explication simple	9
4. Vocabulaire essentiel	9
5. Cours approfondi	10
5.1 La covariance, ou mesurer sans unité	71
5.2 Le coefficient de corrélation, et ce qu'il mesure vraiment	71
5.3 Rang contre valeur : Spearman	72
5.4 La droite de régression : trois nombres et une interdiction	73
5.5 Corrélation n'est pas causalité : les quatre configurations	74
5.6 Contrôler la variable de confusion — et le paradoxe de Simpson	74
5.7 Agrégation : pourquoi les corrélations montent quand on résume	75
5.8 Calculer les liaisons : quel outil, quelle formule	75
6. Exemple concret : « la remise fait-elle vendre plus gros ? »	76
7. Démonstration pas à pas : du nuage au coefficient, puis au contrôle	77
8. Erreurs fréquentes	15
9. Bonnes pratiques professionnelles	16
10. Exercice guidé — la liaison quantité / montant, entièrement refaite	78
11. Exercices autonomes	17
12. Correction détaillée	17
13. Mini-projet M02.P3 — « La page des liaisons » (50 min)	80
14. Résumé du chapitre	18
15. À retenir	19
16. Évaluation formative (auto-correction, 12 min)	68
M02.C07 — HASARD ET INCERTITUDE : PROBABILITÉS DE BASE, ÉCHANTILLONNAGE, BIAIS	82
1. Objectifs du chapitre	8
2. Pourquoi cette notion est importante	8
3. Explication simple	9
4. Vocabulaire essentiel	9
5. Cours approfondi	10
5.1 Hasard, fréquence, probabilité : trois règles suffisent	84
5.2 Ce que le hasard ajoute : la distribution d'échantillonnage	84
5.3 Ce que le hasard ne pardonne pas : le biais	85
5.4 Cinq familles de biais, et leur trace dans notre fichier	86
5.5 L'intervalle de confiance : ce que « 95 % » veut dire	87
5.6 Le bootstrap : remesurer sans retourner sur le terrain	87
5.7 Combien de tickets faut-il mesurer ?	88
5.8 Corriger après coup, et choisir l'outil	89
6. Exemple concret : « le panier moyen du magasin 5, à quoi bon le discuter ? »	90
7. Démonstration pas à pas : de la règle d'extraction à l'intervalle	90

8. Erreurs fréquentes	15
9. Bonnes pratiques professionnelles	16
10. Exercice guidé — mesurer l'incertitude d'un panier moyen	92
11. Exercices autonomes	17
12. Correction détaillée	17
13. Mini-projet M02.P4 — « La page d'incertitude » (45 min, premier volet ; M02.C08 enchaîne)	93
14. Résumé du chapitre	18
15. À retenir	19
16. Évaluation formative (auto-correction, 12 min)	68
M02.C08 — DÉCIDER AVEC INCERTITUDE : INTERVALLE DE CONFIANCE, TESTS, INTERPRÉTATION ET LIMITES	96
1. Objectifs du chapitre	8
2. Pourquoi cette notion est importante	8
3. Explication simple	9
4. Vocabulaire essentiel	9
5. Cours approfondi	10
5.1 La charpente d'un test, en cinq mouvements	98
5.2 Choisir le test d'après la question et le grain	98
5.3 Comparer deux moyennes : le t de Welch, et l'intervalle qui va avec	99
5.4 Ce que notre étude peut détecter : puissance et marge de détection	100
5.5 Deux tests, deux réponses : que faire quand ils divergent	100
5.6 Fréquences et associations : le chi-deux	101
5.7 Comparaisons multiples : le piège qui fausse tout le reste	102
5.8 Les limites du test, et les outils	102
6. Exemple concret : « qui met-on sur le tableau d'honneur ? »	103
7. Démonstration pas à pas : de la question au verdict	104
8. Erreurs fréquentes	15
9. Bonnes pratiques professionnelles	16
10. Exercice guidé — trancher une comparaison de vendeurs de bout en bout	105
11. Exercices autonomes	17
12. Correction détaillée	17
13. Mini-projet M02.P4 — « La page d'incertitude » (45 min, second volet)	107
14. Résumé du chapitre	18
15. À retenir	19
16. Évaluation formative (auto-correction, 12 min)	68
PROJET M02.P — « PROFIL STATISTIQUE DU MAGASIN 5 »	110
1. Énoncé	110
Le matériel	110
Les six livrables	110
Contraintes de rendu	111
2. Barème détaillé	111
3. Correction pas à pas (corrigé enseignant)	112
3.1 — L1 : l'identité statistique, telle qu'elle doit être rendue	112

3.2 — L2 : centres et dispersion	112
3.3 — L3 : positions et forme	112
3.4 — L4 : liaisons	113
3.5 — L5 : incertitude, tests, décision	113
3.6 — L6 : les trois anomalies, écrites comme attendu	114
4. Grille d'auto-évaluation avant rendu	114
5. Ce que le correcteur regardera en premier	115
ÉVALUATION M02 — « STATISTIQUES DESCRIPTIVES ET INFÉRENCE »	116
A • Questions de récupération (non notées)	116
B • Quiz (20 questions • 20 points)	116
Bloc 1 — Population, échantillon, biais (Q1 à Q5)	117
Bloc 2 — Centres (Q6 à Q8)	117
Bloc 3 — Dispersion et positions (Q9 à Q12)	117
Bloc 4 — Formes et liaisons (Q13 à Q16)	117
Bloc 5 — Estimation et tests (Q17 à Q20)	118
C • Exercices pratiques (2 séries • 55 min • auto-correction exigée)	118
D • Étude de cas (20 points • seuil 12 • 60 min)	119
Le dossier	119
Les quatre livrables demandés	119
Ce que le correcteur attend, ligne à ligne	119
Corrigé	119
B • Quiz — réponses et explications	119
C • Exercices pratiques — corrigés	120
D • Étude de cas — éléments de réponse attendus	121
Total et décision d'orientation	121

Module M02.C01 — Population, échantillon, individu, variable, modalité, fréquence

Outil de ce chapitre : un tableur et une base SQL, au choix ; aucun logiciel de statistiques. Durée indicative : 4 h. Niveau : N1.

L'idée du chapitre. Avant de calculer quoi que ce soit, il faut savoir **de quoi l'on parle** : sur combien de choses, sur lesquelles de ces choses, et si ce que l'on a sous la main ressemble à ce que l'on voudrait connaître. Ces cinq mots — population, individu, échantillon, variable, modalité — ne sont pas du vocabulaire scolaire : ce sont les cinq lignes d'en-tête de tout travail qui engage une décision. Une moyenne calculée sur le mauvais objet est juste, et fautive à la fois ; c'est précisément ce qui rend le chapitre obligatoire avant les sept suivants.

Base de travail — deux chemins pour une seule donnée. Les fichiers du module vivent à deux endroits, et il faut le trancher une fois pour toutes. Dans l'atelier du manuel — le dépôt qui contient ces fichiers — ils sont sous `01_socle_donnees/data/`. Chez vous, copiez-les dans votre dossier de module et rangez-les dans deux sous-dossiers, `donnees/projection/` pour le fichier de l'énoncé et `donnees/reference/` pour l'attendu et les référentiels. **Les blocs de code des huit chapitres écrivent le chemin de l'atelier, parce que c'est celui qui s'exécute sans préparation** : si vous travaillez dans votre dossier, remplacez le préfixe `01_socle_donnees/data/` par `donnees/` et ne changez rien d'autre. Séparateur point-virgule, encodage UTF-8, montants en franc CFA (FCFA), virgule décimale au tableur. Tous les chiffres cités dans le module sont lisibles dans `01_socle_donnees/data/reference/chiffres_cites.md`, section M02.

1. Objectifs du chapitre

À la fin de ce chapitre, vous saurez :

1. **Nommer** la population, l'échantillon, l'individu, la variable et la modalité d'un jeu de données donné, sans hésiter sur les deux derniers.
2. **Compter** ce que vous avez : effectif total, effectifs par modalité, fréquences en pourcentage, et les écrire avec l'unité.
3. **Distinguer** une ligne d'un individu statistique, et dire lequel des deux compte pour la question posée.
4. **Repérer** une variable à une seule modalité dans un extrait et expliquer ce que cela interdit comme conclusion.
5. **Écrire** la fiche d'identité statistique d'un fichier — celle qui, en entreprise, se joint au chiffre et le rend défendable.

2. Pourquoi cette notion est importante

Situation 1 — la réunion qui dérape sur un mot. Un responsable commercial annonce : « notre panier moyen est à 114 156 FCFA ». Un autre répond : « c'est faux, je vends tous les jours à des clients qui repartent avec moins de 60 000 ». Aucun des deux n'a tort : le premier a calculé une moyenne sur des tickets, le second pense au ticket le plus courant. La dispute n'est pas un désaccord de chiffres mais **un désaccord d'objet** — sur quoi porte le compte. Ce chapitre règle ces disputes avant qu'elles n'aient lieu.

Situation 2 — le rapport qui ne dit pas ce qu'il couvre. Vous remettez un document qui affirme « 29,8 % des lignes concernent les Matériaux ». Trois remarques peuvent arriver, et elles arrivent : sur quelles lignes ?, sur quelle période ?, et si l'on compte les tickets au lieu des lignes ?. Un rapport qui répond à ces trois questions dans son premier paragraphe met son lecteur en confiance ; un rapport qui n'y répond pas laisse le doute travailler pour lui.

Situation 3 — l'échantillon qui ne représente rien. Vous disposez du fichier complet de quatre années (240 000 lignes propres), mais votre extrait de travail en contient 480 — 0,2 % des lignes. Ce n'est pas un problème en soi : c'est un fait à **dire**. Le problème commence quand on écrit « décembre est notre meilleur mois » comme si l'on avait parlé de l'entreprise, alors que l'on a parlé d'un extrait construit à des fins pédagogiques, à raison de 40 lignes par mois.

Dans les faits. La règle « sur un échantillon, on ne conclut pas sur la population » n'est pas une coquetterie de statisticien : c'est ce qui sépare une analyse d'une rumeur chiffrée. Dans les grandes organisations, les chiffres qui circulent sans mention de périmètre finissent par produire deux tableaux de bord qui se contredisent, et des réunions qui arbitrent au lieu de décider.

3. Explication simple

Imaginez un marché, un samedi matin. Vous voulez savoir « ce que vend le marché ». Vous ne pouvez pas tout voir : vous vous postez à **un** étal, pendant **une** heure, et vous notez chaque vente sur un carnet.

- **Le marché entier, toutes les ventes de toutes les journées** : c'est la **population** — l'ensemble que vous aimeriez décrire.
- **Les ventes que vous avez réellement notées** : c'est l'**échantillon** — la partie visible, celle sur laquelle vous calculez.
- **Chaque vente notée sur une ligne du carnet** : c'est un **individu** statistique — l'unité sur laquelle on compte. Pas le client, pas l'objet vendu : la vente, si c'est elle que vous avez décidé de compter.
- **Une caractéristique que vous notez à chaque fois** (le montant, l'étal, l'heure) : c'est une **variable**.
- **Une valeur prise par cette variable** (« légumes », « 1 500 FCFA ») : c'est une **modalité**.
- **Combien de fois apparaît une modalité** : c'est l'**effectif** ; ramené au total, c'est la **fréquence**.

Tout le reste du manuel applique ce petit vocabulaire. Un tableau de statistiques mal lu est presque toujours un tableau où l'individu n'était pas celui que le lecteur imaginait.

4. Vocabulaire essentiel

Français — English	Définition simple	Piège à éviter
Population — population	L'ensemble complet des choses que l'on voudrait décrire.	La confondre avec le fichier ouvert : le fichier n'est souvent qu'un extrait.
Individu — statistical unit / record	L'unité que l'on compte : une ligne, un ticket, un client, un mois, selon la décision prise.	Compter des lignes en croyant compter des clients.
Échantillon — sample	La partie réellement observée de la population.	Oublier de dire comment il a été choisi : le mode de choix décide de ce qu'il autorise.

Français — English	Définition simple	Piège à éviter
Recensement — census	Observer toute la population, sans échantillon.	Croire qu'un gros fichier est un recensement : 240 000 lignes peuvent n'être qu'un mois.
Variable	Une caractéristique relevée pour tous les individus (une colonne).	Appeler « variable » un identifiant : il varie, mais ne mesure rien.
Modalité — value / category	Une valeur possible d'une variable (« Peinture », 0,04, vrai).	Compter les modalités comme des individus.
Effectif — count / frequency count	Combien d'individus prennent cette modalité.	Donner un effectif sans dire sur combien de lignes il porte.
Fréquence — relative frequency	Effectif divisé par l'effectif total, en pourcentage.	Arrondir chaque ligne à l'entier et obtenir 99 % ou 101 % au total.
Cardinalité — cardinality	Nombre de modalités distinctes d'une variable.	Une cardinalité de 1 dans un extrait : elle interdit la comparaison qu'on voulait faire.
Représentativité — representativeness	Propriété d'un échantillon qui ressemble à sa population sur les variables qui comptent.	La revendiquer sans la discuter : elle s'examine, elle ne se décrète pas.

5. Cours approfondi

5.1 Les cinq questions qui précèdent tout calcul

Avant la moindre formule, un professionnel écrit cinq lignes. Sur le fichier de travail de ce module — l'extrait nettoyé de 480 lignes du magasin 5 pour 2025 — cela donne :

1. **Quelle population ?** Les ventes du magasin 5, sur l'année 2025, telles que la caisse les a enregistrées.
2. **Quel individu ?** La ligne de ticket (un article facturé), parce que le fichier est livré à ce grain.
3. **Quel échantillon ?** 480 lignes, construites à raison de 40 lignes par mois, dans un fichier complet de 240 000 lignes propres.
4. **Quelles variables ?** 13 colonnes : `n_ticket`, `date`, `heure`, `magasin`, `vendeur`, `client`, `produit`, `categorie`, `quantite`, `prix_unitaire_ht`, `remise`, `montant_ht`, `montant_ttc`.
5. **Quelles modalités compte-t-on ?** Selon la question : 7 catégories, 4 vendeurs, 145 produits, 372 clients distincts (hors vides), 1 magasin.

Ces cinq lignes occupent trois minutes. Elles suppriment la moitié des allers-retours d'une analyse, et elles se recopient mot pour mot dans la note qui accompagne le chiffre.

5.2 Population et échantillon : deux noms, un écart à déclarer

Définition. Population — population — l'ensemble complet des individus que l'on voudrait décrire. Elle est presque toujours inatteignable : ce que l'on a sous la main est un fichier, un mois, un magasin.

Définition. Échantillon — sample — la partie réellement observée de la population, sélectionnée par une règle. Ce qui la rend utilisable n'est pas sa taille mais sa **description** : sans la règle de sélection écrite, aucun pourcentage ne peut être discuté, seulement cru.

Un échantillon n'est pas « un petit morceau au hasard des fichiers » : c'est un morceau **choisi par quelque chose**. Ici, le choix est explicite : 40 lignes par mois, en prenant les premières du

mois après tri par date. Ce mode de fabrication a une conséquence que vous devez savoir énoncer : la **répartition mensuelle est forcée** — chaque mois pèse le même poids (40 lignes sur 480, soit 8,3 %), alors que dans la population les mois ne pèsent pas pareil. Un graphique de la répartition par mois sur cet extrait est donc **faux d'office** sur une seule question : « quel mois vend le plus ? » — et parfaitement utilisable sur une autre : « comment se répartissent les catégories de produits ? ».

À retenir. La bonne question n'est jamais « l'échantillon est-il petit ? » mais « **sur quoi le mode de fabrication fausse-t-il le raisonnement ?** ». Un échantillon de 480 lignes bien décrit répond à six questions ; un échantillon de 240 000 lignes mal décrit n'en répond correctement à aucune.

5.3 L'individu n'est pas la ligne

Le fichier contient 480 lignes et 316 tickets : un ticket porte en moyenne 1,52 ligne, certains jusqu'à 4. Les deux objets sont légitimes, mais ils ne répondent pas aux mêmes questions, et ils ne donnent pas les mêmes pourcentages.

Question	Individu à compter	Ce que l'on obtient
Combien d'articles sont facturés ?	la ligne	480
Combien de ventes (paniers) ?	le ticket	316
Quelle part des ventes comportent plusieurs articles ?	le ticket	104 sur 316, soit 32,9 %
Quelle catégorie domine le catalogue vendu ?	la ligne (ou le montant, si l'on pondère)	Matériaux, 143 lignes, 29,8 %

Un même fait, deux énoncés justes : les Matériaux sont la première catégorie **en lignes** (143 sur 480) ; ils ne le sont pas forcément **en montants**, et encore moins en nombre de tickets contenant au moins un article de la catégorie. La règle du métier : **on nomme l'individu avant de nommer le pourcentage**.

Définition. Tirage — sampling — la règle, écrite et reproductible, qui a sélectionné les individus de l'échantillon dans la population. Elle se note avec son effet attendu : « 40 premières lignes par mois après tri par date » dit à la fois ce qui a été pris et ce que cela écrase (les volumes relatifs des mois).

Attention. Une phrase comme « 30 % de nos clients achètent du bois » est doublement ambiguë : 30 % des lignes ou 30 % des clients ? Sur cet extrait, la seconde lecture n'est même pas calculable en l'état, parce que la colonne `client` est vide sur 103 lignes (18 cases vides et 85 ventes au comptoir codées 0). Nommer l'individu, c'est aussi vérifier qu'il est **identifiable** partout où l'on compte dessus.

5.4 Variable, modalité, cardinalité : trois mots, trois usages

Définition. Variable — variable — une caractéristique relevée pour **tous** les individus, c'est-à-dire une colonne dont on peut dire en une phrase ce qu'elle mesure et dans quelle unité.

Définition. Modalité — value, category — une valeur prise par la variable (« Peinture », 0,04, vide). Compter des modalités, ce n'est pas compter des individus : 6 remises différentes s'appliquent à 480 lignes.

Pour chaque colonne, on mesure trois choses — et elles s'écrivent dans un tableau, pas dans une conversation :

Colonne	Nature	Modalités distinctes (mesuré)	Ce que la cardinalité autorise ou interdit
magasin	qualitative nominale	1	Aucune comparaison entre magasins : elle est impossible, pas seulement déconseillée.
vendeur	qualitative nominale	4	Comparaison possible, mais sur 4 individus seulement : un « classement » n'a de sens que comme constat.
categorie	qualitative nominale	7	Répartition exploitable ; c'est la colonne reine de ce chapitre.
produit	qualitative nominale	145	Listes et classements ; jamais un graphique en secteurs (145 parts illisibles).
client	identifiant (nominal, quasi-continu)	372 distincts, 103 lignes sans client	Comptage d'objets, aucun calcul sur la valeur.
remise	quantitative discrète	6 modalités (0 ; 0,03 ; 0,04 ; 0,07 ; 0,08 ; 0,11)	Fréquences et moyenne pondérée : deux réponses différentes, les deux utiles.
quantite, montant_ht, montant_ttc, prix_unitaire_ht	quantitatives	respectivement 45, 456, 456 et 323 valeurs distinctes	Résumés de position et de dispersion : le chapitre suivant.
date, heure	quantitatives (ordinal pour date)	31 jours d'écriture, 12 mois	Analyses calendaires, à condition de se souvenir du tirage (5.2).

Une cardinalité de **1** est une information précieuse : elle dit qu'une variable ne portera aucune réponse comparative. Sur l'extrait, `magasin` vaut « Magasin 5 — Kaya Marché » sur les 480 lignes. Écrire « le magasin 5 réalise 36 073 185 FCFA » est vrai ; en déduire qu'il est « le meilleur magasin » est une faute de logique, pas d'arithmétique.

Définition. Cardinalité — cardinality — le nombre de modalités distinctes d'une variable. Elle ne se devine pas : elle se compte, et elle conditionne le choix du graphique autant que celui de la statistique.

Conseil professionnel. Faites tenir ce tableau dans une page, avec trois colonnes seulement : combien de modalités, y a-t-il des valeurs manquantes, quel calcul cette colonne autorise. C'est la fiche que l'on demande à un analyste qui reprend un dossier laissé par un autre, et c'est ce qui vous évitera de refaire le travail de quelqu'un d'autre dans trois mois.

5.5 Effectif et fréquence : le calcul, et son total qui doit tomber juste

La fréquence d'une modalité est son effectif divisé par l'effectif total. Sur les 480 lignes :

Catégorie	Effectif (lignes)	Fréquence
Matériaux	143	29,8 %
Quincaillerie	112	23,3 %
Consommables	57	11,9 %
Plomberie	57	11,9 %
Electricité	53	11,0 %

Catégorie	Effectif (lignes)	Fréquence
Peinture	34	7,1 %
Bois & panneaux	24	5,0 %
Total	480	100,0 %

Trois réflexes de rédaction, qui viennent de l'impression et non des mathématiques : on affiche les **effectifs** à côté des pourcentages (un pourcentage sans dénominateur ne se vérifie pas) ; on garde **une décimale**, pas trois ; on **additionne les pourcentages affichés** pour vérifier qu'ils retombent sur 100 — ici $29,8 + 23,3 + 11,9 + 11,9 + 11,0 + 7,1 + 5,0 = 100,0$ ✓. Si l'arrondi faisait manquer 0,1 point, on le dirait (« totaux légèrement différents de 100 % pour cause d'arrondi ») au lieu de retoucher une ligne au hasard pour que ça tombe juste.

5.6 Deux fréquences qui se discutent, et pourquoi elles se discutent

Les remises. 173 lignes sur 480 portent une remise, 307 n'en portent aucune : 64,0 % des lignes sont vendues au prix affiché. La moyenne simple des valeurs de la colonne est de 0,0185 (1,85 %), la moyenne **pondérée par les montants** est de 0,0172 (1,72 %). Les deux chiffres sont corrects ; ils répondent à deux questions différentes — « sur une ligne, quelle remise applique-t-on ? » et « sur un franc facturé, quelle remise concède-t-on ? ». La seconde est celle qui intéresse le directeur financier ; la première est celle qui intéresse le responsable de magasin. Un analyste qui ne connaît qu'une des deux se fera corriger en réunion.

Les dates. 480 lignes se répartissent sur 12 mois et 31 jours distincts, avec une particularité mesurée dans le fichier brut d'origine : 55 écritures de dates différentes pour 31 jours réels (12/01/2025 et 2025-01-12 désignent le même jour). Le nettoyage a ramené tout le monde à l'écriture ISO ; la fréquence par jour, elle, ne s'appuie que sur les 31 jours réellement présents dans l'extrait. Annoncer une fréquentation journalière moyenne sans dire que le tirage a forcé 40 lignes par mois serait une conclusion tirée d'un artefact de fabrication.

Attention. Le pourcentage qui suit le mot « la majorité » mérite le même contrôle que les autres. Sur ce fichier, « la majorité des lignes sont des Matériaux » est **faux** (29,8 %), alors que « deux lignes sur trois sont vendues sans remise » est **vrai** (64,0 %). Une majorité exige plus de 50 % ; une modalité dominante n'exige rien de plus que la première place, et le mot juste change le verdict.

5.7 Comment un échantillon se construit — et ce que chaque méthode coûte

Méthode	Ce qu'elle garantit	Ce qu'elle écrase
Tirage systématique (une ligne sur k)	une couverture du temps, de la simplicité	les structures fines ; faux si la source est périodique
Par strate (40 lignes par mois, par catégorie)	que chaque groupe sera représenté	les poids relatifs des groupes — c'est le cas ici
Aléatoire simple	l'absence de biais de choix	le risque de n'avoir aucune ligne d'un petit groupe
De convenance (« les premières lignes du fichier »)	rien	tout : la représentativité n'est pas même discutée

Le vocabulaire statistique complet de l'échantillonnage aléatoire (loi des grands nombres, intervalle d'estimation) tient au chapitre M02.C07. Ici, l'essentiel tient en une phrase : **on choisit une méthode, on la dit, et on écrit ce qu'elle écrase.**

Boîte à outils. Compter proprement, en trois outils : tableur `=NBVAL(plage)` pour l'effectif, `=NB.SI(plage;modalité)/NBVAL(plage)` pour la fréquence, et la formule de comptage des valeurs distinctes `=SOMMEPROD(1/NB.SI(plage;plage))` ; SQL (DuckDB) `SELECT categorie, COUNT(*) AS effectif, ROUND(100.0 * COUNT(*) / SUM(COUNT(*) OVER (), 1) AS freq_pct FROM ventes GROUP BY categorie ORDER BY effectif DESC ; ;` Python (pandas) `df["categorie"].value_counts(normalize=True).mul(100).round(1)`. Les trois doivent rendre le même tableau : quand ils divergent, ce n'est pas le logiciel qui a tort, c'est le périmètre qui a bougé.

6. Exemple concret : le même fichier, trois descriptions

Un collègue remet une note qui dit : « 145 produits, 372 clients, 29,8 % de Matériaux, un magasin ». Elle est juste et inutilisable, parce qu'elle ne dit pas ce qu'elle compte. Réécrivons la même information avec les cinq mots du chapitre, sur le fichier de 480 lignes :

- **Population visée** : les ventes du magasin 5 en 2025, à la ligne de ticket.
- **Échantillon observé** : 480 lignes (0,2 % des 240 000 lignes propres du socle), tirées à raison de 40 lignes par mois après tri par date.
- **Individu** : la ligne de ticket. Les 480 lignes portent 316 tickets (1,52 ligne par ticket, maximum 4), donc 32,9 % des tickets contiennent plusieurs articles.
- **Variables et cardinalités** : 7 catégories, 4 vendeurs, 145 produits, 372 clients distincts hors vides, 6 modalités de remise, 1 seul magasin.
- **Fréquences retenues** : Matériaux 143 lignes (29,8 %), Quincaillerie 112 (23,3 %), sans remise 307 (64,0 %).

Deux lignes de plus que la note du collègue, et la discussion d'après-réunion devient impossible — c'est le but.

7. Démonstration pas à pas : produire la fiche d'identité statistique

Nous fabriquons le document qui accompagnera tous vos chiffres du module. Douze minutes, deux outils.

Étape 1 — Ouvrir le bon fichier. `01_socle_donnees/data/reference/ventes_magasin5_2025_ATTENDU.csv` (480 lignes, séparateur ;, encodage UTF-8 avec BOM). Importez **toutes les colonnes en texte** : c'est le réflexe du chapitre M01.C04, il évite que le typage automatique ne décide à votre place.

Étape 2 — L'effectif, pas le nombre de lignes affichées. Dans le tableur, la formule `=NBVAL(A2:A481)` sur la colonne `n_ticket` renvoie 480. Notez-le : c'est le n de toutes les fréquences du document.

Étape 3 — Les individus qui ne sont pas des lignes. `=SOMMEPROD(1/COUNTIF(A2:A481;A2:A481))` renvoie 316 : le nombre de tickets distincts. Écrivez les deux chiffres côte à côte, avec leur nom — c'est la ligne qui tue l'ambiguïté « on compte quoi ? ».

Étape 4 — La cardinalité de chaque colonne. Appliquez la même formule de valeurs distinctes aux 13 colonnes. Le résultat doit donner, entre autres : 7 (catégories), 4 (vendeurs), 145 (produits), 372 (clients distincts non vides), 6 (remises), 31 (jours), 1 (magasin). Si une valeur vous surprend, c'est un défaut du fichier, pas de la formule : cherchez avant de publier.

Étape 5 — Les effectifs par modalité. Tableau croisé : lignes en valeur, `categorie` en ligne. Vous obtenez 143, 112, 57, 57, 53, 34, 24. Le total du croisé doit redonner 480 au FCFA et au compteur près : c’est le contrôle de cohérence, pas une formalité.

Étape 6 — Les fréquences. Divisez chaque effectif par 480 et multipliez par 100, une décimale. Le total des pourcentages affichés doit faire 100,0 %.

Étape 7 — Le contrôle par SQL. Dans la base du socle (`sahel.duckdb`), ou directement sur le fichier :

```
SELECT categorie,
      COUNT(*)
      ROUND(100.0 * COUNT(*) / SUM(COUNT(*) OVER (), 1)
            AS effectif,
            AS freq_pct
FROM read_csv('01_socle_donnees/data/reference/ventes_magasin5_2025_ATTENDU.csv', sep=';')
GROUP BY categorie
ORDER BY effectif DESC;
```

Sept lignes de requête, les mêmes sept résultats. L’exercice ne consiste pas à choisir le bon outil : il consiste à **ne pas avoir peur de vérifier avec deux**.

Étape 8 — Les manquants, nommés. `=NB.EUILL(F2:F481)` sur la colonne `client` renvoie 18 lignes vides ; 85 lignes portent la valeur 0 (le comptoir). Total : 103 lignes sans client identifié, soit 21,5 % de l’échantillon. Écrivez cette phrase dans la fiche, avec son pourcentage : un lecteur qui l’apprend en annexe la vit comme une cachisserie.

Étape 9 — Ce que le tirage écrase. Une ligne, à la fin de la fiche : « 40 lignes par mois : les volumes relatifs des mois ne sont pas comparables sur cet extrait. » C’est la seule ligne que personne d’autre écrira à votre place.

Étape 10 — Dater et signer. « Fiche établie le 17/09/2026 sur le fichier `ventes_magasin5_2025_ATTENDU.csv`, 480 lignes, empreinte non calculée. » La date et le nom du fichier sont ce qui rendra le document rejouable quand le fichier aura changé de nom, ce qui arrivera.

8. Erreurs fréquentes

Symptôme	Cause	Correction
Deux services publient des pourcentages différents sur « la même » données	l’individu n’est pas le même (lignes vs tickets vs clients)	nommer l’individu dans l’en-tête de chaque tableau ; le répéter dans la légende
Le total des pourcentages fait 99,6 % ou 100,4 %	arrondis cumulés, présentés sans mention	garder une décimale, additionner les valeurs affichées, mentionner l’arrondi si nécessaire
« La majorité des ventes sont des Matériaux »	modalité dominante confondue avec majorité absolue	exiger > 50 % pour « majorité » ; sinon écrire « première catégorie »
Un graphique en secteurs à 145 parts	cardinalité non consultée avant de choisir la visualisation	n’utiliser le camembert qu’à partir du moment où il y a moins de 6 modalités ; sinon un classement barres
Une conclusion sur « le magasin le plus performant » alors que l’extrait n’en contient qu’un	variable à cardinalité 1 prise pour une variable de comparaison	vérifier les cardinalités avant toute phrase comparative ; la fiche d’identité s’en charge
Des effectifs qui ne somment pas au total du fichier	lignes exclues silencieusement (filtre resté actif, en-têtes mal lus)	recalculer le total et l’afficher à côté de la somme des lignes du tableau

9. Bonnes pratiques professionnelles

- Écrivez la **phrase d'identité** en tête de tout livrable : population, individu, période, source, mode de tirage. Cinq segments, une ligne et demie.
- Un pourcentage sans dénominateur est une opinion : affichez l'effectif à côté, toujours.
- Comptez les valeurs distinctes **avant** de commenter une comparaison : une cardinalité de 1 ferme la question.
- Dites ce que le tirage écrase, en une phrase, même si personne ne l'a demandée.
- Gardez les lignes « sans client » dans les effectifs, et nommez-les : les exclure change le dénominateur et donc tous les pourcentages — ce choix doit être écrit, pas subi.
- Vérifiez un résultat par un second outil au moins une fois par dossier, et notez dans le journal que vous l'avez fait.
- Datez la fiche, nommez le fichier. Une fiche sans date est une légende urbaine.

10. Exercice guidé — la fiche d'identité, ensemble, en 25 minutes

Contexte. Votre responsable vous demande de « préparer le terrain » avant l'arrivée du consultant qui audite les pratiques de données du magasin. Il veut une page, pas un rapport.

Étape 1 — Fixer l'objet. Question posée : de quoi parle-t-on ? Réponse rédigée : « Des lignes de ticket facturées au magasin 5 de Sahel Distribution SA sur l'année 2025, telles que la caisse les a enregistrées. » Vous venez de nommer la population et l'individu. Notez-les dans le document, pas dans votre tête.

Étape 2 — Compter. Vous obtenez 480 lignes et 316 tickets. Pourquoi les deux chiffres ? Parce que la ligne est ce que le fichier contient, le ticket ce que le client a vécu, et que le consultant demandera lequel des deux a servi de base au calcul. Réponse écrite : « Effectif : 480 lignes de ticket ; 316 tickets ; 1,52 ligne par ticket en moyenne. »

Étape 3 — Cardinalités. 7 catégories, 4 vendeurs, 145 produits, 372 clients distincts (hors vides), 6 modalités de remise, 1 magasin. Que dit la dernière ? Que cet extrait ne peut rien dire sur la comparaison entre magasins — à écrire noir sur blanc, car c'est la question que le consultant posera en premier.

Étape 4 — Fréquences. Vous dressez le tableau des catégories (143, 112, 57, 57, 53, 34, 24 lignes), vous ajoutez la colonne des pourcentages, vous vérifiez que le total tombe à 100,0 %. Vous ajoutez une ligne « sans remise : 307 lignes, 64,0 % », parce que la remise est la variable qui fâche.

Étape 5 — Les manquants. 18 lignes sans client, 85 lignes au comptoir codées 0. Décision écrite : elles restent dans les effectifs (elles sont des ventes réelles), mais elles sortent de toute analyse par client — et donc, cette analyse-là porte sur 377 lignes, pas 480.

Étape 6 — La phrase de garde. « Extrait construit à raison de 40 lignes par mois : les volumes mensuels ne sont pas comparables entre eux sur ce fichier. » Cette phrase vaut à elle seule la fiche : elle désarme la mauvaise question au lieu de la traiter.

Résultat attendu : une page de dix lignes, sans un seul calcul de moyenne. Le consultant gagnera vingt minutes, vous en gagnerez trois semaines de crédibilité.

11. Exercices autonomes

Exercice 1.1 (★) — Les cinq lignes. Sur le fichier de 480 lignes, rédigez la phrase d'identité : population, individu, échantillon, variables, tirage. (attendu : 480 lignes, 316 tickets, 13 colonnes, 2025, 40 lignes par mois après tri par date ; la phrase fait 4 à 6 lignes)

Exercice 1.2 (★) — Deux dénombrements, deux questions. Calculez, en un tableur : le nombre de lignes, le nombre de tickets, le nombre de tickets comportant au moins deux lignes, et leur part. (attendu : $480 \cdot 316 \cdot 104 \cdot 32,9\%$)

Exercice 1.3 (★) — Le tableau des catégories. Effectifs et fréquences des 7 catégories, avec une décimale et la ligne de total. (attendu : 143 ; 112 ; 57 ; 57 ; 53 ; 34 ; 24 · 29,8 % ; 23,3 % ; 11,9 % ; 11,9 % ; 11,0 % ; 7,1 % ; 5,0 % · total 480 et 100,0 %)

Exercice 1.4 (★★) — La modalité qui interdit la conclusion. Une phrase par variable, pour dire ce qu'elle permet : magasin (1 modalité), vendeur (4), categorie (7), produit (145). (attendu : pas de comparaison possible entre magasins ; constat seulement sur 4 vendeurs ; répartitions et classements sur les catégories ; liste ou top-N sur les produits, jamais un graphique en secteurs)

Exercice 1.5 (★★) — Le dénominateur qui bouge. Calculez la part des lignes vendues sans remise, une fois sur les 480 lignes, une fois sur les 377 lignes portant un client identifié. Commentez les deux chiffres en deux phrases. (attendu : $307 / 480 = 64,0\%$ · $307 / 377 \approx 81,4\%$; le second chiffre parle des ventes identifiées, pas de l'ensemble ; changer de dénominateur sans le dire fabrique un désaccord)

12. Correction détaillée

Exercice 1.1. La phrase attendue tient en six segments : « Population : les lignes de ticket facturées au magasin 5 de Sahel Distribution SA en 2025. Individu : la ligne de ticket. Échantillon : 480 lignes, soit 0,2 % des 240 000 lignes propres du socle. Variables : 13 colonnes, de `n_ticket` à `montant_ttc`. Tirage : 40 lignes par mois après tri par date, ce qui égalise les mois. Source : `ventes_magasin5_2025_ATTENDU.csv`, fiche établie le 17/09/2026. » Ce qui est noté : la présence des cinq noms, et l'unité (lignes, pas ventes).

Exercice 1.2. Trois formules : `=NBVAL(A2:A481)` → 480 ; la formule de valeurs distinctes sur `n_ticket` → 316 ; `=NBVAL(A2:A481)/316` → 1,52. Pour les tickets multi-lignes, un tableau croisé de `n_ticket` en lignes avec « nombre » en valeur, puis un comptage des clés dont l'effectif dépasse 1 → 104, soit $104 / 316 = 32,9\%$. Le piège classique : compter les lignes supplémentaires ($480 - 316 = 164$) au lieu des tickets, ou diviser 104 par 480 au lieu de 316 — le dénominateur suit l'individu choisi, jamais la commodité : 104 tickets sur 316 ne se racontent pas « sur 480 ».

Exercice 1.3. Le tableau doit afficher, dans cet ordre décroissant : Matériaux 143 (29,8 %), Quincaillerie 112 (23,3 %), Consommables 57 (11,9 %), Plomberie 57 (11,9 %), Electricité 53 (11,0 %), Peinture 34 (7,1 %), Bois & panneaux 24 (5,0 %), total 480 (100,0 %). Deux égalités à vérifier : $143 + 112 + 57 + 57 + 53 + 34 + 24 = 480$ ✓, et $29,8 + 23,3 + 11,9 + 11,9 + 11,0 + 7,1 + 5,0 = 100,0$ ✓. À noter aussi : deux catégories sont à égalité parfaite à 57 lignes — un classement qui les départagerait sur la deuxième décimale inventerait une hiérarchie.

Exercice 1.4. Attendu, une ligne par variable : `magasin` — une seule modalité, donc aucune conclusion comparative possible sur cet extrait (la comparer supposerait d'ouvrir le fichier complet) ; `vendeur` — 4 modalités, un classement est descriptible mais instable (retirer un vendeur change tout) ; `categorie` — 7 modalités, répartitions et classements exploitables, graphique en barres horizontales ; `produit` — 145 modalités, on liste, on ne figure pas, et l'on travaille en top-N avec la part restante explicite (« autres : X lignes »).

Exercice 1.5. $307 / 480 = 64,0 \%$; $307 / 377 \approx 81,4 \%$. Commentaire attendu : le premier chiffre décrit l'ensemble des ventes ; le second ne décrit que les ventes où l'on sait à qui, et il est mécaniquement plus élevé parce que le comptoir, où la remise est rare, a quitté le dénominateur. Un chiffre qui bouge de 17 points par un changement de dénominateur doit être accompagné de son dénominateur à chaque fois qu'il est cité — sinon c'est un argument, plus une mesure.

13. Mini-projet M02.P1 — « La fiche d'identité statistique du fichier complet » (50 min)

Commande. Établissez, pour le fichier `01_socle_donnees/data/reference/ventes_propres.csv` (240 000 lignes, 4 années, 6 magasins), la fiche d'identité statistique au format du chapitre : population, individu, période couverte, variables et cardinalités, trois fréquences commentées, manquants nommés, tirage, date et source.

Livrables numérotés. (1) la fiche, une page ; (2) le tableau des effectifs et fréquences d'une variable au choix ; (3) le script ou les formules utilisés, collés en fin de page ; (4) deux phrases sur ce que la fiche empêche de conclure à tort.

Barème (20 points, seuil 13). Fiche complète, cinq rubriques (5) · effectifs et fréquences justes, total à 100,0 % (4) · cardinalités mesurées et non recopiées (3) · manquants chiffrés et nommés (3) · phrase sur le tirage ou la couverture (2) · traçabilité des calculs (2) · style : une page, pas deux (1). Le tout en 50 minutes chrono : si vous dépassez, votre tableau contient plus de lignes que nécessaire.

14. Résumé du chapitre

Statistiquement, un fichier ne dit rien de lui-même : il faut écrire ce qu'il représente. Cinq mots suffisent — population, individu, échantillon, variable, modalité — et un calcul : l'effectif, puis sa fréquence. Les trois quarts des disputes de chiffres naissent d'un individu mal nommé (lignes contre tickets contre clients), non d'une formule ratée. La cardinalité se mesure avant de commenter : à 1 modalité, la comparaison est fermée ; à 145, le graphique en secteurs est fermé. Les manquants restent dans le dénominateur tant qu'on ne l'écrit pas autrement, et un pourcentage ne se cite jamais sans son dénominateur. Enfin, le mode de tirage s'énonce avec son effet : ici, 40 lignes par mois signifient que les mois ne pèseront pas leur poids réel. Ce chapitre ne vous a pas appris à calculer une moyenne : il vous a appris à ne pas en calculer une sur le mauvais objet, ce qui est plus rare et plus utile.

15. À retenir

À retenir. 1. **Nommer l'individu avant tout pourcentage** : 480 lignes, 316 tickets, 372 clients — trois chiffres, tous justes, trois questions différentes. 2. **La population n'est pas le fichier** : l'extrait de 480 lignes couvre 0,2 % des 240 000 lignes propres, et le dire est ce qui rend le chiffre défendable. 3. **Une fréquence = un effectif ÷ un dénominateur** : citez les deux, vérifiez que les pourcentages additionnés retombent sur 100,0 %. 4. **La cardinalité commande** : à 1 modalité aucune comparaison, à 145 aucun camembert, à 7 toutes les répartitions. 5. **Le tirage s'écrit avec son effet** : « 40 lignes par mois » interdit de conclure sur le poids des mois.

À retenir (le réflexe qui vaut une heure de réunion). Une phrase d'identité en tête de chaque livrable : de quoi, sur quoi, sur quelle période, extrait comment, source laquelle. Elle ne coûte rien à écrire et rend le chiffre incontestable sur la forme — ce qui, dans une entreprise, est la moitié du travail.

16. Évaluation formative (auto-correction, 8 min)

1. Un fichier contient 480 lignes et 316 tickets. Que compte-t-on si l'on écrit « notre client moyen achète pour 114 156 FCFA » ?
2. Vrai ou faux : « puisque magasin ne contient qu'une valeur dans l'extrait, on peut comparer le magasin 5 aux autres en divisant par cinq ».
3. Un tableau de fréquences affiche 99,6 % au total. Deux causes possibles ?
4. Sur 307 lignes sans remise sur 480, puis sur 377 lignes identifiées : pourquoi les deux pourcentages (64,0 % et 81,4 %) sont-ils tous les deux corrects, et lequel cite-t-on au directeur financier ?
5. Citez les cinq rubriques de la phrase d'identité, sans relire.

Question ouverte. Un collègue écrit : « 29,8 % de nos ventes concernent les Matériaux, c'est donc la majorité de notre activité ». Reprenez la phrase en une ligne, en corrigeant ce qui doit l'être et en ajoutant ce qui manque.

Corrigé de l'évaluation formative.

1. **Rien de proprement dit.** 114 156 FCFA est le montant moyen par ticket (moyenne des 316 tickets) : le chiffre est un panier moyen, pas un « client moyen ». L'individu est le ticket ; il faut le dire, sinon le lecteur sur-achète (il croit savoir ce qu'un client dépense alors qu'il lit ce qu'un ticket contient).
2. **Faux.** Diviser une valeur unique par cinq invente quatre magasins. Soit on ouvre le fichier complet (240 000 lignes, 6 magasins), soit on écrit « sur le seul magasin 5 ».
3. **Arrondis cumulés** (le cas bénin : mentionner l'arrondi suffit) ou **lignes perdues dans le tableau** (modalité exclue, filtre resté actif, une catégorie absente du croisé) — la seconde cause est une erreur, la première une convention. On vérifie en additionnant les effectifs, pas les pourcentages : la somme doit faire 480.
4. Parce que les deux dénominateurs décrivent deux ensembles différents : toutes les ventes, et les ventes où l'on sait à qui. Au directeur financier, on cite le second **en nommant** le premier (« sur les 377 lignes identifiées, 81,4 % ; l'ensemble des lignes donne 64,0 % ») : un chiffre financier se discute sur ce qu'il couvre avant de se discuter sur sa valeur.
5. Population · individu · échantillon et période · variables et cardinalités · tirage et source (dats). Question ouverte — Réponse attendue : « les Matériaux représentent 143 lignes sur 480,

soit 29,8 % : c'est la première catégorie, pas une majorité (qui exige plus de 50 %) ; le chiffre porte sur les lignes de l'extrait 2025 du magasin 5, pas sur l'activité de l'entreprise ».

Module M02.C02 — Les centres : moyenne, médiane, mode ; minimum, maximum, étendue

Outil de ce chapitre : un tableur d'abord, SQL et Python en vérification. Durée indicative : 4 h. Niveau : N1.

L'idée du chapitre. Résumer 316 tickets par un seul nombre est une décision, pas un calcul. Ce chapitre pose les trois candidats — moyenne, médiane, mode — et les trois bornes — minimum, maximum, étendue — puis répond à la seule question qui vaille en entreprise : **lequel montre-t-on, et que cache-t-il ?** Sur le fichier du module, le même tableau de ventes donne un panier de 114 156 FCFA en moyenne et de 58 423 FCFA en médiane : ce n'est pas une erreur de calcul, c'est la forme des données qui parle.

1. Objectifs du chapitre

À la fin de ce chapitre, vous saurez :

1. **Calculer** moyenne, médiane, mode, minimum, maximum et étendue d'une colonne numérique, dans un tableur, en SQL et en Python, et obtenir le même résultat par les trois voies.
2. **Choisir** le centre qui décrit une distribution donnée, en justifiant par sa forme (symétrique, asymétrique, à valeurs extrêmes, bornée).
3. **Annoncer** un centre sans jamais le séparer de son effectif, de son unité et de sa période.
4. **Démasquer** l'abus de moyenne : dire ce qu'elle doit aux valeurs extrêmes, et chiffrer l'écart avec la médiane.
5. **Utiliser** la moyenne pondérée quand les lignes n'ont pas le même poids, et expliquer la différence avec la moyenne simple.

2. Pourquoi cette notion est importante

Situation 1 — le directeur et le client moyen. On vous demande « combien dépense un client ? ». Vous sortez 114 156 FCFA. Le directeur calibre ses stocks sur ce chiffre, et six mois plus tard la moitié des clients repartent avec moins de la moitié de ce panier. Personne n'a menti : la moyenne est juste, mais **le client moyen n'existe pas** — sur les 316 tickets, 227 sont sous la moyenne, soit 71,8 % de l'échantillon. Une moyenne citée comme un cas typique produit une décision fausse à partir d'un chiffre vrai.

Situation 2 — la comparaison entre vendeurs. Classement brut du chiffre d'affaires par vendeur : Adama Bationo 11 370 350 FCFA sur 125 lignes, Moussa Ilboudo 6 796 535 FCFA sur 109 lignes. L'écart de total s'explique en grande partie par le nombre de lignes ; ramené à la ligne, Bationo est à 90 963 FCFA, Ilboudo à 62 354 FCFA. Avant de parler de performance, il faut savoir **ce que l'on compare** : un total, une moyenne, une médiane. Le chapitre 8 dira si cet écart est statistiquement défendable ; ici, on apprend déjà à ne pas confondre les trois chiffres.

Situation 3 — la remise moyenne qui n'est pas la remise consentie. La moyenne simple de la colonne `remise` vaut 1,85 %. La moyenne pondérée par les montants vaut 1,72 %. Les deux sont justes ; une seule répond à la question du directeur financier (« sur un franc facturé, com-

bien concède-t-on ? »). Un analyste qui ne connaît que la moyenne simple croit que l'entreprise remet plus qu'elle ne le fait.

Dans les faits. L'observation « la moyenne est au-dessus de la médiane sur des montants » est si fréquente qu'elle sert de test de cohérence : sur des données de ventes, une moyenne inférieure à la médiane signale presque toujours un défaut (retours non isolés, doublons, signe inversé). C'est un réflexe de contrôle, pas une loi.

3. Explication simple

Dix amis vont au restaurant. Neuf consomment un plat à 3 000 FCFA, le dixième commande un plateau à fruits de mer à 60 000 FCFA.

- La **moyenne** de la table est $(9 \times 3\,000 + 60\,000) \div 10 = 5\,700$ FCFA. Elle est juste, et elle ne décrit personne : aucun des dix convives n'a dépensé 5 700 FCFA.
- La **médiane** est 3 000 FCFA : c'est ce que paie la moitié de la table, au milieu de la file. Elle décrit la table, mais ne dit rien de l'addition totale.
- Le **mode** est 3 000 FCFA : c'est le montant qui revient le plus souvent.
- Le **minimum** est 3 000, le **maximum** 60 000, l'**étendue** 57 000 FCFA.

L'addition, elle, ne bouge pas : 87 000 FCFA. C'est la leçon du chapitre — **la moyenne porte l'argent, la médiane porte les gens**. Quand on parle de recettes, on prend la moyenne ; quand on parle du comportement habituel d'un client, on prend la médiane ; et l'on dit les deux si l'on ne veut pas être démenti.

4. Vocabulaire essentiel

Français — English	Définition simple	Piège à éviter
Moyenne arithmétique — mean	Somme des valeurs divisée par l'effectif.	La présenter comme « le cas typique » ; elle est sensible aux extrêmes.
Médiane — median	La valeur qui partage la série en deux moitiés d'effectif égal.	Oublier de trier, ou interpoler sans le dire entre deux valeurs.
Mode — mode	La valeur (ou la modalité) la plus fréquente.	Chercher un mode sur des valeurs presque toutes distinctes : il est then artefact.
Minimum / Maximum	Les deux valeurs extrêmes observées.	Les confondre avec des bornes autorisées par le métier.
Étendue — range	Maximum moins minimum.	La résumer à elle seule la dispersion : un seul ticket suffit à l'exploser.
Moyenne pondérée — weighted mean	Moyenne où chaque valeur pèse selon un poids (montant, effectif).	Confondre poids et valeur : pondérer par la colonne elle-même est parfois ce qu'on veut, parfois une faute.
Valeur extrême — outlier	Observation très éloignée du reste, à vérifier avant de commenter.	Supprimer « pour que ce soit propre » sans journaliser la décision.
Trimée (moyenne) — trimmed mean	Moyenne calculée après retrait d'une proportion fixe des extrêmes.	La comparer à la moyenne sans dire quel pourcentage a été retiré.
Centre — measure of central tendency	Nombre unique situé « au milieu » des données.	En choisir un par habitude de logiciel plutôt que par la forme des données.

Français — English	Définition simple	Piège à éviter
Additivité — additivity	Propriété d'un total à se décomposer en sous-totaux cohérents.	Croire qu'une moyenne se décompose : la moyenne d'un ensemble n'est pas la moyenne des moyennes.

5. Cours approfondi

5.1 Les formules, sans mystère

Pour une série de n valeurs triées x_1 le x_2 le $\dots$ le x_n :

- **Moyenne** : $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$. Elle est **additive** : la somme des valeurs est exactement $n \times \bar{x}$. C'est la raison pour laquelle la moyenne est l'outil de la comptabilité et du budget.
- **Médiane** : valeur au rang $\frac{n+1}{2}$ après tri. Si n est pair, on prend la demi-somme des deux valeurs centrales — et on le dit, car ce nombre peut ne correspondre à aucune observation réelle.
- **Mode** : valeur de fréquence maximale. Une série peut n'avoir aucun mode utile (toutes les valeurs distinctes), ou plusieurs (bimodale : deux clientèles distinctes dans le même fichier).
- **Minimum, maximum, étendue** : $x_{\min}$, $x_{\max}$, $x_{\max} - x_{\min}$.

Définition. Moyenne arithmétique — arithmetic mean — le total réparti également. Sa propriété utile : multiplier la moyenne par l'effectif redonne le total, au kuru près. Sa propriété dangereuse : un seul individu extrême la déplace proportionnellement à sa taille, pas à sa fréquence.

Définition. Médiane — median — la valeur du milieu après tri. Elle ne se laisse pas déplacer par un extrême : doubler le plus gros ticket du fichier ne change pas d'un franc la médiane. C'est ce qui la rend lisible pour décrire « le cas courant », et inutilisable pour prévoir une recette.

Définition. Mode — mode — la valeur la plus fréquente. Seul centre calculable sur une variable qualitative (« la catégorie la plus vendue »), il est inexploitable sur une colonne presque continue : nos paniers modaux valent 6 797 et 8 260 FCFA, trois fois chacun sur 316 tickets : rien de spécial, sinon d'être tombés trois fois — et deux valeurs plutôt qu'une, ce qui est déjà une information (la série est multimodale).

5.2 Les trois centres sur le fichier du module : lire les écarts

Sur les 316 tickets de l'extrait nettoyé (480 lignes, magasin 5, 2025) :

Indicateur	Valeur	Ce qu'il permet de dire
Moyenne	114 156 FCFA	le ticket pèse en moyenne ce poids dans la recette totale
Médiane	58 423 FCFA	la moitié des tickets est en dessous, la moitié au-dessus
Mode(s)	6 797 et 8 260 FCFA (3 fois chacun)	deux modes, trois occurrences : aucun exploitable — à écarter explicitement du rapport
Minimum	-150 804 FCFA	un ticket de retour, pas une vente : à isoler, pas à commenter comme un client pauvre
Maximum	1 343 666 FCFA	un chantier, pas un ménage
Étendue	1 494 470 FCFA	la série s'étale sur plus de vingt-cinq fois la médiane (rapport max/médiane : 23,0)

La moyenne dépasse la médiane de 55 733 FCFA — un **rapport de 1,95**. Voilà la phrase à écrire dans une note : « le panier moyen est près de deux fois le panier médian, ce qui indique une

forte concentration de la recette sur peu de gros tickets ». Et sa conséquence opérationnelle, mesurée aussi : **les 10 % des tickets les plus gros portent 47,5 % du chiffre d'affaires de l'extrait**. On peut décider de traiter cette frange à part (délai, acompte, livreur dédié) ; on ne peut plus décider pour toute la clientèle d'après le panier moyen.

5.3 La médiane a un effet de seuil, la moyenne un effet de niveau

Deux propriétés à connaître pour ne pas se faire surprendre en réunion :

- **La médiane ne bouge presque pas** quand une valeur extrême change. Doubler le plus gros ticket du fichier (1 343 666 FCFA) ne déplace pas la médiane d'un franc ; la moyenne, elle, remonte d'environ 4 000 FCFA — 1 343 666 FCFA répartis sur 316 tickets — sans que le comportement habituel de qui que ce soit ait changé.
- **La moyenne se déplace exactement comme une somme** : si l'on retire du fichier 8 lignes de montants négatifs (les retours, dont le total fait basculer des dizaines de milliers de francs), la moyenne par ligne passe de 75 152 à 77 028 FCFA. C'est un autre calcul sur un autre périmètre, pas une correction du précédent.

D'où la règle de rédaction : **toute moyenne citée s'accompagne du périmètre** (avec ou sans retours, avec ou sans doublons, sur extrait ou sur fichier complet). Deux chiffres corrects et différents racontent la même réalité sous deux angles — à condition que l'angle soit nommé.

5.4 Moyenne simple, moyenne pondérée : la colonne `remise` le démontre

Sur 480 lignes, la colonne `remise` contient six modalités. Sa moyenne simple vaut 0,0185 : c'est « la remise moyenne **par ligne** ». La moyenne pondérée par les montants hors taxes vaut 0,0172 : c'est « la remise moyenne **par franc facturé** ». Le calcul :

$$\text{moyenne pondérée} = \frac{\sum_i \text{remise}_i \times |\text{montant_ht}_i|}{\sum_i |\text{montant_ht}_i|}$$

L'écart de 0,13 point (7 % en relatif) vient de ce que les grosses lignes sont moins remisées que les petites. Cette dissymétrie est une information de politique commerciale : si l'on veut protéger la marge sur les gros chantiers, la moyenne simple — celle que le magasin voit — est trompeuse.

Définition. Moyenne pondérée — weighted mean — moyenne dans laquelle chaque valeur compte pour un poids. À utiliser dès que les individus n'ont pas la même taille économique : prix, taux, remises, délais, taux de marge, taux de transformation.

Attention. La moyenne des moyennes n'est pas la moyenne. Reprendre les douze moyennes mensuelles de l'extrait et les moyenner donne un chiffre faux dès que les mois n'ont pas le même nombre de lignes. Sur notre extrait, le tirage a forcé l'égalité (40 lignes par mois) : c'est le seul cas où l'erreur est invisible. Ne prenez jamais cette habitude — agrégez à partir des montants, jamais à partir des pourcentages ou des moyennes intermédiaires.

5.5 Le cas d'école : tickets simples contre paniers composés

Les 316 tickets se séparent en 212 tickets d'une ligne et 104 à plusieurs lignes (32,9 %). Les centres explosent la moyenne générale :

Population	Effectif	Moyenne	Médiane
Tickets d'une seule ligne	212	80 546 FCFA	38 084 FCFA
Tickets de 2 lignes et plus	104	182 668 FCFA	130 461 FCFA

Un « panier moyen de 114 156 FCFA » est donc le mélange de deux comportements différents. La question professionnelle qui suit immédiatement : veut-on piloter le mix (faire passer un client de 1 à 3 lignes) ou le prix (augmenter le panier simple) ? La réponse change le centre à regarder : pour le mix, la médiane et la répartition ; pour le prix, la moyenne et son évolution.

Conseil professionnel. Dans une note, présentez le couple **moyenne + médiane** avec une seule phrase d'interprétation : « moyenne 114 156 · médiane 58 423 FCFA : la recette est tirée par une frange de gros tickets, le comportement courant est à 58 423 FCFA ». Un lecteur qui n'a que la moyenne sur-achète ; un lecteur qui n'a que la médiane sous-estime la recette. Les deux ensemble, et l'affirmation devient robuste.

5.6 Minimum et maximum ne sont pas des bornes métier

Le minimum de la colonne `montant_ttc`, à la ligne, vaut -150 804 FCFA : c'est un retour, pas une erreur de saisie. Le maximum de `quantite` vaut 68 dans le fichier nettoyé — et 14 000 dans l'énoncé : ce sont les 7 lignes dont la quantité a été multipliée par 1 000 à l'enregistrement, corrigées au chapitre M01.C04. Le minimum de `prix_unitaire_ht` est 675 FCFA, le maximum 40 550 FCFA : deux extrêmes plausibles dans un catalogue de quincaillerie, à confronter au fichier fournisseur si l'on veut en tirer une décision.

La règle : **un extrême se qualifie avant de se résumer**. Trois questions, dans l'ordre : est-ce une erreur de fabrication (le $\times 1\,000$) ? est-ce un autre objet métier (le retour) ? est-ce un cas réel et rare (le chantier à 1 343 666 FCFA) ? Selon la réponse, on corrige, on isole dans un segment, ou on garde et on mentionne.

Attention. Supprimer les extrêmes pour « nettoyer » détruit l'additivité de la moyenne : le total de l'entreprise ne change pas, mais la moyenne que vous citez ne correspond plus à aucun chiffre du système de caisse, et plus personne ne peut la retrouver. Si une moyenne sans extrêmes est utile (moyenne trimée), elle se cite **avec** sa règle de retrait et avec le total d'origine. Sur le fichier du module, la moyenne trimée des tickets (25 tickets hors borne supérieure de Tukey) tombe à 71 463 FCFA, la médiane à 54 044 FCFA : les deux se resserrent, c'est exactement ce que l'on attend d'un retrait d'extrêmes — et c'est ce qu'il faut écrire.

5.7 Calculer les six nombres dans les trois outils

Nombre	Tableur (Excel / LibreOffice Calc)	SQL (DuckDB)	Python (pandas)
Moyenne	<code>=MOYENNE(M2:M481)</code>	<code>AVG(montant_ttc)</code>	<code>df.montant_ttc.mean()</code>
Médiane	<code>=MEDIANE(M2:M481)</code>	<code>MEDIAN(montant_ttc)</code>	<code>df.montant_ttc.median()</code>
Mode	<code>=MODE.UNI(M2:M481)</code> (Excel) · <code>=MODE(...)</code> (Calc)	<code>MODE(montant_ttc) WITHIN GROUP (ORDER BY montant_ttc)</code>	<code>df.montant_ttc.mode()</code>
Minimum	<code>=MIN(M2:M481)</code>	<code>MIN(montant_ttc)</code>	<code>df.montant_ttc.min()</code>
Maximum	<code>=MAX(M2:M481)</code>	<code>MAX(montant_ttc)</code>	<code>df.montant_ttc.max()</code>
Étendue	<code>=MAX(...)-MIN(...)</code>	<code>MAX(...)-MIN(...)</code>	<code>df.montant_ttc.max()-df.montant_ttc.min()</code>
Nombre de valeurs	<code>=NB(M2:M481)</code>	<code>COUNT(montant_ttc)</code>	<code>df.montant_ttc.count()</code>

Un détail qui fait perdre une heure : en SQL, la fonction de médiane est une **fonction d'agrégat ordonnée** — là où `AVG` accepte n'importe quoi, la médiane exige de dire dans quel ordre on cherche le milieu. Et dans les deux tableurs, le mode s'appelle différemment selon la version et la suite (Excel 2021+ : `MODE.UNI`, `MODE.MULT` pour les modes multiples ; LibreOffice 24.8 : `MODE`,

MODE.MULT) : vérifiez le nom dans l'assistant de fonction avant de l'écrire dans une procédure destinée à durer.

Boîte à outils. Le contrôle minimal de tout centre : (1) =NB() doit redonner l'effectif attendu — sinon des valeurs texte sont silencieusement ignorées, et votre moyenne porte sur 478 lignes au lieu de 480 ; (2) la moyenne fois l'effectif doit redonner la somme, =MOYENNE(range)*NB(range) contre =SOMME(range) ; (3) pour la médiane, vérifier que l'effectif des valeurs strictement inférieures et celui des supérieures diffèrent d'au plus un ; (4) si un seul de ces contrôles échoue, le problème est dans la colonne, pas dans la formule.

6. Exemple concret : le même indicateur, quatre énoncés

Voici ce que produit un analyste pressé : « panier moyen : 114 156 FCFA ». Le même fait, rédigé pour durer :

1. **Sur quoi** : 316 tickets du magasin 5, exercice 2025, extrait de 480 lignes sur 240 000 du fichier complet.
2. **Combien** : moyenne 114 156 FCFA ; médiane 58 423 FCFA ; mode non retenu (6 797 FCFA, aucune fréquence exploitable sur cette colonne continue).
3. **Forme** : moyenne 1,95 fois la médiane ; les 10 % de tickets les plus gros portent 47,5 % du chiffre d'affaires de l'extrait ; 227 tickets (71,8 %) sont sous la moyenne.
4. **Décision** : piloter le prix sur la moyenne, piloter l'expérience client sur la médiane, et traiter à part les 25 tickets au-dessus de la borne haute (295 445 FCFA).

Quatre lignes, aucun chiffre inventé, et plus de place pour le « ce n'était pas ce que je voulais dire ».

7. Démonstration pas à pas : les six nombres, trois outils, un contrôle

Étape 1 — Le bon fichier, le bon périmètre. 01_socle_donnees/data/reference/ventes_magasin5_2025_ATTENDU.csv, 480 lignes, séparateur ;. On travaillera sur deux objets : la colonne montant_ttc par ligne et le montant par ticket (somme par n_ticket). Notez-le : deux séries, donc six nombres chacun.

Étape 2 — Construire la série « ticket » dans le tableur. Colonne N : la clé de ticket. Colonne O : =SOMME.SI(N:N;N2;M:M) somme les montants du même ticket. Colonne P : =SI(NB.SI(\$N\$2:\$N\$481;N2)=1;O2;"") ne garde que la première occurrence de chaque ticket. Une colonne auxiliaire, un compteur, et la série des 316 paniers est prête. C'est long de dix minutes et c'est exactement ce que le tableur sait faire ; au chapitre suivant, le même travail tiendra en une requête.

Étape 3 — Les six nombres par ticket. Sur la colonne des paniers : =MOYENNE(...) → 114 156 ; =MEDIANE(...) → 58 423 ; =MODE.UNI(...) → 6 797 ; =MIN(...) → -150 804 ; =MAX(...) → 1 343 666 ; =MAX(...)-MIN(...) → 1 494 470. Écrivez-les dans un tableau à deux colonnes : valeur, unité (FCFA).

Étape 4 — Les six nombres par ligne. Même opération directement sur montant_ttc : moyenne 75 152 FCFA, médiane 37 966 FCFA, minimum -150 804 FCFA, maximum 1 229 678 FCFA. Le fait que la moyenne par ligne soit inférieure à la moyenne par ticket est normal et attendu : une ligne est une fraction de ticket (1,52 ligne par ticket).

Étape 5 — Le contrôle d'additivité. `=MOYENNE(M2:M481)*NB(M2:M481)` doit donner 36 073 185 FCFA, soit le total de la colonne. Si l'écart dépasse un franc, vous avez un souci de périmètre (filtre actif, ligne texte ignorée), pas une erreur d'arrondi.

Étape 6 — La version SQL, en une requête.

```
WITH paniers AS (
  SELECT n_ticket, SUM(montant_ttc) AS panier, COUNT(*) AS nb_lignes
  FROM read_csv('01_socle_donnees/data/reference/ventes_magasin5_2025_ATTENDU.csv', sep=';')
  GROUP BY n_ticket
)
SELECT COUNT(*)                AS tickets,
   ROUND(AVG(panier))          AS moyenne,
   ROUND(MEDIAN(panier))       AS mediane,
   MIN(panier)                 AS minimum,
   MAX(panier)                 AS maximum,
   MAX(panier) - MIN(panier)    AS etendue,
   SUM(CASE WHEN nb_lignes = 1 THEN 1 ELSE 0 END) AS tickets_simple
FROM paniers;
```

Pour la suite du module : figez ces deux relations. Ouvrez DuckDB à la racine du dépôt (commande `duckdb`, sans argument) et créez deux vues. Les chapitres C03 à C06 écriront leurs requêtes contre `lignes_ventes` et `paniers`, et ils ne fonctionneront qu'après ces deux lignes.

```
-- une fois pour toutes dans la session, pour tout le module M02
CREATE OR REPLACE VIEW lignes_ventes AS
  SELECT * FROM read_csv('01_socle_donnees/data/reference/ventes_magasin5_2025_ATTENDU.csv',
    sep=';');

CREATE OR REPLACE VIEW paniers AS
  SELECT n_ticket, SUM(montant_ttc) AS panier, COUNT(*) AS nb_lignes
  FROM lignes_ventes
  GROUP BY n_ticket;
```

Un `CREATE VIEW` ne duplique pas les données : il enregistre une question. Vous gagnez trois choses — des requêtes courtes, un point unique où le fichier est nommé, et un signal immédiat le jour où le fichier change de nom ou de séparateur, parce que la vue refusera de se créer. Vérifiez une fois, tout de suite : `SELECT COUNT(*), ROUND(AVG(panier)) FROM paniers;` doit rendre 316 et 114 156.

Étape 7 — La version Python, et la moyenne pondérée.

```
import pandas as pd
d = pd.read_csv("01_socle_donnees/data/reference/ventes_magasin5_2025_ATTENDU.csv", sep=";")
pan = d.groupby("n_ticket").montant_ttc.sum()
print(pan.agg(["count", "mean", "median", "min", "max"]))
pond = (d.remise * d.montant_ht.abs()).sum() / d.montant_ht.abs().sum()
print("remise simple %.4f · pondérée %.4f" % (d.remise.mean(), pond))
```

Sortie attendue : 316 tickets · moyenne 114 156 · médiane 58 423 · -150 804 · 1 343 666 ; remise 0,0185 et 0,0172. Les trois outils tombent d'accord, la note est défendable.

Étape 8 — Les catégories, sans y passer la journée. `GROUP BY categorie` sur les lignes : moyenne et médiane par catégorie, en une colonne de plus. Bois & panneaux donne 201 865 FCFA de moyenne pour 77 904 FCFA de médiane : cette catégorie est tirée par ses gros chantiers. Peinture : 86 422 contre 68 738 — les deux sont proches, la distribution est régulière. Voilà comment, en trente secondes, un classement de catégories devient une interprétation.

Étape 9 — Écrire le commentaire. Deux phrases, pas plus : une sur la position (« le panier médian est à 58 423 FCFA »), une sur la concentration (« la moyenne, 114 156 FCFA, est tirée par 10 % de tickets qui font 47,5 % du CA »).

Étape 10 — Journaliser. Une ligne dans `06_analyse/journal_transformations.txt` : la source, les six nombres, l'outil, la date. Ce qui prend vingt secondes aujourd'hui vous évitera trois quarts d'heure de fouille en janvier.

8. Erreurs fréquentes

Symptôme	Cause	Correction
« Notre client moyen » n'existe nulle part	la moyenne prise pour le cas typique	citer moyenne et médiane, et dire laquelle porte la décision
La moyenne change quand on ajoute une ligne, la décision change avec	aucun contrôle de la forme de la distribution	regarder le rapport moyenne/médiane avant de commenter ; ici 1,95
Le mode affiché est une valeur unique apparue deux fois	mode calculé sur une colonne quasi continue	réserver le mode aux variables qualitatives ou aux colonnes à faible cardinalité
Deux services n'ont pas la même moyenne, aucune erreur de calcul	périmètres différents (retours, doublons, extrait)	nommer le périmètre dans l'intitulé de la cellule, pas en note de bas de page
<code>=MEDIANE()</code> renvoie une erreur ou un texte	valeurs non numériques dans la plage	<code>=NB()</code> contre <code>=NBVAL()</code> ; la différence compte les lignes texte
L'étendue explose après un correctif	minimum négatif non expliqué (retour)	séparer retours et ventes avant de résumer, et le dire

9. Bonnes pratiques professionnelles

- Un centre sans effectif n'est pas une statistique : 114 156 FCFA (n = 316 tickets), toujours.
- Citez l'unité et la période dans le nom de la colonne du tableau, pas dans la légende du graphique.
- Sur des montants, partez du principe que la moyenne sera au-dessus de la médiane ; vérifiez, et commentez le rapport.
- Ne supprimez jamais un extrême sans écrire la règle, le nombre de lignes retirées et le total perdu.
- Pour une variable à 4 ou 5 valeurs (un vendeur, un type de client), le mode et l'effectif par modalité disent plus qu'une moyenne.
- Gardez une colonne « moyenne pondérée » dans vos modèles quand la variable est un taux ou un prix.
- Conservez dans le journal la requête qui a produit les nombres : une note sans requête est une opinion datée.

10. Exercice guidé — le trio moyenne / médiane / mode, ensemble

Consigne. Sur la série des 316 paniers, produisez le tableau des six nombres, puis écrivez les deux phrases de commentaire. Comptez 30 minutes, dont 20 de tableau.

Étape 1 — Isoler la série. Vous summez par ticket et vous ne gardez qu'une occurrence par ticket, comme en §7 étape 2. Contrôle : `=NB()` sur la colonne obtenue doit faire 316. Si vous trouvez 480, la déduplication n'a pas fonctionné et tout ce qui suit sera faux — c'est le moment de le découvrir, pas après la note.

Étape 2 — Les six nombres. Vous les placez dans un tableau à trois colonnes : indicateur, valeur, unité. Vous obtenez 114 156 · 58 423 · 6 797 · -150 804 · 1 343 666 · 1 494 470 FCFA.

Étape 3 — Le mode, et sa mise à l'écart. Le tableur renvoie 6 797 FCFA, et la fonction des modes multiples en ajoute un second à 8 260 FCFA. Vous demandez « combien de fois ? » : `=NB.SI()` répond trois fois sur 316, pour l'un comme pour l'autre. Décision écrite : mode non retenu, avec sa raison. C'est une compétence, pas une résignation.

Étape 4 — Le rapport qui parle. `=114156/58423` → 1,95. Commentaire : « la moyenne est près de deux fois la médiane : la recette est concentrée ». Vous cherchez la concentration : triez décroissant, additionnez les 32 premiers tickets (10 % de 316 arrondi), divisez par le total → 47,5 %. Voilà l'indicateur que le directeur gardera en tête, pas le panier moyen.

Étape 5 — Le retournement. Refaites la moyenne en excluant le plus gros ticket : vous voyez la moyenne descendre nettement, la médiane presque pas. Écrivez cette phrase dans la note : elle explique à elle seule pourquoi deux services peuvent avoir raison avec des chiffres différents.

Étape 6 — Vérification croisée. Relancez la requête SQL de l'étape 6. Les six nombres doivent être identiques au franc près (aux arrondis d'affichage près). S'ils diffèrent, c'est l'encodage ou le séparateur, pas la statistique.

11. Exercices autonomes

Exercice 2.1 (★) — Le tableau de base. Calculez les six nombres de la série des paniers, et le même tableau pour la colonne `montant_ttc` par ligne. (attendu : 114 156 · 58 423 · 6 797 · -150 804 · 1 343 666 · 1 494 470 FCFA ; par ligne 75 152 · 37 966 FCFA, minimum -150 804, maximum 1 229 678)

Exercice 2.2 (★) — Combien sous la moyenne. Comptez les tickets strictement inférieurs à la moyenne, donnez leur part. Concluez en une phrase sur l'expression « client moyen ». (attendu : 227 tickets sur 316, 71,8 %)

Exercice 2.3 (★★) — Simples contre composés. Séparez les 212 tickets d'une ligne des 104 autres ; moyenne et médiane de chaque groupe. Rédigez la phrase que vous diriez au directeur des ventes. (attendu : 80 546 / 38 084 FCFA et 182 668 / 130 461 FCFA ; conclusion : deux clients, un seul fichier)

Exercice 2.4 (★★) — Pondérée, pas simple. Moyenne simple et moyenne pondérée par le `montant_ht` de la colonne `remise`, puis la même paire restreinte aux lignes dont la catégorie est « Matériaux ». Expliquez ce que dit la différence. (attendu sur l'ensemble : 0,0185 et 0,0172 ; la pondérée est inférieure : les fortes lignes sont moins remisées)

Exercice 2.5 (★★★) — Le chiffre qui change sans raison. Recalculez la moyenne des paniers en incluant les lignes de retour (montants négatifs), puis en les isolant dans un segment « avoirs ». Donnez les deux moyennes, la médiane dans les deux cas, et écrivez la règle métier que vous avez suivie. (attendu : la moyenne baisse quand on inclut les retours, la médiane quasiment pas ; règle écrite = les retours ne sont pas des ventes, ils sont un objet à part, et le total reste celui de la caisse)

12. Correction détaillée

Exercice 2.1. Tableaux attendus, avec l'effectif affiché à chaque ligne : paniers n = 316 — moyenne 114 156, médiane 58 423, modes 6 797 et 8 260 (non retenus : 3 occurrences chacun), min -150 804, max 1 343 666, étendue 1 494 470 FCFA ; lignes n = 480 — moyenne 75 152, mé-

diane 37 966 FCFA. Contrôle d'additivité sur les lignes : la moyenne multipliée par l'effectif doit retomber sur le total de la colonne, 36 073 185 FCFA, à l'arrondi d'affichage près — c'est la raison pour laquelle on calcule avec deux décimales et on affiche en entiers.

Exercice 2.2. `=NB.SI(0:0;"<114156")` → 227, soit $227 \div 316 = 71,8 \%$. Commentaire attendu : « dans une distribution asymétrique, la majorité des observations est sous la moyenne ; parler de “client moyen” pour décrire le client courant est un contresens — le client courant est à 58 423 FCFA ». Le point de méthode noté : avoir vérifié que $316 - 227 = 89$ tickets sont au-dessus (les 28,2 % qui portent la recette), et l'avoir écrit.

Exercice 2.3. Moyennes 80 546 et 182 668 FCFA ; médianes 38 084 et 130 461 FCFA. Ratio interne : dans le groupe des tickets simples, la moyenne est 2,11 fois la médiane — le déséquilibre n'a pas disparu en découpant, il s'est déplacé. Phrase attendue : « le panier moyen de 114 156 FCFA mélange deux objets : un achat simple à 80 546 FCFA et un panier composé à 182 668 FCFA ; si l'objectif est de faire passer un client d'un article à plusieurs, l'indicateur de pilotage est la part des tickets composés (32,9 %), pas le panier moyen ».

Exercice 2.4. Ensemble : simple 0,0185, pondérée 0,0172 (formule `=SOMMEPROD(remise;|montant_ht|)/SOMME(|montant_ht|)`). Sur « Matériaux » : les deux se resserrent, la catégorie étant peu remise et de montants homogènes. Lecture attendue : « la moyenne simple surestime la remise réelle de 1,3 point relatif, parce que les petites lignes sont les plus remises ; la politique de remise touche donc les petits clients, pas les chantiers ». Cette phrase est une décision possible : baisses de remise sur les petites lignes, marge préservée.

Exercice 2.5. Avec retours inclus, la moyenne des paniers est celle annoncée (§5.2) : 114 156 FCFA — elle contient trois tickets négatifs, dont un à -150 804 FCFA. En isolant les avoirs, la moyenne des ventes se resserre et la médiane reste à 58 423 FCFA, pratiquement inchangée : la médiane ne « voit » pas les trois cas extrêmes, la moyenne les absorbe. Règle attendue, écrite en une phrase : « un avoir n'est pas une vente : il est compté à part, et le total de caisse reste le total de caisse ». Le barème valorise la règle, pas le calcul.

13. Mini-projet M02.P2 — « Deux pages, six nombres, une décision » (45 min)

Commande. Pour la direction commerciale du magasin 5, produisez deux pages : (1) le tableau des six nombres, sur les paniers et sur les lignes, avec effectifs, unités et périmètre ; (2) une page de décision qui utilise moyenne, médiane et concentration pour trancher **une** question au choix : faut-il augmenter le seuil de livraison gratuite ? faut-il un tarif dédié aux tickets au-dessus de 300 000 FCFA ? faut-il recentrer la remise sur les petites lignes ?

Livrables numérotés. (1) tableau ; (2) page de décision avec le chiffre retenu, celui qui est écarté et pourquoi ; (3) la requête SQL ou le classeur de calcul en annexe ; (4) la ligne de journal.

Barème (20 points, seuil 13). Six nombres exacts et sourcés (5) · périmètre et unité écrits partout (3) · choix du centre justifié par la forme, pas par l'habitude (4) · chiffre de concentration calculé et non recopié (3) · décision datée avec un destinataire (3) · annexe rejouable (2) — total 20.

14. Résumé du chapitre

Trois centres, trois usages : la moyenne porte l'argent et se multiplie par l'effectif pour retrouver le total ; la médiane porte les gens et résiste aux extrêmes ; le mode ne sert que sur du dis-

cret. Deux bornes et une étendue disent l'étalement, pas la fréquence : le minimum de notre série est négatif parce que les retours sont là, et le maximum est un chantier, pas un client. Le rapport moyenne/médiane est votre premier diagnostic de forme — ici 1,95, donc asymétrie marquée, donc 71,8 % des tickets sous la moyenne. La moyenne pondérée est obligatoire dès qu'une variable est un taux ou un prix. Enfin, aucun centre ne se cite sans effectif, unité, période et périmètre : c'est ce qui rend un chiffre défendable quand deux services le calculent chacun de leur côté.

15. À retenir

À retenir. 1. **Moyenne $\times$ effectif = total** : c'est sa définition et sa seule promesse. Ne lui demandez pas de décrire le cas courant. 2. **Médiane = la moitié, pas le milieu du total** : 58 423 FCFA ici, insensible au ticket géant de 1 343 666 FCFA. 3. **Regardez le rapport, pas les valeurs seules** : moyenne $\div$ médiane = 1,95 annonce la concentration (47,5 % du CA sur 10 % des tickets). 4. **Mode uniquement sur du discret** : 6 797 FCFA est une valeur, pas une information. 5. **Taux et prix $\rightarrow$ moyenne pondérée** : 1,72 % de remise réelle contre 1,85 % de moyenne simple.

À retenir. La formulation qui protège. Dans toute note : « moyenne X FCFA, médiane Y FCFA, sur n objets, périmètre ... ». Celui qui écrit cette ligne ne se fait plus reprendre sur le sens d'un chiffre.

16. Évaluation formative (auto-correction, 10 min)

1. Un tableau de bord affiche « panier moyen : 114 156 FCFA » et « panier médian : 58 423 FCFA ». Un directeur conclut : « la moitié de nos clients dépensent plus de 100 000 FCFA ». Qu'y a-t-il à reprendre ?
2. Calculez de tête le nombre de tickets sous la moyenne si 28,2 % sont au-dessus, et dites ce que ce déséquilibre implique pour une politique de prix.
3. Pourquoi le mode est-il écarté de ce chapitre sur la colonne des montants, et sur quelle colonne du même fichier serait-il pertinent ?
4. Moyenne simple 0,0185, moyenne pondérée 0,0172. Lequel des deux chiffres un directeur financier doit-il entendre, et lequel un chef de magasin ?
5. On retire les 25 tickets dépassant la borne de 295 445 FCFA. Que deviennent la moyenne, la médiane et le total ? Lequel de ces trois changements doit être signalé dans la note ?

Corrigé de l'évaluation formative.

1. Deux erreurs. D'abord une confusion de centre : la médiane (58 423 FCFA) est le seuil de la moitié, pas la moyenne. Et le seuil des 100 000 FCFA n'est pas davantage une moitié : 30,4 % des tickets le dépassent (96 tickets sur 316), 28,2 % dépassent la moyenne.
2. $316 \times (1 - 0,282) \approx 227$ tickets sous la moyenne. Conséquence : fixer un tarif ou un seuil de service « sur la moyenne » exclut sept tickets sur dix ; les paliers se calibrent sur des percentiles (chapitre 4).
3. Parce que 316 montants presque tous distincts produisent un mode sans signification : deux valeurs, 6 797 et 8 260 FCFA, trois occurrences chacune. Sur `categorie` ou `remise`, le mode est utile : « Matériaux » avec 143 lignes sur 480, ou remise 0,04 avec 110 lignes sur 480.

4. Le directeur financier entend la **pondérée** (1,72 %), parce qu'elle dit ce que coûte la remise sur chaque franc facturé. Le chef de magasin entend la **simple** (1,85 %), parce qu'elle dit ce qui se pratique sur une ligne — et donc ce qu'il doit rappeler aux vendeurs.
5. La moyenne baisse nettement (vers 71 463 FCFA sur les tickets restants), la médiane descend à 54 044 FCFA, le total du fichier, lui, baisse de tout ce qui a été retiré. C'est **le total** qui doit être signalé : une moyenne sans extrêmes est un outil de description, pas un élément de compte de résultat ; écrire l'un sans l'autre, c'est créer un chiffre que la comptabilité ne reconnaîtra pas.

M02.C03 — Mesurer la dispersion : étendue, intervalle interquartiles, écart-type

L'idée du chapitre. Deux séries peuvent avoir la même moyenne et n'avoir rien de commun. La dispersion est ce qui les sépare dans une note, et c'est elle — pas le centre — qui décide si un indicateur est utilisable pour négocier, alerter ou comparer.

Base de travail — obligatoire. Deux fichiers du socle, dans votre dossier 02_exercices/M02/, ouverts côte à côte : `donnees/projection/ventes_magasin5_2025.csv` (l'énoncé, 489 lignes × 13 variables) et `donnees/reference/ventes_magasin5_2025_ATTENDU.csv` (480 × 13). Séparateur point-virgule, encodage UTF-8, virgule décimale. Montants en franc CFA (FCFA). Tous les chiffres cités sont lus sur l'attendu, au niveau de la ligne (480 lignes) et du panier (316 tickets), et figurent dans `01_socle_donnees/data/reference/chiffres_cites.md`, section M02.

1. Objectifs du chapitre

À la fin de ce chapitre, vous êtes capable de :

1. calculer et comparer les trois dispersions usuelles — étendue, intervalle interquartiles, écart-type — sur la même série, et dire laquelle répond à quelle question ;
2. expliquer pourquoi l'écart-type d'une série d'entiers s'écrit avec des décimales alors qu'aucune valeur ne les contient ;
3. choisir entre écart-type et coefficient de variation pour comparer la variabilité de deux colonnes qui n'ont pas la même échelle ;
4. estimer la précision d'une moyenne grâce à l'erreur type, et dire si un écart entre deux vendeurs mérite une réunion ;
5. décider, chiffres à l'appui, si une catégorie de produits est assez stable pour être pilotée sur sa moyenne ;
6. rédiger une note de dispersion qui ne laisse pas le lecteur deviner de quoi l'on parle.

2. Pourquoi cette notion est importante

Un indicateur sans dispersion est une décision prise à l'aveugle. Trois situations du module le montrent, toutes chiffrées plus bas dans ce chapitre :

- **La négociation.** « Le montant moyen d'une ligne de Bois & panneaux est de 201 865 FCFA, accordons 5 % ». Si l'écart-type de la catégorie vaut 318 080 FCFA, la moyenne ne décrit rien : la remise porte sur un chiffre qui n'existe pas.
- **L'alerte.** Le contrôle de gestion veut être prévenu quand un ticket sort de l'ordinaire. Le seuil retenu change tout : à une fois et demie l'écart interquartiles, il vaut 295 445 FCFA et signale 25 tickets ; à deux écarts-types, il ne signale qu'une douzaine de tickets et laisse filer tout le reste.
- **Le classement.** L'écart de panier moyen entre les deux vendeurs les plus éloignés des quatre principaux vaut 34 014 FCFA. Sans erreur type, c'est un classement ; avec elle (10 244 FCFA), c'est une comparaison qui tient ou qui tombe.

Dans les faits. Le vocabulaire de la dispersion est le premier endroit où un non-statisticien est disqualifié en réunion, souvent injustement. Deux réflexes vous mettent à l'abri : ne jamais prononcer un écart-type sans la moyenne qui l'accompagne, et ne jamais parler de « variance » à l'oral — dites « écart-type », tout le monde voit de quoi il retourne, et vous aussi.

3. Explication simple

Imaginez deux caisses du magasin. À la première, dix clients paient des tickets tous proches de 60 000 FCFA. À la seconde, dix clients encore : cinq paient 5 000 FCFA, cinq paient 115 000 FCFA. Les deux files ont la même moyenne. La première est réglée, la seconde est un tirage.

La dispersion est exactement ce qui distingue les deux files, et elle répond à une question unique : **les valeurs sont-elles serrées autour du centre, ou étalées ?** Trois manières de le mesurer, de la plus naïve à la plus utile :

- **l'étendue** regarde les deux bouts — 1 494 470 FCFA sur nos tickets : vrai, et inutile ;
- **l'intervalle interquartiles (IQR)** regarde la moitié du milieu — 109 924 FCFA, et résiste aux extrêmes ;
- **l'écart-type** regarde toutes les valeurs, chacune comptant pour sa distance au centre — 182 095 FCFA, et sert de matière première à tout le reste du module.

Le mot « dispersion » recouvre donc trois chiffres très différents. En anglais spread, dispersion, variability : le concept est le même, et le mot employé dépend du logiciel plus que du théorème.

4. Vocabulaire essentiel

#	Terme	Français — English — sens simple	À savoir
1	Étendue	étendue — range — plus grande valeur moins plus petite	deux lignes du fichier décident de tout
2	IQR	intervalle interquartiles — interquartile range — Q3 moins Q1	« écart interquartile » en français
3	Variance	variance — variance — moyenne des carrés des écarts	unité au carré, donc peu lisible
4	Écart-type	écart-type — standard deviation — racine carrée de la variance	σ pour une population, s pour un échantillon
5	CV	coefficient de variation — coefficient of variation — écart-type divisé par la moyenne	sans unité, seul comparable entre colonnes
6	Erreur type	erreur type de la moyenne — standard error (SE) — écart-type divisé par racine de n	précision d'un indicateur, pas diversité des clients
7	MAD	écart absolu médian — median absolute deviation — médiane des écarts à la médiane	robuste, absente des tableurs
8	Moyenne tronquée	moyenne tronquée — trimmed mean — moyenne après retrait des extrêmes	change le périmètre, pas le calcul
9	Bornes de Tukey	bornes de Tukey — Tukey fences — Q1 — $1,5 \times \text{IQR}$ et Q3 + $1,5 \times \text{IQR}$	définit l'extraordinaire sans le subir
10	Degré de liberté	degré de liberté — degree of freedom — valeurs libres après estimation	explique le $n - 1$ de la variance
11	Hétérogénéité	hétérogénéité — heterogeneity — mélange de populations dans un même chiffre	le vrai danger, pas la variance

5. Cours approfondi

5.1 Trois dispersions, trois usages

Définition. L'**étendue** (range) est la différence entre maximum et minimum. L'**intervalle inter-quartiles** (IQR) est la différence entre le troisième et le premier quartile. L'**écart-type** est la racine carrée de la **variance**, moyenne des carrés des écarts à la moyenne. Les deux premières se lisent sur la distribution, la troisième sur toutes les valeurs à la fois.

Dispersion	Sur les paniers (316)	Sur les lignes (480)	Ce qu'elle autorise à dire
Étendue	1 494 470 FCFA	1 380 482 FCFA	« du pire au meilleur ticket » — exact, non décisionnel
IQR	109 924 FCFA	à calculer à l'exercice 3.1	« la moitié du milieu tient dans... »
Écart-type	182 095 FCFA	143 915 FCFA	« un ticket s'écarte typiquement de... »
CV	159,5 %	191,5 %	« la moyenne ne décrit pas la série »

Sur 316 valeurs très asymétriques, l'écart-type dépasse nettement l'IQR (rapport de 1,7) : c'est la signature arithmétique de l'asymétrie, que M02.C05 confirmera graphiquement. L'étendue, elle, vaut plus de treize fois l'IQR (rapport mesuré : 13,6) — les 300 tickets du centre tiennent dans un espace treize fois plus petit que celui que la série occupe au total.

Faites-le dans un tableur. Sur la colonne des paniers : `=MAX(plage)-MIN(plage)` pour l'étendue, `=QUARTILE.INC(plage;3)-QUARTILE.INC(plage;1)` pour l'IQR, `=ECARTYPE.STANDARD(plage)` pour l'écart-type. La fonction s'appelle `STDEV.S` en anglais, `ECARTYPE.STANDARD` en français ; la variante `ECARTYPEP` (`STDEV.P`) suppose que vous tenez la population entière. Gardez la version échantillon : vous travaillez sur un extrait de 0,23 % du fichier du magasin.

Attention. Une étendue est une information sur deux lignes. Un seul ticket à 1 343 666 FCFA ou un seul avoir à -150 804 FCFA la change, sans que personne d'autre n'ait changé de comportement. C'est la plus sensible des trois dispersions à l'erreur de saisie, donc la moins bonne candidate à un seuil d'alerte.

5.2 D'où vient l'écart-type, et pourquoi il a des décimales

Quatre pas, tous faisables à la main sur dix lignes :

1. écart de chaque valeur à la moyenne : $x_i - \text{moyenne}$;
2. carré de cet écart ;
3. somme des carrés divisée par $n - 1 \rightarrow$ la **variance** ;
4. racine carrée de la variance $\rightarrow$ l'**écart-type**.

Sur les 316 paniers, la variance vaut 33 158 631 393 — des FCFA au carré, unité qui n'existe pas dans la nature — et sa racine carrée 182 095 FCFA. Le passage par les carrés explique deux choses. D'abord la **sensibilité** : un ticket de 1 343 666 FCFA pèse sur la variance proportionnellement au carré de son écart, donc des milliers de fois plus qu'un ticket ordinaire. Ensuite le **format** : extraire une racine carrée produit des décimales, même quand les données sont des entiers — la dispersion d'une série d'entiers n'a aucune raison d'être un entier.

Faites-le dans un tableur, en trois colonnes, pour voir le mécanisme plutôt que le résultat : écart en A2 par `=B2-MOYENNE(panier)`, carré en C2 par `=A2^2`, variance par `=SOMME(C2:C317)/`

(NB(B2:B317)-1), écart-type par =RACINE() du résultat. Vous venez de reconstituer VAR.S et ECARTYPE.STANDARD : comparez, vous devez retrouver 182 095 au franc près.

Le dénominateur $n - 1$ mérite deux phrases. Il s'appelle le **degré de liberté** (degree of freedom) : une valeur sur 316 a déjà servi, la moyenne, et n'est plus libre. On divise par $n - 1$ quand la moyenne a été calculée sur le même échantillon ; sans cette correction, la variance serait systématiquement trop petite. Sur 316 lignes, l'écart entre les deux conventions vaut un facteur de 1,0016 : négligeable en valeur, décisif en cohérence — tout le module raisonne en échantillon, y compris le test du chapitre M02.C08.

5.3 L'IQR et la règle des 1,5 : une borne qui résiste à ce qu'elle détecte

Définition. Les **bornes de Tukey** (Tukey fences, « moustaches » ou limites externes en français) sont $Q1 - 1,5 \times IQR$ et $Q3 + 1,5 \times IQR$. Une valeur est dite **aberrante au sens de Tukey** si elle les franchit. Le coefficient 1,5 est une convention, pas une loi : on le porte à 3,0 pour ne signaler que l'exceptionnel.

Sur les paniers : $Q1 = 20\,635$, $Q3 = 130\,559$, $IQR = 109\,924$, et $1,5 \times IQR = 164\,886$. La borne haute vaut donc 295 445 FCFA, la borne basse -144 251 FCFA. Vingt-cinq tickets franchissent la haute ; un seul franchit la basse, et c'est le retour de 150 804 FCFA rencontré au chapitre M02.C02.

Comparez avec une borne « à deux écarts-types », soit $\pm 364\,190$ FCFA autour de la moyenne. D'un côté la borne basse descend bien au-dessous de tout ce que le fichier contient — la règle ne signale jamais rien en bas ; de l'autre la borne haute ne rattrape qu'une douzaine de tickets et laisse filer les autres. Voilà, en deux lignes de calcul, pourquoi une borne de détection doit être bâtie sur un indicateur robuste : une règle qui intègre les détectés dans son calcul se laisse fixer par eux.

Faites-le dans le SQL. (les vues `lignes_ventes` et `paniers` ont été créées au C02, § « Pour la suite du module ») :

```
WITH q AS (
  SELECT percentile_cont(0.25) WITHIN GROUP (ORDER BY panier) AS q1,
         percentile_cont(0.75) WITHIN GROUP (ORDER BY panier) AS q3
  FROM paniers
)
SELECT ROUND(q1 - 1.5 * (q3 - q1)) AS borne_basse,
       ROUND(q3 + 1.5 * (q3 - q1)) AS borne_haute,
       q3 - q1                    AS iqr
FROM q;
```

Conseil professionnel. Une borne basse négative sur des montants est un diagnostic, pas un résultat : elle dit que la série est si large que rien ne peut y être « anormalement petit ». Dites-le en réunion — « aucune alerte possible en bas » — plutôt que de supprimer la borne ou de la plaquer à zéro en silence.

5.4 Comparer deux colonnes : le coefficient de variation

Définition. Le **coefficient de variation** (CV, coefficient of variation) est l'écart-type divisé par la moyenne, exprimé en pourcentage. Il est sans unité, donc comparable entre séries d'échelles différentes ; il n'a aucun sens si la moyenne est proche de zéro, ni sur une grandeur sans rapport (un code client, une température en Celsius).

Série	Moyenne	Écart-type	CV	Lecture
Panier (316 tickets)	114 156 FCFA	182 095 FCFA	159,5 %	dispersion très supérieure au centre
Montant par ligne (480 lignes)	75 152 FCFA	143 915 FCFA	191,5 %	plus large encore
Pièces par ligne (480 lignes)	7	8,4	119,7 %	même nature de désordre

Les trois CV dépassent 100 %. Ce n'est pas une anomalie de l'extrait : c'est la nature d'un commerce de matériaux, où une commande de chantier côtoie trois achats de vis. La grille de lecture d'usage — une convention d'équipe, pas un théorème : CV inférieur à 15 %, série stable, la moyenne se suffit ; de 15 à 30 %, moyenne utile à accompagner de l'écart-type ; au-delà de 50 %, la moyenne seule ne décrit plus rien, il faut montrer la distribution (M02.C05).

5.5 Par catégorie : où la moyenne est-elle descriptive ?

Voici le tableau qu'un acheteur réclame, et celui qui clôt une discussion. Sur les lignes, par CV croissant, avec l'effectif de chaque catégorie :

Catégorie	Lignes	Moyenne (FCFA)	Écart-type (FCFA)	CV
Peinture	34	86 422	70 320	81,4 %
Consommables	57	43 877	45 130	102,9 %
Matériaux	143	45 590	49 286	108,1 %
Quincaillerie	112	37 528	45 358	120,9 %
Bois & panneaux	24	201 865	318 080	157,6 %
Plomberie	57	153 596	247 146	160,9 %
Electricité	53	119 088	202 897	170,4 %

Trois lectures professionnelles :

1. **Peinture contre Electricité** : des moyennes proches (86 422 et 119 088 FCFA), des écarts-types sans rapport (70 320 contre 202 897 FCFA). Piloter ces deux rayons avec le même indicateur, c'est piloter mal le second.
2. **Consommables contre Quincaillerie** : des écarts-types presque identiques (45 130 et 45 358 FCFA) mais des CV différents (102,9 % contre 120,9 %), parce que les niveaux diffèrent. Cas d'école de l'écart-type qui ment et du CV qui dit vrai.
3. **Bois & panneaux** : 24 lignes, une moyenne de 201 865 FCFA, un CV de 157,6 %. Chiffre peu descriptif et peu précis : deux raisons de ne pas négocier dessus.

Faites-le dans le SQL. (les vues `lignes_ventes` et `paniers` ont été créées au C02, § « Pour la suite du module ») :

```
SELECT categorie,
       COUNT(*)           AS lignes,
       ROUND(AVG(montant_ttc)) AS moyenne,
       ROUND(STDDEV_SAMP(montant_ttc)) AS ecart_type,
       ROUND(100.0 * STDDEV_SAMP(montant_ttc)
            / NULLIF(AVG(montant_ttc), 0), 1) AS cv_pct
FROM lignes_ventes
GROUP BY categorie
ORDER BY cv_pct DESC;
```

Le `NULLIF` n'est pas un ornement : sans lui, une catégorie vide ou de moyenne nulle fait échouer la requête entière, et six lignes justes ne servent à rien si la septième plante le calcul.

5.6 L'erreur type : de combien votre moyenne est-elle fausse ?

Définition. L'erreur type de la moyenne (standard error of the mean, SE) est l'écart-type divisé par la racine carrée de l'effectif. Elle ne décrit pas la diversité des clients : elle décrit votre ignorance de la moyenne, c'est-à-dire de combien une autre collecte vous aurait donné un autre chiffre.

Pour les paniers : 10 244 FCFA, soit 9,0 % de la moyenne de 114 156 FCFA. La phrase à tenir en réunion : « notre panier moyen est de 114 156 FCFA, précis d'environ deux fois 10 244 FCFA au niveau de confiance usuel de 95 % ». Un écart de 5 000 FCFA entre deux vendeurs est du bruit ; un écart de 40 000 FCFA commence à être une information ; l'écart maximal observé entre les quatre vendeurs de l'extrait, 34 014 FCFA, est en zone intermédiaire — le chapitre M02.C08 tranche cette question par un test, et la tranche en faveur du doute.

Notez le comportement de la formule : la précision progresse comme la racine de l'effectif, donc pour diviser l'erreur type par deux il faut quadrupler le nombre de tickets. C'est la phrase à prononcer quand un collègue réclame « encore un mois de données » pour arbitrer un écart de 2 %.

Faites-le dans un tableur : `=ECARTYPE.STANDARD(plage)/RACINE(NB(plage))`. **En pandas** : `s["montant_ttc"].std(ddof=1) / np.sqrt(len(s))`. Une formule, trois outils, un effet immédiat sur la qualité des discussions : à ce stade du manuel, c'est l'indicateur au meilleur rapport effort-utilité.

Attention. Erreur type et écart-type se calculent avec la même fonction selon les logiciels, se notent tous deux en « ± », et se confondent couramment dans les tableaux de bord. Multiplier l'erreur type par 1,96 donne un intervalle de confiance sur la moyenne ; multiplier l'écart-type par 1,96 donne un intervalle où se trouve 95 % des clients. Deux phrases entièrement différentes, deux décisions opposées.

5.7 Deux dispersions robustes, et ce que leur écart apprend

Définition. L'écart absolu médian (MAD, median absolute deviation) est la médiane des valeurs absolues des écarts à la médiane. Dispersion entièrement robuste : aucune valeur extrême ne peut la déplacer, puisqu'elle est elle-même un ordre statistique.

Sur nos paniers, la MAD vaut 43 372 FCFA contre 182 095 FCFA à l'écart-type : l'écart entre les deux est le diagnostic. Une MAD au quart de l'écart-type annonce une série tenue par quelques valeurs. Le tableur ne la connaît pas ; trois colonnes suffisent, `=ABS(valeur-MEDIANE(plage))` puis `=MEDIANE()` sur la colonne obtenue.

Second garde-fou, la **moyenne tronquée** (trimmed mean) : on retire les 25 tickets hors borne haute et le CV tombe de 159,5 % à 96,6 %. Le niveau reste élevé mais devient descriptible ; la médiane, elle, ne bouge que de quelques milliers de francs (58 423 contre 54 044 FCFA). Règle de lecture : un indicateur qui se stabilise fortement quand on retire quelques lignes est tenu par ces lignes — et cela s'écrit dans la note.

Sur les quantités, le même raisonnement donne 7 pièces en moyenne, 4 au centre, un écart-type de 8,4 (CV 119,7 %) et une amplitude de 81 — de -13 à 68 dans le fichier nettoyé, de -13 à 14 000 dans l'énoncé, avant correction des 7 lignes multipliées par mille. Le seul énoncé de ces nombres suffit à dire que `quantite` ne se prête à aucune prévision en l'état : c'est une affaire de dispersion, pas de moyenne.

5.8 Quel outil pour quelle dispersion

Situation	Outil recommandé	Pourquoi	Ce qu'on évite
CV et écart-type par catégorie, sur 480 lignes	SQL (GROUP BY + STDDEV_SAMP)	un bloc pour moyenne, écart-type, CV, effectifs	sept tableaux croisés recopiés à la main
Vérification pédagogique du calcul	tableur, colonnes intermédiaires	on voit les carrés, on comprend la variance	la calculette : le résultat sans le chemin
MAD, moyenne tronquée	tableur ou pandas	le tableur n'a pas de fonction dédiée, pandas si	tout recalculer à la main sur 316 lignes
Erreur type d'une moyenne	les trois	une formule, effet immédiat	conclure sans elle
Seuil d'alerte publié	tableur puis SQL	bornes lisibles et rejouables	une borne bâtie sur l'écart-type, contaminée
Indicateur de dispersion en diffusion	Power BI ou équivalent, plus tard	le lecteur a besoin du contexte du grain	l'export d'un tableau de valeurs brutes

Pourquoi pas un outil de BI dès maintenant ? Vous publierez ces mesures dans un tableau de bord — dashboard, dans le jargon — au module M06, et ce sera le bon endroit. Mais un indicateur de dispersion diffusé sans sélecteur de grain ni légende se lit comme une anomalie : le lecteur ne sait jamais si l'écart-type qu'il voit décrit les clients, les tickets ou les lignes. À l'étape de préparation, le tableur ou le SQL obligent à nommer le grain — c'est pour cela qu'on y reste.

Boîte à outils. Le contrôle minimal de toute mesure de dispersion : (1) l'effectif utilisé s'écrit à côté de l'indicateur — $n = 316$ pour les paniers, 480 pour les lignes, jamais « nos données » ; (2) l'écart-type doit être plus grand que la MAD et plus petit que l'étendue, sinon vous avez publié une variance ou un écart-type de population sans le vouloir ; (3) un CV supérieur à 100 % s'accompagne d'une phrase sur la nature de la série, sinon l'interlocuteur entendra « erreur de données » ; (4) si la dispersion est calculée après nettoyage, avant/après en deux colonnes, jamais l'une sans l'autre.

6. Exemple concret : négocier le bois de chauffage, ou non

La demande. Le responsable des achats hésite à accorder une remise annuelle à un fournisseur de bois et panneaux, sur la foi d'un montant moyen de 201 865 FCFA par ligne. Sa question réelle : « ce niveau est-il assez stable pour que je négocie dessus ? »

Ce que dit le calcul.

Élément	Valeur	Interprétation
Lignes de la catégorie	24	trop peu pour une moyenne contractuelle
Moyenne	201 865 FCFA	le chiffre avancé en négociation
Médiane	77 904 FCFA	la ligne typique vaut un quart de la moyenne
Écart-type	318 080 FCFA	la dispersion dépasse le centre
CV	157,6 %	hors de toute zone négociable sur la moyenne

La décision. On ne négocie pas sur la moyenne de la catégorie. On négocie une **remise par gamme** (ciments, panneaux, bois de charpente séparément) ou un plafond de remise par commande : dans les deux cas l'indicateur de pilotage devient la médiane par gamme, pas la moyenne par catégorie. Le tableau tient en une page, sans test statistique, et il évite un contrat mal calibré.

La phrase à écrire dans la note. « La catégorie Bois & panneaux de l'extrait compte 24 lignes, une moyenne de 201 865 FCFA et une médiane de 77 904 FCFA ; l'écart-type (318 080 FCFA) excède la moyenne. Une remise assise sur la moyenne catégorie serait versée sur des lignes qui ne lui ressemblent pas. Nous recommandons de conduire la négociation par gamme, avec la médiane de chaque gamme pour base. »

7. Démonstration pas à pas : les trois dispersions, trois outils, un contrôle

Point de départ. Fiche `donnees/reference/ventes_magasin5_2025_ATTENDU.csv` ouverte dans le tableur : 480 lignes de données, lignes 2 à 481, colonne `montant_ttc` en I.

Étape 1 — Le bon effectif. `=NB(I2:I481)` doit renvoyer 480. Si vous obtenez 478 ou moins, des valeurs texte se sont glissées dans la colonne et la dispersion portera sur un sous-ensemble — c'est l'erreur du chapitre M01.C04, rejouée.

Étape 2 — L'étendue. `=MAX(I2:I481)-MIN(I2:I481)` → 1 380 482 FCFA, entre le maximum de 1 229 678 FCFA et le minimum de -150 804 FCFA. Écrivez les deux bornes à côté du résultat : une étendue sans ses deux termes est invérifiable par un tiers.

Étape 3 — L'IQR et les bornes. `=QUARTILE.INC(I2:I481;1)` et `=QUARTILE.INC(I2:I481;3)`, leur différence, puis les bornes à $1,5 \times \text{IQR}$. Contrôle de cohérence : l'IQR d'une colonne de montants doit rester inférieur à son écart-type ; si l'inverse se produit, vous comparez deux colonnes différentes.

Étape 4 — L'écart-type par la voie longue. Colonnes intermédiaires comme au §5.2, sur les paniers : variance 33 158 631 393, écart-type 182 095. Comparez à `=ECARTYPE.STANDARD()` : au franc près c'est bon ; sinon vous avez divisé par n au lieu de $n - 1$.

Étape 5 — L'erreur type. `=ECARTYPE.STANDARD(plage_paniers)/RACINE(NB(plage_paniers))` → 10 244 FCFA. Écrivez la phrase complète dans votre journal de travail, avec les trois nombres.

Étape 6 — Rejouer en SQL, puis en pandas. Reprenez la requête du §5.5 : le CV de Plomberie doit ressortir à 160,9 %.

```
pan = df.groupby("n_ticket")["montant_ttc"].sum().rename("panier")
stat = pan.agg(["count", "mean", "median", "std", "min", "max"])
cv = 100 * stat["std"] / stat["mean"]
se = stat["std"] / np.sqrt(stat["count"])
q1, q3 = pan.quantile([0.25, 0.75])
borne_haute = q3 + 1.5 * (q3 - q1)
n_hors = int((pan > borne_haute).sum())
```

Dernière ligne : 25. Si vous obtenez 24 ou 26, c'est la borne ou le comparateur qui n'est pas le bon — strict contre inclus est la cause la plus fréquente de cet écart d'une unité.

Contrôles qualité du chapitre.

#	Contrôle	Seuil	Résultat attendu	Si échec
1	Écart-type des paniers recompté par la voie des carrés	± 1 FCFA	182 095	dénominateur $n - 1$ oublié
2	CV des lignes recompté	0,1 point	191,5 %	arrondis d'affichage
3	Effectif hors borne haute de Tukey, par filtre	identité	25 tickets	opérateur de comparaison
4	Couverture du tableau §5.5	7 catégories, 480 lignes	7 / 480	une catégorie sans ligne est restée
5	Ordre $\text{MAD} < \text{écart-type} < \text{étendue}$	les trois inégalités	$43\,372 \cdot 182\,095 \cdot 1$ 494 470	indicateur mal identifié

8. Erreurs fréquentes

1. **Comparer des écart-types entre colonnes d'échelles différentes.** « La quantité varie moins que le montant : 8,4 contre 143 915. » Les CV sont de 119,7 % et 191,5 % : la conclusion est juste, l'argument était faux — et il eût été faux en sens inverse. Règle réflexe : jamais un écart-type sans sa moyenne.
2. **Confondre écart-type et erreur type** (§5.6) : mêmes fonctions, mêmes noms selon le logiciel, même signe « $\pm$ ».
3. **Choisir ECARTYPEP par principe.** L'écart est minime sur 316 tickets, mais l'incohérence se propage à tout le module, qui raisonne en échantillon.
4. **Publier un CV de 191,5 % en rouge comme une anomalie.** C'est la nature du commerce de matériaux : un CV élevé se commente, il ne se signale pas — sauf référence métier explicite.
5. **Recalculer les bornes de Tukey après avoir retiré les valeurs extrêmes.** On détruit le bénéfice : la borne se calcule sur la série complète puis s'applique. Si vous écarter 25 tickets, énoncez la règle avant.
6. **Lire « 68 % des valeurs dans l'intervalle moyenne $\pm$ écart-type ».** Cette lecture suppose une distribution approximativement symétrique, ce que M02.C05 montre faux ici : sur 316 tickets asymétriques, l'intervalle ne couvre pas 68 % de la série.

9. Bonnes pratiques professionnelles

1. **Toujours deux dispersions, jamais une** : l'IQR pour borner, l'écart-type ou le CV pour comparer. Celui qui n'en cite qu'une se fait surprendre par la question suivante.
2. **Écrire l'effectif à côté de l'indicateur.** « CV de 159,5 % (316 tickets) » n'a pas la même valeur que « CV de 159,5 % (24 lignes) » : dans le second cas, le chiffre est incertain.
3. **Nommer le périmètre de nettoyage.** Un CV sur la série complète et un CV après retrait des 8 lignes de retours (-283 933 FCFA) sont deux chiffres corrects : le lecteur doit savoir lequel il a sous les yeux.
4. **Transformer l'indicateur en décision explicite.** « CV de 157,6 % → pas de remise assise sur la moyenne catégorie » : une dispersion qui ne change aucun comportement n'est qu'un chiffre de plus.
5. **Prévenir, pas punir.** Un seuil d'alerte sert à regarder, pas à noter un vendeur. Le premier usage d'une borne de Tukey en entreprise est d'ouvrir une enquête, presque jamais de fermer un compte.
6. **Conserver la requête de dispersion en annexe.** Dix lignes, rejouables : c'est elles qui vous feront gagner la réunion de l'année prochaine.

10. Exercice guidé — trois dispersions sur la colonne des prix

Énoncé. Sur la colonne `prix_unitaire_ht` du fichier attendu (480 lignes), calculez étendue, IQR, écart-type, puis CV, et concluez en deux lignes sur l'usage de la moyenne de prix en négociation.

Vous faites — barème 10 points, total 10.

Étape	Ce que vous produisez	Points
A	Effectif et unité (480 lignes, FCFA) écrits en tête	1
B	Étendue, avec ses deux termes	2
C	IQR, et bornes de Tukey qui en découlent	2

Étape	Ce que vous produisez	Points
D	Écart-type et CV, avec la moyenne à côté	3
E	Conclusion en deux lignes, un usage décidé	2

Nous vérifions. Les bornes du prix unitaire sont 675 et 40 550 FCFA : deux extrêmes plausibles dans un catalogue de quincaillerie, à confronter au fichier fournisseur (M01.C06) avant d'en faire un argument. La moyenne de la colonne ne décrit pas le catalogue, elle décrit son arithmétique : ce qu'on en peut tirer n'est pas « le prix moyen est de tant » mais « la moitié du catalogue tient dans telle plage » — c'est l'IQR qui répond, et c'est lui qui se négocie.

Nous corrigeons. Deux erreurs classiques : comparer ce CV à celui d'une autre colonne sans dire que les grains diffèrent (prix par produit contre montant par ligne) ; proposer de « supprimer les produits à prix aberrants » avant d'avoir regardé ce qu'ils vendent réellement.

11. Exercices autonomes

Exercice 3.1 (★) — Les trois dispersions, une par une. Sur les montants **par ligne** (480 lignes), calculez étendue, IQR, écart-type et CV. (attendu : étendue 1 380 482 FCFA, écart-type 143 915 FCFA, CV 191,5 %)

Exercice 3.2 (★) — Deux fournisseurs de ciment. L'un annonce 50 kg par sac avec un écart-type de 0,4 kg, l'autre 49,8 kg avec 0,2 kg. Le cahier des charges accepte de 49,5 à 50,5 kg. Lequel choisir, et que calculez-vous ?

Exercice 3.3 (★★) — Le CV par catégorie, sans recopier. Retrouvez le CV de la catégorie Plomberie et l'effectif qui le soutient. (attendu : 160,9 %, écart-type 247 146 FCFA, 57 lignes)

Exercice 3.4 (★★) — Écart-type ou MAD ? Pour chacune de ces séries, dites lequel vous citez en priorité, en une ligne de justification : (a) 480 montants de lignes ; (b) les effectifs de 30 magasiniers répartis sur six sites ; (c) 500 délais de livraison dont trois retards de 40 jours.

Exercice 3.5 (★★★) — Note de stabilité pour l'acheteur. Six lignes à destination du responsable des achats : deux catégories dont la moyenne est utilisable, une où elle ne l'est pas, une borne d'alerte sur les tickets avec sa justification, et la précision de vos chiffres. (attendu : Peinture 81,4 % et Consommables 102,9 % ; Electricité 170,4 % ; borne 295 445 FCFA, 25 tickets ; erreur type 10 244 FCFA)

12. Correction détaillée

Exercice 3.1. Étendue : 1 229 678 moins -150 804, soit 1 380 482 FCFA. Écart-type : 143 915 FCFA pour une moyenne de 75 152 FCFA, d'où un CV de 191,5 % — sur cette colonne, la moyenne ne décrit pas la série. L'IQR se lit par `=QUARTILE.INC` : notez-le avec ses deux quartiles, sinon un tiers ne peut pas le vérifier. Point de méthode valorisé : l'effectif de 480 écrit à côté de chaque ligne du tableau.

Exercice 3.2. On calcule les CV : 0,8 % et 0,4 %. Le second est deux fois plus régulier et son centre est dans la tolérance, donc on le retient à caractéristiques égales. Réserve attendue : un écart-type ne dit pas quelle part des sacs sort de la tolérance sans hypothèse sur la distribution ; la réponse professionnelle est d'exiger un contrôle sur cent sacs, pas de signer sur la foi du seul écart-type.

Exercice 3.3. 57 lignes pour Plomberie, moyenne de 153 596 FCFA, écart-type de 247 146 FCFA, CV de 160,9 %. Avec un tel effectif, l'erreur type de la moyenne dépasse le cinquième de la moyenne : la conclusion « la moyenne ne décrit rien » est robuste, la valeur exacte du CV ne l'est pas. La phrase attendue tient en deux parties, et les deux doivent être là.

Exercice 3.4. (a) les deux : l'écart entre écart-type et MAD est lui-même le signal (182 095 contre 43 372 FCFA sur les paniers). (b) IQR ou MAD : effectif faible, un départ ou un recrutement domine. (c) MAD : trois délais extrêmes sur cinq cents faussent l'écart-type, et le sujet est précisément ces trois délais — on ne veut pas qu'ils entrent dans le critère qui doit les révéler.

Exercice 3.5. Note attendue. Peinture (CV 81,4 %) et Consommables (102,9 %) : moyennes utilisables comme base d'échange, même si le second CV dépasse encore la zone de confort. Electricité (CV 170,4 %, écart-type 202 897 FCFA) : aucune remise assise sur la moyenne. Borne d'alerte : 295 445 FCFA, soit Q3 plus une fois et demie l'IQR, justifiée parce qu'elle ne se laisse pas fixer par les tickets qu'elle signale ; 25 tickets la franchissent. Précision : moyenne à environ deux fois 10 244 FCFA près, CV connu à plusieurs points près. Toute ligne citant un nombre absent des mesures du socle est comptée 0.

13. Mini-projet M02.P2 — suite : la colonne « précision » (30 min)

Reprenez le **M02.P2** du chapitre précédent (deux pages, six nombres, une décision ; barème 20 points, seuil de validation 13) et ajoutez **deux colonnes** au tableau : le CV et l'erreur type, chacun avec son effectif. La règle d'écriture devient : toute comparaison entre deux vendeurs ou deux catégories est accompagnée de la précision des deux nombres comparés ; une comparaison dont l'écart reste inférieur à deux erreurs types est présentée comme « non discriminante à ce stade ». Deux conséquences à faire apparaître explicitement : la catégorie qui résiste le moins à l'analyse (Bois & panneaux, 24 lignes, CV 157,6 %) est écartée de la page de décision, et le seuil d'alerte proposé est calculé sur la série complète, avant tout retrait.

14. Résumé du chapitre

1. Trois dispersions, trois usages : l'**étendue** décrit les extrêmes (1 494 470 FCFA sur les tickets, 13,6 fois l'IQR), l'**IQR** décrit la moitié du milieu et sert de borne (109 924 FCFA), l'**écart-type** décrit la distance typique au centre et sert de matière première (182 095 FCFA).
2. Un écart-type ne se compare jamais seul : le **CV** le rend comparable (Peinture 81,4 %, Electricité 170,4 %), et c'est lui qui décide si une moyenne est pilotable.
3. L'**erreur type** (10 244 FCFA, 9,0 % de la moyenne) dit de combien votre moyenne est fautive ; sans elle, toute comparaison entre deux vendeurs est une opinion.
4. La **MAD** (43 372 FCFA) et le **CV tronqué** (96,6 % au lieu de 159,5 %) sont les garde-fous des séries sales — et l'écart entre robuste et non robuste est, lui aussi, une information.

15. À retenir

À retenir.

- Une moyenne sans dispersion est une opinion ; deux dispersions suffisent à décider : l'IQR pour borner, le CV pour comparer.
- Sur les tickets : étendue 1 494 470 · IQR 109 924 · écart-type 182 095 FCFA · CV 159,5 % · erreur type 10 244 FCFA (9,0 % de la moyenne) · MAD 43 372 FCFA, le tout sur 316 tickets.
- Une borne de détection se calcule sur la série complète, avant tout retrait ; sinon les détectés fixent la règle qui doit les détecter.
- CV supérieur à 50 % : la moyenne ne décrit rien, on montre la distribution.

À retenir. La formulation qui protège. Dans une note : « écart-type de X FCFA (moyenne Y FCFA, CV Z %, n = N tickets, fichier nettoyé) ». À l'oral : « cette moyenne est précise à p % près ; l'écart que vous voyez est plus petit que cette précision, donc nous ne statuons pas ».

16. Évaluation formative (auto-correction, 10 min)

1. Quelle dispersion est la moins affectée par une erreur de saisie sur une seule ligne, et pourquoi ? **2.** Comment passe-t-on de la variance à l'écart-type, et que faire des décimales obtenues ? **3.** Une série a une moyenne de 250 et un écart-type de 60 ; une autre, une moyenne de 4 000 et un écart-type de 900. Laquelle est la plus instable, et que calcule-t-on pour le savoir ? **4.** À quoi sert l'erreur type, concrètement, en réunion ? **5.** Vrai ou faux : la borne de Tukey se calcule après retrait des valeurs extrêmes. Justifiez.

Corrigé

1. L'IQR et la MAD : ils ignorent les extrêmes par construction, alors que l'étendue est entièrement portée par eux. 2. On extrait la racine carrée, ce qui ramène l'indicateur dans l'unité de la variable ; on affiche arrondi, on calcule avec les décimales. 3. Les CV : 24,0 % et 22,5 % — la première série est la plus instable, malgré un écart-type trois fois plus petit. 4. À traduire une moyenne en « valeur ± précision », donc à décider si un écart constaté vaut une action, une réunion, ou rien. 5. Faux : la borne se calcule sur la série complète puis s'applique ; sinon on écarte des valeurs d'après un critère qu'elles ont elles-mêmes fabriqué.

Auto-validation. Reprenez les cinq contrôles du §7 sur votre fichier, puis comparez vos cinq nombres à la table de référence : 182 095 · 109 924 · 43 372 · 10 244 · 295 445. En cas d'écart, vérifiez le grain avant l'arithmétique : n = 316 tickets, et non 480 lignes.

M02.C04 — Se situer : quartiles, déciles, percentiles, lecture du boxplot

L'idée du chapitre. Un percentile ne répond pas à « combien vaut le ticket ? » mais à « combien de tickets sont en dessous ? ». C'est la mesure qui transforme un montant isolé en position dans une distribution — et donc en seuil de politique commerciale, en alerte calibrée, en classement défendable.

Base de travail — obligatoire. Deux fichiers du socle, dans votre dossier 02_exercices/M02/, ouverts côte à côte : `donnees/projection/ventes_magasin5_2025.csv` (l'énoncé, 489 lignes × 13 variables) et `donnees/reference/ventes_magasin5_2025_ATTENDU.csv` (480 × 13). Séparateur point-virgule, encodage UTF-8, virgule décimale. Montants en franc CFA (FCFA). Effet de référence de ce chapitre : les **316 paniers** (ticket consolidé par `n_ticket`), construits au chapitre M02.C02. Chiffres mesurés, recopiés depuis `01_socle_donnees/data/reference/chiffres_cites.md`, section M02.

1. Objectifs du chapitre

À la fin de ce chapitre, vous êtes capable de :

1. calculer un quartile, un décile, un percentile quelconque sur une série triée — à la main d'abord, puis dans trois outils ;
2. expliquer pourquoi deux logiciels ne renvoient pas exactement le même 90e percentile, et dire quand l'écart compte ;
3. lire une boîte à moustaches sans légende : boîte, médiane décalée, moustaches, points isolés, échelle ;
4. retourner le calcul — passer d'un montant à son percentile, et d'un objectif de couverture au montant seuil ;
5. construire une argumentation de concentration sans jamais confondre part des tickets et part du chiffre d'affaires ;
6. décider quels percentiles publier dans un tableau de bord, et lesquels garder pour l'analyse interne.

2. Pourquoi cette notion est importante

Les positions répondent aux trois questions que votre direction posera réellement.

- « **À partir de combien un client est-il un gros client ?** » Ce n'est pas une question de montant, c'est une question de rang. Sur les 316 tickets de l'extrait, un ticket de 25 000 FCFA est au 30e percentile : ordinaire ; un ticket de 100 000 FCFA est au 70e : déjà rare ; un ticket de 200 000 FCFA est au 85e. Un seuil de politique commerciale se choisit donc en percentile, jamais en montant rond choisi pour sa beauté.
- « **Que couvre notre dispositif de faveur ?** » Les 10 % de tickets les plus élevés portent 47,5 % du chiffre d'affaires de l'extrait ; les 25 % les plus élevés en portent 71,2 %. Réserver un avantage au-dessus de Q3, c'est viser un quart des tickets et près des trois quarts des encaissements. Seule la table des positions rend cette phrase possible — pas la moyenne.
- « **Où se trouve le milieu de nos ventes ?** » La moitié des tickets tient entre 20 635 et 130 559 FCFA ; la moitié du chiffre d'affaires n'est atteinte qu'au 90e percentile. Sans les positions, ces deux faits sont invisibles, et l'entreprise décide avec un seul nombre.

Dans les faits. Le vocabulaire des positions est celui que les directions générales emploient spontanément : « dans le top 10 % », « au 9e décile », « le produit qui fait 80/20 ». Un analyste qui ne sait pas convertir ce langage en calcul est dessaisi de la discussion en trente secondes. Tout ce chapitre sert à traduire dans les deux sens, vite et juste.

3. Explication simple

Rangez les 316 tickets du plus petit au plus grand, sans rien calculer. Vous avez une **série ordonnée**, et chaque ticket occupe une **position** : le premier, le 158e, le 316e.

Les découpages usuels partagent cette file en parts égales : quatre parts (les **quartiles** Q1, Q2 — la médiane — et Q3), dix parts (les **déciles** D1 à D9), cent parts (les **percentiles** P1 à P99). Dire « ce ticket est au 85e percentile » veut dire « 85 % des tickets sont plus petits que lui ».

Le mot « percentile » — parfois écrit « centile », ou « percentille » sous l'influence de l'anglais percentile — porte deux sens selon l'usage : la **valeur à la frontière** (235 318 FCFA) et le **rang en pourcentage** (85). Cette ambiguïté est la source de toutes les confusions du domaine. La question de contrôle qui les règle : « est-ce que je cite un montant, ou un pourcentage de tickets ? ».

Une **boîte à moustaches** — boxplot, « diagramme en boîte » en français — est le dessin qui pose ces cinq nombres sur une ligne : la boîte va de Q1 à Q3, un trait marque la médiane, deux moustaches s'étendent jusqu'aux valeurs extrêmes tolérées, les points au-delà se dessinent à part. Un résumé complet de la distribution en trois centimètres de large.

4. Vocabulaire essentiel

#	Terme	Français — English — sens simple	À savoir
1	Quantile	quantile — quantile — valeur qui partage une série triée	terme générique ; quartile, décile, centile en sont des cas
2	Quartile	quartile — quartile — découpage en quatre	Q2 = médiane ; Q1 et Q3 encadrent la moitié du milieu
3	Décile	décile — decile — découpage en dix	D9 est le 90e percentile
4	Percentile	percentile — percentile — découpage en cent	ne pas écrire « percent » : le suffixe change le sens
5	Rang	rang — rank — position dans la série triée	sans tri préalable, il n'y a pas de percentile
6	Interpolation	interpolation — interpolation — valeur estimée entre deux observations	c'est elle qui fait diverger les logiciels
7	Boîte moustaches	à boîte à moustaches — boxplot — dessin des cinq nombres	« cinq nombres » : min, Q1, médiane, Q3, max
8	Moustache	moustache — whisker — plus grande observation dans la limite tolérée	ce n'est pas le maximum de la série
9	Point isolé	valeur aberrante au sens de Tukey — outlier	à expliquer, jamais à effacer sans le dire
10	Fréquence cumulée	fréquence cumulée — cumulative frequency	part des observations en dessous d'une valeur
11	Fonction répartition	de fonction de répartition — CDF, ogive — la courbe des fréquences cumulées	l'outil des seuils inversés

5. Cours approfondi

5.1 Un percentile est un rang, pas une valeur

Définition. Le **p-ième quantile** d'une série triée est la valeur en dessous de laquelle se trouve la part p de l'effectif. Le **quartile** correspond à $p = 0,25 ; 0,5 ; 0,75$, le **décile** à un dixième, le **percentile** à un centième. « Quantile » désigne la frontière ; « percentile » désigne tantôt cette valeur frontière, tantôt le pourcentage d'observations qui la précèdent.

Sur les 316 paniers de l'extrait, la table des positions mesure :

Position	Valeur (FCFA)	Écart avec la position précédente (FCFA)
P10	7 390	—
P20	16 107	8 717
Q1 (P25)	20 635	4 528
P40	41 064	20 429
Q2 (P50)	58 423	17 359
P60	74 427	16 004
Q3 (P75)	130 559	56 132
P80	165 177	34 618
P90 (D9)	235 318	70 141
P95	435 984	200 666
P99	1 001 048	565 064

Lisez la deuxième colonne, pas la première. Monter de P10 à Q1 — cinq points de percentile — coûte 4 528 FCFA ; monter de P90 à P95, autant de points, coûte plus de deux cent mille francs : la série **s'étale à droite et se resserre à gauche**. C'est la traduction numérique exacte de l'asymétrie constatée au chapitre M02.C03, et la raison pour laquelle un seuil de « client important » fixé en francs est si souvent mal calibré.

L'intervalle Q1-Q3 contient 158 tickets sur 316 : la moitié, au ticket près — c'est le contrôle de cohérence du §7. Un effectif de 165 ou de 148 ne veut pas dire que le logiciel a tort : il veut dire que les bornes n'ont pas été comptées de la même façon.

5.2 Le calcul, puis la divergence des logiciels

Le calcul à la main, sur $n = 316$ valeurs triées, pour trouver Q3 :

1. position théorique : 317 fois trois quarts, soit 237,75 ;
2. on prend la 237e valeur triée et on avance des trois quarts vers la 238e ;
3. résultat : 130 559 FCFA.

Le pas n° 2 s'appelle l'**interpolation linéaire** — linear interpolation — et c'est là que les outils se séparent. Pour le 90e percentile de la même série, les conventions les plus courantes donnent :

Convention	Où on la trouve	90e percentile (FCFA)
Interpolation linéaire, bords inclus	<code>=QUARTILE.INC</code> , <code>=PERCENTILE.INC</code> , pandas <code>quantile()</code> par défaut, <code>percentile_cont</code> en SQL	235 318

Convention	Où on la trouve	90e percentile (FCFA)
Observation immédiatement en dessous	pandas <code>interpolation="lower"</code> , <code>percentile_disc</code> en SQL	234 518
Observation la plus proche	pandas <code>interpolation="nearest"</code>	236 118
Interpolation exclusive	<code>=QUARTILE.EXC</code> , <code>=PERCENTILE.EXC</code>	243 010

Quatre réponses correctes, un écart maximal d'environ 8 500 FCFA sur 235 318 FCFA : 3,6 %. Sur 316 observations, sans conséquence pour une décision ; il cesse d'être négligeable quand l'effectif tombe à quelques dizaines, et devient décisif dès qu'un seuil devient contractuel. Deux règles en découlent : **nommer la méthode dans la note**, et **ne pas débattre d'un seuil à moins de deux chiffres significatifs**.

Faites-le dans un tableur. `=QUARTILE.INC(plage;3)` pour Q3, `=PERCENTILE.INC(plage;0,8)` pour P80, `=MEDIANE(plage)` pour P50. Les mêmes fonctions existent dans LibreOffice, où `=QUARTILE()` sans suffixe correspond à la méthode inclusive. Vérifiez sur votre fichier que P20 (16 107 FCFA) et P40 (41 064 FCFA) encadrent bien la médiane : sinon, votre plage de calcul ne couvre pas les 316 lignes — ou couvre les 480 lignes du fichier, ce qui est une autre série.

Attention. La fonction `=PERCENTILE()` sans suffixe, dans les versions anciennes d'Excel, est la méthode inclusive ; `=PERCENTILE.EXC` n'existe pas avant Excel 2010 et n'existe pas du tout dans certains tableurs en ligne. Si un classeur que vous recevez la contient, vérifiez le résultat sur une petite série avant de le recopier dans une note.

5.3 Retourner le calcul : du montant au percentile

Le besoin inverse est encore plus fréquent en réunion : « notre plus gros client du mois, il est où ? ». On compte

les observations strictement inférieures au montant, on divise par l'effectif, on lit le pourcentage. Sur l'extrait

25 000 FCFA → 30e percentile ; 100 000 FCFA → 70e ; 150 000 FCFA → 78e ; 200 000 FCFA → 85e.

Faites-le dans les trois outils. En SQL ((les vues `lignes_ventes` et `paniers` ont été créées au C02, § « Pour la suite du module »)) :

```
SELECT ROUND(100.0 * COUNT(*) FILTER (WHERE panier < 200000) / COUNT(*)) AS percentile
FROM paniers;
```

En pandas : `float((pan < 200000).mean() * 100)` → 85. En tableur : `=NB.SI(plage;"<200000")/NB(plage)`, formatée en pourcentage — multipliez par 100 à l'affichage et non dans la formule, sinon la cellule devient fausse dès qu'on la recopie ailleurs.

Deux précautions. D'abord, cette fréquence cumulée est **strictement inférieure** : « au 85e percentile » et « dans les 15 % meilleurs » ne coïncident jamais exactement, surtout dans une série dense. Ensuite, un percentile n'est pas un classement de valeur : il dit combien sont en dessous, pas combien pèsent — la part d'encaissements se calcule à part, en sommant les montants.

Définition. La **fréquence cumulée** (cumulative frequency) associe à une valeur la proportion d'observations inférieures ou égales ; sa courbe est la **fonction de répartition** (CDF, cumulative distribution function, ogive en français). Un seul objet mathématique derrière trois questions : quel percentile a ce montant ? quel montant correspond à ce percentile ? quelle part du chiffre d'affaires font les tickets plus petits que celui-ci ?

5.4 Lire une boîte à moustaches

Définition. La **boîte à moustaches** (boxplot) représente cinq nombres : le premier quartile et le troisième, qui forment la boîte ; la médiane, qui la coupe ; la plus petite et la plus grande observation restant dans les bornes de Tukey, qui forment les moustaches. Les observations hors bornes sont dessinées en points. Le « résumé en cinq nombres » (five-number summary) est cette même information, sans le dessin.

Boîte à moustaches des 316 paniers, échelle linéaire : la moitié du milieu tient à gauche



Figure — Boîte à moustaches des paniers du magasin 5 (fichier nettoyé, $n = 316$).

Les cinq choses à regarder, dans cet ordre. (1) La **boîte**, de Q1 à Q3 : elle contient la moitié du milieu, 109 924 FCFA de large ici. (2) Le **trait médian** : au centre de la boîte, la moitié du milieu est symétrique ; collé au bord gauche — notre cas —, il dit que la seconde moitié de la boîte est beaucoup plus étalée que la première. (3) Les **moustaches** : la plus basse observation restant dans la borne de Tukey, -19 711 FCFA, et la plus haute, 281 784 FCFA — ce ne sont **pas** le minimum et le maximum de la série. (4) Les **points isolés** : 25 tickets au-dessus de la borne, dont celui de 1 343 666 FCFA, et un seul en dessous, l'avoir de -150 804 FCFA. (5) L'**échelle** : sans graduations, une boîte ne dit rien ; sur une échelle logarithmique, elle dit autre chose.

Ce qu'une boîte ne dit pas. Elle ne montre pas les bosses : deux distributions de formes très différentes peuvent avoir la même boîte. Pour la forme, il faut l'histogramme — chapitre M02.C05, figure ci-dessous au chapitre suivant. C'est pourquoi les deux figures se complètent, et pourquoi un tableau de bord qui n'affiche que des boîtes aveugle son lecteur sur ce qu'il croit voir.

Conseil professionnel. Quand vous tracez des boîtes par catégorie, alignez-les sur une échelle horizontale commune et ordonnez-les par médiane croissante. Sept boîtes sur une échelle disent plus que sept diagrammes individuels : la comparaison est le sujet, pas la catégorie.

5.5 Déciles et concentration : ce que porte la pyramide

Définition. On appelle **concentration** le fait qu'une part donnée des observations porte une part différente — en général plus grande — du total. La représentation classique met en face les parts cumulées d'effectif et les parts cumulées de montant : c'est la **courbe de Lorenz** (Lorenz curve), outil de l'économie des inégalités, dont la table ci-dessous est la version discrète, en cinq coupes plutôt qu'en une courbe.

Les positions permettent de répartir le chiffre d'affaires entre les tranches de tickets. Sur l'extrait, les cumuls mesurés :

Tranche (du plus petit au plus grand)	Part des tickets	Part cumulée du CA
Sous Q1 (P25)	25 %	1,6 %

Tranche (du plus petit au plus grand)	Part des tickets	Part cumulée du CA
Sous la médiane (P50)	50 %	10,1 %
Sous Q3 (P75)	75 %	28,8 %
Sous P90	90 %	52,5 %
Au-dessus de P80	20,3 %	65,1 %
Au-dessus de P90 (le dernier décile, 32 tickets)	10,1 %	47,5 %

La lecture, en une phrase : **la moitié des tickets ne fait que 10,1 % des encaissements, et un dixième en fait presque la moitié.** C'est ce contraste, et lui seul, qui justifie de traiter le haut de pyramide à part.

Un détail de méthode, instructeur. Le « dernier décile », selon qu'on le définit comme les 10 % d'effectif les plus élevés ou comme tout ce qui dépasse le 90e percentile, contient 31 ou 32 tickets : les deux décomptes sont corrects et donnent 46,9 % et 47,5 % du chiffre d'affaires. Un découpage arrondi en effectif plutôt qu'en pourcentage change la réponse de 0,6 point. Écrivez la définition, sinon le relecteur refait le calcul, trouve un autre nombre, et doute de vous.

Attention. « Les 25 % des tickets les plus élevés font 71,2 % du CA » est une phrase sur la concentration. Elle ne dit rien d'une performance, encore moins d'une faute : dans un commerce de matériaux, un chantier représente à lui seul une journée de comptoir. La conclusion possible est une organisation — suivi dédié, conditions particulières, stock réservé —, jamais un jugement sur les vendeurs.

5.6 Décider avec les percentiles : trois usages types

1. **Fixer un seuil de couverture.** On veut réserver la livraison gratuite aux 20 % de tickets les plus élevés : le seuil est P80, soit 165 177 FCFA, et 64 tickets sur 316 (20,3 %) le franchissent, portant 65,1 % du CA. À 150 000 FCFA — montant rond, 78e percentile —, vous couvrez 22,5 % des tickets et 68,1 % du CA : la décision est la même, le cadrage est faux. On choisit le pourcentage, on en déduit le montant.
2. **Suivre le haut de pyramide.** Publier le 95e percentile (435 984 FCFA) plutôt que le maximum : le maximum est un ticket, le 95e est une statistique. Mais sur 316 tickets, P99 repose sur trois observations — à cet effectif, on publie P90 et on commente P95, on n'affiche pas P99.
3. **Découper une clientèle en strates.** Quatre groupes de 79 tickets environ (quartiles de dépenses) sont défendables : effectifs comparables, frontières explicites. Trois groupes « petits / moyens / gros » à seuils ronds ne le sont pas. Le jour où vous devrez justifier un échantillon d'audit — « on a pris les 15 % plus gros tickets » —, le percentile est votre seule ligne de défense : 48 tickets, 57,1 % du CA, frontière à 200 000 FCFA, tout est écrit et rejouable.

5.7 Quels percentiles publier, lesquels garder

Public	Ce qu'on publie	Ce qu'on garde pour l'analyse
Direction commerciale	médiane, Q3, P90, part du CA du dernier décile	P95, P99, le détail des points isolés
Contrôleur de gestion	Q1, médiane, Q3, IQR, effectif hors bornes	les commentaires ligne à ligne
Acheteur	médiane et IQR par catégorie, CV (M02.C03)	les percentiles par produit, trop instables
Audit, contentieux	tous les percentiles demandés, méthode nommée	rien : tout s'écrit
Lecture interne de formation	de cinq nombres et boîte à moustaches	la querelle d'interpolation

La règle d'écriture qui va avec : **un percentile publié s'accompagne de l'effectif et du mode de comptage des bornes**. « P90 = 235 318 FCFA (n = 316 tickets, fichier nettoyé, interpolation linéaire, comparaison strictement inférieure) » coûte une ligne de plus et ne se discute plus.

5.8 Calculer les positions dans les trois outils

Opération	Tableur	SQL (DuckDB)	pandas
Quartiles	=QUARTILE.INC(plage;1) puis (...),3)	percentile_cont(0.25) WITHIN GROUP (ORDER BY x)	s.quantile(.25)
Percentile quelconque	=PERCENTILE.INC(plage;0,8)	percentile_cont(0.8) WITHIN GROUP (...)	s.quantile(.8)
Observation la plus proche	—	percentile_disc(0.8) WITHIN GROUP (...)	s.quantile(.8, interpolation="nearest")
Déciles par groupe	tri + =RANG()	NTILE(10) OVER (PARTITION BY g ORDER BY x)	pd.qcut(g, 10)
Percentile d'une valeur	=NB.SI(plage;"<v")/ NB(plage)	COUNT(*) FILTER (WHERE x < v) / COUNT(*)	(s < v).mean()
Cinq nombres d'une boîte	formules ci-dessus	min, P25, P50, P75, max en une requête	s.describe(percentiles=[.25,.5,.75])

La requête de découpage qui sert ensuite dans tout le module — les déciles de tickets par vendeur ((les vues `lignes_ventes` et `paniers` ont été créées au C02, § « Pour la suite du module »)) :

```
WITH paniers AS (
  SELECT vendeur, n_ticket, SUM(montant_ttc) AS panier
  FROM lignes_ventes GROUP BY vendeur, n_ticket
),
decoupages AS (
  SELECT vendeur, panier,
    NTILE(10) OVER (PARTITION BY vendeur ORDER BY panier DESC) AS decile
  FROM paniers
)
SELECT vendeur, decile, COUNT(*) AS tickets, SUM(panier) AS ca_decile
FROM decoupages
GROUP BY vendeur, decile
ORDER BY vendeur, decile;
```

Le `NTILE` vit dans une requête à part : on ne peut pas découper et agréger dans le même `SELECT` (DuckDB répond `Cannot group on a window clause`, et c'est très bien qu'il réponde ça — mélanger les deux étapes donnerait un chiffre qui n'a pas de définition). `NTILE(10)` découpe en dix groupes d'effectifs égaux à **l'intérieur de chaque vendeur** : c'est le `PARTITION BY` qui rend licite la comparaison entre vendeurs de tailles différentes. Sans lui, vous découpez la planète en dix et vous appelez ça un classement.

Boîte à outils. Contrôle minimal de toute publication de positions : (1) $Q1 \leq \text{médiane} \leq Q3$, sans exception — sinon le tri ou l'effet est faux ; (2) l'effectif entre $Q1$ et $Q3$ vaut la moitié de n au ticket près ; (3) les moustaches sont des observations réelles, jamais des bornes calculées — vérifiez que la valeur de la moustache existe dans la colonne ; (4) un percentile de rang inférieur à 5 ou supérieur à 95 sur quelques centaines d'observations ne se publie pas, il se commente ; (5) la méthode d'interpolation s'écrit une fois par document, pas par ligne.

6. Exemple concret : la livraison gratuite, décidée au percentile

La demande. « Relevons le seuil de livraison gratuite de 100 000 à 150 000 FCFA : nous voulons la réserver aux gros tickets. » Trois questions, dans l'ordre.

Question	Calcul	Réponse mesurée sur l'extrait
Combien de tickets perdent le bénéfice ?	nb de tickets $\geq$ seuil	96 tickets à 100 000 FCFA (30,4 %), 71 à 150 000 FCFA (22,5 %)
Combien de chiffre d'affaires est en jeu ?	somme des tickets franchissant le seuil	76,7 % du CA au-dessus de 100 000 FCFA, 68,1 % au-dessus de 150 000 FCFA
Qui est touché, côté clients ?	clients distincts, pas tickets	372 clients distincts dans le fichier, dont 18 sans identifiant exploitable

Ce que la table des positions change à la discussion. Le seuil actuel est au 70e percentile, le nouveau au 78e. On n'écarte donc pas « un dixième des tickets » au sens large mais 25 tickets sur 316, et la tranche écartée — entre 74 427 et 165 177 FCFA, soit P60 à P80 — pèse 19,2 % du chiffre d'affaires : ce ne sont pas les tickets du comptoir, ce sont les petits chantiers. C'est exactement ce que la moyenne cache et que les percentiles montrent.

La conclusion professionnelle. Un seuil ne se fixe pas en francs mais en couverture. Note attendue : pour couvrir 20 % des tickets, le seuil est P80 = 165 177 FCFA (64 tickets, 65,1 % du CA) ; le seuil proposé de 150 000 FCFA couvre 22,5 % des tickets et 68,1 % du CA ; le seuil actuel de 100 000 FCFA en couvre 30,4 %. Trois chiffres, une décision, aucune contestation possible de méthode.

7. Démonstration pas à pas : tracer la boîte vous-même

Étape 1 — La série. Colonne des paniers, 316 valeurs (construite aux étapes 1 à 3 de M02.C02). Triez-la : dans le tableur, tri croissant sur la colonne ; en pandas, `pan.sort_values()`.

Étape 2 — Les positions. Calculez Q1, Q2, Q3 par la voie des positions, pas par la fonction : pour Q1, la position est le quart de 317, soit 79 et un quart ; interpolatez entre la 79e et la 80e valeur. Vous devez retrouver 20 635 FCFA.

Étape 3 — Le contrôle d'effectif. `=NB.SI(plage;">=20635")-NB.SI(plage;">130559")` doit donner 158. À 157 ou 159 près, ce sont les bornes : la convention retenue ici est l'intervalle fermé, écrivez la vôtre.

Étape 4 — Les moustaches. Plus grande valeur $\leq$ 295 445 FCFA $\rightarrow$ 281 784 FCFA. Plus petite valeur $\geq$ la borne basse $\rightarrow$ -19 711 FCFA. Notez que la moustache basse est négative : la série contient des avoirs (M02.C02, §5.6), et une boîte honnête les montre.

Étape 5 — Les points isolés. Vingt-cinq au-dessus de la borne haute, un en dessous de la basse. Comptez-les ; ne les dessinez pas « au doigt » : un effectif figé est un contrôle rejouable, un amas de points non.

Étape 6 — Le tracé. Échelle horizontale commune, boîte de Q1 à Q3, trait à la médiane, moustaches, points en petits cercles. Comparez à la figure du §5.4 : la ressemblance est le contrôle qualité.

Contrôles qualité du chapitre.

#	Contrôle	Seuil	Résultat attendu	Si échec
1	Ordre $Q1 \leq \text{médiane} \leq Q3$	sans exception	20 635 · 58 423 · 130 559	tri oublié
2	Effectif entre Q1 et Q3	n / 2 au ticket près	158	bornes incluses ou non

#	Contrôle	Seuil	Résultat attendu	Si échec
3	Les moustaches sont des valeurs de la colonne	appartenance	-19 711 · 281 784	borne confondue avec observation
4	Part cumulée du CA sous la médiane	recoupement avec §5.5	10,1 %	périmètre : tickets ou lignes
5	P20 et P40 encadrent la médiane	ordre	16 107 · 41 064	effet incomplet

8. Erreurs fréquentes

1. **Confondre moustache et maximum.** La moustache s'arrête à la dernière observation dans la borne ; le maximum est un point isolé. Écrire « la moustache va jusqu'à 1 343 666 FCFA » est doublement faux : c'est le maximum, et la borne vaut 295 445 FCFA.
2. **Publier un P99 sur 316 observations.** Trois tickets le déterminent : l'indicateur suit la valeur d'un seul client. À cet effectif, P90 est le rang le plus haut défendable.
3. **Découper en déciles sans base de comparaison.** Un « 1er décile » chez un vendeur de 125 lignes et chez un vendeur de 12 lignes ne désigne pas le même monde : découpez par vendeur (PARTITION BY) ou comparez des percentiles bruts, mais ne mélangez pas les deux dans la même phrase.
4. **Oublier l'interpolation et comparer deux outils.** Quatre valeurs possibles pour le même 90e percentile ; sans la méthode écrite, un désaccord de quelques milliers de francs devient une querelle de compétence.
5. **Lire un percentile comme un pourcentage de valeur.** « Au 85e percentile » ne veut pas dire « 85 % du chiffre » : le premier est un rang, le second une part monétaire. Sur notre série, les 15 % de tickets au-dessus du 85e percentile pèsent 57,1 % du CA — le double de ce que la confusion ferait croire.
6. **Décrire la distribution par les seuls percentiles, sans figure.** Une boîte se lit en dix secondes par un non-statisticien ; trois lignes de chiffres ne se lisent pas. C'est pourquoi l'étape 6 se fait à la main au moins une fois : on ne dessine pas ce qu'on n'a pas compris.

9. Bonnes pratiques professionnelles

1. **Écrire l'effectif et la méthode :** « P90 = 235 318 FCFA (n = 316, interpolation linéaire, fichier nettoyé) ».
2. **Publier la médiane et l'IQR d'abord** sur une série asymétrique ; les percentiles hauts en commentaire, jamais en titre de graphique.
3. **Fixer les seuils en couverture, pas en montants ronds.** Un objectif de « 20 % des tickets » se contrôle six mois plus tard ; un objectif de « 150 000 FCFA » dérive silencieusement avec les prix.
4. **Tracer les boîtes à échelle commune,** ordonnées par médiane, avec le nombre de points isolés écrit sous chaque boîte.
5. **Ne jamais retirer un point isolé sans l'expliquer :** ici, le plus à droite est un chantier, le plus à gauche un avoir — deux réalités métier, pas deux fautes de saisie.
6. **Conserver la requête NTILE en annexe du livrable :** c'est elle qui rend le découpage reproductible par un tiers, donc défendable en audit.

10. Exercice guidé — les cinq nombres, puis le dessin

Énoncé. Sur les 316 paniers : retrouvez les cinq nombres de la boîte (moustaches comprises), dessinez la boîte à l'échelle, et écrivez la phrase de lecture destinée à un directeur non statisticien.

Vous faites — barème 10 points, total 10.

Étape	Ce que vous produisez	Points
A	Les trois quartiles, avec les positions utilisées	3
B	Les deux moustaches, identifiées comme observations réelles	2
C	Le décompte des points isolés, en haut et en bas	2
D	Le tracé à l'échelle commune	1,5
E	La phrase de lecture, sans jargon	1,5

Nous vérifions. $Q1 = 20\,635$, médiane = $58\,423$, $Q3 = 130\,559$ FCFA ; moustaches à $-19\,711$ et $281\,784$ FCFA ; 25 points isolés en haut, un en bas. Phrase attendue : « la moitié des tickets tient entre 20 635 et 130 559 FCFA, et 25 tickets dépassent 295 445 FCFA : ce sont les chantiers, pas des erreurs ». Si votre phrase contient le mot « aberrant » sans le définir, elle est à réécrire — c'est le mot qui fâche en réunion.

Nous corrigeons. L'erreur la plus fréquente : tracer les moustaches jusqu'au minimum et au maximum de la série. Le dessin reste joli, la lecture devient fausse, et le contrôle n° 3 du §7 vous l'aurait signalé.

11. Exercices autonomes

Exercice 4.1 (★) — La table des positions. Retrouvez $P10$, $P20$, $P40$, $P60$, $P80$ et $P95$ sur les paniers, puis écrivez la phrase qui compare les écarts entre ces positions. (attendu : $7\,390 \cdot 16\,107 \cdot 41\,064 \cdot 74\,427 \cdot 165\,177 \cdot 435\,984$ FCFA)

Exercice 4.2 (★) — Le percentile d'un montant. À quel percentile se situent un ticket de 100 000 FCFA et un ticket de 25 000 FCFA ? Donnez la formule de tableur, pas seulement le résultat. (attendu : 70e et 30e, par fréquence cumulée strictement inférieure)

Exercice 4.3 (★★) — Le seuil de couverture. Vous devez fixer le seuil de livraison gratuite pour que 15 % des tickets y soient éligibles. Quel percentile utilisez-vous, quel montant, quelle part du CA ? (attendu : $P85$, 200 000 FCFA, 48 tickets, 57,1 % du CA)

Exercice 4.4 (★★) — Déciles par vendeur. Découpez les tickets de chaque vendeur en déciles avec `NTILE(10) OVER (PARTITION BY vendeur ...)`, puis comparez le premier décile de Bationo à celui d'Ilboudo. Que devient la comparaison si vous découpez l'ensemble de la population au lieu de découper par vendeur ?

Exercice 4.5 (★★★) — Note de concentration. En six lignes, pour la direction : la part du CA des 25 % de tickets les plus élevés, celle des 50 % les plus petits, le seuil de « gros ticket » que vous proposez avec sa justification en percentile, et la réserve de méthode sur le découpage en déciles. (attendu : $71,2\% \cdot 10,1\% \cdot P90 = 235\,318$ FCFA · 46,9 % ou 47,5 % selon l'effectif retenu)

12. Correction détaillée

Exercice 4.1. Les six valeurs attendues sont celles du §5.1. La phrase de lecture porte sur les écarts : entre $P10$ (7 390 FCFA) et $P20$ (16 107 FCFA) il y a moins de la moitié de ce qui sépare $P20$ de $Q1$ (20 635 FCFA), et les derniers rangs s'étalent beaucoup plus loin. Un élève qui reco-

pie la liste sans comparer les écarts est noté à la moitié : la table ne vaut que par sa colonne de différences.

Exercice 4.2. `=NB.SI(plage;"<100000")/NB(plage)` pour 100 000 FCFA, la même formule avec 25 000 pour le second : 70e et 30e percentiles. Le tableur peut donner 70 ou 71 selon que l'on compte strictement en dessous ou en dessous ou égal — écrire le choix fait partie de la réponse, c'est même l'objet de la question.

Exercice 4.3. 15 % éligibles = couper au 85e percentile. Mesures de l'extrait : 200 000 FCFA correspond exactement

au 85e percentile, avec 48 tickets au-dessus (15,2 % de l'effectif) portant 57,1 % du CA. La vérification attendue

la part de chiffre d'affaires se lit en sommant les montants des tickets retenus, pas en recopiant les 15 % de couverture — les deux chiffres ne coïncident jamais, et c'est l'écart entre eux qui fait la valeur de la note.

Exercice 4.4. Par vendeur, chaque décile contient un dixième des tickets de ce vendeur : la comparaison porte sur les positions relatives, donc sur la homogénéité interne. Sur l'ensemble de la population, chaque décile contient un dixième des tickets tous vendeurs confondus, et les vendeurs se répartissent inégalement dans les déciles : la comparaison devient une mesure de mix, pas de performance. Les deux questions sont légitimes ; ce ne sont pas les mêmes, et un tableau de bord qui les mélange sans le dire induit la direction en erreur.

Exercice 4.5. Note attendue. Les 25 % des tickets les plus élevés portent 71,2 % du CA de l'extrait, les 50 % les plus petits 10,1 %. Nous proposons de définir le « gros ticket » au 90e percentile, soit 235 318 FCFA ($n = 316$, interpolation linéaire), parce que ce seuil ne dépend pas d'un seul client et qu'il couvre 10,1 % des tickets pour 47,5 % du CA. Réserve à écrire : selon que le dernier décile compte 31 ou 32 tickets, la part retenue vaut 46,9 % ou 47,5 % — 0,6 point d'écart, sans erreur de personne.

13. Mini-projet M02.P2 — suite : la page des positions (30 min)

Ajoutez au document du **M02.P2** (barème 20 points, seuil de validation 13) une page « positions » : la table des percentiles publiables (P10 à P95), la boîte à moustaches des sept catégories à échelle commune, et le seuil de politique commerciale choisi en percentile avec sa couverture en tickets et sa part de CA. Deux contraintes de rédaction, non négociables au barème : **aucun montant de seuil n'apparaît sans le percentile correspondant**, et **aucun percentile n'apparaît sans l'effectif ni la méthode**. Les deux points isolés extrêmes reçoivent chacun une phrase d'interprétation métier — une phrase qui ne contient pas le mot « aberrant ».

14. Résumé du chapitre

1. Un percentile est un **rang** : 85 % des tickets sont sous 200 000 FCFA, la moitié est entre 20 635 et 130 559 FCFA. Citer la valeur ou le pourcentage ne donne pas la même information.
2. Quatre **méthodes d'interpolation**, quatre réponses pour le même 90e percentile (234 518 à 243 010 FCFA) : nommez la vôtre et l'écart redevient un détail.
3. La **boîte à moustaches** se lit en cinq points — boîte, médiane décalée, moustaches qui sont des observations réelles, points isolés, échelle — et ne dit rien de la forme : l'histogramme vient après (M02.C05).
4. On décide en **couverture** : 158 tickets entre Q1 et Q3, 19,2 % du CA dans la bande P60-P80, 71,2 % au-dessus de Q3, 47,5 % dans le dernier décile.

15. À retenir

À retenir.

- $Q1 : 20\,635 \cdot$ médiane : $58\,423 \cdot Q3 : 130\,559 \cdot IQR : 109\,924 \cdot$ bornes de Tukey : $-144\,251$ et $295\,445 \cdot$ moustaches $-19\,711$ et $281\,784$ FCFA, sur 316 tickets.
- Un seuil se choisit en pourcentage de couverture, puis on en déduit le montant.
- Moustache $\neq$ maximum ; percentile $\neq$ pourcentage de valeur ; P99 sur 316 lignes ne se publie pas.
- Écrire l'effectif, la méthode d'interpolation, et le caractère inclus ou non des bornes.

À retenir. La formulation qui protège. « Le 90e percentile des tickets est de 235 318 FCFA ($n = 316$, fichier nettoyé, interpolation linéaire) ; 32 tickets le dépassent et portent 47,5 % du chiffre d'affaires de l'extrait. »

16. Évaluation formative (auto-correction, 10 min)

1. Quelle différence de sens entre « moustache haute » et « maximum de la série » ? **2.** Vous devez publier le montant à partir duquel on est « gros client », en couvrant 10 % des tickets. Que calculez-vous, et pourquoi pas le maximum divisé par dix ? **3.** Deux collègues obtiennent 234 518 et 243 010 FCFA pour le même percentile. Que s'est-il passé, que fait-on ? **4.** Que dit la table des positions du §5.1 sur la forme de la distribution, sans la voir ? **5.** Vrai ou faux : « 25 % des tickets font 71,2 % du CA, donc les petits clients ne servent à rien ».

Corrigé

1. La moustache s'arrête à la dernière observation restant dans la borne de Tukey (281 784 FCFA) ; le maximum est hors moustache et se dessine comme point (1 343 666 FCFA). 2. Le 90e percentile, soit 235 318 FCFA : couvrir 10 % des tickets, c'est couper à P90. Diviser le maximum par dix suppose une distribution régulière, ce que la série dément (asymétrie mesurée au chapitre M02.C03 : 3,84). 3. Deux méthodes d'interpolation, toutes deux justes : on écrit la méthode retenue dans la note, on cesse de discuter du chiffre. 4. Que la série est très asymétrique : les écarts entre positions croissent fortement vers la droite (4 528 FCFA entre P20 et Q1, contre plus de deux cent mille entre P90 et P95). 5. Faux : c'est une phrase sur la concentration des montants, pas sur l'utilité économique ; les petits tickets font le comptoir et la fréquence, et l'extrait ne permet pas de trancher la question de la marge — il permet de la poser correctement.

Auto-validation. Reprenez les cinq contrôles du §7 sur votre fichier : $20\,635 \cdot 58\,423 \cdot 130\,559 \cdot 158 \cdot -19\,711$ et $281\,784$. Si vos quartiles diffèrent, recomptez vos positions avant de changer de logiciel : sur 316 valeurs, l'erreur est presque toujours dans le tri ou dans l'effet, rarement dans la formule.

M02.C05 — La forme d'une distribution : histogramme, asymétrie, valeurs extrêmes

L'idée du chapitre. Moyenne, dispersion et positions sont des résumés. La **forme**, c'est ce qui reste quand on arrête de résumer : où les valeurs s'accumulent, où la série s'étire, combien de bosses on voit, et ce qu'on fait des trois tickets négatifs. Deux distributions peuvent avoir les mêmes indicateurs et des formes opposées — et appeler des décisions opposées.

Base de travail — obligatoire. Deux fichiers du socle, dans votre dossier 02_exercices/M02/, ouverts côte à côte : `donnees/projection/ventes_magasin5_2025.csv` (l'énoncé, 489 lignes × 13 variables) et `donnees/reference/ventes_magasin5_2025_ATTENDU.csv` (480 × 13). Séparateur point-virgule, encodage UTF-8, virgule décimale. Montants en franc CFA (FCFA). Effet de référence : les **316 paniers** construits au chapitre M02.C02. Chiffres mesurés, copiés depuis `01_socle_donnees/data/reference/chiffres_cites.md`, section M02.

1. Objectifs du chapitre

À la fin de ce chapitre, vous êtes capable de :

1. construire un histogramme lisible — choisir l'amplitude et l'origine des classes, ouvrir la première et la dernière — et justifier ce choix par les règles du métier ;
2. lire une forme : asymétrie à droite ou à gauche, une ou plusieurs bosses, queue épaisse ou non ;
3. calculer et interpréter les deux coefficients de forme (asymétrie et kurtosis) sans leur faire dire plus qu'ils ne disent ;
4. distinguer trois sortes de valeurs extrêmes — erreur de saisie, exception réelle, cas limite — et appliquer à chacune un traitement nommé dans la note ;
5. décider si un indicateur usuel (moyenne, écart-type, corrélation, droite de régression) est licite sur cette forme, ou s'il faut le remplacer ;
6. expliquer à un non-statisticien, avec une figure de trois centimètres, pourquoi « la moyenne ne raconte pas notre magasin ».

2. Pourquoi cette notion est importante

Tout ce que le module a posé depuis quatre chapitres converge ici, et trois décisions de gestion ne se prennent pas sans la forme.

- **Faut-il utiliser la moyenne ?** Sur nos 316 paniers, l'asymétrie mesure 3,84 : une série à 3,84 n'est pas « un peu penchée », elle est dominée par sa queue. C'est la mesure, et non une impression, qui autorise la réponse.
- **Faut-il alerter sur les extrêmes ?** L'histogramme montre 31 tickets au-dessus de 250 000 FCFA, soit 9,8 % de l'effectif, portant 46,9 % du chiffre d'affaires. Une alerte par ticket partirait onze fois par mois : personne ne lit onze alertes par mois. La forme règle le contrôle interne, pas seulement sa formule.
- **Peut-on modéliser ?** Les deux chapitres suivants estimeront une relation entre quantité et montant, puis la solidité d'un écart entre vendeurs. Ces calculs reposent sur des hypothèses

de forme ; connaître la forme, c'est savoir si l'on a le droit d'utiliser l'outil — et avec quelles précautions le dire.

Dans les faits. La forme est le seul endroit du manuel où une figure est plus lue que le texte. En entreprise, la courbe projetée en réunion décide souvent à elle seule : « en fait, c'est une minorité qui fait tout ». Ce chapitre vous apprend à la tracer correctement — un histogramme mal borné ment — et à ne pas la sur-interpréter.

3. Explication simple

Prenez les 316 paniers et rangez-les dans des cases de 50 000 FCFA : « moins de zéro », « de 0 à 50 000 », « de 50 000 à 100 000 », et ainsi de suite. Comptez ce que chaque case contient. Vous avez une **distribution de fréquences** — frequency distribution — le tableau qui dit où va le monde.

Dessinez ces comptes en barres jointives : c'est l'**histogramme**. Sur le fichier réel :

Case (FCFA)	Tickets	Part de l'effectif	Part du CA
moins de 0	3	0,9 %	-0,5 % (les avoirs retranchent)
de 0 à 50 000	133	42,1 %	7,3 %
de 50 000 à 100 000	84	26,6 %	16,5 %
de 100 000 à 150 000	25	7,9 %	8,6 %
de 150 000 à 200 000	23	7,3 %	11,0 %
de 200 000 à 250 000	17	5,4 %	10,3 %
250 000 et plus	31	9,8 %	46,9 %

Quatre faits sautent aux yeux, et aucun ne se réduit à un nombre : la série a **une bosse** à gauche, une **queue** qui ne s'arrête pas à droite, une **dernière classe ouverte** qui contient presque autant de tickets que les trois classes du milieu réunies, et cette dernière classe porte **plus du tiers de la recette**. Un histogramme de quarante-six classes aurait noyé le troisième point dans le bruit ; un histogramme de trois classes l'aurait masqué. Le choix des classes n'est pas cosmétique : c'est une décision analytique, et elle s'écrit.

4. Vocabulaire essentiel

#	Terme	Français — English — sens simple	À savoir
1	Distribution	distribution — distribution — répartition des valeurs d'une variable	se dit d'une variable, à un grain donné
2	Effectif de classe	effectif — frequency — nombre d'observations dans une case	toujours accompagner de la base (316)
3	Histogramme	histogramme — histogram — barres jointives par classes de valeurs continues	un diagramme en barres sépare des catégories, il ne compte pas des intervalles
4	Classe	classe — bin, class interval — intervalle de valeurs regroupées	« bin » en informatique, « classe » en statistique
5	Classe ouverte	classe ouverte — open-ended bin — sans borne haute (ou basse)	nécessaire quand la queue est longue ; à nommer
6b	Densité	densité de fréquence — density — effectif divisé par l'amplitude de classe	seule grandeur comparable si les classes ne sont pas égales
6	Amplitude	amplitude de classe — class width — largeur de l'intervalle	ici 50 000 FCFA ; ce n'est pas le nombre de classes

#	Terme	Français — English — sens simple	À savoir
7	Mode de la distribution	mode — mode — valeur ou classe la plus fréquente	classe 0 à 50 000 FCFA ici, 133 tickets
8	Asymétrie	asymétrie — skewness — déséquilibre gauche / droite	positive = queue à droite
9	Kurtosis	aplatissement — kurtosis — épaisseur des queues	dit peu de la bosse, beaucoup des extrêmes
10	Queue	queue — tail — extrémités de la distribution	« queue épaisse » = valeurs extrêmes structurelles
11	Valeur extrême	valeur extrême — outlier — observation très éloignée du reste	trois sorts : erreur, exception, cas limite
12	Troncation	troncage — trimming — retrait encadré des extrêmes	dire combien, selon quelle règle, et pourquoi

5. Cours approfondi

5.1 Une distribution, trois miroirs

Définition. La **distribution** d'une variable décrit comment ses valeurs se répartissent : quelles valeurs, avec quelles fréquences. Elle se donne de trois manières complémentaires — le tableau d'effectifs (exact, verbeux), l'histogramme (visuel, dépendant des classes) et la fonction de répartition (cumulée, robuste, vue au chapitre M02.C04). Un analyste sait produire les trois et en lire une seule devant un commanditaire.

Regard	Ce qu'il répond	Ce qu'il cache
Tableau d'effectifs par classe	« combien dans chaque tranche », et quel CA	la continuité entre classes voisines
Histogramme	« où est la bosse, où est la queue »	les effectifs précis, si les classes sont larges
Fonction de répartition	« quel percentile à ce montant »	la forme locale, les bosses éventuelles

Le premier réflexe est de vérifier l'effet total : les sept effectifs du §3 somment à 316, l'effectif de la série. Ce contrôle, qui prend vingt secondes, attrape les classes mal bornées, les lignes perdues au tri et les doublons non retirés — trois des défauts que le chapitre M01.C04 vous a fait corriger à la main.

5.2 Construire l'histogramme : les trois décisions

Définition. Un **histogramme** (histogram) est la représentation en barres jointives des effectifs tombant dans des intervalles contigus de même amplitude — les **classes**. Sa parenté avec le diagramme en barres est trompeuse : ici la surface compte, pas la hauteur seule, ce qui impose des classes d'égale largeur pour que les barres soient comparables. Quand les largeurs diffèrent, on dessine des **densités** (density histogram, histogramme de densité) : l'effectif divisé par l'amplitude de la classe.

1. **Amplitude.** Deux règles s'offrent à vous, légitimes, aucune automatique. Celle de **Sturges** (Sturges' rule) : 1 plus le logarithme en base 2 de l'effectif, soit 9 classes ici. Celle de **Freedman-Diaconis**, robuste aux extrêmes : l'amplitude vaut deux fois l'IQR divisé par la racine cubique de l'effectif, soit 32 277 FCFA, ce qui conduirait à 46 classes sur la plage totale. Quarante-six classes pour 316 observations : environ sept tickets par classe, aucune lecture pos-

sible. Retenir 7 classes de 50 000 FCFA est un compromis, et il s'écrit comme tel : « classes de 50 000 FCFA, première et dernière ouvertes ».

2. **Origine.** Des bornes rondes en francs (0 ; 50 000 ; 100 000) se lisent sans calcul mental ; des bornes issues d'une formule (32 277) se justifient mieux mais ne se lisent pas. En entreprise, la borne ronde gagne, à condition que le choix soit tracé.
3. **Extrémités.** La dernière classe est ouverte (« 250 000 et plus ») : bornée en haut, elle ferait disparaître une partie du chiffre d'affaires de la figure. La première l'est aussi, sinon les trois avoirs sont silencieusement exclus du graphique — et un graphique qui exclut des lignes ne somme plus à l'effectif.

Combien de tickets dans chaque tranche de 50 000 FCFA (dernière classe ouverte)




Figure — Histogramme des paniers, six classes de 50 000 FCFA, la dernière ouverte (chiffres lus dans chiffres_cites.json).

Faites-le dans un tableur. Sélectionnez la colonne des paniers, Insertion → Graphique → Histogramme. Deux réglages à corriger immédiatement : le nombre de classes — le réglage automatique produit sur cette plage des intervalles d'amplitude non ronde, que personne ne lit — et le nom des deux classes extrêmes. Si votre tableur ne sait pas ouvrir une classe, créez une colonne auxiliaire de regroupement par formules (`=SI(v>=250000;"250 k et plus";SI(v<0;"négatifs";...))`) : c'est plus long, mais le graphique devient vérifiable ligne à ligne, et il se trie.

Faites-le dans le SQL. (les vues `lignes_ventes` et `paniers` ont été créées au C02, § « Pour la suite du module ») :

```
SELECT CASE
    WHEN panier < 0      THEN '00. négatifs'
    WHEN panier < 50000  THEN '01. 0 - 50 k'
    WHEN panier < 100000 THEN '02. 50 - 100 k'
    WHEN panier < 150000 THEN '03. 100 - 150 k'
    WHEN panier < 200000 THEN '04. 150 - 200 k'
    WHEN panier < 250000 THEN '05. 200 - 250 k'
    ELSE                 '06. 250 k et plus'
END AS classe,
COUNT(*)      AS tickets,
SUM(panier)    AS ca
FROM paniers
GROUP BY classe
ORDER BY classe;
```

Les préfixes numérotés ne sont pas décoratifs : sans eux, `ORDER BY classe` range « 100 - 150 k » avant « 50 - 100 k » en ordre lexicographique, et votre figure raconte une bosse qui n'existe pas. C'est l'une des erreurs de représentation les plus fréquentes en SQL, et la plus invisible.

5.3 L'asymétrie : combien de queue à droite

Définition. L'**asymétrie** (skewness, notée γ_1 ou skew) mesure le déséquilibre de la distribution autour de son centre : en simplifiant, la moyenne des écarts au centre élevés au cube, normalisée par le cube de l'écart-type. Positive, la queue s'étire à droite ; négative, à gauche ; nulle, la distribution est symétrique. Le cube donne son poids à la direction : une valeur très à droite contribue positivement, une valeur très à gauche négativement.

Sur les 316 paniers, l'asymétrie vaut 3,84. La grille d'interprétation d'usage, en valeur absolue : moins de 0,5, quasi symétrique ; de 0,5 à 1, asymétrie modérée ; au-delà de 1, asymétrie forte. À 3,84, la série est fortement asymétrique à droite, et le contrôle croisé est immédiat : la moyenne (114 156 FCFA) vaut 1,95 fois la médiane (58 423 FCFA), et 71,8 % des tickets sont sous la moyenne (mesures M02.C02).

Le lien entre ces trois nombres se comprend plutôt qu'il ne se retient : plus la queue de droite est lourde, plus la moyenne est tirée vers le haut par rapport à la médiane, plus l'asymétrie est grande. Vous pouvez donc poser le diagnostic avec deux nombres seulement, sans logiciel de statistique — et c'est ce que vous ferez en réunion, parce que γ_1 ne se justifie pas devant un non-statisticien. Le coefficient, lui, sert à documenter : une ligne dans l'annexe méthodologique.

Attention. Un coefficient d'asymétrie ne se compare pas entre deux colonnes de grains différents. L'asymétrie des montants par ticket et celle des montants par ligne décrivent deux objets distincts : les comparer, c'est comparer la clientèle et les lignes de commande. Écrivez le grain à côté du chiffre.

5.4 Le kurtosis : ce que les queues racontent

Définition. Le **kurtosis** (kurtosis ; « aplatissement » en français, bien qu'il ne mesure pas la hauteur du pic contrairement à une légende tenace) pénalise la présence de valeurs lointaines : moyenne des écarts au centre élevés à la quatrième puissance, normalisée. pandas, Excel (=KURT) et LibreOffice renvoient l'**excès de kurtosis** (convention de Fisher) : 0 pour une loi normale, positif quand les queues sont épaisses.

Notre série affiche un excès de kurtosis de 18,25, soit 21,25 dans la convention de Pearson, qui ajoute 3. Le message : la distribution n'est pas seulement penchée, ses queues sont épaisses. Traduit en faits vérifiables sur l'extrait : 25 tickets dépassent 300 000 FCFA, 12 dépassent 500 000 FCFA, et le rapport du plus gros ticket à la médiane vaut 23,0.

Pourquoi ce chiffre intéresse le praticien : presque tous les outils des modules suivants — intervalles de confiance (M02.C08), droite de régression (M02.C06), contrôle statistique en production — supposent implicitement des queues modérées. Avec un excès de kurtosis de 18,25, un intervalle construit « à $\pm 1,96$ écart-type » est faux : la formule reste, mais il faut tronquer, ou passer par un calcul par ré-échantillonnage (M02.C07). Vous n'avez pas besoin de faire ce calcul aujourd'hui ; vous avez besoin de savoir **lire l'avertissement quand un autre le fait**, et le citer.

Faites-le dans un tableur. =KURT(plage) existe dans Excel et dans LibreOffice Calc et renvoie l'excès, comme pandas ; les versions récentes d'Excel le nomment =KURT(), l'anglais KURT restant l'appellation d'origine. Vérifiez toujours la convention de votre logiciel avant de citer le chiffre : un kurtosis de Pearson lu comme un excès de Fisher décale de 3 — écart minuscule sur l'indicateur, décisif sur la conclusion qu'on en tire.

5.5 Trois sortes de valeurs extrêmes, trois traitements

Le mot « aberrant » est le plus dangereux du vocabulaire statistique en entreprise : il ferme la discussion au lieu de l'ouvrir. Sur l'extrait, les points isolés relèvent de trois natures différentes, et c'est la nature qui décide du traitement.

Sorte	Exemple mesuré	Traitement	Phrase de note
Erreur de saisie	7 lignes de quantité multipliées par 1 000 dans l'énoncé (maximum 14 000, ramené à 68 après correction)	corriger à la source, garder la trace	« valeur corrigée selon la règle X, N lignes concernées »
Exception réelle	le plus gros panier, 1 343 666 FCFA	conserver, isoler dans l'analyse, nommer	« un chantier porte près de la moitié du CA de l'extrait »
Cas limite légitime	3 paniers négatifs, dont un à -150 804 FCFA (8 lignes d'avoirs, -283 933 FCFA au total)	conserver au total de caisse, exclure des indicateurs de vente	« les avoirs sont comptés à part ; le CA reste le CA »

Un même indicateur change de valeur selon le traitement, et c'est précisément ce qui doit s'écrire : en retirant les 25 tickets au-dessus de la borne haute de Tukey, la moyenne des paniers passe de 114 156 à 71 463 FCFA et le coefficient de variation de 159,5 % à 96,6 % (M02.C03). La série devient descriptible — mais elle ne décrit plus la même population.

Conseil professionnel. N'écrivez jamais « nous avons supprimé les valeurs aberrantes ». Écrivez : « trois tickets sont des avoirs, exclus des indicateurs de vente et inclus au total de caisse ; vingt-cinq dépassent la borne haute, conservés et commentés à part ; sept lignes contenaient une erreur de saisie corrigée en amont ». Trois phrases, trois décisions, plus aucune ambiguïté sur ce que vous avez fait des données.

5.6 Commenter une forme en cinq phrases — grille de rédaction

La forme ne se commente pas en adjectifs. Appliquez cette grille à toute série ; elle tient en un paragraphe.

1. **Étalement** : « la série va de -150 804 à 1 343 666 FCFA » (min, max).
2. **Accumulation** : « 136 tickets sur 316, soit 43,0 % de l'effectif, sont sous 50 000 FCFA, pour 6,8 % du CA » (classe modale et sa part monétaire).
3. **Centre robuste** : « la médiane est à 58 423 FCFA, la moyenne à 114 156 FCFA, rapport de 1,95 ».
4. **Queue** : « 31 tickets dépassent 250 000 FCFA et portent 46,9 % du CA ; 12 dépassent 500 000 FCFA ».
5. **Décision** : « ces trente-et-un tickets sont traités sur une ligne séparée du rapport mensuel ».

Les quatre premières phrases viennent des mesures du socle ; la cinquième est une décision. C'est la structure à réutiliser dans tous les modules : deux faits, un contraste, une extrémité, une décision.

5.7 Ce que cette forme interdit de faire

Trois interdictions tirées de cette série précise, pas d'un manuel :

- **la moyenne seule comme indicateur de politique commerciale.** 89 tickets dépassent la moyenne, soit 28,2 % de l'effectif : un dispositif calé sur « au-dessus de la moyenne » exclut sept clients sur dix, sans que personne ne l'ait décidé explicitement.
- **le raisonnement en « $\pm$ un écart-type ».** Cette lecture suppose une distribution à peu près symétrique ; avec une asymétrie de 3,84 et un excès de kurtosis de 18,25, l'intervalle autour de la moyenne ne couvre pas ce qu'on croit (M02.C03, §8.6).

- **le seuil « trois sigma » en contrôle interne.** Sur une série à queues épaisses, un tel seuil signale une fois sur deux la nature du métier, pas une anomalie. La borne de Tukey, assise sur l'IQR, reste la règle défendable à ce niveau de maturité de l'entreprise.

5.8 Représenter la forme : quelle figure pour quelle question

Question posée	Figure à produire	Ce qu'il faut écrire sur la figure
Où est la bosse, combien de bosses ?	histogramme (ce chapitre)	amplitude des classes, unité, effectif total
Qui possède quoi ?	courbe des fréquences cumulées	percentile lu sur l'axe supérieur (M02.C04)
Comparer des catégories	boîtes à moustaches alignées	médiane et nombre de points isolés par catégorie
Deux varient-elles ensemble ?	nuage de points	les 316 points, pas une moyenne par catégorie (M02.C06)
La série est-elle stable dans le temps ?	courbe mensuelle	dénominateur commun, mois creux explicités (M01.C04)

Boîte à outils. Contrôle minimal de toute figure de forme : (1) la somme des effectifs de classes doit redonner l'effectif total — 316 ici ; sinon, des observations sont hors du graphique ; (2) les classes ouvertes s'affichent avec la mention « et plus » ou « moins de », jamais avec une valeur imaginaire ; (3) une figure sans graduations d'axe ne se publie pas ; (4) le choix d'amplitude tient en une phrase dans la légende ; (5) si la figure contredit le tableau de chiffres, la figure a tort en premier — un histogramme se rate plus facilement qu'une moyenne.

6. Exemple concret : « nos clients ne sont pas comme ça »

La situation. Vous présentez le premier tableau de bord mensuel : panier moyen 114 156 FCFA, écart-type 182 095 FCFA, sept catégories. Le responsable du magasin refuse le chiffre — et il n'a pas tort : sa journée ressemble à 133 tickets sous 50 000 FCFA, pas à 114 156 FCFA.

Ce qui se joue. Il ne conteste pas le calcul, il conteste le résumé. Sa journée type correspond à la classe modale (0 à 50 000 FCFA, 42,1 % des tickets pour 7,3 % du CA) ; votre moyenne correspond à la queue. Les deux sont vrais ; un seul décrit le quotidien.

Attention. Une part d'effectif n'est pas une part de chiffre d'affaires, et le tableur calcule les deux sans vous avertir du changement d'objet : la classe 0 à 50 000 FCFA réunit 42,1 % des tickets et 7,3 % des encaissements, la classe ouverte 31 tickets (9,8 %) et 46,9 % du CA. Écrivez dans la légende ce qui est réparti — le nombre d'achats ou les francs encaissés. En titre de graphique, « part des clients » et « part du chiffre d'affaires » s'inversent souvent, et c'est la source numéro un des contresens en réunion.

La correction, en trois gestes. (1) Publier la médiane en indicateur, la moyenne en note. (2) Mettre l'histogramme du §5.2 en tête de page : le refus devient accord, parce que la figure montre ce que le nombre cachait. (3) Séparer le rapport en deux lignes de pilotage : comptoir (sous 50 000 FCFA, 133 tickets, 7,3 % du CA) et chantiers (au-dessus de 250 000 FCFA, 31 tickets, 46,9 % du CA), la classe du milieu (149 tickets, 46,4 %) servant de témoin.

Ce que le manager retiendra. « On ne pilote pas le comptoir avec les chiffres des chantiers » — phrase sans vocabulaire statistique, qui vient entièrement de la forme de la distribution. C'est

le meilleur argument à opposer à une direction générale qui préfère « un seul chiffre, c'est plus simple ».

7. Démonstration pas à pas : des comptes de classes à la bosse

Étape 1 — La série. Colonne des paniers, 316 valeurs (M02.C02). Conservez les valeurs négatives : c'est la première classe qui les accueille.

Étape 2 — Les bornes. Écrivez les bornes basses en colonne : -1 ; 0 ; 50 000 ; 100 000 ; 150 000 ; 200 000 ; 250 000. Le -1 n'est pas une plaisanterie : il permet de compter les négatifs dans leur propre classe au lieu de les perdre.

Étape 3 — Les comptes. `=NB.SI.ENS(panier;">="&$A2;panier;"<"&A3)` recopié vers le bas, soit 3 ; 133 ; 84 ; 25 ; 23 ; 17. La dernière classe se compte sans borne haute : `=NB.SI(panier;">=250000")` → 31.

Étape 4 — Le contrôle d'additivité. Somme des sept comptes : 316. À faire avant de dessiner quoi que ce soit : cette unique addition détecte les bornes mal écrites, et elle constitue la moitié des erreurs d'histogramme.

Étape 5 — Les parts. Divisez par 316 : 42,1 % pour la deuxième classe, 26,6 % pour la troisième. Écrivez la phrase : « la classe modale est 0 à 50 000 FCFA, avec 133 tickets sur 316 ».

Étape 6 — La moyenne et la médiane sur la figure. Placez-les sur l'axe : la médiane (58 423 FCFA) tombe dans la troisième classe, la moyenne (114 156 FCFA) une classe plus loin. Ce décalage visible fait comprendre l'asymétrie à un lecteur non averti — mieux que le coefficient de 3,84.

Contrôles qualité du chapitre.

#	Contrôle	Seuil	Résultat attendu	Si échec
1	Somme des effectifs de = n		316	borne haute manquante
2	Classe ouverte recomptée au filtre	identité	31	tri ou comparateur
3	Part de la classe modale	≈ 42 %	42,1 %	amplitude modifiée sans le dire
4	Ordre des classes dans la figure	tri numérique, lexicographique	pas préfixes « 01. », « 02. »	ORDER BY classe sans préfixe
5	Position relative moyenne / médiane	moyenne à droite	cohérent avec §6	série non triée

8. Erreurs fréquentes

- Les classes automatiques du logiciel.** Une amplitude issue d'un réglage par défaut produit des bornes sans rapport avec les usages du métier : des tranches qui ne commencent sur aucun multiple rond, et que personne ne lit. Réglez l'amplitude vous-même, et écrivez le réglage.
- Borne supérieure fermée trop tôt.** Dans la première version de la figure de ce chapitre, les bornes s'arrêtaient trop bas : la dernière classe absorbait tout le reste en un tas informe, et la queue disparaissait. Corriger a consisté à ouvrir la dernière classe — et à rendre au graphique sa part de CA (46,9 %).
- Confondre diagramme en barres et histogramme.** Le premier sépare des modalités disjointes (des catégories) ; le second joint des intervalles contigus. Mettre des espaces entre les

barres d'un histogramme suggère qu'il existe des montants « entre les cases » : ce n'est pas le cas.

4. **Lire le kurtosis comme une mesure de hauteur de pic.** Il parle des queues. La phrase correcte est « la série a des queues épaisses (excès de kurtosis 18,25) », pas « la série est pointue ».
5. **Supprimer les extrêmes pour « lisser ».** Après retrait des 25 tickets hors borne, le CV tombe à 96,6 % : le chiffre s'améliore, la population change. Dites-le, sinon vous présentez un magasin qui n'existe pas.
6. **Publier une forme sans effectif.** « Distribution asymétrique à droite » sur 316 tickets et sur 12 tickets ne veut rien dire de même : sur 12 valeurs, trois valeurs hautes suffisent à produire une forte asymétrie. L'effectif se cite avec la forme.

9. Bonnes pratiques professionnelles

1. **Écrire les trois décisions de construction** : amplitude, origine, ouverture des classes. Un histogramme reproductible est un histogramme dont on peut refaire les classes.
2. **Contrôler la somme des effectifs avant la figure** : vingt secondes, la moitié des erreurs évitées.
3. **Accompagner toute moyenne d'un diagnostic de forme** en une phrase : « asymétrie forte, médiane à retenir ».
4. **Séparer comptoir et chantiers dans les indicateurs**, pas seulement dans les discours : si la bosse et la queue appellent des décisions différentes, elles appellent deux lignes dans le rapport.
5. **Nommer le sort de chaque valeur extrême** (corrigée / conservée et commentée / exclue d'un périmètre) et son effectif, une fois pour toutes, dans l'annexe méthodologique.
6. **Conserver la table de comptes à côté de la figure propre** : c'est elle qui sert de preuve quand un chiffre est contesté six mois plus tard.

10. Exercice guidé — refaire les classes, et voir ce qui change

Énoncé. Sur les 316 paniers, construisez deux histogrammes : l'un en classes de 50 000 FCFA (votre référence), l'autre en classes de 100 000 FCFA. Comparez les deux lectures et concluez en trois lignes sur ce que le second masque.

Vous faites — barème 10 points, total 10.

Étape	Ce que vous produisez	Points
A	Les comptes des deux découpages, somme contrôlée à 316	3
B	Les deux figures, axes gradués, classes ouvertes mentionnées	3
C	La phrase sur ce que le grossissement masque	2
D	Le choix argumenté de l'un des deux pour le rapport mensuel	2

Nous vérifions. Le découpage fin donne 3 ; 133 ; 84 ; 25 ; 23 ; 17 ; 31. Le découpage large rassemble presque toute la masse dans les deux premières classes et ne montre plus qu'une traîne sans structure. Ce que le second masque : la concentration dans la classe 0 à 50 000 FCFA (42,1 % des tickets pour 7,3 % du CA) devient indiscernable d'une descente régulière, et les 31 tickets de la classe ouverte cessent d'exister en tant que tels.

Nous corrigeons. L'erreur classique est de conclure « le fin est meilleur ». Le critère n'est pas la finesse mais la question posée : pour répartir une charge de travail au comptoir, 50 000

FCFA ; pour une étude par tranches fiscales, 100 000 FCFA. La figure sert la décision, pas la statistique.

11. Exercices autonomes

Exercice 5.1 (★) — Le contrôle d'additivité. Refaites les comptes de classes de 50 000 FCFA sur les montants **par ligne** (480 lignes) et vérifiez la somme. Que devient la classe modale par rapport à celle des paniers, et pourquoi ? (attendu : somme 480 ; la masse s'accumule encore plus à gauche, la médiane par ligne étant sous la première borne)

Exercice 5.2 (★) — Les deux extrêmes. Retrouvez les paniers négatifs et les paniers les plus élevés ; classez chacun dans les trois sortes du §5.5 en une phrase de justification.

Exercice 5.3 (★★) — Sturges contre Freedman-Diaconis. Recomptez les deux règles sur la série (9 classes ; amplitude de 32 277 FCFA, donc 46 classes) et dites laquelle vous appliquez à un rapport mensuel, en justifiant par la lisibilité et non par l'élégance.

Exercice 5.4 (★★) — La deuxième bosse. Une stagiaire affirme : « il y a deux bosses, une vers 25 000 FCFA et une vers 150 000 FCFA, donc nous avons deux clientèles ». Que vérifiez-vous avant de retenir ou de rejeter l'affirmation, et que répond-on avec nos sept classes ?

Exercice 5.5 (★★★) — Note de forme pour la direction. Six lignes, selon la grille du §5.6 (étalement, accumulation, centre robuste, queue, décision), sans citer un nombre absent des mesures du socle, et en proposant un découpage du rapport mensuel en deux lignes de pilotage.

12. Correction détaillée

Exercice 5.1. Sur les lignes, la masse s'accumule davantage à gauche : la médiane par ligne vaut 37 966 FCFA, déjà sous la première borne de 50 000 FCFA, et les extrêmes de la colonne sont -150 804 et 1 229 678 FCFA. La somme des comptes doit donner 480. Explication attendue : 480 lignes pour 316 tickets, 1,52 ligne par ticket en moyenne — découper les gros tickets en morceaux change l'objet observé, pas seulement son échelle.

Exercice 5.2. Trois paniers négatifs, dont un à -150 804 FCFA, issus de 8 lignes d'avoirs totalisant -283 933 FCFA : correction légitime, conservée au total de caisse et exclue des indicateurs de vente. Au-dessus, 25 tickets dépassent 300 000 FCFA et 12 dépassent 500 000 FCFA, le plus gros à 1 343 666 FCFA : exceptions réelles, conservées et commentées. Aucune de ces valeurs n'est « corrigée » : on ne corrige pas un chantier.

Exercice 5.3. Sturges donne 9 classes (1 plus le logarithme en base 2 de 316) ; Freedman-Diaconis une amplitude de 32 277 FCFA, soit 46 classes sur la plage. Réponse attendue : aucune des deux mécaniquement — on retient 7 classes de 50 000 FCFA pour le rapport mensuel parce que la borne ronde se lit sans effort, en écrivant que la règle robuste conduirait à un découpage infiniment plus fin et illisible avec 316 observations. Ce qui est noté, c'est la trace du choix.

Exercice 5.4. On vérifie (a) que la bosse résiste au changement d'amplitude : une bosse réelle persiste quand on double ou divise les classes, une bosse artificielle se déplace avec les bornes ; (b) que l'effectif le permet : sur 316 observations, une épaule de quelques dizaines de tickets est à peine distinguable du bruit d'échantillonnage. Avec nos classes : une bosse nette (0 à 50 000 FCFA, 133 tickets) et une queue épaisse (31 tickets au-dessus de 250 000 FCFA portant 46,9 % du CA), pas deux bosses comparables. Conclusion professionnelle : la stagiaire a vu juste sur l'existence de deux clientèles, mais la frontière ne se lit pas dans une deuxième bosse — elle se lit dans la queue, et c'est là qu'on la fixe.

Exercice 5.5. Note attendue. Étalement : de -150 804 à 1 343 666 FCFA. Accumulation : 136 tickets sous 50 000 FCFA (43,0 % de l'effectif) pour 6,8 % du CA. Centre : médiane 58 423 FCFA, moyenne 114 156 FCFA, rapport 1,95. Queue : 31 tickets au-dessus de 250 000 FCFA, 9,8 % de

l'effectif, 46,9 % du CA ; 12 au-dessus de 500 000 FCFA. Décision : deux lignes de pilotage, comptoir et chantiers, la moyenne étant conservée comme total de caisse rapporté à l'effectif. Est compté 0 tout nombre que le socle ne mesure pas — marge, rotation de stock, taux de service : ce chapitre ne les connaît pas.

13. Mini-projet M02.P2 — suite : la page de forme (30 min)

Complétez le document du **M02.P2** (barème 20 points, seuil de validation 13) par la page « forme » : l'histogramme des paniers en classes de 50 000 FCFA avec ses comptes de classes en annexe, les deux histogrammes comparés de l'exercice 5.1, et le tableau des valeurs extrêmes en trois colonnes (nature, effectif, traitement). Deux contraintes éliminatoires au barème : le mot « aberrant » n'apparaît pas — chaque valeur extrême est nommée par sa nature métier et son sort — et le découpage en deux lignes de pilotage est justifié par une phrase chiffrée reprenant les parts d'effectif et de CA.

14. Résumé du chapitre

1. Une distribution se regarde dans trois miroirs — effectifs, histogramme, fréquences cumulées — et aucun ne suffit ; la somme des effectifs de classes (316) est le contrôle qui valide les trois.
2. Les classes se **choisissent et s'écrivent** : 50 000 FCFA par lisibilité, première et dernière ouvertes ; Sturges (9 classes) et Freedman-Diaconis (amplitude de 32 277 FCFA, donc 46 classes) sont des points de départ, pas des verdicts.
3. La forme de nos paniers : bosse à gauche (133 tickets sous 50 000 FCFA, 7,3 % du CA), queue à droite (31 tickets au-dessus de 250 000 FCFA, 46,9 % du CA), asymétrie 3,84, excès de kurtosis 18,25 — quatre chiffres qui disent la même chose, et qui interdisent la moyenne seule, le « $\pm \sigma$ » et le seuil « trois sigma ».
4. Trois sorts des extrêmes : erreurs à corriger à la source, exceptions réelles à commenter, cas limites à sortir d'un périmètre d'indicateur. Le traitement s'écrit, il ne se devine pas.

15. À retenir

À retenir.

- Un histogramme se lit d'abord par sa somme d'effectifs (316) et par ses classes ouvertes, pas par sa bosse.
- Asymétrie 3,84, excès de kurtosis 18,25 : la moyenne (114 156 FCFA) est tirée par la queue, la médiane (58 423 FCFA) décrit le quotidien, le rapport des deux (1,95) est le chiffre à retenir dans la note.
- « Anormal » n'est pas un statut de donnée : une valeur extrême est une erreur, une exception ou un cas limite, chacune avec un traitement écrit.
- La forme décide de la licéité des outils : sur cette série, moyenne et écart-type restent valables pour la comptabilité ; pour la décision, on passe aux positions et au ré-échantillonnage.

À retenir. La formulation qui protège. « Sur 316 tickets de l'extrait nettoyé, la distribution des paniers est fortement asymétrique à droite (asymétrie 3,84 ; 42,1 % des tickets sous 50 000 FCFA ; 9,8 % au-dessus de 250 000 FCFA, portant 46,9 % du CA). Nous publions la médiane comme indicateur de pilotage et la moyenne comme total de caisse rapporté à l'effectif. »

16. Évaluation formative (auto-correction, 12 min)

1. Pourquoi un histogramme à classes automatiques est-il un risque professionnel, et non une maladresse esthétique ? **2.** Que dit un excès de kurtosis de 18,25 que ne dit pas une asymétrie de 3,84 ? **3.** Comment vérifier en dix secondes qu'un histogramme ne perd pas d'observations ? **4.** Citez les trois sortes de valeurs extrêmes et leur traitement, avec un exemple chiffré du fichier. **5.** Vrai ou faux : « puisque 42,1 % des tickets sont sous 50 000 FCFA, il faut supprimer la livraison gratuite ». Qu'est-ce qui manque à cette phrase pour être une conclusion ?

Corrigé

1. Parce que l'amplitude change la forme visible, donc l'histoire racontée : nos 7 classes de 50 000 FCFA donnent une bosse et une queue, 46 classes de 32 277 FCFA donnent un bruit, 2 classes ne donnent rien de décisionnable. 2. L'asymétrie dit que la queue est à droite ; le kurtosis dit qu'elle est épaisse — que les valeurs très éloignées sont structurelles et non accidentelles, ce qui invalide les outils calés sur des queues légères. 3. En sommant les effectifs de classes et en comparant à l'effectif total : ici 316. 4. Erreur de saisie : les 7 lignes de quantités multipliées par mille, corrigées en amont ; exception réelle : le chantier à 1 343 666 FCFA, conservé et commenté ; cas limite : les 3 paniers négatifs (8 lignes d'avoirs pour -283 933 FCFA), exclus des indicateurs de vente et conservés au total de caisse. 5. Vrai sur le premier membre seulement ; la conclusion manque de l'effet chiffré — combien de tickets perdent le bénéfice et quel CA est en jeu (M02.C04, §6) — donc elle ne décide rien.

Auto-validation. Reprenez les cinq contrôles du §7 : somme des classes $316 \cdot 31$ tickets dans la classe ouverte $\cdot 42,1\%$ dans la classe modale $\cdot$ classes numérotées $\cdot$ moyenne à droite de la médiane. Puis comparez vos cinq nombres de la grille du §5.6 aux mesures : $1\,343\,666 \cdot 133 \cdot 58\,423 \cdot 31 \cdot 46,9\%$. En cas d'écart, reprenez les bornes de classes avant les formules : c'est là que l'erreur se loge.

M02.C06 — Relier deux variables : covariance, corrélation, causalité, paradoxes

L'idée du chapitre. Deux colonnes varient-elles ensemble ? La corrélation répond en un nombre, et ce nombre est le plus mal employé de toute la statistique d'entreprise. Ce chapitre pose la mécanique — covariance, coefficient, nuage, droite — et surtout la frontière qui sépare « va avec » de « fait aller avec ».

Base de travail — obligatoire. Deux fichiers du socle, dans votre dossier 02_exercices/M02/, ouverts côte à côte : `donnees/projection/ventes_magasin5_2025.csv` (489 lignes × 13 variables) et `donnees/reference/ventes_magasin5_2025_ATTENDU.csv` (480 × 13). Séparateur point-virgule, encodage UTF-8, virgule décimale. Montants en franc CFA (FCFA). Grain de référence : la **ligne** (480 observations) pour quantité, prix, remise et montant ; le **panier** (316 tickets) pour les questions de clientèle. Chiffres mesurés dans `01_socle_donnees/data/reference/chiffres_cites.md`, section M02.

1. Objectifs du chapitre

À la fin de ce chapitre, vous êtes capable de :

1. calculer une covariance et une corrélation, et expliquer pourquoi la première ne se communique pas ;
2. distinguer corrélation de Pearson et corrélation de rangs (Spearman), et choisir l'une ou l'autre selon la présence de valeurs extrêmes ;
3. estimer une droite de régression simple, en lire la pente, l'ordonnée à l'origine et le R^2 , et refuser d'extrapoler hors du domaine observé ;
4. énoncer les quatre explications possibles d'une corrélation observée — lien direct, causalité inverse, cause commune, hasard de l'échantillonnage — et dire ce que vos données permettent de trancher ;
5. contrôler une **variable de confusion** (la catégorie de produits, le vendeur, la période) et vérifier si l'écart survit à ce contrôle ;
6. repérer les trois paradoxes usuels du métier — corrélation mécanique, effet d'agrégation, retournement de Simpson — avec un exemple vérifié sur le fichier.

2. Pourquoi cette notion est importante

Les questions professionnelles ne sont presque jamais des questions de niveau : ce sont des questions de liaison.

- « **La remise fait-elle vendre plus ?** » C'est une corrélation à tester entre `remise` et `montant_ttc`. Sur le fichier, elle vaut -0,031 : les lignes les plus remisées ne sont pas les plus grosses. Cette absence de liaison, si le test du chapitre M02.C08 la confirme, contredit une idée reçue du magasin et ouvre une décision : la remise actuelle n'achète pas de volume mesurable.
- « **Est-ce le prix qui fait le montant, ou la quantité ?** » Les deux corrélations mesurées valent 0,436 pour le prix unitaire et 0,712 pour la quantité : le volume pèse davantage que

l'étiquette dans la recette par ligne. Voilà un argument pour piloter le panier, pas seulement le prix.

- « **Nos meilleurs vendeurs ont-ils les meilleurs produits ?** » La question est exactement celle de la variable de confusion : Bationo a le panier moyen le plus élevé, 103 367 FCFA, et la plus faible part de Bois & panneaux dans ses lignes, 2,4 %. Le contrôle à catégorie contournée, chiffré au §5.6, donne un résultat contre-intuitif.

Dans les faits. Dans une entreprise de cette taille, la corrélation sert surtout d'argument d'autorité : « les gros paniers sont remisés, donc la remise crée du panier ». Vous n'êtes pas là pour produire ce type de phrase, mais pour être celui qui demande : sur quel échantillon, à quel grain, et avez-vous contrôlé la catégorie ? Trois questions qui, sur notre extrait, transforment une affirmation en décision mesurée.

3. Explication simple

Deux colonnes varient ensemble quand, en parcourant les lignes, on constate une régularité : quand l'une monte, l'autre monte (ou baisse). Le **nuage de points** — scatter plot — montre cette régularité ; le **coefficient de corrélation** la résume en un nombre entre -1 et +1.

Le cas le plus parlant du fichier : la quantité vendue sur une ligne et le montant de cette ligne. Plus il y a de sacs, plus le montant monte ; le nuage s'allonge, le coefficient vaut 0,712. Pour mesurer cette allure, on calcule d'abord la **covariance** — covariance — la moyenne des produits des écarts aux deux moyennes : quand les deux variables montent et baissent ensemble, les produits sont positifs, la covariance est positive.

La covariance a un défaut rédhibitoire : elle s'exprime en « unités de x × unités de y », soit ici des pièces-FCFA. Sa valeur, 857 634, ne se lit pas et ne se compare pas. La corrélation est cette covariance nettoyée de ses unités : on divise par les deux écarts-types, et il ne reste qu'un nombre sans unité.

Trois réflexes avant toute formule : (1) regarder le nuage avant le coefficient ; (2) vérifier que les deux colonnes décrivent le même objet au même grain — corréler une moyenne par client avec une ligne de commande est une faute ; (3) écrire ce que la liaison ne dit pas, à commencer par la causalité.

4. Vocabulaire essentiel

#	Terme	Français — English — sens simple	À savoir
1	Covariance	covariance — covariance — moyenne des produits des écarts aux moyennes	garde le signe, perd l'échelle ; <code>COVARIANCE.S / COVAR_SAMP</code>
2	Corrélation linéaire	coefficient de corrélation de Pearson — Pearson correlation — covariance standardisée, entre -1 et +1	ne mesure que le lien linéaire
3	Corrélation de rangs	corrélation de rang de Spearman — Spearman rank correlation — le même calcul sur les rangs	robuste aux extrêmes, capte les liaisons monotones
4	Nuage de points	nuage de points — scatter plot — une observation = un point	l'étape que personne ne saute impunément
5	R ²	coefficient de détermination — coefficient of determination — part de variance expliquée	en régression simple, $R^2 = r$ au carré
6	Pente	pente — slope — variation moyenne de y par unité de x	12 237 FCFA par pièce sur notre série
7	Ordonnée à l'origine	à ordonnée à l'origine — intercept — valeur prédite quand x vaut zéro	ici -10 402 FCFA : une ligne de quantité nulle n'existe pas

#	Terme	Français — English — sens simple	À savoir
8	Causalité	lien de cause à effet — causality — agir sur x change y	ne se déduit pas d'une corrélation
9	Variable de confusion	variable de confusion — confounder — cause commune des deux variables	catégorie, vendeur, saison : trois candidats ici
10	Corrélation partielle	corrélation partielle — partial correlation — lien restant après contrôle d'une tierce	l'outil conceptuel du §5.6
11	Extrapolation	extrapolation — extrapolation — prédire hors du domaine observé	proscrite en note de gestion
12	Régression	régression linéaire simple — simple linear regression — droite des moindres carrés	une méthode d'ajustement, pas une preuve

5. Cours approfondi

5.1 La covariance, ou mesurer sans unité

Définition. La **covariance** entre deux variables x et y est la moyenne des produits des écarts : pour chaque observation, $(x_i - \text{moyenne de } x) \times (y_i - \text{moyenne de } y)$. Elle est positive si les deux varient dans le même sens, négative si elles varient en sens contraire, proche de zéro si aucune allure ne se dégage. On la note $\text{cov}(x, y)$.

Sur les 480 lignes du fichier, la covariance entre `quantite` et `montant_ttc` vaut 857 634. Ce nombre dit le signe et une idée d'ampleur, rien de plus : il change si l'on passe du niveau ligne au niveau ticket, et il devient absurde dès qu'on change de monnaie. Sa seule utilité professionnelle est pédagogique — comprendre que la corrélation est une covariance débarrassée de ses unités.

Faites-le dans un tableur. `=COVARIANCE.S(plage_x; plage_y)` dans Excel comme dans LibreOffice (anglais `COVAR.S`), ou la voie lente, à faire une fois : trois colonnes (écart à la moyenne de x , écart à la moyenne de y , produit des deux) puis `=MOYENNE()` sur la troisième. Vous verrez ce que le signe veut dire : les lignes où beaucoup de pièces s'accompagnent de gros montants ajoutent des produits positifs, et ce sont les plus nombreuses.

Attention. Une covariance calculée sur deux colonnes de natures différentes — un identifiant et un prix, une date et un montant — n'est pas nulle par accident : elle est dénuée de sens, parce que l'ordre des identifiants ne signifie rien. Le logiciel, lui, calcule sans protester. C'est à vous de trier les colonnes autorisées, et c'est le rôle du tableau de typage construit au chapitre M01.C05.

5.2 Le coefficient de corrélation, et ce qu'il mesure vraiment

Définition. Le **coefficient de corrélation linéaire de Pearson** — Pearson correlation coefficient, noté r — est la covariance divisée par le produit des deux écarts-types. Il vaut +1 quand les points sont exactement alignés en montant, -1 exactement alignés en descendant, et zéro quand aucune allure linéaire ne se dégage. Sans unité, il se compare entre colonnes et entre périodes.

Sur le fichier, les couples mesurés donnent :

Couple de variables	Grain	r	Ce que ça veut dire
<code>quantite</code> × <code>montant_ttc</code>	ligne (480)	0,712	lien franc, mais très imparfait

Couple de variables	Grain	r	Ce que ça veut dire
prix_unitaire_ht × montant_ttc	ligne (480)	0,436	le prix compte, moins que le volume
quantite × prix_unitaire_ht	ligne (480)	-0,041	gros volumes et prix bas ne vont pas ensemble
remise × montant_ttc	ligne (480)	-0,031	aucune liaison linéaire entre remise et taille de ligne
heure de saisie × montant_ttc	ligne (480)	0,007	l'heure n'explique pas le montant
montant_ht × montant_ttc	ligne (480)	1,000	liaison mécanique : l'un se déduit de l'autre

Quatre lectures de professionnel :

1. **0,712 est fort, pas écrasant.** Le carré de ce coefficient, 50,7 % — le R^2 du §5.4 — dit que la quantité explique la moitié de la variance du montant. La moitié. Écrire « le montant dépend de la quantité » sans le R^2 est une exagération.
2. **Le couple remise / montant est le plus instructif.** Un montant plus élevé ne s'accompagne pas d'une remise plus forte (-0,031), et les gros volumes ne se négocient pas mieux (-0,041). Résultat négatif, et un résultat négatif mesuré vaut mieux qu'une intuition : la politique de remise du magasin n'est pas calée sur la taille de la ligne.
3. **$r = 1,000$ entre HT et TTC est trivial.** Les deux colonnes se déduisent l'une de l'autre par la TVA et la remise : ce n'est pas une découverte, c'est une identité comptable. Repérer une corrélation mécanique est une compétence — avant de commenter un coefficient élevé, demandez si une colonne n'est pas construite à partir de l'autre.
4. **Un r proche de zéro n'est pas une indépendance.** Le coefficient ne voit que le linéaire : si les fortes remises se concentrent sur les très petites lignes et sur les très grosses, la liaison existe et r reste voisin de zéro. Avant de conclure « aucun lien », on regarde le nuage, la médiane par strate, ou un test d'association sur catégories (M02.C08).

Faites-le dans le SQL. (les vues `lignes_ventes` et `paniers` ont été créées au C02, § « Pour la suite du module ») :

```
SELECT COUNT(*)                AS n,
       ROUND(COVAR_SAMP(quantite, montant_ttc), 0) AS covariance,
       ROUND(CORR(quantite, montant_ttc), 3)      AS pearson
FROM lignes_ventes;
```

Ne mélangez pas les colonnes dans un même contrôle : covariance sur `montant_ht`, corrélation sur `montant_ttc` produit deux chiffres justes séparément et une phrase fausse ensemble. Le réflexe : une requête, un couple de variables.

5.3 Rang contre valeur : Spearman

Définition. La **corrélacion de rang de Spearman** — Spearman rank correlation, notée ρ — remplace chaque valeur par son rang dans la série triée, puis calcule la corrélation de Pearson sur ces rangs. Elle mesure si les deux variables montent ensemble, sans exiger que ce soit proportionnellement.

Sur `quantite` et `montant_ttc`, Spearman vaut 0,641 contre 0,712 en Pearson. Que le rang soit plus faible est une information : quelques lignes à très forte quantité produisent des écarts disproportionnés qui gonflent la liaison linéaire — la quantité maximale après correction est de 68 pièces quand la médiane est de 4, et l'énoncé non nettoyé montait jusqu'à 14 000. Concrètement :

Situation	Ce qu'on publie	Pourquoi
Variables continues, allure proche d'une droite, effectif confortable	Pearson	plus précis quand les hypothèses tiennent

Situation	Ce qu'on publie	Pourquoi
Valeurs extrêmes nombreuses, ou variable déjà ordonnée (note de satisfaction)	Spearman	insensible aux distances, robuste
Effectif faible (une trentaine de points)	les deux, et le nuage	vérifier que la conclusion ne tient pas à trois lignes
Colonne texte convertie en date ou en mois	aucune : re-typologiser d'abord	une date n'est pas une quantité

Règle de rédaction : **quand les deux coefficients se contredisent, c'est l'écart qui s'écrit** ; quand ils concordent, une mention « (Spearman : 0,641) » en note suffit, et elle clôt la discussion sur les valeurs extrêmes.

5.4 La droite de régression : trois nombres et une interdiction

Définition. La **régression linéaire simple** — simple linear regression, méthode des moindres carrés (ordinary least squares, OLS) — trace la droite qui minimise la somme des carrés des écarts verticaux. Elle livre la **pente** (variation moyenne de y par unité de x), l'**ordonnée à l'origine** (valeur prédite quand x vaut zéro) et le **R²** (part de la variance de y expliquée par x).

Sur les 480 lignes, la droite montant = a × quantité + b donne :

Élément	Valeur	Lecture professionnelle
Pente	12 237 FCFA par pièce	une pièce de plus sur une ligne s'accompagne, en moyenne, de 12 237 FCFA de plus
Ordonnée l'origine	à -10 402 FCFA	sans signification : une ligne de quantité nulle n'existe pas
R ²	50,7 %	la quantité explique la moitié de la dispersion du montant, pas plus
Pente standardisée	71,2 %	un écart-type de quantité en plus, c'est 0,71 écart-type de montant : c'est exactement r

Trois usages de ces nombres. D'abord, la **pente est un fait conditionnel** : elle vaut « toutes lignes confondues, sur l'année 2025, au grain ligne ». Elle ne vaut ni par produit, ni par catégorie : la pente d'un rayon de matériaux lourds n'a rien de commun avec celle de la quincaillerie, et la moyenne des pentes par catégorie n'est pas la pente globale.

Ensuite, le **contrôle du point moyen** : la droite des moindres carrés passe par le point (moyenne de x, moyenne de y). Appliquée à la quantité moyenne de 7 pièces, elle prédit 75 257 FCFA, pour une moyenne observée de 75 152 FCFA — 105 FCFA d'écart, dus à l'arrondi d'affichage. Si votre prédiction à la moyenne s'écarte nettement de la moyenne observée, votre droite est fautive : c'est le meilleur contrôle de régression qui soit, et il prend dix secondes.

Enfin, l'interdiction : **on n'extrapole pas**. Prédire le montant d'une ligne de 200 pièces avec une pente calibrée entre -13 et 68 pièces est un exercice de fiction — et c'est précisément le genre de chiffre qui, dans un dossier d'investissement, décrédibilise tout le reste.

Faites-le dans un tableur. =DROITEREG(y; x; VRAI) renvoie pente et ordonnée ; le R² s'obtient par =R2(y; x), ou par le carré de =COEFFICIENT.CORRELATION(). **Dans le SQL :** REGR_SLOPE(montant_ttc, quantite), REGR_INTERCEPT(montant_ttc, quantite), REGR_R2(montant_ttc, quantite) — trois agrégats, une requête, et le contrôle du point moyen se fait en comparant REGR_INTERCEPT + REGR_SLOPE * AVG(quantite) à AVG(montant_ttc).

Conseil professionnel. Présentez toujours la pente et le R^2 ensemble : une pente sans R^2 fait croire à une loi, un R^2 sans pente ne dit pas de combien. Nos deux chiffres dans une phrase : « une pièce de plus sur une ligne s'accompagne en moyenne de 12 237 FCFA de plus, mais cette seule variable ne fait que la moitié du travail (R^2 50,7 %) ».

5.5 Corrélation n'est pas causalité : les quatre configurations

Définition. On dit que x **cause** y si agir sur x change y . La corrélation ne teste pas cela : elle constate une variation conjointe. Quatre configurations produisent une corrélation sans lien causal : la cause commune, la causalité inverse, le hasard de l'échantillonnage, et la sélection du périmètre — ce que les données contiennent déjà avant toute analyse.

Appliquées au fichier :

Configuration	Comment elle apparaîtrait ici	Comment on la reconnaît
Cause commune	Grosses ventes et grosses remises viennent des mêmes périodes de chantier	croiser avec la date et la catégorie : si le lien disparaît à période contenue, c'était la saison
Causalité inverse	On croit que la remise gonfle le panier ; c'est le gros panier qui obtient une remise	la réponse est temporelle ou contractuelle, pas statistique : la remise se décide pendant la vente
Hasard d'échantillonnage	Deux colonnes sans rapport peuvent afficher $r = 0,10$ sur 480 lignes	le test de signification du chapitre M02.C08 ; à $n = 480$, la barre du bruit est vers 0,09
Sélection du périmètre	Sur le seul magasin 5, une liaison propre à la ville apparaît ou disparaît	reproduire sur un autre magasin, puis sur le fichier complet

Le plus utile à votre niveau est le troisième : la **barre de bruit**. Deux colonnes sans aucun rapport, sur 480 lignes, peuvent afficher une corrélation de 0,1. La vôtre, si elle est plus petite que ce seuil, ne mérite aucun commentaire. C'est ce qui rend les chiffres de l'extrait lisibles : à 0,712, la liaison quantité-montant n'a rien de comparable au bruit ; à 0,007, l'heure de saisie ne veut rien dire du tout.

5.6 Contrôler la variable de confusion — et le paradoxe de Simpson

Définition. Une **variable de confusion** (confounder) influence à la fois x et y et fait apparaître un lien qui n'existe pas entre elles. Contrôler un facteur de confusion consiste à comparer x et y **à l'intérieur de chaque strate** de cette variable, puis à regarder si la conclusion survit. Quand elle s'inverse strate par strate, on parle de **paradoxe de Simpson** (Simpson's paradox, effet de Simpson-Yule).

Testons la question la plus politique du module : les vendeurs vendent-ils plus gros parce qu'ils ont de meilleurs produits ?

Étape	Mesure	Valeur
1	Panier moyen le plus élevé des quatre vendeurs (Bationo)	103 367 FCFA
2	Panier moyen le plus faible (Ilboudo)	69 352 FCFA
3	Écart global entre ces extrêmes	34 014 FCFA
4	Part de Bois & panneaux — la catégorie la plus chère — dans leurs lignes	de 2,4 % (Bationo) à 8,5 % (Ouédraogo)
5	Écart maximal entre vendeurs, calculé catégorie par catégorie puis moyenné	57 346 FCFA

Étape	Mesure	Valeur
6	Dispersion de cet écart par catégorie	de 17 433 (Quincaillerie) à 173 167 FCFA (Electricité)

Le résultat contredit le schéma habituel : l'écart entre vendeurs **n'est pas réduit** par le contrôle de la catégorie — il augmente (57 346 contre 34 014 FCFA). Le mix produit n'explique donc pas la différence : il l'occultait. Le cas est même nettement inverse à l'intuition, puisque le vendeur au plus fort panier moyen est aussi celui qui a la plus faible part de la catégorie la plus chère (2,4 % de ses lignes).

Attention. Contrôler une variable multiplie les petites strates, et c'est là que la méthode se brise : Bois & panneaux compte 24 lignes pour vingt-deux vendeurs — certaines strates n'en contiennent que trois. Un écart calculé sur trois observations n'est pas un résultat, c'est un dessin. Fixez un effectif minimal par strate, appliquez-le à toutes les catégories sans exception, et écrivez lesquelles ont été écartées du calcul : c'est ce qui rend la démarche crédible quand la conclusion dérange.

Deux précautions, à écrire dans la note. D'abord, ce calcul n'a pas été mené sur Bois & panneaux : avec 24 lignes réparties sur vingt-deux vendeurs, certaines catégories n'ont que quelques lignes par vendeur, et un écart calculé dessus est du bruit. Ensuite, l'écart moyen par catégorie masque une dispersion énorme (17 433 à 173 167 FCFA) : la conclusion « le mix n'explique rien » est vraie en moyenne, pas dans chaque rayon.

C'est là l'usage professionnel du paradoxe de Simpson, bien plus utile que sa curiosité : **on ne l'invente pas, on le cherche**. La méthode tient en trois questions écrites dans la note : la catégorie explique-t-elle l'écart ? la période ? le type de client ? Si rien ne l'explique, l'écart devient un objet d'explication — et s'il disparaît, l'affirmation initiale était un artefact de découpage.

5.7 Agrégation : pourquoi les corrélations montent quand on résume

Un effet de bord que l'on découvre trop tard : plus on agrège, plus les points s'alignent. Sur les 480 lignes, `quantite` et `montant_ttc` corrélaient à 0,712 ; agrégées par client (372 clients distincts dans l'attendu), les totaux corrélaient généralement plus fort, parce que les irrégularités individuelles se moyennent ; et la corrélation peut s'effondrer si l'on agrège par jour, parce que l'effet de taille de journée écrase tout. Ce **problème d'agrégation** (modifiable areal unit problem dans sa version spatiale, effet de groupement dans sa version courante) a une conséquence pratique unique :

- **le grain s'écrit au même titre que le coefficient** : « $r = 0,712$, au niveau de la ligne (480 observations) » ;
- **on ne compare jamais deux corrélations calculées à des grains différents**, même sur le même fichier ;
- **on se méfie des corrélations spectaculaires sur séries mensuelles courtes** : douze points donnent fréquemment un r très élevé entre deux variables simplement croissantes — le lien est alors une tendance partagée, pas une dépendance.

5.8 Calculer les liaisons : quel outil, quelle formule

Ce que vous voulez	Tableur	SQL (DuckDB)	pandas
Corrélation linéaire	<code>=COEFFICIENT.CORRELATION(x;y)</code> (anglais CORREL)	<code>CORR(x, y)</code>	<code>df.x.corr(df.y)</code>
Covariance d'échantillon	<code>=COVARIANCE.S(x;y)</code>	<code>COVAR_SAMP(x, y)</code>	<code>df.x.cov(df.y)</code>

Ce que vous voulez	Tableur	SQL (DuckDB)	pandas
Corrélation de rangs	<code>=CORREL()</code> sur deux colonnes de <code>=RANG()</code>	tri puis <code>CORR</code> sur les rangs	<code>df[["x","y"]].corr(method="spearman")</code>
Pente, ordonnée, R^2	<code>=DROITEREG()</code> , <code>=R2()</code>	<code>REGR_SLOPE</code> , <code>REGR_INTERCEPT</code> , <code>REGR_R2</code>	<code>scipy.stats.linregress</code>
Matrice de corrélations	table de formules recopiées	une requête par couple	<code>df.corr(numeric_only=True)</code>
Nuage points	de graphique nuage	échantillon puis export	<code>df.plot.scatter("quantite", "montant_ttc")</code>

Boîte à outils. Contrôle minimal de toute corrélation publiée : (1) l'effectif (480 lignes, 316 paniers ou 372 clients) et le grain, dans la légende ; (2) la liste des colonnes autorisées, issue du tableau de typage M01.C05, pour ne pas corréler un identifiant ; (3) le nuage regardé au moins une fois — une corrélation de 0,7 produite par quatre points isolés est une erreur de tracé ; (4) Pearson et Spearman côte à côte sur les séries à forte asymétrie, comme ici ; (5) le carré de r publié avec r , pour que le lecteur sache ce qui reste inexpliqué.

6. Exemple concret : « la remise fait-elle vendre plus gros ? »

La demande. Le directeur veut relever la remise accordée sur les tickets de plus de 100 000 FCFA : « sur nos gros chantiers, la remise fait la différence ».

Ce que le fichier dit, ligne par ligne.

Question	Calcul	Réponse mesurée
Les lignes remisées sont-elles plus grosses ?	<code>CORR(remise, montant_ttc)</code> sur 480 lignes	-0,031 : aucune liaison linéaire
La remise est-elle la règle ou l'exception ?	lignes sans remise	307 sur 480, soit 64,0 % sans aucune remise
Le vendeur remet-il à sa guise ?	test d'association vendeur × remise	3,03 de chi-deux, $p = 0,388$: pas d'association détectée (M02.C08)
La catégorie explique-t-elle les montants ?	CV par catégorie	de 81,4 % (Peinture) à 170,4 % (Electricité) — M02.C03

La conclusion, et sa limite. Sur cet extrait, aucune liaison linéaire mesurable entre remise et taille de ligne : relever la remise sur les gros tickets n'a, dans ces données, pas de contrepartie observée en volume. La limite est à écrire explicitement : 173 lignes seulement portent une remise (480 moins 307), réparties sur six taux (0 ; 0,03 ; 0,04 ; 0,07 ; 0,08 ; 0,11) — un plan d'expérience quasi inexistant. On ne prouve pas l'efficacité d'une politique de prix avec des remises accordées au cas par cas. La recommandation professionnelle n'est donc pas « n'augmentez pas la remise » mais « testez : deux mois, deux groupes de clients, un taux, une mesure ».

La phrase à écrire dans la note. « La liaison entre taux de remise et montant de ligne est nulle sur l'extrait ($r = -0,031$, $n = 480$ lignes). Cette absence ne prouve pas l'inefficacité de la remise : elle signale que le fichier ne contient pas d'expérience de prix exploitable. Nous recommandons un test borné plutôt qu'un ajustement unilatéral de la politique. »

7. Démonstration pas à pas : du nuage au coefficient, puis au contrôle

Étape 1 — Choisir le couple. `quantite` et `montant_ttc`, au niveau de la ligne, sur le fichier attendu (480 lignes). Notez la décision : deux colonnes, un grain.

Étape 2 — Le nuage d'abord. 480 points, échelles linéaires. Ce que l'on doit y voir : un alignement montant, un point très à droite et très en haut (la plus grosse ligne), quelques points sous zéro (les retours). Si le nuage dessine un éventail — dispersion croissante avec x —, la relation est hétéroscédastique et la pente moyenne masque deux régimes : à écrire dans la note.

Étape 3 — La covariance, puis r . `COVAR_SAMP` puis `CORR`, en SQL. Vérifiez que le passage de l'un à l'autre se retrouve : 857 634 divisé par le produit des écarts-types (8,4 et 143 915 FCFA) nous ramène à 0,71, ce qui est la valeur de r aux arrondis de présentation près.

Étape 4 — Spearman. Même couple, méthode des rangs : 0,641. Notez la direction de l'écart — le rang est plus faible —, signe qu'une poignée de valeurs extrêmes pèse davantage sur le linéaire que sur l'ordre.

Étape 5 — La droite. `REGR_SLOPE` = 12 237, `REGR_INTERCEPT` = -10 402, `REGR_R2` = 0,507. Vérifiez le carré de r : $0,712 \times 0,712 = 0,507$ ✓ — en régression simple, R^2 est exactement le carré du coefficient de corrélation.

Étape 6 — Le contrôle par strate. Refaites la pente catégorie par catégorie. Si les pentes s'écartent fortement, la droite globale est une moyenne d'histoires différentes : la mention « toutes catégories confondues » devient obligatoire.

Contrôles qualité du chapitre.

#	Contrôle	Seuil	Résultat attendu	Si échec
1	r dans l'intervalle $[-1 ; +1]$	mathématique	0,712	colonnes de types mélangés
2	R^2 égal au carré de r (régression simple)	au centième	50,7 %	régression multiple ou pondérée
3	Droite passant par le point moyen	écart < 0,2 % de la moyenne	75 257 contre 75 152 FCFA	pente ou ordonnée mal lues
4	Un seul grain, une seule population	effet identique	480 lignes	jointure ou agrégation oubliée
5	Signe de la covariance = signe de r	identité	les deux positifs	sélection de colonnes erronée

8. Erreurs fréquentes

- Commenter r sans avoir vu le nuage.** Un r de 0,7 peut être produit par un point isolé et quelques dizaines d'autres en rond : le coefficient est exact, l'histoire est fausse. Le nuage se regarde avant, et se conserve en annexe.
- Corréler des colonnes mal typées.** Dans l'énoncé, `montant_ttc` est stocké en texte sur 486 des 489 lignes (M01.C04) : lu comme une catégorie par certains outils, comme une suite de chiffres par d'autres, le coefficient dépend alors du logiciel et non des données.
- Publier la covariance.** Sans unité lisible, 857 634 ne veut rien dire. Elle sert au calcul, pas à la note.
- Confondre force et certitude.** Un r de 0,10 sur 40 000 lignes est statistiquement établi et commercialement inutile ; un r de 0,7 sur 12 lignes est commercialement séduisant et statistiquement fragile. Le premier nombre mesure la taille de la liaison, le second sa solidité — et c'est le chapitre M02.C08 qui fournit le second.

5. **Oublier que la pente dépend du périmètre.** 12 237 FCFA par pièce est une moyenne annuelle, toutes catégories. Sur Bois & panneaux seuls, elle change : citer un chiffre global comme s'il s'appliquait à une gamme est la manière la plus rapide de perdre un auditeur.
6. **Inventer une causalité à partir d'un calendrier.** « Les ventes augmentent avec la remise en novembre » : les deux montent, mais la saison des chantiers monte aussi. Une corrélation temporelle partagée n'est pas une liaison causale — c'est la définition même de la cause commune.

9. Bonnes pratiques professionnelles

1. **Une phrase, trois éléments** : le coefficient, l'effectif, le grain. « $r = 0,712$ (480 lignes, niveau ligne, fichier nettoyé) ».
2. **Joindre le nuage.** Trois cents points coûtent une ligne et désarment la moitié des contestations.
3. **Publier R^2 en pourcentage.** « La quantité explique 50,7 % de la variation du montant » : le lecteur comprend qu'il reste 49,3 % à expliquer — c'est exactement le propos.
4. **Nommer la variable de confusion contrôlée,** et dire quand elle ne change rien : ici l'écart entre vendeurs passe de 34 014 à 57 346 FCFA quand on contrôle la catégorie.
5. **Traiter les corrélations proches de zéro comme des résultats,** pas comme des échecs : -0,031 répond à une question de politique commerciale, à condition d'ajouter ce que la donnée ne permet pas de conclure.
6. **Réserver le mot « effet » aux expériences,** et employer « liaison », « lien », « co-variation » pour tout le reste. Cette discipline de vocabulaire est la meilleure ligne de défense de l'analyste.

10. Exercice guidé — la liaison quantité / montant, entièrement refaite

Énoncé. Sur le fichier attendu : nuage, covariance, Pearson, Spearman, droite de régression, R^2 , puis commentaire en trois phrases pour un directeur commercial.

Vous faites — barème 10 points, total 10.

Étape	Ce que vous produisez	Points
A	Le nuage, axes nommés et effectif indiqué	2
B	Covariance et r , avec le calcul de r à partir de la covariance	2,5
C	Spearman, et une phrase sur l'écart entre les deux chiffres	1,5
D	Pente, ordonnée, R^2 , avec le contrôle du point moyen	2,5
E	Commentaire en trois phrases, sans verbe de causalité	1,5

Nous vérifions. Covariance 857 634 · $r = 0,712$ · Spearman 0,641 · pente 12 237 FCFA par pièce · ordonnée -10 402 FCFA · R^2 50,7 %. Contrôle du point moyen : prédire à la quantité moyenne doit rendre la moyenne des montants — 75 257 contre 75 152 FCFA, soit l'arrondi d'affichage.

Nous corrigeons. Deux formulations à supprimer : « la quantité détermine le montant » (trop fort : la détermination est comptable, pas comportementale) et « plus on vend de pièces, plus on gagne » (trop faible : cela vaut pour tout commerce, et le coefficient n'apporte rien). La phrase juste contient le chiffre, le périmètre et la part inexpliquée.

11. Exercices autonomes

Exercice 6.1 (★) — Le tri des colonnes. Listez les colonnes du fichier avec lesquelles il est licite de calculer une corrélation avec `montant_ttc`, et celles où c'est interdit, en une ligne de justification par colonne.

Exercice 6.2 (★) — Le carré. Calculez le carré de 0,712 et retrouvez le R^2 mesuré. Que reste-t-il inexpliqué, et que signifierait un R^2 de 95 % dans ce contexte ?

Exercice 6.3 (★★) — La pente par catégorie. Estimez la pente de `montant = a × quantité` pour Matériaux (143 lignes) et pour Consommables (57 lignes). Comparez à la pente globale de 12 237 FCFA et concluez sur son usage.

Exercice 6.4 (★★) — Le contrôle de confusion. Reprenez l'écart de panier moyen entre les quatre vendeurs en contrôlant cette fois le **trimestre** au lieu de la catégorie. L'écart global est de 34 014 FCFA : dites, chiffres à l'appui, si la période explique une part notable de cet écart.

Exercice 6.5 (★★★) — Note de liaison. Six lignes pour la direction sur le couple remise / montant : le coefficient, l'effectif, le grain, ce que le résultat ne prouve pas, et la proposition d'expérience à mener. (attendu : $r = -0,031$; 480 lignes ; 64,0 % de lignes sans remise ; six taux observés ; un test sur deux groupes)

12. Correction détaillée

Exercice 6.1. Licites : les colonnes numériques à rapport — `quantite`, `prix_unitaire_ht`, `remise`, `montant_ht`, `montant_ttc` — et les composantes extraites de la date (jour du mois, heure), à condition de signaler qu'une heure est une grandeur circulaire. Illicites : `n_ticket` et `client` (identifiants : leur ordre ne signifie rien), `categorie` et `vendeur` (nominales : on les traite par agrégats ou par tableaux de fréquences), `date brute` (une date n'est pas une grandeur). La justification attendue nomme le type de chaque colonne, pas une impression.

Exercice 6.2. $0,712 \times 0,712 = 0,507$, soit 50,7 % : le R^2 mesuré, contrôle réussi. Restent 49,3 % de variance inexpliquée — prix unitaire, catégorie, remise, et tout ce que le fichier ne contient pas. Un R^2 de 95 % devrait éveiller le soupçon de corrélation mécanique : deux colonnes qui se déduisent l'une de l'autre, comme `montant_ht` et `montant_ttc` ($r = 1,000$ ici).

Exercice 6.3. Les pentes par catégorie s'écartent fortement — de l'ordre du simple au double entre matériaux lourds et consommables — et certaines catégories voient la quantité expliquer à peine le montant. Conclusion attendue : la pente globale est un compromis sans correspondant réel ; elle résume, elle ne prévoit pas une ligne d'une catégorie donnée. Sont valorisés le rappel des effectifs (143 et 57 lignes) comme facteur de fiabilité inégale, et la mention de la pente en unité (FCFA par pièce).

Exercice 6.4. Ce qui est attendu, c'est la méthode plus que le résultat : recalculer l'écart maximal entre vendeurs à trimestre contenu, le comparer aux 34 014 FCFA globaux et aux 57 346 FCFA obtenus à catégorie contenue, et écrire la conclusion en fonction du sens observé. Un écart qui survit à deux contrôles successifs cesse d'être un artefact de découpage et devient un objet d'explication — à faire discuter par l'entretien, le planning, ou le portefeuille client.

Exercice 6.5. Note attendue : la liaison entre taux de remise et montant de ligne est nulle ($r = -0,031$, 480 lignes, fichier nettoyé) ; 307 lignes sur 480 ne portent aucune remise et les six taux observés ne forment pas un plan d'expérience exploitable ; nous ne pouvons donc conclure ni à l'efficacité ni à l'inefficacité de la remise, seulement à l'absence de donnée pour la juger ; nous proposons deux mois de test sur deux groupes de clients, avec un taux unique par groupe ; la décision se prendra sur l'écart de panier entre les deux groupes, testé comme au chapitre M02.C08.

13. Mini-projet M02.P3 — « La page des liaisons » (50 min)

Commande. Pour la direction commerciale, produisez une page de trois liaisons chiffrées, choisissez parmi : quantité / montant, prix / montant, remise / montant, vendeur / catégorie, heure / montant. Pour chacune : le coefficient, le grain, l'effectif, le carré du coefficient, et une phrase de conclusion — avec l'obligation d'écrire explicitement ce que la liaison ne dit pas.

Livrables numérotés. (1) le tableau des trois liaisons ; (2) les trois nuages en annexe ; (3) le contrôle de confusion mené sur la liaison que vous jugez la plus forte, avec ses deux chiffres (avant / après contrôle) ; (4) la proposition d'expérience pour la liaison politiquement la plus lourde ; (5) la ligne de journal (date, fichiers, effectifs, versions).

Barème (20 points, seuil 13). Coefficients exacts et sourcés (4) · grain et effectif écrits partout (3) · carré du coefficient commenté (2) · nuages joints et lisibles (3) · contrôle de confusion correctement exécuté (4) · expérience proposée mesurable (2) · journal (2) — total 20. Ce livrable rejoint le document du M02.P2 : le projet du module est la somme des pages, pas leur remplacement.

14. Résumé du chapitre

1. La covariance donne le signe et rien d'autre (857 634 pièces-FCFA) ; la corrélation la standardise (0,712), et seule la seconde se communique.
2. Pearson voit le linéaire, Spearman le monotone : 0,712 et 0,641 sur la même paire, et l'écart entre les deux est un diagnostic sur les valeurs extrêmes.
3. Une droite de régression se réduit à trois nombres — 12 237 FCFA par pièce, -10 402 FCFA, 50,7 % — et le contrôle du point moyen (75 257 contre 75 152 FCFA) vérifie le calcul en dix secondes.
4. Une corrélation ne dit rien de la causalité : cause commune, inversion, hasard, périmètre. Le contrôle de confusion est une méthode, pas une formule — et sur cet extrait il agrandit l'écart entre vendeurs (57 346 contre 34 014 FCFA) au lieu de le résorber.

15. À retenir

À retenir.

- Un coefficient publié porte son effectif, son grain et son carré : 0,712 (480 lignes, niveau ligne), 50,7 % de variance expliquée.
- Une ordonnée à l'origine hors domaine (-10 402 FCFA) et une prédiction hors des valeurs observées s'appellent des extrapolations : elles ne sortent pas du bureau.
- Corrélation mécanique, agrégation, confusion : trois façons de trouver un lien qui n'explique rien. On les teste, on ne les suppose pas.
- Le mot « effet » est réservé aux expériences. Tout le reste est une liaison.

À retenir. La formulation qui protège. « Sur 480 lignes du fichier nettoyé, quantité et montant varient ensemble à hauteur de $r = 0,712$ (Spearman 0,641), soit 50,7 % de la variance expliquée : l'autre moitié tient au prix, à la catégorie et à ce que nous ne mesurons pas. Rien dans ce calcul n'établit qu'augmenter les quantités augmentera la recette. »

16. Évaluation formative (auto-correction, 12 min)

1. Pourquoi la covariance ne se publie-t-elle pas, alors qu'on la calcule ? **2.** Sur le couple quantité / montant, Spearman est plus faible que Pearson. Que dit cet écart ? **3.** Une corrélation de -0,031 entre remise et montant : quelle conclusion licite, quelle conclusion interdite ? **4.** Le R^2 vaut 50,7 %. Que répondez-vous à qui demande « donc la quantité ne compte que pour moitié » ? **5.** Un directeur affirme : « nos vendeurs les plus rentables ont les meilleurs produits, c'est la catégorie qui l'explique ». Quelle vérification faire, et quel a été son résultat sur l'extrait ?

Corrigé

1. Parce qu'elle conserve l'unité des deux colonnes (pièces $\times$ FCFA) : 857 634 ne se lit pas, ne se compare pas, et change si l'on change de monnaie ou de grain. 2. Que quelques valeurs extrêmes pèsent davantage sur la liaison linéaire que sur la liaison de rangs ; la liaison est réelle, mais en partie portée par les plus grosses lignes. 3. Licite : sur cet extrait, aucune liaison *linéaire* entre remise et taille de ligne, et le fichier ne contient pas de plan de prix exploitable. Interdite : « la remise ne sert à rien » — l'absence de liaison observée n'est pas la preuve d'une absence d'effet. 4. Que la moitié de la *dispersion* du montant est associée à la quantité, l'autre au prix, à la catégorie, à la remise et au non-mesuré ; et que 50,7 % est un chiffre de variance, pas un pourcentage de recette. 5. Calculer l'écart entre vendeurs à catégorie contenue et le comparer à l'écart global : ici il ne se réduit pas, il passe de 34 014 à 57 346 FCFA en moyenne par catégorie — la catégorie n'explique donc pas l'écart, elle le masque.

Auto-validation. Reprenez les cinq contrôles du §7 : r dans l'intervalle, R^2 égal au carré de r , point moyen retrouvé, un seul grain, signe de la covariance conforme. Puis recopiez vos cinq nombres en regard de la table de référence : 857 634 $\cdot$ 0,712 $\cdot$ 0,641 $\cdot$ 12 237 $\cdot$ 50,7 %. Sur un seul écart, reprenez la jointure avant la formule.

M02.C07 — Hasard et incertitude : probabilités de base, échantillonnage, biais

L'idée du chapitre. Vous n'avez jamais les données : vous en avez un extrait. Trois idées rendent cet extrait défendable — ce que le hasard ajoute (l'erreur d'échantillonnage), ce que le hasard ne corrige pas (le biais), et la façon de le dire (l'intervalle). Sans elles, un chiffre juste reste une opinion.

Base de travail — obligatoire. Le fichier nettoyé du projet M01, `donnees/reference/ventes_magasin5_2025_ATTENDU.csv` (480 lignes × 13 variables, 316 tickets), et la population dont il est issu : le magasin 5 sur 2025, soit 7 676 lignes et 4 524 tickets, lus dans `01_socle_donnees/data/reference/ventes_propres.csv`. Séparateur point-virgule, UTF-8, virgule décimale, montants en franc CFA (FCFA). Valeurs mesurées dans `01_socle_donnees/data/reference/chiffres_cites.md`, section M02.

1. Objectifs du chapitre

À la fin de ce chapitre, vous êtes capable de :

1. distinguer population, échantillon, unité sondée et statistique, et nommer ces quatre objets dans un dossier réel ;
2. expliquer pourquoi deux tirages de même taille ne donnent pas le même chiffre, et chiffrer cet écart par l'erreur type ;
3. calculer une marge d'erreur et un intervalle de confiance à 95 % pour une moyenne et pour une proportion ;
4. séparer l'**erreur d'échantillonnage**, qui se travaille, du **biais**, qui se lit dans la règle d'extraction ;
5. diagnostiquer le biais de début de mois de notre extrait, le chiffrer, et dire quelle statistique il dégrade ;
6. fixer une taille d'échantillon à partir d'une précision visée, et expliquer pourquoi le premier doublement de précision coûte quatre fois plus cher.

2. Pourquoi cette notion est importante

Un analyste qui ne parle pas d'incertitude livre un nombre sans mode d'emploi, et le décideur en fait ce qu'il veut. Trois accidents sortent de là :

- **La sur-interprétation.** « Le panier moyen est de 114 156 FCFA, nous perdons du terrain » : rien, dans ce chiffre, ne dit si l'écart avec 116 886 FCFA est une baisse ou le bruit normal d'un extrait de 316 tickets.
- **La généralisation abusive.** Un export tronqué, un `LIMIT`, un seul magasin, un seul mois : le rapport dit « l'année », l'auditoire comprend « tout le monde, tout le temps ».
- **Le faux sentiment de sécurité du volume.** 480 lignes suffisent pour une moyenne à ± 20 078 FCFA près ; 240 000 lignes ne suffisent pas si elles viennent d'un périmètre mal choisi. La taille ne rachète jamais la sélection.

Dans les faits. Dans les services études, le nombre de lignes n'est presque jamais le vrai problème : l'extraction obéit à des contraintes techniques (la caisse n'exporte que les derniers jours, l'entrepôt ne garde que treize mois). Le travail de l'analyste est de **reconstituer la règle d'extraction** — qui a été exclu, et comment — avant toute statistique. Ce chapitre vous le fait faire sur votre propre fichier, parce qu'il est plus simple de commencer par un défaut que l'on peut compter.

3. Explication simple

Vous goûtez une marmite de sauce avec une cuillère. Trois choses se passent.

1. **La cuillère n'est pas la marmite** : ce que vous goûtez dépend de ce qu'elle a attrapé. C'est l'**erreur d'échantillonnage**, le hasard de la trempée. Elle baisse si la louche est plus grande.
2. **Si vous plongez toujours en surface, vous trouverez du gras** tous les jours, à toutes les heures, avec toutes les louches du monde. C'est le **biais** : la méthode de trempée, pas la chance.
3. **Ce que vous pouvez annoncer honnêtement** n'est pas « la sauce est salée » mais « salée, et si je regoûte dix fois je resterai dans ce goût-là ». Cela s'appelle un **intervalle de confiance**.

Notre extrait est une cuillère trempée en surface, et nous allons le prouver : il contient les 40 premières lignes de chaque mois — donc seulement les jours 1, 2, 3 et 4 — et représente 6,3 % des lignes du magasin sur l'année. Sa moyenne ne dérape que de 2,3 %, mais sa médiane de 14,3 %. Même cuillère, deux statistiques, deux dégradations : c'est tout le chapitre.

4. Vocabulaire essentiel

#	Terme	Français — English — sens simple	À savoir
1	Population	population — population — l'ensemble qu'on veut décrire	ici 4 524 tickets, magasin 5 en 2025
2	Unité sondée	unité statistique — sampling unit — ce qu'on tire un par un	le ticket ou la ligne : le choix change tout
3	Échantillon	échantillon — sample — la partie réellement observée	480 lignes, 316 tickets
4	Statistique	statistique — statistic — chiffre calculé sur l'échantillon	114 156 FCFA est une statistique
5	Paramètre	paramètre — parameter — le même chiffre sur la population	116 886 FCFA est le paramètre visé
6	Tirage aléatoire simple	tirage aléatoire simple — simple random sampling — toute combinaison équiprobable	notre extrait ne remplit pas cette condition
7	Erreur d'échantillonnage	erreur d'échantillonnage — sampling error — dispersion d'un tirage à l'autre	elle baisse en $1/\sqrt{n}$
8	Biais	biais d'échantillonnage — sampling bias — décalage systématique	il ne baisse pas avec n
9	Erreur type	erreur type — standard error — écart type de la statistique	10 244 FCFA pour notre moyenne
10	Marge d'erreur	marge d'erreur — margin of error — 1,96 fois l'erreur type	20 078 FCFA ici
11	Intervalle confiance	intervalle de confiance — confidence interval — plage compatible avec l'observation	[94 078 ; 134 234] FCFA

#	Terme	Français — English — sens simple	À savoir
12	Niveau de confiance	niveau de confiance — confidence level — taux de réussite de la méthode	95 % est l'usage, pas une probabilité sur votre cas
13	Bootstrap	amorçage bootstrap — bootstrap — remesurer la statistique sur des ré-échantillonnages du fichier	notre outil pour la médiane
14	Graine	graine aléatoire — random seed — numéro qui rend un tirage rejouable	20260917 dans tous nos exemples

5. Cours approfondi

5.1 Hasard, fréquence, probabilité : trois règles suffisent

Définition. La **probabilité** d'un événement est la fréquence vers laquelle se stabilise cette fréquence quand on répète l'expérience beaucoup de fois. Elle ne décrit jamais un cas particulier, seulement une régularité d'ensemble.

Sur les 316 tickets de l'extrait, tirons au sort un ticket puis un second :

Règle	Énoncé	Application mesurée
Complément	$P(\text{non } A) = 1 - P(A)$	136 paniers sur 316 sont sous 50 000 FCFA, soit 43,0 % ; donc 57,0 % sont au-dessus
Indépendance	$P(A \text{ et } B) = P(A) \times P(B)$ si un tirage ne change rien à l'autre	deux petits paniers d'affilée : $0,43 \times 0,43 \approx 18,5$ %
Addition	$P(A \text{ ou } B) = P(A) + P(B)$ si les deux s'excluent	31 paniers au-dessus de 250 000 FCFA et 3 négatifs : 9,8 % plus 0,9 %

Une nuance, souvent sanctionnée : le second tirage **n'est pas indépendant** du premier si l'on tire sans remise dans un petit ensemble. L'effet est négligeable ici (316 éléments), matériel quand on tire 30 valeurs sur 40 — et c'est la raison exacte de la correction du §5.2.

5.2 Ce que le hasard ajoute : la distribution d'échantillonnage

Définition. L'**erreur d'échantillonnage** (sampling error) est la dispersion d'une statistique si l'on refaisait le tirage. Ce n'est pas une faute, c'est le prix d'une lecture partielle ; elle se mesure par l'**erreur type**, écart type de la statistique d'un tirage à l'autre.

Mesurons-la au lieu de la postuler : dans les 316 paniers, 5 000 tirages de 30 tickets sans remise (graine 20260917, donc rejouable), et la moyenne de chaque tirage.

```
import numpy as np, pandas as pd
p = pd.read_csv("01_socle_donnees/data/reference/ventes_magasin5_2025_ATTENDU.csv", sep=";")
pan = p.groupby("n_ticket").montant_ttc.sum().to_numpy(dtype=float) # 316 paniers
n = len(pan)
rng = np.random.default_rng(20260917)
tirages = np.argsort(rng.random((5000, n)), axis=1)[: , :30] # 5000 tirages de 30,
sans remise
moy = pan[tirages].mean(axis=1)
med = np.median(pan[tirages], axis=1)
print(round(moy.mean()), round(moy.std(ddof=1)), np.percentile(moy, [2.5, 97.5]))
```

Résultats mesurés : la moyenne des 5 000 moyennes vaut 114 889 FCFA, c'est-à-dire la moyenne de l'extrait (114 156 FCFA) à la fluctuation près — **le tirage ne trompe pas en moyenne, il éparpille**. L'écart type de cette distribution est de 31 363 FCFA, et 95 % des tirages tombent

entre 63 898 et 182 706 FCFA : avec 30 tickets, votre chiffre peut varier du simple au triple sans que personne ait failli.

Ce que donne le hasard : 5 000 tirages de 30 tickets dans l'extrait (graine 20260917)




Figure — Distribution d'échantillonnage de la moyenne et de la médiane des paniers (n = 30), calculée sur le fichier nettoyé du projet M

La théorie dit la même chose sans simuler : l'écart type d'une moyenne est celui des valeurs divisé par la racine de l'effectif. Nos 316 paniers ont un écart type de 182 095,1 FCFA, d'où une erreur type de 10 244 FCFA — 10 243 si l'on part de l'écart type arrondi à 182 095, différence sans effet sur la marge. Pour des tirages de 30, la formule donne 33 246 FCFA quand la simulation trouve 31 363 FCFA : l'écart vient du tirage **sans remise** dans une population finie, qui réduit la dispersion d'un facteur 0,953. La formule corrigée tombe à 31 679 FCFA — il reste 1 %, et c'est le hasard des 5 000 tirages.

Attention. Deux écarts types se ressemblent dans les notes et n'ont rien à voir : 182 095 FCFA décrit la dispersion **des clients entre eux**, 10 244 FCFA décrit la dispersion **de votre moyenne d'un tirage à l'autre**. Le second est dix-huit fois plus petit, et lui seul fixe la précision de ce que vous annoncez. Confondre les deux revient à écrire « nos clients sont très variés, donc votre moyenne est fausse ».

Même expérience avec la **médiane** : écart type de 14 387 FCFA pour une moyenne des tirages de 59 140 FCFA, soit 24,3 % de variation relative contre 27,3 % pour la moyenne. Contre une idée reçue, la médiane n'est donc pas plus instable ici ; elle est simplement insensible au plus gros ticket (1 343 666 FCFA), ce que la moyenne ne peut pas faire. En échange, sa distribution n'est pas lisse — une médiane de 30 valeurs est toujours l'une des valeurs observées — et l'intervalle [32 006 ; 90 577] FCFA est plus irrégulier que celui des moyennes.

5.3 Ce que le hasard ne pardonne pas : le biais

Définition. Un **bias d'échantillonnage** (sampling bias) est un écart systématique entre la statistique attendue et la valeur de population, produit par la **méthode de sélection**. Augmenter l'échantillon ne le fait pas disparaître : il le rend plus précis autour de la mauvaise valeur.

Ouvrons la fabrication du fichier. Dans le socle de la formation (01_socle_donnees/scripts/generation_socle.py), les lignes du magasin 5 pour 2025 sont triées par date, puis on garde **les 40 premières lignes de chaque mois** — règle choisie pour couvrir douze mois au lieu d'un. Raisonnable pour un cours, elle n'est pas aléatoire, et voici ce qu'elle coûte.

Ce que dit l'extrait	Extrait	Population magasin 5 / 2025	Écart
Lignes	480	7 676	6,3 % de la population
Tickets	316	4 524	7,0 % de la population
Jours du mois observés	1, 2, 3, 4 (31 dates, 2 à 4 par mois)	1 à 31	fin de mois jamais vue
Panier moyen	114 156 FCFA	116 886 FCFA	-2,3 %
Médiane des paniers	58 423 FCFA	68 160 FCFA	-14,3 %

Le diagnostic est net parce que nous avons la population sous la main : dans le magasin sur l'année, les tickets des quatre premiers jours du mois ont une médiane de 58 424 FCFA, les autres 70 267 FCFA, et ces jours-là ne pèsent que 14,9 % des tickets. Notre extrait est fait **uniquement** de ces jours : sa médiane tombe à 58 423 FCFA, soit à un franc près la médiane du début de mois. Le biais n'a rien de mystérieux — il est entièrement attribué à la composition en jours. La moyenne, elle, ne dérape que de 2,3 % parce que les gros tickets existent aussi les premiers jours.

Définition. Un **bias de couverture** (coverage bias) est le cas où la liste de départ ne contient pas toute la population. C'est notre cas : la liste était « les 40 premières lignes de chaque mois », ce qui exclut structurellement trois quarts du calendrier.

Deux réflexes, pour la vie : **demandeur la règle, pas le volume** (« selon quels critères ces lignes ont-elles été retenues ? » — la réponse est dans le code d'extraction ou dans le `WHERE` de la vue) et **chercher la variable cachée** (ici le jour du mois, absente des 13 colonnes du fichier : un biais se lit rarement dans les données, il se lit dans le mode d'emploi des données). Notez aussi ce qui n'est **pas** biaisé : les heures couvrent toute la journée, de 07:01 à 18:57, parce que le tri ne portait que sur la date. Un biais est toujours localisé sur un axe.

5.4 Cinq familles de biais, et leur trace dans notre fichier

Famille	Mécanisme	Dans notre dossier	Ce qu'on peut chiffrer
Couverture	la liste de départ est incomplète	extrait réduit aux quatre premiers jours	médiane -14,3 % (\$5.3)
Sélection	le tri favorise un profil	tri par date avant écrêtage à 40	2 à 4 dates retenues par mois, 29 lignes au plus sur une date, 13 en médiane
Non-réponse	des individus ne sont pas renseignés	18 tickets sans identifiant client, 103 lignes sans client exploitable	21,5 % des lignes
Survivance	on n'observe que ce qui a survécu	489 lignes reçues pour 480 utiles : les doublons ne sont là que parce qu'ils ont été ré-émis	9 lignes de doublon
Mesure	l'instrument déforme	7 quantités à 14 000 unités, 65 dates écrites à la main en JJ/MM/AAAA	M01.C04 et M01.C06

Cinq mécanismes agissent sur 489 lignes, aucun ne provoque d'erreur logicielle — et tous sont comptables : on peut les isoler et les annuler un par un, ce que vous avez fait au projet M01. Trois nuances à retenir. Le **bias du survivant** : mesurer un assortiment sur les produits encore en rayon, ou la rentabilité sur les magasins encore ouverts, conclut que « tout va bien ». Le **bias de Berkson** : une ligne n'existe que si elle a été encaissée — chantier payé à trente jours, livraison sans bon saisi, avoir émis le mois suivant disparaissent avant le premier calcul, sans qu'une valeur erronée soit présente. Le **bias d'accord** (réponse sociale) ne menace pas les don-

nées d'encaissement mais les questionnaires : sur les premières on se bat contre la couverture, sur les seconds contre la volonté.

Conseil professionnel. Écrivez la liste des exclusions dans le rapport, pas dans votre tête : « magasin 5, année 2025, lignes des quatre premiers jours de chaque mois, retours inclus, avoirs de l'année précédente exclus ». Cette demi-page ne prouve pas que vous aviez raison ; elle prouve que vous saviez — et c'est exactement ce que vaut un analyste le jour où un chiffre est contesté.

5.5 L'intervalle de confiance : ce que « 95 % » veut dire

Définition. Un **intervalle de confiance à 95 %** est fabriqué par une méthode qui, appliquée à une infinité de tirages, enfermerait la vraie valeur dans 95 % des cas. Le pourcentage qualifie la **méthode**, pas votre intervalle : une fois calculé, la valeur est dedans ou elle n'y est pas.

C'est la phrase la plus mal dite de la statistique d'entreprise. À ne pas écrire : « il y a 95 % de chances que le vrai panier moyen soit dans notre intervalle ». À écrire : « notre méthode manque la cible une fois sur vingt ; sur ce tirage elle donne 114 156 ± 20 078 FCFA ».

Pour une moyenne à grand effectif : estimation ± 1,96 fois l'erreur type. Estimation 114 156 FCFA, erreur type 10 244 FCFA, marge 20 078 FCFA, intervalle [94 078 ; 134 234] FCFA — 40 156 FCFA de largeur, soit environ un tiers de la valeur annoncée. Voilà le mot juste que le décideur doit entendre : avec 316 tickets, on connaît le panier moyen **à un tiers près**, pas au centime près.

Et le contrôle que presque personne ne fait, possible ici parce que la population est connue : le vrai panier annuel vaut 116 886 FCFA, il est dans l'intervalle. On a vérifié la couverture de la méthode sur ce cas, ce qui change le statut de la note : on peut écrire « notre intervalle contient la valeur mesurée sur 4 524 tickets ».

Pour une proportion, l'erreur type vaut $\sqrt{p(1-p)/n}$. La part de tickets contenant plus d'une ligne : 104 sur 316, soit 32,9 %, erreur type 2,6 points, intervalle [27,7 ; 38,1] %. Cette écriture résiste en réunion : elle ne dit pas « un tiers des tickets », elle dit « entre un quart et deux cinquièmes », et personne n'en déduit une politique commerciale.

Attention. Trois abus fréquents dans les tableaux de bord. (1) Appliquer l'intervalle à un extrait non aléatoire : la formule suppose un tirage au sort, et le nôtre n'en est pas un — son intervalle ne couvre que la variabilité, jamais le biais. (2) Conclure à l'équivalence parce que deux intervalles se chevauchent : c'est le test du chapitre M02.C08 qui tranche. (3) Faire varier le niveau de confiance après coup pour rendre un résultat intéressant : fixez 95 % dans la note de cadrage, avant d'ouvrir le fichier.

5.6 Le bootstrap : remesurer sans retourner sur le terrain

Définition. Le **bootstrap** (bootstrap) traite l'échantillon comme une population : on tire 2 000 fois, **avec remise**, un échantillon de même taille, on recalcule la statistique, et les 2,5^e et 97,5^e percentiles de ces 2 000 résultats servent d'intervalle.

La formule du §5.5 n'existe que pour la moyenne ; le bootstrap s'applique à toute statistique que l'on sait recalculer. Mesures prises sur nos 316 paniers, graine 20260917 :

Statistique		Intervalle par formule	Intervalle par bootstrap	Lecture
Moyenne paniers	des	[94 078 ; 134 234]	[95 397 ; 133 574]	les deux se recoupent : profil peu déformé
Médiane paniers	des	inexistante	[52 318 ; 64 632]	largeur 12 314 FCFA : mieux connue que la moyenne
Minimum paniers	des	inapplicable	[-150 804 ; 797]	artefact, ligne suivante

Le plus petit panier vaut -150 804 FCFA : un ticket sur 316. Dans un ré-échantillonnage, sa probabilité d'être absent est forte, et le minimum saute alors à la valeur suivante, 797 FCFA. Résultat : 64,3 % des 2 000 tirages reproduisent le minimum exact, et l'intervalle obtenu ne mesure pas l'incertitude mais la discontinuité. Règle métier : **on ne bootstrap pas les valeurs extrêmes**, ni rien qui tienne à quelques lignes — seuils de retours, plus gros clients, aberrants de M02.C02-C03 ; ceux-là se comptent.

```
rng = np.random.default_rng(20260917)
rejes = rng.choice(pan, size=(2000, n), replace=True)
print(np.percentile(np.median(rejes, axis=1), [2.5, 97.5])) # [52318. 64632.] avec cette graine
```

Conseil professionnel. Publiez un intervalle bootstrap avec trois précisions : nombre de tirages, graine, version de la bibliothèque. « [52 318 ; 64 632] FCFA, 2 000 tirages, graine 20260917 » se vérifie en trente secondes ; « environ $\pm 6\,000$ FCFA » ne se vérifie pas du tout.

5.7 Combien de tickets faut-il mesurer ?

On retourne le problème : au lieu de subir la précision, on la commande.

Objectif	Calcul	n nécessaire	Avec nos 316 tickets
Proportion à ± 5 points, pire cas	$(1,96 / 0,05)^2 \times 0,25$	385	insuffisant
Proportion à ± 5 points, $p \approx 33\%$	$(1,96 / 0,05)^2 \times p(1 - p)$	340	insuffisant
Proportion à ± 3 points, pire cas	$(1,96 / 0,03)^2 \times 0,25$	1 068	loin du compte
Moyenne de panier à $\pm 10\%$ relatif	$(1,96 \times \sigma / (0,1 \times \text{moyenne}))^2$	978	insuffisant

Trois enseignements de gestion, plus utiles que les chiffres :

1. **Rendements décroissants.** Diviser la marge par deux demande quatre fois plus de données, la diviser par dix en demande cent. Passer de $\pm 20\,078$ à la moitié sur la moyenne équivaut à quadrupler l'effectif — mais un mois complet de magasin en contient 4 524 : on peut le payer sans changer d'outil. La question devient « vaut-il la peine de lire toute l'année pour un chiffre ? », jamais « faut-il un meilleur logiciel ? ».
2. **Le grain est un plan d'échantillonnage.** Tirer 480 lignes ne vaut pas tirer 480 tickets : à 1,52 ligne par ticket, un tirage de lignes sur-représente les paniers à plusieurs lignes, donc les gros. Objet client → tirez des tickets ; objet produit → tirez des lignes ; et écrivez lequel.
3. **Le volume ne dispense pas du plan.** 240 000 lignes reconduisent exactement le même biais de couverture si elles viennent des seuls jours 1 à 4. À l'inverse, un plan stratifié bien né — 30 tickets par trimestre et par vendeur — informe mieux qu'un million de lignes prises à la tête du client.

Définition. L'échantillonnage stratifié (stratified sampling) découpe la population en cases (jour du mois, catégorie, vendeur, trimestre), tire au sort dans chaque case, puis combine les résultats pondérés par le poids réel des cases. C'est le remède direct au §5.3 : il garantit que début et fin de mois sont observés.

5.8 Corriger après coup, et choisir l'outil

Quand re-tyrager est impossible, la technique de secours est la **post-stratification** (pondération) : on garde l'échantillon, mais on redonne à chaque strate son poids réel. Testons-le : sur le montant moyen par ligne, l'extrait annonce 75 152 FCFA pour 68 889 FCFA en population, soit +9,1 % ; en repesant la structure par catégorie de produits aux poids du mois complet, on tombe à 78 060 FCFA, soit +13,3 %. **La pondération a aggravé l'erreur** — non par défaut de méthode, mais par sa limite structurale : on ne corrige que l'axe sur lequel on équilibre, et le défaut d'ici vit dans le calendrier. À écrire noir sur blanc dans un rapport.

Question	Tableur	SQL (DuckDB)	pandas / Python
Tirer k lignes au hasard	<code>=ALEA.ENTRE.BORNES(1;480) + =INDEX()</code>	<code>USING SAMPLE 30 ROWS</code>	<code>df.sample(30, random_state=20260917)</code>
Tirer par strate	filtre puis <code>=ARRALE()</code> sur la sous-plage	<code>ROW_NUMBER() OVER (PARTITION BY mois ORDER BY random())</code>	<code>g.sample(n=30, random_state=...)</code>
Erreur type d'une moyenne	<code>=ECARTYPE.STANDARD(plage)/RACINE(NB(plage))</code>	<code>STDDEV_SAMP(m)/ SQRT(COUNT(*))</code>	<code>s.std(ddof=1) / len(s)**0.5</code>
Marge 95 %	<code>=INTERVALLE.CONFIANCE.NORMAL(0,05;écart_type;effectif)</code>	multiplication par 1,96 (pas de fonction dédiée)	<code>scipy.stats.norm.ppf(0.975)</code>
Intervalle d'une proportion	<code>=1,96*RACINE(p*(1-p)/n)</code>	idem en SQL	<code>proportion_confint (statsmodels)</code>
Bootstrap	déconseillé : pas de boucle rejouable sans macro	export Python	puis <code>rng.choice(valeurs, size=(2000, n), replace=True)</code>

Vigilance d'outillage, parce qu'elle casse les rapprochements entre collègues : les fonctions d'intervalle ne se nomment pas pareil selon le logiciel, et ne rendent pas un intervalle. Dans Excel, `INTERVALLE.CONFIANCE.NORMAL` et `INTERVALLE.CONFIANCE.STUDENT` rendent la **demi-largeur**, à ajouter et retrancher de la moyenne ; dans LibreOffice, la famille s'appelle `INTERVALLE.CONFIANCE.NORMAL` et `INTERVALLE.CONFIANCE.T` (la version héritée `INTERVALLE.CONFIANCE` reste acceptée pour compatibilité). Un facteur 2 d'écart entre deux notes vient plus souvent de ce détail que des données.

Boîte à outils. Le minimum à écrire sous tout chiffre issu d'un extrait : (1) la **population** visée et sa source (tickets du magasin 5, 2025, 4 524) ; (2) l'**unité sondée** (le ticket, pas la ligne) ; (3) l'**effectif** et le taux de représentation (316, soit 7,0 %) ; (4) la **règle d'extraction** reconstituée, avec son biais chiffré quand il est mesurable (jours 1 à 4 ; médiane -14,3 %) ; (5) l'**intervalle** avec sa méthode (formule ou bootstrap, nombre de tirages, graine). Cinq lignes de pied de page, et elles valent plus que le graphique.

6. Exemple concret : « le panier moyen du magasin 5, à quoi bon le discuter ? »

La demande. Le directeur régional prépare un arbitrage d'assortiment et veut un chiffre unique. Un collaborateur a répondu 114 156 FCFA en ouvrant le fichier d'extraction, sans autre forme de procès.

Ce que le dossier permet vraiment de dire.

On savait	On établit en lisant la règle d'extraction	On établit avec l'intervalle
114 156 FCFA	l'extrait ne couvre que les jours 1 à 4 : 6,3 % des lignes du magasin sur l'année	le vrai panier annuel, sur 4 524 tickets, est 116 886 FCFA : -2,3 %, dans l'intervalle [94 078 ; 134 234]
58 423 FCFA de médiane	la médiane du début de mois, dans la population, est 58 424 FCFA	la médiane annuelle est 68 160 FCFA : -14,3 %, et ce n'est pas du bruit

Ce que le chiffre change à la décision. Sur la moyenne, personne n'aurait changé d'avis : 2,3 % dans un intervalle large d'un tiers ne déplace aucune décision. Sur la médiane, si : conclure « la moitié de nos clients est sous 58 000 FCFA » oriente vers un assortiment d'entrée de gamme, alors que la moitié réelle est sous 68 160 FCFA — 9 700 FCFA d'écart par ticket, multipliés par 4 524 tickets, cela devient une question d'assortiment et non d'arrondi. Le travail n'a pas été de calculer plus finement, mais de replacer le chiffre dans le calendrier dont il venait.

La phrase à écrire. « Panier moyen estimé sur l'extrait (316 tickets, jours 1 à 4 de chaque mois) : 114 156 FCFA, intervalle à 95 % [94 078 ; 134 234]. Valeur annuelle complète : 116 886 FCFA, soit un écart de 2,3 % — l'extrait est usable pour la moyenne. La médiane reproduit celle du début de mois et sous-estime de 14,3 % la médiane annuelle : à recalculer sur le mois complet. »

7. Démonstration pas à pas : de la règle d'extraction à l'intervalle

Étape 1 — Reconstituer la règle. Ouvrez le script d'extraction, ou faites-vous le donner. Ici : tri par date puis 40 premières lignes par mois. Recopiez la règle en une phrase dans le carnet de données, avec la date de la vérification.

Étape 2 — Aligner les périmètres. Population au même grain : 7 676 lignes, 4 524 tickets. Extrait : 480 et 316. Le taux de sondage (6,3 % en lignes, 7,0 % en tickets) n'est pas encore un jugement : il dit qu'une lecture exhaustive est possible.

Étape 3 — Mesurer l'écart, statistique par statistique. Moyenne -2,3 %, médiane -14,3 %. On n'écrit pas « l'extrait est biaisé » : on dit quelle statistique est touchée et de combien.

Étape 4 — Attribuer le biais. Médiane des jours 1 à 4 dans la population : 58 424 FCFA ; jours suivants : 70 267 FCFA. L'extrait, à un franc près, est le premier groupe. Le biais est attribué à un axe, pas à une ambiance.

Étape 5 — Séparer le biais de la variabilité. Simulation de 5 000 tirages de 30 : écart type 31 363 FCFA, bande des 95 % du milieu de 63 898 à 182 706 FCFA. À 316, erreur type 10 244 FCFA et marge 20 078 FCFA. Ce que la taille arrange, et ce qu'elle n'arrange pas, sont maintenant deux chiffres distincts.

Étape 6 — Choisir le remède. Élargir la lecture (mois complet, coût nul, 4 524 tickets) avant de bricoler des poids : la pondération par catégorie, elle, remonte l'écart de +9,1 % à +13,3 %.

Contrôles qualité du chapitre.

#	Contrôle	Seuil	Résultat attendu	Si échec
1	Effectif de l'extrait conforme à la règle annoncée	identité	480 lignes pour 40 × 12	règle devinée, pas lue
2	Population et échantillon au même grain	même unité	316 tickets contre 4 524	agrégation de lignes oubliée
3	Écart type simulé et formule	écart < 5 %	31 363 contre 31 679 FCFA	tirage avec / sans remise confondu
4	L'intervalle contient la valeur de population	oui ou non écrit	contient 116 886 FCFA	formule appliquée hors conditions
5	Bootstrap employé hors valeurs extrêmes	interdit sur min et max	minimum exclu, médiane retenue	artefact pris pour incertitude
6	Chaque pourcentage rapporté à son effectif	systématique	32,9 % (104 de 316)	proportion sans dénominateur

8. Erreurs fréquentes

1. **Confondre imprécision et biais.** L'intervalle mesure la fluctuation du tirage ; il ne dit rien de la façon dont on a tiré. Notre extrait a une marge d'erreur honnête et un mauvais calendrier.
2. **Se rassurer avec le volume.** 480, 7 676 ou 240 000 lignes : si la règle de sélection est la même, l'écart systématique est le même. La précision augmente, la justesse non.
3. **Annoncer un pourcentage sans dénominateur.** « 21,5 % des lignes n'ont pas de client exploitable » se défend parce qu'on sait que c'est sur 480 ; sans le dénominateur, la phrase devient une rumeur.
4. **Appliquer les formules d'intervalle à un échantillon de convenance** sans le dire : on peut publier l'intervalle, à condition d'écrire qu'il ne couvre que la variabilité d'échantillonnage.
5. **Bootstraper un minimum, un maximum ou un seuil rare** : ces statistiques ne dépendent que de quelques lignes, et le ré-échantillonnage les fait sauter (64,3 % de tirages identiques sur notre minimum).
6. **Multiplier les sous-populations jusqu'à l'effectif ridicule.** Un intervalle sur 4 tickets d'une strate est un objet mathématique sans contenu : publiez l'effectif de la strate à côté de sa marge, et signalez toute strate de moins d'une dizaine d'observations comme non exploitable.

9. Bonnes pratiques professionnelles

1. **Une ligne de méthodologie par chiffre** : population, unité sondée, effectif, règle d'extraction, intervalle.
2. **La règle d'extraction vit dans le dépôt**, pas dans un e-mail : un en-tête de requête (-- extrait : 40 premières lignes par mois, 2025, magasin 5) survit à son auteur.
3. **Toujours fixer la graine.** Un résultat non rejouable n'est pas un résultat, c'est une anecdote.
4. **Publier la marge avant la conclusion.** Le lecteur décide d'agir ou non ; c'est son rôle, et vous venez de lui donner de quoi.
5. **Fixer le seuil d'exploitation par strate avant de découper** (« toute strate sous 12 observations est agrégée ») : sinon le premier tableau de bord segmenté conclura sur deux tickets.
6. **Faire valider le taux de sondage par le métier.** 7,0 % des tickets du magasin sur l'année, est-ce assez pour un arbitrage d'assortiment ? Le responsable de rayon le sait mieux que vous : son critère n'est pas la précision statistique mais le coût d'une décision ratée.

10. Exercice guidé — mesurer l'incertitude d'un panier moyen

Énoncé. Sur le fichier attendu, estimez le panier moyen, son intervalle à 95 %, et l'écart entre cet intervalle et la valeur annuelle réelle du magasin. Concluez en une phrase pour un directeur.

Vous faites — barème 10 points, total 10.

Étape	Ce que vous produisez	Points
A	Population, unité sondée et effectifs écrits avant tout calcul	2
B	Erreur type et marge d'erreur, formule énoncée	2,5
C	Intervalle à 95 % comparé à la valeur annuelle	2,5
D	Contrôle par bootstrap, avec nombre de tirages et graine	1,5
E	Phrase de conclusion séparant variabilité et biais	1,5

Nous vérifions. 316 tickets pour 4 524 (7,0 %) · erreur type 10 244 FCFA · marge 20 078 FCFA · intervalle [94 078 ; 134 234] FCFA · valeur annuelle 116 886 FCFA, donc couverte · bootstrap 2 000 tirages, graine 20260917, intervalle [95 397 ; 133 574] FCFA.

Nous corrigeons. Trois défauts reviennent : l'intervalle présenté comme « la fourchette des paniers » (il s'agit de la fourchette de la **moyenne** ; celle des clients va de -150 804 à 1 343 666 FCFA) ; le contrôle de couverture oublié ; et la conclusion « nos clients dépensent 114 156 FCFA », qui oublie que 71,8 % des tickets sont sous cette moyenne (M02.C02). La phrase juste porte l'estimation, sa plage, et ce que la plage autorise.

11. Exercices autonomes

Exercice 7.1 (★) — Les quatre objets. Pour votre extrait, nommez la population visée, l'unité sondée, l'échantillon et la statistique, en une ligne chacun avec les effectifs mesurés.

Exercice 7.2 (★) — Deux tirages. Une chance sur deux de tomber sur un panier sous 50 000 FCFA ? Calculez la probabilité pour un puis deux tirages, et dites pourquoi le tirage sans remise rend le calcul légèrement faux.

Exercice 7.3 (★★) — La marge en pratique. Intervalle à 95 % de la part des lignes comportant une remise non nulle (173 lignes sur 480), puis effectif nécessaire pour ramener la marge à ± 3 points.

Exercice 7.4 (★★) — Trancher un désaccord. Un collègue annonce 68 000 FCFA de médiane sur le mois complet contre vos 58 423 FCFA sur l'extrait. Produisez les trois nombres qui permettent de dire qui mesure quoi, et lequel est utilisable pour décrire le magasin.

Exercice 7.5 (★★★) — Le plan. Vous devez livrer un chiffre sur les paniers du trimestre en cours, à ± 10 % près, et la base ne permet d'exporter que 1 200 lignes. Proposez le plan (unité sondée, strates, tirage, contrôles), et dites le risque que le plan ne corrige pas. (attendu : tirer des tickets, strates par mois et par vendeur, contrôle de l'écart type simulé contre la formule, risque résiduel de couverture sur retours et avoirs)

12. Correction détaillée

Exercice 7.1. Population : les 4 524 tickets du magasin 5 en 2025 (ou, à l'échelle du socle, les 240 000 lignes propres des quatre années). Unité sondée : le ticket — 480 lignes pour 316 tickets, 1,52 ligne par ticket. Échantillon : 6,3 % des lignes, 7,0 % des tickets. Statistique : 114

156 FCFA — et non un paramètre, dont la correspondante est 116 886 FCFA. C'est cette distinction qui rend la suite lisible.

Exercice 7.2. 136 tickets sur 316 sous 50 000 FCFA : 43,0 %. Deux tirages supposés indépendants : environ 18,5 %. En tirant sans remise, le second tirage ne porte plus que 135 candidats favorables sur 315, soit un écart de l'ordre de 0,1 point — négligeable ici, mais c'est exactement ce qui rend la dispersion simulée du §5.2 un peu plus petite que la formule (facteur 0,953).

Exercice 7.3. 173 lignes sur 480 : 36,0 %. Erreur type 2,2 points, marge 4,3 points, intervalle [31,7 ; 40,3] %. Pour une marge de ± 3 points : 1 068 lignes au pire cas, 984 lignes à $p \approx 36$ %, soit un peu plus du double de l'effectif disponible pour gagner 1,3 point. C'est la loi du $\sqrt{n}$, et c'est l'objet de la négociation avec le métier.

Exercice 7.4. Les trois nombres : médiane de l'extrait 58 423 FCFA ; médiane annuelle du magasin 68 160 FCFA ; médiane des tickets annuels datés des jours 1 à 4, 58 424 FCFA. La troisième tranche : l'extrait n'est pas faux, il est partiel, et il mesure précisément le début de mois. Seul le deuxième chiffre décrit le magasin entier. On n'a pas « raison » : on a mesuré deux objets différents.

Exercice 7.5. Unité sondée : le ticket — 1 200 lignes en représentent moins (environ 790 au rythme de 1,52 ligne par ticket). Strates : trois mois $\times$ quatre vendeurs, soit 12 cases et environ 66 tickets chacune, effectif à signaler car aucune strate ne descend alors très bas. Tirage : `ROW_NUMBER() OVER (PARTITION BY mois, vendeur ORDER BY random())` avec graine, ou `df.groupby(["mois", "vendeur"]).sample(n=..., random_state=20260917)`. Contrôles : écarts types simulé et théorique, présence de toutes les strates, marge publiée avec l'effectif. Risque résiduel : le tirage n'opère que sur la **liste** produite par la caisse ; si les retours et avoirs en sont absents (8 lignes de retour, -283 933 FCFA dans l'extrait, M02.C02), aucun plan d'échantillonnage ne les fera réapparaître — c'est encore la couverture qu'il faut interroger.

13. Mini-projet M02.P4 — « La page d'incertitude » (45 min, premier volet ; M02.C08 enchaîne)

Commande. À partir du fichier attendu et de la population du magasin sur 2025, produisez une page qui répond à : « que peut-on affirmer, et avec quelle marge, sur le panier moyen et sur la part des tickets avec remise ? ». Le volet décision (comparaisons de vendeurs, tests) est ajouté au chapitre suivant : M02.P4 est rendu une seule fois, pour les deux chapitres.

Livrables numérotés. (1) bloc méthodologie : population, unité sondée, effectifs, taux de sondage, règle d'extraction ; (2) pour chacune des deux statistiques : estimation, erreur type, marge, intervalle, méthode ; (3) un contrôle de couverture, la même statistique calculée sur le mois complet avec l'écart en pourcentage ; (4) dix lignes qui disent ce que l'intervalle autorise, ce qu'il interdit, et ce qu'on irait chercher si on avait le droit de tout lire ; (5) ligne de journal (fichiers, effectifs, nombre de tirages, graine, versions).

Barème (20 points, seuil 13). Méthodologie complète (4) · estimations justes et sourcées (4) · intervalles corrects, méthode explicitée (4) · contrôle de couverture chiffré et commenté (3) · interprétation sans abus de langage (3) · journal (2) — total 20. Le second volet, en M02.C08, apportera ses 20 points ; la note du projet est la moyenne des deux volets.

14. Résumé du chapitre

1. Le hasard éparpille, la méthode décale : erreur type (10 244 FCFA sur notre moyenne) et biais (-14,3 % sur notre médiane) se mesurent séparément et ne se corrigent pas l'un par l'autre.

2. La précision obéit à $\sqrt{n}$: 978 tickets pour ± 10 % relatifs, 1 068 lignes pour ± 3 points, contre 316 disponibles.
3. Un intervalle qualifie une méthode, pas un cas : [94 078 ; 134 234] FCFA se rate une fois sur vingt, et nous avons vérifié qu'il contient la valeur annuelle de 116 886 FCFA.
4. Le bootstrap intervalle toute statistique recalculable — la médiane y gagne ([52 318 ; 64 632] FCFA), les valeurs extrêmes y perdent toute signification.
5. Une pondération ne corrige que l'axe qu'elle équilibre : repeser les catégories a monté l'écart de +9,1 % à +13,3 %, parce que le défaut était dans le calendrier.

15. À retenir

À retenir.

- Avant de calculer : population, unité sondée, effectif, règle d'extraction. Ces quatre lignes précèdent le premier chiffre, dans une note comme dans une requête.
- Erreur d'échantillonnage : $1,96 \text{ fois } \sigma / \sqrt{n}$. Biais : ce que cette formule ne voit pas. Les deux se publient, séparément.
- Un intervalle ne couvre jamais le biais ; un gros volume ne rachète jamais une mauvaise liste. 480 lignes bien tirées battent 240 000 lignes mal choisies.
- Toute simulation se déclare : 5 000 tirages, 2 000 tirages, graine 20260917. Sans graine, pas de résultat.

À retenir. La formulation qui tient debout. « Sur 316 tickets extraits des quatre premiers jours de chaque mois (6,3 % des lignes du magasin en 2025), le panier moyen est de 114 156 FCFA, intervalle à 95 % [94 078 ; 134 234]. La valeur annuelle complète est 116 886 FCFA : notre intervalle la contient. La médiane de l'extrait reproduit celle du début de mois (58 423 contre 58 424 FCFA) et sous-estime de 14,3 % la médiane annuelle : elle ne décrit pas le magasin. »

16. Évaluation formative (auto-correction, 12 min)

1. Quelle différence de nature entre erreur d'échantillonnage et biais, et pourquoi le second ne se réduit-il pas en augmentant l'échantillon ? 2. Sur l'extrait, la moyenne est à 2,3 % de la valeur annuelle et la médiane à 14,3 %. Que dit cet écart de comportement sur la fabrication du fichier ? 3. Un intervalle à 95 % calculé sur un échantillon de convenance : que couvre-t-il, que ne couvre-t-il pas ? 4. Pourquoi ne bootstrap-t-on pas un minimum, et que publie-t-on à la place ? 5. On veut diviser la marge par deux : de combien multiplie-t-on l'effectif, et que répondez-vous au directeur qui propose « de prendre un mois de plus » ?

Corrigé

1. L'erreur d'échantillonnage est la fluctuation d'un tirage à l'autre autour de la cible, et elle décroît en $1/\sqrt{n}$. Le biais déplace la moyenne des tirages : augmenter l'effectif resserre l'intervalle ****autour de la valeur biaisée****, donc rend plus confiant et plus faux à la fois. 2. Que l'extrait sur-représente un profil de jours, et que les positions centrales y sont sensibles : le début de mois a de plus petits paniers (58 424 contre 70 267 FCFA de médiane), la moyenne l'est peu car elle est tirée vers le haut par les gros tickets, présents à toutes les dates. D'où la règle : tester chaque statistique, pas le fichier en bloc. 3. Il couvre la variabilité du tirage, en supposant un tirage aléatoire. Ni le biais de sélection, ni les erreurs de mesure, ni le fait que la population visée n'était pas la bonne. 4. Parce qu'un minimum ne dépend que d'une ou deux observations : 64,3 % de nos ré-échantillonnages reproduisent le même ticket extrême, les autres sautent à la valeur suivante (797 FCFA), et l'intervalle [-150 804 ; 797] FCFA n'a aucune lecture honnête. À la place, on compte des effectifs : 8 lignes de retour, 25 tickets au-dessus du seuil de Tukey, 3 paniers négatifs, chacun avec sa marge de proportion. 5. Par quatre : de 316 tickets il faudrait dé-

passer le millier et demi, quand 978 suffiraient pour ± 10 % relatifs. « Prendre un mois de plus » ajoute de la précision mais reconduit le même biais si le mois suivant est lui aussi tronqué aux quatre premiers jours — la bonne demande est « le mois entier, ou un tirage au sort dans le mois ».

M02.C08 — Décider avec incertitude : intervalle de confiance, tests, interprétation et limites

L'idée du chapitre. Un écart observé est-il un écart réel ? Le test statistique répond à cette question précise — et à aucune autre. Ce chapitre donne la mécanique (hypothèses, statistique de test, valeur p, décision), les trois tests qui couvrent 90 % des demandes d'un service études, et surtout les quatre façons dont on les fait mentir.

Base de travail — obligatoire. Le fichier nettoyé `donnees/reference/ventes_magasin5_2025_ATTENDU.csv` (480 lignes × 13 variables, 316 tickets, 4 vendeurs) et, pour les comparaisons, la population du même magasin sur 2025 (7 676 lignes, 4 524 tickets) dans `01_socle_donnees/data/reference/ventes_propres.csv`. Séparateur point-virgule, UTF-8, virgule décimale, montants en FCFA. Valeurs mesurées dans `01_socle_donnees/data/reference/chiffres_cites.md`, section M02.

1. Objectifs du chapitre

À la fin de ce chapitre, vous êtes capable de :

1. formuler une hypothèse nulle et une hypothèse alternative lisibles, et choisir le test d'après la nature de la variable et le grain de l'observation ;
2. conduire un test de comparaison de moyennes (t de Welch), un test de comparaison de rangs (Mann-Whitney) et un test d'indépendance sur tableau de fréquences (χ^2), avec leurs conditions d'emploi ;
3. lire une valeur p sans lui faire dire « la probabilité que H_0 soit vraie », et publier l'intervalle avec le test ;
4. distinguer « non significatif » de « égal », et chiffrer ce qu'une étude n'est **pas** en état de détecter ;
5. calculer la puissance d'un comparatif et l'effectif nécessaire, et déclarer à temps une étude sous-calibrée ;
6. repérer les quatre abus qui ruinent un travail sinon — comparaisons multiples, seuil de 5 % traité en loi, confusion entre significatif et important, test appliqué à un grain ou à un échantillon mal formé.

2. Pourquoi cette notion est importante

Un comparatif sans test est une loterie commentée. Trois dérives professionnelles, dans l'ordre de fréquence :

- **La prime au plus chanceux.** Quatre vendeurs, six comparaisons deux à deux : même si aucun ne se distingue, la probabilité qu'au moins un test dépasse le seuil de 5 % par pur hasard est d'environ 26,5 % (1 moins 0,95 élevé à la puissance six). Récompenser « le meilleur » sur cette base, c'est récompenser un tirage.
- **Le « ça n'a pas bougé ».** Sur 125 et 109 lignes, un écart réel de 20 000 FCFA par ligne ne serait vu que dans 18,5 % des cas : conclure à l'absence de différence, c'est confondre « non mesuré » et « nul ».

- **Le rapport qui noie le décideur.** Vingt pourcentages sans intervalle ne permettent ni d’agir ni de contester. Le test trace la discussion : la question est écrite avant, la réponse est une plage après.

Dans les faits. En entreprise, la quasi-totalité des demandes évaluables tient dans trois formats : comparer deux moyennes (ce vendeur, ce rayon, ce mois), comparer une part à une cible (21,5 % de lignes sans client, est-ce anormal ?), et tester une association (les remises dépendent-elles du vendeur ?). Les chapitres de référence enseignent souvent vingt tests ; ici on en conduit trois, à fond, sur des données que vous pouvez vérifier — c’est ce qui rend le jugement transférable.

3. Explication simple

Vous comparez deux balances de marché. Bationo affiche un panier plus élevé qu’Ilboudo. Avant de crier à la performance, deux questions :

1. **La balance est-elle fidèle ?** Avec 125 et 109 lignes, l’écart entre deux moyennes peut légitimement varier de $\pm 36\,888$ FCFA d’un extrait à l’autre (l’erreur type de la différence vaut 18 821 FCFA, et la marge à 95 % fait 1,96 fois ce montant). L’écart observé est de 28 609 FCFA : il rentre dans le bruit.
2. **Quelle question pose-t-on ?** « L’écart est-il exactement zéro ? » est une question fausse — la réponse est toujours non, deux groupes ne sont jamais parfaitement égaux. La question juste est : « un écart de cette taille est-il compatible avec l’absence de différence ? ». Le test répond à celle-là.

Le **p** est donc un verdict de compatibilité, pas une probabilité de vérité : « si aucun vendeur ne se ressemblait moins que par hasard, on verrait un écart au moins aussi grand dans 13 cas sur 100 ». À partir de là, on décide — et on écrit la plage, pas seulement la décision.

4. Vocabulaire essentiel

#	Terme	Français — English — sens simple	À savoir
1	Hypothèse nulle	hypothèse nulle — null hypothesis, H0 — l’écart s’explique par le seul hasard	c’est elle qu’on teste, jamais H1
2	Hypothèse alternative	hypothèse alternative — alternative hypothesis, H1 — l’option concurrente	à deux côtés par défaut (un écart dans un sens ou l’autre)
3	Statistique de test	statistique de test — test statistic — l’écart mesuré, divisé par sa variabilité normale	$t = 1,52$ ici
4	Valeur p	valeur p — p-value — probabilité d’observer un écart au moins aussi grand si H0 était vraie	pas $P(H0 \text{ vraie})$
5	Seuil alpha	seuil de signification — significance level, α — le risque qu’on accepte de prendre à tort	0,05 par usage, à fixer avant
6	Significatif	significatif — statistically significant — non compatible avec le seul hasard au seuil choisi	ne veut pas dire « important »
7	Erreur de premier type	erreur de premier type — type I error — conclure à une différence inexistante	risque α
8	Erreur de second type	erreur de second type — type II error — manquer une différence réelle	risque β ; la puissance vaut $1 - \beta$
9	Puissance	puissance statistique — statistical power — probabilité de détecter un écart donné	0,80 est la convention
10	Degrés de liberté	degrés de liberté — degrees of freedom — l’information restante après estimation	226,1 en Welch sur nos deux groupes

#	Terme	Français — English — sens simple	À savoir
11	Test de Welch	test t de Welch — Welch's t-test — comparaison de moyennes, variance libre	à préférer au t de Student classique
12	Test de Mann-Whitney	test de Mann-Whitney — Mann-Whitney U test — comparaison des rangs des deux groupes	robuste aux queues épaisses, n'éprouve pas la moyenne
13	Test du chi-deux	test du khi deux d'indépendance — chi-squared test of independence — fréquences observées contre attendues	exige des effectifs théoriques suffisants
14	Effectif théorique	effectif attendu — expected count — ce que donnerait l'indépendance parfaite	minimum 39,3 ici, franchement au-dessus de 5
15	Correction de Bonferroni	correction de Bonferroni — Bonferroni correction — seuil divisé par le nombre de tests	0,05 sur six tests devient 0,0083

5. Cours approfondi

5.1 La charpente d'un test, en cinq mouvements

Définition. Un **test statistique** est une procédure qui compare l'écart observé à ce que le hasard produit habituellement. Il énonce H_0 (« aucun vendeur ne diffère »), calcule une **statistique de test** (l'écart rapporté à sa variabilité normale), en déduit une **valeur p** (combien de fois le hasard fait au moins aussi bien), et conclut au seuil α fixé d'avance.

Sur notre couple vedette, les montants par ligne de Bationo et d'Ilboudo, les cinq mouvements donnent :

Mouvement	Valeur sur le fichier
H_0 : différence de moyennes nulle	écart à tester
Écart observé	28 609 FCFA (moyennes 90 963 contre 62 354 FCFA)
Erreur type de la différence	18 821 FCFA
Statistique t (Welch), ddl 226,1	1,52 — sous H_0 , la valeur seuil à 5 % est 1,97
Valeur p	0,13 : le hasard fait au moins aussi bien dans 13 % des cas
Décision au seuil de 5 %	on ne rejette pas H_0 — et on publie l'intervalle [-8 279 ; 65 498] FCFA

Quatre lectures exactes de la valeur p, et quatre fausses :

Juste	Faux
P(observer un écart $\geq 28\,609$ FCFA si H_0 est vraie)	P(H_0 est vraie)
Une mesure de compatibilité avec « aucun écart »	Une mesure de la taille de l'écart
Dépend de l'effectif : à écart égal, plus n grossit, plus p baisse	Elle serait indépendante du plan de collecte
Elle dépend du plan de collecte, pas seulement des données	« $p = 0,06$: donc pas de différence »

5.2 Choisir le test d'après la question et le grain

Question	Test	Ce qu'il éprouve	Conditions	Chez nous
Deux moyennes différent-elles ?	t de Welch	égalité des moyennes	indépendance, effectifs suffisants ($n > 30$ par groupe : 125 et 109 ✓)	1,52 ; $p = 0,13$
Un profil entier est-il décalé ?	Mann-Whitney	égalité des distributions (via les rangs)	indépendance ; aucune hypothèse de normalité	$p = 0,0161$

Question	Test	Ce qu'il éprouve	Conditions	Chez nous
Deux parts différentes ?	z sur deux proportions	égalité proportions	des au moins 5 succès et 5 échecs par groupe ✓	$z = 1,21$; $p = 0,225$
Une association existe-t-elle entre deux catégories ?	χ^2 d'indépendance	indépendance des deux variables	effectifs théoriques ≥ 5 pour la plupart des cases	3,03 ; ddl 3 ; $p = 0,388$
Une moyenne tient-elle une cible ?	t sur un échantillon	moyenne = valeur cible	idem t	$t = 1,38$; $p = 0,168$ contre 100 000 FCFA
Un écart est-il nul ?	test d'équivalence, pas un test de différence	écart borné	bornes écrites avant le test	à faire, voir §5.4

Conseil professionnel. Écrivez la question, le test et le seuil **avant** d'ouvrir le fichier, dans le ticket de travail. Un test choisi après avoir vu les données n'est plus un test : c'est une justification. Cette règle unique élimine la moitié des abus du §5.7, et elle est gratuite.

5.3 Comparer deux moyennes : le t de Welch, et l'intervalle qui va avec

Le test de Welch compare l'écart observé à son erreur type, en laissant aux deux groupes leur propre dispersion — c'est la version à utiliser par défaut, celle de Student supposant des variances égales n'ayant plus d'argument pratique (ici les écarts types des deux groupes différent du simple au double environ). Le résultat est dans le tableau du §5.1 : $t = 1,52$, ddl = 226,1, $p = 0,13$.

Le réflexe professionnel n'est pas de s'arrêter au p : c'est de publier l'**intervalle de la différence**, [-8 279 ; 65 498] FCFA. Les deux objets disent la même chose — un intervalle à 95 % exclut zéro si et seulement si le test bilatéral rejette à 5 % — mais l'intervalle dit aussi **de combien** on pourrait se tromper. Une différence de 65 498 FCFA par ligne comme une absence de différence sont toutes deux compatibles avec ce que nous voyons : c'est cela, le résultat.

Écart de montant moyen par ligne entre vendeurs, avec intervalle de confiance à 95 %




Figure — Six comparaisons deux à deux sur les montants par ligne : tous les intervalles contiennent zéro.

La figure est ce qu'on montre au comité : six paires de vendeurs, six intervalles, et **tous traversent zéro**. Le plus petit p des six comparaisons est 0,13. Un diagramme en forêt — forest plot — règle la discussion plus vite que vingt lignes de commentaires, parce que le décideur voit la largeur des barres.

Attention. « Non significatif » ne veut pas dire « les vendeurs se ressemblent ». Cela veut dire : avec ces effectifs et cette variabilité, nous ne pouvons pas distinguer l'écart observé du bruit. La phrase correcte contient la plage : « écart non établi ; la différence, si elle existe, est comprise entre -8 279 et 65 498 FCFA par ligne, ce qui laisse ouverte l'hypothèse d'un avantage de Batio-no comme celle de l'égalité ».

5.4 Ce que notre étude peut détecter : puissance et marge de détection

Définition. La **puissance statistique** (statistical power) d'un test est la probabilité de rejeter H_0 quand l'écart réel vaut une taille donnée ; la **marge de détection** (en anglais minimum detectable effect) est l'écart que le test relève avec 80 % de puissance. Les deux se calculent avant la collecte, et se publient après.

Un test non concluant a une cause chiffrable : le manque de puissance.

Objet	Valeur	Lecture
Erreur type de la différence	18 821 FCFA	ce que le hasard autorise comme flou sur un écart
Puissance pour un écart réel de 20 000 FCFA	18,5 %	une chance sur cinq de le voir
Puissance pour l'écart observé (28 609 FCFA)	33,0 %	encore très insuffisant
Écart détectable avec 80 % de puissance	52 956 FCFA	le seuil de visibilité de l'étude
n par groupe pour détecter 28 609 FCFA à 80 %	412 lignes	contre 125 et 109 disponibles

Trois usages de ce tableau, tous trois absents de la plupart des rapports :

1. **Avant** la collecte : « pour voir un écart de 20 000 FCFA, il me faut environ tant de lignes ; avec ce que vous pouvez me fournir en trois semaines, nous ne verrons rien ». Cette phrase évite un mois de travail pour un « non concluant ».
2. **Après** la collecte, quand le test ne rejette pas : « notre étude ne peut pas établir une différence inférieure à 52 956 FCFA par ligne » — c'est une information, pas une excuse.
3. **Pendant** la lecture d'un rapport qui n'est pas le vôtre : si l'auteur conclut à l'absence d'effet sans donner sa marge de détection, demandez-la.

Le calcul de la marge de détection tient en une ligne : écart seuil = (t critique + z de la puissance) $\times$ erreur type, soit environ 2,8 fois l'erreur type quand on vise 80 % de puissance à un seuil de 5 %.

5.5 Deux tests, deux réponses : que faire quand ils divergent

Définition. Le **test de Mann-Whitney** (Mann-Whitney U test, test de la somme des rangs) classe les observations des deux groupes de la plus petite à la plus grande et compare les rangs, non les montants : il éprouve l'égalité des deux distributions, et reste lisible quand la moyenne n'est qu'un point d'ancrage fragile.

Revenons sur le même couple, cette fois avec les **rangs** (Mann-Whitney) : $p = 0,0161$. Le test de différence de moyennes disait 0,13, celui des distributions dit « décalage observable ». Les deux ont raison, parce qu'ils n'éprouvent pas la même chose.

Indicateur par ligne	Batio-no (125 lignes)	Ilboudo (109 lignes)
Moyenne	90 963 FCFA	62 354 FCFA
Médiane	47 849 FCFA	32 426 FCFA

Indicateur par ligne	Bationo (125 lignes)	Ilboudo (109 lignes)
90 ^e percentile	196 553 FCFA	113 273 FCFA
Part des lignes au-dessus de 250 000 FCFA	7,2 %	3,7 %

Le profil de Bationo est décalé vers le haut **partout à la fois** : +15 423 FCFA à la médiane, et le même décalage au 90^e percentile (196 553 contre 113 273 FCFA). Mais la moyenne de Bationo est portée par une queue épaisse, donc très variable d'un tirage à l'autre — c'est exactement ce que M02.C05 montrait sur la forme de la distribution : quand la dispersion des moyennes explose, un test sur la moyenne s'aveugle alors que le décalage d'ensemble est réel.

La décision professionnelle n'est pas « je garde le plus joli des deux p » mais : **quelle hypothèse porte la décision ?** Si la prime se calcule sur le chiffre d'affaires, c'est la moyenne qui compte, et elle n'est pas établie. Si l'on veut savoir si Bationo amène des clients qui achètent plus systématiquement, la comparaison des distributions est plus proche de la question. Écrivez le lien entre l'objet de la décision et l'hypothèse du test, et la divergence cesse d'être un embarras : elle devient l'information.

Attention. Un intervalle de confiance porte sur une **grandeur estimée**, jamais sur un verdict. Publier « $p = 0,13$, donc pas de différence » puis, trois lignes plus loin, « le panier moyen de Bationo est supérieur de 28 609 FCFA » revient à vendre deux histoires incompatibles : la seconde phrase suppose que l'écart est réel, la première qu'il ne l'est pas. Gardez la page et dites ce qu'elle autorise.

5.6 Fréquences et associations : le chi-deux

Définition. Le **test du khi deux d'indépendance** (chi-squared test of independence) compare, case par case, les effectifs observés d'un tableau croisé aux effectifs **attendus** si les deux variables n'avaient aucun lien ; la statistique additionne les écarts relatifs, et se compare à la loi du khi deux dont les degrés de liberté valent $(\text{nombre de lignes} - 1) \times (\text{nombre de colonnes} - 1)$.

Le χ^2 ne compare pas des montants, il compare des **comptages** : les effectifs observés dans un tableau face aux effectifs qu'aurait produits l'indépendance parfaite. « Le taux de remise dépend-il du vendeur ? » se traite ainsi :

Vendeur	Avec remise	Sans remise	Total
Adama Bationo	42	83	125
Salamatu Sankara	49	79	128
Boureima Ouédraogo	37	81	118
Moussa Ilboudo	45	64	109

Résultat mesuré : khi deux = 3,03 pour 3 degrés de liberté, $p = 0,388$ — aucun vendeur ne se distingue dans sa façon d'accorder une remise. Le plus petit effectif théorique vaut 39,3, très au-dessus du seuil de 5 en dessous duquel l'approximation devient hasardeuse ; sous ce seuil, on passe au test exact de Fisher, qui énumère les tableaux possibles au lieu d'approcher leur distribution.

Sur une question plus ciblée — Ilboudo remet-il plus souvent que Bationo ? — le test des deux proportions est plus puissant qu'un χ^2 global : 41,3 % contre 33,6 % de lignes avec remise, écart de 7,7 points, intervalle $[-4,7 ; 20,1]$ points, $z = 1,21$, $p = 0,225$. Les deux réponses vont dans le même sens, et c'est la seconde qui porte l'information utile à la négociation commerciale : si différence il y a, elle peut aller jusqu'à 20 points en faveur d'Ilboudo, ou être nulle.

5.7 Comparaisons multiples : le piège qui fausse tout le reste

Quatre vendeurs, c'est six comparaisons deux à deux. Six occasions de trouver un « résultat » là où il n'y a que du hasard. Sous H_0 , chaque test a 5 % de chances de franchir le seuil, donc la probabilité d'au moins un franchissement sur six monte à 26,5 % environ : avec six comparaisons, on fabrique une découverte statistique tous les quatre dossiers.

Que faire, concrètement :

1. **Annoncer le nombre de tests.** « Six comparaisons ont été menées » est une phrase de la note, pas une confidence.
2. **Corriger le seuil.** Bonferroni divise α par le nombre de comparaisons : 0,05 sur six tests donne 0,0083. Sur notre fichier, le meilleur p en Welch est 0,13 : rien ne passe avant correction, encore moins après. Le test des rangs, lui, donne 0,0161 sur Bationo contre Ilboudo — significatif à 5 %, **non significatif** après Bonferroni. Cette ligne de conduite évite de choisir le test après coup.
3. **Hiérarchiser les questions.** Une question principale, testée au seuil de 5 %, et des questions secondaires affichées en exploratoire, sans étoile ni conclusion. Un tableau de bord qui met onze indicateurs en gras est un appel à la surprise.
4. **Répliquer plutôt que commenter.** Un résultat né d'une comparaison multiple devient intéressant à partir du moment où une seconde période, un second magasin ou une nouvelle extraction le reproduit.

5.8 Les limites du test, et les outils

Quatre limites à écrire dans la note, parce qu'elles conditionnent ce que la décision peut porter.

- **Le grain et l'indépendance.** Le test de Welch suppose des observations indépendantes. Or nos lignes ne le sont pas : elles sont regroupées en tickets (1,52 ligne par ticket), et 84 des 316 tickets portent **plusieurs vendeurs à la fois** — les deux groupes comparés se recouvrent partiellement, ce qui viole l'hypothèse même de l'indépendance entre échantillons. Deux conséquences chiffrables : au niveau de la ligne, l'erreur type est sous-estimée d'un facteur de l'ordre de la racine de 1,52 ; et si l'on reformule la question au grain du ticket, en affectant chaque ticket à un seul vendeur (règle : le premier cité), le même écart donne 131 597 contre 114 934 FCFA, soit 16 663 FCFA, $t = 0,49$, $p = 0,624$, intervalle [-49 743 ; 83 069] FCFA sur 84 et 68 tickets. Le verdict change parce que la **question** a changé. Voilà pourquoi une comparaison sans grain explicite est une phrase sans sujet.
- **Le test hérite du biais.** M02.C07 a montré que notre extrait ne couvre que les jours 1 à 4 de chaque mois. Un intervalle et un p calculés dessus ne portent que sur ce périmètre-là : ils ne disent rien des fins de mois, et le test, lui, ne le signale pas. C'est à l'analyste de l'écrire.
- **Significatif n'est pas important.** Avec les 240 000 lignes du fichier complet, un écart de 500 FCFA serait « significatif » et ne changerait aucune décision. La grandeur qui décide est l'estimation elle-même et sa plage, jamais le p.
- **Un test ne choisit pas entre deux explications.** « Bationo vend plus gros » peut venir de son portefeuille clients, de sa catégorie de produits ou du calendrier (M02.C06) : le test constate un écart, il ne tranche pas entre cause et coïncidence de périmètre.

Besoin	Tableur	SQL (DuckDB)	pandas / SciPy
t de Welch sur deux groupes	=T.TEST(a;b;2;3) (le type 3 est la variante à variances inégales)	agrégats AVG / COUNT STDDEV_SAMP par groupe, puis calcul	stats.ttest_ind(a, b, equal_var=False)
Mann-Whitney	absent (macro)	nativement (extension ou export, Python)	stats.mannwhitneyu(a, b)

Besoin	Tableur	SQL (DuckDB)	pandas / SciPy
Chi² sur un tableau	=CHISQ.TEST(observés;attendus) (héritée : =TEST.KHIDEUX)	agrégation par GROUP BY, puis test en Python	stats.chi2_contingency(pd.crosstab(x, y))
Test d'une moyenne à une cible	=(moyenne-cible)/ (ECARTYPE.STANDARD(plage)/ RACINE(NB(plage))) puis seuil =LOI.STUDENT.INVERSE(0,05;ddl)	idem, puis comparaison à la loi de Student	stats.ttest_1samp(pan, 100000)
Deux proportions	formule en cinq cellules	COUNT(*) FILTER puis z à la main	statsmodels proportions_ztest
Puissance et effectif	table pré-calculée dans l'onglet hypothèses	—	statsmodels power.TTestIndPower

Boîte à outils. Le bloc de cinq lignes qui accompagne un test dans une note : (1) la question, avec son grain et son seuil, écrite avant ; (2) les effectifs par groupe (125 et 109 lignes, ou 84 et 68 tickets — et jamais les deux sans le dire) ; (3) l'estimation de l'écart avec son intervalle (28 609 FCFA, [-8 279 ; 65 498]) ; (4) le p avec le nom du test (0,13, t de Welch ; 0,0161, Mann-Whitney) ; (5) la marge de détection de l'étude (52 956 FCFA à 80 % de puissance). Ces cinq lignes rendent le résultat attaquant au bon endroit — sur les chiffres, pas sur l'interprétation.

6. Exemple concret : « qui met-on sur le tableau d'honneur ? »

La demande. La direction commerciale veut distinguer « le meilleur vendeur du magasin 5 » pour une prime, et propose de trancher sur le CA : Bationo 11 370 350 FCFA contre Ilboudo 6 796 535 FCFA sur l'extrait.

Ce que le dossier dit, test en main.

Question posée	Réponse mesurée	Ce que cela change à la décision
Le montant moyen par ligne diffère-t-il ?	28 609 FCFA, t = 1,52, p = 0,13	non établi
Et au grain du ticket ?	16 663 FCFA, p = 0,624	non établi, avec une plage énorme
Le profil complet est-il décalé ?	p = 0,0161 en Mann-Whitney, 0,0083 exigé après Bonferroni	décalage réel mais non confirmé au seuil corrigé
Le total est-il plus haut chez Bationo ?	oui — et 110 tickets contre 98, et une part de Bois & panneaux de 2,4 % contre 4,6 % (M02.C06)	le total reflète le portefeuille, pas la performance unitaire

La réponse écrite au comité. « Sur l'extrait, aucun écart de montant moyen entre vendeurs n'est établi au seuil de 5 %, sur aucun des six couples comparés, et les intervalles de confiance vont de -45 910 à +65 498 FCFA. Cette étude ne permet pas de classer les vendeurs : elle permet de dire qu'un écart inférieur à 52 956 FCFA par ligne passerait inaperçu. Pour une prime, nous recommandons un barème assis sur des critères que ces données établissent — tenue du fichier, respect des taux de remise, évolution du CA sur douze mois complets — et non sur une comparaison de moyenne non concluante. »

Ce que le décideur retient. Trois mots : classement non établi. Un rapport qui dit cela est plus utile qu'un rapport qui distribue des médailles au hasard — et il protège celui qui l'a écrit.

7. Démonstration pas à pas : de la question au verdict

Étape 1 — Écrire la question et le seuil. « Le montant moyen par ligne d'Adama Bationo diffère-t-il de celui de Moussa Ilboudo ? » Test bilatéral, $\alpha = 0,05$, grain = la ligne (à justifier), deux groupes. Le ticket de la demande porte cette phrase ; c'est elle qui rend le reste non négociable.

Étape 2 — Vérifier que le test est licite. Effectifs 125 et 109 lignes ✓ assez grands ; colonnes numériques ✓ ; indépendance : **non** — 84 tickets portent les deux vendeurs, à signaler explicitement. Un test licite n'est pas un test exact ; la mention de la violation vaut mieux que son silence.

Étape 3 — Calculer l'écart et son erreur type, à la main.

```
from scipy import stats
a = p.loc[p.vendeur == "Adama Bationo", "montant_ttc"].astype(float)
b = p.loc[p.vendeur == "Moussa Ilboudo", "montant_ttc"].astype(float)
d = a.mean() - b.mean()
se = ((a.var(ddof=1)/len(a)) + (b.var(ddof=1)/len(b)))**0.5
t = stats.ttest_ind(a, b, equal_var=False)
print(round(d), round(se), round(float(t.statistic), 2), round(float(t.pvalue), 3),
round(float(t.df), 1))
```

Contrôle croisé : `d / se` doit redonner `t` ($28\,609 / 18\,821 = 1,52$ ✓). Ce réflexe attrape les erreurs de virgule, de filtre et de colonne mieux que n'importe quel contrôle automatique.

Étape 4 — Publier l'intervalle de la différence. $28\,609 \pm 1,96$ fois $18\,821$, soit $[-8\,279 ; 65\,498]$ FCFA. Zéro est dedans, donc $p > 0,05$: les deux écritures sont cohérentes — et c'est une vérification en soi.

Étape 5 — Confronter par une méthode sans hypothèse de loi. Test par permutation : on mélange les 234 lignes des deux groupes, on les redistribue en 125 et 109, et on recompte l'écart, 10 000 fois (graine 20260917). La proportion de fois où le hasard dépasse 28 609 FCFA donne $p = 0,1443$, contre 0,13 annoncé par le t de Welch : même verdict, à un cheveu près. Le test paramétrique est donc utilisable ici — sur d'autres données, cet écart-là serait le signal d'alarme.

Étape 6 — Traduire en décision, et en condition de reprise. « Écart non établi. Pour trancher, il faudrait environ 412 lignes par vendeur, soit une année complète de chacun des deux — ou un indicateur moins dispersé que le montant par ligne. » Cette dernière phrase est celle qui relance le travail utile : changer d'indicateur coûte moins cher que changer d'effectif.

Contrôles qualité du chapitre.

#	Contrôle	Seuil	Résultat attendu	Si échec
1	<code>t</code> égal à écart / erreur type	identité	$28\,609 / 18\,821 = 1,52$	effectifs ou variances mal lus
2	Intervalle et p cohérents	zéro dans l'IC si $p > \alpha$	IC contient 0, $p = 0,13$	test unilatéral publié comme bilatéral
3	Permutation et <code>t</code> convergent	écart de $p < 0,03$	0,1443 contre 0,13	queues trop lourdes pour le <code>t</code>
4	Effectifs théoriques du χ^2	minimum ≥ 5	39,3	passer au test exact de Fisher
5	Nombre de comparaisons déclaré	explicite	6 comparaisons, seuil 0,0083	sélectivité non signalée
6	Grain du test écrit	unité unique	la ligne (109-125), ou le ticket (84-68)	deux grains mélangés dans la même note

8. Erreurs fréquentes

1. **Lire p comme « la probabilité que H0 soit vraie ».** $p = 0,13$ ne veut pas dire 13 % de chances que les vendeurs soient égaux ; cela veut dire que, s'ils ne différaient pas, un tel écart surgirait dans 13 cas sur 100.
2. **Conclure à l'égalité parce que $p > 0,05$.** Un test non concluant mesure une **impossibilité de conclure** ; notre intervalle court de -8 279 à +65 498 FCFA, ce qui n'a rien d'une égalité.
3. **Traiter 0,05 comme un juge.** Un p à 0,049 ne vaut pas mieux qu'un p à 0,051 ; la décision se prend sur la plage estimée, le coût de l'erreur et la solidité du dispositif, pas sur un cheveu.
4. **Choisir le test après avoir vu les résultats.** Welch donne 0,13, les rangs donnent 0,0161 : publier le second sans dire le premier est une faute professionnelle, pas une nuance technique.
5. **Multiplier les comparaisons sans le dire.** Six tests, 26,5 % de risque d'une fausse découverte : le seuil corrigé de Bonferroni (0,0083) n'est pas une coquetterie, c'est le prix de l'honnêteté sur six questions.
6. **Oublier les dépendances internes.** Comparer des lignes alors que 1,52 ligne forment un ticket et que 84 tickets sont partagés entre vendeurs : l'effet est un excès de confiance, jamais un défaut de prudence.
7. **Tester sans avoir nettoyé le périmètre.** Un test sur un échantillon dont le taux de couverture est faux (jours 1 à 4, M02.C07) produit un p impeccable sur un objet qui n'existe pas.

9. Bonnes pratiques professionnelles

1. **Une question, un test, un seuil, écrits avant.** Dans le ticket, pas en annexe du rapport.
2. **Toujours l'intervalle avec le p.** Le p décide, l'intervalle informe. Un sans l'autre est incomplet ; les deux ensemble sont vérifiables par un tiers.
3. **Publier la marge de détection.** « Nous ne voyons rien de plus petit que 52 956 FCFA par ligne » : cette ligne désarme la moitié des demandes d'analyse prématurées et rend service au commanditaire.
4. **Un test sans hypothèse en contrôle, pas en principal.** La permutation à 10 000 tirages (graine annoncée) vérifie le Welch en trente secondes de calcul ; c'est un contrôle qualité, pas une seconde conclusion.
5. **Corriger pour les comparaisons multiples, ou les étiqueter exploratoires.** Les deux sont acceptables ; le silence ne l'est pas.
6. **Refuser la décision fondée sur un test non concluant,** et le dire une fois, par écrit. Ce n'est pas au statisticien de décider du risque que l'entreprise accepte ; c'est à lui de dire ce que les données ne permettent pas.
7. **Archiver le script du test, avec la graine.** Un verdict contesté six mois plus tard doit être rejouable ligne par ligne ; sinon ce n'est pas un verdict, c'est une ambiance de réunion.

10. Exercice guidé — trancher une comparaison de vendeurs de bout en bout

Énoncé. Testez la différence de montant moyen par ligne entre Salamatou Sankara et Boureima Ouédraogo, publiez l'intervalle, et rédigez la phrase de décision au seuil de 5 %.

Vous faites — barème 10 points, total 10.

Étape	Ce que vous produisez	Points
A	Question, H0, H1, grain et seuil écrits avant calcul	2
B	Écart, erreur type, t, ddl, p — avec le contrôle écart / erreur type	2,5
C	Intervalle à 95 % de l'écart, et lecture de sa position par rapport à zéro	2,5
D	Vérification par permutation ou par test des rangs	1,5
E	Phrase de décision, incluant la marge de détection	1,5

Nous vérifions. Écart -1 729 FCFA (moyennes 73 619 et 71 890 FCFA) · intervalle [-36 947 ; 33 488] FCFA · $t = -0,10$ · $p = 0,923$ · Mann-Whitney $p = 0,9129$ · les deux tests, les deux intervalles, la même conclusion : rien.

Nous corrigeons. Le piège de cet exercice est son apparente facilité : avec un écart quasi nul, on serait tenté d'écrire « les deux vendeurs sont équivalents ». Non : « aucun écart n'est détecté, et l'étude ne verrait pas un écart inférieur à la marge de détection ». Équivalence est un mot qui exige un test d'équivalence avec une borne décidée avant la mesure — jamais un p élevé.

11. Exercices autonomes

Exercice 8.1 (★) — Les quatre phrases. Pour le test Bationo / Ilboudo au niveau ligne, rédigez H0, H1, le grain et le seuil en une ligne chacun, puis dites laquelle des six comparaisons a le plus petit p et ce que ce chiffre signifie (une phrase, pas de jargon).

Exercice 8.2 (★) — Le contrôle de cohérence. À partir de l'écart (28 609 FCFA) et de l'erreur type (18 821 FCFA), retrouvez t , puis vérifiez que l'intervalle publié contient bien zéro. Que doit donner le p par rapport à 0,05, et pourquoi cette vérification n'est pas un recyclage du même calcul ?

Exercice 8.3 (★★) — Effet du grain. Reprenez la comparaison au niveau des **tickets** en les affectant au premier vendeur du ticket. Écrivez les deux effectifs, l'écart, le p , l'intervalle, et expliquez en trois lignes pourquoi le p remonte alors même que l'écart estimé, lui, baisse.

Exercice 8.4 (★★) — Chi-deux et petite case. Testez l'association vendeur $\times$ catégorie de produits au lieu de vendeur $\times$ remise. Donnez le khi deux, les degrés de liberté, le p et le plus petit effectif théorique ; dites si l'approximation est licite et ce qu'on ferait sinon.

Exercice 8.5 (★★★) — Dessiner une étude qui conclut. La direction veut savoir si la remise accordée sur les gros tickets a un effet sur le montant du ticket. Vous disposez des douze mois de 2025 du magasin 5 (4 524 tickets). Rédigez le protocole : question, unité d'observation, variable d'intérêt, test, seuil, ce qui manque pour parler d'effet causal, et la taille d'échantillon nécessaire pour détecter un écart de 10 000 FCFA avec 80 % de puissance. (attendu : un test sur moyennes au grain du ticket, $\alpha = 0,05$, seuil de Bonferroni si plusieurs couples, l'absence de variation expérimentale de la remise comme limite majeure — cf. M02.C06 — et un effectif de plusieurs centaines de tickets par groupe)

12. Correction détaillée

Exercice 8.1. H0 : les montants moyens par ligne des deux vendeurs sont égaux. H1 : ils diffèrent (bilatéral). Grain : la ligne (125 lignes pour Bationo, 109 pour Ilboudo). Seuil : 5 %, fixé avant calcul. Le plus petit p des six comparaisons vaut 0,13, sur ce couple : si les vendeurs ne différaient en rien, un écart d'au moins 28 609 FCFA apparaîtrait dans environ 13 cas sur 100. Aucun classement n'est établi.

Exercice 8.2. 28 609 divisé par 18 821 redonne 1,52 ✓ ; l'intervalle [-8 279 ; 65 498] contient zéro ✓ ; le p doit donc dépasser 0,05, et il vaut 0,13 ✓. Ce n'est pas un recyclage du même cal-

cul : le premier contrôle vérifie l'arithmétique, le second la cohérence entre deux sorties qui ont pu être produites par deux feuilles différentes — et la plupart des erreurs de reporting statistique sont des erreurs de copie, pas de maths.

Exercice 8.3. Au grain du ticket avec affectation au premier vendeur : 84 et 68 tickets, moyennes 131 597 et 114 934 FCFA, écart 16 663 FCFA, $t = 0,49$, $p = 0,624$, intervalle [-49 743 ; 83 069] FCFA. Le verdict se détériore parce que l'effectif fond (234 lignes deviennent 152 tickets) et que la variabilité par ticket est beaucoup plus grande que par ligne — l'erreur type passe de 18 821 à 33 881 FCFA. L'écart absolu baisse, mais le flou augmente plus vite : un test se lit sur le rapport des deux, jamais sur l'un des deux seuls.

Exercice 8.4. Khi deux = 27,72 sur $(4 - 1) \times (7 - 1) = 18$ degrés de liberté, $p = 0,066$. Licéité : le plus petit effectif théorique vaut 5,45 et aucune des 28 cases n'est sous 5 — l'approximation tient, mais de justesse, parce que la catégorie Bois ne pèse que 24 lignes sur 480 (M02.C01) : au moindre découpage supplémentaire, il faudra agréger les petites catégories ou recourir à un test exact par permutation. Verdict : $p = 0,066$, donc rien de concluant à 5 % — et pourtant c'est le seul résultat du module à frôler le seuil, ce qui se note (« association limite entre vendeur et portefeuille de produits, à confirmer sur douze mois complets »). Le réflexe à retenir : ce n'est pas le p qui conditionne la validité du test, ce sont les effectifs théoriques.

Exercice 8.5. Protocole attendu. Question : le taux de remise fait-il varier le montant du ticket. Unité : le ticket (pas la ligne : la remise s'apprécie au ticket). Variable d'intérêt : montant total TTC du ticket. Test : comparaison de moyennes entre tickets avec remise et sans remise, t de Welch, bilatéral, $\alpha = 0,05$. Taille : pour un écart de 10 000 FCFA à 80 % de puissance avec une dispersion de l'ordre de celle des paniers (182 095 FCFA), il faut nettement plus de plusieurs centaines de tickets par groupe — l'ordre de grandeur sort de la formule $n \approx 2 \times (1,96 + 0,84)^2 \times \sigma^2 / \text{écart}^2$. Limite majeure, à écrire dans le protocole : la remise n'a pas été attribuée au hasard, 64,0 % des lignes n'en portent aucune et six taux seulement existent (M02.C06) — le meilleur résultat possible est une **association**, jamais un effet ; une vraie réponse demanderait une période de test avec deux groupes de clients tirés au sort. Le barème de qualité est ici de publier la plage de l'effet, pas l'étoile du p .

13. Mini-projet M02.P4 — « La page d'incertitude » (45 min, second volet)

Commande. Prolongez le volet ouvert en M02.C07 par le volet décision, sur la même page unique : vous devez rendre un verdict argumenté sur la question « les vendeurs du magasin 5 se distinguent-ils mesurablement ? », en traitant au moins deux comparaisons (une sur montants, une sur fréquences), avec leur intervalle, leur seuil corrigé si les comparaisons sont multiples, et la marge de détection de l'étude.

Livrables numérotés. (1) la ou les questions, avec H_0 , le grain et le seuil, datés d'avant calcul ; (2) le tableau des comparaisons : écart, intervalle, test employé, p ; (3) le test sans hypothèse de loi (permutation) sur la comparaison que vous jugez la plus sensible, avec nombre de tirages et graine ; (4) le paragraphe de décision : ce que la direction peut faire de ce verdict, et ce qu'elle ne peut pas en faire ; (5) la marge de détection, avec l'effectif qu'il aurait fallu.

Barème (20 points, seuil 13). Questions et seuil écrits avant (3) · tests correctement choisis et exécutés (5) · intervalles publiés et cohérents avec les p (4) · comparaisons multiples traitées (3) · marge de détection chiffrée (3) · décision rédigée sans abus de langage (2) — total 20. La note du projet M02.P4 est la moyenne de ce volet et du volet ouvert en M02.C07 ; le document final reste la somme des pages P1 à P4, pas leur remplacement.

14. Résumé du chapitre

1. Un test éprouve H_0 : écart observé contre ce que le hasard produit. Sur notre couple vedette, 28 609 FCFA d'écart pour une erreur type de 18 821 FCFA donne $t = 1,52$ et $p = 0,13$: non concluant.
2. L'intervalle de la différence est le vrai résultat : $[-8\,279 ; 65\,498]$ FCFA. Sur les six couples de vendeurs, aucun intervalle n'exclut zéro — le classement des vendeurs n'est pas établi par ce fichier.
3. Deux tests licites peuvent diverger parce qu'ils n'éprouvent pas la même hypothèse : rangs à 0,0161, moyennes à 0,13 ; on choisit d'après la décision visée, et on publie les deux.
4. Un test non concluant se lit avec sa puissance : 18,5 % de chances de voir un écart réel de 20 000 FCFA, et une marge de détection de 52 956 FCFA par ligne — ou 412 lignes par groupe pour faire mieux.
5. Les six comparaisons obligent à un seuil corrigé (0,0083), et le grain du test (ligne ou ticket, 84 tickets partagés) peut changer le verdict : ces deux disciplines sont le contenu réel du métier.

15. À retenir

À retenir.

- Le p répond à « ce chiffre est-il compatible avec l'absence de différence ? », jamais à « la différence existe-t-elle ? » ni « H_0 est-elle vraie ? ».
- Tout test se publie avec son intervalle, ses effectifs par groupe et son nom : 28 609 FCFA, $[-8\,279 ; 65\,498]$, 125 et 109 lignes, t de Welch.
- Non significatif $\neq$ nul. La force de l'étude se mesure à sa marge de détection (52 956 FCFA par ligne ici), pas à ses étoiles.
- Autant de comparaisons, autant de seuils corrigés : 0,05 sur six tests devient 0,0083.

À retenir. La formulation qui protège. « Les montants moyens par ligne des six couples de vendeurs ont été comparés par test t de Welch au seuil de 5 %, fixé avant calcul. Aucun écart n'est significatif avant comme après correction de Bonferroni ; le plus petit p obtenu vaut 0,13. Notre étude ne détecterait pas un écart inférieur à 52 956 FCFA par ligne : en conséquence, nous ne proposons aucun classement de vendeurs fondé sur ces données, et recommandons de raisonner sur douze mois complets avec un indicateur moins dispersé. »

16. Évaluation formative (auto-correction, 12 min)

1. Un p de 0,13 sur un écart de 28 609 FCFA : que dit-il, que ne dit-il pas ? **2.** Pourquoi publier l'intervalle de la différence en plus du p , alors que les deux portent la même information ? **3.** Mann-Whitney donne 0,0161 et Welch 0,13 sur les mêmes données. Quelle règle de conduite, et quel lien avec la forme de la distribution (M02.C05) ? **4.** Quelles deux violations des conditions d'emploi du test de Welch notre comparaison de lignes contient-elle ? **5.** Un directeur demande : « alors ils sont équivalents ? ». Répondez en trois phrases, dont un chiffre.

Corrigé

1. Il dit que, si les deux moyennes étaient égales, un écart au moins aussi grand que celui observé apparaîtrait dans environ 13 cas sur 100. Il ne dit pas la probabilité que les vendeurs soient égaux, ni la taille de la différence, ni que l'étude est bien conduite : un p est muet sur le dispositif. **2.** Parce que le p ne s'adresse qu'à la question « différent de zéro ? », alors que l'intervalle répond à la question de gestion « de combien, au pire ? ». $[-8\,279 ; 65\,498]$ FCFA interdit toute décision de prime, ce que « $p = 0,13$ » ne dit pas explicitement. **3.** Publier les deux, en expliquant

lequel porte la décision : le test des rangs éprouve un décalage d'ensemble du profil (médiane 47 849 contre 32 426 FCFA), celui des moyennes éprouve l'écart de chiffres d'affaires — et la moyenne, sur une distribution à queue épaisse, a une erreur type énorme. C'est la leçon de M02.C05 appliquée à la décision : la forme de la distribution commande la stabilité de l'estimateur. 4. La non-indépendance des lignes au sein des tickets (1,52 ligne par ticket) et le recouvrement des deux groupes (84 tickets portant plusieurs vendeurs à la fois, donc comparés à eux-mêmes en partie). 5. « Non. Nous n'avons trouvé aucune différence mesurable, ce qui est autre chose. Notre étude ne verrait pas un écart inférieur à 52 956 FCFA par ligne, et l'intervalle obtenu laisse tout aller de -8 279 à +65 498 FCFA. Pour parler d'équivalence, il faudrait avoir écrit à l'avance une borne — par exemple “ équivalents si l'écart reste sous 10 000 FCFA ” — et la vérifier ; c'est un test d'équivalence, pas celui que nous avons conduit. »

Projet M02.P — « Profil statistique du magasin 5 »

Module M02 · projet de fin de module · 6 h · à rendre avant le module 3 · barème /20, seuil de passage 13/20

Le cadre réel. Vous êtes toujours chez Sahel Distribution SA. Le directeur a maintenant une phrase pour vous : « je ne veux pas votre moyenne, je veux la vérité du magasin ». Derrière cette phrase maladroite se trouve exactement le travail du module 2 : dire ce que vaut chaque indicateur, comment il a été calculé, ce qu'il dit, ce qu'il ne dit pas, et ce que l'extrait permet ou non d'affirmer. Vous rendez six pages, pas une.

Note de cohérence. Le plan validé annonçait « Profil statistique de la Boutique Kwame, 1 500 ventes ». Le socle de données réel de la formation fournit un autre volume — 480 lignes et 316 tickets une fois nettoyés, pour le magasin 5 sur 2025 — et c'est sur lui que portent les livrables, afin que chaque chiffre du corrigé soit vérifiable. Le livrable, le barème et les exigences de preuve sont inchangés.

1. Énoncé

Le matériel

Élément	Chemin	Ce que c'est
Fichier de travail	01_socle_donnees/data/reference/ventes_magasin5_2025_ATTENDU.csv	le fichier nettoyé au projet M01 : 480 lignes x 13 variables, 316 tickets
Population de référence	01_socle_donnees/data/reference/ventes_propres.csv	toutes les ventes propres, 240 000 lignes ; le magasin 5 sur 2025 y tient 7 676 lignes et 4 524 tickets
Contrôle des chiffres	01_socle_donnees/data/reference/chiffres_cites.md	à utiliser après chaque calcul, pour vérifier — pas pour remplir
Outils	tableur (Excel ou LibreOffice) + Python si vous l'avez	le tableur est obligatoire au moins une fois, Python sert de contrôle

Les six livrables

L1 — Page d'identité statistique (1 page). Population visée, unité sondée, effectifs (480 lignes, 316 tickets, 7 676 lignes et 4 524 tickets en face), taux de représentation, règle d'extraction reconstituée, liste des variables par nature (quantitatives discrètes / continues / nominales / ordinales), et les trois questions du module auxquelles le fichier peut répondre. Une ligne par rubrique, aucune phrase de remplissage.

L2 — Page des centres et de la dispersion (1 page, prolongement de M02.P1 et M02.P2). Cinq indicateurs, chacun au format valeur · calcul · ce que ça dit · ce que ça ne dit pas : moyenne, médiane, mode, écart type, écart interquartiles. Vous ajoutez le coefficient de variation et vous expliquez ce qu'il fait saliver.

L3 — Page des positions et de la forme (1 page). Premier et troisième quartiles, trois percentiles choisis parmi dix, quatre-vingts, quatre-vingt-quinze ; bornes de Tukey et nombre d'observations hors borne ; histogramme commenté (classes, effectifs par classe, part du chiffre d'affaires par classe) ; asymétrie et excursion des valeurs.

L4 — Page des liaisons (1 page). Trois liaisons au choix, chacune avec covariance ou coefficient, effectif, grain, carré du coefficient, droite de régression si elle a un sens, et une ligne « ce que la liaison ne dit pas ». Vous menez en plus **un** contrôle de confusion et vous donnez les deux chiffres, avant et après.

L5 — Page d'incertitude et de décision (1 page). Intervalle à 95 % du panier moyen et de la médiane, biais de l'extrait chiffré, un test de comparaison entre deux vendeurs conduit **au tableur puis vérifié en Python**, le même test entre le magasin 1 et le magasin 5 sur l'année 2025, et la marge de détection de votre étude. Un paragraphe de décision, une phrase de prudence.

L6 — Anomalies et conclusion (1 page). **Trois anomalies chiffrées** au choix (doublons, quantités hors échelle, dates manuscrites, clients non renseignés, retours négatifs, tickets aberrants), chacune en quatre lignes : ce qui est observé, combien, ce que ça change au chiffre, ce qui a été fait. Puis la **conclusion en cinq lignes**, qui dit ce que l'entreprise peut décider avec ce profil, et ce qu'elle ne peut pas.

Contraintes de rendu

1. Un seul document PDF de six pages, nommé `2026-MM-JJ_projet_M02_P_votre_nom.pdf`, plus le classeur de travail et, si vous en avez utilisé, les scripts.
2. Chaque page porte en pied de page : l'effectif utilisé, le grain, le nom du fichier et la date de lecture.
3. Tout nombre affiché doit être accompagné de son moyen de preuve à portée de main : capture de la formule, ligne de commande, ou extrait du script. Un chiffre sans méthode est compté comme faux, même juste.
4. Précision : montants en entiers de FCFA, coefficients à trois décimales, pourcentages à une décimale. Aucun arrondi « de présentation » non signalé.
5. Les comparaisons multiples (plus de deux groupes) doivent annoncer le nombre de tests et le seuil employé.
6. **Interdits** : recopier une valeur depuis `chiffres_cites.md` sans le calcul correspondant ; mélanger dans une même page un total au niveau ligne et un total au niveau ticket sans écrire lequel est lequel ; publier un test sans son intervalle ; conclure à l'absence de différence sur un p supérieur au seuil.

2. Barème détaillé

#	Critère	Pts	Ce qui fait perdre les points
1	L1 : identité statistique exacte, règle d'extraction reconstituée	3	taux de représentation absent ; unité sondée confondue avec le nombre de lignes
2	L2 : cinq indicateurs justes, avec le « ce que ça ne dit pas »	3	mode unique annoncé alors qu'il y en a deux ; moyenne seule présentée comme « le panier type »
3	L3 : positions et forme, histogramme commenté	4	classes fermées qui avalent les retours négatifs ; bornes de Tukey calculées sur le mauvais effectif
4	L4 : liaisons chiffrées et contrôle de confusion mené	3	R^2 publié sans r , ou sans l'effectif ; pente extrapolée hors domaine
5	L5 : intervalles, tests exécutés aux deux outils, marge de détection	4	test exécuté sans grain déclaré ; p lu comme probabilité que H_0 soit vraie ; bootstrap sans graine
6	L6 : trois anomalies chiffrées, conclusion honnête, journal	3	anomalie racontée et pas comptée ; conclusion qui généralise au-delà du périmètre
Total		20	seuil de passage en M03 : 13

3. Correction pas à pas (corrigé enseignant)

Ce corrigé est rédigé comme un compte-rendu de travail. Les valeurs sont celles produites par les fichiers livrés du socle ; si votre fichier diffère, régénérez-le (python3 01_socle_donnees/scripts/generation_socle.py) avant de vous comparer.

3.1 — L1 : l'identité statistique, telle qu'elle doit être rendue

Rubrique	Réponse attendue
Population visée	les tickets du magasin 5 sur l'année 2025 : 4 524 tickets, 7 676 lignes
Échantillon réellement utilisé	316 tickets, 480 lignes — soit 7,0 % des tickets et 6,3 % des lignes
Règle d'extraction	les 40 premières lignes de chaque mois, triées par date : les jours 1 à 4 seulement
Unité sondée à retenir	le ticket pour toute question de clientèle, la ligne pour toute question de produit
Variables quantitatives	quantite (discrète), prix_unitaire_ht, remise, montant_ht, montant_ttc (continues au sens du métier : montants entiers en FCFA)
Variables nominales	magasin, vendeur, produit, categorie ; client est un identifiant, pas une quantité
Questions ouvertes au fichier	panier moyen et sa dispersion, structure par catégorie, liaisons quantité-montant, comparaison de vendeurs
Question fermée	la marge nette, la satisfaction client, l'effet d'une promotion : aucune de ces trois n'est répondable ici

Le correcteur vérifie en priorité la troisième ligne : un candidat qui écrit « 480 lignes prises au hasard » a perdu le fil du module, un candidat qui écrit « les 40 premières lignes de chaque mois » a compris M02.C07.

3.2 — L2 : centres et dispersion

Indicateur	Valeur	Calcul	Ce que ça dit	Ce que ça ne dit pas
Moyenne panier	du 114 FCFA	156 somme de 36 073 185 FCFA sur 316 tickets	la masse d'affaires par ticket	71,8 % des tickets sont sous cette valeur
Médiane	58 FCFA	423 =MEDIANE() sur les 316 totaux	la moitié des tickets est en dessous	ce que font les 25 plus gros tickets
Modes	6 797 et 8 260 FCFA	valeurs les plus fréquentes, deux ex-æquo	deux tailles de ticket reviennent souvent	rien sur les gros paniers, qui sont justement l'enjeu
Écart type	182 FCFA	095 =ECARTYPE.STANDARD()	la dispersion est supérieure à la moyenne	la dispersion est tirée par la queue de droite
Écart interquartiles	109 FCFA	924 130 559 moins 20 635	la moitié centrale s'étale sur cette plage	le chiffre d'affaires total
Coefficient de variation	de 159,5 %	écart type sur moyenne	aucune moyenne ne représente ce fichier à elle seule	—

Phrase à exiger en pied de page : « le ratio moyenne sur médiane vaut 1,95 : la moyenne est à peu près le double de la médiane, ce qui signe une distribution étirée à droite, pas une augmentation générale des paniers ».

3.3 — L3 : positions et forme

Premier quartile 20 635 FCFA, troisième 130 559 FCFA, P10 = 7 390, P80 = 165 177, P90 = 235 318, P95 = 435 984 FCFA ; minimum -150 804, maximum 1 343 666, étendue 1 494 470 FCFA.

Bornes de Tukey : borne supérieure $130\,559 + 1,5 \times 109\,924$, soit 295 445 FCFA, avec 25 tickets au-delà.

L'histogramme attendu compte **sept** classes, la première et la dernière ouvertes, avec 3, 133, 84, 25, 23, 17 et 31 tickets. Deux pièges de fabrication, à commenter :

1. borné à 150 000 FCFA, l'histogramme écrase la moitié du chiffre d'affaires dans la dernière classe ; six classes fermées font disparaître les trois tickets négatifs, qui sont pourtant la preuve qu'il y a des retours ;
2. la classe 0 à 50 000 FCFA pèse 42,1 % des effectifs et 7,3 % du chiffre d'affaires : les deux lectures doivent apparaître, sinon le graphique raconte « un magasin de petits clients » alors que le dernier décile porte 47,5 % du chiffre d'affaires.

Asymétrie 3,84, excès de kurtosis 18,25, 307 valeurs de panier distinctes sur 316 : le vocabulaire à vérifier dans la copie est celui-là, et le mot « normale » n'y a pas sa place.

3.4 — L4 : liaisons

Le couple attendu, parce qu'il est instructif sans être trivial : `quantite` et `montant_ttc` au niveau ligne. Covariance 857 634, coefficient de Pearson 0,712, Spearman 0,641, R^2 50,7 %, pente 12 237 FCFA par pièce, ordonnée à l'origine -10 402 FCFA. Contrôle exigé : la droite au point moyen rend 75 257 FCFA contre 75 152 FCFA observés — l'écart est un arrondi d'affichage, et le candidat qui écrit ce contrôle gagne le point de méthode.

Le contrôle de confusion attendu : l'écart de panier moyen entre le premier et le dernier vendeur vaut 34 014 FCFA toutes catégories confondues ; recompté à catégorie contenue, il remonte à 57 346 FCFA en moyenne (17 433 FCFA au moins en Quincaillerie, 173 167 FCFA au plus en Electricité). La phrase de conclusion juste est : « à catégorie de produits égale, les écarts entre vendeurs ne se résorbent pas — ils s'agrandissent. Le portefeuille de produits n'explique donc pas le classement, et il ne l'innocente pas non plus. »

3.5 — L5 : incertitude, tests, décision

Objet	Valeur attendue	Vérification demandée
Intervalle à 95 % du panier moyen	[94 078 ; 134 234] FCFA, largeur 40 156	erreur type 10 244 FCFA retrouvée par $182\,095$ sur racine de 316
Biais de l'extrait	-2,3 % sur la moyenne, -14,3 % sur la médiane	médiane des jours 1 à 4 dans la population : 58 424 FCFA
Bootstrap de la médiane	[52 318 ; 64 632] FCFA	2 000 tirages, graine 20260917
Valeur de population du panier moyen	116 886 FCFA	elle est bien dans l'intervalle : la couverture est vérifiée
Comparaison Bationo / Ilboudo, au niveau ligne	écart 28 609 FCFA, $t = 1,52$, $p = 0,13$, IC [-8 279 ; 65 498]	tableur <code>=T.TEST(tab1;tab2;2;3)</code> puis <code>scipy.stats.ttest_ind(..., equal_var=False)</code>
Contrôle par permutation	$p = 0,1443$	10 000 redistributions, graine annoncée
Test des rangs sur le même couple	$p = 0,0161$	publié avec la mention du seuil corrigé 0,0083 : non concluant après correction
Comparaison magasin 1 / magasin 5, sur 2025 au grain du ticket	écart -8 997 FCFA, $t = -3,37$, ddl 6 782,8, $p = 0,000751$, IC [-14 226 ; -3 767]	14 463 tickets contre 4 524 ; moyennes 107 889 et 116 886 FCFA
Marge de détection de l'étude vendeurs	52 956 FCFA par ligne à 80 % de puissance	412 lignes par groupe auraient été nécessaires

Les deux derniers blocs sont le cœur du livrable : le premier montre un **écart établi** (intervalle excluant zéro, avec 14 463 et 4 524 tickets), le second montre que le même dispositif, ramené à 125 et 109 lignes, ne voit rien de stable. Le correcteur attend la phrase qui relie les deux : « la

différence entre magasins est mesurable, la différence entre vendeurs non, et la raison est l'effectif, pas la volonté ».

Une exécution au tableur doit laisser voir : la colonne des totaux par ticket (`=SOMME.SI()`), les quatre cellules `MOYENNE`, `NB`, `ECARTYPE.STANDARD`, puis la formule de l'erreur type et la marge. Un candidat qui rend uniquement le `p` Python perd le point de méthode demandé.

3.6 — L6 : les trois anomalies, écrites comme attendu

1. **Neuf lignes en double** dans le fichier reçu : $36\,339\,317 - 36\,073\,185 = 266\,132$ FCFA comptés en trop, soit $+0,74\%$ de chiffre d'affaires si on ne les retire pas. Elles ont été retirées au projet M01 et ne réapparaissent nulle part dans ce livrable.
2. **Sept quantités hors échelle** : maximum 14 000 pièces dans le fichier reçu, 68 une fois l'unité corrigée. Sans correction, la quantité moyenne serait faussée d'un facteur qui déforme la pente de la droite quantité-montant.
3. **Cent trois lignes sans client exploitable** (dont 18 sans identifiant renseigné), soit $21,5\%$ de l'effectif : toute statistique de clientèle est donc calculée sur un périmètre de fait, et le taux est à rappeler à chaque fois — c'est le seul des trois défauts qui ne se répare pas en nettoyant.

Conclusion en cinq lignes, modèle : le magasin 5 sur 2025, dans l'extrait disponible, fait un panier moyen de 114 156 FCFA, intervalle [94 078 ; 134 234], et un demi-ticket type à 58 423 FCFA. La masse d'affaires est concentrée : le dernier décile porte $47,5\%$ du chiffre d'affaires. Aucun classement de vendeurs n'est établi par ces données, et l'extrait sous-estime la médiane annuelle de $14,3\%$ du fait de sa couverture en jours. La liaison quantité-montant est forte (0,712) mais explique la moitié du phénomène, pas l'autre. Nous recommandons un recalcul sur les douze mois complets avant toute décision d'assortiment.

4. Grille d'auto-évaluation avant rendu

Répondez par oui ou non ; trois « non » = ne rendez pas, reprenez la page concernée.

#	Question	Si non
1	Chaque page indique-t-elle effectif, grain, fichier et date de lecture ?	pied de page manquant, point perdu
2	Ai-je écrit la règle d'extraction et son effet chiffré (médiane -14,3 %) ?	reprendre M02.C07 §5.3
3	Moyenne et médiane sont-elles données ensemble, avec le ratio commenté ?	reprendre M02.C02
4	L'histogramme a-t-il sept classes, les deux extrêmes ouvertes ?	reprendre M02.C05 §5.2
5	Ai-je distingué effectif et chiffre d'affaires par classe ?	reprendre M02.C05 §5.4
6	Chaque coefficient publié porte-t-il son effectif, son grain et son carré ?	reprendre M02.C06 §9
7	Le contrôle de confusion est-il chiffré avant/après ?	reprendre M02.C06 §5.6
8	Chaque intervalle est-il accompagné de son erreur type et du nombre de tirages quand il vient d'un bootstrap ?	reprendre M02.C07 §5.5-5.6
9	Chaque test annonce-t-il sa question, son grain, son seuil et le nombre de comparaisons ?	reprendre M02.C08 §5.1-5.2
10	Ai-je écrit « non établi » là où j'ai été tenté d'écrire « identique » ?	reprendre M02.C08 §5.3
11	Les trois anomalies sont-elles comptées, pas racontées ?	reprendre M01 (doublons) et M02.C01
12	Un tiers peut-il rejouer mes calculs sans moi (scripts, formules, graine) ?	joindre le classeur et les scripts

5. Ce que le correcteur regardera en premier

1. **Le pied de page de la page 2.** Effectif, grain, fichier : trois indications qui, si elles manquent, décrètent que le module n'a pas été travaillé mais lu.
2. **La présence de deux chiffres là où un seul suffirait.** Moyenne et médiane, r et R^2 , p et intervalle, écart avant et après contrôle : le module 2 se joue là, pas dans la justesse arithmétique.
3. **La mention du biais de couverture.** Une seule page, même mal mise en forme, qui écrit « jours 1 à 4 » et « -14,3 % » vaut plus que six pages impeccables qui l'ignorent.
4. **La discipline sur les comparaisons.** Six comparaisons annoncées comme telles avec un seuil corrigé, c'est un comportement professionnel, pas une coquetterie technique.
5. **La conclusion.** Cinq lignes qui disent ce que l'on peut décider — et ce que l'on ne peut pas — sont la vraie livraison du module. Une conclusion qui promet une action non fondée sur les pages précédentes fait perdre le point entier.

Évaluation M02 — « Statistiques descriptives et inférence »

Module M02 · durée totale 2 h 45 · quatre épreuves · seuils : quiz 14/20, étude de cas 12/20, projet 13/20

Épreuve	Durée	Barème	Noté	Ce qui est attendu
A · Questions de récupération	15 min	non noté	non	remettre à plat ce qui a été compris en cours de module
B · Quiz	35 min	/20	oui	vingt questions à réponse courte, une seule bonne réponse
C · Exercices pratiques	55 min	/20 (auto-corrigé)	oui	deux séries menées jusqu'au chiffre, tableur ou Python
D · Étude de cas	60 min	/20, seuil 12	oui	un dossier de quatre pages, chiffré et prudent

Le score du module se lit ainsi : **B ≥ 14** et **D ≥ 12** ouvrent le module 3 ; le projet M02.P doit atteindre 13. Un candidat qui réussit B et échoue à D repasse uniquement D — l'écrit de connaissances ne remplace pas le travail sur les données.

A · Questions de récupération (non notées)

À traiter à l'oral ou par écrit, sans document. Elles ne sont pas comptées ; elles servent à repérer ce qui n'est pas assimilé avant de se tromper dans les épreuves notées.

1. Pourquoi la moyenne d'une distribution de paniers peut-elle être juste et inutilisable ?
2. Quelle différence de sens y a-t-il entre 150 000 FCFA « au 70^e percentile » et « le 70^e plus gros ticket » ?
3. Que devient un histogramme si la dernière classe est fermée à 150 000 alors que le maximum vaut 1 343 666 ?
4. Pourquoi dit-on d'un intervalle de confiance qu'il porte sur le paramètre et non sur les observations ?
5. Un p-valeur de 0,13 permet-il d'affirmer que deux vendeurs font le même chiffre ? Répondez en une phrase.
6. Pourquoi compare-t-on des moyennes de prix **par ligne** et non des chiffres d'affaires par vendeur ?
7. Qu'ajoute un test des rangs quand le test de Welch conclut déjà ?
8. Un échantillon de 385 personnes suffit pour une marge de 5 points. Un échantillon de 480 lignes donne-t-il une marge de 5 points sur un montant ? Expliquez.

B · Quiz (20 questions · 20 points)

Barème : 1 point par question, aucune soustraction de point pour une erreur de signe ou d'unité. Les réponses justifiées en une ligne peuvent rapporter un demi-point de bonus, plafonné à 20.

Bloc 1 — Population, échantillon, biais (Q1 à Q5)

Q1. Un fichier contient 480 lignes issues des 40 premières lignes de chaque mois. On veut estimer le panier moyen annuel. Ce que mesure avant tout le taux de 6,3 % : a) la variance · b) la représentativité · c) le taux de remplissage · d) la précision

Q2. Le même échantillon ne contient que les jours 1 à 4 de chaque mois. On peut dire sans mesurer que la moyenne : a) est biaisée de 2 % · b) est biaisée vers le bas · c) est non représentative · d) est biaisée de 14 %

Q3. Trois modalités possibles pour le champ magasin alors qu'il y a cinq magasins. Le risque principal : a) une clé orpheline · b) une valeur manquante · c) un type de donnée · d) une normalisation

Q4. Un champ de montants est vide sur 18 lignes, absent sur 103. La première décision statistique : a) compléter par zéro · b) compléter par la moyenne · c) dire sur quelle population porte chaque chiffre · d) supprimer les 103 lignes

Q5. L'unité d'échantillonnage d'une étude de clientèle doit être : a) la ligne de vente · b) le ticket · c) le jour · d) le client

Bloc 2 — Centres (Q6 à Q8)

Q6. Sur un échantillon de 316 paniers, le plus gros vaut 1 343 666 FCFA. Passer de 316 à 315 paniers en retirant ce maximum déplace surtout : a) la médiane · b) le mode · c) la moyenne · d) l'écart interquartiles

Q7. Deux valeurs également fréquentes, deux modes donc, séparées de 1 463 FCFA. Le mode est ici : a) inutilisable · b) une valeur de prix unitaire, pas de panier · c) un signal de palier tarifaire · d) une erreur de saisie

Q8. Moyenne 114 156, médiane 58 423 FCFA. Le chiffre qui dit « un client sur deux est en dessous » : a) la moyenne · b) la médiane · c) le mode · d) le 75^e percentile

Bloc 3 — Dispersion et positions (Q9 à Q12)

Q9. Écart type 182 095 pour une moyenne de 114 156 FCFA. Le coefficient de variation vaut environ 159,5 % et signale : a) des données fausses · b) une dispersion supérieure à la moyenne, moyenne peu représentative · c) une erreur d'unité · d) une distribution normale

Q10. Premier quartile 20 635 FCFA, troisième 130 559 FCFA. La borne supérieure de Tukey vaut : a) $130\,559 + 1,5 \times 109\,924$ · b) $1,5 \times 130\,559$ · c) $Q3 + 1,5 \times Q1$ · d) $Q3 + 3 \times IQR$

Q11. Sur 316 tickets, 158 sont entre les quartiles — et non 158 comme l'annoncent 50 % des observations. L'écart de 2 s'explique par : a) une erreur de calcul · b) la convention de quantile, qui peut placer une valeur exactement sur un quartile · c) 2 aberrants · d) un arrondi de l'écart type

Q12. Le 90^e percentile du montant par ligne vaut 234 518, 235 318, 236 118 ou 243 010 FCFA selon la méthode. La bonne conduite : a) publier la plus grande · b) publier celle du tableur · c) publier l'une et nommer la méthode · d) publier la moyenne des quatre

Bloc 4 — Formes et liaisons (Q13 à Q16)

Q13. Asymétrie 3,84, excès de kurtosis 18,25. Le couple de qualificatifs exact : a) symétrique pointue · b) à droite et pointue · c) à gauche et plate · d) normale et étroite

Q14. Le chiffre d'affaires est concentré : le dernier décile porte 47,5 % du total, et 1,6 % seulement est sous le premier quartile. La première page du rapport devrait montrer : a) un camembert par catégorie · b) une courbe cumulative · c) un nuage de points · d) un effectif par vendeur

Q15. La covariance entre `quantite` et `montant_ttc` vaut 857 634, en unités « pièces × FCFA ». Comment passe-t-on de là au coefficient de Pearson ? a) on divise la covariance par le produit des deux écarts types · b) on multiplie la covariance par les deux écarts types · c) on élève 0,712 au carré · d) on divise la covariance par l'écart interquartiles

Q16. Pente 12 237 FCFA par pièce, ordonnée -10 402 FCFA, coefficient 0,712. L'affirmation recevable : a) doubler la quantité double le montant · b) une pièce supplémentaire accompagne en moyenne 12 237 FCFA de plus sur la ligne · c) 50,7 % du montant vient de la quantité, le reste est faux · d) la relation est causale

Bloc 5 — Estimation et tests (Q17 à Q20)

Q17. Un intervalle [94 078 ; 134 234] FCFA sur le panier moyen. Le nombre 40 156 est : a) l'erreur type · b) la marge d'erreur · c) la largeur de l'intervalle · d) la variance

Q18. Test de Welch entre deux vendeurs : $t = 1,52$, ddl 226,1, $p = 0,13$, IC [-8 279 ; 65 498]. La conclusion écrite dans le rapport : a) les vendeurs sont équivalents · b) l'écart est de 28 609 FCFA · c) aucun écart stable n'est établi sur cet extrait · d) le vendeur le plus performant est Bationo

Q19. Six comparaisons de paires sont menées, la plus petite p-valeur vaut 0,13, le seuil après correction 0,0083. On conclut : a) une comparaison est significative · b) aucune n'est significative au seuil corrigé, et l'étude manque de puissance · c) il faut publier la plus petite p · d) il faut augmenter alpha

Q20. Marge de détection de 52 956 FCFA par ligne à 80 % de puissance. Le même test au niveau ticket donne une erreur type de 33 881 contre 18 821 : la raison est : a) une erreur de formule · b) le passage de 234 à 107 observations, et le mélange de plusieurs vendeurs sur 84 tickets · c) des queues trop lourdes · d) un seuil mal choisi

C · Exercices pratiques (2 séries · 55 min · auto-correction exigée)

Règles : une feuille de calcul ou un script par série ; tous les nombres doivent être retrouvables par une formule ou une ligne de commande ; les arrondis sont affichés en fin de chaîne. Les corrigés de la partie C sont donnés à la fin du document — l'auto-correction fait partie de l'épreuve, un candidat qui ne se corrige pas perd le point de méthode.

E1 · Profil du magasin (30 min) 1. E1.1 — effectif de lignes, effectif de tickets, moyenne et médiane du montant TTC par ligne, écart type. 2. E1.2 — trois premières et trois dernières lignes triées par `montant_ttc`, par ticket : le chiffre d'affaires est-il porté par les gros tickets ? Donnez le pourcentage du total détenu par les 32 plus gros tickets. 3. E1.3 — Q1, Q3, IQR, borne supérieure de Tukey, nombre d'observations hors borne, et ce que devient cette borne si l'on exclut les retours négatifs.

E2 · Estimer et décider (25 min) 1. E2.1 — intervalle à 95 % de la part de lignes avec remise dans l'échantillon (173 lignes sur 480), puis comparaison à la part observée dans la population de référence si vous y avez accès. 2. E2.2 — comparer le montant par ligne des deux vendeurs les plus fournis, au tableur **puis** en Python : moyenne, écart type, effectif, t, ddl, p, intervalle à 95 % de l'écart. 3. E2.3 — même comparaison par les rangs, puis par permutation (10 000 tirages, graine annoncée). Vous rédigez les trois p-valeurs et une phrase de décision unique. 4. E2.4 — avec 30 % de remise sur les 316 tickets, combien de tickets faudrait-il dans chaque groupe pour mettre en évidence un écart de 28 609 FCFA ?

D · Étude de cas (20 points · seuil 12 · 60 min)

Le dossier

Vous recevez un courriel du directeur commercial :

« Bationo fait des paniers plus gros qu'Ilboudo : 90 963 contre 62 354 FCFA par ligne. C'est 46 % d'écart. Je veux deux choses : la preuve chiffrée, et si tu ne la trouves pas, dis-moi franchement que ces chiffres ne veulent rien dire. Et pendant que tu y es, est-ce que le magasin 5 vend plus cher que le magasin 1 ? »

Vous disposez de : l'extrait nettoyé de 480 lignes (316 tickets), le fichier de référence de 240 000 lignes, la table `dim_date`, un tableur, Python si vous le souhaitez, et une demi-heure de calcul.

Les quatre livrables demandés

1. **La preuve, ou son absence, sur les vendeurs** (6 pts) — au niveau ligne et au niveau ticket, avec les deux échantillons, l'écart estimé, l'intervalle, le test, le seuil corrigé si vous comparez plusieurs paires, et la marge de détection.
2. **La réponse sur les deux magasins** (6 pts) — périmètre et grain annoncés, les deux moyennes, les deux effectifs, l'écart, l'intervalle, le p, la décision.
3. **Une recommandation datée** (4 pts) — trois lignes maximum, qui ne dépasse pas ce que les pages précédentes établissent ; par exemple un plan de mesure (recalcul sur douze mois, effet de la couverture en jours, ce qu'il faudrait collecter).
4. **Un encadré « ce qui aurait changé ma réponse »** (4 pts) — trois contre-vérifications que vous auriez aimées et qui sont impossibles avec ces données (le client, le stock, la marge nette).

Ce que le correcteur attend, ligne à ligne

Livable	Attendu	Point perdu si
1	écart 28 609 FCFA, $t = 1,52$, $p = 0,13$, IC [-8 279 ; 65 498], seuil corrigé 0,0083, MDE 52 956 ; version ticket écart 16 663 FCFA, $p = 0,624$	le mot « équivalents » apparaît ; le grain n'est pas annoncé
2	magasins 1 et 5 sur 2025 au grain du ticket : 107 889 (14 463) et 116 886 FCFA (4 524), écart -8 997, $t = -3,37$, $p = 0,000751$, IC [-14 226 ; -3 767] → écart établi	le candidat compare des lignes sans le dire, ou omet les effectifs
3	décision de mesurer avant de gérer : pas de mutation, pas de prime sur cette base ; recalcul sur douze mois	la recommandation dépasse les chiffres
4	trois limites nommées, avec ce qu'il faudrait comme donnée pour chacune	limites rédigées en « il faudrait plus de données »

Total : 20 points. Seuil de passage : 12.

Corrigé

B · Quiz — réponses et explications

#	Réponse	Explication en une ligne
Q1	b	le taux de 6,3 % est un taux de couverture : il mesure l'exposition à un biais, pas une variance

#	Réponse	Explication en une ligne
Q2	c	le sens et l'amplitude du biais ne se devinent pas, ils se mesurent ; seul le caractère non représentatif est certain
Q3	b	trois modalités sur cinq magasins : deux magasins sont absents du fichier, ce qui change le périmètre de la réponse
Q4	c	avant de combler ou de supprimer, on écrit sur quoi porte chaque chiffre
Q5	b	un client, un ticket : si l'unité est la ligne, les gros tickets comptent double
Q6	c	la moyenne déplace tout le poids de l'observation extrême, la médiane presque rien
Q7	c	deux modes serrés sur un champ de prix signalent un palier tarifaire, pas une erreur
Q8	b	définition de la médiane ; 71,8 % des tickets sont sous la moyenne, ce que la moyenne ne dit pas
Q9	b	un CV de 159,5 % est un signal de dispersion, pas une faute de calcul
Q10	a	$Q3 + 1,5 \times IQR : 130\,559 + 1,5 \times 109\,924$, soit 295 445 FCFA
Q11	b	166 observations exactement à Q1, la frontière dépend de la convention retenue
Q12	c	les méthodes diffèrent de 3,6 % sur cet extrait : on publie une valeur et on nomme la règle
Q13	b	asymétrie positive et excursion marquée, jamais « normale »
Q14	b	la concentration est une affaire de cumul ; le camembert ne la montre pas
Q15	a	covariance sur produit des deux écarts types — c'est ce qui rend le nombre comparable d'un fichier à l'autre ; le carré du coefficient, $0,712^2$, est le R^2
Q16	b	lecture de la pente, dans le domaine observé, sans causalité
Q17	c	40 156 est la largeur ; la marge est la moitié, 20 078 FCFA
Q18	c	un intervalle qui contient zéro n'établit rien ; il n'innocente pas non plus
Q19	b	$0,13 > 0,0083$: aucune comparaison ne passe, et la puissance était faible avant même de commencer
Q20	b	moins d'observations et un effet partagé : deux raisons qui se cumulent

Grille de conversion : 20/20 à 14/20 validé · 13/20 à 11/20 révisions ciblées sur les deux blocs manquants · 10/20 et moins reprendre le module.

C · Exercices pratiques — corrigés

E1.1 — 480 lignes, 316 tickets. Montant TTC par ligne : moyenne 75 152, médiane 37 966, écart type 143 915 FCFA. `=ECARTYPE.STANDARD(plage)` ou `df.montant_ttc.std()`.

E1.2 — le total de l'extrait au grain du ticket vaut 36 073 185 FCFA. Les 32 plus gros tickets, soit 10,1 % des 316, en portent 17 139 852 FCFA : **47,5 %** du chiffre d'affaires pour un ticket sur dix. Les 31 tickets au-dessus de 250 000 FCFA valent 16 903 734 FCFA, soit 46,9 %. Les neuf plus gros seulement suffisent à faire 24,0 % du total (8 642 533 FCFA). Le chiffre d'affaires est donc bien porté par les gros tickets, et la moyenne du magasin parle surtout d'eux.

E1.3 — premier quartile 20 635, troisième 130 559, IQR 109 924, borne 295 445 FCFA, 25 tickets hors borne. En excluant les 3 tickets de retour (montant négatif au niveau du ticket), la borne descend de 1 271 FCFA à 294 174 FCFA et le nombre de tickets hors borne **reste 25** : le nettoyage déplace la borne, il ne change pas le verdict. C'est la réponse attendue — et elle vaut mieux que « la borne est une ligne de conduite », parce qu'elle est mesurée des deux côtés.

E2.1 — 173 sur 480, soit 36,0 % ; erreur type 2,2 points, marge 4,3 points, intervalle [31,7 ; 40,3] % — le même calcul que M02.C07, exerc. 7.3. Dans la population de référence, la part de lignes avec remise se mesure par la même formule sur 240 000 lignes : si les deux chiffres s'écartent de plus d'une dizaine de points, l'extrait n'est plus neutre sur cette variable et la remarque va dans le rapport.

E2.2 — Bationo : 90 963 FCFA de moyenne par ligne, 125 lignes. Ilboudo : 62 354 FCFA, 109 lignes. Écart 28 609 FCFA, erreur type 18 821, marge $\pm 36\,888$, $t = 1,52$, ddl 226,1, $p = 0,13$, IC [-8 279 ; 65 498]. Au tableur `=T.TEST(plage1;plage2;2;3)`, en Python `stats.ttest_ind(a, b, equal_var=False)` : les deux doivent rendre le même p au millième près.

E2.3 — permutation 10 000 tirages, graine annoncée : $p = 0,1443$; test des rangs : $p = 0,0161$. Phrase de décision attendue : « avec 234 lignes, l'extrait ne permet d'établir aucun classement entre vendeurs ; le test des rangs signale une différence de position qui résiste mal à la correction pour six comparaisons (seuil 0,0083) ».

E2.4 — $n = 412$ lignes par groupe pour 80 % de puissance sur un écart de 28 609 FCFA avec 30 % de remise. L'extrait en compte 125 et 109 : l'étude est en dessous d'un facteur quatre.

D · Étude de cas — éléments de réponse attendus

1. Deux niveaux, deux chiffres, même conclusion. Niveau ligne : 234 observations, écart estimé 28 609 FCFA, intervalle [-8 279 ; 65 498] FCFA, $p = 0,13$, seuil corrigé 0,0083 → non concluant. Niveau ticket : 107 observations, écart 16 663 FCFA, erreur type 33 881, $p = 0,624$, intervalle [-49 743 ; 83 069] → non concluant, et il faut écrire pourquoi l'intervalle gonfle : 30 % d'observations en moins, et 84 tickets sur 316 portent plusieurs vendeurs, donc l'effet cherché est partagé. Marge de détection 52 956 FCFA : même une vraie différence de 20 000 FCFA n'aurait que 18,5 % de chances d'être détectée. Verdict à rendre : **classement non établi**, les 46 % du courriel sont un rapport de moyennes, pas un effet démontré.

2. Périmètre : année 2025, magasin 1 contre magasin 5, grain du ticket, total des montants TTC par ticket dans `ventes_propres`. Moyennes 107 889 FCFA (14 463 tickets) et 116 886 FCFA (4 524 tickets) ; médianes 65 313 et 68 160 FCFA. Écart -8 997 FCFA, erreur type 2 668, $t = -3,37$ sur 6 782,8 ddl, $p = 0,000751$, intervalle [-14 226 ; -3 767] FCFA : zéro exclu, **écart établi** — le magasin 5 fait des paniers plus gros, d'environ 8 300 à 14 200 FCFA, soit 7,7 % à 13,2 % du panier moyen du magasin 1. La prudence à joindre : ce test porte sur la population entière des deux magasins, l'extrait nettoyé n'y participe pas ; et rien ici n'explique l'écart (assortiment ou clientèle, on ne sait pas).

3. Recommandation, modèle de rédaction : « aucune mesure individuelle ne se justifie sur cette base ; nous proposons un recalcul sur douze mois complets au grain du ticket (14 463 et 4 524 tickets disponibles, seuil d'observation 0,0083), et la collecte du rattachement client-ligne qui manque sur 21,5 % de l'effectif avant toute comparaison de filets de clientèle ». Une ligne de date, une ligne de responsable, une ligne de revue.

4. Ce qui aurait changé la réponse : le panier par client et non par ticket (84 tickets multi-vendeurs, 103 lignes sans client utile), la marge nette au lieu du chiffre d'affaires (le prix de revient est hors de ce fichier), et l'écoulement du stock (sans lui, un gros mois peut être un transfert en magasin, pas une vente). Pour chacun : la donnée à demander, et le test qui en découlerait.

Total et décision d'orientation

Composante	Score	Seuil	Statut
B · Quiz	... /20	14	bloquant
C · Exercices	... /20	indicatif (auto-correction menée = +0,5)	—
D · Étude de cas	... /20	12	bloquant
Projet M02.P	... /20	13	bloquant

Décision. B et D au seuil, projet au seuil → module validé, passage en M03 (SQL : interroger la source). Quiz seulement en dessous → trois jours pour reprendre C02 et C05, puis une nouvelle version de B. Étude de cas seulement en dessous → nouvelle version de D sur le même dossier,

avec un entretien de 15 minutes sur la lecture des intervalles. Deux échecs → reprise du module, en commençant par les mini-projets P1 à P4.