

MANUEL PROFESSIONNEL · ÉDITION 2026

M09 — Analyse exploratoire de données

Six chapitres · 30 h · fil rouge vente.csv

Analyse de données appliquée & Business Intelligence
6 partie(s) assemblée(s) · document de production

Table des matières

MODULE M09.C01 — LE PROTOCOLE EN 10 ÉTAPES : INSPECTER SANS SE FIER, LA « FICHE D'ENTRÉE » ET LE TEMPS À Y CONSACRER	6
1. Objectifs du chapitre	6
2. Pourquoi cette notion est importante	6
3. Explication simple — la conversation avec la machine	7
4. Vocabulaire essentiel	7
5. Cours approfondi	8
5.1 Pourquoi on explore : le jeu inconnu, la question métier, le livrable provisoire	8
5.2 Les 10 étapes comme contrat	8
5.3 Étape 1 — Inspecter sans se fier	9
5.4 Étape 2 — Comprendre les variables : la fiche d'entrée	11
5.5 Les limites d'un fichier : ce qu'il peut et ne peut pas répondre	12
6. Exemple concret — la fiche d'entrée des 13 colonnes de vente.csv	12
7. Démonstration pas à pas — 5 étapes sur le fil rouge	13
8. Erreurs fréquentes	14
9. Bonnes pratiques professionnelles	14
10. Exercice guidé — « l'affaire des centimes » (15 min, /10)	15
11. Exercices autonomes	15
12. Correction détaillée	15
13. Mini-projet M09.P1 — « La fiche d'entrée en 30 minutes » (1 h)	16
14. Boîte à outils du chapitre	17
15. Résumé du chapitre	17
16. À retenir	18
17. Évaluation formative (auto-correction, 8 min)	18
MODULE M09.C02 — AUDIT ET PREMIÈRES STATISTIQUES : LES 3 FAMILLES DE DÉFAUTS, L'AUDIT VIDE EST SUSPECT, CADRER L'HYPOTHÈSE	20
1. Objectifs du chapitre	6
2. Pourquoi cette notion est importante	6
3. Explication simple — la conversation avec la machine	7
4. Vocabulaire essentiel	7
5. Cours approfondi	8
5.1 Les 3 familles de défauts — et le contrôle qui trouve chacune	21
5.2 L'audit vide est suspect — le contrôle du contrôle	23
5.3 Le centre de santé arrive — les 4 défauts, exécutés	23
5.4 Premières statistiques — juste ce qu'il faut	24
5.5 Cadrer l'hypothèse — la formuler falsifiable avant de la tester	25
6. Exemple concret — le défaut M12 prouvé par la récurrence	26
7. Démonstration pas à pas — 5 étapes sur le centre de santé	27
8. Erreurs fréquentes	14
9. Bonnes pratiques professionnelles	14

10. Exercice guidé — « les 4 défauts du centre de santé » (25 min, /10)	28
11. Exercices autonomes	15
12. Correction détaillée	15
13. Mini-projet M09.P2 — « Le rapport d’audit en 1 page » (1 h)	29
14. Boîte à outils du chapitre	17
15. Résumé du chapitre	17
16. À retenir	18
17. Évaluation formative (auto-correction, 8 min)	18
MODULE M09.C03 — TENDANCES : LA SÉRIE, LA SAISON, LE BRUIT — ET LES PÉRIODES QU’ON A LE DROIT DE COMPARER	33
1. Objectifs du chapitre	6
2. Pourquoi cette notion est importante	6
3. Explication simple — la conversation avec la machine	7
4. Vocabulaire essentiel	7
5. Cours approfondi	8
5.1 La série simple — set_index + resample (le 'ME' de M08)	34
5.2 Décomposer tendance / saisonnalité / bruit — à l’œil et au chiffre	35
5.3 Comparer des périodes à taille égale — le 28 décembre qui ment	36
5.4 La saisonnalité du jour de semaine et de l’heure — le centre de santé	37
5.5 La tendance interrompue — la rupture qui coupe sans retombée	37
6. Exemple concret — la quincaillerie : dire « plat », et le prouver	38
7. Démonstration pas à pas — 5 étapes sur les deux jeux	39
8. Erreurs fréquentes	14
9. Bonnes pratiques professionnelles	14
10. Exercice guidé — « lire la saison du centre de santé » (25 min, /10)	40
11. Exercices autonomes	15
12. Correction détaillée	15
13. Mini-projet M09.P3 — « Le graphique de tendance avec sa question » (1 h)	41
14. Boîte à outils du chapitre	17
15. Résumé du chapitre	17
16. À retenir	18
17. Évaluation formative (auto-correction, 8 min)	18
MODULE M09.C04 — ANOMALIES ET RARETÉS : CE QUI EST INHABITUEL, COMMENT LE PROUVER, QUOI EN CONCLURE	45
1. Objectifs du chapitre	6
2. Pourquoi cette notion est importante	6
3. Explication simple — la conversation avec la machine	7
4. Vocabulaire essentiel	7
5. Cours approfondi	8
5.1 Définir l’anomalie avant de la chercher	46
5.2 Prouver — les trois témoins	47
5.3 Les trois décisions — les 4 défauts de C02 jugés	48

5.4 L'anomalie qui compte — la rupture n'est pas un chiffre	49
5.5 Les raretés qui ne sont pas des anomalies — le plateau 594 363	49
6. Exemple concret — les 594 363, jugés en entier (fil rouge)	50
7. Démonstration pas à pas — 5 étapes sur les deux jeux	39
8. Erreurs fréquentes	14
9. Bonnes pratiques professionnelles	14
10. Exercice guidé — « les 4 défauts du centre de santé, jugés » (25 min, /10)	52
11. Exercices autonomes	15
12. Correction détaillée	15
13. Mini-projet M09.P4 — « L'anomalie avec sa preuve » (1 h)	53
14. Boîte à outils du chapitre	17
15. Résumé du chapitre	17
16. À retenir	18
17. Évaluation formative (auto-correction, 8 min)	18
 MODULE M09.C05 — RELATIONS ET HYPOTHÈSES : CE QUI BOUGE ENSEMBLE, CE QUI NE BOUGE PAS, ET LES 3 FAUSSES CAUSES	 56
1. Objectifs du chapitre	6
2. Pourquoi cette notion est importante	6
3. Explication simple — la conversation avec la machine	7
4. Vocabulaire essentiel	7
5. Cours approfondi	8
5.1 corr() en une ligne — et ses 3 limites	58
5.2 Corrélation $\neq$ causalité — les 3 fausses causes, chiffrées	58
5.3 L'établissement scolaire arrive — le jeu 3, ses 4 défauts	60
5.4 Segmenter — les 3 tranches d'absentéisme et leur gradient	60
5.5 Comparer des groupes — à taille égale, ou en le disant	61
5.6 Formuler l'hypothèse et la tester — l'étape 8	62
6. Exemple concret — le fil rouge : 0.552, 0.001, et la clientèle plate	62
7. Démonstration pas à pas — 5 étapes sur les deux jeux	39
8. Erreurs fréquentes	14
9. Bonnes pratiques professionnelles	14
10. Exercice guidé — « les 3 chiffres du jeu scolaire » (25 min, /10)	64
11. Exercices autonomes	15
12. Correction détaillée	15
13. Mini-projet M09.P5 — « L'hypothèse testée, sa limite nommée » (1 h)	66
14. Boîte à outils du chapitre	17
15. Résumé du chapitre	17
16. À retenir	18
17. Évaluation formative (auto-correction, 8 min)	18
 MODULE M09.C06 — VISUALISATIONS D'EXPLORATION ET CONCLUSIONS PROVI-SOIRES : LA NOTE D'EDA	 69
1. Objectifs du chapitre	6

2. Pourquoi cette notion est importante	6
3. Explication simple — la conversation avec la machine	7
4. Vocabulaire essentiel	7
5. Cours approfondi	8
5.1 Choisir le graphique par question — la table du module	71
5.2 Les 5 erreurs d'exploration — et leur contrôle	72
5.3 matplotlib — les 4 graphiques du projet	72
5.4 seaborn — le confort, documenté	73
5.5 La note d'EDA — 1 page, affirmation + source + limite	74
5.6 Lire une note d'autrui — la rétro-lecture	75
6. Exemple concret — la note d'EDA de la quincaillerie (fil rouge, complète)	75
7. Démonstration pas à pas — 5 étapes sur les deux jeux	39
8. Erreurs fréquentes	14
9. Bonnes pratiques professionnelles	14
10. Exercice guidé — « la rétro-lecture de la note d'autrui » (25 min, /10)	78
11. Exercices autonomes	15
12. Correction détaillée	15
13. Mini-projet M09.P6 — « P3 + P4 : les 4 graphiques et la note » (1 h)	79
14. Boîte à outils du chapitre	17
15. Résumé du chapitre	17
16. À retenir	18
17. Évaluation formative (auto-correction, 8 min)	18

Module M09.C01 — Le protocole en 10 étapes : inspecter sans se fier, la « fiche d'entrée » et le temps à y consacrer

Outils : pandas 2.2.3, numpy 2.3.5 (exécutés), matplotlib 3.10.9 / seaborn 0.13.2 (annoncés, C06), DuckDB (annoncé, le parallèle s'active à C02). **Durée indicative :** 5 h. **Niveau :** N3. **Prérequis :** M02 (les statistiques descriptives) et M08 (pandas) ; M05/M07 utiles (le parallèle SQL et la base de la quincaillerie).

L'idée du chapitre. M08 a appris à **produire** des chiffres ; M09 apprend à **poser les bonnes questions** à un jeu de données qu'on ne connaît pas, et à n'affirmer que des conclusions **provisoires, correctement exprimées**. Ce chapitre pose le **protocole en 10 étapes** — le contrat du module — et ses deux outils d'entrée : l'inspection sans confiance (`shape`, `dtypes`, `head`, `info` — et pourquoi `head(5)` peut mentir) et la **fiche d'entrée** (variables, unités, sources, questions autorisées), complétée **en 30 minutes maximum** : c'est la contrainte du projet M09.P, « 3 heures avec un fichier que personne n'a regardé », et la compétence du module — **s'arrêter** avec un cadrage honnête, pas explorer jusqu'à n'avoir plus rien à rendre.

Matériel de l'atelier — Python 3.13 · pandas 2.2.3 (environnement d'écriture) · numpy 2.3.5. Toutes les commandes de ce chapitre ont été exécutées dans l'atelier le 20/09/2026 sur le dossier `03_exercices/dossier_M09/` (graine 45, déterministe, empreinte figée en `ATTENDU.json`) ; les sorties publiées sont **celles de l'atelier**.

1. Objectifs du chapitre

À la fin de ce chapitre, vous savez :

1. **Définir une analyse exploratoire de données (EDA)** et situer son livrable : une **note provisoire**, pas un verdict.
2. **Dérouler les 10 étapes du protocole** — inspecter, comprendre les variables, détecter les problèmes, premières statistiques, tendances, anomalies, relations, hypothèses, visualisations, conclusions provisoires — et dire pourquoi le protocole est un **contrat** et non une check-list.
3. **Inspecter sans se fier** : `shape`, `dtypes`, `head()`, `info()` — et expliquer sur un exemple exécuté **pourquoi `head(5)` peut mentir**.
4. **Compléter une fiche d'entrée** (variable → sens / unité / source / question autorisée) **en 30 minutes**, en **vérifiant les unités sur les données** et non dans la doc.
5. **Dire ce qu'un fichier peut et ne peut pas répondre** — les limites d'un fichier sont une information, pas un aveu de faiblesse.

2. Pourquoi cette notion est importante

Un analyste n'est jamais payé pour explorer : il est payé pour **répondre à une question métier** (« quand le centre de santé est-il saturé ? », « quels médicaments manquent ? », « l'absentéisme pèse-t-il sur les résultats ? ») avec un jeu de données qu'il ne connaît pas, dans un temps limité. Entre la question et la réponse, il y a toujours la même distance : **comprendre ce qu'on a entre les mains avant de mesurer quoi que ce soit**.

Trois jeux fixent l'enjeu : le **fil rouge** (la quincaillerie M07/M08 — 50 008 ventes, 8 doublons, 208 retours, CA propre 7 876 320 164 FCFA), que M09 rejoue **en EDA pur** — sans savoir ce qu'on y cherche — pour voir si le protocole redonne l'audit de M07/M08 ; le **centre de santé** (18 818 consultations sur 2025-2026) et l'**établissement scolaire** (402 élèves déclarés, 6 000 notes), que vous ne connaissez pas et qui portent des défauts plantés et comptables dans `ATTENDU.json` ; le **projet M09.P**, 3 heures sur un export brut de 10 014 lignes « que personne n'a regardé ».

La faute que le projet punit n'est pas l'erreur de calcul : c'est **l'exploration sans méthode** — explorer « pour voir » pendant 2 h 30, puis découvrir qu'on n'a ni question ni limite à présenter. Le protocole, la fiche d'entrée et le chronomètre sont les trois parades ; ce chapitre couvre les deux premières.

3. Explication simple — la conversation avec la machine

Vous recevez une boîte : « les ventes de la quincaillerie ». Quatre réflexes d'entrée, dans l'ordre :

1. **Ouvrir la boîte sans rien croire.** Combien de lignes ? (shape) Quelles natures de colonnes ? (dtypes) Que disent les 5 premières lignes ? (head) — **5 lignes, c'est une publicité, pas un échantillon.**
2. **Lire l'étiquette de chaque contenant.** Pour chaque colonne : que veut-elle dire, en quelle unité, d'où vient-elle ? C'est la **fiche d'entrée**, remplie **en 30 minutes**, chrono en marche.
3. **Écrire les questions autorisées.** Trois questions que le fichier **peut** répondre, deux qu'il **ne peut pas**. Une analyse sans questions est une promenade.
4. **Partir.** À 30 minutes, on passe au protocole, pas à une « petite vérification de plus » : l'analyste s'arrête avec un cadrage, le chercheur de pépites s'arrête quand il n'a plus de batterie.

La conversation avec la machine tient en une règle : **on ne demande à la machine que des faits (shape, dtypes, head, info) ; les interprétations (« c'est un montant en FCFA », « ces 8 lignes sont des doublons »), on les écrit soi-même, avec leur preuve.**

4. Vocabulaire essentiel

Terme	Définition
analyse exploratoire de données — exploratory data analysis (EDA)	l'examen systématique d'un jeu de données inconnu pour en dégager des structures, des problèmes et des pistes, avant de modéliser.
fiche d'entrée	le document de cadrage d'une analyse : variables (sens, unité, source), questions autorisées, durée prévue. Remplie en 30 minutes maximum .
audit	le passage qui cherche les défauts du jeu (doublons, manquants, valeurs impossibles) ; un audit qui ne trouve rien est suspect, pas réconfortant (C02).
conclusion provisoire	une affirmation posée avec ses limites (période, échantillon, variables absentes), révisable aux données suivantes. Le livrable de M09 est une note de conclusions provisoires.

5. Cours approfondi

5.1 Pourquoi on explore : le jeu inconnu, la question métier, le livrable provisoire

Définition. analyse exploratoire de données — exploratory data analysis (EDA) — l'examen systématique d'un jeu de données inconnu pour en dégager des structures, des problèmes et des pistes, **avant** de modéliser. En M09, le livrable de l'EDA est une **note de conclusions provisoires**, jamais un modèle : modéliser sans protocole, c'est deviner avec des chiffres.

M07/M08 partaient d'une base **connue** (l'audit était fait, les totaux étaient publiés). M09 invertit la situation : vous tenez un fichier **sans** audit, **sans** dictionnaire, et la question métier est vague (« la direction veut savoir quand le centre est saturé »). Trois conséquences :

- **On ne peut pas tout savoir d'avance** : la fiche d'entrée admet l'incertitude (« `statut` : 6 graphies observées — sens supposé : succès/échec d'une opération ; **à confirmer** »).
- **Le livrable n'est pas un tableau de bord** (interdit : le mot même) mais une **note d'EDA** : une page par jeu, chaque affirmation porte sa **source** (la sortie qui la prouve) et sa **limite** (ce qu'elle ne couvre pas). C'est le chapitre C06 qui la rédige ; ce chapitre pose la discipline d'écriture — chaque chiffre publié doit pouvoir dire **d'où il sort**.
- **Le temps est une variable d'analyse** : 3 heures au projet, 30 minutes à l'entrée. Une analyse qui ne peut pas dire « j'arrête ici, voici ce que je sais et ce que je ne sais pas » n'est pas une analyse, c'est une dérive.

5.2 Les 10 étapes comme contrat

La liste de référence du module (récapitulée à la fin du chapitre, figure 1) :

#	Étape	Question posée	Outil principal
1	Inspecter	« Qu'est-ce que j'ai entre les mains ? »	<code>shape</code> , <code>dtypes</code> , <code>head()</code> , <code>info()</code>
2	Comprendre variables	les « Que veut dire chaque colonne, en quelle unité, d'où vient-elle ? »	la fiche d'entrée
3	Détecter problèmes	les « Y a-t-il des doublons, des manquants, des valeurs impossibles ? »	<code>duplicated()</code> , <code>isna()</code> , bornes métier (C02)
4	Premières statistiques	« Quelle est la forme de chaque variable clé ? »	<code>describe()</code> , <code>value_counts()</code> (C02) quartiles,
5	Tendances	« Ça monte, ça descend, ça cycle ? »	séries temporelles simples, <code>resample</code> (C03)
6	Anomalies	« Qu'est-ce qui est inhabituel, et comment le prouver ? »	<code>iqr</code> , bornes métier, récurrence (C04)
7	Relations	« Les variables bougent-elles ensemble ? »	corrélations, tableaux croisés, segments (C05)
8	Hypothèses	« Que puis-je affirmer, et sous quelle condition ? »	formulation falsifiable (C05)
9	Visualisations	« Quel graphique répond à la question ? »	<code>matplotlib/seaborn</code> (C06)
10	Conclusions provisoires	« Que dis-je, et quelles sont mes limites ? »	la note d'EDA (C06)


Le protocole est un contrat, pas une check-list. Une étape peut être **vide** — « aucune anomalie détectée, et voici les 3 contrôles que j'ai faits pour l'affirmer » — mais elle est **jamais passée** : une étape sautée sans explication est un **défaut du rapport**, exactement comme une re-

quête SQL non exécutée l'est en M07. Le rapport du projet (livrable P2) est noté sur les 10 étapes **présentes**, pas sur les 10 étapes bien faites.

À **retenir**. Une étape du protocole se déclare vide — « aucun doublon, et voici les 3 contrôles » — ou se remplit ; elle ne se **saute** jamais : le silence est le seul défaut du rapport EDA, et c'est celui que le correcteur cherche en premier.

Le protocole EDA : 10 étapes, un contrat — une étape se déclare, jamais sautée

Chaque étape = une question posée au jeu + l'outil principal ; le fil rouge (quincaillerie) parcourt les 10.



Le chronomètre (projet M09.P : 3 h) court sur les 10 étapes — la fiche d'entrée se remplit dans les 30 premières minutes.

5.3 Étape 1 — Inspecter sans se fier

Les quatre commandes d'inspection, dans l'ordre, sur `vente.csv` (le fil rouge) :

```
import pandas as pd

v = pd.read_csv("03_exercices/dossier_M09/quincaillerie/vente.csv")
print(v.shape)          # (50008, 13)
print(v.dtypes)
print(v.head())
v.info()
```

Sortie de l'atelier (les abréviations ... sont de l'atelier, pas de la machine) :

```

shape : (50008, 13)

id_vente      int64
id_client     int64
id_produit    int64
id_magasin    int64
id_mode       int64
date_vente    object
date_limite_remise object
quantite      int64
prix_unitaire_ht float64
taux_tva      float64
montant_ttc   float64
montant_remise float64
est_retour    bool

```

Ce que chaque commande dit — et ce qu'elle ne dit pas :

- **shape** : 50 008 lignes, 13 colonnes — la seule information **certaine** du bloc (elle peut être trompée **sur la qualité** : 8 lignes sur 50 008 sont des doublons — l'étape 3 le dira, l'étape 1 ne le voit pas).
- **dtypes** : les dates arrivent en `object` — des **chaînes** `2026-12-12`, pas des dates : on ne peut **ni trier ni comparer ni agréger** par date (`v.nsmallest(3, "date_vente")` lève une erreur, vérifiée à l'atelier) ; `pd.to_datetime` (M08 C08) est l'étape suivante, pas une option.
- **head()** : les 5 **premières** lignes, pas 5 lignes **au hasard** — la différence entre une vitrine et un échantillon.
- **info()** : présence (Non-Null Count), natures, mémoire (4.6+ MB). Ici **0 manquant** — déjà le premier piège : un zéro général est **une information à contrôler**, pas un feu vert (C02 §5.2).

Pourquoi `head(5)` peut mentir — sur le socle, exécuté :

```

print(v.head()["est_retour"].tolist()) # [True, True, True, True, True]
print(v["est_retour"].value_counts().to_dict())

```

```

[True, True, True, True, True]
{False: 49800, True: 208}

```

Attention. Cinq `True` d'affilée dans `head(5)` n'est **pas** un taux de 100 % : c'est la vitrine. Le taux réel est 208 sur 50 008, soit 0,4 %. Une conclusion tirée des 5 premières lignes d'un fichier non trié est une conclusion tirée d'un **échantillon de convenance** — le pire que la machine puisse vous servir.

Les **5 premières lignes sont des retours**. Un fichier « lu » uniquement par `head(5)` donne l'impression d'une base de retours — la réalité est 208 retours sur 50 008 ventes, soit 0,4 %. Deuxième leçon, sur les dates : `head(5)` affiche `2026-12-12`, `2026-10-06`, `2025-11-07`, `2025-01-10`, `2025-06-12` — **non triées**. Le fichier n'est pas ordonné ; rien n'interdit de supposer le contraire sans le vérifier (les plus anciennes ventes sont du 2025-01-01, les plus récentes du 2026-12-28 — exécuté après `pd.to_datetime`).

Troisième leçon, la plus sournoise : `v.duplicated().sum()` renvoie **0** sur `vente.csv` — alors que le fil rouge porte **8 doublons** (audit M07). Pourquoi ? Parce que les 8 lignes doublonnées sont identiques **sur les 12 colonnes métier**, mais portent des `id_vente` différents : le doublon complet (13 colonnes) n'existe pas. L'inspection naïve dit « propre », l'inspection métier (`duplicated(subset=<les 12 colonnes métier>)`) dit 8. **C'est l'objet de l'étape 3** ; l'étape 1 se contente de noter : « il y a une colonne d'identifiant — les doublons se chercheront **hors** identifiant ».

Définition. audit — le passage du protocole qui cherche les défauts du jeu (doublons, manquants, valeurs impossibles) avant de mesurer quoi que ce soit. Un audit qui ne trouve **rien** est **suspect, pas réconfortant** : le contrôle du contrôle (qu'a-t-on réellement contrôlé ?) est fait à C02 §5.2.

Attention. `v.duplicated().sum()` renvoie **0** ici — et ce zéro est **faux en apparence** : le socle porte bien 8 doublons, mais ils sont détectables seulement hors `id_vente`. Un zéro d'audit est une **hypothèse à invalider**, jamais une certification.

5.4 Étape 2 — Comprendre les variables : la fiche d'entrée

Définition. fiche d'entrée — le document de cadrage d'une analyse : variables (sens, unité, source), questions autorisées, durée prévue. Remplie **en 30 minutes maximum** — c'est la limite du livrable P1 du projet, et le signe qu'on cadre plutôt qu'on explore.

La fiche d'entrée est un tableau, une ligne par variable, quatre colonnes :

Variable	Sens	Unité	Source / question autorisée
<code>montant_ttc</code>	montant de la vente, toutes taxes comprises	FCFA (vérifié §5.4)	CA par période, par magasin

Elle se remplit **en 30 minutes maximum**, chrono en marche. Pourquoi 30 minutes ? Parce que le projet M09.P le décide : la fiche doit être **finie** quand le chronomètre du livrable P1 s'arrête — « la fiche d'entrée dans les 30 premières minutes ». Et parce qu'une fiche à 45 minutes n'est plus un cadrage, c'est une exploration déguisée : à 45 minutes, on a déjà commencé à **répondre** des questions qu'on n'a pas encore posées.

Les unités se vérifient sur les données, pas dans la doc. Sur `vente.csv`, deux contrôles exécutés à l'atelier fixent les unités :

```
reco = v["quantite"] * v["prix_unitaire_ht"] * (1 + v["taux_tva"])
print((v["montant_ttc"] - reco).abs().max())
print(v["taux_tva"].unique())
```

```
0.05
[0.19 0.18]
```

- `montant_ttc` $\approx$ `quantite` $\times$ `prix_unitaire_ht` $\times$ $(1 + \text{taux_tva})$ au **centime près** (écart max 0.05 FCFA sur 50 008 lignes) : les montants sont **en FCFA**, pas en centimes — si c'était en centimes, l'équation serait faussée de 100 fois.
- `taux_tva` ne vaut que **0.18 et 0.19** : ce ne sont pas des pourcentages (18, 19) mais des **fractions** — et la table `regle_tva.csv` (2025 $\rightarrow$ 0.18, 2026 $\rightarrow$ 0.19) explique le passage de l'un à l'autre : la fiche d'entrée note « fraction, 0.18 en 2025, 0.19 en 2026 (changement de taux fiscal) ». **C'est une information métier découverte par la fiche**, pas par l'exploration.

Dans les faits. Sur le socle, ce contrôle prend **deux lignes** et 88 ms au total : l'écart max de 0.05 FCFA et les deux valeurs de `taux_tva` suffisent à refuser la convention « centimes » du courriel d'accompagnement. C'est l'exact opposé de ce qu'on ferait « à l'œil » : regarder trois montants et se rassurer.

La fiche d'une analyse EDA admet **l'incertain** : une case se remplit « à confirmer » plutôt que devinée. La fiche d'entrée du projet P1 (C01 §13) en montre 4 ou 5 cases « à confirmer » — c'est **normal**, c'est même le signe qu'elle est honnête.

5.5 Les limites d'un fichier : ce qu'il peut et ne peut pas répondre

La fiche d'entrée se termine par **5 questions** : 3 que le fichier **peut** répondre, 2 qu'il **ne peut pas**. Sur `vente.csv` (le fil rouge, déjà audité en M07/M08) :

Le fichier peut répondre :

- 1. « Quel est le CA par magasin et par mois, avec et sans retours ? » — les 120 lignes de la vue mensuelle de M07, le plus gros mois mesuré à 78 965 529 FCFA (magasin 3, août 2025, vue sans retours).
- 2. « Combien de ventes ont eu lieu un dimanche, et que valent-elles ? » — 7 136 ventes dominicales sur 50 008.
- 3. « Quelle part du CA part en retours ? » — 208 retours, écart de CA 31 939 568 FCFA (CA brut 7 908 259 732 FCFA, CA propre 7 876 320 164 FCFA).

Le fichier ne peut pas répondre :

- 1. « **Pourquoi** un client a-t-il retourné ? » — la colonne `est_retour` est un booléen, il n'y a pas de motif ; la cause est **hors fichier**.
- 2. « **Quel client est le plus rentable**, au sens coût/bénéfice ? » — il y a des CA par client, mais pas de **coûts** (achat, logistique) ; la rentabilité est **hors fichier**.

Ces deux « ne peut pas » sont **aussi précieux que les trois « peut »** : ils empêchent l'analyse de glisser vers des conclusions que les données ne portent pas. C'est la première forme de la **limite** que chaque conclusion provisoire du module devra porter (C05, C06).

Définition. conclusion provisoire — une affirmation posée **avec** ses limites (période, échantillon, variables absentes), révisable aux données suivantes. En M09, c'est la forme de **toute** conclusion : « les dimanches pèsent 7 136 ventes sur 50 008, sur la seule période de l'export (2025-01-01 → 2026-12-28), sans comparaison avec d'autres années » — jamais « le dimanche fait le CA ».

6. Exemple concret — la fiche d'entrée des 13 colonnes de `vente.csv`

La fiche complète du fil rouge (exécutée sur le réexport de la base M07 figée, empreinte `b9a8d973119342ec...`, byte-identique au dossier M08 — c'est la « constance du socle », le premier contrôle du protocole) :

Variable	Sens	Unité	Source / question autorisée
<code>id_vente</code>	identifiant de la ligne de vente	entier	jointures ; pas de doublons complets (vérifié : les 8 doublons du socle sont hors <code>id_vente</code>)
<code>id_client</code>	client de la vente	entier (1 à 1200)	<code>client.csv</code> : nom, ville, type, plafond de crédit — CA par client
<code>id_produit</code>	produit vendu	entier (1 à 380)	<code>produit.csv</code> : catégorie, prix de vente HT, année de référence
<code>id_magasin</code>	magasin vendeur	entier (1 à 5)	<code>magasin.csv</code> : nom, ville, région, surface — CA par magasin
<code>id_mode</code>	mode de paiement	entier (1 à 5)	<code>mode_paiement.csv</code> : libellé, frais en fraction, délai d'encaissement
<code>date_vente</code>	date de la vente	chaîne ISO (2025-01-01 2026-12-28)	à parser (<code>pd.to_datetime</code>) ; séries temporelles (C03)

Variable	Sens	Unité	Source / question autorisée
<code>date_limite_remise</code>	date limite de la remise	chaîne ISO	condition de remise ; les 21 406 dates « sous condition naïve » de l'audit M07 (C02)
<code>quantite</code>	quantité vendue	entier (pièces)	panier moyen : 158 140 FCFA par vente (M08)
<code>prix_unitaire_ht</code>	prix unitaire hors taxes	FCFA	référence de prix du produit (C04 : les rares qui ne sont pas des anomalies)
<code>taux_tva</code>	taux de TVA appliqué	fraction (0.18 en 2025, 0.19 en 2026)	<code>regle_tva.csv</code> — le passage 0.18 → 0.19 est le changement de taux fiscal
<code>montant_ttc</code>	montant de la vente TTC	FCFA (vérifié \$5.4)	CA : 7 908 259 732 FCFA brut, 7 876 320 164 FCFA propre
<code>montant_remise</code>	remise accordée	FCFA (0 si aucune)	part remise par mode de paiement (C05 : corrélation CA × remises)
<code>est_retour</code>	la vente est-elle retournée ?	booléen (208 True)	taux de retour : 208 sur 50 008

Deux conventions **à connaître avant de mesurer** (héritées de M07/M08, reprises ici car la fiche d'entrée les **redécouvre** au lieu de les supposer) : les montants sont **en FCFA** (pas en centimes), et les retours sont **dans la même table** (une vente retournée = une ligne `est_retour = True` à **déduire** du CA propre, pas à supprimer).

7. Démonstration pas à pas — 5 étapes sur le fil rouge

Le bloc complet, tel qu'exécuté dans l'atelier (chronomètre réel : 54 ms pour la lecture, 88 ms pour le bloc d'inspection complet — **le temps de la machine est négligeable ; le temps de l'analyse, c'est le temps des jugements** de la fiche, et celui-là est limité à 30 minutes) :

```
import pandas as pd

# 1 – lire et compter
v = pd.read_csv("03_exercices/dossier_M09/quincailerie/vente.csv")
print(v.shape)

# 2 – natures de colonnes
print(v.dtypes)

# 3 – vitrine (et ce qu'elle ment)
print(v.head())
print(v.head()["est_retour"].tolist())          # 5 retours d'affilée
print(v["est_retour"].value_counts().to_dict()) # {False: 49800, True: 208}

# 4 – présence et mémoire
v.info()

# 5 – bornes des dates (après le parse appris en M08)
dv = pd.to_datetime(v["date_vente"])
print(v["date_vente"].min(), v["date_vente"].max())
```

Sortie de l'atelier (abrégée — `info()` publiée en entier au §5.3) :

```
(50008, 13)
[True, True, True, True, True]
{False: 49800, True: 208}
2025-01-01 2026-12-28
```

Ce que la fiche d'entrée en retire, **ligne à ligne** :

1. `(50008, 13)` → « 50 008 lignes, 13 colonnes ; à vérifier : des doublons ? » (étape 3).
2. `object` sur les 2 dates + 5 retours d'affilée dans `head(5)` → « dates à parser avant tout ; `head` est une vitrine (208 retours sur 50 008, pas 100 %) ».

3. `info()` : 0 manquant partout → « **à contrôler**, pas à féliciter (C02 §5.2) » ; bornes 2025-01-01 → 2026-12-28 → « 24 mois, mais le 2026 s'arrête au 28/12 — la nuance est chiffrée à C03 ».

8. Erreurs fréquentes

1. **Croire `head(5)`** — « les 5 premières lignes sont des retours, donc c'est une base de retours » (208 sur 50 008, exécuté plus haut). `head` est une vitrine : on la regarde, on ne la **conclut** pas.
2. **L'audit vide comme feu vert** — `isna().sum() == 0` sur toutes les colonnes est une information **à contrôler** (les bonnes colonnes ont-elles été chargées ? les dates en `object` cachent-elles des chaînes vides ? les identifiants se referment-ils ?). C02 §5.2 fait de ce contrôle une section : **l'audit vide est suspect**.
3. **Prendre les unités sur le mot du fournisseur** — « `montant_ttc` est en centimes » dit le courriel d'accompagnement ; l'équation `quantite × prix_ht × (1 + tva)` dit **FCFA** (écart max 0.05, exécuté). Sur les données, toujours — la doc ment plus souvent qu'elle ne l'avoue.
4. **Commencer à nettoyer avant la fiche finie** — supprimer les doublons « au passage » pendant l'inspection, c'est détruire la preuve avant le rapport. L'ordre du protocole est le contrat : inspecter (1), comprendre (2), **ensuite** détecter (3).
5. **Poser une question que le fichier ne peut pas répondre** — « pourquoi ce client a-t-il retourné ? » n'a pas de réponse dans `vente.csv` (pas de motif) ; une analyse qui y répond « avec les données » a déjà inventé. Les 2 questions « interdites » de la fiche existent pour cela.

9. Bonnes pratiques professionnelles

1. **Toujours `shape` avant tout le reste** — c'est la seule information certaine du bloc ; une ligne qui ne correspond pas au `shape` attendu est un signal de chargement, pas de données.
2. **`dtypes` en 2 e, pas en 5 e** — une date en `object`, un montant en `int64` là où l'unité a des décimales : chaque écart est noté **dans la fiche**, pas corrigé silencieusement (corriger sans noter, c'est l'erreur de C04 avant la lettre).
3. **`head` et `tail` ensemble** — **la tête ment (les 5 retours), la queue aussi peut mentir ; les 5 premières par date (après `parse`) disent autre chose que les 5 premières du fichier****.
4. **La fiche s'écrit pendant l'inspection, pas après** — à 30 minutes, on n'a plus le temps de se souvenir ; chaque jugement d'inspection (« c'est une fraction, pas un pourcentage ») est écrit **dans la case** de la fiche, avec sa preuve (la sortie).
5. **Les cases « à confirmer » sont des cases** — une fiche d'entrée du projet P1 porte normalement 4 à 5 cases « à confirmer » : c'est le signe d'une analyse honnête, pas d'une paresse. L'étape 3 les résout (ou les laisse, **en le disant**).
6. **Le chronomètre est un outil d'analyse** — il ne punit pas la lenteur, il **force la hiérarchie** : à 30 minutes, on rend la fiche avec ses cases ouvertes, pas une fiche parfaite à 45. La compétence du module est de **s'arrêter**.

Conseil professionnel. En équipe, la fiche d'entrée se **diffuse avant** l'analyse, pas après : 30 minutes de lecture par vos collègues valent plus cher qu'une journée d'analyse sur une bonne idée fausse. Le jour où un collègue vous dit « attendez, statut a 6 graphies », c'est la fiche qui a payé — pas vous.

10. Exercice guidé — « l'affaire des centimes » (15 min, /10)

Contexte. Vous venez de recevoir le réexport de la quincaillerie. Votre collègue, qui l'a reçu avant vous, vous prévient : « Attention, dans ce export `montant_ttc` est **en centimes** — le fournisseur a changé de convention. » La direction attend le CA de la période **cette semaine**.

Consigne. Dans les 15 minutes (chrono), sans ouvrir `ATTENDU.json` :

1. Formulez **une seule question de contrôle** qui départage « FCFA » et « centimes » en une requête, en utilisant **les colonnes du fichier** (pas les clés du socle). (2 pts)
2. Exécutez-la ; publiez la sortie. (2 pts)
3. Donnez la conclusion **avec sa limite** (conclusion provisoire). (2 pts)
4. Votre collègue rétorque : « mais si c'était en centimes **et** que `prix_unitaire_ht` serait aussi en centimes, l'équation marcherait pareil ! » Montrez en **une ligne** comment refuter ce contre-argument en utilisant `regle_tva.csv`. (2 pts)
5. Écrivez la **case unité** de la fiche d'entrée de `montant_ttc`, telle qu'elle doit figurer dans P1. (2 pts)

11. Exercices autonomes

E1 — La fiche d'entrée du fichier inconnu (30 min, chrono). Complétez la fiche d'entrée de `03_exercices/dossier_M09/projet/fichier_inconnu.csv` : forme, 10 variables (sens supposé, unité, source), **3 questions que le fichier peut répondre** et **2 qu'il ne peut pas**. Les sens « supposés » sont autorisés — c'est l'objet d'une fiche **à confirmer** ; mais chaque case doit dire **d'où vient le supposé** (le nom, la valeur observée, le contexte). À 30 minutes, la fiche est rendue **avec** ses cases ouvertes.

E2 — Le zéro qui ment (20 min). Sur `vente.csv`, l'audit naïve renvoie : `v.isna().sum().sum() = 0`. En 20 minutes, produisez **3 contrôles** qui valident ou invalident « le fichier est réellement sans manquant » — au moins **un** de vos contrôles ne doit pas utiliser `isna`. Indice : « absent » peut signifier « manquant », mais aussi « jamais rempli », « codé autrement », ou « dans une autre table ».

12. Correction détaillée

Exercice guidé.

1. **Question de contrôle** : « `montant_ttc` est-il égal, au centime près, à `quantite × prix_unitaire_ht × (1 + taux_tva)` ? » — si l'équation tient, toutes les unités sont **cohérentes entre elles** (FCFA partout ou centimes partout) ; il faut alors une **ancree** : `taux_tva` vaut 0.18 ou 0.19, **en fraction** — en centimes de fraction il serait 1800/1900, en pourcentage 18/19. La seule lecture possible est « fractions », donc les montants qu'elles multiplient sont **en FCFA**.
2. **Sortie exécutée** (celle de l'atelier) :

```
python reco = v["quantite"] * v["prix_unitaire_ht"] * (1 + v["taux_tva"])
print((v["montant_ttc"] - reco).abs().max()) # 0.05

text 0.05
```

1. **Conclusion provisoire** : « Sur 50 008 lignes, `montant_ttc` reproduit `quantite × prix_ht × (1 + tva)` avec un écart maximal de 0.05 FCFA : les montants sont **en FCFA**, la convention du fournisseur n'a pas changé. **Limite** : le contrôle prouve la cohérence des unités **entre elles**, pas leur étalon — il repose sur `taux_tva` (0.18/0.19), lu dans les données (et confirmé par `regle_tva.csv`). »

2. **Le contre-argument** : si tout était en centimes, `taux_tva` resterait **0.18/0.19** (le taux ne dépend pas de l'unité) — mais alors `prix_unitaire_ht` × 100 devrait correspondre à un prix de vente **cohérent avec** `produit.csv`. Une ligne suffit :

```
python p = pd.read_csv("03_exercices/dossier_M09/quincaillerie/produit.csv")
print(v["prix_unitaire_ht"].describe()[["min", "max"]].to_dict(), "| prix_vente_ht de produit.csv : min =", p["prix_vente_ht"].min(), "max =", p["prix_vente_ht"].max())
```

Les prix des deux tables se répondent **au même ordre de grandeur** (des milliers de FCFA) : s'ils étaient en centimes, l'un des deux fichiers serait 100 fois plus cher que l'autre. La convention est **FCFA des deux côtés**. 5. **Case de la fiche** : « `montant_ttc` — montant de la vente TTC — **FCFA** (vérifié : `montant_ttc` ≈ `quantite` × `prix_ht` × (1+`tva`), écart max 0.05 sur 50 008 lignes ; `taux_tva` en fractions 0.18/0.19) — CA brut 7 908 259 732 FCFA (M08) ».

E1 (fiche du fichier inconnu). Forme exécutée : 10 014 lignes, 10 colonnes. Une fiche attendue (les sens sont **supposés** — c'est l'objet ; chaque case dit d'où vient le supposé). Les 5 cases les plus diagnostiques :

- `statut` — succès/échec de l'opération — **6 graphies observées** (OK/ok/Reussie/REUSSI d'un côté, Echouee/echec de l'autre) — **à normaliser avant tout taux de succès** ;
- `client_phone` — numéro du client — 3 graphies observées (+226 ..., sans indicatif, compact) — **à normaliser** ;
- `montant_xof` — montant de l'opération — **FCFA** (l'extension `_xof` le dit) — **à confirmer** : des valeurs négatives ou impossibles ?
- `type_op` — sens de l'opération (in/out, 2 valeurs) — `in` = dépôt ? retrait ? **à confirmer** (le sens change le sens du CA) ;
- `id_export` — compteur séquentiel — **inutile pour l'analyse** ; suspect : pourquoi un export compte-t-il ses lignes ?

3 questions autorisées (exemples attendus) : « Quel est le taux de succès, après normalisation des 6 statuts ? » — « Quelle est la part des 3 canaux, et que vaut le montant moyen par canal ? » — « Le volume d'opérations suit-il un cycle de jour de semaine ? » **2 questions interdites** (exemples attendus) : « Quel est le **bénéfice** de l'opérateur ? » (pas de coûts dans le fichier) ; « Ce client a-t-il **vraiment** reçu l'argent ? » (le fichier dit l'opération, pas le virement — la confirmation est hors fichier).

E2 (le zéro qui ment). Trois contrôles attendus, dont un non-`isna` :

1. **`isna` colonne par colonne, pas en somme** : `v.isna().sum()` — la somme peut cacher une colonne entière à zéro et une autre à 3 : ici, 0 sur **chaque** des 13 colonnes.
2. **Le contrôle non-`isna`** : les chaînes vides ne sont pas des NaN. `v["date_vente"].str.strip().eq("").sum()` → 0 : pas de date codée comme chaîne vide. (C'est le piège : un export qui code « absent » par "" passe **sourdement** `isna` sur une colonne object.)
3. **Les identifiants se referment-ils sur `client.csv` ?** `v["id_client"].nunique() = 1200` = le nombre de lignes de `client.csv` — pas de clé orpheline. Un « manquant » peut aussi être une **clé qui ne pointe nulle part** : `v.merge(client, on="id_client", how="left")` ne perd **aucune** ligne.

13. Mini-projet M09.P1 — « La fiche d'entrée en 30 minutes » (1 h)

Énoncé. Le chronomètre démarre quand vous ouvrez `03_exercices/dossier_M09/projet/fichier_inconnu.csv`. À 30 minutes, il s'arrête, et la **fiche d'entrée** est rendue :

- la **forme** (lignes, colonnes) ;

- les **10 variables** (sens supposé, unité, source — chaque case dit d'où vient le supposé, « à confirmer » accepté) ;
- **3 questions** que le fichier peut répondre ;
- **2 questions** qu'il ne peut pas ;
- les **2 pièges d'inspection** que `head(5)` / `dtypes` vous ont montrés (et leur preuve, en une sortie chacun).

Les 30 minutes restantes (l'heure totale) sont de **l'auto-évaluation** contre la grille P1 du projet M09.P : forme (1 pt), variables (1 pt), questions autorisées (1 pt), questions interdites (1 pt). Un rapport de fiche à **80 % avec ses cases honnêtes** passe ; une fiche « parfaite » à 45 minutes ne correspond plus au contrat.

Pourquoi ce mini-projet. C'est le **réglage du chronomètre** du projet M09.P : le jour J, vous ne serez pas face à un fichier inconnu **et** à un chronomètre inconnu — vous aurez déjà les deux, ensemble, une fois.

14. Boîte à outils du chapitre

Boîte à outils. Ce chapitre enchaîne **7 commandes** d'inspection, dans l'ordre du bloc §7 : `read_csv` (lire), `shape` (compter), `dtypes` (natures), `head/tail` (vitrine), `info` (présence et mémoire), `value_counts` (répartition d'une colonne), `nunique` (combien de valeurs différentes) — et `pd.to_datetime` dès qu'une date doit être triée, comparée ou agrégée.

Besoin	Commande	Ce qu'elle dit	Ce qu'elle ne dit pas
compter	<code>v.shape</code>	lignes x colonnes, certain	la qualité des lignes
natures	<code>v.dtypes</code>	types par colonne	les valeurs (une date en object peut être parfaite ou vide)
vitrine	<code>v.head()</code> / <code>v.tail()</code>	les n premières / dernières lignes	l'ensemble (les 5 retours d'affilée)
présence	<code>v.info()</code>	Non-Null Count par colonne, mémoire	les chaînes vides (colonne object)
répartition	<code>v[col].value_counts()</code>	les modalités fréquentes	les modalités absentes (le zéro, C02)
bornes	<code>pd.to_datetime(v[col]).min()/max()</code>	l'étendue réelle	l'ordre du fichier (non trié)
distincts	<code>v[col].nunique()</code>	combien de valeurs différentes	si elles sont correctes (clé orpheline)

15. Résumé du chapitre

M09 part d'un postulat : **le livrable d'une analyse exploratoire est une note provisoire, pas un verdict** — chaque affirmation y porte sa source et sa limite. Le module fournit les trois outils qui font la différence entre une analyse et une dérive : le **protocole en 10 étapes** (un contrat — une étape vide se déclare, une étape passée est un défaut du rapport), la **fiche d'entrée** (variables → sens / unité / source / question autorisée, en **30 minutes maximum**, unités **vérifiées sur les données** — l'affaire des centimes le prouve : 0.05 FCFA d'écart max départagent FCFA et centimes) et le **chronomètre** (3 heures au projet ; la compétence est de **s'arrêter**). L'inspection sans confiance (`shape`, `dtypes`, `head`, `info`) a livré trois leçons exécutées sur le fil rouge : `head(5)` montre 5 retours d'affilée alors que le taux est de 0,4 % (208 sur 50 008) ; les dates ar-

rivent en `object` (ni triées ni comparables avant `pd.to_datetime`) ; et `duplicated().sum()` renvoie 0 alors que le socle porte 8 doublons — parce que le doublon métier est **hors** `id_vente`. Le chapitre se termine sur la fiche d'entrée complète des 13 colonnes de `vente.csv` (montants en FCFA, `taux_tva` en fractions 0.18 → 0.19) et sur les 3 questions autorisées / 2 questions interdites qui cadreront tout le reste du module.

16. À retenir

À retenir. Trois verbes résument le chapitre : **inspecter** sans se fier (la machine dit des faits, on écrit les jugements), **cadrer** en 30 minutes (la fiche avec ses cases ouvertes), et **s'arrêter** (le chronomètre force la hiérarchie). Le reste du module n'est que de l'exécution de ces trois verbes sur trois jeux.

1. **Le protocole est un contrat** : 10 étapes, une étape vide se **déclare**, une étape passée est un **défaut du rapport**.
2. **head(5) est une vitrine** : 5 retours d'affilée sur un taux de 0,4 % (208 sur 50 008) — on regarde, on ne conclut pas.
3. **shape est la seule information certaine** du bloc d'inspection.
4. **Les dates en object ne sont pas des dates** : pas de tri, pas de comparaison, pas d'agrégat avant `pd.to_datetime`.
5. **Les unités se vérifient sur les données** : $\text{montant_ttc} \approx \text{quantite} \times \text{prix_ht} \times (1 + \text{taux_tva})$ (écart max 0.05 FCFA) + `taux_tva` (0.18/0.19) → **FCFA**, pas centimes.
6. **La fiche d'entrée : 30 minutes maximum**, cases « à confirmer » acceptées — 4 à 5 cases ouvertes sur un fichier inconnu, c'est honnête, pas paresseux.
7. **5 questions par fiche** : 3 que le fichier **peut** répondre, 2 qu'il **ne peut pas** — les « ne peut pas » valent les « peut ».
8. **Le chronomètre est un outil d'analyse** : il force la hiérarchie ; la compétence du module est de **s'arrêter** avec des conclusions provisoires.

17. Évaluation formative (auto-correction, 8 min)

1. **Pourquoi une étape du protocole peut-elle être « vide » mais jamais « passée » ?** → vide : « aucune anomalie détectée, voici les 3 contrôles » ; passée : un silence qui est un défaut du rapport, comme une requête non exécutée en M07. (2 pts)
2. **Les 5 premières lignes de vente.csv sont des retours. Que concluez-vous ? Et pourquoi cette conclusion serait-elle une erreur ?** → Rien, sinon « le fichier commence par 5 retours » ; conclure « base de retours » confond vitrine et ensemble : 208 retours sur 50 008 (0,4 %). (2 pts)
3. **v.duplicated().sum() renvoie 0 sur vente.csv. Le fichier est-il sans doublons ? Un contrôle de quoi ?** → Non : les 8 doublons du socle sont identiques sur les 12 colonnes métier, mais portent des `id_vente` différents ; le contrôle doit être `duplicated(subset=<12 colonnes métier>)`. (2 pts)
4. **Votre collègue affirme que montant_ttc est en centimes. Écrivez la requête qui départage, et sa sortie attendue.** → `(v["montant_ttc"] - v["quantite"]*v["prix_unitaire_ht"]*(1+v["taux_tva"])).abs().max()` → 0.05 (FCFA cohérents) ; en centimes l'écart serait de l'ordre de 100 fois le montant. (2 pts)
5. **taux_tva ne vaut que 0.18 et 0.19. Que dit la fiche d'entrée, et pourquoi ce détail est-il une information métier ?** → « fraction, 0.18 en 2025, 0.19 en 2026 » — le passage de l'un

- à l'autre est un **changement de taux fiscal** (confirmé par `regle_tva.csv`), pas un défaut. (2 pts)
6. **La fiche d'entrée est à 28 minutes avec 5 cases « à confirmer ». Que faites-vous, et pourquoi ?** → Je la rends telle quelle : le contrat est 30 minutes ; les cases se résolvent à l'étape 3 (ou restent, **en le disant**) — 2 minutes de plus, c'est de l'exploration déguisée. (2 pts)
7. **Citez 2 questions que `vente.csv` ne peut pas répondre, et ce qui manque pour y répondre.** → « Pourquoi un retour ? » (pas de motif de retour) ; « Quel client est rentable ? » (pas de coûts) — les causes et les coûts sont **hors fichier**. (2 pts)
8. **Pourquoi le livrable de M09 est-il une « note de conclusions provisoires » et non un tableau de bord ?** → Parce que l'EDA ne prouve pas, elle **dégère des pistes** : chaque affirmation porte sa source (sortie) et sa limite (période, échantillon, variables absentes), révisable aux données suivantes — un tableau de bord affirme, une note provisoire encadre. (2 pts)

Module M09.C02 — Audit et premières statistiques : les 3 familles de défauts, l'audit vide est suspect, cadrer l'hypothèse

Outils : pandas 2.2.3, numpy 2.3.5 (exécutés), DuckDB 1.5.5 (exécuté — le parallèle SQL du dédoublement). **Durée indicative :** 5 h. **Niveau :** N3. **Prérequis :** M09.C01 (le protocole), M02 (les statistiques descriptives), M07 (le parallèle SQL) utile.

L'idée du chapitre. C01 a cadré l'analyse (le protocole, la fiche d'entrée). C02 fait deux choses, dans l'ordre : **trouver les défauts avant qu'ils ne faussent un chiffre** (l'étape 3) et **résumer ce qui reste, juste ce qu'il faut** (l'étape 4) — en **cadrant une hypothèse falsifiable** avant de la tester. Le **centre de santé** y fait son entrée (18 818 consultations, 12 médicaments, 8 767 lignes de stock quotidien) avec **4 défauts plantés et comptables** : 23 motifs manquants, 7 doublons de stock, 1 date dans le futur, 4 stocks négatifs. Et la règle du module y est posée : **l'audit qui ne trouve rien est suspect, pas réconfortant** — le contrôle du contrôle est une section à part entière.

Matériel de l'atelier — Python 3.13 · pandas 2.2.3 · numpy 2.3.5 · DuckDB 1.5.5. Toutes les commandes ont été exécutées dans l'atelier le 20/09/2026 sur `03_exercices/dossier_M09/sante/` (graine 45, déterministe, ATTENDU.json figé) et sur le fil rouge `quincaillerie/` ; les sorties publiées sont **celles de l'atelier**.

1. Objectifs du chapitre

À la fin de ce chapitre, vous savez :

1. **Classer un défaut dans les 3 familles** (doublons, manquants, valeurs impossibles) et nommer le **contrôle** qui le trouve — la matrice du chapitre.
2. **Conduire le contrôle du contrôle** quand l'audit renvoie zéro partout : 3 contrôles exécutés, et pourquoi un zéro non contrôlé n'est pas un feu vert.
3. **Chiffrer un défaut avec sa définition exacte** : « 7 doublons » n'est pas une définition ; « 7 lignes de `stock_medicament.csv` dont le 5-tuple complet est identique » en est une.
4. **Lire `describe()` colonne par colonne** : médiane vs moyenne sur une distribution asymétrique, quartiles, **iqr**, bornes de Tukey — et ce qu'un **min** hors du réel dit de plus que l'audit.
5. **Cadrer une hypothèse falsifiable** (« si c'est une saisonnalité, les étés doivent ressembler plus entre eux qu'à leurs hivers ») **avant** de la tester.

2. Pourquoi cette notion est importante

Un défaut non trouvé ne fausse pas « un peu » un chiffre : il fausse **tous** les chiffres qui passent sur la colonne. Un motif manquant fausse le taux par motif ; un doublon de stock fausse le taux de rupture ; une date dans le futur fausse la période de la série ; un stock négatif fausse la médiane. Le protocole le sait : l'étape 3 existe **avant** l'étape 4, et l'étape 4 existe **avant** les étapes 5 à 10.

Trois faits mesurés sur le socle fixent l'enjeu :

- l'audit du **centre de santé** (le jeu 2, qui arrive ici) trouve **4 familles de défauts comptables** : 23 motifs manquants, 7 doublons de stock, 1 consultation datée au 2027-01-05 (après la fin de la période 2025-01-01 → 2026-12-31), 4 stocks négatifs ;
- le **fil rouge** (la quincaillerie) passe **l'audit vide** : 0 manquant sur 50 008 lignes et 13 colonnes — et c'est justement sur lui que le chapitre montre les **3 contrôles** qui transforment un zéro en résultat ;
- la statistique n'est pas un verdict : sur les consultations/jour, la **moyenne est 25.74** et la **médiane 29.0** — un écart de 3.26 consultations que seule la question métier départage (C02 §5.4).

3. Explication simple — la conversation avec la machine

Le contrôleur qualité qui reçoit une palette de médicaments fait trois passages, **dans l'ordre** :

1. **Compter les paquets en trop.** Un même carton deux fois = un doublon ; on le compte, on l'étiquette, on ne le jette pas sans écriture. (`uplicated()`)
2. **Chercher les étiquettes qui manquent.** Une case vide sur 18 818 paquets n'est pas un détail : c'est une information manquante qu'on comptera et qu'on traitera **après** l'audit, pas pendant. (`isna()` — et les chaînes vides que `isna` laisse passer)
3. **Vérifier le possible.** Un stock de -12 boîtes de cotrimoxazole, entre 548 et 541 ? Impossible : c'est un défaut **de saisie**, pas un fait de stock. Les bornes métier (un stock ne peut pas être négatif) et la **récurrence** (hier + entrées - sorties) le prouvent.

Puis, **un seul passage de résumé** : pas 40 statistiques, les 5 qui répondent à la question métier (« quand le centre est-il saturé ? ») — moyenne, médiane, quartiles, extrêmes, et la répartition par motif.

Et la leçon du chapitre tient en une phrase : **une boîte vide qu'on n'a pas ouverte n'est pas une preuve de propreté** — l'audit qui renvoie zéro doit être **re-vérifié** (les bonnes colonnes ? les bonnes définitions ?), sinon on n'a pas audité.

4. Vocabulaire essentiel

Terme	Définition
iqr — interquartile range	Q3 - Q1 : la largeur du « cœur » de la distribution (les 50 % du milieu), indépendante des extrêmes — c'est elle qui cale les bornes de Tukey.
point aberrant — outlier	une observation au-delà d'une borne définie avant de chercher (Q3 + 1,5 × iqr, borne métier, comparaison à la période) ; « aberrant » est un statut mesuré, pas une impression.
manquant	une valeur absente : <code>NaN</code> ou chaîne vide codée en clair — les deux formes doivent être comptées (C02 §5.1).
borne métier	une limite dictée par le métier, pas par la statistique : un stock ≥ 0, une note entre 0 et 20, une date dans la période de l'export.

5. Cours approfondi

5.1 Les 3 familles de défauts — et le contrôle qui trouve chacune

Famille	Définition exacte	Contrôle pandas	Exemple chiffré du socle
doublons	lignes (ou clés) répétées	<code>duplicated(subset=...)</code>	7 doublons de stock sur 8 767 lignes

Famille	Définition exacte	Contrôle pandas	Exemple chiffré du socle
manquants	valeur absente (NaN ou "")	<code>isna().sum()</code> <code>str.strip().eq("").sum()</code>	+ 23 motifs vides sur 18 818 consultations
valeurs impossibles	hors borne métier ou hors récurrence	bornes métier, min/max, récurrence	4 stocks négatifs (min -12)

Trois précisions qui font la différence entre un audit et une check-list :

- **Les doublons se définissent avant de compter.** `stk.duplicated()` (les 5 colonnes) compte 7 sur `stock_medicament.csv` ; mais sur `vente.csv` (fil rouge), le contrôle naïf comptait 0 alors que 8 doublons métier existent (C01 §5.3) : le doublon s'y définit **hors id_vente**, sur les 12 colonnes métier. La définition fait le chiffre.
- **Les manquants ont deux visages.** `isna()` trouve les NaN — pas les chaînes vides codées en clair. Sur les colonnes texte, le contrôle complet est `isna().sum() + str.strip().eq("").sum()`. (Sur `vente.csv`, les deux visages sont vides — exécuté au §5.2.)
- **Les valeurs impossibles se prouvent deux fois.** Une fois par la **borne métier** (un stock ne peut pas être -12), une fois par la **récurrence** du flux (hier + entrées - sorties doit éгалer aujourd'hui) — le §6 montre la preuve complète sur M12.

Définition. borne métier — une limite dictée par le métier, pas par la statistique : un stock ≥ 0 , une note entre 0 et 20, une date dans la période de l'export. Une valeur hors borne n'est pas « aberrante » au sens statistique : elle est **impossible**, et c'est ce statut qui donne droit à la correction (C04), pas à la simple suppression.

Définition. iqr — interquartile range — $Q3 - Q1$: la largeur du « cœur » de la distribution (le milieu des 50 %), indépendante des extrêmes. C'est elle, pas l'écart-type, qui cale les bornes de Tukey [$Q1 - 1,5 \times iqr$; $Q3 + 1,5 \times iqr$] — sur une distribution asymétrique ou bornée, l'écart-type s'emballe, l'iqr non.

L'audit (étape 3) : 3 familles de défauts, 3 contrôles, 3 exemples chiffrés

Chaque défaut porte sa définition exacte — sans elle, le chiffre n'est pas publiable (P2 lit la définition).

FAMILLE	DÉFINITION EXACTE	CHIFFRE DU SOCLE
Doublons	lignes (ou clés) répétées — définies AVANT de compter contrôle : <code>duplicated(subset=clés métier)</code>	7 lignes de stock (5-tuple identique) · 8 métier hors id_vente
Manquants	valeur absente : NaN OU chaîne vide codée en clair contrôle : <code>isna().sum()</code> + chaînes vides sur les textes	23 motifs vides sur 18 818 consultations
Impossible	hors borne métier ou hors récurrence du flux contrôle : bornes métier + récurrence (hier + in - out)	4 stocks négatifs (min -12) · 1 date au 2027-01-05
L'audit vide est suspect, pas réconfortant : 3 contrôles avant de publier « propre ». (1) <code>isna</code> par colonne (pas en somme) · (2) chaînes vides sur les textes (3) clés refermées sur les tables jointes — sur <code>vente.csv</code> : 0 / 0 / 0 vérifié = audit validé vide.		
Puis l'étape 4 : les statistiques juste nécessaires — médiane 29.0 vs moyenne 25.74/jour, iqr, bornes de Tukey (442 vs -12).		

5.2 L'audit vide est suspect — le contrôle du contrôle

Sur le fil rouge, l'audit « standard » renvoie zéro partout :

```
v = pd.read_csv("03_exercices/dossier_M09/quincaillerie/vente.csv")
c = pd.read_csv("03_exercices/dossier_M09/quincaillerie/client.csv")
print(int(v.isna().sum().sum())) # 0
print(int(v["date_vente"].str.strip().eq("").sum())
      + int(v["date_limite_remise"].str.strip().eq("").sum())) # 0
print(int(v["id_client"].nunique()), len(c)) # 1200 1200
print(int(len(v.merge(c, on="id_client", how="left")) - len(v))) # 0
```

```
0
0
1200 1200
0
```

Le zéro est **vérifié**, pas supposé :

1. **isna par colonne, pas en somme** — la somme peut additionner un zéro d'une colonne et un manquant d'une autre ; ici, 0 sur **chaque** des 13 colonnes.
2. **Les chaînes vides** — un export qui code « absent » par "" passe **sourdement** **isna** sur une colonne `object` : 0 chaîne vide sur les 2 dates.
3. **Les clés se referment-elles ?** — 1 200 clients distincts = 1 200 lignes de `client.csv`, 0 ligne orpheline après le `merge`.

La règle du chapitre : un audit qui ne trouve rien est **suspect** tant que ces 3 contrôles n'ont pas passé — parce qu'un zéro peut venir d'un **mauvais contrôle** (mauvaise colonne, mauvaise définition de doublon, chaîne vide non comptée) autant que d'un fichier propre. L'audit du fil rouge est **validé vide** : 0 manquant **vérifié**, 8 doublons métier (hors `id_vente`, `C01`), et c'est tout.

Attention. Un zéro d'audit n'est pas un résultat, c'est une **hypothèse** : « ce fichier n'a pas de manquant » — et une hypothèse non contrôlée (mauvaise colonne, chaîne vide non comptée, clé non refermée) est l'erreur la plus chère du chapitre, parce que toutes les statistiques d'après partent dessus.

Définition. manquant — une valeur absente, sous deux formes : le NaN que `isna()` compte, et la **chaîne vide** codée en clair que `isna()` laisse passer. Un audit complet compte **les deux** — c'est la distinction qui a fait l'erreur « 0 manquant » de plus d'un stagiaire sur un export `object`.

5.3 Le centre de santé arrive — les 4 défauts, exécutés

Le jeu 2 s'ouvre : `consultation.csv` (18 818 lignes × 7 colonnes), `stock_medicament.csv` (8 767 lignes × 5 colonnes), `medicament.csv` (12 médicaments × 4 colonnes, dont le seuil d'alerte). La fiche d'entrée (`C01`) est faite ; l'audit (étape 3) tourne :

```
import pandas as pd
s = "03_exercices/dossier_M09/sante"
cons = pd.read_csv(s + "/consultation.csv")
stk = pd.read_csv(s + "/stock_medicament.csv")
print(int(cons["motif"].isna().sum())) # manquants
print(int((cons["date_consultation"] > "2026-12-31").sum())) # dates futures
print(int(stk.duplicated().sum())) # doublons
print(int((stk["stock_fin"] < 0).sum())) # stocks négatifs
```

23
1
7
4

Les 4 défauts, **chiffrés avec leur définition exacte** (le format du rapport P2) :

#	Défaut	Définition exacte	Chiffre
D1	motifs manquants	consultation.csv, colonne motif, champ vide	23 sur 18 818
D2	doublons de stock	stock_medicament.csv, 5-tuple complet identique (date, médicament, entrées, sorties, stock)	7 sur 8 767
D3	date dans le futur	consultation hors période de l'export (2025-01-01 → 2026-12-31)	1 — C000001, datée au 2027-01-05
D4	stock négatif	stock_fin < 0, impossible par borne métier	4 — M05 (-1), M07 (-3), M10 (-2), M12 (-12)

Deux lectures qui feront la différence au rapport :

- **D3 n'est pas « une anomalie de date »**, c'est une **hypothèse de saisie** : la consultation C000001 porte la première référence du fichier et une date au 2027-01-05 — soit une coquille pour 2025-01-05 (la période commence ce jour-là), soit une erreur de transcription. L'audit **compte** le défaut ; la correction se décidera **après** (C04), avec la preuve.
- **D4 est un défaut de saisie, pas un fait de stock** — le §6 prouve le cas M12 par la récurrence. Un stock « négatif » n'existe pas en pharmacie : la valeur est fausse, le médicament n'était pas « en dette ».

Dans les faits. L'audit complet du centre de santé (formes + 4 familles + clés : 1 500 patients distincts, 6 agents, 12 médicaments tous refermés sur `medicament.csv`) prend **une vingtaine de lignes** pandas. Ce qui prend du temps, ce n'est pas le code : c'est **écrire chaque définition exacte** — c'est elle qui sera notée au rapport P2.

5.4 Premières statistiques — juste ce qu'il faut

L'étape 4 ne résume **pas tout** : elle résume ce que la question métier (« quand le centre est-il saturé ? ») nécessite. Sur la fréquentation, la distribution des consultations par jour (exécuté) :

```
moyenne 25.74 | médiane 29.0 | Q1 19.0 | Q3 33.0 | min 1 | max 44
iqr = 14.0    | bornes de Tukey [-2.0 ; 54.0] | jours hors bornes : 0
```

Moyenne 25.74, médiane 29.0 — l'écart de 3.26 se lit : la moyenne est **tirée vers le bas** par une queue de jours peu consultés (les dimanches du calendrier du centre, min 1). « Le centre fait 26 consultations par jour » (moyenne) et « la moitié des jours font 29 ou plus » (médiane) sont **deux phrases vraies et différentes** ; c'est la question métier qui choisit — pour la saturation, c'est la médiane (le jour typique), pour la capacité d'achat de médicaments, c'est la moyenne (le total).

`describe()` lu **colonne par colonne**, sur `stock_fin` :

```
count    8767.00
mean     663.76
std      557.45
min      -12.00
25%      319.00
50%      463.00
75%      607.00
max      2910.00
```

Trois choses à en retenir :

1. **Le min -12 est un audit, pas une statistique** : `describe()` vient de redécouvrir le défaut D4 **sans qu'on lui demande** — c'est le réflexe du chapitre : le `min` et le `max` d'un `describe()` se lisent toujours **en premier**.
2. **L'écart-type (557.45) est sans sens ici** : les stocks de 12 médicaments de régimes très différents (insuline ~150, paracétamol ~800) sont mélangés dans la même colonne — un écart-type sur un mélange de populations ne mesure rien. La statistique « juste nécessaire » serait **par médicament** (C04 le fera pour les ruptures).
3. **Les bornes de Tukey se calculent, ne se choisissent pas** : sur M12 seul (Q1 518, Q3 566, iqr 48), la borne basse est **446** — c'est-à-dire 518 moins 72, où 72 est 1,5 fois l'iqr 48 — et **deux** valeurs y tombent dessous : **442** et **-12**. La borne ne fait que **signaler** : 442 est un stock bas mais plausible, -12 est impossible — la décision (C04) les départage.

Attention. Une borne de Tukey qui **signale** n'est pas une borne qui **décide** : 442 et -12 tombent du même côté de 446 et reçoivent deux décisions opposées — la borne ouvre l'enquête (C04), elle ne la conclut pas. Supprimer « ce qui dépasse la borne » sans preuve métier, c'est transformer un signal en délit.

Définition. point aberrant — outlier — une observation au-delà d'une borne définie **avant** de chercher : $Q3 + 1,5 \times \text{iqr}$ (Tukey), une borne métier (stock ≥ 0 , note ≤ 20), ou la comparaison à la période. « Aberrant » est un **statut mesuré** (ici : « 2 valeurs sous 446 pour M12 »), jamais une impression (« ça fait bizarre »).

La dernière statistique de l'étape 4 est la **répartition** : `value_counts()` sur le motif (non vide) : paludisme en tête avec 2 417 consultations, et les 7 autres motifs suivent à quelques dizaines de lignes près — une distribution **plate**, elle-même une information (centre polyvalent, pas de motif dominant). Le creux du midi (927 consultations à 12:00, soit 4,9 % des heures alors que 10 tranches horaires donneraient 10 %) est noté, pas expliqué : c'est du C03.

5.5 Cadrer l'hypothèse — la formuler falsifiable avant de la tester

L'étape 8 du protocole est une **discipline d'écriture**, pas de calcul : avant de tester quoi que ce soit, l'hypothèse se formule de façon à pouvoir **se tromper**. Le gabarit du module :

« Si [mécanisme métier], alors [signature chiffrée dans les données], et [contre-exemple qui tuerait l'hypothèse]. »

Exemple du socle (cadre posé ici, test chiffré au C03) :

« Si la fréquentation du centre est saisonnière (saison des pluies), alors les 8 mois d'été (juin-sept, 2025 et 2026) doivent ressembler plus entre eux qu'à leurs hivers (déc-jan), et un été atypique — disons 20 % sous la moyenne des étés — tuerait l'hypothèse. »

Le test (exécuté, en une ligne, à titre d'annonce — la méthode est au C03) :

```

moyenne des 8 étés : 853 consultations/mois
moyenne des hivers : 655 consultations/mois
autres mois       : 727 consultations/mois
été le plus bas   : 834 | mois max : 2025-07 (882)

```

L'hypothèse est **portée** (853 vs 655, et les 8 étés serrés entre 834 et 882) — mais la conclusion n'est **pas** « c'est la saison des pluies » : c'est « **les données sont compatibles avec** une saisonnalité, testée aux étés 2025-2026 » — la conclusion **provisoire** (C01 §5.5), avec ses limites (2 étés seulement, cause hors fichier).

À retenir. Une hypothèse se **cadre** (une phrase falsifiable, une signature chiffrée, un contre-exemple nommé) **avant** de se tester. Tester d'abord, formuler après, c'est choisir l'hypothèse qui colle aux chiffres — c'est du C05 §5.2 qu'on appelle un **piège d'inférence**.

6. Exemple concret — le défaut M12 prouvé par la récurrence

Le stock négatif le plus fort (−12, médicament M12, 2026-11-03) est prouvé défaut de saisie par **deux preuves indépendantes** (exécuté) :

Preuve 1 — la borne métier. Un stock ne peut pas être négatif : la pharmacie n'a pas « moins de 12 boîtes », elle a **zéro boîte** et une erreur de saisie.

Preuve 2 — la récurrence du flux. Le stock suit hier + entrées − sorties = aujourd'hui. Sur les 3 jours autour du défaut :

date	id_medicament	entree	sortie	stock_fin
2026-11-02	M12	0	3	548
2026-11-03	M12	0	3	-12 <-- défaut
2026-11-04	M12	0	4	541

$548 + 0 - 3 = 545$, pas −12 : la valeur « naturelle » du 2026-11-03 est **545**. Et le lendemain confirme : $545 - 4 = 541$ — la série **continue comme si le défaut n'avait jamais existé**. Un stock réellement à −12 ne pourrait pas « ressusciter » à 541 le jour suivant **sans 553 entrées** ; il n'y en a pas. La valeur −12 est un défaut de saisie, et sa valeur correcte est **déductible** (545) — la correction se décide au C04.

7. Démonstration pas à pas — 5 étapes sur le centre de santé

```
import pandas as pd
s = "03_exercices/dossier_M09/sante"
cons = pd.read_csv(s + "/consultation.csv")
stk = pd.read_csv(s + "/stock_medicament.csv")
med = pd.read_csv(s + "/medicament.csv")

# 1 – formes (contrôle de chargement)
print(cons.shape, stk.shape, med.shape)

# 2 – audit consultation : 3 familles + clés
print(int(cons["motif"].isna().sum()),
      int((cons["date_consultation"] > "2026-12-31").sum()),
      int(cons["id_patient"].nunique()))

# 3 – audit stock : 3 familles + récurrence du défaut le plus fort
print(int(stk.duplicated().sum()), int((stk["stock_fin"] < 0).sum()))
m12 = stk[stk["id_medicament"] == "M12"].sort_values("date")
print(m12[m12["date"].between("2026-11-02", "2026-11-04")].to_string(index=False))

# 4 – statistiques : fréquentation + describe du stock
pj = cons.groupby("date_consultation").size()
print(round(pj.mean(), 2), pj.median())
print(stk["stock_fin"].describe().min())

# 5 – cadrage : moyennes par saison (le test est au C03)
cj = pd.to_datetime(cons["date_consultation"])
mj = cons.assign(m=cj.dt.to_period("M")).groupby("m").size()
print(round(mj[mj.index.month.isin([6, 7, 8, 9])].mean()),
      round(mj[mj.index.month.isin([12, 1])].mean()))
```

```
(18818, 7) (8767, 5) (12, 4)
23 1 1500
7 4
   date id_medicament  entree  sortie  stock_fin
2026-11-02          M12      0      3         548
2026-11-03          M12      0      3         -12
2026-11-04          M12      0      4         541
25.74 29.0
-12.0
853 655
```

8. Erreurs fréquentes

1. **Compter les doublons sans les définir** — `duplicated()` (toutes colonnes) vs `duplicated(subset=clés métier)` : 0 vs 8 sur `vente.csv` (C01), 7 vs 7 sur le stock. La définition précède le chiffre, toujours.
2. **Prendre l'audit vide comme feu vert** — 0 manquant sans les 3 contrôles du §5.2 (colonnes, chaînes vides, clés) n'est pas un résultat, c'est une **hypothèse** — et l'hypothèse la plus chère qu'on puisse laisser courir.
3. **Publier la moyenne seule** — 25.74 de moyenne, 29.0 de médiane : publier l'une sans l'autre, c'est choisir **pour** le lecteur. Sur une distribution asymétrique, les deux vont, ou aucune ne va seule.
4. **Formuler l'hypothèse après le test** — « les étés font 853, les hivers 655, donc c'est saisonnier » : c'est l'hypothèse **choisie pour coller** aux chiffres. Le cadre falsifiable (§5.5) est écrit **avant**, et il nommait son contre-exemple.

5. **Traiter l'anomalie à la borne** — « -12 est sous la borne de Tukey, on supprime » : la borne **signale**, elle ne **décide** pas. 442 (M12) est aussi sous la borne et est un stock plausible — le traitement sans preuve métier, c'est le C04 en avance, fait mal.

9. Bonnes pratiques professionnelles

1. **L'audit se publie avant la statistique** — le rapport P2 présente d'abord les défauts chiffrés (définition exacte + chiffre), ensuite les statistiques : un chiffre calculé **avec** des doublons n'a pas besoin d'être présenté, il a besoin d'être recalculé.
2. **Chaque défaut porte une définition exacte** — « 7 doublons » n'est pas publiable ; « 7 lignes de `stock_medicament.csv` dont le 5-tuple (date, médicament, entrées, sorties, stock) est identique » l'est. Le correcteur relit la définition, pas le chiffre.
3. **min et max d'un describe() se lisent en premier** — c'est là que les bornes métier se trompent (-12) et que les valeurs impossibles se trahissent (22.5 sur 20 au C05).
4. **Une statistique, une question** — la médiane pour « le jour typique », la moyenne pour « la capacité d'achat », l'iqr pour « la variabilité du cœur » : publier 40 statistiques sans questions, c'est de l'exploration déguisée en rapport.
5. **L'hypothèse s'écrit, ne se pense pas** — une phrase falsifiable, une signature chiffrée, un contre-exemple nommé : ce qui n'est pas écrit n'est pas testable, et ce qui n'est pas testable n'entre pas dans la note.

Conseil professionnel. Dans un rapport d'audit, la ligne la plus précieuse n'est pas « 7 doublons trouvés », c'est « **7 doublons, donc 8 760 lignes propres après dédoublonnage, et voici la ligne qui justifie le keep** ». Le chiffre brut est pour vous ; le chiffre **traité et justifié** est pour le lecteur.

10. Exercice guidé — « les 4 défauts du centre de santé » (25 min, /10)

Consigne. Sans ouvrir `ATTENDU.json`, sur `sante/consultation.csv` et `sante/stock_medicament.csv` :

1. Trouvez et **chiffrez** les 4 familles de défauts (1 pt chacune, 4 pts).
2. Écrivez la **définition exacte** de chacun (1 pt — la définition sans le chiffre ne compte pas, le chiffre sans la définition non plus). (3 pts)
3. Pour **D4 (stock négatif)** : donnez la preuve par récurrence du cas le plus fort, avec les 3 lignes exécutées. (2 pts)
4. Donnez pour chaque défaut la **décision** du rapport : corriger / exclure en documentant / garder en signalant — et en une phrase pourquoi. (1 pt)

11. Exercices autonomes

E1 — Le parallèle SQL du dédoublonnage (20 min). En DuckDB sur `stock_medicament.csv` : (1) `COUNT(*)` vs le nombre de 5-tuples distincts (l'écart doit donner le nombre de doublons) ; (2) une requête unique qui liste les 4 stocks négatifs (médicament, date, valeur), triée par gravité. Les deux sorties sont publiées telles que renvoyées par DuckDB.

E2 — Le faux positif de Tukey (20 min). Sur M12 : deux valeurs sous la borne basse (446) — 442 et -12. Pour chacune : statut (point aberrant **confirmé** / simple valeur basse), la preuve (récurrence ou borne métier), et la décision (corriger / exclure / garder en signalant). Indice : 442 est **plausible** — trouvez la phrase qui le prouve sans le chiffre 545.

12. Correction détaillée

Exercice guidé.

1. **Les 4 familles, exécutées** : 23 motifs vides ; 7 doublons de stock ; 1 date future (2027-01-05) ; 4 stocks négatifs (-1, -3, -2, -12).
2. **Les définitions exactes** : celles du tableau §5.3 — le point de vigilance est D2 (« 5-tuple complet identique », pas « même médicament en double ») et D3 (« hors période de l'export », pas « date anormalement tardive »).
3. **La preuve M12** : $548 + 0 - 3 = 545$ (la valeur naturelle), pas -12 ; et $545 - 4 = 541$ le lendemain — la série continue **comme si** le défaut n'existait pas. (Les 3 lignes sont celles du §6.)
4. **Les décisions** : D1 — **garder en signalant** (l'information est perdue, on ne l'invente pas : 23 consultations hors des taux par motif) ; D2 — **exclure en documentant** (7 lignes supprimées, `keep="first"`, la justification est dans le rapport) ; D3 — **exclure de la série temporelle en documentant**, coquille probable pour 2025-01-05 (à confirmer avec la source, C04) ; D4 — **garder en signalant** pour l'instant, correction **déductible** (545 pour M12) décidée au C04 après la preuve.

E1. DuckDB, exécuté :

```
SELECT COUNT(*), COUNT(DISTINCT (date, id_medicament, entree, sortie, stock_fin))
FROM stock;
      lignes  lignes_distinctes
      8767      8760

SELECT id_medicament, date, stock_fin
FROM stock WHERE stock_fin < 0 ORDER BY stock_fin;
id_medicament  date      stock_fin
M12 2026-11-03      -12
M07 2025-10-09      -3
M10 2026-05-21      -2
M05 2025-04-18      -1
```

$8\,767 - 8\,760 = 7$ **doublons** : le parallèle SQL redonne le chiffre pandas (la colonne vertébrale du module, comme la croisée de M08).

E2. 442 — simple valeur basse, **pas** un point aberrant confirmé : c'est un stock de M12 qui se situe juste sous la borne calculée, mais il est **cohérent avec sa récurrence** (le jour et le lendemain se referment sur lui) et **plausible en métier** (M12 tourne autour de 500-560 ; 442 est un jour bas, pas une impossibilité) — décision : **garder**, rien à signaler au rapport (la borne de Tukey n'est qu'un signal, le métier a départagé). **-12** — point aberrant **confirmé** par double preuve (borne métier : un stock négatif n'existe pas ; récurrence : $548 - 3 = 545 \neq -12$ et $545 - 4 = 541$) — décision : **corriger en 545**, la correction étant **déductible** de la récurrence, et le tout documenté au rapport (C04 formalisera la règle).

13. Mini-projet M09.P2 — « Le rapport d'audit en 1 page » (1 h)

Énoncé. Le rapport P2 du projet M09.P commence par les étapes 1 à 4 **sur le centre de santé, en une page** :

- les **formes** des 3 tables (1 ligne) ;
- les **4 défauts** : définition exacte + chiffre + décision (corriger / exclure en documentant / garder en signalant) (4 lignes) ;
- les **3 statistiques** de fréquentation qui répondent à « quand le centre est-il saturé ? » (moyenne, médiane, mois max) (1 ligne) ;

- **1 hypothèse cadrée** (mécanisme, signature chiffrée, contre-exemple) — à tester au C03.

Les 30 minutes restantes : auto-évaluation — chaque défaut a-t-il sa **définition** ? chaque statistique a-t-elle sa **question** ? l'hypothèse est-elle **falsifiable** (son contre-exemple est-il nommé) ? Un rapport à 80 % dont chaque ligne est justifiée passe ; une page « complète » dont une définition manque n'est pas un rapport d'audit.

14. Boîte à outils du chapitre

Boîte à outils. L'audit : `isna().sum()` (+ `str.strip().eq("")` sur les textes), `duplicated(subset=...)` avec sa **définition**, bornes métier et min/max de `describe()`, récurrence du flux. La statistique : `describe()`, `quantile(.25/.75)`, `value_counts()`, moyenne **et** médiane ensemble. Le parallèle : `COUNT(*)` vs `COUNT(DISTINCT ...)` en DuckDB — même nombre, deux écritures.

Besoin	Commande	Chiffre du socle
manquants	<code>col.isna().sum()</code>	23 motifs
doublons	<code>df.duplicated(subset=clés).sum()</code>	7 lignes de stock
hors période	<code>(col_date > fin_période).sum()</code>	1 consultation
hors borne	<code>(col < 0).sum()</code>	4 stocks
récurrence	<code>hier + entree - sortie == aujourd'hui ?</code>	545 ≠ -12 (M12)
forme du cœur	<code>quantile(.75) - quantile(.25)</code>	iqr 14 (consultations/jour)

15. Résumé du chapitre

L'étape 3 du protocole (détecter les problèmes) et l'étape 4 (premières statistiques) sont exécutées sur le centre de santé, qui fait son entrée dans le module : **4 familles de défauts comptables** (23 motifs manquants, 7 doublons de stock sur 8 767 lignes, 1 consultation datée au 2027-01-05, 4 stocks négatifs dont -12) — chacune avec sa **définition exacte**, son chiffre, et sa décision (garder en signalant, exclure en documentant). Le défaut M12 est prouvé **défaut de saisie** par deux preuves indépendantes : la borne métier (un stock négatif n'existe pas) et la récurrence (548 - 3 = 545, pas -12 ; le lendemain, 545 - 4 = 541 — la série continue comme si le défaut n'existait pas). Sur le fil rouge, l'**audit vide** est validé par les 3 contrôles du chapitre (colonnes, chaînes vides, clés refermées) : un zéro non contrôlé n'est pas un feu vert, c'est une hypothèse. La statistique n'est pas un verdict : moyenne 25.74 et médiane 29.0 consultations/jour coexistent (distribution à queue basse), le min -12 d'un `describe()` redécouvre l'audit, et l'iqr cale des bornes qui **signalent** (442 et -12 sous 446 pour M12) sans **décider**. Le chapitre se termine sur la discipline d'écriture : une hypothèse se **cadre falsifiable avant de se tester** — la saisonnalité du centre (étés 853 vs hivers 655 consultations/mois) est posée ainsi, test chiffré au C03.

16. À retenir

À retenir. L'audit **avant** la statistique, la statistique **avant** l'hypothèse testée, et l'hypothèse cadrée **avant** d'être testée : c'est l'ordre des étapes 3, 4 et 8, et c'est tout le chapitre. Chaque défaut porte sa définition exacte, chaque zéro ses 3 contrôles, chaque statistique sa question métier.

1. **3 familles de défauts, 3 contrôles** : doublons (`uplicated(subset=...)` **défini** avant), manquants (`isna + chaînes vides`), valeurs impossibles (borne métier + récurrence).
2. **L'audit vide est suspect** tant que les 3 contrôles du contrôle n'ont pas passé : colonnes, chaînes vides, clés refermées.
3. **Chaque défaut porte une définition exacte** — « 7 doublons » n'est pas publiable, « 7 lignes dont le 5-tuple est identique » l'est.
4. **min/max d'un `describe()` se lisent en premier** — c'est là que le métier se trompe dans la saisie (−12).
5. **Moyenne et médiane vont ensemble** — 25.74 vs 29.0 : l'écart est une information (queue de jours bas), pas un bug.
6. **La borne signale, le métier décide** — 442 est sous la borne et plausible ; −12 est sous la borne et impossible : même test, deux décisions.
7. **Une hypothèse se cadre avant de se tester** — mécanisme, signature chiffrée, contre-exemple nommé ; l'été 20 % sous la moyenne tuerait la saisonnalité.
8. **Le parallèle SQL redonne le chiffre** — `COUNT(*)` 8 767 vs `COUNT(DISTINCT)` 8 760 : 7 doublons, comme en pandas.

17. Évaluation formative (auto-correction, 8 min)

1. **Pourquoi `uplicated()` sans argument a-t-il compté 0 sur `vente.csv` alors que le socle porte 8 doublons ?** → les 8 doublons sont identiques sur les 12 colonnes métier mais portent des `id_vente` différents : le contrôle doit être `uplicated(subset=<12 colonnes métier>)`. (2 pts)
2. **Un audit renvoie 0 manquant sur toutes les colonnes. Que faites-vous avant de publier « fichier propre » ?** → les 3 contrôles du contrôle : `isna` par colonne (pas en somme), chaînes vides sur les colonnes texte, clés refermées sur les tables jointes. (2 pts)
3. **Pourquoi la consultation `C000001` datée au 2027-01-05 est-elle une « hypothèse de saisie » et non une « anomalie de date » ?** → c'est la première référence du fichier et la période commence au 2025-01-05 : la coquille 2025-01-05 est la lecture la plus probable — l'audit compte, la correction se décide après preuve (C04). (2 pts)
4. **Le stock M12 vaut −12 le 2026-11-03, entre 548 et 541. Donnez la preuve par récurrence.** → $548 + 0 - 3 = 545$ (valeur naturelle), pas −12 ; et $545 - 4 = 541$ le lendemain : la série continue comme si le défaut n'existait pas — un stock à −12 ne « ressuscite » pas sans 553 entrées. (2 pts)
5. **Moyenne 25.74, médiane 29.0 consultations/jour. Que dit l'écart, et quelle statistique pour « le jour typique » ?** → une queue de jours peu consultés tire la moyenne vers le bas (les dimanches, min 1) ; « le jour typique » se lit à la **médiane** (29 ou plus le moitié des jours). (2 pts)
6. **Pourquoi l'écart-type de `stock_fin` (557.45) est-il « sans sens » ?** → la colonne mélange 12 médicaments de régimes très différents (insuline ~150, paracétamol ~800) : un écart-type sur un mélange de populations ne mesure rien — la statistique juste est **par médicament**. (2 pts)

7. **M12 a deux valeurs sous la borne basse de Tukey (446) : 442 et -12. Quelle décision pour chacune, et pourquoi la borne n'a pas départagé ?** → 442 : garder (cohérent avec sa récurrence, plausible en métier) ; -12 : corriger en 545 (preuve double). La borne **signale**, le métier **décide** — c'est la récurrence et la borne métier qui départagent. (2 pts)
8. **Écrivez le cadre falsifiable de l'hypothèse « la fréquentation est saisonnière », avec son contre-exemple.** → « Si saison des pluies, les 8 étés ressemblent plus entre eux qu'aux hivers (déc-jan) ; un été 20 % sous la moyenne des étés tue l'hypothèse » — signé, chiffré, testable. (2 pts)

Module M09.C03 — Tendances : la série, la saison, le bruit — et les périodes qu'on a le droit de comparer

Outils : pandas 2.2.3, numpy 2.3.5 (exécutés), DuckDB 1.5.5 (exécuté — le parallèle SQL des tendances). **Durée indicative :** 5 h. **Niveau :** N3. **Prérequis :** M09.C01-C02 (protocole, audit), M02 (statistiques), M08 C08 (resample, set_index), M07 (le GROUP BY mois SQL) utile.

L'idée du chapitre. L'étape 5 du protocole pose la question : « **ça monte, ça descend, ça cycle ?** » C03 y répond avec une discipline : décomposer une série en **tendance / saisonnalité / bruit** (à l'œil et au chiffre), ne comparer que des périodes à **taille égale** (le 28 décembre du socle est le contre-exemple chiffré), et savoir déclarer une tendance **absente** — la quincaillerie du fil rouge est quasi plate, et c'est exactement ce que le chapitre doit apprendre à dire. Le centre de santé, lui, porte la vraie saisonnalité : le pic de juillet (882 consultations), le creux du dimanche (405) et du midi (927), et la rupture de stock qui **coupe** une tendance sans la **retomber**.

Matériel de l'atelier — Python 3.13 · pandas 2.2.3 · numpy 2.3.5 · DuckDB 1.5.5. Toutes les commandes ont été exécutées dans l'atelier le 20/09/2026 sur 03_exercices/dossier_M09/ (graine 45, déterministe, ATTENDU.json figé) ; les sorties publiées sont **celles de l'atelier**.

1. Objectifs du chapitre

À la fin de ce chapitre, vous savez :

1. **Construire la série simple** en pandas : `set_index` + `resample` (le 'ME' de M08) — et reconstruire la vue mensuelle de M07/M08 (120 lignes : 5 magasins × 24 mois) sans SQL.
2. **Décomposer une série** en tendance, saisonnalité et bruit — à l'œil (moyenne glissante) **et** au chiffre (amplitude de la saison vs variabilité résiduelle).
3. **Comparer des périodes à taille égale** : à mois égal, au flux par jour — et identifier la **période partielle** qui ment (le décembre 2026 du socle, arrêté au 28).
4. **Lire la saisonnalité du jour de semaine et de l'heure** (`dayofweek == 6`, rappel M08) : le dimanche du centre (405 consultations), la journée type, le creux du midi.
5. **Distinguer structurel et bruit** — et **déclarer l'absence** de tendance (une étape vide se déclare, C01) : la quincaillerie n'a pas de saison des fêtes, et ça se dit.
6. **Reconnaître la tendance interrompue** : la rupture de stock qui coupe la courbe sans la retomber (M02, 5 jours à zéro — la demande revient au même niveau au restock).

2. Pourquoi cette notion est importante

Toutes les décisions de prévision de capacité partent de la lecture d'une courbe : commander des médicaments pour l'été, prévoir du personnel pour le pic du matin, arbitrer un budget magasin par magasin. Une lecture fausse de la tendance — prendre le bruit pour une saison, la saison pour une dérive, une période partielle pour une année — transforme une exploration en **erreur de prévision** : le centre de santé qui achète à l'aveugle sur juillet 2025 fera le stock de toute la saison des pluies sur un seul mois.

Trois faits mesurés sur le socle fixent l'enjeu :

- la **quincaillerie** (fil rouge) est **quasi plate** : 24 mois entre 313 M et 348 M de FCFA (écart-type 10.8 M), **pas de pic de fin d'année** (décembre 2025 : 315 M, janvier 2026 : 330 M), et une dérive de **+1.6 % à mois égal** (2026/2025) — ce chapitre doit apprendre à **dire** « plat », pas à inventer une saison ;
- le **centre de santé** (jeu 2, arrivé en C02) porte la saisonnalité **structurelle** : les 8 mois d'été (juin-sept) font en moyenne **853** consultations par mois contre **655** pour les hivers — un écart d'environ 198, **quatre fois** la variabilité intra-été (834 à 882) ;
- le **28 décembre 2026** : la base s'arrête là — décembre 2026 fait 307 M « au total » (donc « en baisse » vs 315 M en 2025), mais par **jour** il fait 11.0 M contre 10.2 M : **+8 %**, pas une baisse. La période partielle est le mensonge du chapitre.

3. Explication simple — la conversation avec la machine

La machine est un **fleuve** vu du pont, et la question « ça monte, ça descend, ça cycle ? » s'en répond en séparant **trois choses** :

1. **Le lit du fleuve** (la tendance) : le niveau moyen sur la durée. Ici : le CA de la quincaillerie monte d'environ 1.6 % en un an, à mois égal — un lit qui s'élève à peine.
2. **Les crues saisonnières** (la saisonnalité) : le niveau qui revient **chaque cycle**, au même endroit. Ici : le centre de santé crue chaque été (paludisme, fièvre, diarrhées de la saison des pluies) — juillet 2025 : 882 consultations, le pic de la série.
3. **Les vagues** (le bruit) : le tremblement du niveau **sans cycle**. Ici : les mois qui s'égarent de ± 10 M FCFA autour de la moyenne 328 M — du vent, pas une saison.

La moyenne glissante est la **bâche à vagues** : on l'étale sur 3 mois, les vagues s'effacent, le lit et les crues restent. Et la règle d'or du chapitre : **on ne compare jamais deux portions de fleuve de longueurs différentes** — décembre 2026 compte 28 jours, décembre 2025 en compte 31 : « 307 M < 315 M » n'est pas une baisse, c'est une mesure inégale.

4. Vocabulaire essentiel

Terme	Définition
tendance	la pente de fond de la série (ce qui reste quand on a retiré les cycles) : lecture par la moyenne glissante et la comparaison à période égale.
saisonnalité	saisonnalité — la variation régulière et prévisible liée au cycle (saison, mois, jour de semaine, heure) : elle revient au même endroit du cycle, c'est ce qui la rend exploitable.
bruit	la variabilité sans cycle : ce que la moyenne glissante lisse — on ne le « prédit » pas, on le borne (amplitude, écart-type).
moyenne glissante — moving average — la moyenne calculée sur une fenêtre glissante (ici 3 mois) : chaque point résume la fenêtre, les vagues s'effacent, le lit reste.	

5. Cours approfondi

5.1 La série simple — `set_index + resample` (le 'ME' de M08)

La vue mensuelle de M07/M08 se reconstruit en pandas **sans SQL** (exécuté, fil rouge) :

```
import pandas as pd
v = pd.read_csv("03_exercices/dossier_M09/quincaillerie/vente.csv",
                parse_dates=["date_vente"])
v["ct"] = (v["montant_ttc"] * 100).round().astype("int64") # centimes : exact
sans = v[~v["est_retour"]] # définition M07 : sans retours
vue = sans.groupby([sans["date_vente"].dt.to_period("M"), "id_magasin"])[["ct"].sum() // 100
print(len(vue.reset_index()), "lignes")
print(vue.nlargest(1).to_string())
```

```
120 lignes
montant_ttc
2025-08    3    78965529
```

120 lignes : 5 magasins × 24 mois — la vue M07 est une vue **par magasin**, et la plus grosse cellule est **2025-08 × magasin 3 = 78 965 529 FCFA** (le S2 de M07 C08), sans retours. Le parallèle SQL redonne le même nombre, exécuté en DuckDB :

```
SELECT strftime(date_vente, '%Y-%m') AS mois, id_magasin,
       CAST(SUM(CASE WHEN NOT est_retour THEN ct ELSE 0 END)/100 AS BIGINT) AS ca
FROM vente GROUP BY 1, 2 ORDER BY ca DESC LIMIT 1;
-- 2025-08 | 3 | 78965529
```

Même nombre, deux écritures — la colonne vertébrale du module, comme le dédoublement en C02 : GROUP BY mois (M07) et resample/groupby (pandas) produisent la même série.

Définition. tendance — la pente de fond de la série : ce qui reste quand on a retiré les cycles. Elle se lit à la **moyenne glissante** (qui lisse les vagues) et à la **comparaison à période égale** (à mois égal, au flux par jour) — jamais sur des totaux de périodes inégales.

5.2 Décomposer tendance / saisonnalité / bruit — à l'œil et au chiffre

La moyenne glissante 3 mois sur la vue mensuelle (exécuté, extraits) :

2025-03	328 M	mg3	330 M	2026-04	335 M	mg3	336 M
2025-08	346 M	mg3	326 M	2026-06	348 M	mg3	337 M
2025-12	315 M	mg3	322 M	2026-12	307 M	mg3	324 M

Lecture à l'œil : les vagues (312-348 M) s'effacent sous la bâche (320-337 M) — et la bâche **ne cycle pas** : pas de creux de décembre, pas de crête d'été. La série est plate avec une très légère dérive.

Lecture au chiffre — c'est elle qui départage structurel et bruit :

- l'**amplitude brute** (min-max) de la série est de 41 M FCFA autour d'une moyenne de 328 M ;
- l'**amplitude de la bâche** n'est que de 17 M : les 2/3 de l'amplitude sont du **vent** (bruit), pas du cycle ;
- l'**écart-type** des 24 mois est de 10.8 M, et la **comparaison à mois égal** 2026/2025 tourne autour de **1.0** (de 0.963 à 1.120, moyenne 1.016) : une dérive de +1.6 % en un an, pas une pente.

La règle du chapitre : un cycle est **structurel** quand l'écart **entre** ses positions (été vs hiver) est **grand** comparé à la variabilité **dans** chaque position. Sur le centre de santé (exécuté) : les 8 étés sont serrés entre 834 et 882 (variabilité d'environ 48), et les hivers tournent autour de 655 — l'écart entre positions (≈ 198) **domine** la variabilité intra-position : la saisonnalité est **structurelle**, pas du bruit qui ressemble à une saison.

Définition. moyenne glissante — moving average — la moyenne calculée sur une **fenêtre glissante** (ici 3 mois) : chaque point résume sa fenêtre, les vagues s'effacent, le lit et les crues restent. Sa fenêtre se **déclare** dans la légende (3 mois, pas 6) : une bâche sans fenêtre est une moyenne sans définition.


Définition. bruit — la variabilité **sans cycle** : ce que la moyenne glissante lisse. On ne le « prédit » pas, on le **borne** (amplitude brute, écart-type) — et on vérifie qu'il est **petit** devant l'écart entre positions avant de parler de cycle.

Attention. Ne pas forcer une saison sur une série plate : la quincaillerie n'a pas de pic décembre/janvier (315 M / 330 M, sous la moyenne 328 M) — dire « c'est la saison des fêtes » parce que « normalement il y en a une », c'est importer la saison d'un autre jeu dans les données. Le cycle se **mesure** (amplitude entre positions vs variabilité intra-position), il ne se présume pas.

Définition. saisonnalité — saisonnalité — la variation **régulière et prévisible** liée au cycle (saison, mois, jour de semaine, heure) : elle revient **au même endroit du cycle**, c'est ce qui la rend exploitable pour la prévision. Un pic qui revient chaque juillet est de la saison ; un pic qui revient « de temps en temps » est un événement (C04), pas une saison.

Décomposer une série : le lit (tendance), les crues (saison), les vagues (bruit)

La bâche (moyenne glissante) pour le lit ; l'amplitude entre positions vs intra-position pour la saison.



La règle du chapitre

Un cycle est **STRUCTUREL** quand
l'écart **ENTRE** positions domine
la variabilité **DANS** chaque position :

été vs hiver : environ 198
variabilité intra-été : environ 48

198 >> 48 (x4) : la saison est
structurelle, pas du bruit.

Fil rouge (quincaillerie) : la
bâche n'est qu'à 17 M d'amplitude
vs 10.8 M d'écart-type : PLAT,
+1.6 % à mois égal — déclaré.

Le zéro-fait : rupture M01 (3 j)
au pic de juillet — tendance
interrompue, pas retombée.

Le mois partiel ment (décembre 2026 : 28 jours)

total : 307 M < 315 M (2025) — « baisse » ?

flux par jour : 11.0 M vs 10.2 M — en réalité +8 %.

Règles : comparer à MOIS ÉGAL, ou au flux
par jour — ou DÉCLARER « aucune conclusion »
(l'étape se déclare, elle ne se saute pas).

5.3 Comparer des périodes à taille égale — le 28 décembre qui ment

Le socle s'arrête au **2026-12-28** : décembre 2026 compte **28 jours**, décembre 2025 en compte 31. La comparaison « naïve » des totaux (exécuté) :

décembre 2025 : 315 M FCFA sur 31 jours	
décembre 2026 : 307 M FCFA sur 28 jours	<-- « en baisse » ?
CA par jour 2025 : 10.2 M FCFA	
CA par jour 2026 : 11.0 M FCFA	--> en réalité : +8 %

Le total dit « baisse », le **flux par jour** dit « hausse de 8 % » : c'est la **période partielle** qui ment, pas les données. Les deux règles du chapitre :

1. **À mois égal** pour comparer deux années : 2026/2025 mois par mois, les ratios vont de 0.963 à 1.120 (moyenne 1.016) — on compare janvier à janvier, pas « l'année 2026 » à « l'année 2025 » quand l'une des deux n'est pas finie.
2. **Au flux par jour** pour comparer des mois inégaux (28 vs 31 jours) — ou, mieux, on **ne compare pas du tout** et on le dit : « décembre 2026 est partiel, aucune conclusion de tendance » — l'étape se déclare, elle ne se saute pas (C01).

À retenir. Avant de comparer deux périodes, on les **pèse** : combien de jours chacune contient-elle ? 31 vs 28, 365 vs 362 — si elles ne pèsent pas le même, on compare **à mois égal**, **au flux par jour**, ou on **déclare** la comparaison impossible. Pesez avant de peser.

Attention. Un total de période partielle est une **mesure inégale** : 307 M sur 28 jours n'est pas « un décembre de 307 M ». Comparer 2025 (365 jours) et 2026 (362 jours dans le socle) « en tout », c'est comparer deux portions de fleuve de longueurs différentes — et conclure sur la différence.

5.4 La saisonnalité du jour de semaine et de l'heure — le centre de santé

Le rappel `dayofweek == 6` de M08 trouve ici sa vraie utilisation : les 18 818 consultations réparties par jour de semaine (exécuté) :

lundi	3710	jeudi	3100	dimanche	405
mardi	3290	vendredi	1872	(uniforme : 2688/jour)	
mercredi	3249	samedi	3192		

Le dimanche du centre fait 405 consultations contre 3 710 le lundi — environ 1/9 du lundi, et 15 % de ce que donnerait une répartition uniforme (2 688) : le centre est **presque fermé le dimanche**, mais pas tout à fait (405, pas 0) — c'est la saisonnalité du jour, structurelle comme la saison (elle revient chaque semaine).

La **journée type** (10 heures de 08:00 à 17:00, exécuté) :

08:00	1673	10:00	2203	12:00	927	14:00	2126
09:00	2319	11:00	2044	13:00	1085	15:00	2119
16:00	2030	17:00	2292				

Le pic est le **matin** (09:00 : 2 319), le creux est le **midi** (12:00 : **927** — 4.9 % des consultations contre 10 % attendus en répartition uniforme), et l'après-midi est **stable** (2 030 à 2 292). Une journée type, c'est une saisonnalité **d'heure** : elle réorganise les gardes, pas les stocks.

5.5 La tendance interrompue — la rupture qui coupe sans retombée

Le stock M02 (paracétamol) autour du 2026-03-02 (exécuté) :

date	id_medicament	entree	sortie	stock_fin	
2026-02-28	M02	0	7	1288	
2026-03-01	M02	0	11	1277	
2026-03-02	M02	100	1377	0	<-- tout le stock sort
2026-03-03	M02	0	0	0	<-- 5 jours à zéro
2026-03-04	M02	0	0	0	
2026-03-05	M02	0	0	0	
2026-03-06	M02	0	0	0	
2026-03-07	M02	68	7	61	<-- le restock, la demande revient
2026-03-08	M02	0	4	1344	
2026-03-09	M02	0	11	1333	

La lecture **tendancielle** : les sorties (la demande) faisaient environ 7/jour en février (moyenne 6.7) — pendant les 5 jours de rupture, elles sont **nulles** (on ne distribue pas ce qu'on n'a pas) — et elles **reviennent** au même niveau au restock (7, 4, 11 les trois jours suivant ; moyenne de mars hors rupture : 5.6/jour). La courbe des sorties plonge à zéro **non pas parce que la demande est retombée, mais parce que l'offre est coupée** : c'est une **tendance interrompue, pas une tendance retombée** — confondre les deux, c'est prévoir une baisse de fréquentation qui n'existe pas.

La rupture M01 (3 jours, 2025-07-14 → 2025-07-16) est le même mécanisme **au pire moment** : pendant le **pic de juillet** (882 consultations, le mois max de la série) — la lecture tendancielle est identique (la demande revient au restock), la **décision métier** est au C04 : une rupture de paracétamol en saison des pluies est un signal à traiter, pas un chiffre à corriger.

Dans les faits. Sur le fil rouge, l'étape « tendances » se termine par une **déclaration vide** : « aucune saisonnalité détectée — contrôle : amplitude de la bâche 17 M vs écart-type 10.8 M, ratios à mois égal 0.963–1.120, pas de pic décembre/janvier (315 M / 330 M) ». C'est une étape **vide, déclarée** — pas une étape passée : le protocole (C01) le distinguait, le rapport le prouve.

6. Exemple concret — la quincaillerie : dire « plat », et le prouver

Le fil rouge traverse l'étape 5 en entier (exécuté, sans retours, définition M07) :

1. **La série** : 24 mois, 307 à 348 M FCFA, moyenne 328 M, écart-type 10.8 M ; la vue par magasin fait **120 lignes**, plus grosse cellule **78 965 529 FCFA** (2025-08, magasin 3) — le même nombre que le GROUP BY de M07.
2. **Le lit** : la moyenne glissante 3 mois tourne entre 320 et 337 M — **pas de cycle** sous la bâche ; la comparaison à mois égal 2026/2025 (moyenne 1.016, de 0.963 à 1.120) donne la seule tendance **mesurable** : **+1.6 % en un an**.
3. **La saison déclarée absente** : décembre 2025 (315 M) et janvier 2026 (330 M) ne montent **pas** au-dessus de la moyenne — **pas de saison des fêtes dans ces données** ; l'hypothèse « fin d'année » est testée et **rejetée sur la période**, avec le chiffre qui la rejette (315 < 328, la moyenne).
4. **Le mois partiel** : décembre 2026 (307 M sur 28 jours) ne se compare **pas** à décembre 2025 « au total » ; au flux par jour, c'est +8 % — et la conclusion honnête est « décembre 2026 partiel : aucune conclusion de tendance ».

7. Démonstration pas à pas — 5 étapes sur les deux jeux

```
import pandas as pd
s = "03_exercices/dossier_M09"
v = pd.read_csv(s + "/quincaillerie/vente.csv", parse_dates=["date_vente"])
c = pd.read_csv(s + "/sante/consultation.csv", parse_dates=["date_consultation"])

# 1 – la série mensuelle (fil rouge, sans retours)
v["ct"] = (v["montant_ttc"] * 100).round().astype("int64")
vt = v[~v["est_retour"]].groupby(
    v["date_vente"].dt.to_period("M"))["ct"].sum() // 100
print(len(vt), "mois | moyenne M:", round(vt.mean() / 1e6))

# 2 – la bêche : moyenne glissante 3 mois
mg3 = vt.rolling(3).mean()
print("amplitude brute M:", round((vt.max() - vt.min()) / 1e6),
      "| amplitude mg3 M:", round((mg3.max() - mg3.min()) / 1e6))

# 3 – à mois égal 2026/2025
r = vt[vt.index.year == 2026].values / vt[vt.index.year == 2025].values
print("ratios 2026/2025 : min", round(r.min(), 3), "| max", round(r.max(), 3),
      "| moyenne", round(r.mean(), 3))

# 4 – le mois partiel : flux par jour
d26 = v[(v["date_vente"] >= "2026-12-01")]["ct"].sum() / 100 / 28
d25 = v[(v["date_vente"] >= "2025-12-01") & (v["date_vente"] < "2026-01-01")]["ct"].sum() / 100 / 31
print("CA/jour déc26 M:", round(d26 / 1e6, 1), "| déc25 M:", round(d25 / 1e6, 1))

# 5 – la saison du centre : jour de semaine + heure
c["dw"] = c["date_consultation"].dt.dayofweek
print(c.groupby("dw").size().to_dict())
print(c.groupby("heure").size().loc["12:00"])
```

```
24 mois | moyenne M: 328
amplitude brute M: 41 | amplitude mg3 M: 17
ratios 2026/2025 : min 0.963 | max 1.12 | moyenne 1.016
CA/jour déc26 M: 11.0 | déc25 M: 10.2
{0: 3710, 1: 3290, 2: 3249, 3: 3100, 4: 3192, 5: 1872, 6: 405}
927
```

8. Erreurs fréquentes

1. **Forcer une saison sur une série plate** — la quincaillerie n'a pas de pic de décembre (315 M) : dire « c'est de la saisonnalité des fêtes » parce que « normalement il y en a », c'est importer une saison **d'un autre jeu** dans les données. Le cycle se **mesure** (amplitude entre positions vs variabilité intra-position), il ne se **présuppose** pas.
2. **Comparer des périodes inégales** — 307 M (28 jours) vs 315 M (31 jours) « en baisse » ; l'année 2026 (362 jours dans le socle) vs 2025 « en tout » : chaque total de période partielle est une mesure inégale, et chaque comparaison d'inégaux est une **conclusion fautive avec de vrais chiffres**.
3. **Lire la tendance sur le bruit** — un mois à 348 M (juin 2026) suivi d'un mois à 327 M n'est pas « ça descend » : c'est de l'amplitude (± 10 M autour de 328) — la bêche (17 M d'amplitude sur la moyenne glissante) est là pour le dire avant l'œil.
4. **Confondre tendance interrompue et tendance retombée** — les sorties de M02 tombent à 0 pendant 5 jours : ce n'est pas une chute de la demande, c'est une offre coupée (la demande revient à 7/jour au restock) — la prévision qui en déduirait une baisse de fréquentation commanderait trop pour mars.

5. **Oublier le jour de semaine** — une moyenne « par jour » qui mélange dimanches (405) et lundis (3 710) dilue la saisonnalité la plus forte du jeu santé : la série **par jour de semaine** précède la série par date, ou elle la trahit.

9. Bonnes pratiques professionnelles

1. **La série se construit avant d'être lue** : définition de l'agrégat (sans retours ?), de la granularité (mois), du périmètre (magasins) — la vue mensuelle de M07 se reconstruit en 3 lignes **si la définition est la même** ; sinon le nombre ne retombe pas (78 965 529 exige « sans retours »).
2. **Tendance = bâche + comparaison à période égale** — les deux lectures, ensemble : la moyenne glissante pour le lit, le ratio à mois égal pour la pente ; l'une sans l'autre est une impression.
3. **Un cycle se prouve par l'amplitude** — écart entre positions (été vs hiver : 198) vs variabilité intra-position (été : 48) : le premier doit **dominer** le second, sinon c'est du bruit qui ressemble à une saison.
4. **Le mois partiel se déclare, ne se compare pas** — « décembre 2026 : 28 jours, aucune conclusion de tendance ; au flux par jour, +8 % » — les deux phrases, c'est la pratique complète.
5. **L'étape vide se déclare avec ses contrôles** — « aucune saisonnalité détectée : amplitude de la bâche 17 M vs 10.8 M d'écart-type, ratios 0.963-1.120 » : la négation prouvée vaut plus qu'une courbe vague.

Conseil professionnel. Le graphique de tendance d'un rapport P3 porte **trois lignes**, pas une : la série brute (les vagues), la moyenne glissante (le lit), et la saison attendue (les crues) — quand la troisième n'existe pas, on le **dit** sur le graphique, et on ne la dessine pas. Un graphique à une ligne invite le lecteur à inventer ce que vous n'avez pas prouvé.

10. Exercice guidé — « lire la saison du centre de santé » (25 min, /10)

Consigne. Sur `sante/consultation.csv` (18 818 lignes, défauts C02 déjà audités) :

1. Construisez la série **par mois** de consultations (1 pt).
2. Donnez les **8 étés** (juin-sept, 2025 et 2026) et les **hivers** (déc-jan) : leur moyenne, leur amplitude — et concluez si la saisonnalité est **structurelle** ou du bruit, avec les deux chiffres qui le départagent (3 pts).
3. Montrez la saisonnalité **du jour de semaine** : la valeur du dimanche, celle du lundi, et ce que donnerait une répartition uniforme (2 pts).
4. Donnez la **journée type** : l'heure de pic, l'heure de creux, la valeur du creux, et l'attendu uniforme (2 pts).
5. En une phrase : qu'est-ce que cette saisonnalité change **concrètement** au centre (1 pt) ?

11. Exercices autonomes

E1 — Le parallèle SQL des tendances (20 min). En DuckDB sur `quincaillerie/vente.csv` : (1) la série mensuelle du CA **sans retours** (24 lignes) ; (2) la plus grosse cellule (mois, magasin) — elle doit retomber sur 78 965 529 ; (3) les ratios 2026/2025 à mois égal (min, max, moyenne). Les trois sorties sont publiées telles que renvoyées.

E2 — La rupture qui coupe (20 min). Sur `sante/stock_medicament.csv`, médicament M02 : (1) listez les jours de rupture (stock à zéro) et leurs dates ; (2) comparez le niveau des sorties **avant** (février 2026) et **après** (mars 2026, hors rupture) la rupture ; (3) concluez : tendance retombée ou tendance interrompue, avec les deux chiffres qui le prouvent ; (4) en une phrase, ce que la prévision de mars 2027 **ne doit pas** en déduire.

12. Correction détaillée

Exercice guidé.

1. **La série par mois** : `groupby(to_period("M")).size()` — 24 mois, de 2025-01 à 2026-12, **décembre 2026 partiel** (28 jours) : on le garde dans la série et on le **déclare** partiel (§5.3), on ne le compare pas « au total ».
2. **Étés vs hivers** : moyenne des 8 étés **853** consultations/mois, amplitude 834-882 (≈ 48) ; hivers (déc-jan) **655** ; l'écart entre positions (≈ 198) domine la variabilité intra-été (48) d'un facteur $\sim 4 \rightarrow$ **structurelle**.
3. **Jour de semaine** : dimanche **405**, lundi **3 710**, uniforme **2 688** ($18\,818 / 7$) — le dimanche est à 15 % de l'uniforme : le centre est presque fermé, pas fermé.
4. **Journée type** : pic **09:00** (2 319), creux **12:00** (**927** = 4.9 % contre 10 % attendu uniformément sur les 10 heures) — le creux est le double de l'écart attendu : c'est un creux réel, pas du bruit.
5. **Le concret** : les gardes et la distribution des médicaments se calent sur le pic du matin et l'été (paludisme/fièvre) — pas sur « la moyenne du jour », qui dilue tout.

E1. DuckDB, exécuté :

```
-- (1) série mensuelle sans retours : 24 lignes, 2025-01 → 2026-12
-- (2) plus grosse cellule :
2025-08 | 3 | 78965529
-- (3) ratios 2026/2025 à mois égal (self-join sur mois) :
min 0.963 | max 1.12 | moyenne 1.016
```

Le `GROUP BY mois` de M07 et le `groupby(to_period("M"))` pandas redonnent **la même série** : même nombre, deux écritures — la constance du socle (empreinte `b9a8d973119342ec...`, 19 totaux = M07/M08) passe encore une fois par la porte des tendances.

E2. (1) Rupture M02 : **5 jours**, du **2026-03-02 au 2026-03-06** (stock à zéro ; le 2026-03-02, tout le stock sort en une sortie unique, ce que le C04 qualifiera). (2) Sorties/jour : **6.7** en février 2026, **5.6** en mars 2026 hors rupture — même niveau (l'écart de 1.1/jour est de l'ordre du bruit quotidien). (3) **Tendance interrompue, pas retombée** : pendant la rupture, les sorties sont **nulles par contrainte d'offre** (on ne distribue pas ce qu'on n'a pas) ; au restock (2026-03-07), elles reviennent à 7, 4, 11 — le niveau de février. (4) La prévision de mars 2027 **ne doit pas** déduire une baisse de demande : elle doit prévoir **le niveau de sortie habituel** ($\approx 6\text{-}7/\text{jour}$) **plus** le restock — et signaler le risque de rupture, pas une chute de fréquentation.

13. Mini-projet M09.P3 — « Le graphique de tendance avec sa question » (1 h)

Ancre P3 : les 4 graphiques du projet M09.P doivent répondre à une question — celui-ci est le premier d'entre eux : « ça monte, ça descend, ça cycle ? »

Énoncé. Sur le centre de santé, produire **un** graphique de tendance (courbe) qui répond à « ça monte, ça descend, ça cycle ? », **légendé** : question posée + source (sortie exécutée) + ce qu'on

doit retenir. Le graphique porte les **trois lignes** du conseil §9 (série mensuelle, moyenne glissante, et — ici — la saison lisible) et sa légende **déclare** : la saisonnalité structurelle (étés 853 vs hivers 655), le pic 2025-07 (882), le mois partiel de 2026-12 (aucune conclusion). Auto-évaluation : chaque légende est-elle **vérifiable** sur le socle ? Le mois partiel est-il **déclaré** plutôt que comparé ?

14. Boîte à outils du chapitre

Boîte à outils. La série : `to_period("M") + groupby` (ou `set_index + resample("ME")`), centimes pour l'exactitude (`(montant*100).round() // 100`). La bêche : `rolling(3).mean()`. La comparaison : ratios à mois égal (`série_2026.values / série_2025.values`), flux par jour pour les mois inégaux. La saison : `dayofweek, groupby("heure")`. Le parallèle : `GROUP BY strftime(date, '%Y-%m')` en DuckDB — même série, deux écritures.

Besoin	Commande	Chiffre du socle
série mensuelle	<code>groupby(to_period("M")).sum()</code>	24 mois, moyenne 328 M
vue par magasin	<code>+ "id_magasin" dans le groupby</code>	120 lignes, max 78 965 529
bêche	<code>vt.rolling(3).mean()</code>	amplitude 17 M (vs 41 M brute)
pente	ratios à mois égal	0.963-1.120, moy 1.016
mois partiel	<code>sum() / nb_jours</code>	11.0 vs 10.2 M/jour (déc 2026/2025)
saison hebdo	<code>groupby(dayofweek).size()</code>	dim 405 / lun 3710
journée type	<code>groupby("heure").size()</code>	creux 12:00 = 927

15. Résumé du chapitre

L'étape 5 du protocole (« ça monte, ça descend, ça cycle ? ») est exécutée sur les deux jeux arrivés jusque-là, avec la discipline du chapitre : **décomposer en tendance / saisonnalité / bruit**, à l'œil (moyenne glissante) et au chiffre (amplitude entre positions vs variabilité intra-position), et **ne comparer que des périodes à taille égale**. Sur le fil rouge (quincaillerie, sans retours, définition M07) : 24 mois entre 307 et 348 M FCFA, moyenne 328 M, écart-type 10.8 M ; la vue par magasin redonne les **120 lignes** de M07 (plus grosse cellule **78 965 529 FCFA**, 2025-08 × magasin 3 — même nombre en `GROUP BY` DuckDB) ; la moyenne glissante 3 mois (amplitude 17 M) et la comparaison à mois égal 2026/2025 (0.963 à 1.120, +1.6 %) disent **plat avec une très légère dérive** ; il **n'y a pas** de saison des fêtes dans ces données (décembre 2025 : 315 M, janvier 2026 : 330 M, sous la moyenne) — et l'étape le **déclare** avec ses contrôles ; décembre 2026 (28 jours) ne se compare pas « au total » à 2025 — au flux par jour, c'est +8 %, et la conclusion est « mois partiel, aucune conclusion de tendance ». Sur le centre de santé : la saisonnalité est **structurelle** (étés 853 vs hivers 655 consultations/mois, pic **2025-07** (882 consultations), variabilité intra-été d'environ 48, l'écart ≈ 198 qui la domine), la saison est aussi **hebdomadaire** (dimanche 405 vs lundi 3 710) et **horaire** (pic 09:00, creux **927** à 12:00) ; et la rupture M02 (5 jours à zéro, 2026-03-02 → 2026-03-06) est une **tendance interrompue, pas une tendance retombée** — la demande revient au même niveau au restock, et c'est la lecture qui sauve la prévision.

16. À retenir

À retenir. Trois lectures avant toute affirmation : la **bâche** (le lit), la **comparaison à période égale** (la pente), l'**amplitude** (la saison) — et une négation prouvée vaut plus qu'une courbe vague : « aucune saisonnalité détectée, et voici les contrôles » est une étape faite, pas une étape passée.

1. **La série se construit avant d'être lue** : agrégat, granularité, périmètre — la vue M07 retombe en 120 lignes (5×24) **si la définition est la même**.
2. **Tendance = bâche + ratio à mois égal** — 17 M d'amplitude sous la bâche, +1.6 % à mois égal : c'est la seule tendance mesurable du fil rouge.
3. **Un cycle se prouve par l'amplitude** : écart entre positions (198) qui domine la variabilité intra-position (48) → structurel ; sinon, c'est du bruit.
4. **Période partielle = mensonge** : 307 M sur 28 jours n'est pas un décembre ; on compare à mois égal ou au flux par jour, ou on déclare « aucune conclusion ».
5. **La saison a trois horloges** : saison (été 853 / hiver 655), semaine (dimanche 405), heure (creux 927 à midi) — les trois se mesurent, les trois se déclarent.
6. **Interrompue ≠ retombée** : 5 jours de zéro (rupture) puis retour au niveau — la demande n'est pas tombée, l'offre est coupée.
7. **Le parallèle SQL redonne la série** : `GROUP BY strftime(date, '%Y-%m')` et `group-by(to_period("M"))` — 24 lignes, même 78 965 529.

17. Évaluation formative (auto-correction, 8 min)

1. **Pourquoi la vue mensuelle retombe-t-elle à 120 lignes, et quelle est sa plus grosse cellule ?** → 5 magasins $\times$ 24 mois, **sans retours** (définition M07) ; plus grosse cellule 78 965 529 FCFA (2025-08, magasin 3) — le `GROUP BY` de M07 la redonne. (2 pts)
2. **Que disent la moyenne glissante 3 mois (amplitude 17 M) et l'écart-type (10.8 M) de la quincaillerie ?** → que les 2/3 de l'amplitude brute (41 M) sont du **bruit** sans cycle : la série est plate avec une légère dérive — pas de saison à déclarer, et c'est **ça** qu'on déclare. (2 pts)
3. **Pourquoi « décembre 2026 en baisse vs décembre 2025 (307 M < 315 M) » est-il un mensonge, et que dit le flux par jour ?** → période partielle : 28 jours vs 31 ; au flux par jour, 11.0 M/jour vs 10.2 M → **+8 %**, pas une baisse ; la conclusion honnête : « mois partiel, aucune conclusion de tendance ». (2 pts)
4. **Les ratios 2026/2025 à mois égal vont de 0.963 à 1.120 (moyenne 1.016). Quelle tendance mesurable, et pourquoi pas plus ?** → une dérive de **+1.6 % en un an** ; pas plus, car chaque ratio individuel est de l'ordre du bruit mensuel ($\pm 3-7$ %) — la tendance est la **moyenne** des 12 ratios, pas un ratio. (2 pts)
5. **Étés 853 (834-882) vs hivers 655 consultations/mois : pourquoi la saisonnalité du centre est-elle « structurelle » ?** → l'écart **entre** positions (≈ 198) **domine** la variabilité **dans** les positions (≈ 48 en été) d'un facteur ~ 4 : le cycle revient au même endroit du cycle, c'est exploitable. (2 pts)
6. **Dimanche : 405 consultations ; uniforme : 2 688. Que dit ce chiffre, et que ne dit-il pas ?** → que le centre est presque fermé le dimanche (15 % de l'uniforme) — saisonnalité hebdomadaire réelle ; mais il ne dit **pas pourquoi** (organisation, pas de variable « gardien » dans le fichier) — c'est du C05. (2 pts)
7. **M02 : 5 jours à zéro, sorties nulles pendant la rupture, retour à 7/jour au restock. Tendance retombée ou interrompue ?** → **interrompue** : les sorties sont nulles **par**

contrainte d'offre ; la demande revient au niveau de février (6.7/jour) au restock — la prévision de mars 2027 prévoit le niveau habituel + le restock, pas une baisse. (2 pts)

8. **Écrivez la déclaration d'étape vide du fil rouge, avec ses contrôles.** → « Aucune saisonnalité détectée sur le CA mensuel : amplitude de la moyenne glissante 3 mois 17 M vs écart-type 10.8 M, ratios à mois égal 0.963-1.120 (moyenne 1.016), pas de pic décembre/janvier (315 M / 330 M sous la moyenne 328 M) » — négation prouvée, étape déclarée, pas sautée. (2 pts)

Module M09.C04 — Anomalies et raretés : ce qui est inhabituel, comment le prouver, quoi en conclure

Outils : pandas 2.2.3, numpy 2.3.5 (exécutés), DuckDB 1.5.5 (exécuté — la preuve par récurrence en une requête). **Durée indicative :** 5 h. **Niveau :** N3. **Prérequis :** M09.C02 (l'audit), M09.C03 (les bornes et la période), M02 (quartiles, iqr).

L'idée du chapitre. L'étape 6 du protocole pose la question : « **qu'est-ce qui est inhabituel, et comment le prouver ?** » C04 répond avec une règle d'or : **une anomalie non prouvée est un soupçon, pas un constat** — et trois preuves sont disponibles (position dans la distribution, récurrence, cohérence métier). Ensuite, **trois décisions** et une seule : corriger, exclure **en documentant**, garder **en signalant** — jamais supprimer en silence. Le chapitre porte deux contre-exemples qui changent tout : les **ruptures** du centre de santé (l'anomalie qui **compte** : la corriger serait une erreur métier) et les **6 ventes à 594 363 FCFA** du fil rouge (une rareté **légitime**, prouvée telle par le produit, la quantité et le taux — le plateau le plus suspect de la base est le moins fautif).

Matériel de l'atelier — Python 3.13 · pandas 2.2.3 · numpy 2.3.5 · DuckDB 1.5.5. Toutes les commandes ont été exécutées dans l'atelier le 20/09/2026 sur 03_exercices/dossier_M09/ (graine 45, déterministe, ATTENDU.json figé) ; les sorties publiées sont **celles de l'atelier**.

1. Objectifs du chapitre

À la fin de ce chapitre, vous savez :

1. **Définir l'anomalie avant de la chercher** — trois seuils disponibles : par iqr (position dans la distribution), par borne métier (limite du domaine), par comparaison à la période (l'écart à la saison, C03).
2. **Prouver une anomalie** avec au moins une des 3 preuves : position, **récurrence** (hier + entrées – sorties), cohérence métier — et savoir qu'à défaut, c'est un **soupçon** qu'on signale, pas un fait qu'on traite.
3. **Trancher parmi les 3 décisions** — corriger / exclure en documentant / garder en signalant — et écrire la ligne de rapport qui les justifie (P2).
4. **Reconnaître l'anomalie qui compte** : une rupture de médicament essentiel est un **signal métier**, pas un chiffre à corriger — la corriger serait une erreur.
5. **Distinguer le rare du fautif** : 6 ventes à 594 363 FCFA, le plus gros mois 78 965 529, le top client de M07 — des raretés **légitimes**, prouvées telles avant d'être effacées.

2. Pourquoi cette notion est importante

L'anomalie est le point où l'analyse devient **responsable** : on ne décrit plus, on **décide** — corriger une valeur fausse, exclure une ligne, ou garder une vérité inhabituelle. Trois faits mesurés sur le socle fixent l'enjeu :

- les **4 stocks négatifs** du centre de santé (−1, −3, −2, −12) sont prouvés **défauts de saisie** par double preuve (borne métier + récurrence) — et leur valeur correcte est **déductible** (411, 253, 278, 545) : la correction n'est pas une invention, c'est un calcul ;

- les **ruptures** (M01 : 3 jours en juillet 2025, M02 : 5 jours en mars 2026, M04 : 2 jours en août 2026) sont des **zéros qui ne doivent pas être corrigés** : c'est la réalité de l'offre, avec sa conséquence (des patients non servis) — les « réparer », c'est effacer le problème le plus grave du jeu de données ;
- les **6 ventes à 594 363 FCFA** (le maximum de la base, 50 008 lignes) sont le cas d'école de la **rareté légitime** : identiques entre elles, 6 magasins... non, 2 magasins, 6 clients, 6 dates — et pourtant aucune n'est fautive : 10 unités (le max de la base) du produit 18 (le plus cher : 49 946.47 FCFA) à la TVA 0.19.

3. Explication simple — la conversation avec la machine

La machine vient vous dire : « ça, c'est bizarre. » Le chapitre est le **tribunal** :

1. **L'accusation** (le signal) : une valeur au-delà d'une **borne définie avant** — un stock à -12 , une consultation en 2027, un montant six fois répété. Une borne sans date d'adoption n'accuse personne : elle se choisit **avant** de regarder.
2. **La preuve** (le chapitre entier) : trois témoins possibles — la **position** (« il est à 3 iqr du cœur »), la **réurrence** (« le jour d'avant et d'après s'expliquent, lui non »), le **métier** (« une pharmacie n'a pas -12 boîtes »). Un témoin suffit si c'est le métier ; pour les chiffres, on en veut deux.
3. **Le verdict** (une des trois phrases, et seulement celle-là) : **corriger** (avec la valeur déductible et sa source), **exclure en documentant** (la ligne, la définition, le nombre de lignes retirées), **garder en signalant** (l'information est vraie ou inconnue, on la laisse et on la nomme). **Jamais** « je supprime » sans phrase : le silence est le seul vice de procédure du rapport.

Et le rappel du chapitre : **tout ce qui est rare n'est pas fautif** — le gros client de M07 est un client, pas un bug ; la rupture est une vérité douloureuse, pas une erreur ; et le plateau de 594 363 est une limite **structurelle** du métier, pas un copié-collé.

4. Vocabulaire essentiel

Terme	Définition
anomalie	anomalie — une observation qui s'écarte d'une borne définie avant de chercher (iqr, borne métier, période) ; le statut n'est acquis qu' après preuve .
soupçon	le stade précédent : un signal non prouvé. On le signale (il entre au rapport, étiqueté « soupçon »), on ne le traite pas.
anomalie structurelle	un défaut qui révèle un mécanisme (saisie, export, génération) plutôt qu'une erreur ponctuelle : les 8 doublons du fil rouge, les 4 stocks négatifs déductibles.
rareté légitime	une valeur extrême fautive par aucune preuve : le top client, le plateau de montant max — on la garde, on l'explique.

5. Cours approfondi

5.1 Définir l'anomalie avant de la chercher

Les trois **seuils** disponibles, chacun avec son domaine :

Seuil	Définition	Bon pour	Mauvais pour
iqr (C02)	au-delà de $Q1 - 1,5 \times iqr$ ou $Q3 + 1,5 \times iqr$	valeurs continues de régime stable	mélanges de populations (C02 §5.4)
borne métier	limite du domaine : stock ≥ 0 , note entre 0 et 20, date dans la période	tout domaine borné	tout ce que le métier n'borne pas

Seuil	Définition	Bon pour	Mauvais pour
période (C03)	écart à la saison/jour de semaine attendu	séries avec cycle	séries plates (pas de saison à comparer)

L'ordre compte : la **borne métier** accuse **sans appel** (un stock à -12 n'a pas de discussion), l'**iqr** accuse **en signalant** (442 sous la borne M12 était plausible, C02 §5.4), la **période** accuse **en comparant** (juillet 2025 à 882, c'est la saison — ce n'est pas une anomalie, c'est le cycle). Sur le socle, les 4 familles de C02 se retrouvent chacune sous le seuil qui les trouvait : les doublons (définition métier, C01/C02), les 23 motifs vides (manquant = valeur absente, définition C02), la date 2027 (borne métier : la période s'arrête au 2026-12-31) et les 4 stocks négatifs (borne métier + récurrence).

Définition. anomalie — anomalie — une observation qui s'écarte d'une borne **définie avant** de chercher : iqr (position dans la distribution), borne métier (limite du domaine) ou période (écart au cycle attendu). Le statut « anomalie » n'est acquis qu'**après preuve** ; avant, c'est un **soupçon** — et la différence décide du traitement.

5.2 Prouver — les trois témoins

Témoin 1 — la position dans la distribution. M12 en 2026-11-03 : -12 , là où le cœur du stock tourne entre 518 et 566 (Q1, Q3, iqr 48, borne basse 446 — C02 §5.4) : l'écart au cœur est de 500+ boîtes, **pas** d'une vingtaine comme pour 442. La position accuse, mais à elle seule elle n'est pas suffisante (442 était aussi « au-delà »).

Témoin 2 — la récurrence. Le stock suit hier + entrées - sorties. Sur les 4 défauts, exécuté en DuckDB (une requête, LAG) :

id_medicament	date	reel	attendu_récurrence
M12	2026-11-03	-12	545
M07	2025-10-09	-3	253
M10	2026-05-21	-2	278
M05	2025-04-18	-1	411

Chaque valeur négative a un **jumeau naturel** déductible : 545, 253, 278, 411 — la série s'explique d'avant en après **sans** la valeur enregistrée. C'est la preuve la plus forte du module : elle ne dit pas seulement « c'est faux », elle dit **ce que la valeur était censée être**.

Définition. récurrence (du flux) — la règle de continuité d'une série de stock : hier + entrées - sorties = aujourd'hui. Elle se teste en une ligne (`shift(1)` en pandas, `LAG() OVER (PARTITION BY ... ORDER BY date)` en DuckDB) et c'est elle qui **dédoublle** l'accusation : une valeur qui casse la récurrence est suspectée, une valeur que la récurrence **remplace** (545 pour -12) est condamnée.

Témoin 3 — la cohérence métier. Un stock négatif n'existe pas en pharmacie ; une consultation datée au 2027-01-05 n'existe pas dans un export arrêté au 2026-12-31 ; une note de 25 n'existe pas sur 20. Le métier accuse **sans appel** — et c'est le seul témoin qui puisse parler **seul** (les 4 stocks négatifs, la date future).

Définition. soupçon — le stade d'une anomalie **non prouvée** : un signal (position, borne, période) sans aucun des 3 témoins. Le rapport le **signale** (« valeur au-delà de la borne, non explorée : la période ne suffit pas »), il ne l'exclut pas — traiter un soupçon, c'est confondre l'accusation et le verdict.

L'étape 6 : la borne accuse, la preuve condamne, la décision écrit sa ligne

Une anomalie non prouvée est un soupçon — on le signale, on ne le traite pas. Les 3 témoins, les 4 cas du socle.

TÉMOIN 1 — POSITION

Q1/Q3, iqr, bornes de Tukey

442 sous la borne : plausible

TÉMOIN 2 — RÉCURRENCE

hier + entrées - sorties = aujourd'hui

545 déduit pour -12 : condamné

TÉMOIN 3 — MÉTIER

stock ≥ 0 · note sur 20 · période

pas de -12 boîtes : parle seul

Les 4 cas du socle, jugés (preuve -> décision -> ligne de rapport)

CAS	PREUVE	DÉCISION
4 stocks négatifs (-1, -3, -2, -12)	métier + récurrence (double)	CORRIGER : 411, 253, 278, 545
1 date au 2027-01-05 (C000001)	borne période + 1ère référence	EXCLURE de la série · confirmer source
ruptures M01 3j · M02 5j · M04 2j	zéros vrais (récurrence OK)	GARDER : signal métier, pas défaut
6 ventes au max 594 363 (fil rouge)	plafond : 10 x 49 946.47 x 0.19	GARDER : rareté légitime, pas doublon
Jamais la 4e décision : « je supprime » sans ligne — le silence est le seul vice ; la table P4 se re-joue.		

5.3 Les trois décisions — les 4 défauts de C02 jugés

Défaut (C02)	Preuve	Décision	Ligne de rapport
D1 — 23 motifs vides	information perdue, non reconstituable	garder en signalant	« 23 consultations hors des taux par motif, motif inconnu »
D2 — 7 doublons de stock	5-tuple complet identique, keep="first"	exclure en documentant	« 7 lignes retirées : doublons exacts (date, médicament, entrées, sorties, stock) »
D3 — date 2027-01-05	borne métier (période) + C000001 (1 ^{re} référence)	exclure de la série en documentant ; coquille probable 2025-01-05, à confirmer avec la source	« 1 consultation hors période, exclue des séries ; correction soumise à la source »
D4 — 4 stocks négatifs	borne métier + récurrence (double)	corriger en 411 / 253 / 278 / 545	« 4 valeurs de saisie remplacées par la valeur déductible de la récurrence (tableau des 4) »

La discipline qui fait la différence : **chaque décision porte sa preuve et sa ligne** — pas « on a nettoyé », mais « 7 lignes retirées, voici la définition, voici le nombre ». Sur D3, notez la nuance : la preuve (borne métier) **exclut** de la série, mais ne **corrige** pas — la correction (2025-01-05) reste à **confirmer** : c'est le métier qui confirme, pas la statistique.

À retenir. Trois décisions, et **jamais la quatrième** (« je supprime ») : **corriger** exige une valeur **déductible** et sa source ; **exclure** exige une définition et un nombre ; **garder** exige une phrase. Le rapport P2 lit la ligne, pas le résultat.

Attention. « Corriger » n'existe que pour une valeur **déductible** : 545 pour M12, parce que $548 - 3 = 545$ se **calcule**. Une valeur non déductible (le motif perdu, la date coquille sans témoin) ne se corrige **jamais** par invention — elle s'exclut en documentant ou se garde en signalant. Inventer une correction, c'est fabriquer une donnée.

5.4 L'anomalie qui compte — la rupture n'est pas un chiffre

Les **ruptures** de médicaments essentiels (stock à zéro) du socle : M01 — **3 jours**, 2025-07-14 → 2025-07-16 ; M02 — **5 jours**, 2026-03-02 → 2026-03-06 ; M04 — **2 jours**, 2026-08-10 → 2026-08-11. Ce qu'elles ont de particulier au regard de l'étape 6 : **elles sont vraies**.

- La borne « stock ≥ 0 » ne les accuse **pas** : 0 est dans le domaine (zéro boîte, ce n'est pas une dette) ;
- la récurrence les **explique** (le stock s'épuise : sorties supérieures aux entrées sur plusieurs jours) ;
- le métier les **confirme** : une rupture, c'est un fait de gestion, avec une date de début, une durée, une date de restock.

La décision est donc la quatrième, que le chapitre nomme : **garder, et traiter comme un signal métier** — pas comme un défaut. M01 est le cas le plus grave, parce que sa rupture de **3 jours tombe pendant le pic de juillet** (882 consultations, le mois max de la série, C03) : 3 jours de rupture de médicament essentiel **en saison des pluies** est l'information la plus chère de la table `stock_medicament.csv` — l'effacer (« corriger les zéros »), c'est effacer le problème.

Attention. Corriger un **zéro-fait** est l'erreur la plus chère du chapitre — plus chère que laisser un défaut : un stock négatif non corrigé biaise une médiane, une rupture « corrigée » efface une information **d'exploitation** (patients non servis, date de restock) que le métier attendait du rapport. La frontière est la récurrence : un zéro qui s'explique par épuisement est un fait, un zéro qui casse la récurrence (entre 548 et 541) est un défaut.

Dans les faits. L'exercice d'évaluation E4 du module est fait pour ça : « l'anomalie qu'il ne fallait pas corriger ». Le piège est symétrique des chapitres précédents : C02/C04 apprennent à corriger les défauts de saisie (−12 → 545) ; E4 apprend à **ne pas** corriger les zéros qui sont des faits (ruptures) — la frontière est la **réccurrence** : un zéro qui s'explique par épuisement est un fait, un zéro qui ne s'explique pas (entre 548 et 541) est un défaut.

5.5 Les raretés qui ne sont pas des anomalies — le plateau 594 363

Sur le fil rouge, le tri par montant fait apparaître **6 ventes au maximum absolu : 594 363 FCFA** — identiques, et pour cause. Exécuté :

id_vente	date_vente	id_magasin	id_client	id_produit	quantite	prix_unitaire_ht
3847	2026-10-13	1	390	18	10	49946.47
6880	2026-06-01	2	511	18	10	49946.47
15533	2026-06-15	1	282	18	10	49946.47
42671	2026-04-04	1	858	18	10	49946.47
44168	2026-01-08	1	583	18	10	49946.47
47199	2026-10-11	2	231	18	10	49946.47

L'accusation était évidente (6 fois le même montant au maximum, c'est **du copié-collé**, non ?). Les témoins, exécutés :

1. **Position** : 594 363 est le maximum **possible** de la base : 10 unités (le maximum de `quantite`, qui plafonne à 10) × 49 946.47 (le prix le plus élevé du catalogue : produit 18) × 1.19 (la TVA la plus haute, 0.19) ≈ 594 363. Le plateau n'est pas une répétition, c'est un **plafond structurel** : deux ventes qui tombent toutes deux sur la limite se valent.
2. **Récurrence** : les 6 ventes ont des `id_vente` distincts, des clients distincts (390, 511, 282, 858, 583, 231), des magasins (1, 2) et des dates distinctes (6 mois d'2026) — aucune paire ne se ressemble **hors** du montant.
3. **Métier** : un professionnel qui achète 10 unités du produit le plus cher, c'est une vente **tout à fait possible** (et elle représente 56 % des montants au-dessus de cent mille FCFA — la rareté n'est pas si rare).

Verdict : garder, aucune correction — et écrire la phrase qui sauve le rapport : « 6 ventes au montant max (594 363 FCFA) : plafond structurel ($10 \times \text{produit } 18 \times \text{TVA } 0.19$), clients et dates distincts, aucune anomalie » . Le même raisonnement couvre le **plus gros mois** 78 965 529 FCFA (2025-08 $\times$ magasin 3, C03 : un pic **expliqué** par la vue par magasin, pas écarté) et le **top client** de M07 (un client, pas un bug — le rappel du module).

Définition. anomalie structurelle — un défaut qui révèle un **mécanisme** (export, saisie, génération) plutôt qu'une erreur ponctuelle : les 8 doublons du fil rouge (clé métier redite, `id_vente` distinct), les 4 stocks négatifs déductibles. Le traitement d'une anomalie structurelle se fait **en amont** (la source, le processus) : dans le rapport, on la **documente** avec le mécanisme, pas seulement la valeur.

6. Exemple concret — les 594 363, jugés en entier (fil rouge)

Le parcours complet d'une rareté suspecte, du signal au verdict (exécuté) :

1. **Signal** : `montant_ttc.nlargest(6)` $\rightarrow$ 6 fois 594 363, le maximum de 50 008 lignes ; le tri par montant distincts montre que le reste est **dense** (les 10 montants les plus fréquents comptent 16 à 17 occurrences chacun — pas de pic isolé).
2. **Hypothèse d'accusation** : copié-collé (6 valeurs identiques au max).
3. **Preuves** : plafond structurel ($10 \times 49\,946.47 \times 1.19 \approx 594\,363$, produit 18 = prix max du catalogue de 380 produits), `id_vente` / clients / magasins / dates tous distincts, aucune paire jumelle hors montant.
4. **Verdict : garder, aucune correction** — rareté légitime, phrase de rapport écrite (§5.5).
5. **Leçon** : le tri par valeur est un **générateur de signaux**, pas un juge — sans les 3 témoins, le « 6 fois identique » aurait été traité en doublons, et le rapport aurait enlevé 5 ventes réelles de 594 363 au CA.

7. Démonstration pas à pas — 5 étapes sur les deux jeux

```
import pandas as pd
s = "03_exercices/dossier_M09"
cons = pd.read_csv(s + "/sante/consultation.csv")
stk = pd.read_csv(s + "/sante/stock_medicament.csv")
v = pd.read_csv(s + "/quincaillerie/vente.csv")
pr = pd.read_csv(s + "/quincaillerie/produit.csv")

# 1 – les 4 stocks négatifs, prouvés par récurrence (pandas)
stk["date"] = pd.to_datetime(stk["date"])
for mid in ("M05", "M07", "M10", "M12"):
    m = stk[stk["id_medicament"] == mid].sort_values("date").reset_index(drop=True)
    neg = m[m["stock_fin"] < 0]
    for i in neg.index:
        nat = int(m.loc[i - 1, "stock_fin"] + neg.loc[i, "entree"] - neg.loc[i, "sortie"])
        print(mid, neg.loc[i, "date"].date(), "réel", int(neg.loc[i, "stock_fin"]),
              "| naturelle", nat)

# 2 – les ruptures : les zéros qui sont des faits (M02)
m02 = stk[stk["id_medicament"] == "M02"].sort_values("date")
print(m02[m02["stock_fin"] == 0]["date"].dt.date.tolist())

# 3 – la date future : borne métier
print(int((cons["date_consultation"] > "2026-12-31").sum()),
      cons.loc[cons["date_consultation"] > "2026-12-31", "date_consultation"].tolist())

# 4 – le plateau du max : plafond structurel ?
mx = int(v["montant_ttc"].max())
top6 = v[v["montant_ttc"] == mx]
print(int(top6.shape[0]), "ventes au max", mx)
print(top6[["id_vente", "id_client", "id_magasin", "date_vente"]].to_string(index=False))
print("max quantite:", int(v["quantite"].max()),
      "| prix max:", pr["prix_vente_ht"].max(), "produit",
      int(pr.loc[pr["prix_vente_ht"].idxmax(), "id_produit"]))

# 5 – le verdict, en mots :
# 4 stocks : CORRIGER (valeurs déductibles) ; date future : EXCLUDE (à confirmer) ;
# ruptures : GARDER (signal métier) ; plateau 594363 : GARDER (plafond structurel).
```

```
M05 2025-04-18 réel -1 | naturelle 411
M07 2025-10-09 réel -3 | naturelle 253
M10 2026-05-21 réel -2 | naturelle 278
M12 2026-11-03 réel -12 | naturelle 545
[datetime.date(2026, 3, 2), datetime.date(2026, 3, 3), datetime.date(2026, 3, 4),
 datetime.date(2026, 3, 5), datetime.date(2026, 3, 6)]
1 ['2027-01-05']
6 ventes au max 594363
id_vente id_client id_magasin date_vente
3847      390      1 2026-10-13
6880      511      2 2026-06-01
15533     282      1 2026-06-15
42671     858      1 2026-04-04
44168     583      1 2026-01-08
47199     231      2 2026-10-11
max quantite: 10 | prix max: 49946.47 produit 18
```

8. Erreurs fréquentes

1. **Traiter le soupçon comme l'anomalie** — « c'est au-delà de la borne, on supprime » : la borne **accuse**, la preuve **condamne** ; sans preuve, la valeur sort du rapport avec son étiquette de soupçon, pas du fichier.

2. **Corriger une valeur non déductible** — inventer le motif perdu, deviner la date coquille : une correction sans source (récurrence, référentiel, source métier) est une **fabrication de donnée**, pas un nettoyage.
3. **Effacer les zéros qui sont des faits** — les ruptures (0 stock) corrigées « parce que c'est bizarre » : on efface le signal métier le plus grave du jeu (M01 : 3 jours en juillet, pendant le pic de 882 consultations).
4. **Punir le rare comme fautif** — les 6 ventes à 594 363 traitées en doublons, le top client de M07 exclu « parce qu'il tire le total » : la rareté légitime s'**explique** (plafond structurel, comportement client), elle ne s'élimine pas.
5. **Décider sans ligne de rapport** — « on a nettoyé » sans définition, sans nombre, sans preuve : le rapport P2 lit la **ligne**, pas le résultat — « 7 lignes retirées (doublons 5-tuples) » passe, « nettoyage effectué » non.

9. Bonnes pratiques professionnelles

1. **La borne d'abord, la valeur ensuite** — « au-delà de 446 (Q1 M12 – 1,5 × iqr) » est défini **avant** le tri ; « ça fait bizarre » ne l'est pas : un seuil sans date d'adoption n'accuse personne.
2. **Deux témoins pour les chiffres, un seul suffit pour le métier** — la borne métier parle seule (–12, 2027) ; pour les valeurs du domaine (442 ? 545 ?), position + récurrence ensemble.
3. **Chaque décision écrit sa ligne** — corriger : valeur + source ; exclure : définition + nombre ; garder : le pourquoi. Trois phrases, trois formats, pas de quatrième.
4. **L'anomalie qui compte est la plus chère du rapport** — la rupture M01 (3 jours au pic de juillet) vaut plus que les 4 corrections de stocks : le rapport la met en avant, chiffrée, datée, avec sa conséquence (patients non servis).
5. **Le tri par valeur est un générateur de signaux** — pas un juge : chaque pic de `nlargest` passe par les 3 témoins avant de devenir un fait ; le plateau 594 363 en est la démonstration (signal le plus suspect, verdict le plus légitime).

Conseil professionnel. Dans un rapport P2, la section anomalies tient en **une table** : signal / preuve(s) / décision / ligne de rapport. Pas de narrative interminable : le lecteur doit pouvoir **contrôler** chaque ligne (re-jouer la preuve), et une table se contrôle, un récit non. Cinq lignes sur le socle (23, 7, 1, 4, plateau) couvrent tout le chapitre.

10. Exercice guidé — « les 4 défauts du centre de santé, jugés » (25 min, /10)

Consigne. Les 4 défauts de C02 sont connus (23 motifs vides, 7 doublons de stock, 1 date au 2027-01-05, 4 stocks négatifs). Pour chacun, sans rouvrir ATTENDU.json :

1. Nommez la **borne** (métier, iqr, période) qui l'accuse (4 × 0,5 pt).
2. Donnez la **preuve** retenue (1 pt) et, pour les 4 stocks, la **valeur déductible** de chacun (4 × 1 pt). (5 pts au total)
3. Écrivez la **décision** (corriger / exclure en documentant / garder en signalant) et la **ligne de rapport** qui va avec (4 × 0,5 pt). (2 pts)

11. Exercices autonomes

E1 — La preuve par récurrence en SQL (20 min). En DuckDB sur `stock_medicament.csv`, avec `LAG(stock_fin) OVER (PARTITION BY id_medicament ORDER BY date)` : listez les 4 stocks négatifs avec leur **valeur attendue par récurrence** (hier + entrées – sorties). La sortie doit donner $-12 \rightarrow 545$, $-3 \rightarrow 253$, $-2 \rightarrow 278$, $-1 \rightarrow 411$.

E2 — Le plateau qui n'est pas un doublon (20 min). Sur `vente.csv` : (1) comptez les ventes au montant max (594 363) et listez leurs `id_vente`, `id_client`, `id_magasin`, `date_vente` ; (2) montrez que le plateau est un **plafond structurel** (quantité max, prix max du catalogue, TVA 0.19) ; (3) concluez : doublon ou rareté légitime, et **pourquoi** une paire parmi les 6 n'est **pas** un doublon métier (rappel C01 : la définition du doublon sur les 12 colonnes hors `id_vente`).

12. Correction détaillée

Exercice guidé.

- Les bornes** : D1 — aucune borne (un motif vide n'est hors domaine, c'est une information **absente** : la « borne » est la complétude attendue) ; D2 — définition métier du doublon (5-tuple) ; D3 — **période** (l'export s'arrête au 2026-12-31) ; D4 — **borne métier** ($\text{stock} \geq 0$).
- Les preuves** : D1 — aucune (l'information est perdue : c'est précisément pour ça qu'on ne la corrige pas) ; D2 — l'identité du 5-tuple (définition exécutée) ; D3 — borne métier + la position de C000001 (1^{re} référence du fichier) ; D4 — **double** : borne métier + récurrence, valeurs déductibles **411 (M05), 253 (M07), 278 (M10), 545 (M12)**.
- Les décisions** : D1 — **garder en signalant** (« 23 consultations hors des taux par motif ») ; D2 — **exclure en documentant** (« 7 lignes retirées : doublons exacts du 5-tuple, `keep="first"` ») ; D3 — **exclure de la série en documentant** (« 1 consultation hors période exclue ; coquille probable 2025-01-05, à confirmer avec la source ») ; D4 — **corriger** (« 4 valeurs de saisie remplacées par la valeur déductible de la récurrence : 411, 253, 278, 545 »).

E1. DuckDB, exécuté — la requête du §5.2 redonne exactement :

id_medicament	date	reel	attendu_réurrence
M12	2026-11-03	-12	545
M07	2025-10-09	-3	253
M10	2026-05-21	-2	278
M05	2025-04-18	-1	411

E2. (1) **6** ventes au max 594 363 : 6 `id_vente` distincts (la liste est publiée aux §5.5 et §7), clients 390, 511, 282, 858, 583, 231 ; magasins 1 (×4) et 2 (×2) ; dates du 2026-01-08 au 2026-10-13. (2) **Plafond structurel** : quantité plafonne à **10**, le produit **18** est le plus cher du catalogue (**49 946.47**), la TVA la plus haute est **0.19** : $10 \times 49\,946.47 \times 1.19 \approx 594\,363$ — deux ventes qui touchent toutes les limites se valent, c'est la définition du plafond. (3) **Rareté légitime, pas un doublon** : la définition du doublon métier (C01) porte sur les 12 colonnes **hors** `id_vente` — et ici, les 6 ventes diffèrent sur `date_vente`, `id_client`, `id_magasin` (et `id_vente`) : aucune paire n'est identique **sur la définition**, donc aucune n'est un doublon ; l'identité du montant est l'**effet** du plafond, pas sa **cause**.

13. Mini-projet M09.P4 — « L'anomalie avec sa preuve » (1 h)

Énoncé. La section anomalies du rapport P2 (projet M09.P) doit porter **la table du conseil §9** sur un jeu au choix (quincaillerie ou santé) : 4 à 6 lignes, chacune avec signal / preuve(s) / décision / ligne de rapport. Contrainte d'évaluation : **chaque preuve doit être re-jouable** — le cor-

recteur relance la commande citée et doit retomber sur le chiffre. Auto-évaluation : une ligne sans commande citée = une ligne qui ne compte pas ; une décision « corriger » sans valeur déductible et sa source = une ligne fausse.

14. Boîte à outils du chapitre

Boîte à outils. Les seuils : `quantile(.25/.75) + iqr (C02)`, bornes métier (`col < 0`, `col > 20`, date hors période), période (C03 : écart au cycle). Les preuves : position (`nlargest`, distance à la borne), **récurrence** (`shift(1)` en pandas, `LAG() OVER (PARTITION BY ... ORDER BY date)` en DuckDB), métier (le référentiel, la source). Les décisions : corriger (valeur + source), exclure (définition + nombre), garder (signal + phrase). Le rare : `nlargest` + les 3 témoins avant tout traitement.

Besoin	Commande	Chiffre du socle
position	<code>col.nlargest(n)</code> , distance à Q3 + 1,5 × iqr	6 ventes au max 594 363
récurrence	<code>shift(1) / LAG() OVER</code>	545, 253, 278, 411
borne métier	<code>(col < 0).sum()</code> , date hors période	4 stocks, 1 date (2027-01-05)
zéros-faits	<code>col == 0</code> groupés par période	M01 3 j · M02 5 j · M04 2 j
plafond	prix max catalogue × quantité max × TVA max	10 × 49 946.47 × 1.19

15. Résumé du chapitre

L'étape 6 du protocole (« qu'est-ce qui est inhabituel, et comment le **prouver** ? ») est exécutée avec la règle du chapitre : **une anomalie non prouvée est un soupçon**, et trois témoins sont disponibles — la **position** dans la distribution (iqr, C02), la **récurrence** (hier + entrées – sorties : `shift(1)` en pandas, `LAG` en DuckDB) et la **cohérence métier** (stock ≥ 0, période de l'export, note sur 20). Sur le centre de santé, les 4 défauts de C02 sont jugés : les 23 motifs vides se **gardent en signalant** (information perdue, non reconstituable), les 7 doublons de stock **s'excluent en documentant** (5-tuple identique, 7 lignes), la consultation du 2027-01-05 **s'exclut de la série** (borne période, C000001, coquille probable 2025-01-05 à confirmer avec la source) et les 4 stocks négatifs se **corrigent** — en 411, 253, 278 et 545, valeurs **déductibles** par la récurrence (preuve double : métier + flux). Les **ruptures** (M01 : 3 jours, 2025-07-14 → 16 ; M02 : 5 jours, 2026-03-02 → 06 ; M04 : 2 jours, 2026-08-10 → 11) sont l'inverse exact d'un défaut : des **zéros qui sont des faits**, à garder et à traiter comme **signal métier** — M01 pendant le pic de juillet (882 consultations) est l'anomalie qui **compte**. Sur le fil rouge, les **6 ventes à 594 363 FCFA** (le maximum de 50 008 lignes) démontrent le rare légitime : plafond structurel (10 × produit 18 à 49 946.47 × TVA 0.19), clients, magasins et dates distincts — **garder, aucune correction**, et la même leçon couvre le plus gros mois (78 965 529, expliqué) et le top client de M07.

16. À retenir

À retenir. La borne **accuse**, la preuve **condamne**, la décision **écrit sa ligne** — et les deux contre-exemples du socle gardent le chapitre honnête : la rupture qui ne se corrige pas (0 = un fait, pas un défaut) et le plateau 594 363 qui ne s'élimine pas (rare ≠ fautif).

1. **Définir avant de chercher** : iqr / borne métier / période — un seuil sans date d'adoption n'accuse personne.

2. **Trois témoins** : position (500+ boîtes du cœur pour M12), récurrence ($545 \neq -12$, et $545 - 4 = 541$), métier (pas de -12 boîtes en pharmacie).
3. **Trois décisions, jamais la quatrième** : corriger (valeur déductible + source), exclure en documentant (définition + nombre), garder en signalant — pas « supprimer ».
4. **Corriger = déduire** : 411, 253, 278, 545 se **calculent** ; une valeur non déductible ne se corrige jamais par invention.
5. **L'anomalie qui compte est un fait** : ruptures M01 3 j (pic de juillet, 882), M02 5 j, M04 2 j — les corriger, c'est effacer le problème.
6. **Rare $\neq$ fautif** : $6 \times 594\,363 =$ plafond structurel ($10 \times 49\,946.47 \times 1.19$) ; le tri par valeur génère des signaux, il ne juge pas.
7. **Chaque décision écrit sa ligne** : signal / preuve / décision / ligne de rapport — la table P4 se **re-joue**, le récit non.

17. Évaluation formative (auto-correction, 8 min)

1. **Pourquoi 442 (M12, sous la borne 446) n'est-il pas corrigé alors que -12 l'est ?** → 442 est un soupçon **débatu** : cohérent avec sa récurrence, plausible en métier (jour bas, pas impossible) — il se **garde** ; -12 a la **double** preuve (métier : pas de stock négatif ; récurrence : $548 - 3 = 545$, et $545 - 4 = 541$) — il se **corrige** en 545, valeur déductible. (2 pts)
2. **Les 4 stocks négatifs valent -1 , -3 , -2 , -12 . Donnez leurs valeurs déductibles et la commande qui les déduit.** → 411 (M05), 253 (M07), 278 (M10), 545 (M12) ; `shift(1)` en pandas ou `LAG(stock_fin) OVER (PARTITION BY id_medicament ORDER BY date)` en DuckDB : hier + entrées - sorties. (2 pts)
3. **Pourquoi la rupture M02 (5 jours à zéro, 2026-03-02 → 06) ne se corrige-t-elle pas ?** → parce que les zéros sont **vrais** : la borne stock ≥ 0 ne les accuse pas (0 est dans le domaine), la récurrence les explique (épuisement : sorties > entrées), et le métier les confirme (rupture = fait de gestion) — c'est un **signal** (patients non servis), pas un défaut. (2 pts)
4. **M01 est rompu 3 jours en 2025-07-14 → 16. Pourquoi cette rupture « compte-t-elle » plus que les autres ?** → parce qu'elle tombe **pendant le pic de saison** (juillet 2025 : 882 consultations, le mois max de la série) : 3 jours de médicament essentiel manquant **en saison des pluies** — l'information la plus chère de la table de stock. (2 pts)
5. **6 ventes à 594 363 FCFA, le maximum de la base. Pourquoi ne sont-ce pas des doublons ?** → le doublon métier se définit sur les 12 colonnes **hors** `id_vente` (C01) : les 6 ventes diffèrent sur date, client, magasin — l'identité du montant est l'**effet** du plafond structurel ($10 \times \text{produit} \times 18 \times \text{TVA } 0.19$), pas sa cause. (2 pts)
6. **Quelle est la valeur exacte du plafond, et pourquoi « $\approx$ » ?** → $10 \times 49\,946.47 \times 1.19 = 594\,362.99 \approx 594\,363$: le montant est arrondi au FCFA (centimes entiers, M08 C08) — l'approximation est l'arrondi, pas l'hypothèse. (2 pts)
7. **Écrivez la ligne de rapport de D3 (la date 2027-01-05), avec sa nuance.** → « 1 consultation hors période (2027-01-05, C000001), **exclue des séries** ; coquille probable pour 2025-01-05 — correction **soumise à la source** » : la preuve (borne période) exclut, elle ne **corrige** pas. (2 pts)
8. **Une valeur au-delà de la borne, non explorée faute de temps. Que fait-on ?** → on la **signale** en soupçon (« au-delà de la borne, non explorée ») : elle entre au rapport **étiquetée**, elle ne sort pas du fichier — traiter un soupçon, c'est confondre accusation et verdict. (2 pts)

Module M09.C05 — Relations et hypothèses : ce qui bouge ensemble, ce qui ne bouge pas, et les 3 fausses causes

Outils : pandas 2.2.3, numpy 2.3.5 (exécutés). **Durée indicative :** 5 h. **Niveau :** N3. **Pré-requis :** M09.C01-C04 (protocole, audit, tendances, anomalies), M02 (corrélation vue en M02.C06).

L'idée du chapitre. L'étape 7 du protocole pose la question : « **les variables bougent-elles ensemble ?** » et l'étape 8 : « **que puis-je affirmer, et sous quelle condition ?** » C05 y répond avec un coefficient en une ligne (`corr()`), ses **3 limites** (linéarité, scale, valeurs extrêmes), le **corollaire du module** — corrélation $\neq$ causalité, avec les **3 fausses causes** chiffrées sur le socle (variable tierce, régression vers la moyenne, sens inversé) — et deux disciplines : **segmenter** avant de comparer, et **comparer des groupes à taille égale ou en le disant**. L'établissement scolaire fait son entrée ici (402 élèves déclarés, 6 000 notes, 1 687 absences/retards, 4 défauts) : la corrélation absentéisme $\times$ résultats est **-0.232** — négative, modérée, et **partiellement expliquée par une tierce variable** quand on contrôle le niveau du T1. Le fil rouge porte l'autre leçon : remises $\times$ montants à 0.552, taux $\times$ montants à **0.001** — le scale n'est pas le comportement.

Matériel de l'atelier — Python 3.13 · pandas 2.2.3 · numpy 2.3.5. Toutes les commandes ont été exécutées dans l'atelier le 20/09/2026 sur `03_exercices/dossier_M09/` (graine 45, déterministe, ATTENDU.json figé) ; les sorties publiées sont **celles de l'atelier**.

1. Objectifs du chapitre

À la fin de ce chapitre, vous savez :

1. **Calculer la corrélation de Pearson** en une ligne (`corr()`) et dire ses **3 limites** : elle ne mesure que le lien **linéaire**, elle dépend du **scale** des variables (0.552 vs 0.001 sur le fil rouge), et une **valeur extrême** peut la tirer.
2. **Reconnaître les 3 fausses causes** d'une corrélation : variable **tierce** (confond — mesurée sur le socle : la corrélation s'effondre quand on contrôle le T1), **régression vers la moyenne** (les extrêmes retournent vers le milieu sans cause) et **sens inversé** (l'effet va de B à A, pas de A à B).
3. **Segmenter** une variable continue en groupes métier (`np.where`) et lire le **gradient** : 3 segments d'absentéisme [123, 208, 69] élèves $\rightarrow$ moyennes 11.13 $\rightarrow$ 10.51 $\rightarrow$ 9.76.
4. **Comparer des groupes à taille inégale** : le panier par mode de paiement (5 groupes, le plus gros **8 fois** plus grand que le plus petit, écart de moyennes de 2 % : du bruit) et le taux par classe (4e : 4.26 j, 2nde : 2.35 j — un écart **réel** à n égales).
5. **Cadrer et tester l'hypothèse** (l'étape 8) : formulation falsifiable, test sur les données, **conclusion provisoire** avec ses limites — le pont vers la note d'EDA (C06).

2. Pourquoi cette notion est importante

L'EDA se termine là où commence la **responsabilité** : l'étape 7 produit des associations, l'étape 8 décide ce qu'on en **dit**. Et c'est précisément là que le rapport EDA se trompe le plus souvent :

une corrélation publiée comme une cause, un groupe petit comparé à un groupe grand, un segment défini après avoir vu les résultats. Trois faits mesurés sur le socle fixent l'enjeu :

- la corrélation **absentéisme × résultats** du jeu scolaire est **-0.232** — et quand on **contrôle le niveau du T1** (la tierce variable : le niveau d'origine), elle s'effondre par bandes (-0.145, -0.085, **+0.163**) : une partie du lien brut est la variable tierce, pas l'absence ;
- sur le fil rouge, **remises (en FCFA) × montants** donne 0.552, mais **taux de remise × montants** donne **0.001** : même fichier, deux variables, deux mondes — le scale a imité un comportement ;
- les **5 modes de paiement** font des paniers moyens à **2 % près** les uns des autres, pour des groupes de 20 175 ventes et de 2 552 : comparer ces groupes « au total » sans dire leurs tailles, c'est faire passer le bruit pour une différence.

3. Explication simple — la conversation avec la machine

La corrélation est une **corde** qui relie deux variables : si l'une tire, l'autre suit, la corde est tendue (+) ou opposée (-), et `corr()` mesure la tension de **-1 à +1**. Mais la corde joue **trois tours** au lecteur pressé :

1. **Le tour de la tierce variable** : deux variables bougent ensemble **parce qu'une troisième les pousse toutes les deux** — les élèves absents et les élèves qui décrochent sont **poussés par le même facteur** (le niveau d'origine) ; la corde entre absence et note est un fil de la variable tierce, pas un lien direct.
2. **Le tour du scale** : deux grandeurs qui grandissent **ensemble** (une remise en FCFA grandit avec le montant de la facture) se corrôlaient **même sans lien** — 0.552 ; divisez par le montant (le **taux**) et la corde retombe : **0.001**.
3. **Le tour des extrêmes** : un groupe qui part très bas (7.01 au T1) remonte vers le milieu (7.21 au T2) **sans que rien ne l'ait aidé** — la régression vers la moyenne imite une cause qui n'existe pas.

La discipline du chapitre : **tendre la corde** (`corr()`), **vérifier le tour** (les 3 pièges), et **dire la tension en un chiffre** avec ses limites — jamais « ça cause ça ».

4. Vocabulaire essentiel

Terme	Définition
corrélation	corrélation — la mesure d'association entre deux variables (Pearson : de -1 à +1, lien linéaire) ; n'est jamais une causalité (le piège du module).
piège d'inférence	le saut interdit de l'association à la cause : 3 formes mesurées — variable tierce, régression vers la moyenne, sens inversé.
variable tierce — confond — la troisième variable qui cause les deux : si on la contrôle (on compare à elle égale), la corrélation résiduelle est le lien direct.	
segment	un groupe défini avant de regarder les résultats (bornes métier sur la variable) : ici, les 3 tranches d'absentéisme (< 2, 2-5, ≥ 6 jours).

5. Cours approfondi

5.1 `corr()` en une ligne — et ses 3 limites

```
import pandas as pd
s = "03_exercices/dossier_M09/scolaire"
no = pd.read_csv(s + "/note.csv")
ab = pd.read_csv(s + "/absence.csv")
no = no[(no["note"] >= 0) & (no["note"] <= 20)]
abs_par = ab.groupby("id_eleve")["duree_jours"].sum()
taux = abs_par.reindex(sorted(no["id_eleve"].unique()), fill_value=0)
moy = no.groupby("id_eleve")["note"].mean()
print(round(float(moy.corr(taux.reindex(moy.index))), 3), len(moy))
```

```
-0.232 400
```

-0.232 sur 400 élèves : une association **négative, modérée** — les élèves plus absents ont des moyennes plus basses, mais « modérée » est le mot qui compte : une grande partie de la variance de la moyenne n'est **pas** dans l'absentéisme. Les 3 limites, chacune exécutée sur le socle :

1. **Linéarité** — `corr()` mesure le lien **linéaire** ; une relation en U (les absents très peu **et** très beaucoup font mal, les moyens vont bien) donne une corrélation **nulle** tout en ayant un lien fort. Le nuage (C06) est le contrôle.
2. **Scale** — sur le fil rouge (exécuté) : `montant_remise × montant_ttc → 0.552`, mais `montant_remise / montant_ttc × montant_ttc → 0.001` : la remise en FCFA grandit **avec** le montant (une facture de 500 000 FCFA a une remise plus grosse en FCFA qu'une facture de 5 000, même à taux nul) — le scale a imité un comportement. Le **taux** (max 0.015 sur la base) est la variable qui mesure le comportement, et elle ne bouge **pas** avec le montant.
3. **Valeurs extrêmes** — une poignée de valeurs à l'extrême peut **tirer** le coefficient (le cas de M02 : une ligne aberrante qui fait une corrélation) ; `corr()` a des variantes robustes (rangs), mais le réflexe du chapitre est plus simple : **recalculer sans les 5 % extrêmes** et voir si le signe tient.

Attention. Un coefficient dont le **signe change** quand on retire les valeurs extrêmes n'est pas une mesure : c'est un fil tendu par quelques observations. Le réflexe d'office avant publication est de le recalculer **sans** les extrêmes — si le signe tient, la corrélation est robuste ; s'il s'effondre, c'est la queue qui parlait, pas la distribution.

Définition. corrélation — corrélation — la mesure d'association entre deux variables ; Pearson mesure le lien **linéaire**, de -1 (opposé) à +1 (proportionnel), 0 = pas de lien linéaire. Trois avertissements d'office : elle ne mesure **pas** la causalité, pas le lien non linéaire, et pas le comportement si l'une des variables est un **scale** (montant en FCFA) et non un **taux**.

5.2 Corrélation ≠ causalité — les 3 fausses causes, chiffrées

Fausse cause 1 — la variable tierce (confond). L'histoire la plus plausible : « les absences **font** baisser les notes ». Le test (exécuté) : contrôler le **niveau du T1** (proxy du niveau d'origine) et recalculer, **par bande de niveau** :

```
corr globale abs_T2 × note_T2 : -0.206
bande T1 [8,10) (n=107) : -0.145
bande T1 [10,12) (n=139) : -0.085
bande T1 [12,14) (n=77) : +0.163
```

En contrôlant le niveau, la corrélation **s'effondre** ($-0.206 \rightarrow -0.145 / -0.085 / +0.163$, du signe inversé dans la bande haute) : une part importante du lien brut était **le niveau d'origine** qui pousse l'absence **et** la note — la corde entre absentéisme et résultats est en grande partie un fil de la tierce variable. Ce que les données **autorisent** : « les élèves plus absents ont en moyenne des notes plus basses, **et** le niveau d'origine explique une part de ce lien » — pas « les absences font baisser les notes ».

Fausse cause 2 — la régression vers la moyenne. Les élèves très en bas au T1 (moyenne 7.01) font **7.21** au T2 — ils **montent** sans cause identifiée ; les très hauts (14.93) font **14.61** — ils **descendent**. Les extrêmes retournent vers le milieu **par hasard d'échantillonnage** (une note anormalement basse a statistiquement de chances d'être moins basse au trimestre suivant), et on lit « l'aide a marché » ($7.01 \rightarrow 7.21$) là où il n'y a qu'une **retombée vers la moyenne**. Le contrôle : comparer à la **moyenne de tous** les élèves sur la même transition, pas à soi-même.

Fausse cause 3 — le sens inversé. « Les absents ont de mauvaises notes » peut aller **dans l'autre sens** : ce ne sont pas les absences qui font la moyenne, c'est la **moyenne qui fait l'absence** (l'élève qui décroche arrête d'aller en cours). Les données du fichier **ne départagent pas** les deux sens (pas de variable « motivation », pas d'intervention) — et c'est précisément **ce qu'on écrit** : « association bidirectionnellement compatible ; le fichier ne départage pas les sens ».

Définition. piège d'inférence — le saut interdit de l'**association** à la **cause**, sous ses 3 formes mesurées : variable **tierce** (la troisième variable qui cause les deux — contrôlée, la corrélation résiduelle est le lien direct), **régression vers la moyenne** (les extrêmes retournent vers le milieu sans cause), **sens inversé** (B cause A, on affirme A cause B). Un coefficient sans ces 3 contrôles est une **association**, pas une **cause**.

Corrélation, jamais causalité : les 3 fausses causes, chiffrées sur le socle

Le brut : absentéisme x moyenne générale = -0.232 ($n=400$), association négative modérée. Trois façons de la lire en trop :

1 — VARIABLE TIERCE (confond) la tierce variable (le niveau d'origine) contrôle par bande de T1 : brut (abs T2 x note T2) : -0.206 bande T1 [8,10] $n=107$: -0.145 bande T1 [10,12] $n=139$: -0.085 bande T1 [12,14] $n=77$: $+0.163$ le lien s'EFFONDRE (et change de signe) une part du lien brut = tierce variable, pas l'absence en elle-même.	2 — RÉGRESSION VERS LA MOYENNE les extrêmes reviennent vers le milieu la transition T1 -> T2 : T1 < 8 (7.01) -> T2 : 7.21 (monte) T1 > 14 (14.93) -> T2 : 14.61 (desc.) moyenne globale : 10.57 les deux sens, même chiffre : 10.57 les deux extrêmes reviennent vers 10.57 sans qu'on les ait aidés : c'est la variance d'une note, pas « l'aide a marché ».	3 — SENS INVERSÉ B cause A, on affirme A cause B le fichier ne départage pas : absence -> note ? (les absents chutent) note -> absence ? (chute -> absences) pas d'intervention, pas de variable motivation ni d'ordre chronologique les deux sens restent compatibles avec les mêmes chiffres : le fichier ne tranche Phrase : association, sens non départagé.
Le coefficient va avec ses 4 chiffres : $-0.232 \cdot n = 400 \cdot$ contrôle (bandes de T1) · limite (proxy, 1 année, sens) les 4 ensemble, ou la phrase ne part pas. Test du scale : montants 0.552 -> taux 0.001 — le scale n'est pas le comportement.		
Segments (bornes métier, avant de regarder) : 123 / 208 / 69 élèves -> moyennes 11.13 / 10.51 / 9.76 gradient régulier = la signature d'un lien direct (pas une fausse cause).		

5.3 L'établissement scolaire arrive — le jeu 3, ses 4 défauts

Le jeu 3 s'ouvre (entré avec son audit C02 déjà fait ici) : `eleve.csv` (402 lignes × 3 colonnes, 400 élèves distincts), `note.csv` (6 000 lignes × 5 colonnes : 5 matières × 400 élèves × 3 trimestres), `absence.csv` (1 687 lignes × 5 colonnes : 1 278 absences et 409 retards). Les 4 défauts plantés, exécutés :

#	Défaut	Définition exacte	Chiffre
S1	notes hors bornes	<code>note < 0</code> ou <code>> 20</code> (sur 20, domaine métier)	6 (22.5, 22.5, 25.0, -1.5, -0.5, -3.0)
S2	doublons d'élèves	<code>id_eleve</code> répété dans <code>eleve.csv</code>	2 (E0107, E0233)
S3	absence un jour férié	absence datée un jour où l'établissement est fermé	4 (2025-11-01, 2025-12-25, 2025-12-26, 2026-01-01)
S4	absent mais noté	élève avec ≥ 10 absences au T2 et des notes au T2	3 (E0004 : 13, E0006 : 15, E0007 : 15)

Deux lectures qui feront la différence :

- **S2 cache une contradiction** : l'un des deux IDs doublons est déclaré **F** sur une ligne et **M** sur l'autre (même `classe`) — c'est un doublon **avec contradiction**, pas un simple doublon exact (l'autre est identique sur ses 3 colonnes) : le premier se règle **avec la source**, le second se dédoublonne.
- **S4 est le défaut qui fausse la corrélation** : 3 élèves comptent **13, 15, 15 absences au T2** et ont **5 notes au T2** chacun — des absents notés tirent la corrélation vers le bas **par construction** (max des absences, notes quand même présentes) : la corrélation -0.232 se **recalcule** hors ces 3 élèves au C06, et l'écart est publié (les deux chiffres vont dans la note d'EDA).

Dans les faits. L'audit du jeu scolaire (formes + 4 défauts + types d'absence + clés refermées) passe par les mêmes commandes que le jeu 2 — le protocole (C01) est le même sur les 3 jeux ; ce qui change, c'est le **métier** des bornes : une note sur 20, un jour férié, un élève noté en étant absent. Les bornes métier suivent le métier, pas l'inverse.

5.4 Segmenter — les 3 tranches d'absentéisme et leur gradient

Ségmenter, c'est trancher avant de regarder : les bornes (< 2 , $2 \text{ à } 5$, ≥ 6 jours d'absence sur la période) sont fixées **métier** (« absent occasionnel / absent régulier / absent structurel »), **pas** après avoir vu les moyennes (exécuté, `np.where`) :

```
segment <2 jours : n=123 | moyenne 11.13 | médiane 11.21
segment 2-5 jours: n=208 | moyenne 10.51 | médiane 10.40
segment >=6 jours: n=69  | moyenne  9.76 | médiane  9.51
```

Le **gradient** est la lecture du chapitre : $11.13 \rightarrow 10.51 \rightarrow 9.76$, un demi-point par tranche, **regulier** — c'est la signature d'un **lien direct** (pas d'un accident de groupe) ; la médiane suit la moyenne (pas de queue qui tire). Et la nuance du chapitre : le segment « ≥ 6 jours » n'est pas un groupe d'**exclus** — ce sont 69 élèves réels, et la phrase du rapport est « les 69 élèves les plus absents font en moyenne 9.76/20, soit 1.37 point sous les 123 les moins absents » — **des élèves, pas des valeurs.**

Définition. segment — un groupe défini **avant** de regarder les résultats : les bornes sont **métier** (< 2 , $2 \text{ à } 5$, ≥ 6 jours d'absence), pas statistiques, et s'écrivent dans le rapport **avant** les chiffres. Définir le segment après avoir vu les moyennes (« les 3 tranches qui maximisent l'écart »), c'est **choisir** la conclusion — le segment n'est plus une découpe, c'est un argument.

Définition. variable tierce — confond — la troisième variable qui **cause les deux** variables observées : ici, le niveau d'origine (proxy : la note du T1) pousse l'absence **et** la note du T2. La tester, c'est **contrôler** : comparer à elle égale (par bande) — la corrélation résiduelle est le lien **direct**, le reste est le fil de la tierce variable.

5.5 Comparer des groupes — à taille égale, ou en le disant

Le fil rouge fournit le contre-exemple (exécuté) : le panier moyen par **mode de paiement** (5 groupes) :

id_mode	n ventes	panier moyen	médiane
1	20175	157863	120134
2	12366	157205	116052
3	12322	159573	121794
4	2593	156150	120315
5	2552	159959	120545

Deux leçons :

1. **Les tailles inégales mentent** : le groupe 1 compte **8 fois** plus de ventes que le groupe 5 (20 175 vs 2 552) — une différence de panier de 2 % entre des groupes de cette taille est **du bruit** (la variance d'un groupe de 2 552 est bien plus grande que celle d'un groupe de 20 175). La phrase du rapport : « les 5 modes de paiement ne différencient **pas** le panier moyen (écart max 2 %, groupes de 20 175 à 2 552 ventes) » — l'écart **et** les tailles, les deux chiffres.
2. **Les moyennes suivent, les médianes disent** : les moyennes vont de 156 150 à 159 959 (2 %), les médianes de 116 052 à 121 794 (5 %) — la **médiane** est plus lisible ici (distribution à queue haute, C02), et les deux vont **ensemble** dans la phrase.

Le **bon** comparé de groupes sur le socle : le **taux d'absence par classe** (exécuté) — 5e : 3.35 j (n=110), 4e : **4.26 j** (n=105), 3e : 2.63 j (n=100), 2nde : 2.35 j (n=85) : les groupes sont **à taille proche** (85 à 110, rapport de 1.3), et l'écart 4e vs 2nde est de **1.91 jour** d'absence — un écart **réel**, pas du bruit de taille : « la 4e est la classe la plus absente (4.26 jours), à effectif proche des autres classes ».

Le **tableau croisé** (fréquence d'un couple de modalités) est le troisième regard, ici sur matière × trimestre (moyennes exécutées) :

matiere	T1	T2	T3
anglais	10.16	10.28	10.19
français	10.76	10.89	10.75
histoire_geographie	11.40	11.36	11.45
maths	9.83	9.91	9.85
sciences	10.62	10.52	10.59

Deux lectures : (1) **rien ne bouge entre trimestres** (chaque matière varie d'environ 0.1 point) — le tableau croisé **vide** est une information : pas d'effet de trimestre, l'étape se **déclare** (C01) ; (2) le **classement des matières est stable** : histoire_geographie (11.4) devant français (10.8), sciences (10.6), anglais (10.2) et maths (9.9) — la matière la plus « facile » n'est pas celle qui a la meilleure moyenne au T3, c'est celle qui en a eu **la meilleure en continu** : le classement se lit sur les 3 trimestres, pas sur un.

Définition. tableau croisé — tableau de contingence — la fréquence (ou la moyenne) d'un **couple de modalités** : matière × trimestre ici, 5×3 cases. Sa force est la **comparaison en cases** : « rien ne bouge entre trimestres » se voit sur les 3 colonnes d'une ligne, « le classement est stable » sur les 5 lignes d'une colonne — deux lectures que la moyenne globale (10.57) ne donne pas.

Attention. Comparer des groupes **sans dire leurs tailles**, c'est faire passer le bruit pour une différence : 2 % d'écart de panier sur 2 552 ventes n'est pas une « préférence de paiement », c'est de la variance. La phrase complète est toujours **écart + tailles** — sans les deux chiffres, la comparaison ne sort pas du brouillon.

5.6 Formuler l'hypothèse et la tester — l'étape 8

Le gabarit (C02 §5.5) s'applique à la relation (exécuté sur le socle) :

« Si l'absence fait baisser la note (effet direct), alors, à niveau T1 égal, plus d'absences au T2 doivent donner une note T2 plus basse — et si ce n'est pas le cas (ou si l'écart est nul), l'association vient de la tierce variable. »

Le test est le tableau du §5.2 : à niveau T1 contrôlé, la corrélation résiduelle est **faible et instable** ($-0.145 / -0.085 / +0.163$) — l'hypothèse « effet direct fort » est **rejetée sur la période** ; l'association brute (-0.232) **persiste** (les bandes restent globalement négatives) : la conclusion provisoire honnête est « association négative modérée, **partiellement** expliquée par le niveau d'origine ; le fichier ne permet pas de chiffrer la part exacte » — avec les limites (proxy T1, 1 année scolaire, 3 élèves absents-notés non exclus du brut).

À retenir. Une corrélation se **publie** avec ses 4 chiffres : la valeur (-0.232), la taille ($n=400$), le **contrôle** (bandes de T1), et la **limite** (proxy, période) — les 4 ensemble, ou la phrase ne part pas.

6. Exemple concret — le fil rouge : 0.552, 0.001, et la clientèle plate

Le parcours complet de la leçon scale → comportement (exécuté) :

1. **Le signal** : `corr(montant_remise, montant_ttc) = 0.552` — « les remises vont avec les gros montants » ?
2. **Le test de scale** : le **taux** de remise (`montant_remise / montant_ttc`, max **0.015** sur la base) corrélé au montant = **0.001** — la corde retombe : c'était le scale, pas un comportement. (45.5 % des ventes n'ont **aucune** remise : le taux est 0 pour elles, le montant non.)
3. **La clientèle, segmentée** : 1 200 clients, le **top 10 %** (120 clients) pèse **13.8 %** du CA — une clientèle **plate** (un top 10 % qui pèse 40 % serait concentré, 13.8 % ne l'est pas) ; le top 1 (client 73, 11 561 025 FCFA) pèse à lui seul **0.15 %** — le « gros client » de M07 reste **un client, pas un bug** (C04).
4. **La leçon** : chaque association du fil rouge a passé son test de scale (taux, pas montants) avant de devenir une phrase — et la phrase est « pas de lien entre le taux de remise et le montant », pas « remises et montants vont ensemble ».

7. Démonstration pas à pas — 5 étapes sur les deux jeux

```
import pandas as pd
s = "03_exercices/dossier_M09"
no = pd.read_csv(s + "/scolaire/note.csv")
ab = pd.read_csv(s + "/scolaire/absence.csv")
v = pd.read_csv(s + "/quincaillerie/vente.csv")

# 1 – la corrélation brute (scolaire)
no = no[(no["note"] >= 0) & (no["note"] <= 20)]
abs_par = ab.groupby("id_eleve")["duree_jours"].sum()
taux = abs_par.reindex(sorted(no["id_eleve"].unique()), fill_value=0)
moy = no.groupby("id_eleve")["note"].mean()
print(round(float(moy.corr(taux.reindex(moy.index))), 3))

# 2 – le contrôle de la tierce variable (bandes de T1)
t1 = no[no["trimestre"] == 1].groupby("id_eleve")["note"].mean()
t2 = no[no["trimestre"] == 2].groupby("id_eleve")["note"].mean()
abs_t2 = ab[(ab["date"] >= "2025-12-01") & (ab["date"] <= "2026-02-28")
            & (ab["type"] == "absence")].groupby("id_eleve").size()
d = pd.DataFrame({"t1": t1, "t2": t2, "abs": abs_t2.reindex(t1.index, fill_value=0)}).dropna()
print(round(float(d["abs"].corr(d["t2"])), 3))
print([round(float(d[(d.t1 >= lo) & (d.t1 < hi)]["abs"].corr(d[(d.t1 >= lo) & (d.t1 < hi)]
["t2"]))), 3)
      for lo, hi in [(8, 10), (10, 12), (12, 14)]]

# 3 – les segments (np.where) et leur gradient
seg = pd.cut(taux, [-0.1, 1.9, 5.9, 99], labels=["<2", "2-5", ">=6"])
print(pd.DataFrame({"seg": seg, "moy": moy}).groupby("seg", observed=True)["moy"]
      .agg(["count", "mean"]).round(2).to_string())

# 4 – le test de scale (fil rouge)
print(round(float(v["montant_remise"].corr(v["montant_ttc"])), 3),
      round(float((v["montant_remise"] / v["montant_ttc"]).corr(v["montant_ttc"])), 3))

# 5 – groupes à taille inégale : panier par mode (n + moyenne + médiane)
print(v.groupby("id_mode")["montant_ttc"].agg(["count", "mean", "median"]).round(0).to_string())
```

```
-0.232
-0.206
[-0.145, -0.085, 0.163]
      count      mean
seg
<2         123    11.13
2-5         208    10.51
>=6          69     9.76
0.552 0.001
      count      mean      median
id_mode
1         20175  157863.0  120134.0
2         12366  157205.0  116052.0
3         12322  159573.0  121794.0
4          2593  156150.0  120315.0
5          2552  159959.0  120545.0
```

8. Erreurs fréquentes

1. **Publier la corrélation comme cause** — « les absences font baisser les notes » avec -0.232 en note de bas de page : le chiffre prouve une **association**, les 3 fausses causes (§5.2) partagent l'hypothèse de cause — la phrase est « associés », jamais « causent ».
2. **Corréler un scale avec un montant** — 0.552 sur les remises en FCFA, **0.001** sur le taux : toujours s'assurer que la variable mesure le **comportement** (taux, part, fréquence), pas la **grandeur** (FCFA, unités).

3. **Comparer des groupes à taille inégale sans dire les tailles** — 2 % d'écart de panier sur 2 552 ventes : le bruit de taille fait l'écart — la phrase sans les n n'est pas une comparaison, c'est un accident.
4. **Définir le segment après avoir vu les moyennes** — « les 3 tranches qui maximisent l'écart de moyenne » : le segment **choisit** la conclusion ; les bornes (< 2 , 2-5, ≥ 6 jours) sont **métier** et précèdent le calcul.
5. **Oublier les absents-notés dans le calcul** — les 3 élèves du défaut S4 (13, 15, 15 absences au T2, 5 notes au T2 chacun) tirent la corrélation par construction : le chiffre brut (-0.232) et le chiffre **corrigé** vont **tous deux** dans la note (C06), avec l'écart publié.

9. Bonnes pratiques professionnelles

1. **Le coefficient va avec ses 4 chiffres** — valeur (-0.232), taille (n=400), contrôle (bandes de T1), limite (proxy, période) : les 4 ensemble, ou la phrase ne part pas.
2. **Le scale se teste avant d'être cité** — recalculer en **taux** (montant ÷ base) : si le coefficient retombe (0.552 → 0.001), c'était la grandeur, pas le comportement — et on publie le taux, pas le montant.
3. **Le confond se contrôle, pas se suppose** — identifier la tierce variable plausible (le niveau d'origine), la **mesurer** (proxy T1), contrôler **par bande** : c'est l'écart entre le brut et le contrôlé qui est l'information.
4. **Le groupe va avec son n** — écart + tailles dans la même phrase (panier par mode : 2 % sur 20 175 → 2 552) ; un groupe de moins de 100 observations se compare **en le disant** (« n=77 dans la bande haute »).
5. **La conclusion provisoire nomme ce qu'elle ne sait pas** — « le fichier ne départage pas les sens », « la part exacte de la tierce variable n'est pas chiffrable ici » : ce qui est **non mesuré** se dit, il ne se tait pas.

Conseil professionnel. Dans la note d'EDA (C06), chaque corrélation publiée porte son **encadré limite** : « association, pas causalité — contrôlé sur [X], non contrôlé sur [Y] ». Le lecteur professionnel **reconnait** le rapport à cet encadré : c'est la différence entre un stagiaire qui calcule et un analyste qui **garantit**.

10. Exercice guidé — « les 3 chiffres du jeu scolaire » (25 min, /10)

Consigne. Sur scolaire/ (audit C02 déjà fait) :

1. Recalculez la corrélation absentéisme × moyenne générale (formule du §5.1) et donnez son **ordre de grandeur** (faible / modérée / forte) et son **sens** (2 pts).
2. Contrôlez la tierce variable : les corrélations résiduelles **par bande de T1** (3 bandes) — et en une phrase, ce que le contrôle **révèle** (3 pts).
3. Segmentez l'absentéisme (< 2 , 2-5, ≥ 6 jours) : les 3 tailles, les 3 moyennes, et la **lecture** du gradient (3 pts).
4. Donnez le taux d'absence par classe et la classe la plus absente — avec les n des 4 classes (2 pts).

11. Exercices autonomes

E1 — Les 3 fausses causes, chacune identifiée (25 min). Sur le socle : (1) **variable tierce** — écrivez le test de contrôle (bandes de T1) et sa lecture ($-0.206 \rightarrow$ les 3 bandes) ; (2) **régression vers la moyenne** — les 2 groupes d'extrêmes du T1 (moyennes 7.01 et 14.93) et ce qu'ils font au T2 (7.21 et 14.61) : pourquoi ce mouvement **n'est pas** une cause ; (3) **sens inversé** — pourquoi le fichier ne départage **pas** « absence $\rightarrow$ note » de « note $\rightarrow$ absence », et la phrase honnête qui va dans le rapport.

E2 — Le petit groupe qui ment (20 min). Sur `vente.csv` : (1) le panier moyen par mode de paiement avec les **n** — l'écart max en % ; (2) montrez que l'écart est **du bruit de taille** (le rapport de n entre le plus grand et le plus petit groupe) ; (3) écrivez la phrase du rapport **complète** (écart + tailles + conclusion).

12. Correction détaillée

Exercice guidé.

1. **-0.232**, $n=400$: association **négative, modérée** ($|0.2|$ « modérée faible » à « modérée ») — les élèves plus absents ont des moyennes plus basses, mais une grande part de la variance reste hors absentéisme.
2. **Le contrôle** : brut $\text{abs_T2} \times \text{note_T2} = -0.206$; bandes de T1 : $[8,10) -0.145$ ($n=107$), $[10,12) -0.085$ ($n=139$), $[12,14) +0.163$ ($n=77$) — le contrôle **révèle** que le lien brut est **partiellement** le niveau d'origine (la tierce variable pousse l'absence et la note) : à niveau égal, le lien direct est faible et instable (même du signe inversé en haut de gamme).
3. **Les segments** : $n = 123 / 208 / 69$, moyennes **11.13 / 10.51 / 9.76** (médianes 11.21 / 10.40 / 9.51) — **gradient régulier** (-0.62 puis -0.75) : la signature d'un lien direct, pas d'un accident ; les 69 élèves du segment haut font 1.37 point de moins que les 123 du segment bas.
4. **Par classe** : 5e 3.35 j ($n=110$), 4e **4.26 j** ($n=105$), 3e 2.63 j ($n=100$), 2nde 2.35 j ($n=85$) — la **4e** est la plus absente, à effectif proche des autres (rapport 105/85 : des groupes comparables).

E1. (1) **Tierce variable** : le test est le contrôle par bande de T1 (§5.2) : -0.206 au brut, $-0.145 / -0.085 / +0.163$ contrôlé — l'écart est la part du **niveau d'origine** ; (2) **Régression vers la moyenne** : $T1 < 8$ (7.01) $\rightarrow$ T2 7.21 ($+0.20$) et $T1 > 14$ (14.93) $\rightarrow$ T2 14.61 (-0.32) : les deux extrêmes **reviennent vers le milieu** (10.57, la moyenne globale) **sans cause identifiée** — c'est la variance d'une note (anormalement basse a des chances d'être moins basse au trimestre suivant), pas « l'aide a marché » ; (3) **Sens inversé** : le fichier contient les deux variables **simultanément**, pas l'une avant l'autre (pas d'intervention, pas de variable « motivation ») — il ne peut **pas** départager « absence $\rightarrow$ note » de « note $\rightarrow$ absence » ; la phrase honnête : « association bidirectionnellement compatible ; le fichier ne départage pas les sens, une étude longitudinale (ou une intervention) le pourrait ».

E2. (1) Paniers moyens : 156 150 (mode 4, $n=2\,593$) à 159 959 (mode 5, $n=2\,552$) : l'écart max est de **2.4 %** entre les 5 modes (médianes : 116 052 à 121 794, soit 5 %) ; (2) **Bruit de taille** : le rapport de n est de **8** entre le plus grand groupe (20 175, mode 1) et le plus petit (2 552, mode 5) — la variance d'une moyenne est proportionnelle à $1/n$: la moyenne du groupe 2 552 est environ la **racine carrée de 8** (≈ 2.8) fois plus bruyante que celle du groupe 20 175 : 2.4 % est **dans** le bruit de ce rapport de tailles ; (3) **La phrase** : « Les 5 modes de paiement ne différencient pas le panier moyen : écart max 2.4 % (156 150 à 159 959 FCFA) pour des groupes de 2 552 à 20 175 ventes (rapport 8) — l'écart est du bruit de taille, pas une préférence de paiement » (les moyennes et médianes vont ensemble dans la phrase).

13. Mini-projet M09.P5 — « L'hypothèse testée, sa limite nommée » (1 h)

Énoncé. La section relations du rapport P2 (projet M09.P) doit contenir **une** hypothèse du gabarit C02 §5.5, **testée** sur le socle, avec : le cadre falsifiable (mécanisme, signature chiffrée, contre-exemple), la sortie du test (exécutée), et la **conclusion provisoire** avec ses limites nommées (proxy, période, variables absentes, sens non départagés). Auto-évaluation : la conclusion dit-elle ce qu'elle **ne sait pas** ? L'encadré « corrélation, pas causalité » est-il présent ? (Le projet M09.P et l'évaluation rejouent l'exercice sur le fichier inconnu — c'est le même gabarit.)

14. Boîte à outils du chapitre

Boîte à outils. La corrélation : `s1.corr(s2)` (Pearson) + ses 4 chiffres (valeur, n, contrôle, limite). Le scale : recalculer en **taux** (montant / base). Le confond : `pivot_table` / bandes (`np.where`, `cut`) + corrélation **par bande**. Le segment : `pd.cut` / `np.where` avec des bornes **métier**. Le groupe : `groupby.agg(["count", "mean", "median"])` — le n **toujours** avec l'écart. Le conteneur : le `DataFrame` — tableau de données — dataframe de pandas, qui porte toutes ces commandes.

Besoin	Commande	Chiffre du socle
corrélation	<code>s1.corr(s2)</code>	-0.232 (n=400)
contrôle confond	corr par bande de T1	-0.145 / -0.085 / +0.163
test de scale	<code>corr((a/b), c)</code>	0.552 → 0.001
segments	<code>pd.cut(taux, [-0.1, 1.9, 5.9, 99])</code>	123 / 208 / 69 → 11.13 / 10.51 / 9.76
groupes	<code>groupby.agg(["count", "mean", "median"])</code>	5 modes, 20 175 → 2 552, 2.4 %

15. Résumé du chapitre

Les étapes 7-8 du protocole (« les variables bougent-elles ensemble ? » / « que puis-je affirmer ? ») sont exécutées avec le **jeu scolaire qui fait son entrée** (402 élèves déclarés, 400 distincts, 6 000 notes, 1 687 absences/retards — 1 278 absences, 409 retards — et 4 défauts : 6 notes hors bornes, 2 doublons d'élèves dont un **avec contradiction** F/M, 4 absences un jour férié, 3 élèves **absents-notés** au T2 (13, 15, 15 absences, 5 notes chacun)) et avec le fil rouge. La corrélation absentéisme × résultats est **-0.232** (n=400) : association **négative, modérée** — et le contrôle de la **tierce variable** (le niveau d'origine, proxy T1) la **décompose** : -0.206 au brut, -0.145 / -0.085 / +0.163 par bande de T1 — une part du lien brut est la variable tierce, pas l'absence ; la **régression vers la moyenne** est mesurée (T1 < 8 : 7.01 → 7.21 ; T1 > 14 : 14.93 → 14.61, les extrêmes reviennent vers le milieu sans cause) ; le **sens** n'est pas départagé par le fichier (pas d'intervention, pas de variable motivation) — la phrase honnête le dit. Les **segments** d'absentéisme (bornes métier < 2, 2-5, ≥ 6 jours) font un **gradient régulier** : 123 / 208 / 69 élèves, moyennes 11.13 → 10.51 → 9.76 — des élèves, pas des valeurs. La **comparaison de groupes** passe par les tailles : les 5 modes de paiement ne différencient **pas** le panier (2.4 % d'écart, groupes de 2 552 à 20 175, rapport 8 : du bruit), alors que la 4e est la classe la plus absente (4.26 j vs 2.35 en 2nde, n=105/85 : un écart réel) ; et sur le fil rouge, le **scale** a imité un comportement (remises × montants 0.552, taux × montants **0.001**) — chaque association a passé son test de scale avant de devenir une phrase.

16. À retenir

À retenir. La corde se **tend** (`corr()`), le tour se **vérifie** (tierce variable, régression, sens), et la phrase part avec **ses 4 chiffres** (valeur, n, contrôle, limite) — « associés, jamais causent » est la règle d'or, et le scale est le tour le plus discret : $0.552 \rightarrow 0.001$ en changeant de variable.

1. **corr()** mesure le lien linéaire — pas la causalité, pas le lien en U, pas le comportement si l'une des variables est un scale.
2. **Les 3 fausses causes se mesurent** : tierce variable (contrôle par bande : $-0.206 \rightarrow -0.145 / -0.085 / +0.163$), régression ($7.01 \rightarrow 7.21, 14.93 \rightarrow 14.61$), sens (le fichier ne départage pas).
3. **Le coefficient va avec ses 4 chiffres** : valeur, n, contrôle, limite — les 4 ensemble, ou la phrase ne part pas.
4. **Segmenter = trancher avant de regarder** : les bornes sont métier ($< 2, 2-5, \geq 6$ j), le gradient ($11.13 \rightarrow 10.51 \rightarrow 9.76$) est la lecture, les 69 élèves du haut sont des **élèves**.
5. **Le groupe va avec son n** : 2.4 % d'écart sur 2 552 ventes est du bruit ; la 4e (4.26 j, $n=105$) est un écart réel à n proches.
6. **Le test de scale est obligatoire** : recalculer en taux — $0.552 \rightarrow 0.001$ sur les remises du fil rouge ; 0.015 de taux max, 45.5 % de ventes sans remise.
7. **La conclusion provisoire nomme ce qu'elle ne sait pas** : proxy, période, sens non départagés, absents-notés non exclus — l'encadré limite est la signature du rapport.

17. Évaluation formative (auto-correction, 8 min)

1. **La corrélation absentéisme × moyenne est -0.232 ($n=400$). Que dit ce chiffre, et que ne dit-il pas ?** → une association **négative, modérée** (les plus absents ont en moyenne des notes plus basses) ; il ne dit **pas** que l'absence **cause** la baisse (les 3 fausses causes partagent l'hypothèse de cause), pas la part exacte de la tierce variable, pas le sens. (2 pts)
2. **Pourquoi le contrôle par bande de T1 ($-0.145 / -0.085 / +0.163$) change-t-il la conclusion ?** → le contrôle **isole** la tierce variable (le niveau d'origine pousse l'absence et la note) : à niveau égal, le lien direct est **faible et instable** (même du signe inversé en bande haute) — l'association brute est **partiellement** la tierce variable, pas l'absence. (2 pts)
3. **Les élèves T1 < 8 (7.01) font 7.21 au T2. Pourquoi « l'aide a marché » est une lecture en trop ?** → c'est la **régression vers la moyenne** : les extrêmes retournent vers le milieu (10.57) **sans cause** — une note anormalement basse a des chances d'être moins basse au trimestre suivant ; le contrôle est la **moyenne de tous** les élèves sur la même transition, pas soi-même. (2 pts)
4. **Pourquoi le fichier ne départage pas « absence → note » de « note → absence » ?** → les deux variables sont **simultanées** (pas d'intervention, pas de variable motivation, pas d'ordre causal mesurable) ; la phrase honnête : « association bidirectionnellement compatible, le fichier ne départage pas les sens ». (2 pts)
5. **Les 5 modes de paiement font 2.4 % d'écart de panier (156 150 à 159 959). Est-ce une préférence de paiement ?** → non : groupes de 2 552 à 20 175 ventes (rapport 8) — l'écart est **dans** le bruit de taille (variance de la moyenne $\propto 1/\sqrt{n}$) ; la phrase complète : écart + tailles + « pas de différenciation ». (2 pts)
6. **Les segments d'absentéisme ($< 2, 2-5, \geq 6$ j) donnent 11.13 / 10.51 / 9.76. Pourquoi ce gradient est-il « la signature d'un lien direct » ?** → il est **régulier** (-0.62 puis -0.75 , pas de saut accidentel) et la **médiane suit la moyenne** (pas de queue qui tire) : un lien direct se lit en gradient monotone ; un accident de groupe ferait sauter une tranche sans l'autre. (2 pts)

7. **Remises × montants : 0.552. Taux × montants : 0.001. Quelle est la leçon, et quelle variable publie-t-on ?** → le **scale** (la remise en FCFA) grandit avec le montant **sans comportement** : c'est la grandeur, pas le choix ; on publie le **taux** (max 0.015, 45.5 % des ventes à taux nul) — et la conclusion « pas de lien entre taux de remise et montant ». (2 pts)
8. **Les 3 élèves du défaut S4 (13, 15, 15 absences au T2, 5 notes chacun). Pourquoi sont-ils un problème pour la corrélation ?** → ce sont des **absents-notés** : maximum d'absences **et** notes présentes — ils tirent la corrélation **par construction** (le défaut S4) ; le chiffre brut (−0.232) et le chiffre **hors les 3** vont tous deux dans la note (C06), avec l'écart publié. (2 pts)

Module M09.C06 — Visualisations d'exploration et conclusions provisoires : la note d'EDA

Outils : pandas 2.2.3, numpy 2.3.5, matplotlib 3.10.9, seaborn 0.13.2 (exécutés). **Durée indicative :** 5 h. **Niveau :** N3. **Prérequis :** M09.C01-C05 (les 5 étapes précédentes), M08.C08 (les 4 graphiques de base).

L'idée du chapitre. L'étape 9 pose la question : « **quel graphique répond à la question ?** » et l'étape 10 : « **que dis-je, et quelles sont mes limites ?** » C06 choisit le graphique **par question** (courbe = évolution, barres = comparaison, boxplot = dispersion par groupe, histogramme = forme, nuage = association), passe les **5 erreurs d'exploration** en revue (l'axe qui ne part pas à zéro **sans le dire**, le graphique sans question, la couleur qui porte une info non mentionnée, l'échelle logarithmique surprise, le nuage sans taille d'échantillon), et produit le livrable de fin de module : la **note d'EDA** — 1 page par jeu, chaque affirmation porte sa **source** (sortie exécutée) et sa **limite**. Le fil rouge y revient **complet** : la note de la quincaillerie, avec les 3 jeux chacun en un paragraphe. Et la transition vers M10 : « Vos résultats sont justes. S'ils sont illisibles, ils ne serviront à rien. »

Matériel de l'atelier — Python 3.13 · pandas 2.2.3 · numpy 2.3.5 · matplotlib 3.10.9 · seaborn 0.13.2. Tous les graphiques ont été **exécutés** dans l'atelier le 20/09/2026 sur `03_exercices/dossier_M09/` (graine 45, déterministe, ATTENDU.json figé) ; les codes publiés sont **ceux de l'atelier**, et chaque sortie citée est une sortie exécutée.

1. Objectifs du chapitre

À la fin de ce chapitre, vous savez :

1. **Choisir le graphique par question** : évolution → courbe, comparaison → barres (avec les n), dispersion par groupe → boxplot, forme → histogramme, association → nuage — la table question → graphique du module.
2. **Repérer les 5 erreurs d'exploration** et les **écrire en contrôle** : axe sans zéro **déclaré**, graphique sans question, couleur informante non mentionnée, échelle logarithmique **annoncée**, nuage avec **n**.
3. **Produire les 4 graphiques du projet** en `matplotlib` (courbe CA + bâche, barres paniers par mode, nuage montant × taux, boxplot notes par segment) — chaque graphique légendé : question + source + ce qu'on doit retenir.
4. **Utiliser seaborn pour le confort** (boxplot, heatmap des tableaux croisés) — et savoir que le **même** boxplot se fait en `matplotlib` pur (dépendance minimale) ou en `seaborn` (l'option confort, documentée).
5. **Écrire la note d'EDA** : 1 page par jeu, affirmation + **source** (sortie) + **limite** — et **en lire une écrite par quelqu'un d'autre** (rétro-lecture : repérer les 5 erreurs dans une note d'autrui).

2. Pourquoi cette notion est importante

Le rapport EDA se **lit** avant de se **vérifier** : un lecteur pressé ne relancera pas vos commandes, il regardera vos graphiques et vos phrases. Et c'est précisément là que l'exploration ment le plus

souvent — pas dans les chiffres (vérifiés par le protocole, C01-C05), mais dans **leur présentation** : un axe qui dramatise, une couleur qui raconte, un graphique qui ne répond à rien. Trois faits du socle fixent l'enjeu :

- la courbe du CA mensuel sur **axe 310-350 M** (pas à zéro) donne l'impression d'une forte variation ; sur **axe à zéro**, elle est **plate** — deux graphiques du **même** chiffre, deux lectures opposées ;
- le nuage montant $\times$ taux de remise **sans n** est illisible : 50 008 points à transparence 0.25 **ou** un nuage clair de 200 points ressemblent à la même chose — la taille d'échantillon change la lecture, elle doit être **dans** le titre ;
- la note d'EDA du fil rouge tient en **4 affirmations**, chacune avec sa source (sortie) et sa limite — c'est le livrable **P4** du projet, et l'épreuve de palier P2 le note sur la **limite** (ce que l'affirmation ne sait pas), pas sur le chiffre.

3. Explication simple — la conversation avec la machine

Le graphique est la **traduction** d'une sortie vers un lecteur. Comme toute traduction, elle peut trahir :

1. **La question d'abord** — « ce graphique répond à **quelle** question ? » : une courbe sans question est une décoration, un boxplot sans question est un amas de moustaches. La question est **dans le titre**, pas dans la légende.
2. **L'axe est une décision** — partir de zéro ou non, c'est un **choix d'édition** : sur des données **relatives** (part, taux), zéro est honnête ; sur des **niveaux** (CA mensuel 300-350 M), zéro écrase la variation — l'**axe non zéro** est légitime **s'il est déclaré** (« axe de 310 à 350 M »), jamais s'il est silencieux.
3. **La couleur raconte** — une couleur par groupe **sans légende** est une info cachée ; le **n** manquant est une échantillon fantôme ; l'échelle log **surprise** est une distribution qu'on a cachée. Les 5 erreurs d'exploration, c'est la liste de contrôle de la **présentation**, pas du calcul.

La note d'EDA est la **dernière étape du protocole** : 1 page, chaque affirmation **sourcée** (la sortie qui la prouve) et **limitée** (ce qu'elle ne dit pas). Le module s'arrête là — et c'est le livrable : pas 40 graphiques jolis, 4 graphiques qui **répondent** et 1 page qui **garantit**.

4. Vocabulaire essentiel

Terme	Définition
graphique — chart — la traduction visuelle d'une sortie vers un lecteur ; se choisit par question (courbe/barres/boxplot/histogramme/nuage) et se légende (question + source + n).	
légende	le bloc texte du graphique : question posée, source (sortie exécutée), taille d'échantillon (n), et l'axe quand il ne part pas de zéro.
biais de sélection — biais d'échantillonnage — l'écart entre la population étudiée (le fichier) et la population visée (le métier) : les 1 200 clients du fil rouge ne sont pas tous les clients du groupe.	
note d'EDA	le livrable de fin d'exploration : 1 page par jeu, chaque affirmation = source (sortie) + limite (ce qu'elle ne dit pas).

5. Cours approfondi

5.1 Choisir le graphique par question — la table du module

Question	Graphique	Pourquoi	Chiffre du socle
« Ça monte, ça descend, ça cycle ? »	courbe (+ n) (bâche)	(+ l'axe horizontal est le temps	CA mensuel 307-348 M, mg3 320-337 M
« Les groupes se comparent-ils ? »	barres (+ n)	la longueur est la valeur, le n est la fiabilité	panier par mode, n 2 552 à 20 175
« La dispersion change-t-elle par groupe ? »	boxplot	médiane, iqr, queues — la forme du groupe	notes par segment d'absentéisme
« Quelle est la forme de la variable ? »	histogramme	la répartition des valeurs , pas des temps	montants 762.63 à 594 363 FCFA
« Les variables bougent -elles ensemble ? »	nuage (+ n)	chaque point est une observation	montant × taux de remise (n=50 008)

Le préambule de M10 tient dans cette table : on ne choisit **pas** un graphique « qui est joli », on choisit **celui qui répond** — et M10 (visualisation) fera le chemin inverse (le graphique de **communication**, avec ses règles d'édition). En **exploration** (M09), le graphique est au service de la **question**, pas du lecteur final.

Définition. légende — le bloc texte du graphique : la **question** posée (dans le titre), la **source** (la sortie exécutée), la **taille d'échantillon** (n) et **l'axe** quand il ne part pas de zéro. Un graphique sans légende est une image ; un graphique avec légende est une **réponse** — et c'est la légende que le lecteur **vérifie** (pas le code, qu'il ne relance pas).

Le graphique se choisit PAR QUESTION — la table du module (tout est exécuté)

Pas un graphique « joli », celui qui répond. La légende : question + source + n + axe déclaré s'il n'est pas à zéro.

QUESTION	GLYPHE	RÉPONSE (sortie exécutée)
Ca monte, ça descend, ça cycle ? courbe (+ bâche)		CA mensuel 307-348 M, mg3 320-337 M plat, +1.6 % à mois égal (déclaré)
Les groupes se comparent-ils ? barres (+ les n)		panier par mode : écart 2.4 % n de 2 552 à 20 175 : c'est le bruit
La dispersion change par groupe ? boxplot		notes par segment : médianes 11.21 / 10.40 / 9.51 : un gradient
Quelle est la forme de la variable ? histogramme		montants 762.63 à 594 363 (ratio ~780) plateau x6 au maximum (plafond)
Bougent-elles ensemble ? nuage (+ le n)		montant x taux : corr 0.001 (n=50 008) pas de lien (remise = 45.5 % des ventes)

Les 5 contrôles de présentation (la rétro-lecture, dans l'ordre) :

(1) question dans le TITRE · (2) axe déclaré si non zéro · (3) couleur avec légende · (4) log annoncée · (5) n au titre

Le livrable de fin : la note d'EDA (1 page par jeu) — affirmation + source + limite

« Le CA est plat sur 24 mois (mg3 320-337 M). Source : G1 exécutée. Limite : décembre 2026 partiel (28 j), exclu. »
La limite se lit à voix haute : si « et sa limite est que ... » reste vide, on recule l'affirmation.

Transition M10 : « Vos résultats sont justes. S'ils sont illisibles, ils ne serviront à rien. »

5.2 Les 5 erreurs d'exploration — et leur contrôle

1. **L'axe qui ne part pas à zéro sans le dire.** La courbe du CA mensuel sur axe 310-350 M (exécuté) « dramatise » la variation (l'œil lit un delta de 40 M comme une onde) ; sur axe à zéro, la même courbe est plate. **Le contrôle** : l'axe non zéro est **déclaré** dans la légende (« axe 310-350 M ») — jamais silencieux.
2. **Le graphique sans question.** Un boxplot « des notes » sans question ne répond à rien. **Le contrôle** : la question est **dans le titre** (« Notes par segment d'absentéisme : la dispersion change-t-elle ? »), pas dans un sous-titre.
3. **La couleur qui porte une info non mentionnée.** Colorer les points par `est_retour` sans le dire dans la légende, c'est **raconter** une info cachée. **Le contrôle** : chaque couleur a sa **légende** — pas de couleur orpheline.
4. **L'échelle logarithmique surprise.** Les montants vont de 762.63 à 594 363 FCFA (ratio ~780) : en échelle log, le **plateau** des 6 ventes à 594 363 (C04) se « lisse » et disparaît visuellement. **Le contrôle** : l'échelle log est **annoncée** (« axe log ») — elle est un **choix d'édition**, pas un défaut.
5. **Le nuage sans taille d'échantillon.** Le nuage montant $\times$ taux (exécuté, $n=50\,008$, transparence 0.25) : sans le n dans le titre, le lecteur ne sait pas s'il voit 50 008 points ou 200. **Le contrôle** : le **n est dans le titre** (« $n = 50\,008$ ventes »), et la transparence est **mentionnée** si elle masque des points.

Attention. L'erreur la plus coûteuse pour le lecteur pressé n'est pas le chiffre faux (le protocole l'a vérifié, C01-C05) : c'est la **présentation** qui ment — un axe qui **dramatise**, un n qui **masque**, une couleur qui **raconte**. Le chiffre est garanti ; la **traduction** est le chapitre, et elle se **contrôle** (les 5 contrôles, §5.2), elle ne se **suppose** pas.

Définition. graphique — chart — la traduction visuelle d'une sortie vers un lecteur. Il se choisit **par question** (table §5.1), il se **légende** (question + source + n + l'axe s'il n'est pas à zéro), et il est **exécuté** (le code est re-jouable, la sortie est citée). Un graphique sans question est une décoration ; un graphique sans n est un échantillon fantôme.

5.3 matplotlib — les 4 graphiques du projet

Les 4 graphiques du livrable P3, **exécutés** (les codes sont ceux de l'atelier) :

```

import matplotlib as mpl; mpl.use("Agg")
import matplotlib.pyplot as plt
import pandas as pd
s = "03_exercices/dossier_M09"
v = pd.read_csv(s + "/quincaillerie/vente.csv", parse_dates=["date_vente"])
v["ct"] = (v["montant_ttc"] * 100).round().astype("int64")

# G1 – courbe : CA mensuel (sans retours) + moyenne glissante 3
vt = v[~v["est_retour"]].groupby(v["date_vente"].dt.to_period("M"))["ct"].sum() // 100
t = vt.index.to_timestamp()
fig, ax = plt.subplots(figsize=(8, 4), dpi=100)
ax.plot(t, vt.values / 1e6, "o-", ms=3, label="CA mensuel (M FCFA, sans retours)")
ax.plot(t, vt.rolling(3).mean().values / 1e6, "-", lw=2, label="moyenne glissante 3 mois")
ax.set_title("CA mensuel – ça monte, ça descend, ça cycle ? (n = 24 mois, axe 310-350 M)")
ax.legend(); ax.set_ylabel("M FCFA")
fig.tight_layout(); fig.savefig("g1_ca_mensuel.png"); plt.close(fig)

# G2 – barres : panier moyen par mode de paiement, avec les n
pm = v.groupby("id_mode")["montant_ttc"].agg(["count", "mean"]).reset_index()
fig, ax = plt.subplots(figsize=(7, 4), dpi=100)
ax.bar(pm["id_mode"].astype(str), pm["mean"] / 1e3)
for i, r in pm.iterrows():
    ax.text(i, r["mean"] / 1e3, f"n={int(r['count'])}", ha="center", va="bottom", fontsize=8)
ax.set_title("Panier moyen par mode de paiement – les tailles sont dans le graphique")
ax.set_ylabel("k FCFA"); ax.set_xlabel("id_mode")
fig.tight_layout(); fig.savefig("g2_panier_mode.png"); plt.close(fig)

# G4 – nuage : montant x taux de remise, avec le n
v["rr"] = v["montant_remise"] / v["montant_ttc"]
fig, ax = plt.subplots(figsize=(6, 4), dpi=100)
ax.scatter(v["montant_ttc"] / 1e3, v["rr"], s=4, alpha=0.25)
ax.set_title(f"Montant x taux de remise (n = {len(v)} ventes ; corr = 0.001 ; transparence 0.25)")
ax.set_xlabel("montant TTC (k FCFA)"); ax.set_ylabel("taux de remise")
fig.tight_layout(); fig.savefig("g4_montant_remise.png"); plt.close(fig)

```

Ce que chacun répond (la légende, pas la décoration) :

- **G1** — « Ça monte, ça descend, ça cycle ? » : la bâche (orange) est **plate** (320-337 M), la série (bleue) oscille (307-348 M) — **ni cycle, ni dérive forte** (C03 : +1.6 % à mois égal) ; le titre **déclare l'axe 310-350 M** (erreur n°1 contrôlée).
- **G2** — « Les paniers diffèrent par mode ? » : les barres sont **quasi identiques** (156-160 k), et les **n sont dans le graphique** (2 552 à 20 175) — l'écart de 2.4 % est **du bruit de taille** (C05), la légende le dit.
- **G4** — « Remises et montants vont-ils ensemble ? » : le nuage est une **bande horizontale** (taux 0 à 0.015, corr 0.001) — **pas de lien** ; le **n est dans le titre**, la transparence est **mentionnée** (erreurs n°5 et n°3 contrôlées).

5.4 seaborn — le confort, documenté

seaborn (option confort) reprend le **même** boxplot et fait la **heatmap** des tableaux croisés, **exécutés** :

```

import seaborn as sns
import pandas as pd
s = "03_exercices/dossier_M09"
no = pd.read_csv(s + "/scolaire/note.csv")
ab = pd.read_csv(s + "/scolaire/absence.csv")
el = pd.read_csv(s + "/scolaire/eleve.csv")
no_p = no[(no["note"] >= 0) & (no["note"] <= 20)].copy()
abs_par = ab.groupby("id_eleve")["duree_jours"].sum()
taux = abs_par.reindex(sorted(no_p["id_eleve"].unique()), fill_value=0)
no_p["seg"] = pd.cut(taux.reindex(no_p["id_eleve"].values, fill_value=0).values,
                    [-0.1, 1.9, 5.9, 99], labels=["<2 j", "2-5 j", ">=6 j"])

# G3 – boxplot : notes par segment d'absentéisme
fig, ax = plt.subplots(figsize=(6, 4), dpi=100)
sns.boxplot(data=no_p, x="seg", y="note",
            order=["<2 j", "2-5 j", ">=6 j"], ax=ax)
ax.set_title("Notes par segment d'absentéisme : la dispersion change-t-elle ? (n = 6000 notes)")
fig.tight_layout(); fig.savefig("g3_notes_segment.png"); plt.close(fig)

# G5 – heatmap : le tableau croisé matière x trimestre (C05)
h = no_p.pivot_table(index="matiere", columns="trimestre", values="note", aggfunc="mean")
fig, ax = plt.subplots(figsize=(6, 4), dpi=100)
sns.heatmap(h, annot=True, fmt=".2f", cmap="viridis", ax=ax)
ax.set_title("Moyennes matière x trimestre (heatmap seaborn) – n = 6000 notes")
fig.tight_layout(); fig.savefig("g5_heatmap.png"); plt.close(fig)

```

Le boxplot (G3) répond « la dispersion change-t-elle par segment ? » : les 3 boîtes montrent le **gradient** (médianes 11.21 / 10.40 / 9.51) **et** les queues — la médiane descend de 1.7 point du segment bas au segment haut. **La heatmap** (G5) est le **tableau croisé** (C05 §5.5) rendu lisible : les cases stables (± 0.1) se voient, le **classement des matières** (histoire_géographie en tête) se lit sur les 5 lignes. Le **même** boxplot se fait en matplotlib pur (ax.boxplot) — matplotlib est la **dépendance minimale** (le projet l'utilise), seaborn est l'**option confort**, et les deux produisent le **même** graphique sur les **mêmes** données.

Attention. Un graphique produit en seaborn **sans** son équivalent matplotlib est une **dépendance non documentée** : le lecteur (et l'évaluateur) doit pouvoir **re-jouer** le graphique avec la dépendance minimale — c'est la raison pour laquelle le projet utilise matplotlib et seaborn est **documenté**, pas **implicite**.

Définition. biais de sélection — biais d'échantillonnage — l'écart entre la population **étudiée** (le fichier) et la population **visée** (le métier) : les 1 200 clients du fil rouge ne sont pas **tous** les clients du groupe, les 400 élèves ne sont pas **tous** les élèves de l'établissement. C'est la **limite** la plus fréquente de la note d'EDA : on ne généralise qu'à la **population du fichier**, pas au-delà — et on le **dit**.

5.5 La note d'EDA — 1 page, affirmation + source + limite

La note d'EDA (l'étape 10, le livrable **P4**) est **1 page par jeu**. Chaque affirmation porte **3 choses** : la **phrase** (ce qu'on dit), la **source** (la sortie exécutée qui la prouve), et la **limite** (ce qu'elle **ne** dit pas). Le **contrôle** de la note : relire chaque affirmation et se demander « qu'est-ce que cette phrase **ne** peut **pas** conclure ? » — c'est la **limite**. La note de la quincaillerie (fil rouge) est au §6 ; voici sa **structure** (4 affirmations) :

1. **Tendance** : « Le CA (sans retours) est **plat** sur 24 mois » — source : G1 + mg3 (320-337 M) — limite : « décembre 2026 partiel (28 j), exclu ; 5 magasins agrégés, pas par magasin ».
2. **Données** : « 8 doublons métier exclus (50 008 → 50 000 ventes) » — source : duplicated (C01/C02) — limite : « les 15 deadlines inversées et les 21 406 dates naïves sont **déclarées**, non corrigées (source à confirmer) ».

3. **Clients** : « Le top 10 % des clients pèse 13.8 % du CA (clientèle plate) » — source : groupby CA — limite : « le fichier ne porte pas le **segment** client (particulier/entreprise) — lecture en CA seul ».
4. **Remises** : « Pas de lien taux de remise × montant (corr 0.001) » — source : G4 — limite : « 45.5 % des ventes sans remise ; conclusion en **taux**, pas sur la politique de remise ».

Définition. note d'EDA — le livrable de **fin** d'exploration : 1 page par jeu, où chaque affirmation porte sa **source** (la sortie exécutée, **re-jouable**) et sa **limite** (ce qu'elle **ne** dit pas, **remplie**). Ce n'est ni le rapport complet (10 étapes, P2), ni un résumé : c'est la **garantie** — le lecteur y vérifie les **limites**, pas les chiffres (déjà validés par le protocole).

À retenir. La note d'EDA **garantit** : chaque affirmation est **sourcée** (la sortie qui la prouve, re-jouable) et **limitée** (ce qu'elle ne dit pas, écrit). Le lecteur ne relance pas vos commandes — il lit vos **limites**. C'est **elles** qui font la différence entre un rapport de stagiaire et un rapport **d'analyste**.

5.6 Lire une note d'autrui — la rétro-lecture

L'exercice de **rétro-lecture** (un collègue a écrit la note, vous la lisez) est la meilleure école de la **présentation** : on repère les 5 erreurs **sans** relancer le code. Le contrôle de rétro-lecture tient en 5 questions, **dans l'ordre** :

1. **Quelle question** ce graphique répond-il ? (sinon : erreur n°2)
2. L'**axe** est-il à zéro, ou **déclaré** s'il ne l'est pas ? (sinon : erreur n°1)
3. Chaque **couleur** a-t-elle sa **légende** ? (sinon : erreur n°3)
4. L'**échelle** (log/lin) est-elle **annoncée** ? (sinon : erreur n°4)
5. Le **n** est-il **dans** le titre, et la transparence mentionnée ? (sinon : erreur n°5)

Une note qui passe les 5 questions est **présentable** ; une note qui en échoue une est **rejetée en présentation** (pas en calcul — les chiffres ont été vérifiés par le protocole, c'est la **traduction** qui est en défaut).

6. Exemple concret — la note d'EDA de la quincaillerie (fil rouge, complète)

NOTE D'EDA — Quincaillerie (fil rouge M07/M08) · période 2025-01-01 → 2026-12-28 · 5 magasins · 1 200 clients · 380 produits · source : `dossier_M09/quincaillerie` (empreinte `b9a8d973119342ec...`, 19 totaux = M07/M08).

1. **Le CA (sans retours) est plat sur 24 mois** : mensuel 307-348 M FCFA, moyenne glissante 3 mois entre 320 et 337 M — ni cycle de fin d'année (décembre 2025 : 315 M, sous la moyenne), ni dérive forte (+1.6 % à mois égal). Source : G1 (courbe + bâche, exécutée). Limite : décembre 2026 partiel (28 jours), exclu des conclusions ; agrégat des 5 magasins, pas par magasin.
2. **Les données portent 8 doublons métier, exclus** : 50 008 → 50 000 ventes distinctes, retours 208 → 200, écart CA retours 31 939 568 FCFA. Source : `duplicated` sur les 12 colonnes hors `id_vente` (C01/C02, exécuté). Limite : les 15 deadlines inversées et les 21 406 dates sous la condition naïve sont déclarées, non corrigées — correction soumise à la source.
3. **La clientèle est plate** : le top 10 % des clients (120) pèse 13.8 % du CA ; le top 1 (client 73, 11 561 025 FCFA) pèse 0.15 % à lui seul. Source : groupby CA par client (exécuté). Limite : le fichier ne porte pas le segment client (particulier / entreprise) — lecture en CA seul ; 1 200 clients, pas tous les clients du groupe (biais de sélection).

4. **Pas de lien entre le taux de remise et le montant** (corr 0.001, taux max 0.015) : le 0.552 obtenu en **FCFA** est un effet de **scale**, pas un comportement. Source : G4 (nuage, n=50 008, exécuté) + C05 §5.1. Limite : 45.5 % des ventes sans remise — la conclusion est en taux, pas sur la politique de remise.

Les 3 jeux, chacun en un paragraphe (la note rejoue les jeux 2 et 3 arrivés en C02/C05) : le **centre de santé** — « la fréquentation est **saisonnier** (étés 853 vs hivers 655 consultations/mois, pic 2025-07 : 882), avec une rupture **qui compte** (M01, 3 jours au pic de juillet) et 4 défauts de saisie corrigés par récurrence (545, 253, 278, 411) » (limite : 2 étés seulement, cause hors fichier) ; l'**établissement scolaire** — « absentéisme et résultats **associés** (−0.232), partiellement par une variable tierce (contrôle T1 : −0.145/−0.085/+0.163) ; la 4e est la classe la plus absente (4.26 j) » (limite : corrélation, pas causalité ; sens non départagé ; 3 élèves absents-notés non exclus du brut).

Dans les faits. La note d'EDA du fil rouge (celle-ci) tient en **4 affirmations** (une quinzaine de lignes de texte) et les 4 graphiques en **une quarantaine de lignes de code** : exécutés, les 5 graphiques de l'atelier (G1-G5) pèsent entre 20 et 59 Ko, et le **temps atelier** du livrable P3+P4 est d'environ **40 minutes** (les graphiques d'abord, la note ensuite, la rétro-lecture en dernier) : c'est le **livrable** du module, et il se **lit** en 3 minutes — c'est **ça** qu'on rend, pas 40 graphiques.

7. Démonstration pas à pas — 5 étapes sur les deux jeux

```
import matplotlib as mpl; mpl.use("Agg")
import matplotlib.pyplot as plt
import seaborn as sns
import pandas as pd
s = "03_exercices/dossier_M09"
v = pd.read_csv(s + "/quincaillerie/vente.csv", parse_dates=["date_vente"])
no = pd.read_csv(s + "/scolaire/note.csv")
ab = pd.read_csv(s + "/scolaire/absence.csv")

# 1 – la table question -> graphique (choix)
#   évolution -> courbe (G1) | comparaison -> barres+n (G2) | dispersion -> boxplot (G3)
#   forme -> histogramme | association -> nuage+n (G4)

# 2 – G1 : courbe CA + bâche (axe non zéro DECLARE dans le titre)
v["ct"] = (v["montant_ttc"] * 100).round().astype("int64")
vt = v[~v["est_retour"]].groupby(v["date_vente"].dt.to_period("M"))["ct"].sum() // 100
fig, ax = plt.subplots(figsize=(8, 4), dpi=100)
ax.plot(vt.index.to_timestamp(), vt.values / 1e6, "o-", ms=3)
ax.plot(vt.index.to_timestamp(), vt.rolling(3).mean().values / 1e6, "-", lw=2)
ax.set_title("CA mensuel – ça monte, ça descend, ça cycle ? (n = 24 mois, axe 310-350 M)")
fig.tight_layout(); fig.savefig("g1.png"); plt.close(fig)

# 3 – G2 : barres paniers par mode, avec les n
pm = v.groupby("id_mode")["montant_ttc"].agg(["count", "mean"]).reset_index()
fig, ax = plt.subplots(figsize=(7, 4), dpi=100)
ax.bar(pm["id_mode"].astype(str), pm["mean"] / 1e3)
for i, r in pm.iterrows():
    ax.text(i, r["mean"] / 1e3, f"n={int(r['count'])}", ha="center", va="bottom", fontsize=8)
ax.set_title("Panier moyen par mode de paiement – les tailles sont dans le graphique")
fig.tight_layout(); fig.savefig("g2.png"); plt.close(fig)

# 4 – G3 : boxplot seaborn (notes par segment d'absentéisme)
no_p = no[(no["note"] >= 0) & (no["note"] <= 20)].copy()
taux = ab.groupby("id_eleve")["duree_jours"].sum()
no_p["seg"] = pd.cut(taux.reindex(no_p["id_eleve"].values, fill_value=0).values,
                    [-0.1, 1.9, 5.9, 99], labels=["<2 j", "2-5 j", ">=6 j"])
fig, ax = plt.subplots(figsize=(6, 4), dpi=100)
sns.boxplot(data=no_p, x="seg", y="note", order=["<2 j", "2-5 j", ">=6 j"], ax=ax)
ax.set_title("Notes par segment d'absentéisme (n = 6000 notes)")
fig.tight_layout(); fig.savefig("g3.png"); plt.close(fig)

# 5 – la note d'EDA : chaque affirmation = phrase + source + limite (le $6 est la sortie)
print("note d'EDA : 4 affirmations fil rouge + 3 jeux (voir $6)")
```

8. Erreurs fréquentes

1. **L'axe non zéro silencieux** — la courbe CA sur axe 310-350 M **sans le dire** : le lecteur lit une onde là où il y a une série plate. L'axe non zéro est **légitime s'il est déclaré** (« axe 310-350 M » dans le titre), jamais silencieux.
2. **Le graphique sans question** — un boxplot « des notes » : la question est **dans le titre** (« la dispersion change-t-elle par segment ? »), sinon le graphique est une décoration, pas une réponse.
3. **La couleur orpheline** — colorer par `est_retour` sans légende : la couleur **raconte** une info cachée ; chaque couleur a sa **légende**, pas de couleur orpheline.
4. **L'échelle log surprise** — le plateau des 6 ventes à 594 363 (C04) **disparaît** en échelle log non annoncée : l'échelle log est un **choix d'édition**, elle est **annoncée** (« axe log »), jamais silencieuse.
5. **Le nuage sans n** — 50 008 points **ou** 200 points ressemblent à la même bande : le **n est dans le titre**, et la transparence est **mentionnée** si elle masque des points.

9. Bonnes pratiques professionnelles

1. **La question est dans le titre** — jamais dans un sous-titre ni dans le pied de page : le titre du graphique **est** la question (« Ça monte, ça descend, ça cycle ? »), la légende porte la source et le n.
2. **L'axe se déclare s'il n'est pas à zéro** — « axe 310-350 M » dans le titre ; sur des données **relatives** (part, taux), zéro est l'axe **honnête**.
3. **Le n est dans le titre, la transparence est mentionnée** — « n = 50 008 ventes ; transparence 0.25 » : l'échantillon **fantôme** est l'erreur la plus coûteuse du lecteur pressé.
4. **matplotlib pour le projet, seaborn pour le confort** — le même boxplot en `ax.boxplot` (dépendance minimale) ou en `sns.boxplot` (confort) : on documente **les deux** produisant le **même** graphique sur les **mêmes** données.
5. **La note d'EDA garantit les limites** — chaque affirmation : phrase + source (re-jouable) + **limite** (ce qu'elle ne dit pas) : c'est la limite qui fait la différence entre un stagiaire et un **analyste** (l'épreuve P2 note **la limite**).

Conseil professionnel. La note d'EDA se **lit à voix haute** avant d'être rendue : chaque affirmation « ... et sa limite est que ... » — si la phrase « et sa limite est que » reste **vide** pour une affirmation, c'est que l'affirmation **déborde** de ce que les données disent, et elle est **reculée** (ou retirée). La limite n'est pas une décoration de fin de phrase, c'est le **contrôle** de l'affirmation.

10. Exercice guidé — « la rétro-lecture de la note d'autrui » (25 min, /10)

Consigne. Un collègue a rendu cette note d'EDA (le code est **correct**, c'est la **présentation** qui est en cause). Repérez les **5 défauts de présentation** (1 pt chacun), puis réécrivez le **titre** et la **légende** de chaque graphique en les corigeant (2 pts pour l'ensemble) :

Note d'EDA — Quincaillerie · 5 magasins

1. Graphique A (courbe du CA mensuel, axe 310-350 M) : « Le CA est en **forte baisse** depuis mars 2026. »
2. Graphique B (barres du panier par mode, sans n) : « Les modes de paiement **différencient** le panier. »
3. Graphique C (nuage montant × remise **en FCFA**, sans n) : « Les remises **causent** la baisse du CA. »
4. Graphique D (boxplot des notes, sans question) : « Les notes des élèves. »
5. Affirmation : « Les 1 200 clients du fichier **représentent tous les clients** du groupe. »

11. Exercices autonomes

E1 — La note d'EDA du centre de santé (30 min). Écrire la **note d'EDA complète** (1 page) du jeu 2 : 4 affirmations (saisonnalité, rupture qui compte, 4 défauts corrigés, fréquentation type), chacune avec **source** (sortie exécutée) et **limite**. Contrainte : la phrase « et sa limite est que ... » doit être **remplie** pour chacune — une limite vide = une affirmation qui déborde.

E2 — Les 5 erreurs, chacune produite et contrôlée (30 min). Sur `vente.csv` : produire **chacune** des 5 erreurs d'exploration (axe non zéro silencieux, graphique sans question, couleur orpheline, échelle log surprise, nuage sans n) **puis** son **contrôle** (la déclaration qui la corrige) — 5 graphiques × 2, chacun légendé avant / après.

12. Correction détaillée

Exercice guidé — les 5 défauts de présentation :

1. **Graphique A — axe non zéro silencieux** (+ une **tendance fausse** : mars 2026 fait 338 M, **au-dessus** de la moyenne ; il n'y a **pas** de baisse) : déclarer « axe 310-350 M » dans le titre, et corriger la tendance (« le CA est **stable** autour de 328 M, mars 2026 à 338 M est **au-dessus** de la moyenne »).
2. **Graphique B — barres sans n** : les paniers sont **quasi identiques** (156-160 k, écart 2.4 %) pour des groupes de **2 552 à 20 175** ventes (rapport 8) — mettre les **n dans le graphique** et corriger (« les modes **ne différencient pas** le panier : écart 2.4 % sur des groupes de rapport 8 = bruit de taille »).
3. **Graphique C — nuage sans n + scale** (remises en **FCFA**, corr 0.552 = effet de scale, pas de comportement) + **causalité** (« causent ») : mettre le **n dans le titre**, passer au **taux** (corr **0.001**), et corriger (« **pas de lien** entre le **taux** de remise et le montant ; association, pas causalité »).
4. **Graphique D — boxplot sans question** : la question est **dans le titre** (« Notes par segment d'absentéisme : la **dispersion** change-t-elle ? (n = 6000 notes) »).
5. **Affirmation — biais de sélection** : les 1 200 clients du fichier ne sont **pas** tous les clients du groupe ; corriger (« les 1 200 clients du **fichier** — pas une population complète ; **limite** de généralisation »).

Ensemble (2 pts) : les 5 titres/légendes corrigés portent chacun la **question** (titre), la **source** (sortie), le **n**, et l'**axe déclaré** s'il n'est pas à zéro.

E1. (structure attendue, les sorties sont celles de l'atelier) — 1. Saisonnalité : « la fréquentation est **saisonnier** : étés 853 vs hivers 655 consultations/mois, pic 2025-07 (882), dimanche 405 vs lundi 3 710 » — source : groupby mois/jour de semaine (exécuté, C03) — limite : 2 étés seulement, la cause (pluies) est hors fichier. 2. **Rupture qui compte** : « **M01 rompu 3 jours (2025-07-14 → 16) au pic de juillet, M02 5 jours (2026-03-02 → 06), M04 2 jours** » — source : stock à zéro groupé (exécuté, C04) — limite : **c'est un fait (offre coupée), pas un défaut à corriger**. 3. **4 défauts corrigés** : « **4 stocks négatifs corrigés par récurrence (545, 253, 278, 411), 23 motifs vides gardés en signalant, 7 doublons exclus, 1 date future exclue** » — source : C04 (exécuté) — limite : **la date future est exclue, sa correction (2025-01-05) est **soumise à la source**. 4. Fréquentation type : « pic du matin (09:00 : 2 319), creux du midi (12:00 : 927) » — source : groupby heure (exécuté, C03) — limite : 10 heures seulement, pas de nuit/week-end différencié.

E2. (les 5 paires erreur → contrôle, sur vente.csv) — 1. Axe non zéro : courbe CA axe 310-350 M **silencieux** → **contrôle** : « axe 310-350 M » dans le titre. 2. Sans question : boxplot « des montants » → **contrôle** : « Montant par quantité : la **forme** change-t-elle ? (n = 50 008) ». 3. Couleur orpheline : points colorés par est_retour sans légende → **contrôle** : légende « rouge = retour, bleu = vente (n retours = 208) ». 4. Échelle log surprise : histogramme des montants en log **non annoncée** (le plateau 594 363 disparaît) → **contrôle** : « axe **log** » dans le titre. 5. Nuage sans n : montant × taux **sans n** → **contrôle** : « n = 50 008 ventes ; transparence 0.25 » dans le titre.

13. Mini-projet M09.P6 — « P3 + P4 : les 4 graphiques et la note » (1 h)

Énoncé. Le **livrable final** du projet M09.P : (P3) les **4 graphiques** du jeu travaillé, **chacun** légendé (question dans le titre, source, n, axe déclaré s'il n'est pas à zéro) ; (P4) la **note d'EDA** (1 page), 4 affirmations chacune avec **source** (re-jouable) et **limite** (remplie). Auto-évaluation : lire la note **à voix haute** — chaque « et sa limite est que ... » est-elle **remplie** ? Chaque graphique répond-il à une **question** écrite dans son **titre** ? Un graphique sans question ou une affirmation

sans limite = un livrable **incomplet** (pas un graphique joli, mais un graphique qui **répond**). Le projet M09.P s'arrête là : c'est le **livrable** du module — 4 graphiques qui répondent, 1 page qui garantit.

14. Boîte à outils du chapitre

Boîte à outils. Le choix : la table question → graphique (§5.1) — courbe/barres/boxplot/histogramme/nuage. `matplotlib` (dépendance minimale) : `ax.plot` (courbe), `ax.bar` (barres), `ax.scatter` (nuage), `ax.boxplot` (boxplot pur) ; `seaborn` (confort) : `sns.boxplot`, `sns.heatmap` (les tableaux croisés, C05). Les 5 contrôles question dans le titre, axe déclaré s'il n'est pas à zéro, chaque couleur a sa légende, échelle annoncée, n dans le titre. La note d'EDA : affirmation + source (re-jouable) + limite (remplie) — 1 page par jeu.

Besoin	Commande	Chiffre du socle
courbe + bâche	<code>ax.plot + rolling(3).mean()</code>	CA mensuel 307-348 M, mg3 320-337 M
barres + n	<code>ax.bar + ax.text(f"n={n}")</code>	panier par mode, n 2 552 à 20 175
boxplot	<code>sns.boxplot</code> (ou <code>ax.boxplot</code>)	notes par segment, médianes 11.21/10.40/9.51
nuage + n	<code>ax.scatter(alpha=0.25) + n</code> au titre	montant × taux (n=50 008, corr 0.001)
heatmap	<code>sns.heatmap(annot=True)</code>	matière × trimestre (5×3, stable)
forme	<code>ax.hist</code> (échelle log annoncée)	montants 762.63 à 594 363 (ratio ~780)

15. Résumé du chapitre

Les étapes 9-10 du protocole (« quel graphique répond à la question ? » / « que dis-je, et quelles sont mes limites ? ») sont exécutées pour **clôre le module** : le graphique se choisit **par question** (courbe = évolution, barres = comparaison **avec les n**, boxplot = dispersion par groupe, histogramme = forme, nuage = association **avec le n**), et passe les **5 erreurs d'exploration** en contrôle (l'axe non zéro **déclaré**, le graphique **avec question** dans le titre, la couleur **avec légende**, l'échelle log **annoncée**, le nuage **avec n**). Les **4 graphiques du projet** sont exécutés en `matplotlib` (courbe CA + bâche, barres paniers par mode **avec les n**, nuage montant × taux **avec le n**) et le **boxplot** + la **heatmap** en `seaborn` (le **même** boxplot se fait en `matplotlib` pur — `matplotlib` est la **dépendance minimale**, `seaborn` l'option **confort**, les deux produisent le **même** graphique sur les **mêmes** données). Le **livrable de fin** est la **note d'EDA** : 1 page par jeu, chaque affirmation = **phrase** + **source** (sortie re-jouable) + **limite** (remplie) — la note du fil rouge (quincaillerie) porte **4 affirmations** (tendance plate 307-348 M, 8 doublons exclus 50 008 → 50 000, clientèle plate top 10 % = 13.8 % du CA, pas de lien taux de remise × montant corr 0.001) et **rejoue les 3 jeux** chacun en un paragraphe (santé : saisonnier 853/655 + rupture qui compte ; scolaire : associé -0.232 partiellement par une tierce variable + 4e la plus absente 4.26 j). La **rétro-lecture** (lire une note d'autrui) est la 6^e école : 5 questions dans l'ordre (question, axe, couleur, échelle, n) départagent le **présentable** du **rejetable en présentation**. Et la transition vers M10 tient en une phrase : « Vos résultats sont justes. S'ils sont illisibles, ils ne serviront à rien. »

16. À retenir

À retenir. Le graphique se choisit **par question**, il se **légende** (question + source + n + axe déclaré), et la note d'EDA **garantit** — chaque affirmation est **sourcée** (re-jouable) et **limitée** (remplie). Le module s'arrête là : pas 40 graphiques jolis, **4 qui répondent** et **1 page qui garantit**.

1. **La question est dans le titre** — jamais dans un sous-titre : le titre **est** la question, la légende porte la source et le n.
2. **Les 5 erreurs ont 5 contrôles** : axe déclaré s'il n'est pas à zéro, graphique avec question, couleur avec légende, échelle log annoncée, nuage avec n.
3. **L'axe non zéro est légitime s'il est déclaré** — sur les données **relatives** (taux, part), zéro est l'axe **honnête** ; sur les **niveaux**, déclarer.
4. **matplotlib pour le projet, seaborn pour le confort** — le même boxplot en `ax.boxplot` ou `sns.boxplot` : dépendance minimale vs confort, les **mêmes** données.
5. **La note d'EDA garantit les limites** — phrase + source (re-jouable) + **limite** (remplie) : c'est la **limite** qui fait la différence (l'épreuve P2 la **note**).
6. **La rétro-lecture est l'école** — 5 questions dans l'ordre (question, axe, couleur, échelle, n) : on repère la **présentation** en défaut **sans** relancer le code.
7. **Le livrable du module** : 4 graphiques qui **répondent** + 1 page qui **garantit** — et la transition M10 : « Vos résultats sont justes. S'ils sont illisibles, ils ne serviront à rien. »

17. Évaluation formative (auto-correction, 8 min)

1. **Quelle question chaque graphique répond-il (courbe, barres, boxplot, histogramme, nuage) ?** → courbe = évolution (« ça monte, ça descend, ça cycle ? »), barres = comparaison (avec les n), boxplot = dispersion par groupe, histogramme = forme de la variable, nuage = association (avec le n) — le graphique se choisit **par question**, pas par joliesse. (2 pts)
2. **La courbe du CA mensuel est sur axe 310-350 M. C'est une erreur ?** → pas **si elle est déclarée** (« axe 310-350 M » dans le titre) ; c'est une erreur **silencieuse** sans déclaration — l'œil lit une onde là où il y a une série plate (320-337 M en bâche). L'axe non zéro est un **choix d'édition légitime**, jamais silencieux. (2 pts)
3. **Pourquoi le n est-il dans le titre du nuage (et la transparence mentionnée) ?** → 50 008 points **ou** 200 points ressemblent à la même bande : sans le **n**, le lecteur ne sait pas la taille de l'échantillon (échantillon **fantôme**) ; la transparence qui **masque** des points doit être **mentionnée** (0.25 ici). (2 pts)
4. **Les 6 ventes à 594 363 (C04) en histogramme log non annoncée : que se passe-t-il, et pourquoi ?** → le **plateau** du montant max se **lisse/disparaît** visuellement : l'échelle log (ratio ~780 des montants) **compresse** l'extrême — c'est un **choix d'édition** qui doit être **annoncé** (« axe log »), sinon c'est une distribution **cachée**. (2 pts)
5. **Quelle est la structure d'une affirmation de la note d'EDA ?** → **phrase** (ce qu'on dit) + **source** (la sortie exécutée, **re-jouable**) + **limite** (ce qu'elle **ne** dit pas, **remplie**) : la limite est le **contrôle** de l'affirmation — une limite vide = une affirmation qui **déborde** (reculée ou retirée). (2 pts)
6. **matplotlib vs seaborn : lequel pour le projet, et pourquoi les deux sont-ils documentés ?** → `matplotlib` est la **dépendance minimale** (le projet l'utilise : courbe, barres, nuage, boxplot pur `ax.boxplot`) ; `seaborn` est l'**option confort** (boxplot, heatmap des tableaux croisés) — les deux produisent le **même** boxplot sur les **mêmes** données, et on **documente** les deux. (2 pts)

7. **La rétro-lecture : les 5 questions, dans l'ordre ?** → (1) quelle **question** ce graphique répond-il ? (2) l'**axe** est-il à zéro ou **déclaré** ? (3) chaque **couleur** a-t-elle sa **légende** ? (4) l'**échelle** (log/lin) est-elle **annoncée** ? (5) le **n** est-il **dans le titre** (et la transparence mentionnée) ? — une note qui passe les 5 est **présentable**. (2 pts)
8. **Pourquoi l'épreuve de palier P2 note-t-elle la « limite » plutôt que le chiffre ?** → parce que les **chiffres** ont déjà été **vérifiés** par le protocole (C01-C05, autovalidés **--strict**) : ce qui reste à juger, c'est **l'honnêteté** — ce que l'affirmation **ne** dit pas. La **limite** est la signature de l'**analyste** (pas du stagiaire qui calcule), et c'est **elle** que le lecteur pressé **lit**. (2 pts)